■■■

第 34 章 美的集团（AI 研究院）：家电巨头的”VLA 论文工厂”——DiffusionVLA、DexVLA、ChatVLA 与 PointVLA
第 35 章 逐际动力（LimX Dynamics）：“模型只是技能，系统才是大脑”——COSA 具身智能体操作系统
第 36 章 北京人形机器人创新中心（X-Humanoid）：“天工”与”慧思开物”——国家级创新中心的开源大小脑
第 37 章 银河通用（Galbot）：“仿真合成数据派”的旗手，从十亿帧抓取到”银河星脑”
第 38 章 星动纪元（Robot Era）：清华交叉信息院的”视频预测派”——VPP、ERA-42 与 Ctrl-World
第 39 章 星海图（Galaxea）：开放世界数据 + 双系统 VLA，走向”原生动作思维链”与分布式真机强化学习
第 40 章 自变量机器人（X Square Robot）：从开源 WALL-OSS 到”世界统一模型”WALL-B
第 41 章 千寻智能（Spirit AI）：“脏数据”哲学、登顶 RoboChallenge，与 RoboArena 的 72 小时
第 42 章 智平方（AI² Robotics）：全域全身 VLA、“快在慢中”与类脑 NeuroVLA
第 43 章 它石智航（TARS）：“不仿真、不遥操、不是 VLA”——以人为中心数据训练的具身世界引擎 AWE
第 44 章 极佳视界（GigaAI）：世界模型”造数据”，再用世界模型”练策略”
第 45 章 原力灵机（Dexmal）：做行业的”度量衡”——RoboChallenge、Dexbotic 与具身原生模型 DM0
第 46 章 灵初智能（PsiBot）：灵巧手优先——从 DexGraspVLA 到人类手部数据驱动的 Psi-R2 与世界模型 Psi-W0
第 47 章 智在无界（BeingBeyond）：以人为中心的机器人学习——Being-H0 → H0.5 → H0.7
第 48 章 穹彻智能（Noematrix）：从 AnyGrasp、RH20T 到”零遥操作”的世界动作模型 Noe-0
第 49 章 地平线（Horizon Robotics）与地瓜机器人：智驾芯片巨头的”一个大脑，多种形态”——H-RDT、HoloMotion 与 HoloBrain
第 50 章 星尘智能（Astribot）：为 AI 而生的绳驱身体，与 Lumo 基座 + DuoCore 快慢双系统
第三部分（上）横向对比与身位矩阵
第三部分（下）趋势、预测与建议
附录

导读与方法论：如何读这份报告

> 报告名称：《人形机器人”大脑”全景深度报告：全球 50 家核心公司与机构的技术路线、代表作拆解与身位研判》 信息截止：2026 年 10 月 30 日（包含 2026 年 10 月 29 日智元 GO-3 Preview 等最新发布） 篇幅：50 个公司/机构章节 + 行业全景 + 横向对比 + 趋势展望 + 附录，约 85–90 万字

一、这份报告要回答什么问题

人形机器人行业在 2023–2026 年经历了一场”大脑革命”：机器人的控制方式从”工程师编程”转向”从数据中学习”，从”每个任务一个模型”转向”一个通用基础模型”，从”实验室演示”转向”真实工厂与家庭部署”。这份报告试图让读者在读完之后：

1. 理解整个行业：机器人大脑是怎么从 2016 年的抓取实验一路演化到 2026 年的世界动作模型的；今天的技术版图上有哪些流派、各自的核心主张是什么；
2. 深入理解每一家：50 家最重要的公司与机构，每家选取 3 篇最具代表性的论文、技术报告或开源项目，完整拆解其问题、方法、架构、数据、训练、结果、局限与意义；
3. 看清每一家的身位：它在全球格局中处于什么位置、领先在哪里、落后在哪里、和谁是同一路线、和谁是对立路线；
4. 判断未来：未来 12–36 个月哪些方向会胜出、哪些假设最需要验证、风险在哪里。

二、“机器人大脑”的定义与范围

本报告中的”大脑”采用广义定义，指让机器人感知世界、理解任务、规划行动、生成动作并在执行中持续改进的全部智能软件栈，按 2026 年的行业共识分为三层：

层级	俗称	职责	典型频率	代表技术
System 2	大脑	语义理解、推理、任务规划、记忆、工具调用、多机编排	0.5–10 Hz	VLM、具身推理模型（ER）、智能体 OS
System 1	小脑（操作）	把意图转为视觉运动动作（手臂、手、躯干）	10–200 Hz	VLA、扩散/流匹配动作专家、世界动作模型
System 0	小脑（运动）/ 脊髓	全身平衡、运动追踪、接触与安全反射	200–1000 Hz	强化学习全身控制器、运动追踪基础模型

由于”人形机器人大脑”与”通用机器人大脑”在技术上高度重合（大量关键工作首先在机械臂、双臂或轮式平台上验证，再迁移到人形），本报告不局限于双足人形，而是覆盖所有对人形大脑有直接影响的工作。

三、50 家的选择标准

入选标准为以下两条之一（用户要求：“大脑做得很好的，或者公司声量很大的”）：

- A. 大脑技术领先：有被广泛引用/使用的代表性论文、技术报告或开源项目，或在第三方评测中表现突出；
- B. 声量与产业影响力大：出货量、融资规模、客户部署、媒体与资本关注度位于行业前列。

在此基础上兼顾地域（美国、中国、欧洲/全球）、类型（前沿大脑公司、人形整机公司、科技巨头、基础设施/平台、学术机构）与技术路线的多样性。

50 家名单与分组

篇	章	公司/机构	类型
第一篇：全球前沿大脑	1	Google DeepMind	科技巨头 / 平台大脑
	2	Physical Intelligence（π）	纯大脑公司
	3	NVIDIA	全栈平台
	4	Skild AI	纯大脑公司
	5	Generalist AI	纯大脑公司
第二篇：美国人形整机	6	特斯拉 Optimus	整机
	7	Figure AI	整机
	8	1X Technologies	整机（家用）
	9	Boston Dynamics	整机
	10	Agility Robotics	整机（物流）
	11	Sunday Robotics	整机（家用）
第三篇：科技巨头与基础设施	12	Meta（FAIR）	科技巨头 / 研究
	13	Amazon（FAR / Covariant 一脉）	科技巨头 / 超级用户
	14	Hugging Face（LeRobot）	开源生态
	15	丰田研究院（TRI）	产业研究院
	16	Genesis AI	仿真 + 全栈
第四篇：学术策源地	17	斯坦福大学	学术
	18	UC Berkeley	学术
	19	卡内基梅隆大学	学术
	20	UC San Diego	学术
	21	清华大学	学术
	22	香港大学	学术
	23	上海人工智能实验室	国家实验室
	24	北京智源人工智能研究院	研究院
第五篇：中国科技大厂	25	字节跳动 Seed	大厂
	26	阿里巴巴（达摩院 + 通义）	大厂
	27	蚂蚁集团·灵波科技	大厂
	28	腾讯（Robotics X + 混元）	大厂
	29	小米	大厂 / 整机

篇	章	公司/机构	类型
	30	小鹏汽车	车企 / 整机
第六篇：中国人形整机与国家平台	31	宇树科技	整机
	32	智元机器人	整机
	33	优必选	整机
	34	美的集团（AI 研究院）	制造巨头研究院
	35	逐际动力	整机
	36	北京人形机器人创新中心	国家/地方创新平台
	37	银河通用	整机 + 大脑
	38	星动纪元	整机 + 大脑
第七篇：中国具身大脑创业公司	39	星海图	大脑 + 本体
	40	自变量机器人	大脑 + 本体
	41	千寻智能	大脑 + 本体
	42	智平方	大脑 + 本体
	43	它石智航	大脑 + 数据
	44	极佳视界	世界模型 + 大脑
	45	原力灵机	评测 + 工具 + 大脑
	46	灵初智能	灵巧手大脑
	47	智在无界	人类视频大脑
	48	穹彻智能	大脑 + 数据
	49	地平线 / 地瓜机器人	芯片 + 平台 + 大脑
	50	星尘智能	整机 + 大脑

未单列但在正文中涉及的玩家：OpenAI（2026 年确认自研人形，见第 6、7、19 章）、Apptronik（Gemini Robotics 合作伙伴，见第 1 章）、傅利叶（GR-1 曾用于 GR00T N1 数据采集，见第 3、20 章）、Covariant（并入第 13 章）、Walden Robotics（TRI 分拆，见第 15 章）、Dyna Robotics、乐聚、加速进化、众擎、帕西尼等。

四、每章的统一结构

每个公司/机构章节采用相同的结构，便于横向阅读：

0. 速览卡片：成立、核心人物、融资/资本、产品、模型谱系、开放程度、三篇代表作、身位一句话；
1. 故事的开端：创始逻辑、历史背景、核心判断； 2–4. 三篇代表作的完整拆解：问题 → 核心思想 → 架构（常附结构示意图）→ 数据 → 训练 → 推理/部署 → 结果 → 局限 → 意义；
2. 技术路线总结：把三篇代表作串成一条演进线；
3. 横向对比与身位：与同类/对手的对比表与身位判断；
4. 未来展望与风险；

5. 延伸阅读与核验来源：论文/博客/新闻链接 + 核验说明（明确哪些是论文事实、哪些是公司口径、哪些是二手信息、哪些存在冲突）。

五、核验方法与信息可靠性分级

5.1 研究过程

- 以论文原文的已知内容为基础，对 2025 年下半年至 2026 年 10 月的每一项关键事实，通过网络检索进行多源交叉核实；
- 对每家公司至少进行 2–4 轮检索，重点核实：模型名称与发布日期、参数规模与架构要点、数据规模、关键评测数字、融资与商业化数据。

5.2 本报告的信息分级（读者请务必注意）

等级	含义	在正文中的表述
A：论文/官方技术报告事实	来自同行评审论文、arXiv 技术报告、官方技术博客的明确陈述	直接陈述
B：多源一致的官方发布	公司新闻稿、发布会内容，多家主流媒体一致报道	直接陈述，必要时注明”公司称”
C：公司自报的评测与宣称	“全球第一”“登顶”“超越 X”等公司自评或榜单宣称	标注”公司口径”“宣称”“未见独立验证”
D：单一来源/二手解读	仅见于单一媒体、聚合网站、二手论文解读	标注”据单一来源”“二手资料”“未经核实”
E：本报告的分析与推断	作者基于公开信息的分析	明确标注”本报告分析”“推测”

特别提醒： 1. 2026 年具身智能行业存在大量营销性榜单与”全球第一”宣称（参见第 41 章 RoboArena 事件），本报告对此类信息一律降级处理； 2. 部分 2026 年的模型（如 Gemini Robotics 2、GO-3 Preview、Noe-0、Skild S1、GEN-1.5）尚无完整技术报告，本报告不对其内部结构做无依据的推测； 3. 本次研究环境中无法直接访问部分网站原文（如 arXiv 全文页面、部分公司官网），事实核验主要依靠检索引擎提供的原文摘录与多源比对完成；对于未能逐字核实的数字，正文均已注明。

六、阅读路径建议

读者类型	建议路径
想快速建立全局认知	本导读 → 第 01 章行业全景 → 第 90 章横向对比 → 第 91 章趋势展望
投资人 / 产业决策者	第 01 章 → 第 90 章 → 第 91 章 → 重点公司章节（第 2、3、7、31、32 章等）的”速览卡片 + 身位 + 风险”
研究者 / 工程师	第 01 章第三节（技术构件）→ 按技术路线阅读各章”代表作拆解”（如 VLA：第 1、2、17、21、25 章；世界模型：第 3、8、12、38、44、47 章；全身控制：第 7、9、19、20 章；人类数据：第 5、11、20、43、47 章）

读者类型	建议路径
只关心中国格局	第 01 章第七节 → 第 21–50 章 → 第 90 章中国部分
只关心美国格局	第 1–20 章 → 第 90 章

七、文件结构

```
report/
├── 00_导读与方法论.md            ← 本文件
├── 01_行业全景.md                ← 技术演进史、技术构件、数据、评测、算力、产业格局
├── 02_技术专题深潜.md            ← 十个技术专题：从张量级数据流到评测统计
├── chapters/
│   ├── 01_Google_DeepMind.md
│   ├── 02_Physical_Intelligence.md
│   ├── …（共 50 章）
│   └── 50_Astribot.md
├── 90_横向对比与身位矩阵.md      ← 50 家一表、路线谱系、分维度横评
├── 91_趋势与未来展望.md          ← 2026 十大趋势、2027– 2029 预测、风险、给不同读者的建议
└── 99_附录.md                    ← 大事年表、150 项代表作索引、术语表
```

第一部分 行业全景：机器人大脑的十年演进、技术构件与产业格局

> 本章是整份报告的”地图”。读完本章，读者应能把 50 家公司的任何一篇代表作，放到正确的历史位置与技术坐标上。

一、一句话讲清楚：机器人大脑这十年发生了什么

> 2016 年，机器人靠工程师写控制器、靠数十万次试错学一个抓取动作；2023 年，RT-2 让一个视觉语言大模型直接”说出”机器人动作；2024 年，π0 把扩散/流匹配动作专家接到大模型上，机器人第一次能稳定叠衣服；2025 年，Helix、GR00T 把”慢思考 + 快执行”的双系统装进人形机器人，世界模型开始被用来造数据和做评估；2026 年，三层大脑（推理-动作-全身控制）成为共识，VLA 与世界模型开始融合，机器人第一次出现了”看一段视频就会做”的上下文学习，以及在数十户陌生家庭中零样本做家务的能力——但最好的系统在真实复杂家务上的完整成功率，仍然只有 10%–60%。

二、十年演进史：七个时代

时代 0（2010 年代中期以前）：编程的身体

传统机器人（包括 2013–2023 年液压 Atlas 的大部分惊艳表演）依靠模型预测控制（MPC）+ 轨迹优化 + 手工状态机。工程师为每个动作设计目标、约束与代价函数。优点是精确、可解释、动态性能强；缺点是每个新任务都需要专家手工设计，无法扩展到开放世界的成千上万种日常任务。（参见第 9 章 Boston Dynamics）

时代 1（2015–2019）：深度强化学习与”手臂农场”

- 端到端视觉运动策略（Levine 等，2015）首次让神经网络从像素直接输出电机指令；
- Google 的”手臂农场”与 QT-Opt（2018）：7 台机械臂、约 58 万次真实抓取、离线 Q 学习，抓取成功率约 96%（第 1 章）；
- CMU 的”50K 次尝试、700 机器人小时”（Pinto & Gupta，2016）（第 4、19 章）；
- 仿真到真实的强化学习在足式机器人上取得突破：ETH ANYmal、Berkeley/OSU 的 Cassie（第 10、18 章）。

教训：RL 能学会单一技能，但一个技能就要几十万次试错，无法规模化到通用操作；而运动控制（locomotion）则在”仿真 RL + sim2real”上找到了可规模化的道路——这条路后来成为人形”小脑”的基础。

时代 2（2021–2022）：语言进入机器人

- SayCan（Google，2022）：LLM 判断”说得通吗”，价值函数判断”做得到吗”（第 1 章）；
- Inner Monologue、Code as Policies、Socratic Models：语言成为机器人的”思维载体”（第 5 章 Andy Zeng）；

- RT-1（Google，2022.12）：13 万条示范、700+ 条指令训练一个 3500 万参数的 Transformer——“Transformer 吃下动作”（第 1 章）。

教训：LLM 能做高层规划，但底层动作仍需要独立训练的策略；数据的多样性比数量更影响泛化。

时代 3（2023）：VLA 诞生与开源联邦

- RT-2（2023.07）：“动作就是语言”——把动作离散化为 token，与网络数据协同微调 55B VLM，语义泛化翻倍（第 1 章）；
- Open X-Embodiment（2023.10）：21 家机构、22 种本体、100 万+ 轨迹——机器人领域第一个”联邦数据集”（第 1 章）；
- ALOHA / ACT（斯坦福，2023）：低成本双臂遥操作 + 动作分块，10 分钟数据学会精细双臂任务（第 11、17 章）；
- Diffusion Policy（哥大/TRI/MIT，2023）：用扩散模型表达多模态动作分布（第 15 章）；
- GR-1（字节，2023.12）：视频生成式预训练提升机器人操作（第 25 章）。

这一年确立了此后三年的两条主线：RT-2 解决了”语义从哪来”（继承互联网 VLM），ACT 与 Diffusion Policy 解决了”动作怎么生成”（动作分块 + 生成式动作模型）。

时代 4（2024）：开源 VLA 与”大模型 + 动作专家”

- Octo（Berkeley 等，2024.05）：开源通才策略，模块化、扩散头（第 18 章）；
- OpenVLA（斯坦福等，2024.06）：开源 7B VLA，超越 55B 的 RT-2-X（第 17 章）；
- UMI（2024）：无本体手持采集，硬件无关（第 11 章）；
- RDT-1B（清华，2024.10）：12 亿参数双臂扩散基础模型，物理可解释统一动作空间（第 21 章）；
- π0（PI，2024.10）：VLM + 流匹配动作专家，50Hz 动作块，叠衣服——确立了此后两年主流 VLA 的标准架构（第 2 章）；
- GR-2（字节，2024.10）：3800 万视频片段的网络规模视频-语言-动作模型（第 25 章）；
- 人形 RL 与动作追踪：Berkeley 的 Transformer 人形运动（第 18 章）、CMU 的 H2O/OmniH2O（第 19 章）、UCSD 的 ExBody/Open-TeleVision（第 20 章）、斯坦福 HumanPlus（第 17 章）。

时代 5（2025）：双系统人形、世界模型兴起、RL 进入 VLA

- Helix（Figure，2025.02）：S2（7B VLM，7–9Hz）+ S1（80M，200Hz），首个控制人形全上半身的 VLA（第 7 章）；
- GR00T N1（NVIDIA，2025.03）：开源人形双系统 + 数据金字塔（第 3 章）；
- Gemini Robotics / ER（DeepMind，2025.03）→ 1.5（2025.09，思考型 VLA + Motion Transfer）（第 1 章）；
- π0.5（2025.04）：异构数据协同训练，走进陌生家庭（第 2 章）；
- GO-1 / AgiBot World（智元，2025.03）、GraspVLA（银河，2025.01）、G0（星海图，2025.08）等中国 VLA 集中涌现（第 32、37、39 章）；
- Cosmos（NVIDIA，2025.01）、V-JEPA 2（Meta，2025.06）、Genie Envisioner（智元，2025.08）、WorldVLA（阿里，2025.06）：世界模型进入机器人（第 3、12、32、26 章）；

- 全身控制基础模型：Atlas LBM（BD+TRI，2025.08）、Agility 全身控制模型、SONIC（NVIDIA，2025.11）（第 9、10、3 章）；
- RL 进入大 VLA：π*0.6 / RECAP（2025.11）、GR-RL（字节，2025.12）（第 2、25 章）；
- 缩放定律：GEN-0（27 万小时，2025.11）、清华数据缩放定律（ICLR 2025）（第 5、41 章）。

时代 6（2026）：三层大脑共识、VLA × 世界模型融合、上下文学习、部署态

- 全身自主：Helix 02（S0/S1/S2，2026.01）、Gemini Robotics 2（全身 + 五指手，2026.07）（第 7、1 章）；
- 世界动作模型：DreamZero → GR00T N2（NVIDIA，2026.02/03）、1XWM（2026.01）、GO-3 Preview / WRAM（智元，2026.10）、UnifoLM-WLA-1.0（宇树，2026.09）、WALL-B（自变量，2026.04）、Being-H0.7（智在无界，2026.04）、RoboJEPA（Meta，2026.10）（第 3、8、32、31、40、47、12 章）；
- 可引导与组合泛化：π0.7（2026.04）（第 2 章）；
- 上下文学习：Skild S1（视频提示，10 分钟任务）、GEN-1.5（3–12 秒示范，一次学会）（第 4、5 章）；
- 家庭零样本：Helix 2.5（30 户陌生家庭，56%）（第 7 章）；
- 大规模人类/无本体数据：Generalist 50 万小时+、Xiaomi-Robotics-1 10 万小时 UMI、它石百万小时（宣称）、Being-H0.7 20 万小时人类视频、Noe-0 零遥操作（第 5、29、43、47、48 章）；
- 部署态与量产：智元 2 万台下线、宇树科创板上市、特斯拉弗里蒙特产线早期生产、Figure 03 进驻宝马、1X NEO 量产（第 32、31、6、7、8 章）；
- 评测时代与信任危机：RoboChallenge、RoboArena、BEHAVIOR Challenge；Spirit v1.6 事件（第 45、41、17 章）。

三、技术构件拆解：一个 2026 年的机器人大脑由什么组成

3.1 总体架构：三层大脑

```
┌──────────────────────────────────────────────────────────────────────────────┐
│ System 2：推理与编排（大脑）                                                 │
│ · 具身推理 VLM / ER 模型：空间理解、指点、轨迹、任务进度、工具调用           │
│ · 智能体 OS：记忆、技能调度、多机协同、异常处理                              │
│ · 代表：Gemini Robotics-ER、RoboBrain、RynnBrain、Robix、COSA、RxBrain       │
├──────────────────────────────────────────────────────────────────────────────┤
│ System 1：视觉运动策略（操作小脑）                                           │
│ · VLA：VLM 主干 + 动作专家（扩散/流匹配/自回归）                             │
│ · 世界动作模型（WAM）：视频/潜空间世界模型 + 动作联合生成                    │
│ · 代表：π 系列、GR00T、Helix S1、GO 系列、GO.5、DreamZero、1XWM              │
├──────────────────────────────────────────────────────────────────────────────┤
│ System 0：全身控制（运动小脑 / 脊髓）                                        │
│ · 运动追踪基础模型、RL 全身控制器、安全反射层                                │
```

```
| · 代表：Helix S0、SONIC、HOVER、BFM-Zero、HoloMotion、Agility WBC        |
└──────────────────────────────────────────────────────────────────────────┘
```

为什么是三层（详见第 7 章 4 节分析）： 1. 频率的物理约束：语义推理需要数十亿参数，只能低频；全身平衡需要 1kHz 级反应，只能用小网络； 2. 数据来源不同：S0 可以在仿真中大规模 RL；S1/S2 需要真实视觉与语义数据； 3. 可解释与可控：分层让每层可以独立评测、升级与安全认证。

也存在反对三层的声音：Generalist 的"和声推理"主张取消系统 1/2 的划分（第 5 章）；自变量 WALL-B 主张单网络统一（第 40 章）；小鹏 VLA 2.0 去掉语言转译（第 30 章）。

3.2 VLM 主干：大脑的"语义来源"

主干家族	代表用户	特点
Gemini（闭源）	DeepMind	最强综合能力，云端 + 蒸馏
PaliGemma / Gemma 3	PI（π0 → π0.6/0.7）、XR-1（二手）	小而精，开源
Qwen2.5-VL / Qwen3-VL	小米、宇树、字节 GR-3/GR-RL、阿里 RynnBrain、NVIDIA N1.7（Cosmos-Reason2 基于 Qwen3-VL 架构）、上海 AI Lab、优必选 Thinker、原力灵机 DM0（Qwen3-1.7B）	2026 年最广泛使用的开源具身 VLM 底座
InternVL	智元 GO-1、上海 AI Lab	国内开源
Eagle / Cosmos Reason	NVIDIA GR00T	自研
Llama 2 + Prismatic	OpenVLA	早期开源
SmolVLM	Hugging Face SmolVLA	极小
不用 VLM（视频模型为主干）	NVIDIA DreamZero（Wan2.1-14B）、1XWM（14B 视频模型）	世界模型派
从零联合训练	自变量 WALL-B（据报道）	统一模型派

一个关键工程发现：取 VLM 的中间层而非最后一层特征给动作专家（GR00T N1、SmolVLA），往往更快、更好——因为最后几层过度特化于生成文本。

3.3 动作表示：机器人大脑的"输出语言"

表示方式	原理	代表	优缺点
均匀离散 token	每维 256 桶	RT-1、RT-2、OpenVLA	简单、与 LLM 统一；精度差、慢
频域压缩 token（FAST）	DCT + BPE	π0-FAST、π0.5 预训练、G0 阶段一	训练快、信息密；推理需解码较多 token
学习式量化（VQ/RVQ）	VQ-VAE 学习码本	RDT2（RVQ）、WALL-OSS-0.5（视觉对齐 RVQ）	紧凑、可学习
潜在动作	从视频相邻帧学习离散码	GR00T N1（LAPA）、UniVLA、GO-1、XR-1（UVMC）、WholeBodyVLA	让无标签视频可用

表示方式	原理	代表	优缺点
扩散	从噪声迭代去噪	Diffusion Policy、Octo、RDT、DexVLA、Atlas LBM	多模态表达力强；步数多
流匹配	学习噪声到动作的速度场	π0 系列、GR00T、Xiaomi-Robotics-0、GR-3、DM0	2025–2026 主流，步数少、稳定
连续回归	MLP 直接回归	OpenVLA-OFT	快，但难表达多模态
与视频联合生成	动作作为视频去噪的一个模态	DreamZero、GR-1/2	继承视频物理先验；算力高
从生成视频反推（IDM）	生成未来视频 → 逆动力学	1XWM、Vidar、DreamGen	可利用视频模型；物理一致性风险

2026 年的主流配方："离散 token 预训练（FAST/RVQ）让 VLM 学会动作表征 + 流匹配动作专家输出连续动作 + 梯度隔离/桥接保护 VLM 能力"（π0.5/KI、RDT2、WALL-OSS-0.5、DM0）。

3.4 动作分块与实时执行

- 动作分块（Action Chunking）：一次预测未来 H 步（ACT 100 步、π0 50 步、GR00T 16 步、FiS-VLA 8 步），降低复合误差、表达时间结构（第 11 章）；
- 时间集成 / 滚动时域：ACT 的时间集成、Diffusion Policy 的 T_o/T_p/T_a 设计（第 15 章）；
- 异步执行：推理与执行并行——PI 的 RTC、HF SmolVLA 异步推理、Xiaomi-Robotics-0 的"干净动作前缀 + Λ 形注意力掩码"（第 29 章）。

3.5 跨本体：一个大脑如何驱动多种身体

方案	代表	机制
零填充统一维度	π0	动作/状态零填充到最大维度
物理可解释统一空间	RDT-1B	128 维，每维有物理含义
本体专属编解码器	GR00T N1	每种本体一个 MLP，共享 DiT 主干
Motion Transfer	Gemini Robotics 1.5	跨 ALOHA/Franka/Apollo 学习共享运动规律
本体先验输入	HoloBrain-0	相机参数 + URDF 作为输入
TVI token	NavFoM	相机视角与任务时间作为标识 token
抽象物理操作	银河 AstraBrain WAM	把动作抽象为"抓取、推拉"
统一动作空间 + 稀疏专家	Being-H0.5	人手与多种机器人共享空间，MoE 专家
上下文适应	Skild Brain	从交互历史中在线推断身体
多头动作专家	DexVLA	每种本体一个头

3.6 思维链：机器人"先想后做"的三种载体

载体	代表	优势
自然语言	RT-2 CoT、Gemini Robotics 1.5 思考型 VLA、π0.5 高层子任务、ChatVLA-2、DM0 思考模式	继承 LLM 推理能力、可解释

载体	代表	优势
图像（子目标）	π0.7（世界模型生成子目标图像）、腾讯 RxBrain	比语言更精确的视觉目标
动作	智元 GO-2 动作思维链、星海图 G0.5 原生动作思维链、灵初 Psi-R1 CoAT	绕开语言对物理量的表达瓶颈
空间	InternVLA-M1 空间提示、DM0 具身空间脚手架、RoboBrain 2.5 3D 推理	精确的空间定位与关系推理

3.7 记忆

长时程任务（收拾整个厨房、长流程装配）需要记忆：- PI MEM（2026.03）：短时视频记忆 + 长时文本记忆，支持约 15 分钟的整厨清洁（第 2 章）；- 阿里 RynnBrain：时空记忆，被打断后可恢复原任务（第 26 章）；- 它石 AWE 3.5：长时记忆与长时序空间理解（第 43 章）；- 智源 RoboOS：跨机器人共享空间/时间/本体记忆（第 24 章）；- GEN-1.5：约 30 秒上下文；Skild S1：长达约 10 分钟的视频上下文。

3.8 世界模型：四种流派

流派	原理	代表	在机器人中的角色
像素/视频生成 + 逆动力学	生成未来视频，再反推动作	1XWM、Vidar、DreamGen	策略 / 数据生成
视频-动作联合生成（WAM）	动作作为视频去噪的一个模态	DreamZero / GR00T N2、GR-1/2、WorldVLA	策略
视频扩散特征作为表征	只取视频模型中间特征，不生成	VPP（星动纪元）	策略的视觉主干
隐式 / 潜空间预测（JEPA 式）	在表征空间预测未来，不生成像素	V-JEPA 2、RoboJEPA（Meta）、Being-H0.7、宇树 WLA（动态区域）	规划器 / 策略
动作条件神经模拟器	以动作为条件生成未来观察，闭环运行	特斯拉神经世界模拟器、Ctrl-World、GE-Sim、LingBot-World、Genie 3、WALL-SS	评估、数据生成、RL 训练场
事件级	以事件而非帧为单位预测	自变量 WALL-WM	高效策略 / 规划

2026 年的共识：世界模型在机器人中有五种用途——①造数据（Cosmos、GigaWorld-0）②评估策略（1X、Ctrl-World、GE-Sim）③强化学习训练场（AWE 3.5、GigaBrain-0.5M*、WALL-SS、特斯拉）④生成子目标（π0.7、RxBrain）⑤直接作为策略（DreamZero、1XWM、WRAM）。

3.9 全身控制：人形的"小脑与脊髓"

2025–2026 年形成的标准范式是"动作追踪 + 仿真 RL + 零样本 sim2real"：1. 数据：人类动捕（AMASS、LAFAN1）+ 视频重建动作（HoloMotion、VideoMimic）；2. 重定向：保留交互关系的高质量重定向（OmniRetarget）；3. 训练：大规模并行仿真 RL，域随机化，特权教师 → 学生蒸馏（H2O）；4. sim2real 对齐：差分动作模型（ASAP）；5. 提示接口：行为基础模型（Meta Motivo、BFM-Zero）可被动作、目标、奖励提示；6. 残差精修：在通用追踪器上叠加残差策略完成物体交互（ResMimic）；7. 安全反射：Agility"运动皮层"、智平方 NeuroVLA 的 SNN 脊髓层。

代表	机构	规模 / 频率	训练信号
Helix 02 S0	Figure	约 1000 万参数 / 1kHz	1000+ 小时人类动作 + RL
SONIC	NVIDIA	120 万–4200 万参数	700 小时动捕
Agility WBC	Agility	<100 万参数	仿真 RL
HoloMotion	地平线	约 4 亿（第三方）	视频重建动作为主
BFM-Zero	CMU + Meta	—	无监督 RL（FB 表征）
Atlas RL	BD + RAI	—	动捕 + 每技能约 1.5 亿次仿真

3.10 强化学习后训练：超越模仿

方法	机构	核心思想
HIL-SERL	Berkeley	示范 + 奖励分类器 + 人在环路纠正，1–2.5 小时近 100%
RECAP（π*0.6）	PI	价值函数 + 优势条件化策略，把 RL 变为条件化监督学习
GR-RL	字节	离线 RL 过滤数据 + 形态对称增强 + 在线潜空间探索
DPPO	北京人形（Pelican-VL）	RL 精炼 → 诊断 → 针对性 SFT 循环
RAMP	极佳（GigaBrain-0.5M*）	世界模型条件策略的 RL
模型内 RL	它石 AWE 3.5	在生成的可交互世界中 RL
分布式真机 RL	星海图 G-Fleet	车队级部署-交互-回流-训练闭环
价值/进度模型	DeepMind ER 2、RoboBrain 2.5	为 RL 提供通用奖励/进度信号

四、数据：一切的燃料

4.1 六种数据来源

来源	成本	规模潜力	本体对齐	代表
机器人遥操作	高（设备 + 人力）	低–中	完美	PI、智元 AgiBot World、Figure（早期）、Gemini（ALOHA 车队）
无本体手持/穿戴采集（UMI/手套）	低–中	中–高	需对齐（设计接口一致）	UMI、Sunday 手套、小米（10 万小时 UMI）、RDT2、穹彻 RoboPocket
人类第一视角视频	低	极高	形态鸿沟大	Figure Index/Go-Big、特斯拉、智在无界、UCSD PH2D、EgoDex、它石、Generalist
仿真合成	极低（GPU）	极高	sim2real 鸿沟	银河 SynGrasp-1B、上海 AI Lab InternData、Genesis、RoboTwin、DexMimicGen

来源	成本	规模潜力	本体对齐	代表
世界模型生成	低（GPU）	高	物理一致性风险	Cosmos、DreamGen、GigaWorld-0
部署回流	部署即采集	随出货量增长	完美	特斯拉（未来）、智元（2 万台）、银河（8 万小时回流）、Figure BMW、PI RECAP

4.2 数据规模对照（公开宣称，口径不一，仅供量级参考）

时间	数据集/公司	规模	类型
2018	QT-Opt	约 58 万次抓取	真机 RL
2022	RT-1	13 万条示范	遥操作
2023	OXE	100 万+ 轨迹	多机构联邦
2024	π0	约 1 万小时	遥操作
2025	AgiBot World	100 万+ 轨迹（约 3000 小时）	遥操作
2025	SynGrasp-1B	十亿帧	仿真
2025.11	GEN-0	27 万小时+	人类交互
2026.01	LingBot-VLA 1.0	2 万小时	多构型真机
2026.01	Being-H0.5	约 3.5 万小时（人 + 机）	混合
2026.02	RDT2	1 万小时+	UMI
2026.04	GEN-1	50 万小时+	人类交互
2026.04	Being-H0.7	约 20 万小时	人类视频
2026.07	LingBot-VLA 2.0	6 万小时	多构型真机
2026.07	Xiaomi-Robotics-1	10 万小时 UMI + 1 万小时跨本体	UMI + 真机
2026.07	Tencent RxBrain	5 万小时+	具身数据
2026	它石 AWE	100 万小时（宣称），目标千万小时	人类 + 触觉
2026	银河通用	100 万小时人类 + 8 万小时回流（宣称）	混合
2026.08	Figure Index	约每秒 35 分钟人类经验（宣称）	人类第一视角
2026	穹彻 Noe-0	十万小时级家庭数据，47 城（宣称）	无本体

观察：2024 年行业数据规模在万小时量级；2026 年头部玩家宣称的数据规模达到十万到百万小时量级——两年增长约两个数量级。增长几乎全部来自人类/无本体数据，而非机器人遥操作。

4.3 缩放定律的证据

1. 数据多样性缩放：清华《模仿学习数据缩放定律》——泛化与环境数、物体数呈幂律（第 41 章）；π0.5——训练家庭数从少到约 100，陌生家庭表现持续上升（第 2 章）；
2. 真实数据规模缩放：GEN-0——预训练数据与算力增加带来可预测的下游提升，小模型会"僵化"（第 5 章）；Xiaomi-Robotics-1——宣称首次系统验证（第 29 章）；
3. 世界模型缩放：RoboJEPA——想象误差随模型规模呈二阶幂律下降（第 12 章）；
4. 运动控制缩放：SONIC——网络与动捕数据规模扩大带来追踪能力提升（第 3 章）；银河 WBC 0.5 宣称（第 37 章）；
5. 反例与条件：π0.7——不加元数据时，混合质量数据越多可能越差（第 2 章）；TRI LBM——不微调的多任务模型不一定优于单任务（第 15 章）。

五、评测：从演示视频到榜单时代

5.1 主要基准

类型	基准	特点	2026 年代表成绩（口径各异）
仿真	LIBERO	桌面操作，已接近饱和	98%–99%（Xiaomi-Robotics-0 98.7%、Being-H0.5 98.9%、GO-2 98.5%、InternVLA-M1 空间 98.0%）
仿真	CALVIN	长程语言条件操作	VPP、GR-1 等显著提升
仿真	SimplerEnv	真实-仿真对齐评测	InternVLA-M1 等
仿真	RoboCasa / RoboCasa365	厨房移动操作	Xiaomi-Robotics-1 74.5%（RoboCasa）
仿真	RoboTwin 2.0	双臂、强随机化	多家宣称 SOTA
仿真	RoboDojo	困难长程	Xiaomi-Robotics-1 13.93%；GO-3 Nano Preview 56.42%（口径待核）
仿真	BEHAVIOR Challenge	50 个完整家务	2025 冠军完整成功率约 12.4%
仿真	VLABench、GenieSim	综合	—
真机	RoboChallenge（Table30 等）	第三方统一真机	Spirit v1.5 50.33%；DM0 双项第一
真机	RoboArena	众包成对比较	2026.06 操纵事件
真机	GM-100	100 项真实任务，跨本体	LingBot-VLA 15.7%/17.3% vs π0.5 13.0%
真机	MolmoSpaces（AI2）	第三方	Psi-R2 46.4%
真机	Figure 30 户家庭	公司自评、严格整任务	Helix 2.5 56% vs 9%
世界模型	WorldArena、EWMBench	世界模型质量	多家宣称第一
推理	ERQA、Point-Bench、RefSpatial 等	具身推理	Gemini Robotics-ER 系列领先

5.2 评测的四个结构性问题

1. 仿真基准饱和：LIBERO 已普遍 98%+，区分度消失；
2. 真机评测噪声大：TRI 研究显示，小样本真机评测的方差远大于论文报告的提升（第 15 章）；
3. 榜单碎片化与营销化：几乎每家都能在某个榜单"登顶"；
4. 众包可操纵：RoboArena 事件（第 41 章）。

本报告的建议：优先相信 ①严格定义的整任务成功率（如 Figure 30 户家庭、BEHAVIOR 完整成功率）②第三方、盲测、大样本的评测 ③真实商业部署的可靠性数据（如 Generalist 宣称的 99%、千寻宁德时代的 >99%、GO-2 龙旗产线 99.5%——但这些也多为公司口径）。

六、算力：从云端到端侧

层级	代表	说明
训练	NVIDIA H100/B200 集群；特斯拉 Cortex；小鹏 3 万卡；国产摩尔线程 MTT S5000 千卡（RoboBrain 2.5）	数据与模型规模快速增长，训练算力需求随之上升
云端推理	Gemini Robotics 云端骨干	网络依赖是硬伤
端侧推理	NVIDIA Jetson Thor；特斯拉 AI4/AI5；小鹏 3 颗图灵芯片（约 2250 TOPS）；地瓜 RDK S600；Figure 双嵌入式 GPU	2026 年主流 VLA 在端侧可达 30–200Hz；14B 世界模型仍需高端端侧算力

趋势：世界动作模型（14B 级）的兴起对端侧算力提出更高要求（利好 NVIDIA、特斯拉 AI5、地平线等）；同时，小模型路线（SmolVLA 0.45B、HoloBrain-0 0.2B、DM0 2.4B、Being-H-Flash）在为端侧部署寻找"够用"的平衡点。

七、产业格局：中美两极与资本洪流

7.1 中美对比

维度	美国	中国
前沿大脑公司	PI、Skild、Generalist、DeepMind（平台）	星海图、自变量、千寻、智平方、它石、极佳、原力灵机、灵初、智在无界、穹彻
整机	特斯拉、Figure、1X、BD、Agility、Apptronik、Sunday	宇树、智元、优必选、银河、星动纪元、逐际、小米、小鹏、星尘……
出货量	百台到千台级	2026 年上半年中国人形出货近 2 万台（IDC）；智元、宇树领跑全球
开源	PI（上一代）、NVIDIA、HF、Meta	极其积极：宇树、智元、阿里、蚂蚁、小米、上海 AI Lab、智源、星海图、自变量、千寻、原力灵机、智在无界等
学术	斯坦福、Berkeley、CMU、UCSD 等策源地	清华、北大、上海交大、港大等快速崛起，顶会论文数量大幅增长
底座模型	Gemini、Gemma、Llama	Qwen 成为全球具身 VLM 最常用底座之一

维度	美国	中国
资本	单家估值高（Figure 390 亿美元、PI 110 亿美元+、Skild 140 亿美元+）	融资频繁、单轮规模快速上升（它石 4.55 亿美元、星动纪元年内近 50 亿元）；宇树科创板上市（2026.08）、智元控股上市公司
核心优势	前沿模型、数据规模（Generalist）、平台生态（NVIDIA）	硬件供应链与成本、出货量、开源速度、工厂场景
核心短板	硬件成本、量产规模	高端算力受限、前沿基础研究深度、评测公信力

7.2 六大技术路线流派（2026）

流派	核心主张	代表
VLA 主流派	VLM + 动作专家，数据多样性 + 后训练	PI、DeepMind、Figure、智元（GO 线）、星海图、千寻、小米
世界模型派	机器人大脑的母体应是”预测世界”的模型	NVIDIA（DreamZero/N2）、1X、极佳、星动纪元、智在无界、Meta（JEPA）
人类数据派	规模化数据来自人类，而非遥操作	Generalist、它石、Sunday、Figure（Index）、特斯拉、智在无界、灵初、小米（UMI）、穹彻
仿真/合成派	仿真与合成数据是规模化之路	银河通用、Genesis、上海 AI Lab、NVIDIA（Cosmos/Isaac）
系统/OS 派	模型只是技能，系统才是大脑	逐际 COSA、智源 RoboOS、阿里 RynnRCP、腾讯 Tairos、优必选 Co-Agent、智元 Genie Master
统一模型派	单网络统一视觉、语言、动作、物理	自变量 WALL-B、Generalist（和声推理）、小鹏 VLA 2.0、智元 WRAM

（各流派之间并非互斥——大多数头部公司在 2026 年同时布局多条路线。）

7.3 商业化阶段（2026 年 10 月）

场景	阶段	代表
汽车/3C 制造	试点 → 早期规模化	优必选（多家车企）、Figure（宝马）、小米（自家工厂）、BD（现代，2028 规模化）、它石/千寻（线束）、特斯拉（自家工厂）
物流仓储	付费部署	Agility（GXO）、星动纪元（顺丰、邮政）、智元
零售/商业服务	试点	银河通用（太空舱）、腾讯 + 宇树（文旅、商场）
科研教育	成熟	宇树（全球最常用研究平台）、HF（SO-101）

场景	阶段	代表
家庭	早期（遥操作兜底 / 小规模部署）	1X NEO、自变量（与 58 同城）、Sunday Memo、Figure Helix 2.5（研究）

八、本章小结：读懂后续 50 章的五把钥匙

1. 语义从哪来：互联网 VLM（RT-2 以来的共识），但 2026 年出现了”视频模型为母体”“从零联合训练”的挑战；
2. 动作怎么生成：流匹配动作专家是主流，世界模型联合生成是新潮；
3. 数据从哪来：从遥操作走向人类/无本体数据与部署回流，规模从万小时到百万小时；
4. 如何超越模仿：RL 后训练、世界模型中训练、部署中持续学习；
5. 如何证明有用：从演示视频到榜单，再到真实部署的可靠性与吞吐——这是 2027 年的主战场。

第一部分（续）技术专题深潜：把机器人大脑”拆到螺丝钉”

> 本章是 50 个公司章节的”技术词典 + 原理课”。公司章节讲”谁做了什么”，本章讲”这些方法到底是怎么工作的”。读者可以在阅读任何公司章节时随时回到这里查阅。内容以公开论文中的通用方法为基础，数学推导力求准确；具体公司的实现细节以各章及其原论文为准。

专题 1：一条 VLA 的完整数据流——以 π0 类架构为例，从像素到电机

1.1 输入是什么

一个典型的 2025–2026 年 VLA（π0、GR00T、GR-3、Xiaomi-Robotics-0、DM0 等结构相近）在每个控制周期接收：

输入	典型规格	说明
多路相机图像	2–4 路，每路 224×224 或原生分辨率	头部/外部相机 + 腕部相机
历史帧（可选）	0–6 帧	π0.7 每路最多 6 帧；多数 VLA 只用当前帧
语言指令	一句话到一段话	“把杯子放进水槽”；π0.5 还有高层子任务
本体状态 q_t	关节角、末端位姿、夹爪开合	维度因本体而异（π0 零填充到 18 维）
其他条件（2026 新增）	子目标图像、元数据、控制模式	π0.7、RxBrain

1.2 Token 化

```
图像 224×224 ──► ViT（如 SigLIP，patch 14）──► 16×16 = 256 个视觉 token
                                  └──► （可选）pixel shuffle / 压缩 ──► 64 个 token（GR00T N1、SmolVLA 的做法）
语言 ──► 分词器 ──► 约 10– 50 个文本 token
状态 q_t ──► 线性层 ──► 1 个状态 token（或每个关节一个）
加噪动作块 A_t^τ （H×d，例如 50×18）──► 线性层 + 时间步 τ 嵌入 ──► H 个动作 token
```

以 3 路相机、每路 256 token 计，一个周期的 token 序列长度约为 3×256 + 30 + 1 + 50 ≈ 850——这就是为什么高分辨率多相机会显著增加延迟，也是为什么很多工作要压缩视觉 token。

1.3 注意力掩码：分块因果

π0 的关键工程设计之一是分块因果注意力（blockwise causal）：

```
            看得见 →   [图像+文本]   [状态]   [动作]
[图像+文本]              ✓           ✗        ✗
[状态]                   ✓           ✓        ✗
[动作]                   ✓           ✓        ✓
```

- [图像+文本] 只看自己 → 它的 KV 可以缓存，流匹配的多步积分中不必重算；
- [动作] 可以看到一切 → 动作生成以完整观察为条件；

- 块内部是双向注意力。

1.4 两组权重共享一个 Transformer（“动作专家”）

图像/文本 token 走 VLM 的 FFN 与注意力投影权重（约 3B），状态/动作 token 走”动作专家”权重（约 300M），但所有 token 在每一层一起做自注意力。这像一个”按 token 类型路由的两专家 MoE”。好处：动作专家可以在每一层直接读取 VLM 的中间表征，而不只是最后一层的输出。

（GR00T N1 的做法不同：VLM 先单独前向，取第 12 层特征，再通过交叉注意力送入 DiT 动作模块；FiS-VLA 则把 VLM 最后几层直接改造为快系统。三者代表了”VLM 与动作专家如何连接”的三种方案。）

1.5 流匹配训练：一步一步

给定一个训练样本（观察 o_t、真实动作块 $A_t \in \mathbb{R}^{H\times d}$）：

```
# 伪代码（概念性，非任何公司的源码）
tau = sample_beta()                    # 采样时间 τ ∈(0,1)，π 0 偏向高噪声端
eps = randn_like(A_t)                  # 高斯噪声
A_tau = tau * A_t + (1 - tau) * eps    # 在噪声与真实动作之间线性插值
v_pred = model(o_t, A_tau, tau)        # 网络预测速度场
v_target = A_t - eps                   # 目标速度（从噪声指向数据）
loss = mse(v_pred, v_target)
```

（不同论文对 τ 的方向约定不同——有的令 τ=0 为数据、τ=1 为噪声，此时目标速度符号相反，本质相同。）

1.6 流匹配推理：积分 10 步

```
A = randn(H, d)                    # 从纯噪声开始
dt = 1.0 / 10
for k in range(10):                # 10 步欧拉积分
    tau = k * dt
    A = A + dt * model(o_t, A, tau)    # 图像/文本的 KV 已缓存，只重算动作部分
return A                           # 得到 H 步动作块
```

为什么流匹配取代了扩散成为主流：①训练目标简单（回归一个速度）；②推理步数少（5–10 步即可）；③与”直线路径”（rectified flow）结合时更稳定。

1.7 执行：动作块与重规划

```
t=0      推理得到 A[0:50]
t=0..k   执行 A[0:k]（例如 k=25，半个块）
t=k      用最新观察重新推理，得到新块 → 与旧块剩余部分衔接
```

衔接问题：新块与旧块在切换点不连续 → 抖动。解决方案：- ACT 的时间集成（对重叠预测加权平均）；- PI 的实时分块（RTC）：把”新块的前几步必须与旧块剩余动作一致”视为一个修补（inpainting）约束，在流匹配推理中通过引导实现；- Xiaomi-Robotics-0 的干净动作前缀 + Λ 形注意力掩码：把旧块动作作为前缀输入，但只让紧邻前缀的动作 token 看得见它，后面的 token 必须看视觉——兼顾平滑与反应性。

1.8 一张"延迟预算表"（示意）

环节	典型耗时（量级）
相机采集与传输	10–30 ms
视觉编码 + VLM 前向（3B 级）	30–80 ms（端侧 GPU）
动作专家 10 步积分	10–40 ms
网络（若云端）	50–150 ms
合计	端侧约 60–150 ms；云端约 150–300 ms（Gemini Robotics 1.0 报告约 250 ms 端到端）

动作块让 50 Hz 的有效控制频率成为可能，即便模型本身只能 5–15 Hz 推理。

专题 2：动作表示的数学——从 256 个桶到频域压缩

2.1 均匀离散化（RT-2 / OpenVLA）

对每个动作维度 $a_i \in [l_i, u_i]$，均匀切成 $B = 256$ 个桶：

$$\text{token}_i = \left\lfloor \frac{a_i - l_i}{u_i - l_i} \cdot (B-1) \right\rceil$$

一个 7 维动作 = 7 个 token；一个 50 步动作块 = 350 个 token。问题：①高频控制下相邻步几乎相同，"预测下一个 token"信息量极低；②精度受桶宽限制。

2.2 FAST：把动作当成"图像"压缩

对动作块 $A \in \mathbb{R}^{H \times d}$ 的每个维度 j（一条长度 H 的时间序列）做离散余弦变换：

$$C_{k,j} = \sum_{n=0}^{H-1} A_{n,j} \cos\left[\frac{\pi}{H}\left(n + \tfrac{1}{2}\right)k\right]$$

然后： 1. 缩放并取整：$\hat{C} = \text{round}(\gamma \cdot C)$——平滑轨迹的能量集中在低频，高频系数大多变成 0； 2. 按"低频优先、维度交错"展平：$[\hat{C}_{0,1}, \hat{C}_{0,2}, \ldots, \hat{C}_{0,d}, \hat{C}_{1,1}, \ldots]$； 3. 用 BPE 合并常见的系数组合（尤其是大量连续的 0）。

直观类比：均匀离散化像"逐像素存储图片"，FAST 像"JPEG 压缩"。结果是 token 数大幅减少、每个 token 信息量更大，自回归训练效率显著提升（π0-FAST 约 5 倍训练加速）。

2.3 VQ-VAE 与 RVQ：学出来的码本

VQ-VAE：编码器 E 把动作块编码为向量 z_e，在码本 $\{e_k\}_{k=1}^{K}$ 中找最近的码字 $z_q = e_{k^*}$，
$k^* = \arg\min_k \| z_e - e_k \|$，解码器 D 重建动作。损失：

$$\mathcal{L} = \| A - D(z_q) \|^2 + \| \text{sg}[z_e] - e_{k^*} \|^2 + \beta \| z_e - \text{sg}[e_{k^*}] \|^2$$

（sg 为停止梯度；第二项更新码本，第三项为承诺损失）。

RVQ（残差向量量化）：用多级码本逐级量化残差——第 1 级量化 z_e，第 2 级量化 $z_e - e^{(1)}$，……用较小码本的组合表达更精细的信息。RDT2、WALL-OSS-0.5（视觉对齐 RVQ）采用此类方法。

2.4 扩散（DDPM / DDIM）

前向加噪：$A^k = \sqrt{\bar{\alpha}_k} A^0 + \sqrt{1-\bar{\alpha}_k}\,\epsilon$；训练：$\mathcal{L} = \mathbb{E} \parallel \epsilon - \epsilon_\theta(o, A^k, k) \parallel^2$；推理：从 $A^K \sim \mathcal{N}(0, I)$ 出发逐步去噪（DDPM 约 100 步，DDIM 可降到约 10 步）。 Diffusion Policy 用这一框架表达多模态动作分布：两种都正确的绕行方式不会被”平均”成错误的中间路线。

2.5 潜在动作

见专题 4。

2.6 表示方式选择的经验法则（2026）

需求	推荐
与 LLM 预训练统一、训练快	FAST / RVQ 离散 token
高频、精细、多模态动作	流匹配连续动作专家
利用无动作标签视频	潜在动作
继承视频物理先验	视频-动作联合生成
主流组合	离散 token 训练 VLM 学”动作语义” + 流匹配专家输出”动作细节”

专题 3：双系统与三层大脑的工程实现

3.1 为什么必须分频

层	参数量级	可承受频率	物理需求
S2 推理	3B–70B+	0.5–10 Hz	理解场景、规划步骤
S1 视觉运动	80M–1B（或与 S2 共享）	10–200 Hz	跟踪物体、调整手的轨迹
S0 全身控制	1M–50M	200–1000 Hz	平衡、接触力、反射

人的神经系统也是这样：大脑皮层”想”、小脑”协调”、脊髓”反射”。

3.2 层间接口的三种选择

接口	代表	优点	缺点
自然语言	Gemini ER→VLA、π0.5 子任务、Robix→GR-3	可解释、可人工干预、模块可独立替换	信息损失（难以描述精确空间/力）
潜在向量	Helix S2→S1、GR00T VLM→DiT	信息丰富、可端到端训练	不可解释，两层必须联合训练
结构化中间表示	RoboBrain（3D 坐标/轨迹）、RxBrain（子目标图像）、π0.7（子目标图像）	精确且可解释	需要专门训练生成这些表示
运动目标	S1→S0：末端位姿、关节目标、参考动作片段	物理意义明确	S0 需要足够通用（追踪器/行为基础模型）

3.3 异步运行与”时间错位”

S2 以 7–9 Hz 输出一个潜在向量，S1 以 200 Hz 运行——S1 在大部分时刻使用的是"几十到上百毫秒前"的 S2 输出。Figure 在训练 Helix 时人为地在 S1 与 S2 的输入之间引入时间偏移，模拟部署时的异步延迟，使 S1 学会在"略微过时的意图"下仍能正确行动。

3.4 KV 缓存与层复用

- π0：图像/文本前缀的 KV 在 10 步积分中复用；
- GR-3：动作 DiT 只使用 VLM 后半部分层的 KV 缓存，DiT 层数为 VLM 的一半；
- FiS-VLA：把 VLM 最后几层直接作为快系统，以不同频率运行；
- GR00T N1 / SmolVLA：只用 VLM 中间层（例如第 12 层）的特征。

这些设计的共同目标：在不牺牲语义的前提下，把每个控制周期的计算量压到最低。

专题 4：潜在动作——让无标签视频变成机器人训练数据

4.1 问题

互联网与人类第一视角视频有数百万小时，但没有机器人动作标签。潜在动作模型（Latent Action Model, LAM）的思路：动作 = 解释两帧之间变化的最小信息。

4.2 基本 LAM（Genie / LAPA 式）

```
输入：帧 x_t 与 x_{t+k}
编码器（逆动力学）：z = E(x_t, x_{t+k})          # 推断"发生了什么动作"
量化：z_q = VQ(z)                                # 离散潜在动作码，码本大小通常很小（如 8– 256）
解码器（前向动力学）：x̂_{t+k} = D(x_t, z_q)      # 用当前帧 + 动作码重建未来帧
损失：重建误差 + VQ 损失
```

关键约束：码本很小、信息瓶颈很窄 → 编码器只能编码"最关键的变化"（动作），而不能把整帧图像抄过去。

训练好后，任何视频都可以被标注为潜在动作序列 → VLA 先学"预测潜在动作"（预训练），再用少量机器人数据学"潜在动作 → 真实动作"的解码器。

4.3 UniVLA 的改进：任务中心

问题：视频中的变化不全是动作（相机抖动、路人、光照）。UniVLA 的做法： 1. 在 DINOv2 特征空间而非像素空间做重建（对外观变化不敏感）； 2. 两阶段：先不带语言学一组码（吸收所有变化），再加语言条件学第二组码——第一组码已吸收"任务无关变化"，第二组码被迫只编码"与指令相关的动态"。

4.4 XR-1 的改进：视觉与运动共享码本（UVMC）

双分支 VQ-VAE：视觉分支编码帧间视觉动态，运动分支编码机器人真实运动，两者共享一个码本 + 对齐损失 → 同一个码既能从视频中读出，也能对应到真实运动。

4.5 在各家的使用

机构	用法
NVIDIA GR00T N1	把潜在动作作为一种"虚拟本体（LAPA）"参与训练
智元 GO-1	"潜在规划器"预测潜在动作 token，动作专家再细化（成功率 66%→78%）
港大 UniVLA / WholeBodyVLA	任务中心潜在动作；扩展到人形全身
北京人形 XR-1	统一视觉-运动码

专题 5：世界模型——五种用法与四种实现

5.1 定义

机器人世界模型：$p(o_{t+1:t+k} \mid o_{\le t}, a_{t:t+k-1})$——给定过去观察与将要执行的动作，预测未来观察（或其表征）。

5.2 四种实现

(a) 像素/视频生成式：以视频扩散模型（如 Wan、Cosmos）为基础，以动作或文本为条件生成未来帧。 (b) 视频-动作联合生成（WAM）：在同一去噪过程中同时生成未来视频 latent 与动作（DreamZero）——

$$p_\theta(v_{t+1:t+k}, a_{t:t+k-1} \mid o_{\le t}, \ell)$$

动作不再需要单独的头。 (c) 潜空间预测（JEPA 式）：编码器 E 把观察映射为表征 $s = E(o)$，预测器 P 学习 $\hat{s}_{t+1} = P(s_t, a_t)$，损失在表征空间计算：$\| \hat{s}_{t+1} - \mathrm{sg}[E(o_{t+1})] \|$（V-JEPA 2-AC、RoboJEPA、Being-H0.7 一类）。 (d) 轻量结构化预测：只预测"哪里会动"（宇树 WLA 用光流监督动态区域）、只预测"关键事件"（自变量 WALL-WM）。

5.3 五种用法

用法	机制	代表
①造数据	外观/视角/人→机/仿真→真实迁移，扩充训练集	Cosmos Transfer、DreamGen、GigaWorld-0
②评估策略	策略在世界模型中闭环运行，统计成功率并排序	1X、Ctrl-World、GE-Sim
③RL 训练场	在世界模型中做强化学习	AWE 3.5、GigaBrain-0.5M*、WALL-SS、特斯拉
④生成子目标	世界模型生成"下一步应该是什么样"的图像作为提示	π0.7、RxBrain
⑤直接作为策略	生成未来并从中得到动作	DreamZero、1XWM（+IDM）、Vidar

5.4 用世界模型做规划：MPC + CEM（V-JEPA 2-AC 的方法）

```
# 交叉熵方法（CEM）在表征空间做模型预测控制（概念伪代码）
mu, sigma = zeros(T, d_a), ones(T, d_a)
s0, s_goal = E(o_now), E(o_goal)
for it in range(n_iters):
    plans = mu + sigma * randn(N, T, d_a)          # 采样 N 条动作序列
```

```
        costs = []
        for plan in plans:
            s = s0
            for a in plan:
                s = P(s, a)                          # 在表征空间"想象"
            costs.append(norm(s - s_goal))
        elite = plans[argsort(costs)[:K]]            # 选最好的 K 条
        mu, sigma = elite.mean(0), elite.std(0)      # 更新分布
    execute(mu[0])                                   # 只执行第一步，然后重新规划
```

5.5 世界模型的三大难题

1. 物理一致性："看起来合理但物理上错误"（1X 坦承的失败模式）；
2. 推理速度：14B 视频模型约 7 Hz（DreamZero）；Fast-WAM 把单步从约 800 ms 降到约 190 ms；隐式模型（Being-H-Flash）可上端侧；
3. 评估的可信度：世界模型中的成功率与真实成功率的相关性需要验证（Ctrl-World 报告排序一致）。

专题 6：强化学习后训练——从 PPO 到"优势条件化"

6.1 为什么不直接用 PPO

PPO 等在线策略梯度方法在仿真中很成功（运动控制），但对大 VLA + 真机极不友好： - 需要大量在线样本，真机太慢、太贵、有风险； - 大模型的策略梯度方差大、训练不稳定； - 稀疏奖励（只有"成功/失败"）。

6.2 RECAP：把 RL 变成"条件化监督学习"

1. 训练一个价值函数 $V(o)$（π*0.6 中为分布式价值，预测"还有多久完成/能否成功"）；
2. 对每个数据片段估计优势 $A(o,a) \approx r + V(o') - V(o)$（或用多步回报）；
3. 二值化：$I = \mathbb{1}[A > \delta]$（这一步"比平均好"还是"比平均差"）；
4. 训练优势条件化策略 $\pi(a \mid o, I)$——好的与坏的数据都用，但打上标签；
5. 推理时始终令 $I = 1$（"请做好的那种动作"），可选地用 CFG 放大：

$$\tilde{\pi} \propto \pi(a \mid o)\left[\frac{\pi(a \mid o, I=1)}{\pi(a \mid o)}\right]^{w}$$

   理论上，当 w 适当时，这等价于对"高优势动作"进行策略改进——这也是"条件化 + CFG"能实现 RL 式提升的直观原因。

数据来源：示范 + 自主运行（含失败）+ 人类纠正，多轮迭代。

6.3 HIL-SERL：小策略的高效真机 RL

- 奖励：用少量成功/失败图像训练二分类器作为奖励；
- 算法：RLPD（示范数据与在线数据各占一半批次、高 UTD 比的 SAC 类离策略算法）；
- 人在环路：出错时人工接管，纠正数据进入回放缓冲区；
- 结果：1–2.5 小时内多个精密任务接近 100%（第 18 章）。

6.4 GR-RL：离线过滤 + 在线微调

1. 离线 RL 训练一个 critic（任务进度模型），在成功与失败轨迹上学习；
2. 用 critic 过滤示范中的有害片段（让进度下降的动作）；
3. 形态对称增强（双臂镜像）；
4. 在线 RL：在潜空间中探索（由学习的噪声预测器生成探索动作），而非直接给动作加噪。

6.5 其他方案对照

方法	关键词
DPPO（Pelican-VL）	RL 精炼 → 诊断薄弱能力 → 针对性 SFT，循环
RAMP（GigaBrain-0.5M*）	世界模型条件策略 + RL
模型内 RL（AWE 3.5）	在生成的可交互世界中切片训练
G-Fleet（星海图）	分布式车队：部署 → 交互 → 回流 → 训练
价值/进度模型（ER 2、RoboBrain 2.5）	为任意任务提供通用的进度/奖励信号

专题 7：人形全身控制——一个 S0 控制器是怎么训练出来的

7.1 流程总览

```
人类动作数据（AMASS / LAFAN1 / 自采动捕 / 视频重建）
        |  ① 重定向（人体骨架 → 机器人骨架）
        ▼
机器人参考动作库（剔除不可行动作）
        |  ② 仿真中训练追踪策略（PPO，数千个并行环境，域随机化）
        ▼
特权教师策略（可见未来参考、地形、摩擦、质量……）
        |  ③ 蒸馏
        ▼
可部署学生策略（仅本体感知 + 稀疏目标；常用历史窗口/Transformer 推断动力学）
        |  ④ sim2real 对齐（域随机化 / 差分动作模型 / 少量真机微调）
        ▼
真机部署（200– 1000 Hz）
```

7.2 追踪奖励（典型形式）

$$r_t = w_p e^{-\| p_t^{ref} - p_t \|^2/\sigma_p} + w_r e^{-\| \theta_t^{ref} \ominus \theta_t \|^2/\sigma_r} + w_v e^{-\| v_t^{ref} - v_t \|^2/\sigma_v} + w_{root}(\cdot) - \text{(能耗、力矩、动作平滑、自碰撞惩罚)}$$

其中 p 为关键身体部位位置、θ 为关节/部位朝向、v 为速度。指数形式让奖励在误差小时接近 1、误差大时迅速衰减。

7.3 关键技巧

技巧	作用	代表
动作可行性过滤	去掉机器人做不到的人类动作	H2O、ExBody2
保留交互的重定向	避免脚滑、穿地、手离开物体	OmniRetarget

技巧	作用	代表
教师-学生蒸馏	用特权信息训练，再蒸馏到真实可观测输入	H2O、Berkeley 人形 RL
历史/Transformer 输入	隐式系统辨识，适应地形与负载	RMA、Radosavovic 等、Skild
差分动作模型	学习 sim 与 real 的动力学差异，回到仿真微调	ASAP
残差策略	在通用追踪器上叠加物体交互修正	ResMimic
行为基础模型	一个策略被动作/目标/奖励"提示"	Meta Motivo、BFM-Zero
质心感知 + MoE	激进动作下保持平衡，分离通用基元与本体动力学	智在无界 FAST

7.4 FB 表征的一句话直觉（Motivo / BFM-Zero）

学习前向 $F(s,a,z)$ 与后向 $B(s)$，使占用度量满足 $M^{\pi_z}(s,a,s') \approx F(s,a,z)^\top B(s')$。对任意奖励 r，令 $z_r = \mathbb{E}[r(s)B(s)]$，则 $Q^{\pi_{z_r}}(s,a) \approx F(s,a,z_r)^\top z_r$——新任务只需算一个向量 z_r，无需重新训练。

专题 8：跨本体——一个大脑驱动多种身体的十种方法

（详见第一部分 3.5 节表格。）这里补充一个选择指南：

你的情况	推荐方案
本体数量少、结构相似	零填充统一维度（π0）
本体差异大、希望共享物理含义	物理可解释统一空间（RDT）
本体差异大、数据量不均	本体专属编解码器 + 共享主干（GR00T）
本体结构已知、希望 3D 精确	显式输入相机参数与 URDF（HoloBrain）
希望利用人类数据	人-机统一动作空间（Being-H0.5、HAT）
希望应对硬件变化与损伤	历史上下文适应（Skild、RMA）

专题 9：数据工程——采集、标注与质量

9.1 采集方式谱系

方式	设备成本（量级）	采集效率	数据质量	代表
主从臂遥操作（puppeteering）	万美元级	中	高（关节空间直接对应）	ALOHA、SO-101
VR 头显 + 手部追踪	千–万美元	中	中高	Open-TeleVision、Figure、宇树
动捕服 + 全身遥操作	十万元级	低–中	高	特斯拉早期、BD
RGB 摄像头"影子"遥操作	极低	中	中	HumanPlus、H2O
手持夹爪（UMI）	百美元级	高	中高（接口对齐）	UMI、RDT2、小米

方式	设备成本（量级）	采集效率	数据质量	代表
技能手套	约 200 美元	高	中高（与机器人手共同设计）	Sunday
头戴第一视角 + 手部姿态	消费级	极高	中（形态鸿沟）	PH2D、EgoDex、Figure Index、Being
触觉手套 / 全模态	中	中	高（含触觉）	它石 WIYH、灵初、Genesis

9.2 自动标注

- 事后指令重标注（hindsight relabeling）：让 VLM 看一段示范视频，回答”如果要让机器人做出这段动作，应该给它什么指令”——Helix 的做法；
- 任务描述标准化：SmolVLA 用 VLM 重写社区数据中混乱的任务描述；
- 子任务切分：π0.5 的高层子任务标注；
- 元数据标注：π0.7 为每段数据标注速度、质量、控制模式——让模型”知道这段数据是怎么做的”。

9.3 质量控制的三个原则（2026 共识）

1. 多样性优先：每个环境/物体少量示范、覆盖尽可能多的环境与物体（清华数据缩放定律）；
2. “脏”数据有价值，但要能被区分：恢复行为与失败数据有用（千寻、RoboMIND 失败轨迹），但需要元数据或价值模型让模型区分好坏（π0.7、RECAP）；
3. 接口对齐：采集设备的观察与动作空间要与部署机器人一致（UMI、Sunday 手套）。

专题 10：评测方法论——如何判断一个机器人大脑真的更好

10.1 样本量与置信区间

成功率 $\hat{p}$ 的标准误差 $\mathrm{SE} = \sqrt{\hat{p}(1-\hat{p})/n}$。要让 95% 置信区间半宽不超过 ±10%（成功率约 50% 时）：

$$1.96\sqrt{0.25/n} \le 0.1 \Rightarrow n \ge 96$$

含义：一个任务只做 10–20 次试验时，“成功率 60% vs 50%”在统计上几乎没有意义。这正是 TRI 在 LBM 研究中强调”约 1800 次真机盲测”的原因（第 15 章）。

10.2 好评测的五个要素

要素	说明	反例
盲测	评测者不知道运行的是哪个模型	开发者自己评测自己的模型
大样本	每个条件足够多次试验	每任务 10 次
整任务成功	只算完整完成	只报”部分进度”
分布外	新环境、新物体、新指令	在训练场景中测试
利益隔离	评测者与被测方无利益关联	RoboArena 事件

10.3 里程碑评分

对长时程任务，除二元成功率外，可按子目标（里程碑）给出部分分数（TRI LBM、BEHAVIOR q-score），用于区分”差一点成功”和”完全失败”——但对外宣传时，应以整任务成功率为主。

10.4 读榜单时的五个问题

1. 是第三方平台还是自建榜单？
2. 是仿真还是真机？真机是否标准化？
3. 每个任务试验了多少次？有没有置信区间？
4. 比较的基线是哪个版本、是否经过同等微调？
5. “第一”是在哪个子榜、哪个模型版本（例如 GO-3 Nano Preview vs GO-3 Preview）？

本章小结

如果把 2026 年的机器人大脑比作一辆车： - VLM 主干是导航系统（知道去哪、认得路）； - 动作专家是方向盘与油门（把意图变成平滑的操作）； - 全身控制器是底盘与悬挂（保证不翻车）； - 世界模型是驾驶模拟器与预判能力（想象接下来会发生什么）； - RL 后训练是驾驶陪练（从错误中进步）； - 数据是燃料，评测是驾照考试。

50 个公司章节，就是 50 种不同的”造车方案”。

第 1 章 Google DeepMind：从”把动作当成语言”到”全身智能”

> 一句话定位：机器人基础模型（VLA）范式的发明者与定义者。DeepMind 的打法是”以最强的通用多模态大模型（Gemini）为母体，把机器人当作 Gemini 的又一个输出模态”，用”推理大脑（ER）+ 动作模型（VLA）+ 端侧模型（On-Device）“的三件套，向所有本体厂商输出”安卓式”的机器人大脑。截至 2026 年 10 月，它在”通用性 + 推理能力 + 生态开放度”三项上仍处在全球第一梯队的最前列。

0. 速览卡片

维度	内容
机构	Google DeepMind（Alphabet 旗下；2023 年 Google Brain 与 DeepMind 合并）
机器人负责人	Carolina Parada（机器人负责人），Vikas Sindhwani、Kanishka Rao 等长期核心；早期代表人物 Vincent Vanhoucke、Karol Hausman、Brian Ichter、Chelsea Finn（已离开创办 PI 的多位成员原属 Google）
代表模型谱系	QT-Opt → BC-Z → SayCan → RT-1 → PaLM-E → RT-2 → RT-X → ALOHA Unleashed → Gemini Robotics 1.0 / ER → On-Device → Gemini Robotics 1.5 / ER 1.5 → ER 1.6 → Gemini Robotics 2 / ER 2 / On-Device 2（2026.07）
技术路线	大 VLM 母体 + 动作解码；“思考型 VLA”；“分层智能体”（ER 做规划/调用工具，VLA 做执行）；跨本体 Motion Transfer
开放程度	ER 系列通过 Gemini API / AI Studio 对外开放；VLA 与 On-Device 仅限可信测试伙伴（Trusted Tester）；早期 RT-1、OXE 数据集开源
本体伙伴	Apptronik（Apollo / Apollo 2，战略合作）、Boston Dynamics（2026 CES 宣布合作，新一代 Atlas）、Agile Robots、Agility Robotics、Enchanted Tools、Franka、Trossen、Dexmate、SO-101 等
本报告选取的三篇代表作	① RT-2（2023）② Gemini Robotics 1.0 → 1.5（2025）③ Gemini Robotics 2 家族（2026）
身位评估	通用推理与跨本体泛化：全球第一档；全身控制/灵巧手：2026 年才补齐，仍在追赶 Figure/特斯拉的”整机端到端”；商业化：走平台授权路线，营收贡献尚小

1. 故事的开端：Google 的机器人十年

要理解 DeepMind 今天的机器人大脑，必须回到 2016 年的 Google 山景城——那里有一排被员工戏称为”手臂农场（arm farm）“的 KUKA 机械臂，日夜不停地尝试抓取散落在箱子里的杂物。

第一幕：暴力规模化的强化学习（2016–2019）。 Sergey Levine 等人在 Google Brain 做的"手眼协调"抓取实验，以及 2018 年的 QT-Opt（7 台机械臂、约 58 万次真实抓取尝试、离线 Q 学习），证明了"规模化的真机数据 + 深度学习"能让抓取成功率达到 96% 左右。但这条路的代价是：一个技能就要几十万次试错，无法扩展到成百上千种任务。

第二幕：语言进入机器人（2021–2022）。 2022 年 4 月的 SayCan（"Do As I Can, Not As I Say"）是第一个让大语言模型（PaLM）给真实机器人做任务规划的重要工作：LLM 负责回答"这一步说得通吗"（say），每个底层技能的价值函数负责回答"这一步做得到吗"（can），两者相乘决定下一步执行哪个技能。同期的 Inner Monologue、Code as Policies 把"语言 = 机器人的思维载体"推向主流。但这时的 LLM 只是一个"上层调度器"，底层动作仍由独立训练的小模型完成。

第三幕：Transformer 吃下动作（2022.12）。 RT-1（Robotics Transformer 1）是转折点：Everyday Robots 的 13 台移动机械臂在 17 个月里采集了约 13 万条示范、覆盖 700+ 条指令，训练出一个约 3500 万参数的 Transformer。它的输入是 6 帧历史图像 + 一句语言指令（经 Universal Sentence Encoder 编码、通过 FiLM 注入 EfficientNet-B3），每张图被 TokenLearner 压成 8 个 token，最后输出 11 维动作（7 维手臂 + 3 维底盘 + 1 维模式切换），每一维离散成 256 个桶，以约 3 Hz 运行。RT-1 在已见任务上达到 97% 成功率，并首次显示出"数据多样性比数据量更影响泛化"。

第四幕：动作就是语言（2023.07）——RT-2。 这是本章第一篇代表作，也是整个 VLA 时代的起点，下一节详述。

第五幕：开放与联邦（2023.10）——Open X-Embodiment。 DeepMind 牵头 21 家机构（后扩到 30+）整合出 Open X-Embodiment（OXE）数据集：22 种机器人本体、100 多万条轨迹、527 种技能。在其上训练的 RT-1-X 在小数据实验室的任务上平均比各家原方法高约 50%，RT-2-X 在"涌现技能"上约为 RT-2 的 3 倍。OXE 后来成为 Octo、OpenVLA、π0 等几乎所有开源 VLA 的预训练底座——这是 DeepMind 对行业最大的"公共品"贡献之一。

第六幕：低成本双臂与灵巧操作（2024）。 斯坦福的 ALOHA 低成本双臂平台被 DeepMind 升级为 ALOHA 2，并做出了 ALOHA Unleashed（用扩散策略 + 大规模示范学会系鞋带、挂衬衫）和 DemoStart（仿真中用少量示范 + 自动课程强化学习训练灵巧手）。ALOHA 2 车队后来成为 Gemini Robotics 的主力数据采集平台。

第七幕：Gemini 化（2025–2026）。 2025 年 3 月，DeepMind 用 Gemini 2.0 为底座推出 Gemini Robotics 与 Gemini Robotics-ER；6 月推出端侧版；9 月推出带"思考"与跨本体 Motion Transfer 的 1.5；2026 年 4 月推出 ER 1.6；7 月 30 日推出 Gemini Robotics 2 家族，第一次把"全身控制 + 五指灵巧手 + 多机协作"纳入一个统一的模型家族。

与此同时，Alphabet 内部的另一条线——2023 年被关闭的 Everyday Robots、以及工业软件公司 Intrinsic——让 DeepMind 在 2023 年后彻底转向"不自己造整机、只做大脑"的平台路线。这一点决定了它和特斯拉、Figure 的根本区别。

---

2. 代表作一：RT-2（2023）——"把动作当成另一种语言"

> 论文：*RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control*（Brohan, Brown, …，Zitkovich 等，2023.07，CoRL 2023）

2.1 它要解决的问题

2023 年上半年，行业面对一个尴尬局面：一边是在互联网数据上训练、懂得"什么是恐龙""哪个是能量饮料"的视觉语言模型（VLM，例如 PaLI-X、PaLM-E）；另一边是只在几万条机器人示范上训练、对新物体"两眼一抹黑"的控制模型（RT-1）。SayCan 式的"LLM 做规划 + 小模型做技能"只能让语义知识影响"选哪个技能"，却无法让它影响"手怎么动"。

RT-2 的提问非常直接：能不能让同一个大模型，既回答"图里是什么"，又直接输出"手该往哪动"？

2.2 核心思想：动作 token 化

RT-2 的关键洞察只有一句话：如果把机器人的动作写成一串文本 token，那么动作预测就只是 VLM 的又一种"看图说话"。

具体做法：

1. 动作空间定义：每一步动作由 8 个数组成——1 个"是否终止"的离散标志、末端执行器 6 自由度的位移与旋转增量（Δx, Δy, Δz, Δroll, Δpitch, Δyaw）、1 个夹爪开合量。
2. 离散化：除终止位外，每个连续维度均匀切成 256 个桶，于是一步动作就是 8 个整数，例如 "1 128 91 241 5 101 127 217"。
3. 映射到词表：
    - 对 PaLI-X，其分词器本身给 0–1000 的每个整数都分配了独立 token，所以直接用数字 token 表示动作桶；
    - 对 PaLM-E，没有现成的整数 token，就把词表里 256 个最少使用的 token"征用"为动作符号。
4. 输出约束：在机器人任务上解码时，把采样空间限制在合法的动作 token 内，保证输出一定可执行。

这样，"VLA（Vision-Language-Action）"这个词第一次被正式提出：一个模型、一个词表、一个自回归解码器，同时承担视觉问答与机器人控制。

2.3 架构

RT-2 并没有发明新网络，它是两个现成 VLM 的"再训练"：

变体	底座	视觉编码器	语言主干	参数量
RT-2-PaLI-X	PaLI-X	ViT-22B（较小版本用更小 ViT）	UL2 式编码器-解码器	5B 与 55B
RT-2-PaLM-E	PaLM-E	ViT-4B	PaLM 仅解码器	12B

输入：当前一帧机器人相机图像 + 文本提示（"Q: what action should the robot take to [task]? A:"）。输出：动作 token 串，解码后反量化为连续控制指令。

2.4 数据与训练：协同微调（co-fine-tuning）

RT-2 最容易被忽视、但最关键的工程选择是 co-fine-tuning：不是只用机器人数据微调 VLM，而是把原始的网络视觉语言数据（WebLI 等图文对、VQA、图像描述）与 RT-1 的机器人示范数据混在同一个批次里一起训练，并对机器人数据做上采样。

为什么？因为只用机器人数据微调，会让模型迅速"忘掉"它在互联网上学到的概念（灾难性遗忘）；而混合训练让模型在学"怎么动"的同时，保留"这是什么、那是什么"的语义知识。论文的消融实验显示：co-fine-tuning 的泛化效果显著好于纯机器人数据微调，而从头训练（不用预训练 VLM）的效果最差。

机器人数据来自 RT-1 数据集（13 台机器人、17 个月、厨房办公环境）。

2.5 推理部署：大模型怎么跑在机器人上

55B 参数的模型显然塞不进机器人。RT-2 的做法是云端推理：模型部署在多 TPU 的云服务上，机器人通过网络发送图像、接收动作。实测 55B 版本能达到 1–3 Hz，5B 版本约 5 Hz。这个频率对于"移动到某处并抓取"这类准静态任务足够，但对于需要连续力控、动态平衡的任务远远不够——这正是两年后 π0、Helix 等工作要解决的问题。

2.6 实验结果

DeepMind 做了超过 6000 次真机评估试验：

- 已见任务：RT-2 与 RT-1 相当（说明换成大模型没有损失原有能力）；
- 未见场景的泛化（新物体、新背景、新环境）：RT-2 的成功率约 62%，RT-1 约 32%，接近翻倍；
- 涌现能力：RT-2 能完成训练数据中从未出现过的语义任务，例如"把香蕉放到 2+1 的和上"（符号理解）、"捡起已经灭绝的动物"（从一堆玩具中选出恐龙）、"把可乐罐移到泰勒·斯威夫特的照片旁"（人物识别）、"拿一个可以当临时锤子用的东西"（选石头）。这些语义知识全部来自网络预训练，而不是机器人数据。
- 思维链变体：基于 PaLM-E 的 RT-2 还试验了"先输出一句自然语言计划、再输出动作"的 chain-of-thought 版本，例如面对"我累了，给我拿点喝的"，先说出"Plan: pick rxbar chocolate / energy drink"，再执行。这一思想在 2025 年被 Gemini Robotics 1.5 发展为"思考型 VLA"。

2.7 局限

RT-2 论文本身坦率列出了局限：

1. 不会学新动作：泛化体现在"语义"层面——认得新物体、理解新指令——但机器人的物理技能集合并没有扩大，它只会做 RT-1 数据里出现过的那些动作（抓、放、推、开抽屉等）。
2. 太慢太贵：55B 模型 1–3 Hz、依赖云端，无法做高频灵巧操作。
3. 离散化损失精度：256 桶的均匀量化对精细操作不友好；自回归逐 token 生成也难以输出高频、平滑的动作序列。

2.8 为什么它是"代表作"

RT-2 给出了此后三年整个行业的"第一性公式"：

> VLA = 预训练 VLM（语义与常识）+ 机器人动作数据（技能）+ 共同训练（防遗忘）

OpenVLA（2024，斯坦福等）几乎是 RT-2 的开源复刻（Llama 2 + DINOv2/SigLIP + 256 桶动作 token）；π0 把离散动作 token 换成了流匹配（flow matching）连续动作专家；GR00T、Helix 把单一大模型拆成"慢系统 + 快系统"；但它们都继承了 RT-2 的基本判断：机器人大脑的语义能力，应当从互联网规模的视觉语言预训练中"继承"，而不是从机器人数据中"重新学"。

---

3. 代表作二：Gemini Robotics 1.0 → 1.5（2025）——把机器人变成 Gemini 的一个"模态"

> 技术报告：*Gemini Robotics: Bringing AI into the Physical World*（2025.03，arXiv 2503.20020）；*Gemini Robotics 1.5: Pushing the Frontier of Generalist Robots with Advanced Embodied Reasoning, Thinking, and Motion Transfer*（2025.09/10，arXiv 2510.03342）；以及 *Gemini Robotics On-Device*（2025.06 博客与 SDK）

3.1 背景：两年之间发生了什么

从 RT-2 到 Gemini Robotics 之间的两年，行业发生了三件事：

- Physical Intelligence 的 π0（2024.10）证明了"VLM + 流匹配动作专家"能以 50 Hz 输出连续动作块，完成叠衣服这类高灵巧任务；
- Figure 的 Helix（2025.02）证明了"慢系统 7B VLM + 快系统 80M 策略"的双系统能在人形上跑起来；
- DeepMind 自己的 Gemini 2.0 在空间理解（2D 指点、3D 框、多视角对应）上远超同代模型。

DeepMind 的结论是：机器人大脑的瓶颈有两个，一是"具身推理（Embodied Reasoning）"——看懂三维物理世界；二是"灵巧执行"——把理解转成高频平滑的动作。 于是 Gemini Robotics 从一开始就是两个模型。

3.2 Gemini Robotics-ER：会"空间思考"的 Gemini

ER（Embodied Reasoning）模型是在 Gemini 2.0 Flash 基础上强化空间与物理推理能力得到的 VLM，它不直接输出电机指令，而是输出机器人可用的"中间表征"：

- 2D 指点（pointing）：输出图像中某个物体或部位的像素坐标（"指出杯子的把手"）；
- 2D/3D 检测框：从单张或多张图像中给出物体的三维包围盒；
- 轨迹预测：画出从当前位置到目标的末端运动轨迹；
- 抓取预测：给出抓取位姿；
- 多视角对应：在不同相机视角间匹配同一个点；
- 代码生成控制：在零样本模式下，ER 可以生成调用机器人 API 的代码直接完成任务；在少样本模式下，通过上下文中的几条示范做 in-context learning。

为了衡量这种能力，DeepMind 发布了 ERQA（Embodied Reasoning Question Answering） 基准，约 400 道多选题，覆盖空间推理、轨迹推理、动作推理、状态估计、多视角推理等。

3.3 Gemini Robotics（VLA）：云端大脑 + 本地小脑

1.0 版 VLA 的系统架构是一个非常务实的"两段式"：



这一设计与 Figure 的 Helix、NVIDIA 的 GR00T 在思想上同源（慢-快分离），但 DeepMind 的特点是：慢系统就是 Gemini 本身（蒸馏版），因而直接继承了 Gemini 的世界知识、多语言理解和空间推理。

数据：DeepMind 在 12 个月里用一个 ALOHA 2 双臂机器人车队采集了”数千小时”的专家遥操作示范，覆盖数千种任务；再加上网络图文、视频、代码数据和 ER 数据混合训练。

三大能力维度（DeepMind 自己的框架）： 1. 通用性（Generality）：在新物体、新指令、新环境、新视觉干扰下保持成功率，论文报告其在泛化基准上的平均表现是此前最强 VLA 的两倍以上； 2. 交互性（Interactivity）：理解自然语言（含多语言）对话式指令，能在执行中被打断、改口、实时调整； 3. 灵巧性（Dexterity）：叠折纸狐狸、装午餐盒（拉链袋 + 放面包 + 盖盖）、打包行李等长时程、多阶段任务。对于最难的长程任务，用 2000–5000 条专门数据做”专精化（specialization）“后能显著提升成功率；对新任务，约 100 条示范即可快速适配。

跨本体：同一模型被微调到双臂 Franka 和 Apptronik 的 Apollo 人形上，显示出一定的本体迁移能力。

3.4 Gemini Robotics On-Device（2025.06）：把大脑塞进机器人

云端方案在工厂、仓库、家庭等网络不稳定的场景是硬伤。2025 年 6 月，DeepMind 发布 On-Device 版本：一个针对机载算力优化的 VLA，完全本地运行，并首次开放 Gemini Robotics SDK（含 MuJoCo 仿真评测）。官方称只需 50–100 条示范即可把它适配到新任务，并演示了适配到双臂 Franka FR3 与 Apollo 人形。这是 DeepMind 第一次让外部开发者亲手微调它的机器人模型——平台化的关键一步。

3.5 Gemini Robotics 1.5（2025.09）：会”先想后做”、能”跨身迁移”

1.5 版本是 DeepMind 机器人路线的成熟形态，包含两个模型：

(1) Gemini Robotics 1.5（VLA）——两大创新：

- Thinking VLA（思考型 VLA）：模型在输出动作之前，先用自然语言生成”内部思考轨迹”（thinking traces），例如”我需要先把蓝色毛衣分到深色衣物堆，所以先抓起它，移动到右边的篮子……“。思考可

以把一个长指令拆成若干个短的、可执行的子步骤，并在执行中根据视觉反馈修正。这本质上是把 RT-2 时代的”chain-of-thought”变成了模型的原生能力，并且思考与动作交错（interleave）进行，而不是一次性规划完。DeepMind 报告”思考模式”显著提升了多步骤任务的进度完成率，同时让机器人的行为对人类更可解释。

- Motion Transfer（MT，运动迁移）：传统 VLA 换一个本体就要重新收集大量数据。1.5 提出了一种新的模型架构与训练配方，使单一模型能从 ALOHA（双臂桌面）、双臂 Franka（工业臂）、Apollo（人形） 这三类形态差异巨大的机器人的异构数据中联合学习，抽取跨本体共享的”运动与物理”规律。效果是：在 ALOHA 上学会的技能，零样本就能在 Apollo 人形或 Franka 上执行（报告中称之为跨本体技能迁移）。这对于”数据稀缺”的人形机器人意义重大——人形可以”借用”成本低得多的双臂桌面平台的数据。

(2) Gemini Robotics-ER 1.5（推理/编排模型）——它被定位为”机器人的高层大脑”：

- 在 15 个具身推理学术基准（Point-Bench、RefSpatial、RoboSpatial-Pointing、Where2Place、BLINK、CV-Bench、ERQA、EmbSpatial、MindCube、RoboSpatial-VQA、SAT 等）上取得最高的综合分数，DeepMind 博客的对比图显示其综合得分高于 GPT-5 与 ER 1.0；
- 可以原生调用工具：例如为了完成”按照我所在城市的垃圾分类规则把这些垃圾分好”，ER 1.5 会先调用 Google 搜索查当地规则，再把分类任务拆成子任务，逐条以自然语言指令下发给 VLA 执行；
- 思考预算可调：开发者可在延迟与准确度之间权衡；
- 安全：在 DeepMind 自建的 ASIMOV 语义安全基准上取得最好成绩。

智能体化的系统架构：



开放策略：ER 1.5 通过 Gemini API（Google AI Studio）向所有开发者开放；VLA 1.5 仅向精选伙伴开放。这形成了”推理层开放、动作层受控”的分层商业模式。

3.6 局限与争议

- 数据主要来自 ALOHA 2 双臂平台，在真正的人形全身任务（行走 + 操作）上，1.5 时代的展示仍以上半身操作为主；
- 云-端分离依赖网络，On-Device 版能力弱于云端版；
- 评测多为自家任务集，第三方难以复现（VLA 权重不开源），与 π0/π0.5 开源 openpi 形成鲜明对比；
- 灵巧手：1.5 时代主要是平行夹爪，与 Figure/特斯拉强调的五指灵巧手路线差距明显。

---

4. 代表作三：Gemini Robotics 2 家族（2026.07）——“全身智能”

> 官方博客：*Gemini Robotics 2 brings whole body intelligence to robots*（2026-07-30）；配套 *Gemini Robotics 2 安全技术报告*；前序：*Gemini Robotics-ER 1.6*（2026-04-14）

4.1 过渡：ER 1.6（2026.04）的”智能体视觉”

在 2 代发布前三个半月，DeepMind 先发布了 Gemini Robotics-ER 1.6。它的关键词是 agentic vision（智能体式视觉）：模型不再”看一眼就回答”，而是把视觉推理和代码执行结合起来——例如读一个工业仪表盘时，模型会写代码对图像做裁剪、放大、几何测量，再给出精确读数。这种”会用工具看图”的能力，直接服务于工厂巡检、仪表读取、精密定位等工业场景，也为 2 代 ER 的”任务进度追踪”打下基础。

4.2 Gemini Robotics 2 家族的三个成员

模型	定位	关键能力	开放程度（截至 2026.10）
Gemini Robotics 2（VLA）	动作模型	全身控制：把行走、下蹲、弯腰、抓取作为一个统一问题求解；支持五指灵巧手	早期合作伙伴
Gemini Robotics-ER 2	推理/编排模型	用机器人相机画面追踪任务进度；把长任务拆分给多台机器人协作；在共享空间中协调多机	Gemini API / AI Studio 公开预览；企业平台私有预览
Gemini Robotics On-Device 2	端侧模型	本地运行，用”几小时数据、不到 200 条示范”即可适配新本体	早期合作伙伴

4.3 全身控制：从”桌面双臂”走向”人形全身”

2 代最重要的变化是动作空间从上半身扩展到全身。展示平台包括：

- Apptronik Apollo 2，配 SharpaWave（22 自由度五指灵巧手）与 Inspire（因时） 五指手；
- 双臂 Franka Duo + Robotiq 夹爪；
- Dexmate、Trossen 以及 Hugging Face 生态里的低成本 SO-101 机械臂。

公开报道的官方数字（来自 DeepMind 7 月 30 日发布内容的二手转述，hand 配置细节各报道略有出入）：

Apollo 2 全身拾取任务成功率

物体位置	成功率
货架上	76.3%

物体位置	成功率
桌面上	68.4%
地面上（需深蹲/弯腰 + 平衡）	45.7%

五指灵巧手任务成功率

任务	成功率
拧下灯泡	92%
拧上灯泡	36%
系垃圾袋	44%
使用簸箕	32%
封自封袋	40%

解读：这组数据非常"诚实"，也非常有信息量：

1. 高度越低、全身协调需求越大，成功率越低（货架 76% → 地面 46%），说明"边平衡边操作"的全身协同仍是硬骨头；
2. "拆"比"装"容易得多（拧下 92% vs 拧上 36%）：装配需要对准、旋入、力反馈判断，这正是当前 VLA 缺乏精细力控与触觉闭环的体现；
3. 可形变物体（垃圾袋、自封袋）在 40% 上下，距离商用（通常要求 95%+）还有很长的路。

DeepMind 选择公开这些"不好看"的数字，本身就是一种姿态：它们把 Gemini Robotics 定位为通用研究平台与开发者平台，而不是某个场景的"交付产品"。

4.4 ER 2：从"单机大脑"到"机器人团队的调度员"

ER 2 的两个新能力，标志着 DeepMind 把"多智能体编排"作为下一阶段的重点：

- 任务进度追踪（progress tracking）：ER 2 能持续观看机器人相机画面，判断"任务完成了几成""刚才那一步是否成功"，这相当于为机器人提供了一个通用的奖励模型/成功检测器——这对于后续的强化学习自我提升（类似 PI 的 π*0.6 RECAP 中的价值函数）至关重要；
- 多机分工：把一个长任务拆成若干并行子任务，分配给共享空间中的多台机器人（可以是不同形态），并协调它们避免冲突。

配套的 ASIMOV-Agentic 安全基准评测三件事：ER 是否能拒绝不安全的 VLA 工具调用、能否预判任务是否可行、在不确定时能否主动请求人类介入。DeepMind 同时发布了 2 代的安全技术报告，涵盖安全约束遵循和人机近距离测试——在全行业中，DeepMind 是把"机器人安全评测"做得最系统的一家。

4.5 On-Device 2：生态扩张的"楔子"

"不到 200 条示范、几小时数据适配一个新本体"——这句话的商业含义是：任何一家本体厂商，都可以以很低的成本把 Gemini 大脑装进自己的机器人。学术界已出现基于 On-Device 做人形专精化微调的工作（例如 2026 年 7 月的 CLIFT：用非侵入式闭环迭代微调把 Gemini Robotics On-Device 变成人形专用模型），说明 On-Device 正在成为一个被外部研究者使用的"底座"。

4.6 伙伴生态：Apptronik 与 Boston Dynamics

- Apptronik：自 2024 年底与 DeepMind 结成战略合作，Apollo/Apollo 2 是 Gemini Robotics 的"官方人形"；Apptronik 自身专注硬件与量产，大脑主要依赖 Gemini。
- Agile Robots：据报道，2026 年 3 月这家德国工业机器人公司宣布在其工业平台中集成 Gemini Robotics 的 VLA 模型——成为继 Apptronik、Boston Dynamics 之后又一家深度接入 Gemini Robotics 的硬件厂商；在 Gemini Robotics 2 发布时，VLA 与 On-Device 模型仍仅向 Apptronik、Boston Dynamics、Franka、Agile Robots 等合作伙伴开放（有单一来源称 ER 2 基于 Gemini 3.5 架构，未经官方确认）。
- Boston Dynamics：2026 年 1 月 5 日 CES 上，在现代汽车集团发布会中宣布与 DeepMind 建立 AI 合作，新一代量产版电动 Atlas 将以 Gemini Robotics 为大脑研究对象，首批量产 Atlas 交付给现代汽车与 Google DeepMind，计划在现代汽车工厂测试。这是一次"回归"——Google 在 2013 年收购、2017 年把 Boston Dynamics 卖给软银。对 BD 来说，这意味着它在 TRI 的 LBM 合作之外，又接入了全球最强的通用推理大脑。

---

5. 技术路线总结：DeepMind 大脑的五条"设计哲学"

1. 母体论：机器人大脑不应从零训练，而是"长在"最强的通用多模态模型上。Gemini 每一次升级（2.0 → 2.5 → 3），机器人大脑都"免费"获得更强的世界知识与推理能力。
2. 分层论：推理（ER）与执行（VLA）分开训练、分开发布、分开迭代。ER 可以做大做慢、调用工具；VLA 必须做快做稳。两者通过自然语言接口连接——这是一种"可解释的分层"，与 Figure Helix 用潜在向量连接两层形成对照。
3. 思考论：动作之前先用语言思考，让 VLA 能处理多步骤任务并具备可解释性。这条路线把 LLM 领域"推理模型（o1/R1）"的成功迁移到了机器人。
4. 跨本体论：Motion Transfer 让一套权重驱动多种形态，把数据便宜的平台（ALOHA 双臂）的能力迁移给数据昂贵的平台（人形）。
5. 平台论：不造整机，做"机器人界的 Android/Gemini API"。ER 开放给所有人，VLA/On-Device 分级授权。

---

6. 横向对比与身位

对比维度	Google DeepMind	Physical Intelligence	NVIDIA GR00T	Figure Helix	特斯拉 Optimus
母体	Gemini（闭源，最强之一）	PaliGemma/Gemma 系（开源 VLM 起步）	Eagle/Cosmos Reason（自研）→ N2 改用世界模型	自研 7B 级 VLM	自研（FSD 体系）
层次结构	ER（推理）+ VLA（执行）+ On-Device	单一 VLA + 高层语言子任务预测（π0.5）	System 2 + System 1 → 世界动作模型	S2 + S1 + S0（三层）	端到端单网络（公开信息有限）
层间接口	自然语言	自然语言（π0.5 的高层推理）	潜在 token	潜在向量	不详
动作生成	动作解码器（细节未完全公开）	流匹配动作专家	DiT 流匹配 → 视频-动作联合生成	视觉运动 Transformer	不详

对比维度	Google DeepMind	Physical Intelligence	NVIDIA GR00T	Figure Helix	特斯拉 Optimus
全身控制	2026.07 才在 2 代纳入	主要为移动操作臂	依赖 WBC（HOVER/SONIC 等）	S0 1kHz 全身控制（2026.01）	自研
开放程度	ER 开放 API；VLA 受限	openpi 开源权重	开源权重（N1 系列）	闭源	闭源
安全评测	最系统（ASIMOV 系列）	一般	一般	不公开	不公开

身位判断：

- 领先之处：具身推理（ER 系列在 15+ 基准上领先）、自然语言交互与多语言、跨本体迁移、安全体系、生态开放（API）。在"机器人通用常识"这一项上，2026 年仍无人能撼动。
- 相对落后之处：①高频全身控制与灵巧操作——2 代的灵巧手成功率（32%–44%）显示其在接触丰富任务上仍落后于专门优化的系统；②真实部署规模——相比特斯拉/Figure 的工厂部署、Generalist 的"数十万小时真实交互数据"、PI 的大量真实家庭测试，DeepMind 的数据飞轮主要依赖自有车队与伙伴；③开源影响力——开发者社区的心智被 openpi、GR00T、LeRobot 占据。
- 一句话：DeepMind 是"机器人大脑的上层建筑"最强者，但"肌肉记忆"仍需伙伴和更多真机数据来补。

---

7. 未来展望与风险

展望（2026Q4–2027）：

1. 与 Gemini 3.x/4 同步升级：DeepMind 的节奏表明，机器人模型会跟随 Gemini 主线迭代（2.0 → 2.5 → 3）。下一代很可能引入更长的视频记忆、更强的 3D 世界表征。
2. 世界模型合流：DeepMind 拥有 Genie 3（实时可交互世界模型）与 Veo（视频生成）两张王牌。将世界模型用于策略评估、合成数据与"想象中训练"，几乎是确定方向——这与 NVIDIA（Cosmos/DreamZero）、1X（世界模型）殊途同归。
3. Atlas + Gemini 的工厂验证：2026–2027 年现代汽车工厂里的 Atlas 将是 Gemini Robotics 的第一块"工业试金石"，其结果将决定 DeepMind 平台路线能否在严苛工业场景里成立。
4. 从 ER 到"机器人 Agent 平台"：ER 2 的多机编排 + 任务追踪 + 工具调用，正在把 Gemini 变成"机器人团队的操作系统"。

风险：

- 平台 vs 整机的路线风险：如果特斯拉/Figure 的"整机端到端 + 自有数据飞轮"跑出显著优势，平台型大脑可能被边缘化为"上层调度器"；
- 数据风险：自有 ALOHA 车队的数据规模与真实世界多样性，可能不及 Generalist（50 万小时+）、它石（百万小时人类数据）等以数据为核心的新玩家；
- 组织风险：Google 机器人团队历史上多次人员流失（PI 的大量创始成员、Skild 合作者等都出自 Google 机器人体系），人才持续外流是 DeepMind 机器人业务的长期隐忧。

---

8. 延伸阅读与核验来源

三篇代表作 - RT-2：Brohan et al., *RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control*, CoRL 2023（arXiv 2307.15818） - Gemini Robotics：*Gemini Robotics: Bringing AI into the Physical World*（arXiv 2503.20020）；*Gemini Robotics 1.5*（arXiv 2510.03342） - Gemini Robotics 2：DeepMind 博客 Gemini Robotics 2 brings whole body intelligence to robots（2026-07-30）

前序与相关 - RT-1（arXiv 2212.06817）；Open X-Embodiment（arXiv 2310.08864）；SayCan（arXiv 2204.01691）；PaLM-E（arXiv 2303.03378）；ALOHA Unleashed（2024） - Gemini Robotics-ER 1.6 博客（2026-04）；Gemini Robotics ER 2 介绍 - Gemini Robotics 1.5 博客（2025-09-25）

2026 动态核验来源 - SiliconANGLE：Gemini Robotics 2 系列 - The Robot Report：Gemini Robotics 2 enables full body control - SiliconANGLE：ER 1.6 - TechCrunch：Boston Dynamics 新一代 Atlas 将有 DeepMind 基因；Boston Dynamics 官方博客 - packetnebula：Gemini Robotics 2 官方基准解读（灵巧手与全身拾取成功率数字来源，为对官方发布内容的二手转述）

> 核验说明：Gemini Robotics 2 的具体成功率数字来自对 DeepMind 7 月 30 日发布内容的二手转述，部分报道对”Apollo 2 所配手型”表述不一；Gemini Robotics 2 尚无完整架构论文公开，本章对其内部结构不做臆测。RT-2、RT-1、OXE、Gemini Robotics 1.0/1.5 的数字来自原论文与官方博客。

第 2 章 Physical Intelligence（π）：一群 Google 老兵如何定义”开源 VLA 的标准答案”

> 一句话定位：全球最具影响力的纯”机器人大脑”创业公司。π 系列（π0 → π0-FAST → π0.5 → π0.6/π*0.6 → π0.7）几乎每一代都成为行业的”参考实现”：π0 确立了”VLM + 流匹配动作专家”架构，π0.5 确立了”异构数据协同训练 + 高层语义子任务”的开放世界泛化范式，π0.6 把强化学习引入大 VLA 的真实部署，π0.7 则把”可引导（steerable）“和”组合泛化”带到台前。openpi 开源仓库让 π 成为全球 VLA 研究与创业公司的事实基线（包括大量中国公司的对标对象）。

0. 速览卡片

维度	内容
成立	2024 年初，旧金山
创始团队	Karol Hausman（CEO，前 Google 机器人）、Sergey Levine（UC Berkeley）、Chelsea Finn（斯坦福）、Brian Ichter（前 Google，SayCan/RT 系列）、Lachy Groom（投资人/运营）等；大量核心研究员来自 Google RT 系列团队
融资	种子轮 7000 万美元（2024.03）；A 轮 4 亿美元（2024.11，估值约 24 亿美元）；B 轮 6 亿美元（2025.11，投后估值约 56 亿美元）；2026 年 3 月彭博报道洽谈约 10 亿美元、投后估值 110 亿美元以上的新一轮（是否完成各方说法不一）
硬件策略	不造机器人；使用 UR5e、Franka、Trossen/ALOHA 式双臂、ARX、移动双臂等多种第三方本体
开源	openpi（π0、π0-FAST、π0.5 权重与训练代码，JAX + PyTorch）
代表模型	π0（2024.10）、π0-FAST（2025.01）、π0.5（2025.04）、KI（2025.05）、RTC（2025.06）、π0.6 / π*0.6（2025.11）、MEM（2026.03）、π0.7（2026.04）
本章三篇代表作	① π0 ② π0.5 ③ π0.7（含其前置技术 π*0.6/RECAP 与 MEM）
身位	学术影响力与开源影响力全球第一；模型能力与 DeepMind 并列第一梯队；商业化最弱环节（收入极少；2026 年 10 月 13 日推出申请制 Pi API 测试版，提供托管微调与推理）

1. 故事的开端：从 Google 走出来的”梦之队”

2023 年，Google 的机器人团队拥有当时世界上最好的 VLA（RT-2）、最大的多机构数据集（OXE）、最强的语言模型。但这个团队也面临大公司的典型困境：机器人研究在 Google 内部的优先级远低于 Gemini，Everyday Robots 在 2023 年初被裁撤，硬件车队缩减。

Karol Hausman 与 Brian Ichter 等人判断：机器人领域的"GPT 时刻"需要一个只做机器人大脑、能够快速试错的组织。他们拉上了深度强化学习与机器人学习领域最有声望的两位教授——Sergey Levine（Berkeley，QT-Opt、SAC、离线 RL 的奠基人之一）与 Chelsea Finn（斯坦福，MAML、ALOHA/Mobile ALOHA 的指导者之一）——于 2024 年成立了 Physical Intelligence。公司名的缩写"π"既是物理智能（Physical Intelligence）的首字母，也暗含"通用常数"的寓意。

π 的战略可以概括为三句话：

1. 只做大脑，不做本体——用尽可能多的不同机器人收集数据，逼模型学会"跨本体"；
2. 数据为王，但要"多样"——相比单纯堆小时数，更看重环境、任务、本体的多样性；
3. 开源基线，闭源前沿——把上一代模型开源给社区（openpi），用最新一代保持领先。

---

2. 代表作一：π0（2024.10）——"VLM + 流匹配动作专家"范式的确立

> 论文：*π0: A Vision-Language-Action Flow Model for General Robot Control*（Black, Brown, Driess, …, Levine, Finn 等，arXiv 2410.24164）

2.1 它要解决的问题

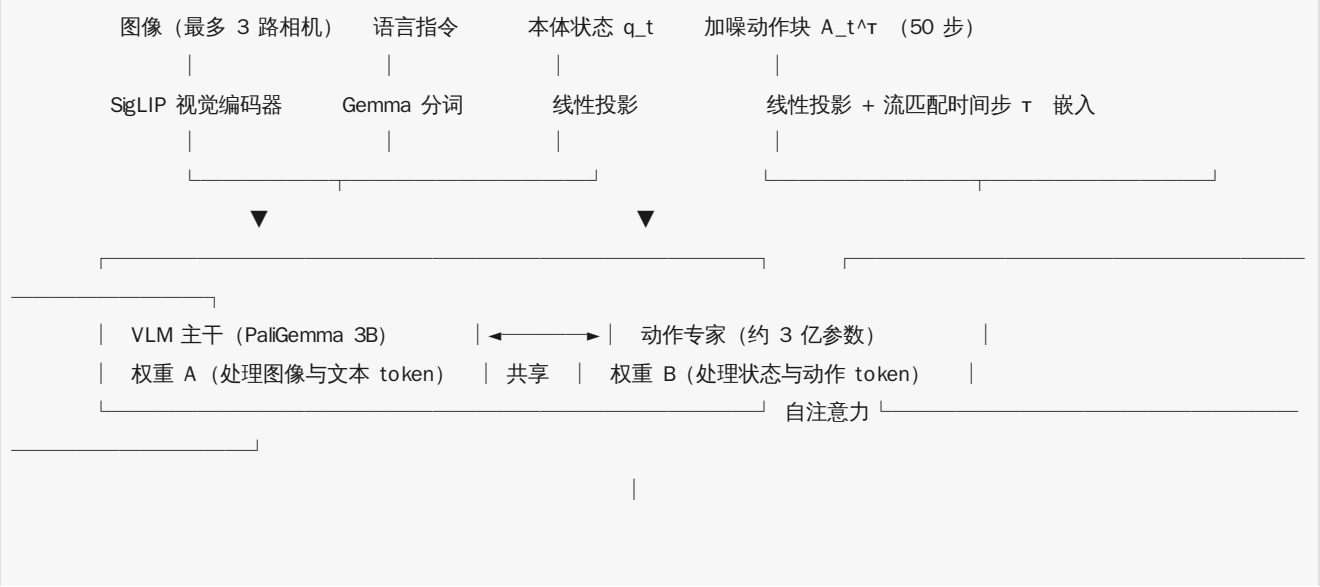
RT-2/OpenVLA 一类"离散 token 化"的 VLA 有两个硬伤：

- 频率太低：自回归一个 token 一个 token 地生成动作，7B 模型往往只有几 Hz，做不了叠衣服这种需要连续、柔顺、高频调整的任务；
- 精度太差：256 桶的量化在双臂灵巧操作中误差积累明显。

另一方面，ACT、Diffusion Policy 这类"小模型 + 连续动作生成"方法虽然能做高频灵巧操作，却没有语义泛化能力，只能"一个任务训一个模型"。

π0 的目标是两者兼得：既继承 VLM 的语义与常识，又能以 50 Hz 输出连续、平滑、精确的动作块。

2.2 架构：一个 VLM + 一个"动作专家"



▼

预测向量场 v_θ（A_t^τ，o_t）→ 积分 10 步得到动作块

关键设计：

1. VLM 主干：PaliGemma（SigLIP 约 4 亿参数视觉编码器 + Gemma 2B 语言模型），总约 30 亿参数，用互联网规模预训练提供语义知识。
2. 动作专家（Action Expert）：一个约 3 亿参数、结构与 Gemma 类似但更窄的 Transformer，专门处理本体状态 token 与动作 token。它与 VLM 主干不是串联的两个模型，而是同一个 Transformer 的两组权重——类似"混合专家（MoE）"：图像/文本 token 走 VLM 的权重，状态/动作 token 走动作专家的权重，但所有 token 在每一层共享自注意力。整体约 33 亿参数。
3. 分块因果注意力（blockwise causal attention）：token 被分成三块——[图像+文本]、[本体状态]、[加噪动作]。前一块不能看到后一块（保证 VLM 前缀可被 KV 缓存复用），块内部双向注意力。这样在推理时，图像和文本只需前向一次，后续 10 步流匹配积分只需重算动作专家部分。
4. 流匹配（Flow Matching）：动作专家不是直接回归动作，而是学习一个"从噪声流向真实动作"的速度场。训练时，取真实动作块 A，采样噪声 ϵ 与时间 τ，构造 $A^\tau = \tau A + (1-\tau)\epsilon$，让网络预测 $(\epsilon - A)$ 方向的速度；推理时从纯噪声出发用欧拉法积分 10 步得到动作块。流匹配相比 DDPM 式扩散更简洁、步数更少。论文还用了一个偏向"高噪声时间步"的 Beta 分布采样 τ，强调学习"从粗到细"的动作结构。
5. 动作块（Action Chunking）：一次输出未来 H=50 步动作，对应 50 Hz 控制下约 1 秒。这一思想来自 ALOHA/ACT，可显著降低高频控制中的复合误差。

2.3 数据："π 数据集 + OXE"的混合配方

- π 自有数据：约 1 万小时的灵巧操作示范，覆盖 7 种机器人构型、68 类任务——包括单臂 UR5e、双臂 UR5e、Franka、双臂 Trossen、双臂 ARX、移动 Trossen、移动 Fibocom 等。
- 开源数据：OXE "Magic Soup" 子集（含 DROID、Bridge 等），提供更大的视觉与场景多样性。
- 采样权重：对每个"任务-机器人"组合按样本量的 $n^{0.43}$ 次方加权，避免大任务淹没小任务。
- 动作空间统一：不同机器人的动作/状态维度不同，统一零填充到最大维度（18 维），由模型自己学会"这台机器人用前几维"。

2.4 训练配方："预训练 + 后训练"，像训练 LLM 一样训练机器人

π0 论文最有影响力的观点之一，是把 LLM 的"预训练-后训练"范式明确引入机器人：

- 预训练：在多样但质量参差的海量数据上训练，让模型学到广泛的能力，尤其是从错误中恢复的行为（因为低质量数据里充满了失误与纠正）；
- 后训练（post-training）：在少量高质量、精心整理的特定任务数据上微调，让模型学会"流畅、高效、可靠"地完成复杂任务。

作者的类比是：只在高质量数据上训练的模型"不知道犯错后该怎么办"；只在多样数据上训练的模型"不够熟练"。两阶段结合，才能既稳又强。

2.5 实验结果

- 开箱即用（零样本）：在叠衬衫、清理桌面（bussing）、装袋、把食品放进烤面包机等任务上，π0 显著超过 OpenVLA（7B，离散 token）与 Octo（93M，扩散头）；
- 语言跟随：与不使用 VLM 初始化的 π0-small 对比，VLM 初始化带来明显的指令跟随提升；
- 后训练的复杂任务：从烘干机取衣服 → 放入篮子 → 带到桌边 → 逐件叠好；清理餐桌；组装纸箱；装鸡蛋。洗衣折叠是当时公认的"机器人图灵测试"之一，π0 的演示视频在行业内引发轰动。
- 与小模型对比：在后训练的灵巧任务上，π0 也超过 ACT、Diffusion Policy 等专门方法，说明大模型预训练在灵巧任务上同样有正迁移。

2.6 openpi：改变行业格局的开源

2025 年 2 月，PI 开源 openpi 仓库，发布 π0 与 π0-FAST 的基础权重、在 ALOHA/DROID/LIBERO 上的微调示例和训练代码（最初基于 JAX，后续支持 PyTorch），2025 年 9 月又开源了 π0.5。开源的影响是深远的：

- 全球无数实验室与创业公司（包括大量中国公司）以 π0/π0.5 为起点做微调或二次开发；
- 第三方评测平台（如 RoboChallenge、RoboArena）把 π0/π0.5 作为"必比基线"——中国的千寻 Spirit v1.5 在 2026 年 1 月登顶 RoboChallenge 时，宣传重点正是"超越 π0.5"；
- Hugging Face LeRobot 把 π0 移植到 PyTorch，使其进入更广泛的开源生态。

2.7 π0-FAST：另一条"离散"支线（2025.01）

π0 发布三个月后，PI 发表了 *FAST: Efficient Action Tokenization for Vision-Language-Action Models*。它重新审视"离散 token 化"路线，问题是：为什么自回归 VLA 在高频灵巧任务上训不动？ 答案是：高频动作在相邻时间步高度相关，逐步、逐维的 256 桶 token 让"预测下一个 token"几乎变成"复制上一个 token"，学习信号极弱。

FAST（Frequency-space Action Sequence Tokenization）的做法借鉴了 JPEG 压缩：

1. 对动作块的每个维度做离散余弦变换（DCT），把时间序列转成频率系数；
2. 对系数做缩放与取整量化（高频系数大多变为 0）；
3. 把各维度的系数按"低频在前"交错展平；
4. 用 BPE（字节对编码） 压缩成更短的 token 序列。

结果：同样的动作块，token 数大幅减少且每个 token 信息量更高；基于 FAST 的自回归 π0-FAST 在训练速度上比扩散版 π0 快约 5 倍，性能相当；PI 还发布了在 100 万条真实轨迹上训练的通用 tokenizer FAST+。代价是推理时需要自回归解码较多 token，速度慢于流匹配。

FAST 的真正价值在后面才显现：它成为 π0.5 预训练阶段和"知识隔离（KI）"训练的关键组件。

---

3. 代表作二：π0.5（2025.04）——走进从未见过的家

> 论文：*π0.5: a Vision-Language-Action Model with Open-World Generalization*（arXiv 2504.16054）；
> 配套：*Knowledge Insulating Vision-Language-Action Models: Train Fast, Run Fast, Generalize Better*（2025.05）

3.1 它要解决的问题

π0 很强，但它是在"见过的环境里"强。如果把机器人放进一个从未见过的真实家庭——陌生的厨房布局、陌生的碗碟、陌生的光照——还能工作吗？这就是"开放世界泛化（open-world generalization）"，也是家用机器人的根本门槛。

PI 的假设是：泛化来自知识迁移，而知识必须来自多种来源。光靠"在目标场景采集数据"是不可扩展的；必须让模型从各种各样的数据中"拼凑"出在新环境中所需的能力。

3.2 数据：一份"异构数据菜谱"

π0.5 的训练数据由以下几类组成（这是论文最核心的贡献之一）：

数据类型	内容	作用
MM：移动操作数据	约 100 个真实家庭中、移动双臂机器人做家务的示范（约 400 小时）	目标场景的直接经验
ME：多环境非移动数据	单臂/双臂静态机器人在多种家庭环境中的数据	环境多样性
CE：跨本体实验室数据	π0 时代的各种实验室数据 + OXE	技能多样性
HL：高层子任务标注	把长任务切分成"捡起盘子""打开抽屉"等语义子任务并标注	学会"下一步该做什么"
WD：网络数据	图像描述、VQA、物体检测	语义与常识
VI：口头指令数据	人类实时口头"教练"机器人完成任务（"把那个碗放进水槽"）	学会听从细粒度指令

一个惊人的事实是：真正来自"移动机器人在家庭中"的数据，只占第一阶段训练样本的极小比例（论文报告约 2.4%）；绝大部分能力来自其他来源的迁移。消融实验显示，去掉 ME 或 CE 数据会显著降低在新家庭中的表现，去掉网络数据则主要损害对"陌生物体"的识别与理解。

3.3 模型与训练：两阶段 + 层级推理

π0.5 的结构延续 π0（VLM + 动作专家），但训练与推理方式升级：

两阶段训练： 1. 预训练阶段：所有数据（包括动作）都以离散 token 的形式训练——动作用 FAST 编码。这让整个模型像训练 VLM 一样高效，且能把机器人数据与网络数据无缝混合。 2. 后训练阶段：加入流匹配动作专家，学习输出连续动作块，以支持高频精细控制；同时继续保留部分离散 token 训练与网络数据，防止遗忘。

层级推理（同一个模型的两次调用）：

```
观察（图像）+ 高层指令："把厨房收拾干净"
            |
            ▼  第一步：模型以文本形式输出"高层子任务"
    "pick up the plate"（捡起盘子）
            |
            ▼  第二步：同一个模型，以子任务为条件，用动作专家输出 50 步连续动作块
    [a_t, a_{t+1}, …, a_{t+49}]
```

这与 DeepMind 的"ER + VLA 两个模型"不同，π0.5 是一个模型扮演两个角色——高层推理与低层控制共享同一套权重，因此高层推理天然"知道"低层能做什么。这种设计被很多后续工作沿用（例如智元 GO-1 的 ViLLA、星海图 G0 等都以不同形式实现了"一个/两个模型的快慢协作"）。

3.4 知识隔离（Knowledge Insulation, KI）

π0.5 发布一个月后，PI 发表了 KI 论文，回答了一个微妙但重要的问题：为什么给 VLM 接上一个随机初始化的动作专家后，VLM 原有的语言与语义能力会"被污染"？

原因是：在联合训练初期，动作专家的梯度质量很差，这些梯度回传进 VLM 主干，破坏了它在互联网上学到的表征。

KI 的方案： - 用 FAST 离散动作 token 训练 VLM 主干（让 VLM 自己学到"动作的表征"）； - 用流匹配训练动作专家； - 在动作专家到 VLM 之间加"梯度截断（stop-gradient）"：动作专家可以读取 VLM 的表征，但它的梯度不回传给 VLM； - 同时继续用网络数据联合训练 VLM。

效果是"训练快（离散 token 训练高效）、运行快（推理用流匹配连续动作）、泛化好（VLM 知识不被破坏）"，即论文标题所说的三件事。这一配方后来成为 π0.6 及很多开源 VLA 的默认做法。

3.5 实验结果

- 在三个从未见过的旧金山真实家庭中，π0.5 驱动的移动双臂机器人完成了收拾厨房（把碗碟放进水槽、擦台面）、整理卧室（叠被子、把衣服放进洗衣篮、捡起地上的物品）等10–15 分钟级别的长时程任务；
- 环境数量的缩放规律：训练环境数量从少到多（直至约 100 个）时，在全新环境上的表现持续上升，在约 100 个环境时，接近"直接在测试环境上训练过的模型"的表现。这条曲线是"数据多样性比数据量更重要"的最有力证据之一；
- 语言跟随：对"把勺子放进抽屉""把衬衫放在床上"之类的细粒度指令的跟随率显著高于 π0。

3.6 局限

PI 在论文与博客中坦承：π0.5 在新家庭中仍然会犯错——抓不稳、走错位置、忘记任务进度（模型没有长期记忆）、在面对极不熟悉的物体时失败。这些问题分别由后续的 π*0.6（RL 自我改进）、MEM（记忆）、π0.7（可引导与组合泛化）去回答。

---

4. 代表作三：π0.7（2026.04）——可引导的通用模型与"涌现能力"

> 论文：*π0.7: a Steerable Generalist Robotic Foundation Model with Emergent Capabilities*（arXiv 2604.15483，2026-04-16）；官方博客 *π0.7: a Steerable Model with Emergent Capabilities*。 前置技术：*π*0.6: a VLA That Learns From Experience*（arXiv 2511.14759，2025.11）；*MEM: Multi-Scale Embodied Memory for Vision Language Action Models*（arXiv 2603.03596，2026.03）。

要读懂 π0.7，必须先理解它的两块"基石"：π*0.6 的 RECAP（从经验中学习）和 MEM（多尺度记忆）。

4.1 前置一：π0.6 与 π*0.6 / RECAP（2025.11）——让 VLA 从自己的经验中变强

π0.6 底座：VLM 主干升级到约 40 亿参数（Gemma 3 4B 级别），动作专家扩大到约 8.6 亿参数，并采用 KI 式训练。

问题：模仿学习的天花板是”示范者的水平”，而且模型无法从部署中的失败里学习。真实工业场景要求的是”连续运行数小时不出错 + 越干越快”。

RECAP（RL with Experience and Corrections via Advantage-conditioned Policies） 的流程：

```
① 预训练：在示范数据上训练 VLA，同时训练一个"价值函数"（分布式价值，预测任务还要多久完成/能否成功）
        ↓
② 部署：机器人自主执行任务，收集"自主经验"；人类在机器人出错时远程接管纠正（"干预/纠错数据"）
        ↓
③ 用价值函数给每段数据计算"优势（advantage）"：这一步比平均水平好还是差？
        ↓
④ 训练"优势条件化策略"：把二值化的优势指示符 I_t（"这一步是好的/不好的"）作为输入条件喂给 VLA
        ↓
⑤ 推理时：始终告诉 VLA "请执行优势为正的动作" → 得到优于平均示范水平的策略
        ↓
   回到②，迭代多轮
```

RECAP 巧妙之处在于：它不需要 PPO 那样的在线策略梯度（对大模型和真机都极不稳定），而是把 RL 转化为”条件化监督学习”——好的数据和坏的数据都用，但打上”好/坏”的标签；推理时只要”好”的那一半行为。这与 LLM 领域的 “Decision Transformer / 奖励条件化” 一脉相承，也和 classifier-free guidance 的思想相通。

价值函数的直观表现：当机器人在推进任务时，价值预测上升；卡住或犯错时，价值走平甚至下降。这本身就是一个可以用于监控的”任务进度计”。

结果：在制作意式浓缩咖啡、在陌生家庭中叠各种衣物、在工厂中组装包装纸箱三类任务上，π*0.6 在最难的任务上吞吐量提升一倍以上、失败率显著下降；媒体报道其能连续一整天制作咖啡、长时间不间断叠衣服、在真实工厂中组装纸箱，成功率在 90% 以上。

4.2 前置二：MEM（2026.03）——给机器人装上”多尺度记忆”

π0.5 的一大失败模式是”忘事”：收拾厨房到一半，忘了哪些柜子已经检查过。MEM（Multi-Scale Embodied Memory）给 VLA 设计了两种记忆：

- 短时视频记忆：用视频编码器把过去若干帧（多相机、多时间步）压缩成紧凑表征，让模型感知”刚才发生了什么”（例如物体被遮挡前在哪里）；
- 长时文本记忆：模型用自然语言写下并更新”已完成事项摘要”（例如”已经擦完台面，水槽里还有两个碗”），作为长期记忆随时读取。

视频负责”细节与动态”，文本负责”长程与抽象”——这种”多尺度”设计让基于 π0.6 的机器人能完成长达约 15 分钟的整厨清洁等任务。

4.3 π0.7 的核心思想：可引导（Steerable）

π0.7 的核心洞察是：机器人数据的”质量”是高度异质的——同样是叠衣服，有人做得快、有人做得慢；有的成功、有的失败；有的用关节控制、有的用末端控制。传统 VLA 把这些数据一视同仁地混在一起训练，结果模型学到的是”平均水平”甚至更差。

π0.7 的回答：把”这段数据是怎么做的”也作为输入告诉模型，让模型学会”在条件 X 下应该如何行动”；推理时，用户通过指定条件来”引导（steer）“模型的行为。

4.4 架构与输入

π0.7 约 50 亿参数，由三部分组成：

组件	规模	作用
VLM 主干	约 40 亿参数	理解图像、语言与各类条件
MEM 式视频历史编码器	—	压缩多相机、多帧历史
动作专家	约 8.6 亿参数	流匹配输出连续动作块

输入的”多模态提示（multi-modal prompt）“： 1. 相机图像：最多 4 路相机，每路最多 6 帧历史； 2. 语言：任务指令、子任务指令，乃至人类的”口头教练”（verbal coaching）； 3. 子目标图像（subgoal images）：最多 3 张”当前子步骤结束时场景应该是什么样”的图像——由一个以 BAGEL（字节跳动开源的统一多模态模型）初始化的世界模型异步生成（二手资料称约 140 亿参数、约每 4 秒或意图变化时刷新一次）； 4. 回合元数据（episode metadata）：描述这段行为”如何完成”的标签，如速度、质量等； 5. 控制模式标签：告诉模型输出关节空间还是末端空间的动作。

训练技巧——条件随机丢弃：训练时每种条件都会被随机丢弃（例如子目标图像只出现在约 25% 的样本中，元数据约 15% 的时间被整体丢弃），使得推理时任意子集的条件都能工作；推理时还可以在元数据上使用 classifier-free guidance（CFG），进一步放大”更快”“更高质量”等期望行为。

4.5 关键发现

1. “元数据让数据缩放重新成立”：论文报告，不带元数据的 π0.7 在更大、质量混杂的数据上训练时，性能反而可能下降；带元数据的 π0.7 则随数据增加持续提升。这是一个对整个行业都很重要的结论——它意味着”收更多数据”必须配合”更好的数据标注/条件化”，否则规模化会被低质量数据拖累。
2. 组合泛化（compositional generalization）：π0.7 能完成训练数据中从未出现的”任务 × 本体”组合。最有代表性的例子是：在 UR5e 机械臂上叠衬衫——训练集中没有任何 UR5e 叠衬衫的数据——仅通过人类的口头分步指导就完成了任务。这说明模型把”叠衬衫的知识”（来自其他本体）和”UR5e 的运动能力”（来自其他任务）组合了起来。
3. 通才追平 RL 专才：论文称，π0.7 开箱即用（无任务专属后训练）即可在论文涉及的所有任务上与 π*0.6 的 RL 专用策略相竞争——包括意式浓缩咖啡制作、纸箱组装、叠衣服——并且在多样化叠衣服与纸箱组装上的吞吐量甚至高于 RL 专才；同时 PI 也坦承，在专才训练过的大量重复任务上，专才仍可持平或更好。
4. 跨本体的”口头教练”：二手解读称，π0.7 在 UR5e 上零样本叠衬衫的成功率约 80%，接近专家遥操作员的约 80.6%（未在论文原文中逐字核实）。

4.6 为什么 π0.7 重要

π0.7 标志着 VLA 设计哲学的一个转向：从"模型输出什么"到"如何给模型下指令"。语言只是提示的一种；子目标图像、元数据、控制模式、口头教练都是提示。这与 LLM 从"补全模型"走向"指令遵循 + 系统提示"的历程高度相似。它也把世界模型（生成子目标图像）作为"规划器"嵌入到 VLA 的输入端——这是 2026 年"VLA 与世界模型合流"大趋势的一个典型样本。

---

5. 技术路线总结：PI 的"方法论"

年份	关键问题	PI 的答案	对行业的影响
2024	大模型如何输出高频连续动作？	VLM + 流匹配动作专家（π0）	成为 VLA 主流架构（GR00T、GO-1、G0、WALL-OSS、Xiaomi-Robotics-0 等都采用类似结构）
2025.01	自回归 VLA 为何训不动？	FAST 频域 token 化	成为离散预训练的标准 tokenizer
2025.04	如何在没见过的环境工作？	异构数据协同训练 + 高层子任务（π0.5）	"数据多样性 > 数据量"成为共识
2025.05	动作专家为何破坏 VLM？	知识隔离（KI）	成为训练默认配方
2025.06	推理延迟导致动作块衔接抖动？	实时动作分块（RTC）	解决异步执行的工程问题
2025.11	如何超越示范者水平？	RECAP 优势条件化 RL（π*0.6）	开启"VLA + 真机 RL"热潮
2026.03	长任务忘事？	MEM 多尺度记忆	记忆成为 VLA 标配组件
2026.04	混合质量数据拖累缩放？	可引导多模态提示 + 元数据（π0.7）	"数据条件化"成为新范式

PI 的方法论有一个鲜明特征：每一步都在解决上一代模型在真实部署中暴露出的具体问题，并且把解决方案写成可复现的论文。这使它在学术界的公信力极高。

---

6. 横向对比与身位

与 DeepMind 的对比：两者是"同门师兄弟"——PI 的创始团队大多来自 Google RT 系列。区别在于：DeepMind 依托 Gemini 母体，强在推理与语言；PI 依托开源 VLM（PaliGemma/Gemma）做小而精的模型，强在动作质量、数据配方与 RL 后训练。DeepMind 用两个模型分层（ER + VLA），PI 倾向于一个模型兼任高低层（π0.5）并用多模态提示引导（π0.7）。

与 NVIDIA GR00T 的对比：GR00T N1 在结构上借鉴了 π0（VLM + DiT 流匹配），但更强调仿真与合成数据（DreamGen、Isaac）；PI 几乎完全依赖真实数据。2026 年 NVIDIA 转向"世界动作模型"（DreamZero/GR00T N2），PI 则把世界模型作为"子目标生成器"接入 π0.7——两者在"世界模型如何进入机器人大脑"上给出了不同答案。

与中国追赶者的对比：π0/π0.5 是中国大量 VLA 公司的直接对标物。2026 年 1 月千寻 Spirit v1.5 在 RoboChallenge 上超过 π0.5，说明在"开源上一代"层面，中国团队已经追平；但 π0.7（未开源）所代表的可引导性、组合泛化与 RL 后训练体系，仍是领先的。

身位：模型能力全球第一梯队（与 DeepMind、Generalist 并列），学术影响力与开源影响力第一；商业化最慢——截至 2026 年中，公开报道普遍认为其收入极少。

2026 年 10 月 13 日：Pi API Beta。多家媒体报道，PI 开放了 Pi API 测试版：开发者可以上传自己的机器人数据、在 PI 托管的算力上微调 Pi 模型，并通过托管推理网关把得到的模型部署到自己的机器人上；访问需申请、分批开通，尚无公开价目表。关于开放了哪些模型，报道说法不一（有报道称包括 π0、π0.5 等；另有分析指出此次未发布新模型）。这是 PI 从"研究 + 开源"走向"模型即服务"的标志性一步，也印证了本章对其"平台化"路径的判断。

---

7. 未来展望与风险

展望： 1. 从模型公司到平台公司：API/微调服务化是自然的下一步，PI 可能成为"机器人界的 OpenAI"——向本体厂商、集成商提供模型与微调服务； 2. RL 规模化：RECAP 证明了真机 RL 的可行性，下一步是"车队级"的持续学习——每台部署的机器人都在为模型贡献经验； 3. 世界模型的深度整合：π0.7 已用世界模型生成子目标，未来可能进一步用世界模型做策略评估与"想象中训练"。

风险： 1. 数据护城河：PI 不做本体、不做部署，数据主要靠自建采集团队与合作伙伴。相比特斯拉、Figure（自有工厂）或 Generalist（数十万小时真实交互）、它石（百万小时人类数据），PI 的数据规模是否足够，存在疑问； 2. 估值压力：百亿美元级估值需要商业化兑现，而机器人大脑的商业模式（按机器人授权？按 API 调用？）仍未被验证； 3. 开源的"双刃剑"：openpi 让行业整体进步，也让追赶者快速追平上一代能力。

---

8. 延伸阅读与核验来源

三篇代表作 - π0：arXiv 2410.24164；openpi GitHub - π0.5：arXiv 2504.16054；Knowledge Insulation（2025.05） - π0.7：arXiv 2604.15483；PI 博客 π0.7

前置与相关 - π0-FAST / FAST tokenizer：arXiv 2501.09747 - π*0.6 / RECAP：arXiv 2511.14759；PI 博客 - MEM：arXiv 2603.03596 - Real-Time Chunking（RTC，2025.06）

2026 动态核验来源 - Humanoids Daily：π0.7 与组合泛化 - Emergent Mind：π0.7 摘要 - Implicator：PI 接近 10 亿美元融资、估值翻倍 - physicalailab：PI 模型、openpi 与 Pi API（2026.10） - Unite.AI：Physical Intelligence 开放 Pi API 测试版；DoNews：Pi API 走向托管服务

> 核验说明：π0/π0.5/FAST/KI/π*0.6 的技术细节来自原论文与官方博客；π0.7 的参数拆分（4B + 视频编码器 + 860M）与输入规格来自论文摘要及多篇一致的二手解读；"子目标世界模型约 14B"仅见于二手资料；2026 年融资与 API 信息各方说法不一，本文已标注。补充核验：π0.7 开箱即与 π0.6 RL 专才竞争、在多样化叠衣服与纸箱组装上吞吐量更高来自论文原文；UR5e 叠衬衫约 80% vs 专家 80.6% 为二手解读；模型规模另有"7B"的说法，本章采用多数来源的约 5B。

第 3 章 NVIDIA：卖铲子的人，也在定义”金矿的形状”

> 一句话定位：NVIDIA 是人形机器人”全栈基础设施”的唯一供应者——从训练用的 GPU、仿真用的 Isaac Sim/Isaac Lab/Newton、合成数据用的 Cosmos 世界模型，到机器人端侧的 Jetson Thor 芯片，再到开源的 GR00T 人形基础模型。它的大脑路线经历了一次关键转向：从 2025 年”VLM + DiT 双系统”的 GR00T N1 系列，转向 2026 年以视频生成模型为母体的”世界动作模型（World Action Model, WAM）“——DreamZero，并以此作为下一代 GR00T N2 的基础。NVIDIA 的每一次路线选择，都会通过它庞大的开发者生态迅速变成行业”默认选项”。

0. 速览卡片

维度	内容
机构	NVIDIA（Isaac 机器人平台 + GEAR 实验室 + Cosmos 团队）
核心人物	Jensen Huang（战略推动者）；GEAR（Generalist Embodied Agent Research）实验室由 Jim Fan 与 Yuke Zhu 共同领导；Deepu Talla（机器人与边缘计算副总裁）
大脑模型谱系	GR00T N1（2025.03）→ N1.5（2025.05）→ N1.6（2025 下半年）→ N1.7（2026，商用授权）→ GR00T N2（基于 DreamZero，计划 2026 年底）
世界模型	Cosmos WFM（2025.01）→ Cosmos Predict / Transfer / Reason 系列 → Cosmos Reason 2 → Cosmos 3（GTC 2026 宣布，LeRobot 集成规划中）
全身控制	HOVER（2024，多模式统一全身控制器）、SONIC（2025.11，运动追踪规模化的人形行为基础模型）
仿真与数据	Isaac Sim、Isaac Lab、Newton 物理引擎（与 DeepMind、迪士尼合作）、GR00T-Mimic / DexMimicGen、GR00T-Dreams / DreamGen
端侧算力	Jetson AGX Thor（Blackwell 架构，面向人形机器人的车载计算平台）
开放程度	GR00T 权重与代码开源（GitHub: NVIDIA/Isaac-GR00T；Hugging Face）；N1.7 提供商用授权；SONIC 开源
本章三篇代表作	① GR00T N1（及 N1.5–N1.7 演进）② Cosmos 世界基础模型平台（含 DreamGen 应用）③ DreamZero 世界动作模型（GR00T N2 的基础）
身位	生态影响力全球第一；开源人形基础模型的”默认选择”之一；在”世界模型 → 策略”这条路线上处于引领者位置

1. 故事的开端：为什么一家芯片公司要做机器人大脑？

2024 年 3 月的 GTC 大会上，黄仁勋身后站着一排人形机器人——Figure、Agility、Apptronik、傅利叶、宇树、1X……他宣布了 Project GR00T（Generalist Robot 00 Technology）。这个场景本身就是 NVIDIA 机器人战略的隐喻：NVIDIA 不造机器人，但它希望所有机器人都站在它的平台上。

NVIDIA 的逻辑是"三台计算机"理论：

1. 训练计算机（DGX）：训练机器人基础模型；
2. 仿真计算机（OVX + Omniverse/Isaac Sim）：生成合成数据、做仿真训练与测试；
3. 机器人计算机（Jetson Thor）：在机器人上运行模型。

而 GR00T 基础模型、Cosmos 世界模型，本质上都是为了让这三台计算机被用起来的"示范应用"与"生态黏合剂"：开源一个足够好的模型，让所有本体厂商以它为起点；它所依赖的数据生成、仿真和推理，自然全部发生在 NVIDIA 的硬件与软件栈上。

但如果只把 GR00T 看作"营销"，就低估了它。GEAR 实验室在 Jim Fan 与 Yuke Zhu 的带领下，产出了 Voyager、Eureka、MimicGen、HOVER、DreamGen、SONIC、DreamZero 等一系列有影响力的研究，其中一些在学术上处于领先位置。

---

2. 代表作一：GR00T N1（2025.03）——"数据金字塔"与开源人形双系统

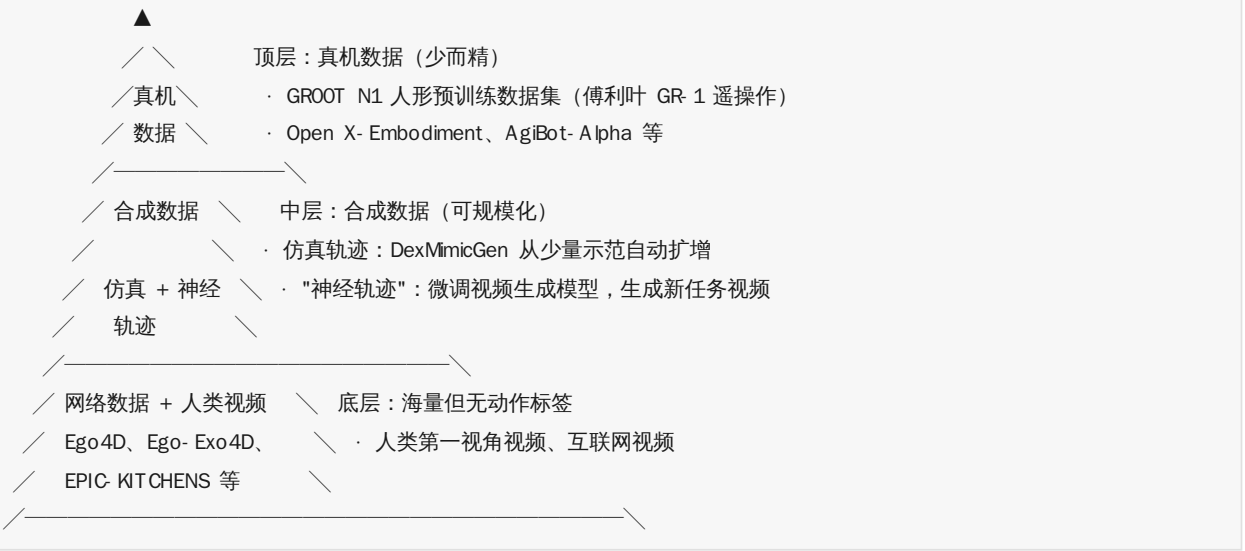
> 论文：*GR00T N1: An Open Foundation Model for Generalist Humanoid Robots*（NVIDIA，arXiv 2503.14734，GTC 2025 发布）

2.1 要解决的问题

2025 年初，人形机器人行业面临的核心问题是：人形机器人的真机数据极度稀缺。不同于自动驾驶（有数百万辆车产生数据）、不同于 LLM（有整个互联网），人形机器人的遥操作数据昂贵、慢、且每家本体都不同。

GR00T N1 的回答是一座"数据金字塔"，以及一个能消化金字塔每一层数据的模型。

2.2 数据金字塔



金字塔的核心难题是：底层和中层的视频数据没有”动作标签”——人类视频里没有机器人的关节角。GR00T N1 用了两种方法给它们”补标签”：

1. 潜在动作（Latent Actions）：借鉴 LAPA，训练一个 VQ-VAE，输入视频的当前帧与未来帧，学习一个离散的”潜在动作码”来解释两帧之间的变化。这样任何视频都能被标注为一串潜在动作，作为一种虚拟的”LAPA 本体”参与训练。
2. 逆动力学模型（IDM）伪标签：在有动作标签的机器人数据上训练一个 IDM（给定前后帧，预测中间动作），再用它给生成的视频标注伪动作。

合成数据的规模：论文报告用 DexMimicGen 在约 11 小时内生成了约 78 万条仿真轨迹（相当于约 6500 小时的人类示范）；用微调后的视频生成模型生成了数百小时的”神经轨迹”视频。

2.3 架构：System 2 + System 1



关键设计细节：

- 总参数约 22 亿（N1-2B），其中 VLM 约 13 亿；
- 取 VLM 中间层特征：作者发现用 LLM 第 12 层而非最后一层的表征，推理更快、下游策略效果更好——因为最后几层过度特化于”生成文本”；
- 每张图仅 64 个视觉 token（224×224 输入，经 pixel shuffle 压缩）；
- 本体专属编解码器：用不同的 MLP 处理不同机器人的状态与动作维度，让一个 DiT 主干支持多种本体（单臂、双臂、人形、“LAPA 虚拟本体”）；
- 推理效率：在 L40 GPU 上采样一个 16 步动作块约 64 毫秒。

2.4 训练

- 预训练：在金字塔全部数据上端到端训练（VLM 语言部分冻结），第三方汇总称 GR00T-N1-2B 预训练约使用 5 万 H100 GPU 小时（未在论文原文中逐字核实）；
- 后训练：在特定本体/任务上微调，可只用少量数据。

2.5 实验结果

- 仿真基准：在 RoboCasa（厨房移动操作）、DexMimicGen 跨本体基准、GR-1 桌面操作基准上，GR00T N1 在少数据设置下均优于 Diffusion Policy 等基线；
- 真机：在傅利叶 GR-1 人形机器人上执行抓放、关抽屉、双手交接、工业零件摆放等任务；论文显示在仅使用约 10% 训练数据时，GR00T N1 依然大幅领先于用全量数据训练的部分基线，体现出预训练的样本效率优势；
- 神经轨迹的贡献：加入视频生成的"神经轨迹"数据后，仿真与真机任务成功率都有可观提升。

2.6 演进：N1.5 → N1.6 → N1.7

版本	时间	关键变化
N1.5	2025.05（Computex）	VLM 升级为针对"指代与定位（grounding）"微调的 Eagle 2.5 且完全冻结；简化适配层；引入 FLARE（未来潜在表征对齐）目标，能从人类第一视角视频中学习；结合 DreamGen 合成数据，语言跟随能力显著提升
N1.6	2025 下半年	VLM 换为内部 Cosmos-Reason-2B 变体，支持原生长宽比输入；DiT 从 16 层加深到 32 层；VLM 顶部 4 层解冻；去掉后处理适配器；加入更多本体数据（宇树 G1 行走操作、双臂 YAM、智元 Genie-1 等）
N1.7	2026	VLM 换为 Cosmos-Reason2-2B（基于 Qwen3-VL 架构）；DiT 维持 32 层；加入 EgoScale 大规模人类第一视角预训练以增强开箱即用的灵巧性；提供商用授权；通过 Hugging Face 博客以"开放推理 VLA"定位发布，并接入 LeRobot

演进的逻辑：NVIDIA 在 2025 年的一年里不断加大"推理型 VLM"（Cosmos Reason）在 GR00T 中的比重，同时加深动作 DiT——这与 PI 的 π0.6（4B VLM + 860M 动作专家）思路相近。但到了 2026 年，NVIDIA 判断这条路线有天花板，开始转向世界动作模型（见第 4 节）。

2.7 意义与局限

意义：GR00T N1 是第一个开源的、明确面向人形机器人的基础模型，其"数据金字塔"框架被行业广泛引用；本体专属编解码器 + 共享主干的设计，成为跨本体 VLA 的标准做法之一。大量中国人形公司（宇树的 UnifoLM-VLA-0 就基于 Qwen2.5-VL 与 GR00T 的代码体系）以 GR00T 为起点。

局限：开箱即用的零样本能力有限，真实部署仍需大量后训练；“VLM 中间层 + 小 DiT”的结构在语义泛化上弱于 π0.5/Gemini Robotics；对全身行走操作的支持依赖外部全身控制器。

---

3. 代表作二：Cosmos 世界基础模型平台（2025.01–）——给物理 AI 造一个”数据宇宙”

> 论文：*Cosmos World Foundation Model Platform for Physical AI*（NVIDIA，arXiv 2501.03575，CES 2025 发布）；后续：Cosmos Predict 2/2.5、Cosmos Transfer、Cosmos Reason 1/2；应用：*DreamGen: Unlocking Generalization in Robot Learning through Neural Trajectories*（2025.05）

3.1 要解决的问题

如果真机数据是稀缺的，那么”能否用一个足够好的物理世界模拟器，生成无限的训练数据？“传统物理仿真（Isaac Sim）精确但”假”——渲染画面与真实世界存在视觉鸿沟，且建模每一个场景、每一种可变形物体都极其耗时。视频生成模型（如 Sora）画面逼真但”不懂物理”，也不受控制。

Cosmos 的目标是打造面向物理 AI 的”世界基础模型（World Foundation Model, WFM）“：一个预训练好的、懂物理、可被下游开发者微调成”某个机器人/某辆车的专属世界模拟器”的视频模型。

3.2 平台构成

组件	内容
数据管线	从约 2000 万小时原始视频中筛选、切分、标注，得到约 1 亿个高质量片段，重点覆盖驾驶、手部操作、人体运动、物体交互、相机运动等”物理丰富”的内容
Cosmos Tokenizer	视频分词器，提供连续（用于扩散模型）与离散（用于自回归模型）两种，在高压缩率下保持高重建质量
扩散式 WFM	7B 与 14B 两种规模，文本/图像/视频条件生成未来视频
自回归式 WFM	4B 与 12B 两种规模，基于离散 token 逐帧预测
后训练示例	相机位姿条件化、机器人操作（动作条件化的未来预测）、自动驾驶多视角生成
安全护栏	输入输出过滤，防止生成有害内容

3.3 Cosmos 家族的分化（2025）

- Cosmos Predict：世界预测模型（“给定现在，预测未来”），用于策略评估、合成数据；
- Cosmos Transfer：多模态条件生成（类似 ControlNet），输入仿真器渲染的分割图、深度图、边缘图，输出逼真视频——把 Isaac Sim 的”假画面”变成”真画面”，大幅缩小 sim2real 视觉鸿沟；
- Cosmos Reason：具备物理常识与时空推理的 VLM（Reason 1 为 7B，Reason 2 有 2B 等多个规模），既可做数据标注与过滤的”评论家”，也成为 GR00T N1.6/N1.7 的 VLM 主干。

这三者形成一个闭环：Reason 理解与评判 → Predict 想象未来 → Transfer 把仿真变真实。

3.4 DreamGen：世界模型如何变成机器人数据

DreamGen 是把 Cosmos 思想落地到人形机器人的代表应用（论文使用 WAN2.1 等视频模型作为底座，方法本身与具体视频模型解耦），它的四步流程是：

```
① 微调视频世界模型：用目标机器人（如 GR-1）的少量真机遥操作视频微调视频生成模型，
   让它"学会这台机器人的外观与运动学"
        ↓
② 提示生成"梦境"：给定初始帧 + 新的语言指令（"把水倒进杯子""用锤子敲"），
   生成大量机器人执行新任务、在新环境中的合成视频
        ↓
③ 恢复伪动作：用逆动力学模型（IDM）或潜在动作模型，从合成视频中反推动作序列
        ↓
④ 用"神经轨迹"训练策略
```

结果：论文报告，仅凭在单一环境中采集的”抓放”类遥操作数据，GR-1 人形机器人就能借助 DreamGen 学会在 10 个新环境中执行 22 种新行为（如倒水、敲击、折叠等动词层面的新技能）。这是”用世界模型扩展机器人技能边界”的早期有力证据。NVIDIA 随后把它产品化为 GR00T-Dreams 蓝图。

3.5 意义

Cosmos 的意义不仅在于模型本身，更在于它把”世界模型”从研究概念变成了一套可下载、可微调的开发者工具。它让”合成数据”从”仿真器专家的手工活”变成了”提示词 + GPU 时长”的规模化生产。中国的极佳科技（GigaWorld）、蚂蚁灵波（LingBot-World）、智元（Genie Envisioner）等，都在这一方向上与 Cosmos 形成对标或竞争。

---

4. 代表作三：DreamZero（2026.02）——“世界动作模型即零样本策略”，GR00T N2 的基础

> 论文：*World Action Models are Zero-shot Policies*（NVIDIA GEAR，arXiv 2602.15922，2026.02）；项目页 dreamzero0.github.io；NVIDIA 技术博客 *Pretrained to Imagine, Fine-Tuned to Act: The Rise of World-Action Models*

4.1 问题的提出：VLA 的”物理泛化”天花板

DreamZero 论文的出发点是一个尖锐的观察：

> 当前最先进的 VLA 擅长语义泛化（认识新物体、理解新指令），但在新环境中面对从未见过的物理动作时泛化很差。

原因在于 VLA 的母体是 VLM——VLM 在互联网图文上学到的是”这是什么”，而不是”世界会如何运动”。动作专家只能从有限的机器人数据中学动力学。

而视频生成模型恰恰相反：它在海量视频上学到的就是”世界如何随时间演变”——物体如何下落、布料如何折叠、手如何与物体交互。如果机器人大脑的母体不是 VLM，而是视频生成模型，会怎样？

4.2 核心思想：动作只是视频的又一个”模态”

DreamZero 的方法论可以用一句话概括：联合生成”未来视频”与”动作”，让动作成为同一个去噪过程中被生成的另一个模态，不再需要单独的动作头。



这种设计带来三个好处：

1. 继承视频模型的物理先验：140 亿参数的视频模型在海量视频中学到的运动、接触、形变规律，直接为动作生成服务；
2. 视频作为稠密监督：与 VLA 只用”动作”监督不同，WAM 在训练时还要预测未来视频，这提供了远比动作标签更稠密的学习信号；
3. “想象”与”行动”一致：模型生成的动作与它想象的未来是同一个过程的产物，天然自洽。

4.3 训练与推理

- 母体：阿里开源的 Wan2.1-I2V-14B-480P 图生视频模型；
- 结构：一个自回归扩散 Transformer，以流匹配同时预测”未来视频 latent”与”动作块”——不另设逆动力学解码器；
- 时间分辨率：视频按约 5 FPS 采样，动作在智元平台上为 30Hz、在 DROID（Franka）上为 15Hz；每个块约覆盖 1.6 秒（开源仓库中推理使用 24 步动作块）；
- 机器人数据：约 500 小时智元 G1 遥操作数据 + DROID（Franka）；另有只在 DROID（约 7.5 万条片段）上训练的 DreamZero-DROID 版本——这也说明中国开源/公开数据（智元）已成为全球前沿研究的基础资源；
- 对比基线：π0.5-DROID 与 NVIDIA 内部的 GR00T N1.6-DROID；在智元 G1 的未见任务上报告零样本结果；
- 开源：预训练、微调与评测代码（GitHub dreamzero0/dreamzero）及 Hugging Face 检查点；
- 推理速度：项目页报告每个动作块推理约 150 毫秒，可实现约 7Hz 的闭环控制。对于一个 14B 的视频扩散模型，这是相当激进的工程优化结果（当然，7Hz 仍低于 VLA 动作专家常见的 50Hz 级别，因此高频细节仍依赖底层控制器）。

4.4 关键结果

- 零样本泛化：在未见过的任务与环境上，DreamZero 的表现显著优于现有 VLA（NVIDIA 在 GTC 2026 发布 GR00T N2 预览时称：基于该架构的模型在新环境中完成新任务的成功率是领先 VLA 的两倍以上——

这是厂商宣称，尚无独立评测）；

- 跨本体视频迁移：仅用 10–20 分钟来自人类或其他机器人的纯视频示范（无动作标签），就能让模型在未见任务上获得 42% 以上的性能提升。这意味着”看一段视频学一个技能”开始在大模型层面变得可行。

4.5 GR00T N2：路线转向

2026 年 3 月 GTC 主题演讲中，黄仁勋预告了 GR00T N2：基于 DreamZero 研究的”世界动作模型”架构，计划于 2026 年底推出。行业评论普遍认为这标志着 GR00T 正在从”以 VLM 为主干”转向”以世界模型为主干”。

与此同时，现有产品线继续由 N1.7（商用授权版）承接。NVIDIA 还宣布与 Hugging Face 合作把 GR00T 1.7 引入 LeRobot 生态，并规划 Cosmos 3。

4.6 WAM 路线的争议

- 算力成本：14B 视频扩散模型的训练与推理成本远高于 3–5B 的 VLA，端侧部署需要 Jetson Thor 级算力乃至更高；
- 控制频率：7Hz 的闭环频率意味着它更像一个”高层运动规划器”，仍需与 SONIC 一类高频全身控制器配合；
- 语言与推理能力：视频模型的语言理解远弱于 VLM，复杂指令理解和多步推理如何保证？NVIDIA 的答案可能是”Cosmos Reason 做推理 + WAM 做执行”的组合，但具体形态要等 N2 正式发布。

---

5. 补充：全身控制的”小脑”——HOVER 与 SONIC

一个人形机器人大脑如果只有”上层 VLA/WAM”，是走不了路的。NVIDIA 在全身控制上的两项代表工作：

- HOVER（2024，与 CMU 等合作）：一个统一的神经全身控制器，支持多种控制模式（根速度、关节角、末端位姿、动捕追踪等），通过”掩码”切换模式，避免为每种模式训练一个控制器；
- SONIC（2025.11，arXiv 2511.07820）：*Supersizing Motion Tracking for Natural Humanoid Whole-Body Control*。核心判断是：“运动追踪（motion tracking）”就是人形控制的可扩展基础任务——人类动捕数据提供了逐帧的稠密监督，无需为每个技能手工设计奖励。SONIC 把网络从 120 万参数扩展到 4200 万参数，使用约 700 小时动捕（1 亿帧以上）、约 2.1 万 GPU 小时训练，得到一个包含编码器、解码器与运动学规划器的”人形行为基础模型”，开源发布（面向宇树 G1 29 自由度构型），并提供低延迟遥操作版本。

分层结构：GR00T（VLA/WAM）→ 输出上层目标（末端位姿、根速度、运动片段）→ SONIC/HOVER（高频全身控制器）→ 关节力矩。这与 Figure Helix 02 的 S0/S1/S2、逐际 COSA 的 System 0/1/2 在结构上一致——“三层大脑”正在成为人形机器人的行业共识架构。

---

6. 技术路线总结

阶段	主干	动作生成	数据哲学	代表
2025 上半年	Eagle VLM（中间层特征）	DiT + 流匹配	数据金字塔 + 潜在动作	GR00T N1 / N1.5
2025 下半年 – 2026 上半年	Cosmos Reason VLM	更深的 DiT（32 层）	加入人类第一视角规模化预训练（EgoScale）	N1.6 / N1.7
2026 下半年 –	视频扩散世界模型（14B）	与视频联合去噪	视频即监督；纯视频示范即可学技能	DreamZero → GR00T N2

NVIDIA 的路线有一个一以贯之的主题：“数据从哪里来”。从数据金字塔，到 Cosmos 合成数据，到 DreamGen 神经轨迹，再到 DreamZero 直接以视频为母体——NVIDIA 一直在寻找绕开”真机数据稀缺”的办法。这与 PI/Generalist 的”真实数据为王”形成了鲜明的路线对立。

---

7. 横向对比与身位

维度	NVIDIA GR00T/DreamZero	PI π 系列	DeepMind Gemini Robotics
母体	VLM（N1 系）→ 视频世界模型（N2）	VLM（Gemma 系）	Gemini
数据哲学	合成 + 视频 + 真机金字塔	真实数据多样性	自有车队 + 网络数据
开源	权重开源，N1.7 可商用	上一代开源	ER 开放 API
全身控制	SONIC/HOVER 独立开源	弱	2 代纳入
商业逻辑	卖芯片、卖算力、卖平台	卖模型/API	卖 API/平台授权

身位判断： - 生态位：NVIDIA 是唯一一家在”训练-仿真-推理”三个环节都占据主导的公司，GR00T 的真正竞争力在于它与 Isaac/Cosmos/Jetson 的整合，以及 NVIDIA 作为”中立供应商”对所有本体厂商的吸引力（例如据报道 LG 于 2026 年 8 月宣布基于 Isaac GR00T 技术栈开发双足人形，计划 2027 年一季度公开亮相）； - 模型能力：GR00T N1 系列在纯模型能力上略逊于 π0.5/Gemini Robotics，但 DreamZero 在”物理动作泛化”这一维度上可能实现反超——这取决于 GR00T N2 的实际表现； - 影响力：Cosmos + GR00T 让”世界模型 + 合成数据”成为行业热词，在中国尤为明显。

---

8. 未来展望与风险

展望： 1. GR00T N2 能否兑现：如果 WAM 架构在真实人形部署中证明了”2 倍于 VLA”的新任务泛化能力，2027 年行业可能出现从 VLA 向 WAM 的大规模迁移； 2. Cosmos 3 与”物理 AI 数据工厂”：合成数据的质量与可控性将决定 NVIDIA 在数据侧的话语权； 3. Jetson Thor 及其后继：WAM 的高算力需求恰恰利好 NVIDIA 的端侧芯片业务——这是商业上的”自洽”。

风险： 1. “既当运动员又当裁判”：NVIDIA 的模型越强，与其客户（本体厂商、大脑公司）的竞争就越直接，可能促使客户转向自研或其他平台（例如特斯拉自研 AI5 芯片、中国厂商转向国产算力）； 2. 中国市场：出口管制使中国人形厂商在高端训练与端侧芯片上越来越多地寻求替代（地平线、华为等），NVIDIA 在中国的生态影响力存在下滑风险； 3. 视频模型路线的不确定性：WAM 能否满足高频、精细、强接触的工业操作要求，尚未被大规模验证。

9. 延伸阅读与核验来源

三篇代表作 - GR00T N1：arXiv 2503.14734；GitHub NVIDIA/Isaac-GR00T；Hugging Face：GR00T N1.7 博客 - Cosmos：arXiv 2501.03575；DreamGen（arXiv 2505.12705） - DreamZero：arXiv 2602.15922；项目页；NVIDIA 技术博客：The Rise of World-Action Models

相关 - SONIC：arXiv 2511.07820；Hugging Face nvidia/GEAR-SONIC - HOVER（arXiv 2410.21229）

2026 动态核验来源 - The Humanoid Hub：GR00T N2 基于 DreamZero 的世界动作模型 - NVIDIA 博客：NVIDIA 与 Hugging Face 为 LeRobot 带来新模型 - DeepWiki：Isaac-GR00T 版本说明

> 核验说明：GR00T N1 架构与训练细节来自原论文；N1.6/N1.7 的结构变化来自官方 GitHub 仓库与 Hugging Face 模型卡（N1.6 发布时间各来源有出入，本文按 2025 下半年处理）；DreamZero 的母体模型、推理速度、视频迁移收益来自论文与项目页；“GR00T N2 新任务成功率为领先 VLA 两倍以上”为 NVIDIA 在 GTC 2026 的官方宣称，尚无独立验证。补充核验：DreamZero 的单一自回归 DiT（流匹配联合预测视频 latent 与动作块）、5 FPS 视频 / 30Hz（智元）与 15Hz（DROID）动作、约 1.6 秒分块、约 500 小时智元 G1 遥操作数据 + DROID、对比 π0.5-DROID 与 GR00T N1.6-DROID 来自 arXiv 论文与开源仓库。

第 4 章 Skild AI：卡内基梅隆的”全身体大脑”与机器人的”上下文学习”

> 一句话定位：Skild AI 是全球估值最高的机器人大脑公司之一（2026 年 1 月 C 轮后估值超过 140 亿美元），由 CMU 两位教授 Deepak Pathak 与 Abhinav Gupta 创办。它的路线可以概括为”全身体（omni-bodied）”：一个大脑驱动四足、人形、机械臂、移动操作臂等一切形态，并且能在没见过的身体上通过”上下文适应”自我调整。2026 年 8 月发布的 S1 把”上下文学习（in-context learning）“带进了机器人：看一段演示视频就能完成长达 10 分钟、预训练中从未见过的任务。与 PI 的”学术公开”不同，Skild 几乎不发表技术论文，更偏”产品化 + 商业化”，并已宣称年化收入突破 1 亿美元。

0. 速览卡片

维度	内容
成立	2023 年，匹兹堡
创始人	Deepak Pathak（CEO，CMU 助理教授，好奇心驱动探索、极限跑酷、LEAP Hand）；Abhinav Gupta（总裁，CMU 教授，大规模自监督机器人学习先驱）
融资	A 轮 3 亿美元（2024.07，估值约 15 亿美元，Lightspeed、Coatue、软银、贝索斯等）；2025 年软银与 NVIDIA 等参与新一轮；C 轮 14 亿美元（2026.01.14，软银领投，估值超过 140 亿美元）
商业化	2026 年 3 月宣布与 ABB Robotics、Universal Robots（优傲）合作；公司称年化经常性收入（ARR）超过 1 亿美元
产品	Skild Brain（2025.07）→ 跨本体上下文适应（2025.09）→ S1：机器人上下文学习（2026.08）
开放程度	闭源；几乎没有完整技术报告，主要通过博客、演示视频与访谈披露
本章三篇代表作	① Skild Brain（2025.07）② “全身体”上下文适应：一个大脑适应未见过的身体（2025.09）③ S1：长时程任务的视频上下文学习（2026.08）；附：创始人学术谱系中的关键论文
身位	商业化与资本化最成功的纯大脑公司之一；在”跨形态（四足+人形+机械臂）通用性”上最激进；技术透明度低，难以独立评估

1. 故事的开端：两位教授的”数据饥渴症”

要理解 Skild，得先理解两位创始人在学术界的”执念”。

Abhinav Gupta 是”规模化机器人数据”思想最早的倡导者之一。2016 年他与学生 Lerrel Pinto 发表的 *Supersizing Self-supervision: Learning to Grasp from 50K Tries and 700 Robot Hours*，是最早用数万次真机试

错训练抓取的工作之一；2018 年的 *Robot Learning in Homes* 把低成本机器人放进真实家庭采集数据，比 π0.5 早了七年提出”家庭多样性”的价值。他的信条是：机器人缺的不是算法，是数据；而数据必须来自真实世界的多样性。

Deepak Pathak 则来自强化学习与”学会适应”的方向。他的代表作包括 2017 年的 *Curiosity-driven Exploration*（ICM，好奇心驱动探索）、2021 年的 *RMA: Rapid Motor Adaptation*（四足机器人在线适应地形，与 Berkeley Jitendra Malik 合作）、2023 年的 *Extreme Parkour*（四足机器人仅凭单目深度相机完成跳跃、攀爬等极限跑酷）、*LEAP Hand*（低成本灵巧手）以及 *VRB: Affordances from Human Videos*（从人类视频中学习”哪里可以抓、怎么动”）。他的信条是：真正的智能体现在”适应”——在没见过的情况下快速调整。

这两个信条，正好构成了 Skild 的两条主线：规模化的多样数据（来自仿真与人类视频），以及在推理时的快速适应（上下文学习）。

2023 年，二人离开 CMU 全职创业（保留学术身份），2024 年 7 月以 15 亿美元估值完成 3 亿美元 A 轮——这在当时是一家”还没有发布产品”的机器人大脑公司前所未有的估值。

---

2. 代表作一：Skild Brain（2025.07）——“全身体”通用大脑的首次亮相

> 发布形式：官方博客与演示视频（2025 年 7 月下旬）；无完整技术报告。

2.1 它展示了什么

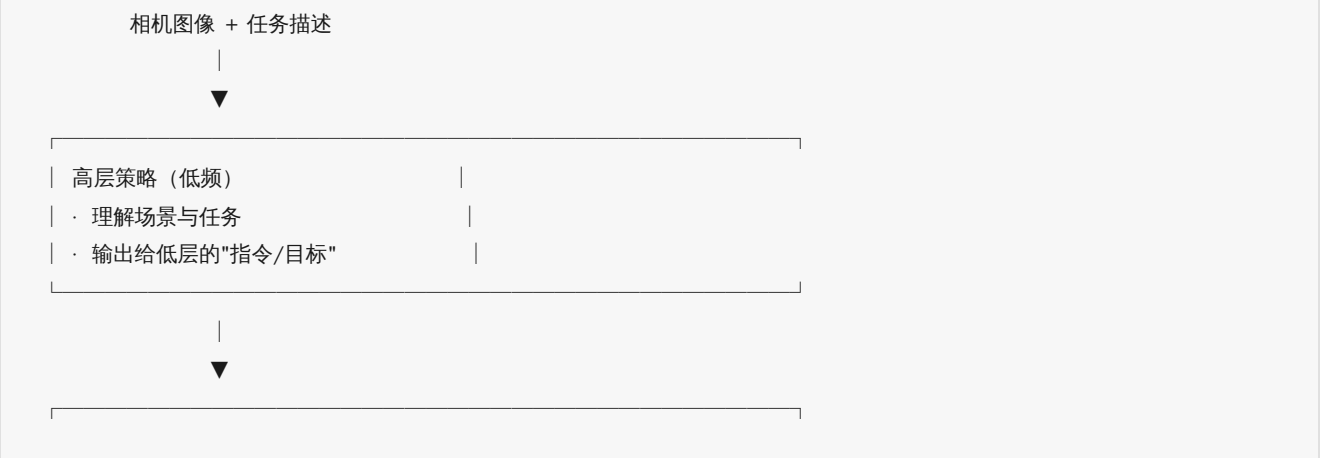
2025 年 7 月底，Skild 发布 Skild Brain 的演示视频，其内容非常”硬核”：

- 四足与人形机器人在陡峭、满是碎石与断枝的林地中行走，爬楼梯；
- 机器人被人从侧面猛踹后恢复平衡；
- 在杂乱的桌面上分拣碗碟，期间被人类故意干扰（移动物体、推开手臂）仍能继续完成；
- 在不同硬件上运行同一个大脑：四足、人形、桌面机械臂、移动操作臂。

2.2 公开披露的技术路线

由于没有技术报告，以下内容来自 Skild 博客、访谈与多方报道的交叉印证：

（1）分层双频率架构



```
  │ 低层策略（高频）                    │
  │ · 把高层指令转换为关节角度与电机力矩    │
  │ · 负责平衡、抗扰动、接触适应           │
  └──────────────────────────────────────┘
                    │
                    ▼
    四足 / 人形 / 机械臂 / 移动操作臂
```

这与 Figure Helix、GR00T 的双系统在思想上一致，但 Skild 的重点是：低层策略本身要能跨形态工作——这是其"全身体"主张的技术核心。

（2）数据：仿真 + 人类视频 + 少量真机后训练

Skild 公开表示，其预训练数据主要来自两个来源： - 大规模仿真：在 NVIDIA Isaac Lab / Omniverse 上，对海量不同形态（不同腿长、质量分布、关节配置）的虚拟机器人做强化学习训练。有二手资料称其仿真训练覆盖了约 10 万种形态，但未得到一手资料确认； - 互联网人类视频：Skild 把"人"看作"另一种机器人本体"——人类视频中的动作意图与物体交互，作为一种跨形态知识注入模型。

之后再用有针对性的少量真实数据后训练，形成交付给客户的解决方案。

（3）为什么强调"全身体"

Pathak 的核心论点是：如果一个大脑只在一种机器人上训练，它学到的是"这台机器人的特性"；如果它在成千上万种形态上训练，它被迫学到的是"物理世界中如何移动与操作的一般规律"。这与 LLM 的逻辑类似——在足够多样的数据上训练，模型学到的是"语言的一般规律"而非"某篇文章的写法"。

2.3 局限

Pathak 本人在 2025 年的访谈中坦承：人形机器人上的表现仍然有限，因为团队"还没来得及把模型规模化到人形"。早期演示中，操作任务主要在机械臂与轮式平台上展示，人形主要展示行走与抗扰动。

---

3. 代表作二：一个大脑适应"没见过的身体"（2025.09）

> 发布形式：Skild 博客与 Deepak Pathak 社交媒体（2025 年 9 月）："In-context learning for Robotics is here. Skild Brain adapts to new bodies and survives extreme shifts — without ever being trained on any of these robots."

3.1 实验设计：故意"弄坏"机器人

这是 Skild 最有辨识度的一组演示：

- 把机器人的腿锯短或加装高跷，改变腿长与质量分布；
- 让机器人某个电机失效或被卡住；
- 把模型放到一台从未在训练中出现过的全新机器人上。

结果是：Skild Brain 在几秒钟内”察觉”到身体的变化，并调整步态继续行走或完成任务——没有任何梯度更新，也没有针对这些机器人的训练数据。

3.2 技术原理：上下文中的”系统辨识”

这种能力的学术根源可以追溯到 Pathak 参与的 RMA（Rapid Motor Adaptation，2021）：

- 训练时，在仿真中随机化机器人的物理参数（质量、摩擦、电机强度、腿长等）；
- 让策略的输入包含最近一段时间的状态-动作历史；
- 策略被迫从这段历史中隐式推断”我现在是一个什么样的身体、处于什么样的环境”，并据此调整行为。

Skild 把这一思想规模化：当训练覆盖的形态足够多、历史上下文足够长、模型足够大时，策略在推理时就表现出类似 LLM “上下文学习”的能力——把最近的交互历史当作”提示”，在线适应一个新身体。Pathak 称之为”机器人的上下文学习”，这也为一年后的 S1 埋下了伏笔。

3.3 意义

这组演示回答了人形机器人产业的一个现实痛点：硬件在不断变化。每一代本体都会改变关节配置、质量分布、电机特性；如果每次都要重新采集数据训练，大脑公司将被硬件迭代拖垮。“全身体 + 上下文适应”给出的答案是：让大脑天然对硬件变化鲁棒。这也是 Skild 能同时向 ABB（工业机械臂）、Universal Robots（协作臂）以及各类四足/人形厂商销售的基础。

---

4. 代表作三：S1——长时程任务的视频上下文学习（2026.08）

> 官方博客：*Introducing S1: In-Context Learning for Robotics*（Skild AI Team，2026-08-18；媒体报道集中于 8 月 25 日前后）。

4.1 问题：机器人学新任务为什么这么贵？

2026 年的主流 VLA（π0.5、GR00T、Gemini Robotics）学一个新任务的标准流程是：采集几十到几百条遥操作示范 → 微调（后训练）→ 部署。这意味着每个新任务都要几天到几周的工程投入。即便是 Gemini Robotics On-Device 2 宣称的”不到 200 条示范”，也仍是”训练”而不是”告诉”。

LLM 的历史告诉我们：真正的通用性体现在上下文学习——给 GPT-3 几个例子，它不用更新权重就能做新任务。S1 的目标就是让机器人做到同样的事：给它看一段演示视频，它就会做。

4.2 S1 做到了什么（据 Skild 官方与多方报道）

- 单视频提示：输入一段（人或机器人）完成任务的演示视频作为”提示”，S1 在不更新权重、不微调的情况下执行该任务；
- 长时程：任务长度可达约 10 分钟，例如栽种盆栽、煎薄饼、手冲咖啡这类多步骤、长序列、涉及多种工具与材料的任务；
- 任务在预训练中从未出现过。

4.3 关键数据：上下文学习 vs 语言提示

Skild 公布了一组对比（来自公司自有评测，经多家媒体转述）：

方法	在预训练未见过的任务上的成功率
以语言为提示的模型（预训练数据 10 万小时级）	约 9%
S1 视频上下文学习	约 66%

另一个被广泛引用的数字是：一条视频示范带来的性能，约相当于 380 条任务专属后训练示范的效果。

解读： 1. 语言提示的天花板：仅靠一句”做一杯手冲咖啡”，模型必须在预训练中见过类似任务才能做；面对真正的新任务，成功率断崖下跌（9%）。这揭示了当前 VLA”语义泛化”的边界：理解”做什么”不等于知道”怎么做”。 2. 视频提示的信息量：一段演示视频包含了任务的步骤顺序、物体位置、手部动作、工具使用方式等大量程序性知识，模型只需要”对齐”而不需要”发明”。 3. 数据规模的门槛：上下文学习能力在 LLM 中是”规模涌现”的；S1 的结果暗示机器人领域也在接近类似的门槛——这与 Generalist GEN-1.5（单次 3–12 秒人类示范学会新任务）几乎同时出现，形成了 2026 年夏天”机器人上下文学习”的集体突破叙事。

4.4 推测的技术实现（基于公开信息与学术脉络的分析）

Skild 没有公开 S1 的架构，但结合其公开表述与学术脉络，可以合理推断其关键要素：

1. 超长上下文：要把一段数分钟的演示视频与实时观察同时放入上下文，模型必须具备高效的长视频编码与记忆机制（类似 PI MEM 的多尺度记忆思想）；
2. “人是另一种本体”：Skild 一贯把人类视频作为训练数据，这使得模型具备”看人做 → 自己做”的跨形态映射能力，是视频提示可行的前提；
3. 大规模多任务预训练 + 元学习式训练目标：要让模型学会”从演示中学习”，训练数据中需要大量”演示-执行”配对，让模型学会”如何使用上下文中的演示”——这与 LLM 中通过多样任务预训练涌现 ICL 的机制类似。

（以上为分析推断，非 Skild 官方披露。）

4.5 质疑与局限

- 评测透明度：66%/9% 与”380 条示范”均来自 Skild 内部评测，尚无第三方复现；
- 任务难度的定义：演示任务（栽花、煎饼、手冲咖啡）虽然长，但多为桌面级、可重复的家务/餐饮流程，对精度与可靠性的要求低于工业装配；
- 依赖广泛预训练：S1 的上下文学习依然建立在海量预训练之上，“一条视频学会”并不意味着”任何视频都能学会”。

---

5. 技术路线总结：Skild 的”三位一体”

支柱	内容	学术根源
全身体（Omni-bodied）	一个大脑跨四足、人形、机械臂、移动平台	Gupta 的规模化数据思想；跨形态仿真训练

支柱	内容	学术根源
适应（Adaptation）	从交互历史中在线推断身体与环境，零梯度适应	Pathak 的 RMA、好奇心驱动探索
人类视频（Human-as-embodiment）	把人类视频当作一种机器人数据	VRB、HRP 等从人类视频学习可供性的工作

S1 正是这三根支柱在 2026 年的汇合：大规模跨形态预训练（全身体）+ 上下文中的快速适应（适应）+ 以视频为提示（人类视频）。

---

6. 横向对比与身位

维度	Skild AI	Physical Intelligence	Generalist AI
核心叙事	全身体 + 上下文学习	可引导的通用 VLA + RL	真实数据缩放定律 + 和声推理
数据主来源	仿真 + 人类视频 + 少量真机	多本体真机遥操作 + 网络数据	数十万小时人类真实操作数据
形态覆盖	四足、人形、机械臂、移动操作臂	机械臂、移动双臂	各类末端执行器（夹爪到五指手）
学术透明度	低（博客 + 视频）	高（论文 + 开源）	中（博客 + 部分数据）
商业化	ARR 超 1 亿美元（公司称），工业伙伴	很少	早期伙伴（如 Elite Robots）
2026 标志性成果	S1（视频 ICL，10 分钟任务）	π0.7（可引导、组合泛化）	GEN-1.5（3–12 秒示范，一次学会）

身位判断： - Skild 是”最像产品公司的大脑公司”：估值与收入在纯大脑公司中领先，工业伙伴（ABB、UR）意味着它的大脑正在进入真实产线； - 技术上，“全身体 + 适应”是其独特优势，在运动控制与跨形态鲁棒性上可能领先所有竞争者；在灵巧操作与语义推理上，公开证据不如 PI/DeepMind 充分； - 由于缺乏技术报告与开源，学术界与开发者社区对 Skild 的认知更多来自演示视频，这在一定程度上限制了其生态影响力。

---

7. 未来展望与风险

展望： 1. “一段视频就能部署”：如果 S1 的能力在工业场景被验证，机器人部署成本将从”每任务数周”降到”每任务一段视频”，这是机器人商业化最关键的一步； 2. 工业伙伴渠道：通过 ABB、UR 等存量巨大的工业机械臂装机基础，Skild 可能比人形整机公司更早实现大规模软件授权收入； 3. 人形的”补课”：Pathak 承认人形是短板，2026–2027 年 Skild 在人形全身操作上的进展值得重点关注。

风险： 1. 可验证性：在没有技术报告、没有开源、没有第三方评测的情况下，百亿美元估值高度依赖演示视频与公司自述； 2. 数据来源：仿真 + 人类视频的路线在”高精度接触操作”上是否足够，仍有疑问（相比之下，Generalist 依赖数十万小时真实操作数据）； 3. 竞争：GEN-1.5、π0.7 在同一时间窗口内提出了类似的”少样本/一次学会”能力，Skild 的先发优势窗口可能很短。

---

8. 延伸阅读与核验来源

三篇代表作 - Skild Brain 发布：The Robot Report：Skild AI is giving robots a brain（2025.07） - 跨身体上下文适应：Deepak Pathak 2025 年 9 月发布 - S1：Skild 官方博客 Introducing S1（2026-08-18）；The Robot Report：S1；Humanoids Daily：S1 长时程上下文学习

创始人学术谱系（建议阅读） - Pinto & Gupta, *Supersizing Self-supervision*（ICRA 2016） - Gupta et al., *Robot Learning in Homes*（NeurIPS 2018） - Pathak et al., *Curiosity-driven Exploration by Self-supervised Prediction*（ICML 2017） - Kumar, Fu, Pathak, Malik, *RMA: Rapid Motor Adaptation for Legged Robots*（RSS 2021） - Cheng et al., *Extreme Parkour with Legged Robots*（2023） - Bahl et al., *Affordances from Human Videos as a Versatile Representation for Robotics (VRB)*（CVPR 2023）

2026 动态核验来源 - Business Wire：Skild AI 融资 14 亿美元，估值超 140 亿美元 - The Robot Report：Skild AI 融资 14 亿美元打造全身体大脑 - Robotics & Automation News：S1 从视频示范学习任务

> 核验说明：Skild 没有发布完整技术报告，本章"架构"部分来自官方博客与媒体报道的交叉印证；"S1 66% vs 9%""1 条视频 ≈ 380 条示范"均为公司内部评测经媒体转述；网络上流传的"Skild Brain 5000 亿参数""Brain 2.0 1.2 万亿参数"等说法仅见于来源可疑的二手网站，本章不予采信；ARR 超 1 亿美元为公司自述。第 4.4 节为基于公开信息的分析推断，已明确标注。

第 5 章 Generalist AI：用”数十万小时真实数据”证明机器人存在缩放定律

> 一句话定位：Generalist AI 是 2025–2026 年崛起最快的机器人大脑公司，由 RT-2/PaLM-E 的核心作者 Pete Florence、Code as Policies 的作者 Andy Zeng 与前 Boston Dynamics 工程师 Andrew Barry 创办。它最鲜明的主张是：机器人的”GPT 时刻”取决于真实世界数据的规模，而不是仿真或架构技巧。GEN-0（2025.11）用超过 27 万小时真实操作数据首次在机器人领域展示出可预测的缩放定律；GEN-1（2026.04）把多项任务的成功率推到 99% 以上、速度提升约 3 倍；GEN-1.5（2026.08）实现了”看一次 3–12 秒的人类示范就学会新任务”。它是 2026 年”机器人上下文学习”叙事的两大主角之一（另一位是 Skild S1）。

0. 速览卡片

维度	内容
成立	2024 年（2025 年走出隐身模式），美国
创始人	Pete Florence（CEO，前 Google DeepMind 高级研究科学家，PaLM-E、RT-2 核心作者）；Andy Zeng（前 Google，Code as Policies、Transporter Networks、Socratic Models 作者）；Andrew Barry（前 Boston Dynamics）
融资	多轮融资，报道称获得包括黄仁勋、李飞飞等知名人士支持的约 2 亿美元融资（具体轮次与估值以官方为准）
模型谱系	GEN-0（2025.11.04）→ GEN-1（2026.04）→ GEN-1 多末端执行器支持（2026.07）→ GEN-1.5（2026.08.19）
数据	GEN-0：超过 27 万小时真实操作数据，每周新增约 1 万小时；GEN-1：超过 50 万小时真实交互数据
开放程度	闭源；通过官方博客披露技术要点；早期访问伙伴（如中国协作机器人公司艾利特 Elite Robots，2026.07 宣布合作）
本章三篇代表作	① GEN-0：和声推理与机器人缩放定律 ② GEN-1：可靠性与速度的跃迁 ③ GEN-1.5：一次示范的上下文学习
身位	“真实数据规模”上的全球领先者；技术叙事上与 PI、Skild、DeepMind 并列第一梯队；商业化处于早期

1. 故事的开端：从 RT-2 作者到”数据工厂”

Pete Florence 在 Google 期间参与了机器人领域两篇最重要的论文：PaLM-E（2023，562B 的具身多模态语言模型）和 RT-2（2023，VLA 的开山之作）。Andy Zeng 则是”用语言和代码驱动机器人”思想的代表人物（Code as Policies 让 LLM 直接写机器人控制代码；Socratic Models 让多个基础模型通过语言协作）。

这两人在 Google 亲眼看到了一个事实：RT-2 的语义泛化来自网络数据，但它的"技能"完全被 RT-1 那 13 万条示范所限制。无论 VLM 多大，机器人能做的动作种类都没有扩大。他们得出的结论是：

> 机器人智能的瓶颈不是模型，而是物理交互数据的规模与多样性。只有当真实操作数据达到"互联网级别"，机器人才会出现 LLM 那样的缩放定律与涌现能力。

于是 Generalist 的核心工作不是"设计更巧妙的网络"，而是"建一座真实世界数据工厂"——在世界各地的家庭、仓库、工作场所大规模采集真实的人类操作数据。从公开信息看，其数据主要由人类借助专门的采集设备在真实环境中完成日常操作产生（这与 UMI、Sunday 的手套等"无本体采集"路线同属一类），而非传统的机器人遥操作——这也解释了为何其数据能以每周上万小时的速度增长。

---

2. 代表作一：GEN-0（2025.11.04）——和声推理与机器人缩放定律

> 官方博客：*GEN-0: Embodied Foundation Models That Scale with Physical Interaction*（generalistai.com，2025-11-04）

2.1 数据：27 万小时，且每周增长 1 万小时

GEN-0 的预训练数据是超过 27 万小时的真实世界多样化操作数据，并以每周约 1 万小时的速度增长（且在加速）。作为参照：

数据集/公司	规模（量级）
RT-1 数据集（Google，2022）	约 13 万条示范（约数百小时量级）
Open X-Embodiment（2023）	100 万+ 条轨迹（数千小时量级）
π0 自有数据（2024）	约 1 万小时
AgiBot World（2025）	100 万+ 条轨迹（约 3000 小时量级）
GEN-0（2025.11）	27 万+ 小时
GEN-1（2026.04）	50 万+ 小时

这是 2025 年底公开报道中规模最大的真实机器人/操作预训练数据之一，比此前最大的公开数据集高出一到两个数量级。

2.2 和声推理（Harmonic Reasoning）：没有"系统 1 / 系统 2"的双系统

几乎所有同时代的人形大脑（Figure Helix、GR00T、智元 GO-1、星海图 G0）都采用"慢思考 + 快执行"的双系统。Generalist 提出了一个不同的方案——和声推理：

- 模型内部有两条异步的、连续时间的 token 流：一条是"感知流"（持续摄入传感器信息），一条是"动作流"（持续输出动作）；
- 两条流不是"先想后做"的串行关系，也不是"慢的指挥快的"的层级关系，而是像音乐中的和声一样同时进行、相互协调；
- 模型"边感知边思考边行动"，在不需要把思考和行动拆成两个模型的前提下，兼顾推理深度与实时反应。

为什么这样设计：物理世界不会”等你想完”。在真实操作中，物体会滑动、人会打断，模型必须在行动的同时持续更新理解。双系统架构中，慢系统的延迟会导致快系统基于”过时的意图”行动；和声推理试图从根本上消除这种时间错位。

（Generalist 没有公开和声推理的具体网络结构，以上为其官方博客的概念性描述。）

2.3 缩放定律：机器人第一次出现”可预测的变强”

GEN-0 最重要的贡献是实证了机器人领域的缩放定律：

1. 预训练数据与算力越多，下游后训练性能越好，且这种提升是”一致且可预测”的——跨越多个任务，都可以用类似 LLM 的幂律曲线拟合；
2. 模型规模的”相变”：据多方解读，Generalist 观察到小模型（约 10 亿参数级）在吸收大规模复杂物理数据时会出现”僵化（ossification）”——权重逐渐无法吸收新信息，继续加数据也不再变好；而 70 亿参数及以上的模型能够持续内化大规模机器人预训练数据。（此阈值来自二手解读，Generalist 一手博客的摘录中未见确切数字。）

这一发现的意义：它为整个行业回答了一个价值数百亿美元的问题——“继续投钱采集数据和扩大模型，机器人会不会变得更好？” GEN-0 的答案是”会，而且可预测”。这直接影响了 2026 年全行业的数据军备竞赛：它石智航宣称要冲击千万小时人类数据、蚂蚁灵波把 VLA 2.0 的预训练数据扩到 6 万小时、智元/银河通用等持续扩大数据采集中心。

2.4 局限

- GEN-0 主要是一个”预训练基座 + 缩放实验”的展示，具体任务性能的公开数据有限；
- 数据来源（人类操作数据）与机器人本体之间的”形态鸿沟”如何弥合，官方未详细披露。

---

3. 代表作二：GEN-1（2026.04）——从”能做”到”做得可靠、做得快”

> 发布：2026 年 4 月初（SiliconANGLE 报道日期为 4 月 6 日）；7 月扩展至多种末端执行器。

3.1 关键指标

指标	GEN-1	对照
多项任务成功率	超过 99%（并非所有任务）	此前系统约 64%（公司对比口径）
纸箱组装时间	约 12.1 秒	GEN-0 与 PI 的 π0 均约 34 秒
任务完成速度	约为现有方法的 3 倍	—
适配新任务所需机器人数据	约 1 小时	传统需数十至数百小时
预训练数据	50 万小时+ 真实交互数据	GEN-0 时为 27 万小时

3.2 “99%”意味着什么

机器人行业有一句话：“演示 80% 的成功率很容易，商用要的是 99.9%”。在工厂、仓库里，一个 80% 成功率的机器人意味着每 5 次就要人工介入一次——这比不用机器人还麻烦。GEN-1 宣称在多项任务上突破 99%，是

Generalist 把"缩放定律"转化为"商业可用性"的关键一步。

Generalist 自己也强调 GEN-1 "远非完美、并不能解决所有任务"，但这种"可靠性优先"的叙事，与 PI π*0.6（用 RL 提升可靠性与吞吐）、Dyna Robotics（强调商业可靠性）一起，代表了 2026 年行业从"炫技演示"走向"可靠交付"的转向。

3.3 "速度"为什么重要

把纸箱组装从 34 秒压缩到 12 秒，意义不只是"快"：

- 商业 ROI：机器人的经济价值与吞吐量直接相关；比人慢 3 倍的机器人很难回本；
- 技术含义：VLA 慢的原因之一是模仿学习学到的是"人类示范者在遥操作时的谨慎速度"；GEN-1 能显著快于示范者，说明其训练与推理中引入了超越模仿的技术（Generalist 只说"引入了新的训练与推理技术"，未披露细节）。

3.4 预训练不含"机器人数据"

据报道，GEN-1 的预训练数据不包含机器人本体数据（以人类真实交互数据为主），新本体、新任务的适配在后训练阶段首次接触机器人数据，而只需约 1 小时。这是一个非常激进的路线声明：机器人大脑可以主要从"人如何与物理世界交互"中学习，机器人数据只用于最后的"形态对齐"。

3.5 多末端执行器（2026.07）

2026 年 7 月，Generalist 宣布 GEN-1 支持广泛的末端执行器——从五指拟人手到采用新驱动方式的专用工具。这意味着同一个大脑可以服务于平行夹爪、吸盘、灵巧手等不同硬件，进一步扩大了其商业适用面。同月，中国协作机器人厂商艾利特（Elite Robots）宣布与 Generalist 合作开发下一代具身智能。

---

4. 代表作三：GEN-1.5（2026.08.19）——"看一次就会"

> 发布：2026 年 8 月 19 日官方博客与演示。

4.1 核心能力

GEN-1.5 是一个能从一次简短的人类示范中学会新物理任务的机器人基础模型：

- 示范长度约 3–12 秒；
- 无需梯度更新、无需微调——纯上下文学习；
- 输入包括视频、传感器信号、语言与机器人位姿，以 100Hz 输出动作，上下文窗口约 30 秒。

4.2 关键数据（公司自有评测）

设置	10 项新任务平均成功率
仅看一次示范（one-shot，零梯度）	约 59%
用约 5 分钟数据、约 10 步参数更新微调后	约 83%

此外，Generalist 还发布了诸如"安装 O 型圈"之类的精细操作演示（未附基准数据）。多位来自大型实验室的研究者将其称为"机器人的 GPT-3 时刻"（Radical Ventures 博客转述）；质疑者则指出尚无独立测试。

4.3 与 Skild S1 的对比

2026 年 8 月，两家公司几乎在同一周发布了"机器人上下文学习"：

维度	Generalist GEN-1.5	Skild S1
发布	2026-08-19	2026-08-18（博客日期）
提示形式	3–12 秒人类示范（含传感器/位姿等多模态）	一段演示视频
任务长度	短时程精细操作为主（如 O 型圈安装）	长时程（最长约 10 分钟，如手冲咖啡）
公布成绩	一次示范 59%；5 分钟微调后 83%	视频 ICL 66% vs 语言提示 9%
控制频率	100Hz 输出	未公开
数据底座	50 万小时+ 真实人类交互	仿真 + 人类视频 + 真机

两者共同指向一个结论：当预训练数据足够大、足够多样时，机器人模型会出现与 LLM 类似的上下文学习能力。这可能是 2026 年机器人领域最重要的范式信号——它预示着机器人部署的方式将从"采数据 → 训模型"转向"给示范 → 直接做"。

4.4 为什么"3–12 秒"很关键

- 采集成本：3–12 秒的示范可以由现场工人随手完成，而不需要专业遥操作员与昂贵的遥操作设备；
- 长尾任务：工厂与家庭中充满了"每个只做几次"的长尾任务，按任务采集数百条数据永远不划算；一次示范学会是解决长尾的唯一可扩展方式；
- 与人类学习的类比：人类学徒看师傅做一遍就能模仿——GEN-1.5 首次在机器人大模型上逼近这种学习效率（尽管成功率仍远低于人类）。

---

5. 技术路线总结：Generalist 的"三个押注"

1. 押注真实数据规模：不依赖仿真、不依赖互联网视频，而是建立专门的真实人类操作数据采集体系，把数据做到 50 万小时以上；
2. 押注缩放定律：相信"更多数据 + 更大模型 = 可预测的更强"，并在 GEN-0 中给出实证；
3. 押注统一的感知-行动流：用和声推理替代主流的双系统，追求"边感知边行动"的连续智能。

这三个押注相互强化：只有数据足够多，大模型才不会"僵化"；只有模型足够大，统一的感知-行动流才能同时承载推理与控制；只有统一的流，才能在 100Hz 下利用 30 秒的上下文做到"看一次就会"。

---

6. 横向对比与身位

与 PI 的对比：二者都来自 Google RT 系列体系、都相信"预训练-后训练"范式。区别在于：PI 主要使用机器人遥操作数据 + 网络数据、强调数据多样性与条件化（π0.7 元数据）；Generalist 主要使用人类真实交互数据、强

调数据规模与缩放定律。π0.7 发现”不加元数据时，混合质量数据越多越差”，而 Generalist 宣称”数据越多越好、可预测”——这两个结论并不矛盾，可能反映了两家数据质量控制方式的差异。

与中国”人类数据派”的对比：它石智航（TARS）走的是几乎相同的路线（百万小时人类数据 + 具身原生基座 AWE），并宣称在 2026 年底冲击千万小时；Sunday Robotics 用 200 美元手套采集家庭数据。2026 年，“以人类真实操作数据为主、机器人数据为辅”已成为一个独立的技术流派，Generalist 是其中公开成果最突出的代表。

身位： - 数据规模：全球最大的真实操作预训练数据之一（50 万小时+），领先； - 模型能力：在可靠性（99%+）、速度（3 倍）、一次学会（GEN-1.5）上的公开宣称处于全球最前列，但均为公司自有评测； - 透明度：低于 PI，高于 Skild； - 商业化：早期，以合作伙伴模式推进。

---

7. 未来展望与风险

展望： 1. 数据飞轮的复利：每周 1 万小时以上的数据增长，意味着 Generalist 的预训练数据每年可增加 50 万小时以上，若缩放定律持续成立，其模型能力将持续拉开差距； 2. 从”一次学会”到”零次学会”：GEN-1.5 一次示范 59%，随着数据与模型继续扩大，“看一次就能稳定做”甚至”听一句就能做”可能在 2027 年出现； 3. 大脑授权模式：多末端执行器支持 + 艾利特等硬件伙伴，表明其商业模式是”向硬件厂商授权大脑”。

风险： 1. 数据形态鸿沟：人类数据与机器人身体之间的差异，在力控、精度、速度上可能形成系统性偏差； 2. 评测可信度：所有关键数字均为公司自评，亟需第三方基准（如 RoboArena、RoboChallenge）的独立验证； 3. 资本消耗：大规模真实数据采集是极其烧钱的业务，数据规模的线性增长需要持续的巨额投入。

---

8. 延伸阅读与核验来源

三篇代表作 - GEN-0：Generalist 官方博客（2025-11-04） - GEN-1：SiliconANGLE 报道；The Robot Report；Robotics & Automation News；多末端执行器支持（The Robot Report）；官方博客：Towards Machines with a Thousand Hands - GEN-1.5：MarkTechPost：GEN-1.5 从一次 3–12 秒示范学习新任务；华尔街见闻：GEN-1.5 带来重要进展

创始人学术背景 - Driess et al., *PaLM-E*（2023）；Brohan et al., *RT-2*（2023） - Liang et al., *Code as Policies*（2022）；Zeng et al., *Transporter Networks*（2020）；*Socratic Models*（2022）

其他 - 艾利特与 Generalist 合作（PR Newswire）

> 核验说明：GEN-0 数据规模、和声推理与缩放定律来自官方博客；“约 10 亿参数僵化、70 亿参数以上可持续吸收”的相变阈值来自二手解读；GEN-1 与 GEN-1.5 的所有数字均为公司自有评测，经多家媒体转述且彼此一致；数据采集方式的描述基于公开报道的推断，官方未完整披露采集设备细节。

第 6 章 特斯拉 Optimus：把”一辆会开车的车”变成”一个会干活的人”

> 一句话定位：特斯拉是全球声量最大、量产野心最大的人形机器人玩家。它几乎不发表论文，但它的”大脑”路线是整个行业最”重”、最激进的：与 FSD 共享同一套端到端神经网络架构与”神经世界模拟器”，以人类第一视角视频为主要技能来源，以自研 AI5 芯片为端侧算力，以百万台级产线为数据飞轮的终极燃料。截至 2026 年 10 月，Optimus 已在弗里蒙特新建产线上开始”早期生产”，对外交付目标为 2027 年底。其大脑的真实水平仍是行业中最难被外部验证的”黑箱”。

0. 速览卡片

维度	内容
项目启动	2021 年 AI Day 宣布（当时由真人扮演）；2022 年 AI Day 首台原型 Bumble C 亮相
版本	Bumble C（2022）→ Optimus Gen 1（2022–2023）→ Gen 2（2023.12）→ V2.5 / 改进版（2024–2025）→ Gen 3 / V3（2026）
AI 负责人	Ashok Elluswamy（特斯拉 AI 副总裁，FSD 与 Optimus AI 统一负责）；原 Optimus 项目负责人 Milan Kovac 于 2025 年中离职；据报道 Optimus AI 负责人 Ashish Kumar 于 2025 年下半年离职加入 Meta
大脑路线	端到端神经网络（与 FSD 共享架构）+ 神经世界模拟器 + 人类视频学习 + 真机数据；Grok 作为语音与推理交互层（据报道）
算力	训练：Cortex / Cortex 2.0 超算集群（德州超级工厂）；端侧：AI4 → AI5（计划 2027 年 4 月前后集成进 Optimus）
硬件亮点	Gen 3 手：手部 22 自由度 + 腕/前臂 3 自由度，执行器移至前臂、腱绳驱动
量产	2026 Q3 财报电话会：弗里蒙特产线（规划年产 100 万台）开始早期生产；爬坡”斜率平缓、颠簸”，达到每周约 2 万台至少需一年；德州规划年产 1000 万台产线；对外交付约 2027 年底，先工业后家庭
开放程度	完全闭源；无论文；技术细节主要来自 AI Day、财报电话会、学术会议主题演讲与官方视频
本章”三篇代表作”	① FSD 端到端网络与”神经世界模拟器”（ICCV 2025 主题演讲等）② 从人类第一视角视频学习技能（2025）③ Optimus Gen 3：灵巧手 + AI5 + 百万台产线（2026）
身位	声量与量产野心全球第一；大脑能力难以外部评估；在”自动驾驶 → 人形”的技术迁移上独一无二

> 说明：特斯拉没有学术论文，本章的”代表作”取其最重要的三次公开技术披露，并以分析为主、事实与推断明确区分。

---

1. 故事的开端：马斯克的”最重要产品”

2021 年 8 月，特斯拉第一届 AI Day 的结尾，一个穿着白色紧身衣的舞者走上台跳了一段机械舞——这就是”Tesla Bot”的首次亮相。台下一片哄笑，但马斯克说了一句后来被反复引用的话：“特斯拉可以说是世界上最大的机器人公司，因为我们的车就是轮子上的半感知机器人。”

这句话是理解 Optimus 大脑的钥匙。特斯拉的判断是：

1. 自动驾驶和人形机器人本质上是同一个问题——用摄像头感知世界、用神经网络理解世界、在物理世界中做出动作；
2. 特斯拉已经在自动驾驶上建立了全世界最大的”视觉-动作”数据飞轮（数百万辆车每天产生的视频），以及配套的训练基础设施（Dojo/Cortex 超算）、数据引擎（自动标注、困难样本挖掘）、端侧芯片（FSD 芯片/AI4/AI5）；
3. 这套能力可以”平移”到人形机器人上。

2022 年 AI Day 上，团队展示的 Optimus 原型直接复用了 FSD 的”占用网络（occupancy network）“做环境感知，复用了 FSD 芯片做端侧推理。马斯克多次表示 Optimus 最终的价值将超过汽车业务——这一判断在 2025 年特斯拉股东大会通过的新薪酬方案中被具象化：其中一项里程碑就是累计交付 100 万台 Optimus。

---

2. 代表作一：端到端网络与”神经世界模拟器”——一个大脑，两种身体

> 公开来源：FSD v12（2023–2024）端到端架构；Ashok Elluswamy 在 ICCV 2025（夏威夷，WDFM-AD 研讨会）的主题演讲；ScaledML 2026、CVPR 2026 等后续演讲与相关报道。

2.1 FSD v12：从 30 万行代码到一个神经网络

2023 年底至 2024 年初，特斯拉在 FSD v12 中完成了一次”革命”：把原先由感知网络 + 大量手写规划控制代码（据马斯克称约 30 万行 C++）组成的系统，替换成一个端到端神经网络——输入是摄像头视频，输出直接是转向、油门、刹车指令。这个网络从数百万段人类驾驶视频中模仿学习。

这一转变的意义在于：它证明了”纯视觉、端到端、模仿学习、海量数据”这条路线在一个复杂的真实世界控制问题上是可行的。而这正是 Optimus 大脑的蓝本。

2.2 ICCV 2025 主题演讲：统一架构 + 神经世界模拟器

2025 年 10 月，Ashok Elluswamy 在 ICCV 2025 的自动驾驶基础模型研讨会上，首次较系统地介绍了特斯拉的 AI 架构（报道中演讲标题有”Building an Autonomous Future”与”Building Foundational Models for Robotics at Tesla”两种说法）。要点如下：

（1）单一端到端网络：输入包括各摄像头图像、运动学信号（如车速）、音频与地图信息，直接输出控制指令。网络从视频、地图与运动学数据中学习。

（2）神经世界模拟器（Neural World Simulator）：这是演讲中最引人注目的部分—— - 一个用同一批车队数据训练的视频生成模型，能够根据 AI 的动作合成新的高保真视频，即”如果我这样开，世界会变成什么样”； - 能同时合成 8 路特斯拉摄像头的画面，完全是合成的； - 用途包括：评估新版本模型（在模拟器中闭环测试）、训练、强化学习，以及对抗性事件注入（人为在模拟中制造危险情况，测试模型的应对）。

（3）Optimus 共享这个大脑：演讲中展示了 Optimus 在神经世界模拟器中行走于特斯拉超级工厂内部的视频。在 2026 年的 ScaledML 会议上，Elluswamy 进一步表示：“同一个视频生成网络可以泛化到室内场景，让 Optimus 在其中行走。”2026 年 CVPR 的相关报道也称，一个统一的神经网络架构同时驱动 FSD 与 Optimus，世界模拟器以约 36Hz 生成训练数据。

2.3 分析：特斯拉的”世界模型”与 DeepMind/NVIDIA/1X 有何不同？

维度	特斯拉神经世界模拟器	NVIDIA Cosmos / DreamZero	1X 世界模型
训练数据	自有车队数百万辆车的多摄像头视频	互联网视频 + 机器人数据	NEO 机器人数据 + 视频
动作条件化	以车辆/机器人动作为条件	部分以动作为条件	以机器人动作为条件
用途	评估、训练、RL、对抗测试	合成数据、策略评估、直接作为策略（DreamZero）	策略评估 → 直接作为大脑（预测未来 + 逆动力学）
开放程度	闭源	开源	部分开放（挑战赛数据）

特斯拉的独特优势在于数据规模与闭环：它的世界模拟器建立在全世界最大的真实世界多摄像头视频库之上，并且直接服务于一个已经在数百万辆车上运行的产品。对于 Optimus 而言，这意味着可以在世界模拟器中大规模”想象”工厂、仓库场景并做闭环强化学习，而无需等待真实机器人数量的增长。

2.4 局限与疑问

- 从驾驶到操作的鸿沟：驾驶的动作空间是低维的（转向、加减速），而人形机器人有数十个自由度、需要接触与力控。FSD 的成功能迁移多少到灵巧操作，外界无从验证；
- 室内操作数据从哪来：车队数据对”开车”是海量的，对”叠衣服、拧螺丝”则几乎为零——这正是代表作二要回答的问题。

---

3. 代表作二：从人类第一视角视频中学习（2025）

> 公开来源：特斯拉 Optimus 官方视频与社交媒体发布（2025 年中）；Optimus AI 团队成员公开表述；相关报道。

3.1 路线转向：从动捕服、遥操作到”看人做”

Optimus 的技能学习方式经历了三个阶段：

阶段	方式	问题
2023–2024	动作捕捉服 + VR 遥操作：操作员穿戴动捕设备、佩戴头显，直接”附身”控制 Optimus 示范任务	采集慢、成本高、需要专门场地；2024 年 10 月”We, Robot”发布会上 Optimus 的互动被曝大量依赖远程遥操作，引发争议
2025	人类第一视角视频：让人佩戴摄像头完成任务，模型从视频中学习	需要解决”人手 → 机器人手”的形态映射
2026–	人类视频 + 世界模拟器 + 真机后训练	规模化与可靠性

2025 年中，特斯拉发布了一段 Optimus 完成多种家务（倒垃圾、用吸尘器、搅拌锅、拿取物品等）的视频，并表示这些技能由单一神经网络执行，且直接从人类第一视角视频中学习。据二手报道，时任 Optimus AI 负责人 Ashish Kumar 将核心思路概括为”直接从人类完成任务的第一视角视频中学习”，并称这让新技能的引导可以通过”拍视频”而非”遥操作”完成。

3.2 为什么这对特斯拉格外重要

- 规模：遥操作的数据产出受限于机器人数量与操作员人数；人类视频的产出只受限于”有多少人戴着摄像头干活”——特斯拉自己就有数万名工厂工人；
- 与 FSD 的同构性：FSD 就是从”人类驾驶视频”中模仿学习的。从”人类操作视频”中学习，是同一方法论的自然延伸；
- 与世界模拟器的互补：人类视频提供”技能的种子”，世界模拟器提供”技能的规模化练习场”。

3.3 技术挑战（行业共性问题，特斯拉未公开其解法）

1. 形态鸿沟（embodiment gap）：人手 27 个自由度、触觉灵敏，Gen 2 的手只有 11 个自由度——这也是 Gen 3 把手升级到 22 自由度的重要动机之一：手越像人，人类视频越好用；
2. 动作标签缺失：视频中没有关节角，需要通过手部姿态估计、重定向（retargeting）或逆动力学模型推断；
3. 视角差异：人头部的第一视角与机器人头部摄像头的视角、高度不同。

这些问题在学术界有大量研究（UCSD 的 Humanoid Policy ~ Human Policy、PKU/智在无界的 Being-H0、NVIDIA 的 EgoScale、Figure 的 Project Go-Big 等），说明”从人类视频学习”是 2025–2026 年人形机器人大脑的共识方向，特斯拉是其中规模最大的潜在玩家。

3.4 组织动荡

需要客观指出的是，Optimus 团队在 2025 年经历了显著的人员变动：项目负责人 Milan Kovac 于 2025 年 6 月前后离职，此后 Optimus AI 由 FSD 负责人 Ashok Elluswamy 统一领导；据报道 Ashish Kumar 也在 2025 年下半年离开特斯拉加入 Meta。人员变动与”FSD + Optimus 统一 AI 团队”的组织调整同时发生，客观上强化了”同一个大脑”的路线。

---

4. 代表作三：Optimus Gen 3——灵巧手、AI5 与百万台产线（2026）

> 公开来源：特斯拉 2026 年各季度财报电话会（尤其是 2026 年 10 月 Q3 电话会）、专利文件、官方演示视频与多方报道。

4.1 手：从 11 自由度到 22 自由度

马斯克多次表示，手是人形机器人最难的硬件（Q3 2026 电话会再次强调）。Gen 3 手的公开信息（来自专利与多方报道，部分细节存在出入）：

- 手部 22 个自由度 + 腕部/前臂 3 个自由度，每条手臂合计约 25 个自由度；
- 执行器移到前臂，通过腱绳（tendon）驱动手指——这模仿了人类前臂肌肉通过肌腱驱动手指的结构，使手掌更轻薄、更接近人手尺寸；
- 相关专利申请最早可追溯至 2024 年 10 月。

大脑视角的意义：22 自由度的手让”人类视频 → 机器人”的映射更加直接（关节可以近乎一一对应），但也让控制问题的维度急剧上升——这要求大脑在高维动作空间中输出精确、协调的指令。

4.2 AI5 芯片

AI5 是特斯拉自研的下一代推理芯片，用于车辆与 Optimus。据 2026 年 Q3 电话会的相关报道，AI5 计划于 2027 年 4 月前后开始集成进 Optimus。更强的端侧算力，意味着 Optimus 可以在本地运行更大的端到端网络——这对于需要低延迟、不依赖网络的工厂与家庭场景至关重要。

4.3 Grok：语言交互层

据多方报道，特斯拉 Optimus 以 xAI 的 Grok 作为语音交互与推理层。这形成了一个有趣的分层：Grok（语言、对话、高层推理）+ 端到端网络（感知与动作）。这与 DeepMind 的”ER + VLA”、Figure 的”S2 + S1”在结构上相似，只是语言层来自姐妹公司 xAI。

4.4 产线：数据飞轮的终极燃料

2026 年 10 月 Q3 财报电话会的要点（据电话会文字记录与报道）：

- 弗里蒙特工厂拆除 Model S/X 产线（据报道用时 46 天），在腾出的空间建设 Optimus 产线，规划产能 100 万台/年，大部分设备已到位，已开始”早期生产”；
- 马斯克预计产能爬坡”斜率平缓且颠簸”，因为设计仍在变化，达到每周约 2 万台至少需要一年；
- 德州超级工厂规划一条年产 1000 万台的更大产线；
- 对外交付约在 2027 年底，先工业客户、后家庭；剩余的 AI、机电设计、可靠性与使用寿命问题预计在”明年年底”前后解决；
- 马斯克表示将发布 Optimus 完成”非预编程任务”的视频。

大脑视角的意义：特斯拉 FSD 的核心竞争力来自”数百万辆车 = 数百万个数据采集器”。如果 Optimus 达到百万台级部署，每一台机器人都将成为数据采集器与世界模拟器的”真实锚点”——这是任何一家大脑公司都无法复制的数据飞轮。特斯拉的大脑战略，本质上是一个”先量产、后智能”的赌注：赌产量带来的数据规模最终会碾压一切算法优势。

4.5 现实与差距

- 时间表一再推迟：马斯克曾预测 2025 年生产数千台 Optimus 并在工厂中”有用地工作”，实际在 2026 年 10 月才开始早期生产；
- 自主能力未被独立验证：截至 2026 年 10 月，Optimus 公开展示的自主任务（分拣电池、家务）缺乏可量化的成功率数据，外界无法将其与 Figure Helix 2.5（30 户家庭 56%）、Gemini Robotics 2（公开各任务成功率）进行对比；
- 竞争对手已有工业部署：Figure 公布了在宝马斯帕坦堡工厂 11 个月的部署数据；Agility Digit 已在 GXO 等物流客户处商用。

---

5. 技术路线总结：特斯拉的”四个统一”

1. 架构统一：车与机器人共享端到端网络架构；
2. 模拟器统一：同一个神经世界模拟器服务于驾驶与人形；
3. 数据方法统一：都从”人类示范视频”中模仿学习；
4. 硬件统一：同一代 AI 芯片、同一套训练集群、同一支 AI 团队。

这是一种“规模经济压倒一切”的工程哲学：特斯拉不追求在某个学术基准上领先，而是追求一套能在两种产品上摊薄成本、共享数据、同步迭代的体系。

---

6. 横向对比与身位

维度	特斯拉 Optimus	Figure	1X	Boston Dynamics
大脑来源	自研，与 FSD 共享	自研 Helix	自研世界模型 + Redwood	TRI LBM + DeepMind Gemini
技术透明度	极低（无论文）	中（技术博客详细）	中（博客 + 开放挑战）	中高（博客 + TRI 论文）
数据主来源	人类视频 + 世界模拟器 + 真机	人类视频（Index/Go-Big）+ 遥操作	NEO 家庭数据 + 视频	遥操作 + 仿真 RL
量产	百万台产线规划，早期生产	BotQ 工厂，Figure 03 量产	NEO 消费级预售/交付	量产版 Atlas 2026 起交付现代
公开成功率数据	无	有（Helix 2.5：56%）	有限	有限

身位判断： - 声量与资源：全球第一。特斯拉拥有资金、数据基础设施、芯片、工厂与品牌的全部要素； - 大脑能力：无法外部评估。基于 FSD 的历史，特斯拉有能力把端到端 + 世界模拟器做到极致，但人形操作的难度与驾驶不在一个量级； - “后发但重装”：在学术创新上明显落后于 PI/DeepMind/NVIDIA，在量产与数据规模的潜力上无人能及。

---

7. 未来展望与风险

展望： 1. 2027 是检验年：AI5 集成（约 2027 年 4 月）、对外交付（约 2027 年底）、产能爬坡——三件事将共同决定 Optimus 是”真正的产品”还是”永远的演示”； 2. 世界模拟器 + 车队级 RL：若 Optimus 达到数万台

部署，特斯拉可能是第一个实现”机器人车队数据闭环 + 世界模拟器大规模强化学习”的公司； 3. 与 xAI 的协同：Grok 作为语言与推理层，可能随 xAI 模型能力提升而增强 Optimus 的任务理解与交互能力。

风险： 1. 时间表风险：马斯克的时间表历来过于乐观； 2. 人才流失：2025 年的核心人员离职可能影响研发连续性； 3. “量产先于智能”的风险：如果大脑能力在 2027 年仍不足以完成有经济价值的通用任务，百万台产线将面临”有产能、无需求”的局面； 4. 竞争：中国厂商（宇树、优必选、智元等）在成本与出货量上的快速推进，可能先于特斯拉占领工业人形市场。

---

8. 核验来源

- Humanoids Daily：特斯拉 AI 负责人详解 FSD 与 Optimus 统一世界模拟器
- Humanoids Daily：Ashok Elluswamy 阐述特斯拉统一 AI 的未来
- 老虎证券：特斯拉发布”世界模拟器”，Optimus 共享同一大脑
- Not a Tesla App：Q3 2026 财报电话会回顾；Optimus 正式开始生产
- The Motley Fool：Tesla Q3 2026 电话会文字记录
- ABC7：特斯拉在弗里蒙特开始生产 Optimus（2026-10-23，马斯克称为首批”生产级”机器人，部分部件仍需调整测试）
- Not a Tesla App：Optimus 获得类人手；Teslamagz：22 自由度手专利
- Wikipedia：Optimus (robot)

> 核验说明：特斯拉无学术论文，本章技术描述来自公开演讲与财报电话会的报道转述；Gen 3 手部执行器数量各来源不一（17/23/25 个），本文只采用”22+3 自由度、执行器在前臂、腱绳驱动”这一多源一致的说法；Ashish Kumar 离职加入 Meta 为媒体报道；“世界模拟器 36Hz”仅见于单一报道；Grok 集成为多方报道，官方细节有限。

第 7 章 Figure AI：Helix 的三级跳——从”双系统上半身”到”零样本走进 30 户陌生家庭”

> 一句话定位：Figure 是美国人形整机公司中大脑技术披露最详细、迭代最快的一家。2025 年 2 月与 OpenAI 分手后，它在 18 个月里连续推出 Helix（双系统 VLA，首个控制人形全上半身的 VLA）、Helix 02（S0/S1/S2 三层全身自主）和 Helix 2.5（基于人类经验数据集 Index 预训练，在 30 户陌生家庭零样本执行任务）。它的路线是”整机 + 自研大脑 + 人类视频规模化”，是特斯拉之外最有可能实现”整机端到端数据飞轮”的美国公司。

0. 速览卡片

维度	内容
成立	2022 年，加州（Sunnyvale / San Jose）
创始人	Brett Adcock（CEO，连续创业者，曾创办 Vettery、Archer Aviation）
AI 负责人	Corey Lynch（AI 负责人，前 Google Brain 机器人研究员，Language Table、Interactive Language 等工作作者）
融资	2024 年 B 轮 6.75 亿美元（估值约 26 亿美元，投资方含微软、NVIDIA、OpenAI、贝索斯等）；2025 年 9 月 C 轮超过 10 亿美元，投后估值 390 亿美元
硬件	Figure 01 → Figure 02（2024.08）→ Figure 03（2025.10，面向量产与家庭）；BotQ 自建工厂
大脑谱系	与 OpenAI 合作（2024）→ Helix（2025.02） → Helix 物流/规模化（2025）→ Project Go-Big（2025.09）→ Helix 02（2026.01） → 家庭整理演示（2026.03/05）→ Index 数据集（2026.08）→ Helix 2.5（2026.09）
部署	宝马斯帕坦堡工厂：Figure 02 部署 11 个月、每日 10 小时班次、搬运 9 万+ 零件、参与 3 万+ 辆 X3 生产（公司数据）；2026 年 6 月 Figure 03 进驻宝马；据报道截至 2026 年 6 月底约有 740 台 Figure 机器人在运行；2026 年 9 月 30 日宣布退役 F.02 机队
开放程度	闭源；技术博客较详细（架构、频率、参数量级、数据量）
本章三篇代表作	① Helix（2025.02）② Helix 02（2026.01）③ Helix 2.5 + Index（2026.08–09）
身位	美国人形整机”大脑”第一梯队；全身自主与家庭泛化的公开结果全球领先

1. 故事的开端：和 OpenAI 分手

2024 年 3 月，Figure 发布了一段轰动全网的视频：Figure 01 一边和人对话，一边把苹果递给对方、把垃圾收进篮子，并解释”我给你苹果是因为它是桌上唯一能吃的东西”。视频背后是 OpenAI 的多模态大模型（负责对话与推理）+ Figure 自研的神经网络策略（负责动作）。

但不到一年，2025 年 2 月，Brett Adcock 宣布终止与 OpenAI 的合作，理由是：“我们在端到端机器人 AI 上取得了重大突破，完全由内部自研……要在真实世界中规模化地解决具身 AI，必须把机器人 AI 垂直整合。” 他的类比是：“你不能把 AI 外包，就像你不能把手机的操作系统外包。”

两周后，Figure 发布了 Helix。

这次分手是行业的一个标志性事件：它标志着人形整机公司开始认为大脑必须自研，“通用大模型公司提供大脑、整机公司提供身体”的分工模式受到质疑。（讽刺的是，2026 年 OpenAI 自己也宣布要做人形机器人。）

---

2. 代表作一：Helix（2025.02）——首个控制人形全上半身的 VLA

> 官方技术博客：*Helix: A Vision-Language-Action Model for Generalist Humanoid Control*（figure.ai，2025-02-20）

2.1 Helix 宣称的四个”第一”

1. 第一个对人形机器人整个上半身进行高频连续控制的 VLA——包括手腕、躯干、头部和每根手指，共约 35 个自由度；
2. 第一个同时控制两台机器人协作的 VLA——两台 Figure 02 用同一套权重，协作完成把陌生杂货放进冰箱的任务；
3. 能抓起”几乎任何小型家居物品”——包括数千种训练中从未见过的物品，只需自然语言指令（“捡起沙漠里的东西”→ 抓起仙人掌玩具）；
4. 一套神经网络权重完成所有行为——不需要针对特定任务微调；
5. 完全在机器人本体的嵌入式低功耗 GPU 上运行，具备商业部署条件。

2.2 架构：“System 2 思考，System 1 行动”

Helix 借用了卡尼曼”快思考与慢思考”的框架：



```
| System 1（S1）：约 8000 万参数的视觉运动策略      |
| · 交叉注意力的编码器-解码器 Transformer          |
| · 运行频率 200 Hz                              |
| · 输入：多尺度视觉特征 + 本体状态 + S2 潜在向量   |
| · 输出：35 维上半身连续动作（含手指、腕、躯干、头）  |
└──────────────────────────────────────────────────┘
```

关键设计：

- 两个系统独立运行、异步解耦：S2 以 7–9Hz 慢慢"想"，S1 以 200Hz 快速"做"。S1 总是使用 S2 最新输出的潜在向量，同时以 200Hz 的频率根据最新视觉与状态做出反应。这让机器人既有语义理解，又能实时应对物体滑动、位置变化；
- 层间接口是潜在向量而非自然语言：与 DeepMind（ER 用自然语言给 VLA 下指令）不同，Helix 的 S2→S1 接口是一个可端到端训练的连续向量，信息量更丰富，但可解释性更弱；
- S1 的视觉主干：一个完全卷积、多尺度的视觉骨干网络，在仿真中预训练初始化；
- 部署硬件：S2 与 S1 分别运行在 Figure 02 上的两块嵌入式 GPU 上。

2.3 数据与训练

- 数据量：约 500 小时的高质量、多机器人、多操作员遥操作数据——在当时的 VLA 中属于很小的数据量（π0 为约 1 万小时）；
- 自动标注：用一个 VLM 观察每段示范视频片段，"事后"生成"如果要让机器人做出这段视频中的动作，应该给它什么指令？"——即事后指令重标注（hindsight relabeling），从而得到大量语言-动作配对，无需人工逐条写指令；
- 端到端训练：S2 与 S1 联合训练，S1 的损失（动作回归）的梯度通过潜在向量回传到 S2，让 S2 学会"产出对动作最有用的语义表征"；
- 训练技巧：在训练中引入 S1 与 S2 输入之间的时间偏移，模拟部署时两系统的异步延迟，提高部署鲁棒性。

2.4 Helix 的延续（2025 全年）

- 物流场景（2025.02–06）：Helix 被用于包裹分拣（把传送带上的包裹翻转、使条码朝下放置）。Figure 陆续发布的物流更新显示，通过引入立体视觉、多尺度特征、学习式视觉本体感知以及推理加速等改进，单件处理时间与条码识别率持续提升，并扩展到可形变的软包裹；
- 家庭场景：洗碗机装载、叠衣服、整理杂物等演示；
- Project Go-Big（2025.09）：Figure 宣布与 Brookfield（拥有约 10 万套住宅单元的地产巨头）合作，大规模采集人类在真实家庭中的第一视角视频，作为 Helix 的"互联网规模人形预训练"数据；并展示了仅从人类视频中学习的导航能力零样本迁移到机器人（"人类到机器人的零样本迁移"）。

2.5 意义与局限

意义：Helix 证明了"小数据（500 小时）+ 大 VLM + 高频小策略"可以在人形上实现高自由度灵巧操作与语义泛化，并且可以完全在端侧运行。它和 GR00T N1（2025.03）一起，把"双系统"变成了 2025 年人形大脑的主流架构。

局限：只控制上半身，下半身行走仍由独立的传统/RL 控制器负责；“走过去 → 操作 → 再走”的切换是割裂的。

---

3. 代表作二：Helix 02（2026.01）——S0 / S1 / S2 三层全身自主

> 官方技术博客：*Introducing Helix 02: Full-Body Autonomy*（figure.ai，2026-01-27）

3.1 问题：为什么”走”和”做”必须统一？

真实家务（例如洗碗）不是”先走到水槽、停下、再操作”，而是边走边操作、边弯腰边平衡：打开洗碗机门时要后退半步、弯腰放碗时要调整重心、单手扶着门另一只手放餐具……如果下半身控制器和上半身 VLA 是两个系统，它们之间的协调会成为瓶颈：上半身”不知道”下半身在干什么，下半身”不知道”上半身要去哪。

3.2 三层架构

层级	频率	规模	职责	输入 → 输出
System 2	低频	大型 VLM	语义推理、任务理解、长程任务上下文	图像 + 语言 → 潜在语义目标
System 1	200 Hz	视觉运动策略	把目标转化为全身动作：手臂、手指、躯干、腿	头部相机、手掌相机、指尖触觉、本体感知 + S2 目标 → 全身运动目标
System 0	1 kHz	约 1000 万参数	学习式全身控制器：平衡、接触力、全身协调	全身关节状态 + 基座运动 → 关节级执行器指令

System 0 的训练（官方披露）： - 在超过 1000 小时的人类动作数据（重定向到关节级）上训练，结合仿真到真实的强化学习； - 核心思想是直接学习”追踪人类动作”，而不是为行走、转身、下蹲、伸手分别设计奖励函数——这与 NVIDIA SONIC（运动追踪即可扩展的基础任务）的思路高度一致； - 据二手报道，这个学习式控制器替代了约 10.9 万行手写的 C++ 控制代码，训练使用了约 20 万个并行仿真环境（这两个数字未在官方博客摘录中得到确认）。

S1 的升级：从只控制上半身扩展到全身，并新增了手掌相机（解决手部遮挡下的近距离视觉）与指尖触觉传感器（Figure 03 的指尖传感器可感知数克级的力），让精细操作获得”手眼触”闭环。

3.3 标志性演示：4 分钟洗碗机任务

2026 年 1 月 27 日发布的演示中，Figure 03 在一个全尺寸厨房里： - 端到端完成”把餐具装进洗碗机”的任务，历时约 4 分钟； - 执行了 61 个有序的行走与操作动作； - 无重置、无人工干预，在数分钟内保持任务上下文，并能隐式地从小错误中恢复。

Figure 称这是当时人形机器人”最长的完全自主任务”之一。随后公司又发布了机器人在仓库中连续工作 8 小时乃至 24 小时直播的演示（公司宣称，未见独立验证）。

3.4 分析：Helix 02 的三层架构为什么成为行业共识

2026 年，几乎同一时间，多家公司提出了结构相同的”三层大脑”：

公司	高层（语义）	中层（视觉运动）	底层（全身控制）
Figure Helix 02	S2 VLM	S1 200Hz 全身	S0 1kHz，人类动作追踪 + RL
NVIDIA	Cosmos Reason / GR00T	GR00T / DreamZero	SONIC（动作追踪基础模型）
逐际动力 COSA	System 2 Agentic OS（LLM + 世界模型）	System 1 VLA/WAM	System 0 全身运动基础模型
Agility	上层任务系统	—	全身控制基础模型（“运动皮层”）

共识背后的逻辑： 1. 频率分层是物理决定的：语义推理需要数亿到数十亿参数，只能低频运行；全身平衡需要 1kHz 级反应，只能用小网络；中间必须有一层把”想法”变成”全身运动目标”； 2. “运动追踪”成为底层的统一训练范式：用人类动捕数据训练一个能追踪任意人体动作的控制器，它就天然具备了行走、下蹲、弯腰、伸手的全部能力，上层只需给出”动作目标”； 3. 底层可以 sim2real，上层必须真实数据：S0 可在仿真中大规模 RL 训练；S1/S2 需要真实视觉与语义数据。

---

4. 代表作三：Helix 2.5 与 Index（2026.08–09）——零样本走进 30 户陌生家庭

> 官方发布：*Helix 2.5: Zero-Shot 30-Home Generalization*（figure.ai，2026-09-17）；Index 人类经验数据集（2026-08-25 发布）

4.1 Index：一个”人类经验”数据管道

Index 是 Figure 在 2026 年 8 月 25 日推出的大规模人类行为数据集与数据管道，是 Project Go-Big 的延续与升级。据报道，Index 每秒产生约 35 分钟的人类经验数据（即每天约 5 万小时量级）——这一规模如果属实，将超过此前公开的所有机器人/人类操作数据采集速率。

数据的核心是人类在真实家庭中完成日常任务的第一视角记录。Figure 的判断与特斯拉、Generalist、它石一致：人类经验数据是唯一能以”互联网规模”获取的物理交互数据。

4.2 实验设计：严格定义的”零样本”

Helix 2.5 的评测设计值得仔细看：

- 地点：旧金山湾区的 30 户真实家庭，没有在任何一户家庭中采集过任何数据，也没有做任何微调；
- 任务：三种全身家务行为——整理客厅、叠毛巾、铺床；
- “零样本”的准确含义：对”家庭与物体”是零样本；但这三种行为本身仍是用在其他地方采集的示范来指定和训练的；
- 成功标准：必须完成整个任务，没有部分得分；
- 物体去重：评测物体由 AI 模型与人工复核比对训练数据，确保是”新物体”。

4.3 结果

策略	零样本整任务成功率
从零训练（不使用 Index 预训练）	约 9%（Figure 工程师的帖子给出 8%）

策略	零样本整任务成功率
以 Index 预训练的 Helix 2.5	约 56%（420 次中 237 次成功）

4.4 解读

1. 人类经验预训练带来约 6 倍的零样本提升：这是迄今为止”人类视频/经验数据预训练对人形机器人有效”的最直接、最大规模的公开证据之一；
2. 56% 意味着什么：对”整理一个陌生客厅”这种高度开放的任务，56% 的整任务成功率在学术上非常亮眼；但对商用家庭服务而言，距离”可靠”还有很大差距（多家媒体指出了这一点）；
3. 与 π0.5 的对比：π0.5（2025.04）在 3 个陌生家庭中展示了移动操作泛化；Helix 2.5（2026.09）把评测扩大到 30 户、全身人形、420 次试验并公布整任务成功率——评测的规模与严格程度提升了一个数量级；
4. 与 Skild S1、Generalist GEN-1.5 的对比：三者都在 2026 年夏秋展示了”以大规模人类数据预训练换取新场景/新任务泛化”的能力，只是切入点不同：Figure 是”新家庭、已知任务”，Skild/Generalist 是”新任务、给示范”。

---

5. 硬件与大脑的协同设计：Figure 03

2025 年 10 月发布的 Figure 03 是为 Helix 重新设计的机器人，这一点对理解 Figure 的大脑至关重要：

- 视觉系统：相比 Figure 02，相机帧率提升约 2 倍、延迟降至约 1/4、视场角扩大约 60%，并在每只手掌中嵌入摄像头——这些都是为 VLA 的”看清楚、看得快”服务；
- 触觉：指尖触觉传感器可感知数克级的力；
- 家用安全：柔软、可洗的织物外壳，多层泡沫，降低质量与夹手风险；
- 无线充电：通过脚部感应充电，便于机器人自主补能、长时间工作；
- 量产设计：为 BotQ 工厂的大规模制造而设计。

“为大脑设计身体”是 Figure 与纯大脑公司（PI、Skild、Generalist）的根本区别：它可以根据大脑的需要调整传感器配置，并保证训练数据与部署硬件完全一致。

---

6. 技术路线总结

阶段	时间	核心突破	数据
Helix	2025.02	双系统 VLA；上半身 35 自由度；端侧运行；多机协作	约 500 小时遥操作 + 自动标注
Helix 规模化	2025	物流分拣速度与鲁棒性；人类视频导航迁移	遥操作 + Project Go-Big 人类视频
Helix 02	2026.01	S0/S1/S2 三层全身自主；手掌相机 + 触觉	1000+ 小时人类动作（S0）+ 遥操作 + 人类视频
Helix 2.5	2026.09	30 户陌生家庭零样本，56% vs 9%	Index 人类经验数据集预训练

Figure 的路线可以概括为：架构上先解决”控制带宽”（双系统 → 三层），数据上再解决”规模”（遥操作 → 人类经验）。

---

7. 横向对比与身位

维度	Figure	特斯拉	1X	Gemini Robotics 2
全身自主	Helix 02 三层，1kHz S0	自研，细节不详	世界模型驱动 + RL 行走	2026.07 加入全身
家庭泛化公开结果	30 户，56%	无	家庭试用，少量数据	无家庭大规模评测
工业部署公开数据	宝马 11 个月	自家工厂（数据不公开）	少	Apptronik/BD 合作中
数据战略	Index（每秒约 35 分钟人类经验）	人类视频 + 车队 + 世界模拟器	NEO 家庭数据 + 视频	ALOHA 车队 + 网络

身位判断： - Figure 在 2026 年是公开证据最充分的人形整机大脑：三层架构、全身自主、30 户家庭零样本评测、宝马 11 个月部署数据，均有较详细的官方披露； - 其 390 亿美元估值（2025.09）在人形整机公司中领先，资本与人才密度高； - 与特斯拉相比，Figure 的透明度高得多；与纯大脑公司相比，Figure 的软硬一体与真实部署更进一步。

---

8. 未来展望与风险

展望： 1. Index 的规模化效应：若”每秒 35 分钟人类经验”的数据管道持续运转，Helix 的下一代（Helix 3？）可能在家庭零样本成功率上实现大幅跃升； 2. 家庭市场：Figure 03 的家用设计 + Helix 2.5 的家庭泛化，表明 Figure 把家庭作为与工业并列的主战场； 3. 工厂规模化：Figure 03 进驻宝马、F.02 机队退役，意味着 Figure 正在从”试点”走向”批量部署”。

风险： 1. 56% 到 99% 的鸿沟：家庭场景对可靠性和安全性的要求极高，从”学术领先”到”消费级可靠”可能需要多年； 2. 宝马项目的性质：评论者指出宝马合作仍是试点而非大规模采购合同； 3. 估值与营收错配：390 亿美元估值需要大规模商业化兑现； 4. 特斯拉与中国厂商的成本压力：在硬件成本与量产规模上，Figure 面临特斯拉与中国厂商的双重竞争。

---

9. 延伸阅读与核验来源

三篇代表作 - Helix：figure.ai/news/helix（2025-02-20） - Helix 02：Introducing Helix 02: Full-Body Autonomy（2026-01-27） - Helix 2.5：Helix 2.5: Zero-Shot 30-Home Generalization（2026-09-17）；Corey Lynch 发布

核验来源 - Figure 新闻索引 - Humanoids Daily：Helix 2.5 走进 30 户陌生家庭；Unite.AI：Helix 2.5 - Interesting Engineering：Helix 02 全身控制 - Investing.com：Figure 发布 Helix 02 - robotique-store：Helix 版本与宝马部署汇总 - Wikipedia：Figure AI

> 核验说明：Helix 架构参数（S2 约 7B、7–9Hz；S1 约 80M、200Hz；35 自由度；约 500 小时数据）来自 Figure 2025 年 2 月官方博客；Helix 02 的 S0（约 10M 参数、1kHz、1000+ 小时人类动作）来

> 自官方博客；“替代 10.9 万行代码”“20 万仿真环境”为二手报道；Helix 2.5 的 56%（237/420）来自官方发布与多家媒体一致转述；Index”每秒约 35 分钟”与宝马部署数据为公司口径，未见独立核实。

第 8 章 1X Technologies：押注”世界模型即大脑”的家用人形先锋

> 一句话定位：1X 是第一家把人形机器人作为消费级家用产品公开预售的公司（NEO，2025 年 10 月开放预订，2 万美元或每月 499 美元订阅），也是最早、最坚定地押注”世界模型”作为机器人大脑核心的整机公司。它的大脑路线经历了三个阶段：把世界模型用作”学习式模拟器”来评估策略（2024）→ 推出端侧运行的全身 VLA Redwood（2025）→ 以 140 亿参数视频生成模型为主干、通过”想象未来视频 + 逆动力学”直接驱动 NEO 的 1X World Model（1XWM，2026.01）。1X 的路线与 NVIDIA DreamZero、特斯拉神经世界模拟器、蚂蚁 LingBot-World、极佳 GigaWorld 共同构成了 2026 年”世界模型派”的主力。

0. 速览卡片

维度	内容
成立	2014 年（前身 Halodi Robotics），挪威；后将总部重心移至美国加州
创始人	Bernt Børnich（CEO）
AI 团队	Eric Jang 曾任 AI 副总裁（Redwood 时期的对外代表人物）；2026 年”全面押注世界模型”，引入前 Luma AI 研究员 Samarth Sinha，团队有所调整；Daniel Ho 等为世界模型方向负责人之一
投资方	OpenAI Startup Fund（2023 年 A 轮领投）、EQT Ventures、三星 NEXT、Tiger Global 等（多轮）
硬件	EVE（轮式人形，用于安保与物流）→ NEO Beta（2024）→ NEO Gamma（2025）→ NEO（消费版，2025.10 预售）
量产	2026 年 4 月 30 日加州海沃德工厂开始全面生产 NEO，首年目标约 1 万台；消费者交付计划于 2026 年底开始
大脑谱系	世界模型（学习式模拟器，2024）→ 1X 世界模型挑战赛（开放数据）→ Redwood AI（2025） → 1XWM 作为策略（2026.01）→ 世界模型实验室（2026）
本章三篇代表作	① 1X World Model：学习式模拟器与开放挑战（2024）② Redwood AI：端侧全身移动操作 VLA（2025）③ 1XWM：以视频世界模型为主干的机器人策略（2026）
身位	“世界模型派”的整机代表；家用人形商业化最激进；自主能力仍依赖遥操作兜底

1. 故事的开端：从挪威安保机器人到加州家用人形

1X 的前身 Halodi Robotics 成立于 2014 年，最初的产品 EVE 是一个轮式底盘 + 人形上半身的机器人，被部署在挪威的写字楼做安保巡逻。这段经历给了 1X 两个独特的认知：

1. 真实场景数据的价值：EVE 在真实楼宇中长期运行，积累了大量真实世界的遥操作与自主运行数据；

2. 安全优先的硬件哲学：1X 坚持使用低减速比、可反向驱动的”肌腱式”电机设计，让机器人柔软、轻、对人安全——这为后来”走进家庭”奠定了硬件基础。

2023 年，OpenAI 创业基金领投了 1X 的 A 轮，这是 OpenAI 在人形机器人领域最早的投资之一。此后 1X 把战略重心从”安保/物流”转向”家庭”，推出了双足的 NEO。

Bernt Børnich 的信条是：家庭才是通用机器人的真正训练场——工厂的任务重复、环境固定，学不到通用智能；家庭的任务多样、环境千变万化，是”让机器人学会世界”的唯一途径。而要在家庭中采集足够多的数据，必须先把机器人卖进家庭。这一”先进家庭、再学智能”的逻辑，与特斯拉”先量产、再智能”如出一辙。

---

2. 代表作一：1X World Model——学习式模拟器与开放挑战（2024）

> 官方博客：*1X World Model*（2024.09）及后续 *1X World Model Challenge*（开放数据集与基准，2024–2025）

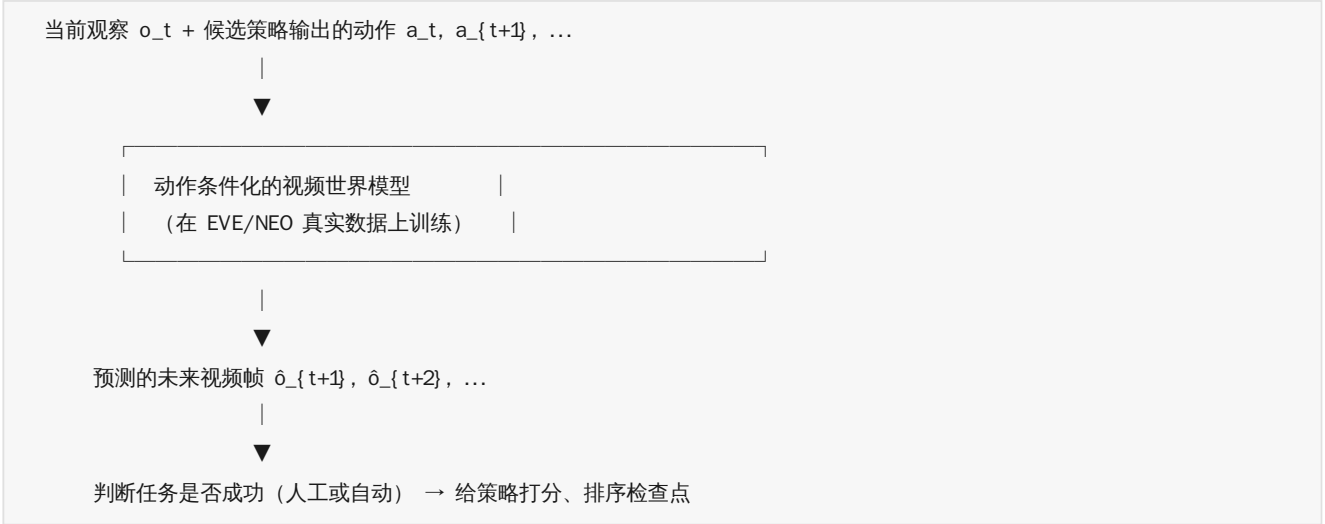
2.1 要解决的问题：机器人策略怎么”评估”？

在 LLM 领域，评估一个模型只需要跑一遍测试集。但在机器人领域，评估一个策略需要在真实世界中一次次运行——每次运行都要布置场景、复位物体、记录结果。当你有几十个候选模型检查点、上百种任务时，真机评估的成本会让研发陷入停滞。

更糟的是，家庭环境千差万别，你永远无法在评估中覆盖用户家里的所有情况。

2.2 方案：用世界模型当”模拟器”

1X 的思路是：用真实机器人数据训练一个动作条件化的视频预测模型——输入当前画面和机器人将要执行的动作序列，输出机器人”如果这样做，接下来会看到什么”。这个世界模型就成了一个”学习式模拟器（learned simulator）“：



1X 报告，世界模型对任务成功的预测与真实世界结果具有相关性，可以在真机测试前对策略检查点进行排序，大幅减少真机评估成本。

2.3 开放挑战：把数据交给社区

1X 随后发起了 1X World Model Challenge，开放了大量 EVE/NEO 的真实运行数据与视频分词器，设置了压缩（视频 token 预测的损失）、采样（生成未来帧的质量）、评估等赛道。这是人形机器人公司中少见的开放举措，让学术界可以直接在真实人形数据上研究世界模型。

2.4 意义

这项工作在 2024 年就提出了"世界模型 = 机器人的模拟器与评估器"这一判断，比 2025 年行业的"世界模型热"早了近一年。它也为 1X 后来"世界模型即策略"的路线积累了数据、工具与团队。

---

3. 代表作二：Redwood AI（2025）——端侧全身移动操作 VLA

> 官方页面：*Redwood AI*（1x.tech，2025 年中发布）；相关报道。

3.1 定位：NEO 的"在机大脑"

Redwood 是 1X 为 NEO 打造的可部署的通用机器人模型，其关键特征（来自官方表述与多方报道）：

- 完全在机器人内置 GPU 上运行，不依赖云端；
- 行走与手臂/手部操作联合控制——与把"移动"和"操作"作为两个独立问题的系统不同，Redwood 同时输出移动与操作动作，是最早面向家庭场景的双足人形端到端移动操作系统之一（时任 AI 副总裁 Eric Jang 语）；
- 训练数据：来自 1X 早期 EVE 与当前 NEO 在真实环境中的运行数据（遥操作示范 + 自主运行）；
- 能力：在家庭环境中执行开门、取物、把衣物放进洗衣机等任务，能泛化到新物体与任务变体；
- 规模：多家二手资料称其为约 1.6 亿参数的视觉-语言 Transformer（约 5Hz 级别运行），但该数字未见 1X 官方确认。

3.2 配套：强化学习全身运动控制器

1X 官网同时介绍了一个新的 RL 运动控制器，为 NEO 提供"完整的移动能力"：任意方向行走、坐下、跪下，以及借助立体视觉爬楼梯。这形成了与 Figure、NVIDIA 类似的"上层策略 + 底层 RL 控制器"分层结构。

3.3 小模型的逻辑

Redwood 在参数量上远小于 π0（33 亿）、GR00T N1（22 亿）、Helix S2（70 亿）。这反映了 1X 的工程取舍：家用机器人对成本、功耗、散热极其敏感，必须在端侧芯片上实时运行；与其用一个大模型低频运行，不如用一个小模型在高质量的同本体数据上训练到"够用"。

3.4 局限：遥操作兜底

2025 年 10 月 NEO 开放预售时，1X 明确告知用户：在自主能力尚不足以完成的任务上，NEO 可以由 1X 的远程专家（遥操作员）接管完成（用户可安排时段）。这一透明但颇具争议的设计引发了大量关于隐私与"真自主"的讨论。它也说明了一个现实：截至 2025 年底，即使是最激进的家用人形公司，其大脑也远不足以独立完成

家务。1X 的策略是用遥操作兜底换取进入家庭的机会，再用家庭中积累的数据训练出更强的大脑——又一个”数据飞轮先行”的赌注。

---

4. 代表作三：1XWM——以视频世界模型为主干的机器人策略（2026.01）

> 官方博客：*1X World Model*（1x.tech/discover，2026.01，“NEO 开始自主学习”）；Humanoids Daily 对 1X 世界模型负责人 Daniel Ho 的访谈《Imagination as Policy》。

4.1 核心转向：“想象”就是”策略”

如果说 2024 年的世界模型是”评估策略的模拟器”，那么 2026 年的 1XWM 则更进一步：世界模型本身就是策略。它的推理流程是：



这与 VLA 的根本区别在于：VLA 是”看图 → 直接输出动作”，1XWM 是”看图 → 想象未来 → 从想象中反推动作”。

4.2 三阶段训练

1. 网络规模视频预训练：主干在互联网视频上预训练，学会通用的视觉与物理动态；
2. 人类第一视角数据中期训练（mid-training）：在大量人类第一视角视频上继续训练，学会”手如何与物体交互”；
3. NEO 专属感知运动日志微调：用约 70 小时的 NEO 机器人数据做本体微调，让模型学会 NEO 的外观与运动学。

这个”网络视频 → 人类第一视角 → 少量机器人数据”的三段式，与 NVIDIA DreamZero（Wan2.1 14B + 智元机器人数据）几乎同构，代表了 2026 年世界模型派的标准配方：世界知识来自视频，交互知识来自人，本体知识只需要极少量机器人数据。

4.3 “NEO 开始自己学习”

1X 宣称 1XWM 能泛化到未见过的物体、环境与任务，并把这一能力称为 NEO “开始自主学习”——因为世界模型可以从 NEO 在家庭中的每一次运行中学习，再把学到的东西用于”想象”新任务的执行方式。1X 随后在 2026 年成立了专门的世界模型实验室。

4.4 1X 自己承认的失败模式

1X 在博客中坦率列出了 1XWM 的问题： - 生成的视频”看起来合理但物理上错误”：在深度、接触、几何约束上出错（例如手穿过物体、物体凭空移动），导致 IDM 提取出无法执行或有害的动作； - 部分灵巧任务仍然困难。

这些问题是视频生成模型作为策略的共性难题：视频模型优化的是”像不像”，而机器人需要的是”对不对”。

4.5 争议：1XWM 到底有没有在 NEO 上实时运行？

需要指出的是，第三方分析对 1XWM 在 NEO 上的实际角色存在争议：有观点认为，Redwood 才是实际部署的通用策略，而 1XWM 是一个”预测、评估与自主学习”的研究方向，尚未被 1X 明确确认为 NEO 的实时动作通路。行业媒体把 1XWM 称为 NEO 的”认知核心”，但这是媒体的说法而非 1X 官方用语。本报告认为，较稳妥的理解是：1XWM 已在 NEO 上作为策略进行演示，但量产交付版 NEO 的实际运行栈可能是 Redwood + 世界模型的组合，具体比例未公开。

---

5. 技术路线总结

阶段	世界模型的角色	策略	数据
2024	学习式模拟器（评估、排序策略）	小型策略	EVE/NEO 真实数据，开放挑战赛
2025	研发工具	Redwood（端侧全身移动操作 VLA）+ RL 运动控制	EVE + NEO 示范与运行数据
2026	策略本身（想象 → IDM）	1XWM（14B 视频主干）+ Redwood	网络视频 → 人类第一视角 → 约 70 小时 NEO 数据

1X 的独特之处在于它把世界模型同时用在了三个位置：评估器、数据生成器、策略。这种”世界模型中心主义”是一个高风险、高回报的选择。

---

6. 横向对比与身位

维度	1X（1XWM）	NVIDIA（DreamZero）	特斯拉（神经世界模拟器）
世界模型主干	14B 视频扩散	14B 视频扩散（Wan2.1）	自研视频生成（车队数据）
动作获取	生成视频 → IDM 反推	视频与动作联合去噪	主要用于评估/训练/RL
机器人数据	约 70 小时 NEO	智元大规模数据	车队 + Optimus
部署	NEO 家用（演示）	GR00T N2（规划 2026 年底）	Optimus（工厂）

身位判断： - 1X 是家用人形商业化的先行者，NEO 是全球最早公开预售、开始量产的家用人形之一； - 在世界模型路线上，1X 是整机公司中最坚定、最早的布道者，但与 NVIDIA 相比在资源与开放程度上处于劣势； - 其自主能力在 2025–2026 年仍需遥操作兜底，“真自主”程度是外界最大的疑问。

---

7. 未来展望与风险

展望： 1. 家庭数据飞轮：若 NEO 在 2026 年底至 2027 年实现数千台家庭部署，1X 将拥有全球最大的”人形机器人在真实家庭中”的数据集——这是世界模型最需要的燃料； 2. IDM 与”视频 → 动作”接口的改进：解决”生成视频物理不一致”问题，可能需要像 DreamZero 那样把动作与视频联合生成； 3. 从遥操作兜底到自主：遥操作数据本身是训练数据，随着时间推移，兜底比例的下降速度将是 1X 大脑进步的最直接指标。

风险： 1. 隐私与信任：家庭中的摄像头与远程遥操作，是消费者接受度的最大障碍； 2. 算力与成本：14B 视频模型的推理成本与家用机器人的成本、功耗约束存在根本矛盾； 3. 竞争：Figure（Helix 2.5 家庭零样本）、Sunday（Memo）、以及中国低成本家用机器人在 2026 年快速逼近。

---

8. 延伸阅读与核验来源

- 1X 官网 AI 页面
- 1X World Model：自主学习（官方）；1X World Model（官方）
- Humanoids Daily：Imagination as Policy——1X 总监 Daniel Ho 谈世界模型飞轮
- Humanoids Daily：1X 全面押注世界模型，引入 Luma AI 的 Samarth Sinha
- Humanoid.guide：NEO 开始自主学习
- The Robot Report：Redwood AI
- eWeek：1X 开设美国工厂，首年目标 1 万台
- Wikipedia：1X Technologies

> 核验说明：1XWM 的 14B 主干、三阶段训练、约 70 小时 NEO 数据、IDM 提取动作、失败模式来自 1X 官方博客及多方一致转述；Redwood”约 1.6 亿参数”仅见于二手聚合网站，本章已标注；1XWM 是否为 NEO 量产版实时运行栈存在争议，本章给出了稳妥表述；NEO 消费者交付截至 2026 年 10 月尚未见确认报道。

第 9 章 Boston Dynamics：运动控制之王的”大脑移植手术”

> 一句话定位：Boston Dynamics（波士顿动力）是人形机器人”身体”的传奇——液压 Atlas 的后空翻与跑酷定义了公众对人形机器人的想象。但在”大脑”时代，它做了一个关键决定：**放弃手写的模型预测控制（MPC）作为唯一路线，转向学习——与丰田研究院（TRI）合作训练”大行为模型（LBM）“，与 RAI 研究所合作做强化学习运动生成，并在 2026 年 CES 上宣布与 Google DeepMind 合作，把 Gemini Robotics 装进量产版电动 Atlas。** 它是”顶级身体 + 外部顶级大脑”组合的代表，背后是现代汽车集团”到 2028 年部署数万台 Atlas”的工业野心。

0. 速览卡片

维度	内容
成立	1992 年，从 MIT Leg Lab 分拆（创始人 Marc Raibert）
股东变迁	Google（2013）→ 软银（2017）→ 现代汽车集团（2020/2021，控股）
产品	Spot（四足，商用）、Stretch（仓储搬运）、Atlas（液压版 2013–2024 退役 → 电动版 2024.04 发布，2026 年 CES 发布量产版）
大脑合作方	丰田研究院 TRI（2024.10 起，LBM）；RAI 研究所（Marc Raibert 创办的 AI 研究所，RL）；NVIDIA（Jetson Thor、Isaac Lab）；Google DeepMind（2026.01 起，Gemini Robotics）
量产计划	2026 年产量全部分配给现代汽车与 Google DeepMind；现代汽车计划到 2028 年建立年产约 3 万台机器人的体系、部署数万台 Atlas；Atlas 计划 2028 年起进入现代佐治亚 Metaplant 产线；2026 年 9 月在佐治亚开设机器人 Metaplant 应用中心（2027 年将建约 10 倍规模的设施）
本章三篇代表作	① Atlas 大行为模型（与 TRI，2025.08）② 基于动捕的强化学习全身运动（与 RAI 研究所，2025）③ 量产 Atlas + Gemini Robotics + 现代工厂训练体系（2026）
身位	硬件与运动控制全球顶尖；大脑主要依靠合作；工业落地路径最清晰（母公司即客户）

1. 故事的开端：从”预编程的奇迹”到”学习的必要”

在 2013–2023 年的十年里，Boston Dynamics 的液压 Atlas 做出了无数令人惊叹的动作：后空翻、跑酷、体操。但内行都知道，这些动作背后是精心设计的模型预测控制（MPC）+ 离线优化的轨迹库：工程师为每一个动作设计目标、约束与代价函数，机器人在线求解最优控制。这种方法的优点是精确、可解释、动态性能极强；缺点是每一个新动作、每一种新任务都需要工程师手工设计，无法扩展到成千上万种日常操作。

2022 年后，随着 RT-2、Diffusion Policy、ALOHA 等学习方法的突破，Boston Dynamics 内部也意识到：要让 Atlas 从"表演者"变成"工人"，大脑必须从"编程"转向"学习"。 2024 年 4 月，液压 Atlas 退役，全电动 Atlas 发布——它的关节可以 360° 旋转，"身体的可能性"远超人类，这本身也需要学习方法来探索。

Boston Dynamics 选择的路径是合作而非从零自研：它找到了两家在机器人学习领域最强的研究机构——丰田研究院（Diffusion Policy 与 LBM 的发源地）和 RAI 研究所（由 Boston Dynamics 创始人 Marc Raibert 创办）。

---

2. 代表作一：Atlas 大行为模型（与 TRI，2025.08）

> 官方博客：*Large Behavior Models and Atlas Find New Footing*（bostondynamics.com，2025-08-20）；TRI 同步发布。

2.1 核心主张：手和脚"几乎一视同仁"

这项工作最重要的一句话是：

> 单一大行为模型直接控制整个机器人，对待手和脚几乎完全相同。

过去的人形机器人（包括 Figure Helix 1 代、早期 GR00T）都把"行走与平衡"与"手臂操作"分开：下半身由专门的控制器负责，上半身由学习策略负责。Atlas LBM 则让一个策略同时输出全身所有关节的动作——迈步是动作，伸手也是动作；为了够到远处的物体，策略自己决定"迈一步"还是"弯腰"。这比 Figure Helix 02（2026.01）的全身自主早了约 5 个月。

2.2 架构

组件	内容
主干	4.5 亿参数的扩散 Transformer（DiT），基于 TRI 的 LBM（大规模化的 Diffusion Policy 类架构）
训练目标	流匹配（flow matching）
输入	头部相机图像、本体感知（关节状态）、语言提示
输出	控制整个 Atlas 的动作，频率 30 Hz
形式	单一、语言条件化的多任务策略

2.3 数据管线：四步循环

Boston Dynamics 与 TRI 描述的开发流程是一个典型的"数据-训练-评估"闭环：

1. 采集：通过 VR 遥操作系统，在真实 Atlas（以及只有上半身的 Atlas 操作测试台 MTS）和仿真中采集具身行为示范数据；
2. 处理：对数据进行标注、整理、筛选；
3. 训练：在全部任务数据上训练一个统一的神经网络策略；
4. 评估：在一套测试任务上评估，根据失败模式决定下一轮采集什么数据。

遥操作系统的重要性：要让一个策略学会全身动作，示范者必须能用全身”附身”机器人——Boston Dynamics 为此开发了基于 VR 与身体追踪的全身遥操作系统，操作员的手、躯干、腿部动作都能映射到 Atlas 上。

2.4 演示内容

- 工厂零件拣放：一段连续 2 分钟不中断的工厂拣放任务——机器人从容器中取出零件、走到另一处、放入指定位置，期间处理物体掉落等意外；
- 新颖任务：系绳结、折叠椅子、翻转轮胎、展开桌布等——这些任务涉及可形变物体、大物体全身搬运，是传统 MPC 极难手工编程的；
- 意外恢复：人为干扰（例如关上容器盖、把物体挪走）后，策略能自主调整、重新完成任务。

2.5 意义

1. “一个策略控制全身”的早期证明：在双足人形上，用单一学习策略同时完成行走与灵巧操作，这在 2025 年中是领先的；
2. TRI LBM 研究的工业验证：TRI 的 LBM 研究（见第 15 章）在固定双臂平台上验证了”多任务预训练提升样本效率”；Atlas LBM 把这一结论推到了全尺寸人形；
3. Boston Dynamics 文化的转变：从”动作工程师”到”数据工程师”。

2.6 局限

- 30Hz 对于高动态全身动作而言偏低，高动态行为仍依赖底层控制器；
- 4.5 亿参数且不含大规模 VLM 预训练，语义泛化能力有限（这正是后来引入 Gemini 的原因）。

---

3. 代表作二：基于动捕的强化学习全身运动（与 RAI 研究所，2025）

> 来源：Boston Dynamics 与 RAI 研究所发布的 Atlas 强化学习系列视频与博客（2025）；RAI 研究所《强化学习加速人形行为生成》；相关学术论文（如 ZEST，arXiv 2602.00401）。

3.1 问题：如何让一个 360° 关节的机器人”像人一样动”？

电动 Atlas 的关节活动范围远超人类，这既是优势也是难题——手工设计”自然的人类动作”几乎不可能。RAI 研究所给出的方案是：用人类动作捕捉与动画作为参考，用强化学习训练机器人去”追踪”这些参考动作。

3.2 方法

- 参考动作：人类动作捕捉数据，以及动画师制作的动画；先做运动重定向（retargeting），把人体动作映射到 Atlas 的骨架上；
- 仿真训练：在仿真中用强化学习训练一个控制策略，奖励是”与参考动作的接近程度”+ 物理约束（平衡、接触、关节限制）；
- 规模：据 RAI 研究所介绍，每一个动作技能都基于约 1.5 亿次仿真运行生成；
- 零样本迁移：训练好的策略零样本部署到真实 Atlas 上，无需真机微调。

3.3 成果

Atlas 展示了行走、跑步、爬行（“匍匐前进”）、侧手翻、霹雳舞等动作——其中多接触动作（手、肘、膝同时着地）对传统 MPC 来说极难建模。学术论文 ZEST 也报告了在 Atlas 上从动作捕捉中学习匍匐、霹雳舞等动态多接触技能。

3.4 意义

这项工作与 NVIDIA SONIC、Figure Helix 02 S0 共同印证了 2025–2026 年的一个行业共识：“动捕追踪 + 仿真 RL + 零样本迁移”是人形底层运动控制的标准范式。对于 Boston Dynamics 来说，它意味着 Atlas 的”小脑”也完成了从 MPC 到学习的转型——上层由 LBM/Gemini 负责，下层由 RL 运动策略负责。

---

4. 代表作三：量产 Atlas + Gemini Robotics + 工厂训练体系（2026）

> 来源：CES 2026（2026-01-05，现代汽车集团发布会）；Boston Dynamics 官方博客 *Boston Dynamics & Google DeepMind Form New AI Partnership*；现代汽车 AI 机器人战略；2026 年 9 月佐治亚机器人应用中心开幕报道。

4.1 CES 2026：三件事同时发生

1. 量产版 Atlas 亮相：面向工业部署的设计；
2. 与 Google DeepMind 建立 AI 合作：DeepMind 机器人负责人 Carolina Parada 称 Atlas 将是合作的”第一个测试案例”，双方将在接下来数月启动联合研究，在 Atlas 上使用 Gemini Robotics 基础模型；
3. 现代汽车的 AI 机器人战略：现代计划到 2028 年建立年产约 3 万台机器人的生产体系；Atlas 将从 2028 年起分阶段部署到集团各工厂，首先是佐治亚的现代汽车美国 Metaplant。2026 年的 Atlas 产量已全部分配给现代汽车与 Google DeepMind。

4.2 “双大脑合作”的含义

Boston Dynamics 现在同时拥有两个外部大脑合作方：

合作方	提供	优势
TRI（LBM）	多任务行为模型，扩散/流匹配策略	精细操作、样本效率、学术严谨
Google DeepMind（Gemini Robotics）	具身推理（ER）+ VLA + 端侧模型	语义理解、推理、跨本体、语言交互

结合 DeepMind Gemini Robotics 2（2026.07）新增的全身控制能力，可以推测（本报告分析）：未来 Atlas 的大脑栈可能是”Gemini Robotics-ER（任务理解与编排）+ Gemini Robotics / LBM（全身视觉运动策略）+ RL 运动控制器（高频平衡与运动）”的三层组合。

4.3 工厂即训练场：机器人 Metaplant 应用中心

2026 年 9 月 21 日，Boston Dynamics 在现代佐治亚园区开设了机器人 Metaplant 应用中心（Robotics Metaplant Application Center），用于训练 Atlas 完成零部件装配与重物搬运等任务；计划 2027 年建设约 10 倍规模的设施。按照现代的”韩国式预训练模式”，机器人先在训练中心做”预训练”，再部署到产线，在生产现场持续迭代学习。

大脑视角的意义：这是一个“工厂内数据飞轮”——母公司现代汽车既是客户、又是数据源、又是测试场。相比 Figure 需要说服宝马、特斯拉只能用自家工厂，Boston Dynamics 拥有一个集团内部、规模巨大、场景标准化的汽车制造体系作为训练场。

4.4 冷静看待

- 多家媒体（包括一些低可信度来源）声称 Atlas”已在 Metaplant 自主工作”，但较一致的说法是正式产线部署从 2028 年开始；
- “到 2028 年数万台”属于集团规划，实际节奏取决于大脑能力能否满足汽车产线的可靠性要求（通常 99.9% 以上）。

---

5. 技术路线总结：从”编程身体”到”学习身体 + 借用大脑”

层级	2013–2023（液压 Atlas）	2025–2026（电动 Atlas）
高层任务	人工编排	Gemini Robotics-ER / 语言指令
视觉运动策略	无（预设轨迹 + 感知模块）	LBM（4.5 亿参数 DiT，30Hz，全身）/ Gemini Robotics
底层运动控制	MPC + 离线轨迹优化	动捕参考 + 仿真 RL + 零样本迁移（与 MPC 并存）
数据来源	工程师设计	VR 全身遥操作 + 仿真 + 工厂运行数据

Boston Dynamics 的战略可以概括为：把自己最强的东西（身体与运动控制）做到极致，把大脑交给最强的合作者，把母公司的工厂变成数据飞轮。

---

6. 横向对比与身位

维度	Boston Dynamics	Figure	特斯拉	Agility
大脑	TRI LBM + DeepMind Gemini + RAI RL	自研 Helix	自研（FSD 体系）	自研全身控制 + 上层系统
全身单策略	2025.08（LBM）	2026.01（Helix 02）	不详	全身控制基础模型（底层）
工业客户	母公司现代（内生）	宝马（外部）	自家工厂	GXO、舍弗勒等
硬件水平	全球顶尖（360° 关节）	顶尖	顶尖	成熟、务实

身位判断： - 身体：全球第一档； - 大脑：自身研发能力中上，但通过与 TRI、DeepMind 的合作获得了第一梯队的大脑资源； - 落地：拥有最确定的大客户（现代汽车），但大规模部署时间点（2028）晚于部分竞争对手的宣称。

---

7. 未来展望与风险

展望： 1. Gemini + Atlas 的首批成果：2026 年下半年至 2027 年，DeepMind 与 BD 的联合研究成果将是 Gemini Robotics 全身控制能力在顶级人形硬件上的首次大规模验证； 2. 工厂数据飞轮：Metaplant 应用中心的扩建意味着 Atlas 将在真实汽车制造场景中积累海量数据； 3. Spot 的复用：有报道称 Gemini Robotics 也可能运行在 Spot 上，形成"四足 + 人形"的统一大脑。

风险： 1. 大脑依赖外部：如果 DeepMind 或 TRI 的合作关系变化，Boston Dynamics 将面临核心能力缺口； 2. 成本：Atlas 的高端硬件成本与中国厂商（宇树等）的低价策略形成鲜明对比； 3. 时间表：2028 年的大规模部署节点，相对于特斯拉、Figure、中国厂商的激进时间表，可能在市场竞争中显得保守。

---

8. 延伸阅读与核验来源

- Boston Dynamics 博客：Large Behavior Models and Atlas Find New Footing（2025-08-20）
- Toyota 新闻：BD 与 TRI 的 AI 机器人迈向通用人形的关键一步
- RAI 研究所：强化学习加速人形行为生成；i-programmer：Atlas 强化学习
- ZEST（arXiv 2602.00401）：Atlas 上从动捕学习多接触技能
- Boston Dynamics 博客：与 Google DeepMind 建立新 AI 合作；TechCrunch；The Robot Report
- A3 Automate：Boston Dynamics 2026 年开始生产重新设计的 Atlas
- Korea Herald：Atlas 2028 年进入现代佐治亚 Metaplant
- CBT News：Boston Dynamics 开设机器人训练中心

> 核验说明：LBM 的参数量、训练目标、输入输出与频率来自 Boston Dynamics 官方博客；"每个动作约 1.5 亿次仿真"来自 RAI 研究所官方页面；DeepMind 合作与产量分配来自 CES 2026 官方发布与多家主流媒体；"已在 Metaplant 自主工作"的说法来自低可信来源，本章未采信；4.2 节三层大脑栈为本报告分析推测。

第 10 章 Agility Robotics：最早”拿到工资”的人形机器人，与它的”运动皮层”

> 一句话定位：Agility 是全球第一家让人形机器人以付费方式进入真实商业运营的公司（Digit 在 GXO 物流仓库以”机器人即服务”模式工作）。它的大脑哲学与 Figure、特斯拉截然不同：不追求”通用大模型”的叙事，而是追求”安全、可靠、能上班”。其代表性技术是一个参数量不到 100 万、完全在仿真中训练、零样本迁移到真机的”全身控制基础模型”——Agility 称之为 Digit 的”运动皮层”。2026 年，Agility 宣布通过 SPAC 上市、发布 Digit 5（“AI 赋能、协作安全”的人形），并在加州弗里蒙特设立 AI 中心。它代表了”务实派”人形大脑路线。

0. 速览卡片

维度	内容
成立	2015 年，从俄勒冈州立大学（OSU）动力机器人实验室分拆
创始人	Jonathan Hurst（首席机器人官，双足动力学专家）、Damion Shelton
管理层	Peggy Johnson（CEO，前微软高管、Magic Leap CEO）；Pras Velagapudi（CTO）
产品	Cassie（双足，2017）→ Digit（2019 起，多代）→ Digit 4 → Digit 5（2026.09.15 发布，2027 年早期访问）
商业	GXO（首个付费人形部署，2024 起，RaaS 模式；2026 年扩展至另两处美国设施）、舍弗勒（洗衣机外壳装卸）、AGCO（2027 年试点）；Digit 5 累计多年期订单承诺超 3 亿美元（公司口径）
资本	2026 年 6 月 24 日宣布与 Churchill Capital Corp XI 合并（SPAC），交易前股权估值 25 亿美元，预计募资超 6.2 亿美元（含富士康领投的约 2 亿美元 PIPE），拟以 AGLT 代码上市（截至报道时尚未完成）
大脑	全身控制基础模型（2025，“运动皮层”）+ 上层任务系统 + Agility Arc 云平台；2026 年 7 月设立弗里蒙特 AI 中心
本章三篇代表作	① 学术根基：双足 RL 的 sim2real（Cassie 时代，2020–2021）② 全身控制基础模型（2025）③ Digit 5 与”协作安全的 AI 人形”（2026）
身位	商业化落地最早、最务实；在”通用大模型”维度上不是领先者，但在”可靠工作”维度上是标杆

1. 故事的开端：鸵鸟腿与”被动动力学”

Agility 的 DNA 来自俄勒冈州立大学 Jonathan Hurst 的实验室。Hurst 的核心研究是双足行走的被动动力学——他认为，好的腿应该像鸵鸟腿一样，通过弹性与机械结构"自然地"行走，而不是靠电机硬撑。2017 年的 Cassie 就是这一理念的产物：没有上半身，只有一双反关节的"鸟腿"，但能在崎岖地面上稳定行走。

Cassie 成为了全球最重要的双足强化学习研究平台之一。Berkeley、OSU 等团队在 Cassie 上完成了一系列里程碑： - 2020–2021 年，OSU 的 Siekmann 等人发表 *Sim-to-Real Learning of All Common Bipedal Gaits via Periodic Reward Composition*：用周期性奖励组合，在仿真中训练出走、跑、跳、单腿跳等所有常见步态，并零样本迁移到 Cassie 真机；同期的工作还让 Cassie 学会了盲走楼梯； - 2021 年，OSU 团队用 RL 训练的 Cassie 一次充电跑完了 5 公里，并在 2022 年创下双足机器人 100 米最快纪录的吉尼斯世界纪录；同期 Berkeley（Koushil Sreenath 组）等团队也在 Cassie 上完成了 RL 跳跃、奔跑等一系列研究。

这些工作的意义：它们在人形机器人行业爆发之前，就证明了"仿真中强化学习 + 零样本 sim2real"是双足运动控制的可行路线——这条路线后来被宇树、Figure（Helix 02 S0）、NVIDIA（SONIC）、Boston Dynamics（与 RAI）等全面采用。Agility 是这条路线最早的商业受益者。

在 Cassie 上加上躯干、手臂与头部，就有了 Digit。

---

2. 代表作一：学术根基——双足 RL 的 sim2real（2020–2021）

> 代表论文：Siekmann, Green, Warila, Fern, Hurst, *Sim-to-Real Learning of All Common Bipedal Gaits via Periodic Reward Composition*（ICRA 2021）；Siekmann et al., *Blind Bipedal Stair Traversal via Sim-to-Real Reinforcement Learning*（RSS 2021）。

2.1 问题

传统双足控制需要为每一种步态（走、跑、跳）设计专门的控制器与参考轨迹。能否用一个统一的方法，让 RL 自己"发现"所有步态？

2.2 方法：周期性奖励组合

- 把步态描述为一个周期内"脚在空中/着地"的时间比例与相位关系；
- 用一组周期性的概率奖励函数来描述"在周期的某个相位，脚应该受力还是应该移动"；
- 改变奖励中的相位参数，就能得到走（双脚交替、有双支撑期）、跑（有腾空期）、跳（双脚同步）、单腿跳等不同步态；
- 在仿真中用 PPO 训练一个以步态参数为条件的策略，配合动力学随机化，零样本迁移到 Cassie。

2.3 意义

这项工作体现了 Agility 一系的方法论特色：用"结构化的奖励设计"引导 RL，而不是盲目堆数据。这与后来 Figure/NVIDIA 的"动捕追踪"路线形成对照——前者用物理结构先验，后者用人类动作先验。两者在 2025 年的 Agility 全身控制模型中实现了融合。

---

3. 代表作二：全身控制基础模型（2025）——Digit 的"运动皮层"

> 官方博客：*Training a Whole-Body Control Foundation Model*（agilityrobotics.com，2025 年中）；The Robot Report（2025-09-14）报道；NVIDIA 客户案例。

3.1 问题：为什么需要一个"运动皮层"？

Digit 在仓库里要做的事情——搬箱子、放到传送带、转身、蹲下——都需要全身协调：手要抬多高、腰要弯多少、脚要往哪迈，都必须同时决定，而且要在搬运数十磅重物时保持平衡、在被人碰到时保持安全。

如果上层 AI（无论是 VLA 还是任务规划器）要直接控制每一个关节，它将不得不同时学会"完成任务"和"不摔倒"，这对上层模型极不友好。Agility 的思路是：像人脑一样，把"运动皮层"单独出来——上层只说"手去那里"，运动皮层负责"全身怎么配合才能让手到那里且不摔倒"。

3.2 接口设计

输入（来自上层）	输出
手的目标位置/姿态（自由空间中）	全身所有关节的控制指令
躯干的目标位置/姿态	（平衡、步伐、手臂、躯干协调）
行走速度等运动指令	

用户（或上层 AI）只需告诉 Digit 手或躯干应该在空间中移动到哪里，模型会自己算出如何协调身体其余部分，安全、平稳地到达。Agility 把它描述为一个始终在线的安全与控制层。

3.3 关键特点

- 极小：参数量不到 100 万——与 Figure Helix 02 的 S0（约 1000 万参数）、NVIDIA SONIC（最大约 4200 万参数）相比都小得多；
- 纯仿真训练：在 NVIDIA Isaac Sim/Isaac Lab 中通过强化学习训练，大规模并行、大量动力学随机化；
- 零样本 sim2real：直接部署到真机，无需额外调参；
- 已进入生产：NVIDIA 的客户案例称，Agility 已将仿真训练的全身控制基础模型成功部署到真实的仓储与制造运营中；舍弗勒工厂中 Digit 用它完成洗衣机外壳的装卸。

3.4 与 Figure S0 / NVIDIA SONIC 的对比

维度	Agility 全身控制基础模型	Figure Helix 02 S0	NVIDIA SONIC
规模	< 100 万参数	约 1000 万参数	120 万–4200 万参数
训练信号	仿真 RL（以任务目标为条件，参考了动捕等先验的说法不一）	1000+ 小时人类动作追踪 + RL	700 小时动捕追踪 + RL
接口	手/躯干目标位姿	S1 输出的全身运动目标	动作片段/目标
频率	高频（未公开具体值）	1 kHz	高频
商用	已在客户现场生产使用	Figure 03	开源研究

解读：Agility 的模型最小、最"工程化"——它追求的不是"能做霹雳舞"，而是"每天在仓库里搬 8 小时箱子不出事"。这体现了 Agility 一贯的价值观：可靠性 > 炫技。

3.5 局限

- 它只是”运动皮层”，不是”大脑”：上层的任务理解、视觉识别、操作策略仍需另外的系统；
- 对于精细灵巧操作（Digit 的手是简单的夹爪/抓手），它并不涉及。

---

4. 代表作三：Digit 5 与”协作安全的 AI 人形”（2026）

> 来源：Agility 新闻稿（2026-09-15 Digit 5 发布）；SPAC 合并公告（2026-06-24）；弗里蒙特 AI 中心（2026-07）。

4.1 Digit 5 的定位：第一个”协作安全”的人形

Agility 把 Digit 5 描述为”世界上第一台 AI 赋能、协作安全（cooperatively safe）的人形机器人”。关键词是”协作安全”：

- 传统工业机器人需要安全围栏把人隔开；
- 协作机器人（cobot）可以与人共处，但要满足严格的安全标准（如功率与力限制）；
- 人形机器人如果要真正在仓库、工厂与人并肩工作，必须满足同等甚至更高的安全要求——而一个会摔倒、会突然移动的双足机器人，是安全认证的噩梦。

Digit 5 的硬件升级包括约 50 磅（约 23 公斤）有效载荷、约 9 分钟快速充电等；早期访问计划在 2027 年，并计划进入欧盟与英国市场（这意味着需要满足欧洲的机器人安全法规）。

4.2 AI 的角色：安全层

在 Agility 的体系中，AI 的首要任务是安全：全身控制基础模型作为”始终在线的安全与控制层”，确保无论上层发出什么指令，机器人都保持平衡、不做危险动作、在接触人时做出合规反应。这与 DeepMind 在 Gemini Robotics 2 中强调的 ASIMOV 安全基准、语义安全层形成了”物理安全 + 语义安全”的互补视角。

4.3 弗里蒙特 AI 中心与上层智能

2026 年 7 月，Agility 在加州弗里蒙特开设 AI 中心，旨在随着部署规模扩大加速 Digit 的 AI 开发。这表明 Agility 也在补强上层智能（视觉、操作策略、任务学习）——在大模型时代，“只有可靠的运动皮层”已不足以竞争。

4.4 商业化：已签约订单 vs 宏大愿景

Agility 的商业数据相对”实在”： - Digit 5 累计多年期订单承诺超 3 亿美元（公司口径）； - GXO 扩展协议：另外两处美国设施，2027 年初开始以 Digit 4 部署，Digit 5 上市后过渡； - AGCO：2027 年在堪萨斯州 Hesston 生产基地开展试点。

与特斯拉”百万台产线”、Figure”390 亿美元估值”相比，Agility 的数字小得多，但它是少数有明确付费客户与合同金额披露的人形公司。

---

5. 技术路线总结

Agility 的大脑路线是一种”自下而上”的路线：

```
2017–2021：双足 RL sim2real（Cassie）—— 先解决"走得稳"
        ↓
2019–2024：Digit + 传统控制 + 任务系统 —— 解决"能上班"（GXO 付费部署）
        ↓
2025：全身控制基础模型 —— 解决"全身协调 + 安全"
        ↓
2026：Digit 5 + AI 中心 —— 补强上层智能，解决"协作安全 + 更多任务"
```

与之相对，Figure/特斯拉/PI 是”自上而下”的：先有大模型与通用叙事，再逐步落地到具体场景。两条路线各有优劣：自下而上更可靠、更早赚钱，但可能在通用性上落后；自上而下更有想象空间，但商业化更晚。

---

6. 横向对比与身位

维度	Agility	Figure	特斯拉	Boston Dynamics
首个付费商业部署	2024（GXO）	宝马（试点）	自家工厂	母公司（2028 起）
大脑核心	全身控制基础模型 + 任务系统	Helix 三层 VLA	端到端 + 世界模拟器	LBM + Gemini
手	简单抓手	五指灵巧手	22 自由度灵巧手	灵巧手
资本路径	SPAC 上市（25 亿美元估值）	390 亿美元估值私募	上市公司	现代集团
安全定位	“协作安全”是核心卖点	家用安全设计	不详	工业安全

身位判断： - 商业化：全球第一梯队（最早付费部署、合同金额披露）； - 大脑：底层运动控制成熟、可靠；上层通用智能不是其优势，在大模型叙事中处于”跟随者”位置； - 定位：如果说 Figure/特斯拉在赌”通用人形”，Agility 在赌”物流仓储这一个场景先做透”。

---

7. 未来展望与风险

展望： 1. 上市后的资本补给：SPAC 完成后募集的 6 亿美元以上资金，将用于扩大生产与 AI 研发； 2. 协作安全认证：如果 Digit 5 率先通过欧洲/美国的协作安全认证，将形成重要的准入壁垒； 3. 上层大脑的选择：Agility 可能接入外部大脑（例如其曾是 Gemini Robotics 的可信测试伙伴之一），或在弗里蒙特 AI 中心自研上层 VLA。

风险： 1. 通用性竞争：如果通用人形（Figure、特斯拉、中国厂商）在 2027–2028 年在物流场景中达到同等可靠性且成本更低，Agility 的场景专精优势可能被侵蚀； 2. SPAC 不确定性：交易尚未完成，市场环境变化可能影响上市进程； 3. 中国竞争：中国人形厂商在物流搬运场景的低价产品正在快速进入市场。

---

8. 延伸阅读与核验来源

- Agility 官方：Training a Whole-Body Control Foundation Model
- The Robot Report：Agility 解释如何训练全身控制基础模型
- NVIDIA 客户案例：Agility Digit
- Interesting Engineering：Agility 上市，下一代 Digit 需求增长
- Agility 新闻稿：商业势头与企业需求
- Siekmann et al., *Sim-to-Real Learning of All Common Bipedal Gaits via Periodic Reward Composition*（ICRA 2021）
- Siekmann et al., *Blind Bipedal Stair Traversal via Sim-to-Real Reinforcement Learning*（RSS 2021）

> 核验说明：全身控制模型"不到 100 万参数、Isaac 仿真训练、零样本迁移"来自 Agility 官方博客与 NVIDIA 案例的一致描述；Digit 5、SPAC、GXO/AGCO 信息来自公司新闻稿及多家媒体；订单金额为公司口径；单台价格等数字各来源冲突，本章未采用。

第 11 章 Sunday Robotics：ACT 与 Diffusion Policy 的作者们，用一只 200 美元的手套挑战遥操作

> 一句话定位：Sunday 是一家”学术血统最纯正”的家用机器人公司——联合创始人 Tony Zhao 是 ALOHA / ACT（动作分块 Transformer）的第一作者，Cheng Chi 是 Diffusion Policy 与 UMI（通用操作接口）的第一作者。这两项工作分别定义了 2023–2025 年机器人模仿学习的”模型范式”（动作分块）与”数据范式”（无本体手持采集）。2025 年 11 月，他们推出了家用半人形机器人 Memo 与基础模型 ACT-1——一个完全不使用机器人数据、只用自研”技能采集手套”在 500 多个真实家庭中采集的数据训练出的机器人大脑。Sunday 代表了”以人为本体的低成本数据采集”路线的最激进实践。

0. 速览卡片

维度	内容
成立	2024 年，美国加州
联合创始人	Tony Zhao（CEO，斯坦福博士，ALOHA/ACT、Mobile ALOHA 作者）；Cheng Chi（斯坦福/哥伦比亚博士，Diffusion Policy、UMI 作者）
融资	2025 年 11 月走出隐身，种子/A 轮约 3500 万美元（Benchmark、Conviction）；2026 年 3 月据报道完成由 Coatue 领投的 1.65 亿美元 B 轮，估值约 11.5 亿美元
产品	Memo：轮式底盘 + 可升降躯干 + 双臂的家用半人形机器人（不爬楼梯，刻意取舍以降低成本与复杂度）
大脑	ACT-1：端到端机器人基础模型，长时程操作 + 地图条件化导航，训练数据中零机器人数据
数据	技能采集手套（Skill Capture Glove）：约 200 美元/只（对比约 2 万美元的遥操作装置），与 Memo 的手共同设计（几何与传感器一致）；在 500+ 个美国家庭中采集约 1000 万条家庭日常操作片段（公司口径）；Skill Transform 管线把手套数据转换为机器人数据，转换成功率约 90%
本章三篇代表作	① ALOHA / ACT（2023，模型范式源头）② UMI（2024，数据范式源头）③ ACT-1 + 技能采集手套 + Memo（2025.11）
身位	“人类数据派”中最具学术公信力的家用机器人公司；家用场景与 1X、Figure 正面竞争

1. 故事的开端：两篇改变行业的论文

2023 年春天，机器人学习领域同时出现了两篇注定成为”教科书”的论文：

- 斯坦福的 Tony Zhao（导师 Chelsea Finn）发布了 ALOHA——一套成本约 2 万美元的低成本双臂遥操作系统，以及与之配套的 ACT（Action Chunking with Transformers） 算法；

- 哥伦比亚大学的 Cheng Chi（导师宋舒然 Shuran Song，后随导师转至斯坦福）与 TRI、MIT 合作发布了 Diffusion Policy——第一次把扩散模型系统地用于机器人动作生成。

这两篇论文共同回答了 2023 年模仿学习的核心问题："如何让一个策略从几十条人类示范中学会精细、多模态的操作？" ACT 的答案是"一次预测一整块动作"，Diffusion Policy 的答案是"用扩散模型表达多模态动作分布"。此后两年，几乎所有 VLA（π0、GR00T、Helix、GO-1……）的动作头都在这两种思想的基础上演化。

2024 年，Cheng Chi 又发布了 UMI（Universal Manipulation Interface）——一个手持夹爪采集装置，让人"拿着夹爪干活"就能采集可直接训练机器人的数据，把数据采集从"必须有机器人"解放出来。

2024 年，二人决定一起创业：如果 ACT 和 Diffusion Policy 解决了"模型"，UMI 指明了"数据"，那么下一步就是把它们组合成一个真正能进入家庭的产品。

---

2. 代表作一：ALOHA 与 ACT（2023）——"动作分块"的诞生

> 论文：Tony Z. Zhao, Vikash Kumar, Sergey Levine, Chelsea Finn, *Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware*（RSS 2023）

2.1 ALOHA：低成本双臂遥操作

ALOHA（A Low-cost Open-source Hardware System for Bimanual Teleoperation）由两对 ViperX/WidowX 机械臂组成：操作员手持一对"主臂"（leader），机器人的一对"从臂"（follower）实时跟随——这是一种关节空间的直接映射（puppeteering），比 VR 遥操作更直观、延迟更低、力的感觉更自然。整套系统约 2 万美元，开源硬件设计。

ALOHA 让"用双臂做精细操作的示范"变得廉价而高效，操作员可以完成穿扎带、打开调料杯盖、插电池、装鞋等需要毫米级精度和双手配合的任务。后来 Google DeepMind 的 ALOHA 2、Mobile ALOHA，以及大量中国公司的双臂采集平台，都以 ALOHA 为原型。

2.2 ACT：动作分块 Transformer

问题：标准行为克隆（BC）每一步预测一个动作，误差会随时间累积（compounding error）：一小步偏差导致下一步的观察偏离训练分布，偏差越来越大。人类示范中还存在停顿、犹豫等非马尔可夫行为，单步预测难以建模。

ACT 的三个设计：

1. 动作分块（Action Chunking）：每次预测未来 k 步（例如 100 步）的动作序列，而不是单步。这把"决策次数"减少了 k 倍，直接降低了复合误差；同时一个动作块可以表达"先停顿再动"这样的时间结构。
2. 时间集成（Temporal Ensembling）：每一步都预测一个动作块，于是同一时刻会有多个重叠的预测；对它们做指数加权平均，得到平滑的最终动作，消除块与块之间的跳变。
3. CVAE 训练：把策略训练成条件变分自编码器（CVAE）的解码器——编码器把（动作序列 + 关节状态）压缩成一个风格隐变量 z，解码器以图像、关节状态与 z 为条件生成动作块；推理时 z 取先验均值。这用于建模人类示范中的多样性与噪声。

网络：ResNet18 视觉主干（4 路相机）+ Transformer 编码器-解码器，约 8000 万参数，50Hz 控制。

结果：仅用约 50 条示范（约 10 分钟数据），ACT 就在 6 项精细双臂任务上达到 80–90% 的成功率，大幅超越此前的 BC 方法。

2.3 影响

“动作分块”是 ACT 留给行业最重要的遗产：π0 的 50 步动作块、GR00T 的 16 步动作块、Gemini Robotics 的动作块、Helix 的高频输出，都继承了这一思想。2024 年的 Mobile ALOHA（Zipeng Fu、Tony Zhao、Chelsea Finn）把 ALOHA 装上移动底盘，展示了炒虾、开柜子放锅、乘电梯等家庭移动操作——这正是 Sunday Memo 的直接前身。

---

3. 代表作二：UMI（2024）——“不用机器人也能采机器人数据”

> 论文：Cheng Chi, Zhenjia Xu, Chuer Pan, Eric Cousineau, Benjamin Burchfiel, Siyuan Feng, Russ Tedrake, Shuran Song, *Universal Manipulation Interface: In-The-Wild Robot Teaching Without In-The-Wild Robots*（RSS 2024）

3.1 问题

ALOHA 降低了遥操作成本，但它仍然需要机器人在场。要在成千上万个真实家庭、餐厅、商店中采集数据，你不可能把机器人搬过去。

3.2 方案：手持夹爪 + 鱼眼相机

UMI 是一个 3D 打印的手持平行夹爪： - 夹爪上装一个 GoPro 鱼眼相机（155° 视场），从”手腕视角”录像； - 夹爪两侧加装镜子，在单个相机画面中提供隐式立体视觉； - 用相机自带的 IMU 与视觉 SLAM 恢复夹爪的 6 自由度轨迹； - 从画面中识别夹爪开合程度。

人拿着 UMI 去任何地方干活，就得到了”腕部相机图像 + 末端轨迹 + 夹爪开合”——这正是一个机器人用腕部相机执行同样任务所需的全部训练数据。

3.3 关键设计：“策略接口”的对齐

UMI 最精妙的地方在于让人的数据和机器人的部署在”观察空间”与”动作空间”上完全一致： - 观察：机器人上同样装一个 GoPro 腕部相机、同样的镜子，画面分布与人手持时一致； - 动作：输出相对末端位姿（相对当前位姿的变化），与具体机械臂无关； - 延迟匹配：在训练时显式处理相机、动作执行的延迟差异。

这样训练出的 Diffusion Policy 可以直接部署到不同的机械臂（UR5e、Franka 等）上——“硬件无关”。

3.4 结果与影响

UMI 演示了洗碗、抛物、杯子摆放（在任意环境中泛化）等任务，并验证了”在大量不同环境中采集的数据带来环境泛化”。UMI 的影响极其深远： - 清华的 RDT2（2025）用 UMI 式数据实现零样本跨本体； - Generalist、

它石智航、穹彻（RoboPocket）等都走"无本体采集"路线； - Data Scaling Laws in Imitation Learning（清华高阳组，2024）用 UMI 采集了大量环境数据研究缩放规律。

---

4. 代表作三：ACT-1 + 技能采集手套 + Memo（2025.11）

> 官方博客：*ACT-1: A Robot Foundation Model Trained on Zero Robot Data*（sunday.ai，2025-11）；Tony Zhao 发布推文。

4.1 从夹爪到手套：UMI 的"五指化"

UMI 用的是平行夹爪，只能采集"夹爪式"的操作。家务中大量动作需要手：拿杯子、拧瓶盖、叠衣服、抓多个物体。Sunday 的方案是 技能采集手套（Skill Capture Glove）：

- 与 Memo 的手共同设计：手套与机器人手几何结构一致、传感器配置一致——这是 UMI "策略接口对齐"思想在五指层面的延续；
- 成本约 200 美元，对比约 2 万美元的遥操作设备，便宜约 100 倍；
- 采集者戴着手套在自己家里做日常家务，数据自然地覆盖了真实家庭的多样性。

4.2 数据规模

据 Sunday 公开信息： - 在超过 500 个美国家庭中采集； - 约 1000 万条家庭日常操作片段（"routines"）； - 通过 Skill Transform 管线把手套数据转换为机器人可用的数据（考虑手套与机器人在运动学、视角上的细微差异），转换成功率约 90%。

4.3 ACT-1：零机器人数据的基础模型

ACT-1 的三大宣称能力（Tony Zhao 原话："超长时程任务、零样本泛化、先进灵巧性"）：

1. 超长时程：完成"收拾餐桌 → 把碗碟装进洗碗机 → 启动"这类包含数十个子步骤的家务；
2. 零样本泛化：在未采集过数据的新家庭中工作；
3. 灵巧性：抓取红酒杯（极易碎、透明、形状复杂）等精细操作。

架构要点（来自官方博客的公开描述）：ACT-1 在一个端到端模型中结合了长时程操作与地图条件化导航——模型以家庭的地图信息为条件决定去哪里，同时输出操作动作。这与 π0.5 的"高层子任务 + 低层动作"、Figure Helix 的"S2/S1"不同，强调的是"导航与操作的统一"。

4.4 Memo：为数据而设计的身体

Memo 的设计处处体现"数据优先"： - 轮式底盘：放弃双足，避免平衡、能耗、维护与成本问题（代价是不能爬楼梯）； - 可升降躯干：覆盖从地面到高柜的工作高度； - 与手套一致的手：保证人类数据可以直接迁移； - 外观友好：卡通化的外形降低家庭用户的心理门槛。

2026 年 Sunday 计划选择约 50 个家庭进行早期部署（截至本报告撰写时未见完成情况的确认）。

4.5 "零机器人数据"的意义与疑问

意义：如果 ACT-1 的宣称成立，它意味着机器人基础模型可以完全绕过遥操作——数据采集成本下降两个数量级，规模可以像"众包"一样扩张。这是对 PI（遥操作 + 多本体）、Figure（遥操作 + 人类视频）等路线的直接挑战。

疑问： - 90% 的转换成功率意味着仍有 10% 的数据无法使用或需要修正； - "零机器人数据"在部署时是否真的不需要任何机器人数据微调？官方未披露评测细节； - 家庭任务的成功率、可靠性数据尚未公开。

---

5. 技术路线总结：从"模型 + 数据"两个源头汇合

```
模型范式源头：ACT（2023）——动作分块、时间集成
        +
多模态动作生成：Diffusion Policy（2023）——扩散模型表达多模态
        +
数据范式源头：UMI（2024）——无本体、硬件无关、接口对齐
        |
        ▼
ACT-1（2025）：手套采集（五指化 UMI）+ 端到端长时程操作与导航
```

Sunday 的独特之处在于：它的创始人亲手发明了这条技术链上的关键环节，因此对每个环节的取舍有最深的理解。

---

6. 横向对比与身位

维度	Sunday	1X	Figure	Generalist
场景	家庭	家庭	工业 + 家庭	通用（授权）
本体	轮式半人形 Memo	双足 NEO	双足 Figure 03	不造本体
数据采集	200 美元手套（零机器人数据）	遥操作 + 家庭运行	遥操作 + 人类视频（Index）	人类真实交互（数十万小时）
大脑	ACT-1（操作 + 导航一体）	Redwood + 1XWM	Helix 三层	GEN 系列
学术透明度	中（博客）	中	中	中

身位判断： - Sunday 是 2025–2026 年最受学术界关注的家用机器人创业公司之一，创始团队的学术公信力极高； - 在"人类数据派"中，它的数据方案最便宜、与本体耦合最紧密； - 产品与商业化处于非常早期的阶段（50 户早期部署计划），大规模验证尚未开始。

---

7. 未来展望与风险

展望： 1. 众包式数据飞轮：200 美元的手套可以大规模分发，数据规模的增长不再受限于机器人数量； 2. 轮式家用机器人的成本优势：放弃双足使 Memo 有可能以远低于双足人形的价格进入家庭； 3. 从 ACT-1 到 ACT-2：随着手套数据规模扩大，模型能力有望遵循缩放规律提升（Generalist 已经展示了人类数据的缩放定律）。

风险： 1. 手套 → 机器人的鸿沟：力、触觉、动态特性在人手与机器人手之间存在本质差异； 2. 家用市场的时间窗口：家用机器人的可靠性、安全与隐私门槛极高，消费市场的真正打开可能比预期晚得多； 3. 竞争：与 1X（已量产）、Figure（Helix 2.5 家庭零样本 56%）在同一市场竞争，Sunday 需要更快拿出可量化的家庭表现数据。

---

8. 延伸阅读与核验来源

三篇代表作 - ALOHA/ACT：Zhao, Kumar, Levine, Finn, *Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware*（RSS 2023，arXiv 2304.13705） - UMI：Chi et al., *Universal Manipulation Interface*（RSS 2024，arXiv 2402.10329） - ACT-1：Sunday 官方博客：ACT-1: A Robot Foundation Model Trained on Zero Robot Data；Tony Zhao 发布

相关 - Chi et al., *Diffusion Policy: Visuomotor Policy Learning via Action Diffusion*（RSS 2023）——详见第 15 章（TRI） - Fu, Zhao, Finn, *Mobile ALOHA*（2024）

核验来源 - AI Business：Sunday Robotics 走出隐身 - Humanoid.guide：Memo 规格 - Humanoid Mega Hub：Sunday Robotics（B 轮信息） - Euronews：Memo 能拿红酒杯、装洗碗机

> 核验说明：ALOHA/ACT 与 UMI 的技术细节来自原论文；ACT-1"零机器人数据"、手套价格、500+ 家庭、1000 万条片段、90% 转换率均为公司口径；B 轮金额与估值来自二手聚合来源；2026 年 50 户早期部署的执行情况未见确认。

第 12 章 Meta（FAIR）：杨立昆的”非生成式世界模型”路线在机器人上的实践

> 一句话定位：在”机器人大脑”赛道上，Meta 是一个特殊的存在——它不卖机器人、不做 VLA，却在推进一条与主流截然不同的路线：JEPA（联合嵌入预测架构）式的”潜空间世界模型”。这条路线源自 Yann LeCun 的长期主张：“智能不应该靠预测像素（生成式），而应该在抽象表征空间中预测未来。”从 Meta Motivo（2024–2025，零样本全身人形控制的行为基础模型）、V-JEPA 2（2025.06，用 100 万小时视频 + 62 小时机器人数据实现零样本规划），到 RoboJEPA（2026.10，80 亿参数、多本体、出现缩放定律的潜空间机器人世界模型），Meta 为行业提供了”世界模型 ≠ 视频生成”的另一种答案。

---

0. 速览卡片

维度	内容
机构	Meta FAIR（基础人工智能研究）；Reality Labs（据 2025 年报道成立人形机器人团队）
关键人物	Yann LeCun（JEPA 思想提出者，2025 年底宣布离开 Meta 创业）；Mahmoud Assran、Nicolas Ballas（V-JEPA 系列核心作者）；Jeannette Bohg（斯坦福教授，RoboJEPA 共同通讯作者）
代表工作	Meta Motivo（2024.12 发布 / 2025.04 论文）、V-JEPA 2 与 V-JEPA 2-AC（2025.06）、V-JEPA 2.1、RoboJEPA（2026.10，arXiv 2610.10515）；以及 Digit 360 触觉指尖、Sparsh 触觉表征、PARTNR 人机协作基准等
开放程度	高：代码与权重开源（Motivo 为 CC BY-NC 4.0；V-JEPA 2 开源；RoboJEPA 开源检查点）
本章三篇代表作	① Meta Motivo：零样本全身人形控制的行为基础模型 ② V-JEPA 2：自监督视频世界模型与零样本机器人规划 ③ RoboJEPA：多本体潜空间世界模型的缩放定律
身位	不做产品的”基础研究供给者”；“非生成式世界模型”路线的全球引领者；对人形产业的直接影响小于 NVIDIA/DeepMind，但对研究方向的影响深远

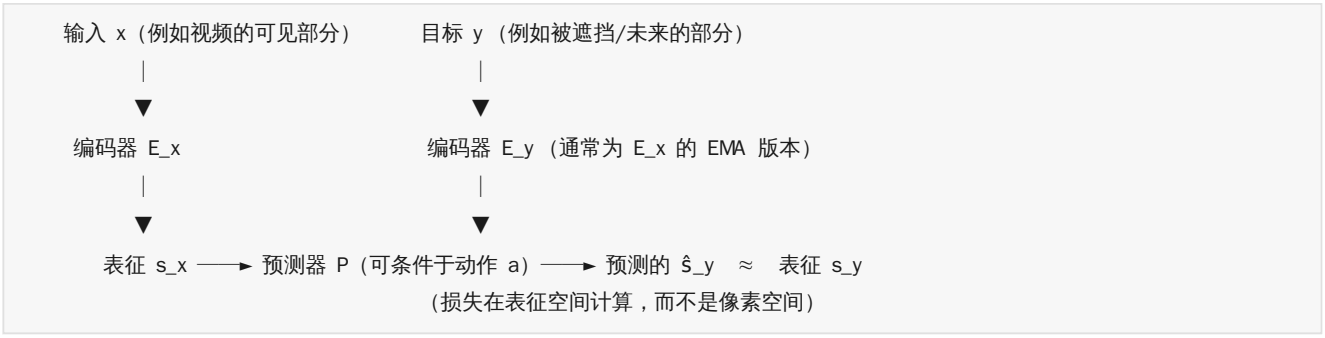
---

1. 故事的开端：LeCun 的”反生成”宣言

2022 年，Yann LeCun 发表了一篇长文 *A Path Towards Autonomous Machine Intelligence*，提出了一个与 GPT 路线针锋相对的观点：

> 让 AI 在像素层面预测未来（例如生成视频）是一种浪费——世界中大量细节本质上不可预测（树叶怎么摆、水波怎么动），模型会把容量浪费在这些无关细节上。真正的世界模型应该在一个抽象的表征空间中预测未来：只预测”重要的、可预测的”部分。

这就是 JEPA（Joint-Embedding Predictive Architecture，联合嵌入预测架构） 的核心思想：



从 I-JEPA（图像，2023）、V-JEPA（视频，2024）到 V-JEPA 2（2025），Meta 一步步把这一思想推向机器人。

与此同时，Meta 还在另一个方向探索"人形控制的基础模型"——Meta Motivo。

---

2. 代表作一：Meta Motivo（2024.12 发布 / 2025.04 论文）——零样本全身人形控制的行为基础模型

> 论文：*Zero-Shot Whole-Body Humanoid Control via Behavioral Foundation Models*（Meta FAIR，arXiv 2504.11054）；代码 facebookresearch/metamotivo；Hugging Face 权重 facebook/metamotivo-S-*/M-1。

2.1 要解决的问题

人形全身控制的传统做法是：每个任务训练一个 RL 策略——行走一个、跳跃一个、追踪某段动作一个。能否训练一个"行为基础模型"，在测试时不经任何训练，就能被"提示"去完成任意新任务（追踪任意动作、到达任意姿态、优化任意奖励）？

2.2 核心方法：FB-CPR

前向-后向表征（Forward-Backward, FB） 是一种无监督强化学习的理论框架：它学习两个映射——前向映射 F(s, a, z) 与后向映射 B(s)——使得任何奖励函数 r 都可以被投影成一个潜向量 z = E[r(s) B(s)]，而以 z 为条件的策略 π(s, z) 就是该奖励下的最优策略的近似。这意味着：训练完成后，给定任意新奖励，只需算一个向量 z，就能零样本得到策略。

但纯 FB 在高维人形上会学到大量"不自然"的行为。Meta 的改进是 FB-CPR（Forward-Backward representations with Conditional-Policy Regularization）：

- 利用只有观测、没有动作的人类动作捕捉数据（AMASS 等）；
- 把这些无标签轨迹嵌入到与策略相同的潜空间中；
- 用一个潜变量条件化的判别器，鼓励以 z 为条件的策略去覆盖数据集中出现的状态——即"让策略的行为像人"。

2.3 零样本"提示"的三种方式

提示方式	如何得到 z	示例
动作追踪	把目标动作序列经 B 编码	模仿一段舞蹈
目标姿态到达	把目标姿态经 B 编码	摆出某个姿势
奖励优化	用少量样本估计 E[r(s)B(s)]	“向前跑”“举手”

2.4 结果与发布

- 在仿真人形（SMPL 骨架，HumEnv 环境）上，零样本完成动作追踪、姿态到达、奖励优化等全身任务，性能可与针对任务专门训练的方法竞争，并优于当时最好的无监督 RL 与基于模型的基线；
- 开源多个检查点：S 系列约 2450 万参数，最大的 M-1 约 2.88 亿参数；
- 许可证为 CC BY-NC 4.0（仅限非商业）。

2.5 意义与局限

意义：Motivo 是”行为基础模型（Behavioral Foundation Model）”这一概念的代表作——把”预训练 + 提示”范式引入了人形全身控制，与 NVIDIA SONIC（动作追踪基础模型）、Figure S0 等在 2025–2026 年形成呼应。 局限：只在仿真人形上验证，未做真机部署；不涉及视觉与操作。

---

3. 代表作二：V-JEPA 2（2025.06）——用视频学”世界如何运转”，再用 62 小时机器人数据学会”行动”

> 论文：*V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning*（Meta FAIR，2025.06）；官方博客 *Introducing the V-JEPA 2 world model and new benchmarks for physical reasoning*。

3.1 两阶段训练

阶段一：无动作的自监督视频预训练 - 数据：超过 100 万小时的互联网视频 + 100 万张图像，无任何人工标注； - 目标：掩码预测——遮住视频的一部分时空块，让模型在表征空间中预测被遮住部分的表征； - 模型：ViT 编码器（最大为 ViT-g，约 10 亿参数；报道称 V-JEPA 2 整体约 12 亿参数）； - 能力（论文报告）： - 运动理解：Something-Something v2 上以注意力探针取得 77.3 的 top-1 准确率（擅长细粒度运动信息）； - 动作预测：EPIC-KITCHENS-100 人类动作预期 Recall@5 = 39.7，当时的最优水平； - 视频问答：与 8B 级语言模型对齐后，PerceptionTest 达到 84.0； - 后续的 V-JEPA 2.1（arXiv 2603.14482）进一步改进了这些指标（例如 EPIC-KITCHENS Recall@5 约 40.8），并成为 RoboJEPA 的编码器。

阶段二：动作条件化后训练（V-JEPA 2-AC） - 冻结视频编码器，在其表征空间上训练一个动作条件化的预测器：“给定当前表征和机器人动作，预测下一时刻的表征”； - 数据：仅约 62 小时来自开源 DROID 数据集的机器人数据（Franka 机械臂，无奖励、无成功标签）。

3.2 零样本规划：在表征空间里”想”

V-JEPA 2-AC 不是一个策略，而是一个世界模型。机器人执行任务的方式是模型预测控制（MPC）：

```
给定：当前图像 → 编码为 s_0；目标图像 → 编码为 s_goal
        |
        ▼
采样大量候选动作序列（交叉熵方法 CEM）
        |
        ▼
对每个候选序列，用预测器在表征空间中"想象"：s_0 → ŝ_1 → ŝ_2 → … → ŝ_T
        |
        ▼
选出使 ‖ ŝ_T − s_goal‖ 最小的动作序列，执行第一步，然后重新规划
```

3.3 结果

- 部署在两个不同实验室的 Franka 机械臂上，场景与训练数据（DROID）中的环境不同；
- 仅给定目标图像，完成伸手、抓取、拾取放置等任务；
- Meta 报告在新环境中拾取放置的成功率约 65%–80%；
- 全过程没有在这些环境中采集任何数据、没有任务专属训练、没有奖励。

3.4 V-JEPA 2 vs 视频生成式世界模型

维度	V-JEPA 2（潜空间预测）	Cosmos / DreamZero / 1XWM（像素生成）
预测目标	抽象表征	像素/视频 latent
推理开销	低（只预测表征）	高（生成视频）
可解释性	低（表征不可直接看）	高（可看生成视频）
规划方式	表征空间 MPC（采样优化）	生成视频 → 反推动作，或联合生成
机器人数据需求	极少（62 小时）	较少到中等
适合的任务	目标图像条件的短程操作	语言条件、长程、复杂操作

V-JEPA 2 的意义在于证明了："不生成像素"的世界模型同样可以支持零样本机器人规划，而且需要的机器人数据极少。但它的局限也很明显：目标需要用图像指定（而非语言）、规划速度受采样优化限制、任务时程较短。

---

4. 代表作三：RoboJEPA（2026.10）——潜空间机器人世界模型的缩放定律

> 论文：*RoboJEPA: Scaling Robotic Latent World Models*（Meta FAIR 等，arXiv 2610.10515，2026.10）；作者含 Artem Zholus，共同通讯作者 Jeannette Bohg、Nicolas Ballas、Mahmoud Assran。

4.1 从"一个实验室的 62 小时"到"12 种本体的 1.5 万小时"

V-JEPA 2-AC 只用了 62 小时单一本体（Franka）的数据。RoboJEPA 的问题是：如果把动作条件化潜空间世界模型做大，会发生什么？

维度	V-JEPA 2-AC（2025.06）	RoboJEPA（2026.10）
机器人数据	约 62 小时（DROID）	约 15,022 小时
数据集数量	1	23 个操作数据集
本体数量	1（Franka）	12 种
预测器规模	约 3 亿参数级	最大 80 亿参数（迄今最大的 JEPA 预测器）
编码器	V-JEPA 2	V-JEPA 2.1
开源	是	是（检查点开源）

4.2 关键发现：想象误差的缩放定律

RoboJEPA 报告了一条”想象误差（imagination error）的二阶幂律”缩放定律：在 2200 万至 20 亿参数的模型上拟合缩放曲线，并在 40 亿与 80 亿参数的留出实验上验证了预测——即模型越大，在潜空间中”想象”未来的误差按可预测的规律下降。

这与 Generalist GEN-0（真实数据上的策略缩放定律）共同构成了 2025–2026 年机器人领域两条最重要的”缩放定律证据”——一条来自策略，一条来自世界模型。

4.3 意义

1. 多本体世界模型：一个潜空间世界模型可以同时理解 12 种不同机器人的动作如何改变世界，这为”跨本体规划”与”通用机器人模拟器”提供了基础；
2. 非生成式路线的规模化证明：此前质疑 JEPA 路线的一个主要理由是”无法规模化”；RoboJEPA 用 80 亿参数和清晰的缩放曲线回应了这一质疑；
3. 开放：检查点开源，使学术界可以在此基础上研究潜空间规划与策略学习。

4.4 局限

- 作为一项 2026 年 10 月刚发布的工作，其在真实人形机器人上的规划/控制效果仍有待更多验证；
- 潜空间世界模型如何与语言指令、长程任务结合，仍是开放问题。

---

5. 技术路线总结：Meta 的”三块拼图”

拼图	代表作	回答的问题
身体如何动	Meta Motivo	能否用一个行为基础模型零样本完成任意全身任务？
世界如何变	V-JEPA 2	能否从无标签视频中学到可用于规划的世界模型？
能否规模化	RoboJEPA	潜空间世界模型是否有缩放定律？

Meta 的路线可以概括为一句话：“先理解世界，再学会行动；理解发生在表征空间，而不是像素空间。” 这与 PI/Figure（直接学策略）、NVIDIA/1X（生成视频）形成三足鼎立的格局。

---

6. 横向对比与身位

世界模型流派	代表	核心	机器人中的角色
潜空间预测（JEPA）	Meta V-JEPA 2 / RoboJEPA	表征空间预测，不生成像素	规划器（MPC）
视频生成 → 动作	1X 1XWM、NVIDIA DreamGen	生成未来视频 + 逆动力学	策略 / 数据生成
视频-动作联合生成	NVIDIA DreamZero、蚂蚁、极佳等	动作作为视频的一个模态	策略
动作条件化神经模拟器	特斯拉、1X（早期）、Genie 3	以动作为条件生成未来观察	评估、RL 训练场

身位判断： - Meta 在机器人领域是“研究供给者”而非”产品竞争者”； - 在”非生成式世界模型”这一路线上，Meta 处于全球引领地位； - 对人形产业的直接商业影响较小，但其开源模型（V-JEPA 2 编码器、Motivo）被大量研究者作为基础组件使用； - Meta 内部的人形机器人项目（Reality Labs）进展未公开，若推进，可能把 FAIR 的研究成果转化为产品。

---

7. 未来展望与风险

展望： 1. JEPA + VLA 融合：用 V-JEPA 的视频表征作为 VLA 的视觉编码器，或用 RoboJEPA 作为 VLA 的”想象器”做测试时规划，是自然的下一步； 2. 人形机器人项目：Meta 若推出自有人形平台，将拥有”开源模型 + 社交平台 + AR/VR 设备（第一视角数据）“的独特组合——Meta 的智能眼镜（Ray-Ban Meta 等）可能成为全球最大的人类第一视角数据来源； 3. LeCun 离开后的路线延续性：JEPA 路线在 Meta 内部能否持续获得资源，值得观察。

风险： 1. 战略优先级：Meta 的 AI 资源主要投向超级智能实验室（MSL）与大语言模型，机器人研究的优先级存在不确定性； 2. 路线风险：如果视频生成式世界模型（DreamZero、1XWM）在机器人策略上取得压倒性成功，潜空间路线可能被边缘化； 3. 非商业许可：Motivo 的非商业许可限制了产业界的直接采用。

---

8. 延伸阅读与核验来源

三篇代表作 - Meta Motivo：arXiv 2504.11054；Hugging Face：metamotivo-M-1 - V-JEPA 2：Meta 官方博客；V-JEPA 研究页 - RoboJEPA：arXiv 2610.10515

其他核验来源 - The Robot Report：V-JEPA 2 用原始视频训练机器人 - CNBC：Meta 发布 AI 世界模型 - AI Weekly：Meta FAIR 发布 8B RoboJEPA - LeCun, *A Path Towards Autonomous Machine Intelligence*（2022）

> 核验说明：Motivo 的 FB-CPR 方法、模型规模与许可证来自论文与 Hugging Face 模型卡；V-JEPA 2 的数据规模、62 小时机器人数据与 65%–80% 成功率来自 Meta 官方与 The Robot Report；RoboJEPA 的数据规模、80 亿参数与缩放定律来自 arXiv 论文（2026 年 10 月发布，独立报道较少）；Reality Labs 人形团队为 2025 年媒体报道，进展未公开。补充核验：V-JEPA 2 的 SSv2 77.3、EPIC-KITCHENS-100 Recall@5 39.7、PerceptionTest 84.0（8B 对齐）与 ViT-g 约 10 亿参数编码器来自 arXiv 2506.09985；V-JEPA 2.1 的改进数字来自 arXiv 2603.14482。

第 13 章 Amazon（FAR / Covariant 一脉）：全球最大的机器人用户，如何打造人形”小脑”工具链

> 一句话定位：亚马逊是全球部署机器人数量最多的企业（其履约网络中运行着上百万台各类机器人），也是人形机器人最具潜力的”超级买家”。2024 年 8–9 月，亚马逊以”人才收购 + 非独家授权”的方式吸纳了 Covariant 的三位创始人——Pieter Abbeel、Peter Chen、Rocky Duan——以及其机器人基础模型 RFM-1，并组建 Amazon FAR（Frontier AI & Robotics）。FAR 在 2025–2026 年发布的工作（OmniRetarget、ResMimic、Holosoma）几乎都聚焦于一个问题：如何把人类动作数据高质量地转化为人形全身”移动+操作”能力——这是人形大脑中”小脑”层最核心的数据与训练工具链。

0. 速览卡片

维度	内容
机构	Amazon FAR（Frontier AI & Robotics）；亚马逊机器人（Amazon Robotics）
核心人物	Pieter Abbeel（UC Berkeley 教授，深度强化学习与机器人学习先驱）、Peter Chen、Rocky Duan（Covariant 联合创始人）；合作者包括 Guanya Shi（CMU）、C. Karen Liu（斯坦福）、Angjoo Kanazawa（Berkeley）、Carmelo Sferrazza 等
历史	Covariant（2017 年创立，仓储拣选 AI）→ RFM-1（2024.03）→ 亚马逊雇佣创始人并获得非独家模型授权（2024.08–09）→ Amazon FAR
代表工作	RFM-1（Covariant，2024）；OmniRetarget（2025.09/10）；ResMimic（arXiv 2510.05070）；Holosoma（2025.12，全栈 sim2real 代码库）；2026 年的后续工作
亚马逊其他相关	Vulcan（带触觉的仓储拣选机器人，2025）；DeepFleet（机器人车队调度基础模型，2025）；人形机器人送货测试等
开放程度	FAR 的研究以论文 + 开源代码形式发布（如 GitHub amazon-far/ResMimic、Holosoma）
本章三篇代表作	① RFM-1：Covariant 的多模态机器人基础模型 ② OmniRetarget：保留交互关系的动作重定向与数据生成 ③ ResMimic + Holosoma：从通用动作追踪到全身移动操作的残差学习与全栈工具链
身位	“人形小脑工具链”的重要贡献者；亚马逊作为超级用户的场景与数据优势巨大；尚未公开发布自有人形大脑产品

1. 故事的开端：从 OpenAI 到仓库

Pieter Abbeel 是深度强化学习的奠基人之一：他的学生 John Schulman 发明了 TRPO/PPO，Sergey Levine 曾在他的组做博士后，Chelsea Finn 也出自 Berkeley 体系。Peter Chen 与 Rocky Duan 都是 Abbeel 的学生，曾在 OpenAI 早期工作。2017 年，三人创办了 Covariant，目标是"让机器人在真实仓库里可靠地拣选任意物品"。

Covariant 的路线非常务实：它把 AI 部署在全球各地的仓储拣选站上，让机器人每天处理数以百万计的真实拣选——这些真实世界的成功与失败，构成了 Covariant 最宝贵的数据资产。到 2024 年，Covariant 宣称其系统已在多个国家的仓库中运行，积累了海量的真实操作数据。

2024 年 3 月，Covariant 发布了 RFM-1。半年后，亚马逊以"雇佣创始人 + 非独家授权模型"的方式完成了一次典型的"人才收购"（这种模式与微软-Inflection、谷歌-Character.AI 类似）。亚马逊发言人称，Covariant 的模型将用于驱动其履约网络中的部分机器人操作系统。

---

2. 代表作一：RFM-1（Covariant，2024.03）——"任意模态到任意模态"的机器人基础模型

> 发布：Covariant 官方博客与技术介绍（2024 年 3 月）。

2.1 设计思想

RFM-1（Robotics Foundation Model 1）是较早的"商用机器人基础模型"之一。据 Covariant 介绍，它是一个约 80 亿参数的 Transformer，在文本、图像、视频、机器人动作与各种传感器读数上联合训练，形成一个"任意到任意（any-to-any）"的多模态序列模型：

- 输入/输出可以是任意模态的组合：给图像 + 文本 → 输出动作；给图像 + 动作 → 输出预测的未来图像（视频预测）；给图像 → 输出文本描述……
- 语言交互：机器人可以接受文本或图像形式的指令、回答问题，并在不确定时主动请求进一步的指示（例如"我不确定该抓哪一个，请指出"）；
- 物理预测：模型可以生成"如果执行这个抓取动作，接下来会发生什么"的视频预测，用于判断动作结果——这是一种早期的"世界模型"能力。

2.2 数据优势

RFM-1 的核心竞争力在于其训练数据来自真实仓库中长期运行的拣选系统：大量真实物品、真实失败、真实的长尾情况（反光包装、变形袋子、缠绕物品）。这与学术界基于实验室遥操作数据的 VLA 形成鲜明对比。

2.3 意义与局限

意义：RFM-1 在 2024 年初就提出了"多模态 any-to-any + 视频预测 + 语言交互"的机器人基础模型构想，在概念上领先于同期多数工作。 局限：主要面向固定工作站的拣选（吸盘/夹爪），不涉及人形全身控制；技术细节公开有限；亚马逊收购后，Covariant 公司本身的后续发展受到质疑（有媒体报道了相关举报与"空壳公司"指控，未经证实）。

---

3. 代表作二：OmniRetarget（2025.09/10）——高质量重定向是人形 RL 的"地基"

> 论文：*OmniRetarget: Interaction-Preserving Data Generation for Humanoid Whole-Body Loco-Manipulation and Scene Interaction*（Amazon FAR 等，arXiv 2509.26633）；作者包括 Angjoo Kanazawa、Pieter Abbeel、Carmelo Sferrazza、C. Karen Liu、Rocky Duan、Guanya Shi 等。

3.1 被低估的问题：重定向的"伪影"

2025 年，"用人类动捕数据训练人形 RL 策略"已成为共识（见第 7、3、9 章）。但这里有一个经常被忽视的环节——运动重定向（retargeting）：人类和机器人的骨骼比例、关节结构、质量分布都不同，必须把人类动作"翻译"成机器人能执行的动作。

传统重定向常产生各种伪影：- 脚滑（foot skating）：脚在着地时滑动；- 穿地（ground penetration）：脚陷入地面；- 交互关系丢失：人搬箱子时手贴着箱子，重定向后机器人的手可能离箱子几厘米或穿进箱子；人坐在椅子上，重定向后机器人"悬空坐"。

Abbeel 在发布时一针见血地指出：对于接近可行的轨迹，控制策略的优化地形会好得多；带伪影的轨迹会让 RL 事倍功半。

3.2 方法：保留交互关系的重定向

OmniRetarget 的核心是一个交互网格（interaction mesh）：- 把人体关键点、物体、地形表面上的点共同构造成一个网格，显式建模人-物-环境之间的空间与接触关系；- 重定向被表述为一个优化问题：在满足机器人运动学约束（关节限位、无穿透、脚不滑）的前提下，最小化交互网格的形变（即尽量保持"手与箱子的相对关系""脚与台阶的相对关系"）；- 除了重定向单段动作，它还能通过改变物体位置、尺寸、地形高度等，从一段人类示范生成大量多样化的、物理一致的机器人训练轨迹——这就是"数据生成"的含义。

3.3 结果

- 用 OmniRetarget 生成的数据训练 RL 策略，只需极简的奖励设计（据报道仅约 5 项奖励与 4 项域随机化），就能学会复杂的全身移动操作与场景交互技能，例如搬运箱子、攀爬平台、在复杂地形上移动并与物体交互；
- 在宇树 G1 等人形上实现长时程、多接触的技能执行。

3.4 意义

OmniRetarget 揭示了一个工程真理：在"人类数据 → 人形技能"这条管线中，数据质量（重定向质量）往往比算法更重要。它把重定向从"预处理小步骤"提升为"核心数据生成技术"。

---

4. 代表作三：ResMimic + Holosoma（2025.10–12）——从通用动作追踪到精确全身移动操作

> 论文：*ResMimic: From General Motion Tracking to Humanoid Whole-body Loco-Manipulation via Residual Learning*（arXiv 2510.05070；代码 github.com/amazon-far/ResMimic）；Holosoma 全栈代码库（2025.12）。

4.1 问题：通用动作追踪器”不够准”

到 2025 年下半年，业界已有多个”通用动作追踪器”（General Motion Tracking，GMT）——一个策略可以追踪任意人类动作（如 NVIDIA SONIC、CMU/Berkeley 的多项工作）。但当任务涉及与物体的精确交互（搬起一个重箱子、把椅子推到桌下），通用追踪器往往”动作像、但做不成”：手的位置差几厘米，箱子就掉了；没有考虑物体重量，机器人就失去平衡。

4.2 方法：两阶段”预训练-后训练”残差学习

```
阶段一（预训练）：通用动作追踪策略 π _GMT
  · 在大规模人类动作数据上训练，只关心"像人一样动"
  · 不考虑物体
        |
        ▼
阶段二（后训练）：残差策略 π _res
  · 输入：机器人状态 + 物体状态（位置、姿态）+ 参考动作
  · 输出：对 π _GMT 动作的"修正量" Δ a
  · 最终动作：a = a_GMT + Δ a
  · 奖励：物体追踪（物体是否按参考轨迹移动）+ 接触奖励 + 课程学习
```

这一设计借鉴了 LLM 的”预训练-后训练”范式：通用追踪器提供”像人的全身运动先验”，残差策略只需学习”为完成具体物体交互所需的小幅修正”，大大降低了学习难度。

4.3 结果

在仿真与宇树 G1 真机上，ResMimic 完成了需要全身参与的移动操作任务（如搬运较重物体、用身体多部位接触物体），在任务成功率与动作精度上明显优于直接用通用追踪器或从零训练的基线。

4.4 Holosoma：全栈 sim2real 工具链

2025 年 12 月，Abbeel 宣布 Amazon FAR 开源 Holosoma——一个完整的人形 sim2real 代码库，覆盖： - 多种仿真后端； - 训练（RL 训练流程）； - 重定向（含 OmniRetarget 类方法）； - 真机推理部署； - 为人形设计，也可适配四足。

意义：Holosoma 把 FAR 的研究成果打包成可复用的基础设施，类似于 NVIDIA 的 Isaac Lab + SONIC、或 Hugging Face 的 LeRobot。这表明亚马逊在人形领域的策略是”先做好工具链与小脑能力，再考虑上层大脑”。

4.5 2026 年的延续

2026 年的后续工作（如 OmniXtreme 等引用并延续 OmniRetarget/ResMimic 的研究）显示，这条”高质量重定向 → 通用追踪 → 残差精修”的路线仍在向高动态、高泛化方向推进。

---

5. 亚马逊的更大棋局

FAR 的研究不能孤立来看。亚马逊在机器人上的完整布局包括：

层级	亚马逊的布局
场景与需求	全球最大的履约网络，上百万台机器人在运行
专用机器人	Kiva/Proteus（移动机器人）、Sparrow/Robin/Cardinal（拣选）、Vulcan（触觉拣选，2025）
车队智能	DeepFleet（机器人车队调度基础模型，2025）
人形探索	测试 Agility Digit；据报道建设人形机器人送货测试场
前沿研究	Amazon FAR（人形全身控制、数据生成、工具链）
基础模型	RFM-1 授权（Covariant）

分析：亚马逊的独特优势在于它同时是需求方、数据方与研发方。当人形机器人的大脑足够成熟时，亚马逊可以在自家仓库里进行全球最大规模的部署与数据采集。FAR 目前专注于”小脑”工具链，可能是为将来自研或采购人形打下”控制层”的基础。

---

6. 横向对比与身位

维度	Amazon FAR	NVIDIA（SONIC/GR00T）	CMU LeCAR（见第 19 章）	Figure S0
关注层级	小脑：重定向、追踪、残差移动操作	全栈：大脑 + 小脑 + 仿真	小脑：追踪、sim2real	小脑（自用）
开放	论文 + 代码（Holosoma）	开源	开源	闭源
数据观	高质量重定向即数据生成	动捕规模化	人类视频 + 动捕	1000+ 小时动捕

身位判断： - 在”人形全身移动操作的数据与训练工具链”上，Amazon FAR 是全球最有影响力的工业研究团队之一； - 尚未发布面向人形的”上层大脑”（VLA/世界模型），在大脑层的公开存在感弱于 NVIDIA、DeepMind； - 亚马逊作为全球最大机器人用户的潜在影响力，远大于 FAR 目前的公开成果。

---

7. 未来展望与风险

展望： 1. 从小脑到大脑：FAR 是否会发布面向仓储人形的 VLA/世界模型，是 2027 年值得关注的看点； 2. 仓储人形的规模化：一旦人形在仓库中证明经济性，亚马逊的采购与部署规模将重塑整个人形产业； 3. RFM 系列的演进：RFM-1 授权后，Covariant 技术在亚马逊内部的演进路径尚不透明。

风险： 1. “人才收购”模式的监管风险：相关交易结构受到反垄断关注； 2. 专用机器人 vs 人形：亚马逊已有极其成熟的专用机器人体系，人形的增量价值需要充分证明； 3. 人才流动：顶尖研究者在大公司与创业公司之间流动频繁。

---

8. 延伸阅读与核验来源

三篇代表作 - RFM-1：Covariant 官方发布（2024.03） - OmniRetarget：arXiv 2509.26633；Pieter Abbeel 发布说明；ResearchGate - ResMimic：arXiv 2510.05070；项目页；GitHub amazon-far/ResMimic

核验来源 - SiliconANGLE：亚马逊雇佣 Covariant 创始人 - The Batch（DeepLearning.AI）：亚马逊与 Covariant 合作 - Bloomberg：亚马逊将雇佣 Covariant 创始人 - OmniXtreme（arXiv 2602.23843）

> 核验说明：RFM-1"约 80 亿参数、any-to-any 多模态、视频预测、请求澄清"来自 Covariant 2024 年官方发布与媒体报道（参数量为 Covariant 自述）；交易为"雇佣创始人 + 非独家授权"、金额未披露；OmniRetarget 作者与"约 5 项奖励、4 项域随机化"来自论文相关介绍；Holosoma 来自 Abbeel 公开发布；关于 Covariant"空壳公司"的指控未经证实，本章仅作提及。

第 14 章 Hugging Face（LeRobot）：机器人领域的”Transformers 库”与开源民主化

> 一句话定位：Hugging Face 不追求”最强的机器人大脑”，而是追求”让每个人都能训练机器人大脑”。它的 LeRobot 项目（2024.05 起）为机器人学习提供了统一的数据格式、模型实现、训练与部署工具，以及低成本的开源硬件（SO-100/SO-101 机械臂、LeKiwi、HopeJR 人形、Reachy Mini）；它的 SmolVLA（2025.06）证明了一个 4.5 亿参数的小 VLA 在社区数据上也能达到大模型的性能；2026 年的 LeRobot v0.6 则把世界模型策略、奖励模型、NVIDIA GR00T N1.7 等前沿能力纳入开源工具链。它与 Dexmal（原力灵机）共同发起的 RoboChallenge，成为 2026 年最被引用的真机评测平台之一。它是人形大脑生态的”基础设施与公共品提供者”。

0. 速览卡片

维度	内容
机构	Hugging Face（纽约/巴黎），LeRobot 团队
关键人物	Rémi Cadène（LeRobot 创始负责人，前特斯拉 Optimus 团队）；Thomas Wolf（HF 联合创始人，力推开源机器人）；LeRobot 研究团队（SmolVLA 作者群）
收购	2025 年 4 月收购法国 Pollen Robotics（Reachy 系列人形机器人）
开源硬件	Koch v1.1、SO-100 / SO-101（与 The Robot Studio 合作的低成本机械臂）、LeKiwi（移动底盘）、HopeJR（低成本开源人形，2025 年发布）、Reachy Mini（桌面机器人，2025.07）、Reachy 2
软件	LeRobot 库（数据集格式 LeRobotDataset、策略实现、训练/评估/部署）；Hub 上数千个社区机器人数据集
模型	自研 SmolVLA（2025.06）；集成 ACT、Diffusion Policy、TDMPC、VQ-BeT、π0/π0-FAST/π0.5（PyTorch 移植）、GR00T N1.5 → N1.7、MolmoAct2、EO-1 等
评测	与原力灵机等共同推出 RoboChallenge（2025 年，真机评测平台，Table30 等榜单）
本章三篇代表作	① LeRobot：开源机器人学习库与数据标准（2024）② SmolVLA：社区数据训练的高效小 VLA（2025）③ LeRobot v0.6：世界模型策略、奖励模型与前沿模型整合（2026）
身位	开源机器人生态的中枢；不以模型能力竞争，以生态与标准取胜

1. 故事的开端：一位特斯拉 Optimus 工程师的”开源梦”

2024 年初，Rémi Cadène 从特斯拉 Optimus 团队加入 Hugging Face。他看到的问题是：机器人学习领域的碎片化极其严重——每个实验室有自己的数据格式、自己的训练代码、自己的硬件，一篇论文的方法很难在另一个实验室复现；而真正好用的开源机器人硬件动辄数万美元，学生与爱好者无法参与。

Hugging Face 在 NLP 领域用 Transformers 库解决过同样的问题：统一的模型接口 + 统一的 Hub + 开放的社区，让"下载一个模型、跑一行代码"成为现实。Cadène 和 Thomas Wolf 的目标，就是在机器人领域复刻这个成功。

2024 年 5 月，LeRobot 正式发布。

---

2. 代表作一：LeRobot（2024）——统一数据、模型与硬件

2.1 三层设计

（1）数据层：LeRobotDataset - 统一格式：表格化的状态/动作数据（Parquet）+ 视频压缩的图像流（MP4），既节省存储又便于流式加载； - 直接托管在 Hugging Face Hub 上，任何人都可以一行代码下载、可视化、训练； - 提供数据可视化工具，可在浏览器中逐帧查看示范。

到 2025–2026 年，Hub 上已有数千个社区上传的机器人数据集，主要来自 SO-100/SO-101 等低成本平台——这构成了一个去中心化、众包式的机器人数据生态。

（2）模型层：统一的策略实现 - 首批集成 ACT、Diffusion Policy、TDMPC、VQ-BeT 等经典模仿学习/强化学习方法； - 2025 年起集成 π0、π0-FAST（从 JAX 移植到 PyTorch）、自研 SmolVLA，后续加入 π0.5、GR00T N1.5/N1.7 等； - 统一的训练、评估、部署接口，让研究者可以在同一数据集上公平比较不同方法。

（3）硬件层：低成本开源机器人 - SO-100 / SO-101：与 The Robot Studio 合作设计的 6 自由度低成本机械臂，采用总线舵机，物料成本约百美元级，可 3D 打印，支持"主从臂"遥操作采集（继承 ALOHA 的 puppeteering 思想）； - LeKiwi：给 SO 臂加上全向移动底盘； - HopeJR：低成本开源人形（2025 年发布，宣称成本约数千美元）； - Reachy Mini：桌面级可编程机器人（2025 年 7 月，价格数百美元）； - 收购 Pollen Robotics 后获得 Reachy 2 人形平台。

2.2 意义

LeRobot 对行业最大的贡献是降低门槛：一名学生用几百美元的 SO-101、一台带 GPU 的电脑，就能采集数据、训练 ACT/π0/SmolVLA、部署到真机。这让全球成千上万的个人与小团队进入机器人学习领域，也为"社区数据训练基础模型"提供了数据来源。

---

3. 代表作二：SmolVLA（2025.06）——社区数据训练的高效小 VLA

> 论文：*SmolVLA: A Vision-Language-Action Model for Affordable and Efficient Robotics*（Hugging Face，arXiv 2506.01844）

3.1 要解决的问题

2025 年的主流 VLA 都很大：π0 约 33 亿参数、OpenVLA 70 亿、GR00T N1 22 亿。它们需要高端 GPU 训练与推理，且主要在机构自有的大规模数据上预训练。问题是： 1. 能否用一个足够小的模型，在消费级 GPU 甚至 CPU 上运行？ 2. 能否只用社区贡献的、杂乱的开源数据，训练出有竞争力的 VLA？

3.2 架构：剪裁过的 VLM + 流匹配动作专家

组件	设计
VLM 主干	SmolVLM2（约 5 亿参数级的小型 VLM）；只使用 LLM 的前一半层（约 16 层）的特征——借鉴 GR00T"取中间层"的发现，既提速又不损性能
视觉 token	每帧图像压缩到较少的 token（约 64 个），不做图像切块
动作专家	约 1 亿参数，流匹配生成动作块
注意力	动作专家中交错使用交叉注意力（关注 VLM 特征）与因果自注意力（动作 token 之间）
总规模	约 4.5 亿参数
训练	VLM 主干冻结，只训练动作专家

3.3 数据：481 个社区数据集

- 预训练数据来自 Hugging Face Hub 上约 481 个社区公开数据集（不同报道为 481 或 487 个），约 2.3 万条示范、约 1000 万帧，主要采集自 SO-100 机械臂；
- 社区数据的一个大问题是任务描述混乱（有的写"pick"，有的写"task1"，有的为空）。SmolVLA 用一个 VLM 自动重写/标准化任务描述；
- 相机视角命名也不统一（"top""front""cam_1"），同样做了标准化映射。

3.4 异步推理

SmolVLA 提出了一个实用的异步推理栈：把"机器人客户端"与"策略服务器"解耦——机器人在执行当前动作块的同时，服务器已经在根据最新观察计算下一个动作块。报道称这使任务完成时间缩短约 30%，或在固定时间内完成约 2 倍的任务。（这与 PI 的实时分块 RTC 解决的是同一类问题。）

3.5 结果

- 在仿真基准 LIBERO 与 Meta-World 上，SmolVLA 的表现与规模大得多的 π0（33 亿）、OpenVLA（70 亿）相当或更好；
- 在真实 SO-100/SO-101 任务上，有预训练时平均成功率约 78.3%，无预训练时约 51.7%——说明社区数据预训练确实有效；
- 可在消费级 GPU 上训练，甚至在 CPU 上推理。

3.6 意义

SmolVLA 是"小模型 + 社区数据"路线的代表。它证明了：VLA 的能力并不完全依赖规模；对于低成本机械臂上的桌面任务，一个精心设计的小模型配合多样的社区数据，足以达到实用水平。它也为边缘端部署（低功耗机器人、教育机器人）提供了现实选项。

---

4. 代表作三：LeRobot v0.6（2026.07）——世界模型策略、奖励模型与前沿模型整合

> 来源：LeRobot v0.6.0 发布说明（2026.07）；Hugging Face × NVIDIA 博客 *NVIDIA Isaac Teleop and GR00T 1.7 Open VLA Model Available in LeRobot*；v0.6.1（2026.08.03）。

4.1 v0.6 的新增内容

新能力	意义
世界模型策略（world-model policies）	把 2026 年最热的"世界模型 → 策略"路线纳入开源工具链
奖励模型 API	为真机强化学习（如 RECAP 类方法）、成功检测、数据筛选提供标准接口
仿真基准	统一的仿真评估
rollout CLI	标准化的部署与评估命令行
深度数据	支持 RGB-D 数据
HF Jobs 训练	在 Hugging Face 云端直接训练
新 VLA 模型	GR00T N1.7（替代 N1.5，且 N1.5 不再支持）、MolmoAct2（AI2）、EO-1、EVO1、Multitask DiT 等
NVIDIA Isaac Teleop	开源遥操作工具

4.2 与 NVIDIA 的合作

2026 年 7 月，NVIDIA 与 Hugging Face 宣布把 Isaac Teleop 与 GR00T 1.7（"面向通用人形机器人的最新开放、可商用 VLA 基础模型"）引入 LeRobot，并计划未来整合 Cosmos 3。这意味着：- 开源社区可以直接在 LeRobot 中使用 NVIDIA 最新的人形基础模型；- NVIDIA 借助 Hugging Face 的社区触达数十万开发者；- LeRobot 成为"开源人形大脑"的事实标准入口之一。

4.3 RoboChallenge：开源评测的"中立场"

2025 年，Hugging Face 与原力灵机（Dexmal，见第 45 章）等共同推出 RoboChallenge——一个真机评测平台：研究者提交模型，平台在标准化的真实机器人与任务上运行评测，公开排行榜（如 Table30 榜单）。2026 年 1 月千寻 Spirit v1.5 在其上超过 π0.5 登顶，引发广泛关注；后来也出现过榜单成绩因评测数据异常被撤销的争议（见第 41 章）。RoboChallenge 的意义在于：它把"机器人模型谁更强"从各家自说自话，变成了可以在同一真机环境中比较的问题——尽管其可信度仍在建设中。

---

5. 技术路线总结

Hugging Face 的"路线"不是一种模型架构，而是一种生态哲学：

```
低成本开源硬件（SO-101、HopeJR、Reachy）
        ↓ 让更多人采集数据
统一数据格式 + Hub（LeRobotDataset）
        ↓ 让数据可以汇聚
统一模型实现（ACT → π0 → SmolVLA → GR00T N1.7 → 世界模型策略）
```

```
        ↓ 让方法可以复现与比较
开放评测（RoboChallenge）
        ↓ 让能力可以被客观衡量
社区反馈 → 更多数据、更多模型
```

---

6. 横向对比与身位

维度	Hugging Face LeRobot	NVIDIA Isaac/GR00T	PI openpi	智元/宇树开源
定位	中立的开源生态中枢	平台 + 硬件销售	模型开源	本体公司的开源生态
数据	社区众包（数千数据集）	合成 + 合作伙伴	自有	自有大规模数据集
硬件	低成本开源	不做本体（参考设计）	不做	自有本体
模型	小模型 + 集成第三方	GR00T	π 系列	GO-1/UnifoLM

身位判断：Hugging Face 是全球开源机器人生态的”中枢节点”——它不必拥有最强模型，因为所有最强的开源模型最终都会出现在 LeRobot 里。这种”生态位”在 NLP 领域已被证明极具价值。

---

7. 未来展望与风险

展望： 1. 社区数据的规模效应：随着 SO-101 等低成本硬件的普及，社区数据可能达到数万小时级别，为”开源基础模型”提供燃料； 2. 开源人形：HopeJR、Reachy 2 等平台若成熟，可能让人形机器人研究像今天的桌面机械臂一样普及； 3. 评测标准化：RoboChallenge 若建立起足够的公信力，可能成为机器人领域的”LMSYS Arena”。

风险： 1. 数据质量：社区数据质量参差、本体单一（以低成本桌面臂为主），对人形全身控制的帮助有限； 2. 商业模式：开源生态的变现路径（云训练、硬件销售、企业服务）仍在探索； 3. 评测公信力：真机评测的标准化、防作弊机制仍需完善。

---

8. 延伸阅读与核验来源

三篇代表作 - LeRobot：GitHub huggingface/lerobot；LeRobot 发布索引 - SmolVLA：arXiv 2506.01844（Emergent Mind）；Pure AI 报道 - LeRobot v0.6：The AI Feed：LeRobot 0.6 闭合机器人学习闭环；Hugging Face 博客：Isaac Teleop 与 GR00T 1.7 进入 LeRobot

核验来源 - NVIDIA 博客：NVIDIA 与 Hugging Face 为 LeRobot 带来新模型与框架 - AIwire：NVIDIA 与 Hugging Face 为开源机器人社区带来新模型 - Wikipedia：Hugging Face

> 核验说明：SmolVLA 的架构（约 4.5 亿参数、约 1 亿动作专家、前约 16 层特征、冻结 VLM）、数据（481/487 个数据集、约 1000 万帧）与成功率（78.3% vs 51.7%）来自论文及多篇一致的二手解读，数据集数量各来源略有出入；LeRobot v0.6 内容来自发布说明的报道；HopeJR、Reachy Mini 价格为 2025 年发布时公开信息的概数。

第 15 章 丰田研究院（TRI）：扩散策略的发源地，与”大行为模型”的严谨科学

> 一句话定位：如果说 RT-2 定义了 VLA 的”语义继承”，那么 TRI 参与提出的 Diffusion Policy（扩散策略，2023）则定义了 VLA 的”动作生成”——此后几乎所有主流 VLA 的动作头（π0 的流匹配、GR00T 的 DiT、Atlas LBM、Helix……）都是扩散/流匹配家族的后代。TRI 随后提出”大行为模型（Large Behavior Model, LBM）”概念，并在 2025 年发表了行业中统计上最严谨的 VLA 评测研究（约 1700 小时数据、1800 次真机盲测 + 数万次仿真评估），回答了”多任务预训练到底有没有用”这个根本问题。2025 年，TRI 的 LBM 被 Boston Dynamics 搬上 Atlas；2026 年，前 TRI LBM 负责人 Russ Tedrake 带队分拆创办 Walden Robotics（3 亿美元种子轮），丰田则宣布从 2028 年起在工厂部署约 40 万台机器人。TRI 是”学术严谨性 + 汽车工业落地”结合的代表。

0. 速览卡片

维度	内容
机构	Toyota Research Institute（丰田研究院），2015 年成立，总部加州 Los Altos，另有剑桥（马萨诸塞）等研究点
关键人物	Gill Pratt（CEO）；Russ Tedrake（MIT 教授，曾任 TRI 机器人研究负责人、LBM 高级副总裁，2026 年分拆创办 Walden Robotics）；Ben Burchfiel、Siyuan Feng、Eric Cousineau 等；Cheng Chi（Diffusion Policy 一作，当时为哥伦比亚大学博士生，与 TRI 合作，后创办 Sunday）；宋舒然 Shuran Song（Diffusion Policy/UMI 通讯作者）
代表工作	Diffusion Policy（2023）；UMI（2024，与斯坦福/哥伦比亚合作）；LBM 研究：A Careful Examination of Large Behavior Models for Multitask Dexterous Manipulation（2025.07，arXiv 2507.05331）；Atlas LBM（与 Boston Dynamics，2025.08）；Punyo（柔性人形研究平台）
2026 动态	Walden Robotics（2026.07.15 走出隐身，约 3 亿美元种子轮、估值约 11 亿美元，丰田、NVIDIA、波音等投资，RaaS 模式，丰田为早期生产客户）；丰田计划从 2028 年起在自有及供应商工厂部署约 40 万台机器人（每年最高约 1 万亿日元，以”匠人”示范训练机器人）
本章三篇代表作	① Diffusion Policy（2023）② LBM 严谨评测研究（2025）③ 从 LBM 到工业：Atlas LBM、Walden 分拆与丰田 40 万台机器人计划（2025–2026）
身位	动作生成范式的奠基者之一；方法论与评测严谨性的标杆；产业化通过 BD、Walden 与丰田工厂实现

1. 故事的开端：一家汽车公司为什么要研究”机器人大脑”？

2015 年，丰田投资 10 亿美元成立 TRI，聘请 DARPA 机器人挑战赛的组织者 Gill Pratt 担任 CEO。最初的重点是自动驾驶与"老龄化社会的家用辅助机器人"——日本社会的人口结构，让丰田比任何车企都更早意识到"机器人照护"的必要性。

TRI 机器人团队的独特之处在于它的MIT 基因：Russ Tedrake（MIT 欠驱动机器人与 Drake 仿真器的作者）长期领导 TRI 的机器人研究，带来了严格的控制理论与"像物理学家一样做实验"的科学文化。这种文化在 2025 年的 LBM 研究中体现得淋漓尽致。

---

2. 代表作一：Diffusion Policy（2023）——把扩散模型变成机器人的"手"

> 论文：Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, Shuran Song, *Diffusion Policy: Visuomotor Policy Learning via Action Diffusion*（RSS 2023；IJRR 扩展版 2024）——哥伦比亚大学、TRI、MIT 合作。

2.1 要解决的问题：人类示范的"多模态"

假设人类示范"把 T 形块推到目标位置"：有时人从左边绕过去推，有时从右边绕过去。这两种方式都对，但它们的"平均"——从中间直接撞上去——是错的。

传统行为克隆用均方误差回归动作，学到的恰恰是这个"错误的平均"。这就是动作分布的多模态问题。此前的解决方案（高斯混合、离散化分类、隐式能量模型 IBC）要么表达能力有限，要么训练不稳定。

2.2 核心思想：把动作生成看成"去噪"

Diffusion Policy 把扩散模型（当时在图像生成中刚刚大获成功）用于动作：

- 训练：对示范中的动作序列逐步加噪声，训练网络 $\epsilon_\theta(O, A^k, k)$ 在给定观察 O 的条件下预测所加的噪声；
- 推理：从纯高斯噪声出发，以观察为条件，迭代 K 步去噪（训练用 DDPM 约 100 步，推理用 DDIM 约 10 步加速），得到动作序列。

扩散模型天然能表达任意复杂的多模态分布——它不会"平均"两种方式，而是在每次采样时"选择"其中一种。

2.3 三个关键工程设计

1. 动作序列预测 + 滚动时域控制（receding horizon）：
    - 观察时域 $T_o = 2$（用最近 2 帧观察）；
    - 预测时域 $T_p = 16$（一次预测未来 16 步动作）；
    - 执行时域 $T_a = 8$（执行前 8 步后重新规划）。 这与 ACT 的动作分块思想异曲同工：预测序列带来时间一致性，部分执行带来闭环反应能力。
2. 视觉条件化而非联合建模：观察只作为条件（通过 FiLM 注入），不参与去噪，因此视觉编码只需算一次，推理更快。
3. 两种网络骨干：
    - CNN 版：1D 时间卷积 U-Net + FiLM 条件化，稳定、调参少，是大多数任务的默认选择；

- Transformer 版：时间序列 Transformer，对高频、需要精确动作变化的任务更好，但更难调。 视觉编码器采用 ResNet-18（用空间 softmax 替代全局平均池化、用 GroupNorm 替代 BatchNorm），端到端训练。

另一个重要发现：位置控制（输出目标位姿）比速度控制更适合扩散策略——这与此前许多工作的经验相反。

2.4 结果

- 在 4 个基准（Robomimic、Push-T、Block Pushing、Franka Kitchen）的 12 个任务上，相比此前最好方法平均提升约 46.9%；
- 真机任务：Push-T、翻转杯子、倒酱汁并用勺子抹匀（涉及液体与可形变物体的连续操作）等，表现稳定。

2.5 影响：动作生成范式的奠基

后续工作	与 Diffusion Policy 的关系
Octo（2024）	扩散动作头 + Transformer 主干
UMI（2024）	用 Diffusion Policy 作为策略
π0（2024）	把扩散换成更简洁的流匹配，动作专家与 VLM 共享注意力
RDT-1B（2024，清华）	10 亿参数扩散 Transformer
GR00T N1（2025）	DiT + 流匹配
Atlas LBM（2025）	4.5 亿参数 DiT + 流匹配
Xiaomi-Robotics-0、WALL-OSS、GO-1……	都使用扩散/流匹配动作专家

可以说，2024–2026 年"VLM + 扩散/流匹配动作专家"的主流 VLA 架构，是 RT-2（上半身）与 Diffusion Policy（下半身）的结合。

---

3. 代表作二：大行为模型的严谨评测（2025.07）——"多任务预训练到底有没有用？"

> 论文：*A Careful Examination of Large Behavior Models for Multitask Dexterous Manipulation*（TRI LBM 团队，arXiv 2507.05331）

3.1 背景：TRI 的"大行为模型"愿景

2023 年 9 月，TRI 宣布用 Diffusion Policy 快速教会机器人 60 多种技能（倒液体、用工具、操作软物体），并提出目标：到 2024 年底达到 1000 种技能，进而训练"大行为模型（LBM）"——一个能执行数百种任务、并能快速学会新任务的通用模型。

但到了 2025 年，行业中充斥着各种 VLA 的"惊艳演示"，却很少有人认真回答：多任务预训练真的比单任务训练好吗？好多少？在统计上可信吗？

3.2 实验设计：像做临床试验一样评测机器人

这篇论文最值得学习的是它的方法论：

设计	内容
模型	扩展 Diffusion Policy 范式的多任务 DiT 策略（LBM），以多路相机图像、本体状态与语言为输入
数据	约 1700 小时示范数据（TRI 自有双臂遥操作数据 + 仿真数据 + 公开数据集）
平台	双臂操作平台，真实与仿真同时评测
评测规模	约 1800 次真实世界试验 + 数万次仿真试验
盲测	真机评测采用盲法 A/B 测试：评测者不知道当前运行的是哪个模型
指标	二元成功率 + 基于里程碑的任务完成度评分（衡量部分进展）
统计	使用严格的统计分析（置信区间、假设检验），明确报告结论的统计显著性

3.3 关键发现

1. 多任务预训练 + 微调 > 单任务训练：预训练过的 LBM 在微调后，成功率更高、对分布偏移（光照、位置、物体变化）更鲁棒；
2. 数据效率：二手解读称微调后的 LBM 达到同等表现所需的任务数据约为单任务模型的 1/3 到 1/5（论文原文的具体数字有待核实）；
3. 不微调的多任务模型并不总是更好：直接使用（不经任务微调）的多任务模型，并不能稳定超过单任务模型——这是一个对”通用模型开箱即用”叙事的重要冷水；
4. 评测的方差非常大：同一模型在不同评测批次、不同评测者下的结果差异显著，许多论文中”几个百分点的提升”在统计上可能并不显著。

3.4 意义

这篇论文对行业的贡献，与其说是一个模型，不如说是一种科学态度： - 它提醒整个行业，真机评测的统计噪声远大于大多数论文报告的提升幅度； - 它为”预训练-微调”范式提供了迄今最严谨的正面证据，同时诚实地揭示了”开箱即用”的局限； - 它推动了后续第三方评测平台（RoboArena、RoboChallenge）对”盲测”“大样本”“统计显著性”的重视。

---

4. 代表作三：从 LBM 到工业——Atlas、Walden 与丰田的 40 万台机器人（2025–2026）

4.1 Atlas LBM（2025.08）

TRI 与 Boston Dynamics 合作，把 LBM 搬到了全尺寸人形 Atlas 上：4.5 亿参数 DiT + 流匹配、30Hz、语言条件化、单一策略控制全身（详见第 9 章）。这是 LBM 第一次在双足人形上验证”手脚一体”的全身控制。

4.2 Walden Robotics（2026.07）

2026 年 7 月 15 日，Walden Robotics 走出隐身，宣布完成约 3 亿美元种子轮融资，估值约 11 亿美元： - 创始团队：Russ Tedrake（联合创始人兼 CEO，前 TRI LBM 高级副总裁，MIT 教授）及多位 TRI 核心成员（报道提及 Ben Burchfiel、Siyuan Feng、Adrien Gaidon 等）； - 投资方：丰田（丰田汽车、Toyota Invention

Partners、Toyota Ventures）、Deviation Capital 领投，NVIDIA、波音等参与； - 定位：全栈物理 AI 公司，打造”在真实工作中持续学习与改进”的通用机器人； - 商业模式：至少初期不直接销售硬件，采用机器人即服务（RaaS）；丰田既是股东也是早期生产客户； - 形态：报道说法不一——有的描述为”部分人形”的 AI 机器人系列，有的称其刻意不走标准人形路线（如不用腿）。

Walden 的出现意味着 TRI 的 LBM 技术栈正式走向商业化，“持续学习”的定位也与 PI 的 RECAP、Skild 的上下文学习等 2026 年热点一致。

4.3 丰田的 40 万台机器人计划（2026.09）

据日经亚洲等 2026 年 9 月报道： - 丰田估计从 2028 年起每年最多投入约 1 万亿日元（约 64 亿美元） 实现全球工厂自动化； - 在自有工厂与主要供应商工厂中逐步部署约 40 万台机器人（约 15 万台在丰田自有工厂，约 25 万台在集团公司及其他设施）； - 训练方式：由工人示范，而不是逐个动作编程——丰田全球约 60 家工厂中有约 1.8 万名被称为”匠（takumi）”的资深技工，他们将提供示范、评估与专业知识； - 中心化学习的技能数据将在全球工厂间共享，避免各地重复训练。

报道指出，该计划使用的机器人程序以 TRI 的扩散策略 LBM 框架为核心之一（此关联在部分报道中有提及，但并非所有来源都明确确认）。

分析：如果这一计划落地，丰田将成为全球最大规模的”示范学习”工业应用之一——它把 Diffusion Policy/LBM 从实验室带到了真正的大规模制造，并以”匠人示范”这一极具日本特色的方式解决数据来源问题。

---

5. 技术路线总结

阶段	时间	核心贡献
动作生成范式	2023	Diffusion Policy：多模态动作分布、动作序列、滚动时域
数据采集	2024	UMI（与斯坦福/哥大合作）：无本体、硬件无关数据采集
规模化与科学评测	2025	LBM 严谨评测：预训练-微调有效，但”开箱即用”有限；评测统计噪声极大
人形验证	2025	Atlas LBM：单策略全身控制
产业化	2026	Walden 分拆（RaaS、持续学习）；丰田 40 万台机器人计划

TRI 的路线有一个贯穿始终的主题：“做可验证的科学”。它不追求最大的模型或最炫的演示，而追求”这个结论在统计上站得住吗”。

---

6. 横向对比与身位

维度	TRI	PI	DeepMind
动作生成贡献	Diffusion Policy（奠基）	流匹配动作专家、FAST	动作 token 化（RT-2）

维度	TRI	PI	DeepMind
评测严谨性	最高（盲测、统计显著性）	高	高（安全评测系统）
VLM 语义	较弱（LBM 不以大 VLM 为核心）	强	最强
产业化	BD、Walden、丰田工厂	API/授权	平台授权

身位判断： - 学术影响力：Diffusion Policy 是近五年机器人学习领域被引用最多的论文之一，TRI 在动作生成范式上的贡献是奠基性的； - 模型前沿性：在"大 VLM + 大数据"的规模竞赛中，TRI 不是领先者； - 产业化路径：通过 BD（人形）、Walden（RaaS）、丰田（自有工厂）三条线落地，路径清晰、客户确定。

---

7. 未来展望与风险

展望： 1. 丰田工厂作为数据飞轮：40 万台机器人 + 1.8 万名匠人示范，可能形成全球最大的制造业示范学习数据集； 2. Walden 的持续学习：如果 Walden 实现"部署中持续改进"，将是 LBM 范式的重要升级； 3. 严谨评测的推广：TRI 的评测方法论可能成为行业标准。

风险： 1. 人才分流：核心团队分拆到 Walden，TRI 自身的研究连续性面临考验； 2. 语义能力短板：在需要复杂语言理解与推理的场景，LBM 需要与大 VLM（如 Gemini）结合； 3. 40 万台计划的不确定性：成本数字为估算而非承诺，部署将随工厂改造逐步推进，可靠性与标准化挑战巨大。

---

8. 延伸阅读与核验来源

三篇代表作 - Diffusion Policy：Chi et al., RSS 2023（arXiv 2303.04137）；IJRR 2024 扩展版 - LBM 评测：arXiv 2507.05331；数据集（Dryad） - 产业化：Boston Dynamics LBM 博客；AI Business：Walden 走出隐身；Boston Globe：Walden Robotics；Automotive World：丰田计划从 2028 年部署 40 万台工厂机器人；TechRepublic：丰田 40 万台机器人、64 亿美元现代化

其他 - The Robot Report：TRI 预训练 LBM 加速机器人学习 - TechTimes：丰田押注 40 万台机器人捕获匠人技能

> 核验说明：Diffusion Policy 的技术细节与 46.9% 平均提升来自原论文；LBM 研究的 1700 小时、约 1800 次真机试验来自论文摘要与数据集页面，"3–5 倍数据效率"为二手解读；Walden 的融资、估值、投资方与 RaaS 模式来自多家媒体（投资方表述略有差异）；丰田 40 万台计划来自日经亚洲等报道，"以 TRI LBM 为核心"的关联并非所有来源都确认。

第 16 章 Genesis AI：从”最快的物理引擎”到”仿真驱动的全栈机器人公司”

> 一句话定位：Genesis AI 以 2024 年 12 月开源的 Genesis 物理引擎一夜成名（GitHub 星标迅速破万，宣称比现有 GPU 仿真器快 10–80 倍），随后以 1.05 亿美元种子轮成立公司，押注一条与 Generalist、Sunday”真实数据派”截然相反的路线：以大规模、高保真物理仿真为主要数据来源训练机器人基础模型。2026 年 5 月，它发布首个模型 GENE-26.5（配套自研灵巧手与触觉数据手套），6 月发布首款通用机器人 Eno（轮式移动操作平台），并与 LG CNS 结成战略合作——从”仿真工具公司”变成了”仿真 + 模型 + 硬件”的全栈公司。

---

0. 速览卡片

维度	内容
成立	2024–2025 年，总部位于美国加州（帕洛阿尔托）与法国巴黎
联合创始人	周衔（Zhou Xian）（CEO，CMU 博士，Genesis 物理引擎项目发起人）；Théophile Gervet 等
融资	2025 年约 1.05 亿美元种子轮（Eclipse、Khosla Ventures 等），公司表示将继续融资
开源	Genesis 物理引擎（2024.12，与全球 20 余家实验室合作）
模型	GENE-26.5（2026.05.06，闭源权重；以发布年月命名，预期快速迭代）
硬件	Genesis Hand（与中国公司无疆科技 Wuji Tech 合作设计的灵巧手）、触觉数据手套；Eno（2026.06.16，轮式移动操作机器人 + 灵巧手）
商业	与 LG CNS 建立长期战略合作；Eno 计划 2026 年底开始生产与定向客户部署（先工业：制造、物流、实验室；再服务业：酒店、医院；最后家庭与户外）
本章三篇代表作	① Genesis 物理引擎（2024.12）② GENE-26.5：仿真 + 人类示范训练的灵巧操作基础模型（2026.05）③ Eno：全栈通用机器人（2026.06）
身位	“仿真派”在创业公司中的旗手；工具影响力大，模型与产品处于早期

---

1. 故事的开端：一个”生成式物理引擎”的野心

周衔在 CMU 攻读博士期间（导师 Katerina Fragkiadaki 等），研究方向集中在”机器人学习中的仿真与生成”。他和合作者们观察到：

1. 机器人数据稀缺的根本原因是真实世界数据采集太慢；

2. 现有物理仿真器（MuJoCo、Isaac Gym/Sim、PyBullet）各有局限：要么只擅长刚体，要么速度不够，要么难以表达布料、液体、软体等复杂物理；
3. 更关键的是，搭建一个仿真场景本身就需要大量人工——建模物体、设置物理参数、设计任务与奖励。

他们提出的愿景是一个"生成式物理引擎"：不仅要快、要支持多种物理，还要能用自然语言自动生成场景、任务与数据——让"造数据"本身被 AI 自动化。

2024 年 12 月，这个由 CMU 牵头、联合全球二十多家高校与研究机构历时约两年开发的项目以 Genesis 之名开源。

---

2. 代表作一：Genesis 物理引擎（2024.12）

> 开源项目：Genesis（GitHub Genesis-Embodied-AI/Genesis），2024 年 12 月发布。

2.1 设计目标与架构

特性	内容
通用多物理	在一个框架内统一刚体、MPM（物质点法，用于沙土、雪、塑性体）、SPH（光滑粒子流体动力学，液体）、FEM（有限元，软体）、PBD（基于位置的动力学，布料、绳索）等多种求解器，并支持它们之间的耦合
极速	纯 Python 前端 + 底层 GPU 并行（基于 Taichi 等技术），宣称在单张 RTX 4090 上仿真一个 Franka 机械臂场景可达约 4300 万 FPS（约为实时的 43 万倍），比现有 GPU 加速仿真器快 10–80 倍
可微分	部分求解器支持可微分仿真，可用于基于梯度的优化与系统辨识
照片级渲染	集成光线追踪渲染，缩小视觉 sim2real 鸿沟
生成式数据引擎（愿景）	用自然语言描述生成场景、物体、任务、奖励与轨迹（发布时部分功能仍在开发中）

2.2 争议：速度基准是否公平？

Genesis 发布后，社区中出现了对其速度宣称的质疑：有研究者指出，其基准测试在某些设置下（例如几乎没有碰撞的场景、关闭了部分功能、与其他仿真器的配置不对等）可能高估了相对优势；在接触密集的真实机器人任务中，速度优势会大幅缩小。Genesis 团队随后对基准进行了补充说明。这一争议提醒我们：仿真器的"速度"必须在具体的、接触丰富的任务上比较才有意义。

2.3 意义

无论速度争议如何，Genesis 的发布都极大地提升了"仿真作为机器人数据来源"的关注度，并为学术界提供了一个开源、多物理、易用的替代方案（与 NVIDIA Isaac、DeepMind MuJoCo/MJX、以及 NVIDIA-DeepMind-迪士尼合作的 Newton 形成竞争）。

---

3. 代表作二：GENE-26.5（2026.05.06）——仿真 + 人类示范训练的灵巧操作模型

> 发布：Genesis AI 官方发布与演示（2026-05-06）；TechCrunch、Technology.org、Humanoid.guide 等报道。

3.1 模型定位

GENE-26.5 是一个机器人操作基础模型，与以下两件硬件配套： - Genesis Hand：与中国灵巧手公司无疆科技（Wuji Tech）合作设计的类人灵巧手； - 触觉数据手套：用于采集带触觉信息的人类示范。

模型名称中的"26.5"即"2026 年 5 月"，周衔表示，得益于自研的仿真体系，预计会有很多快速的迭代版本。

3.2 训练数据：仿真为主，人类示范为辅

- 主要数据来源：物理仿真。Genesis 用自家引擎大规模生成灵巧操作数据——包括复杂接触、可形变物体、工具使用等；
- 辅助数据来源：人类示范，通过触觉数据手套采集，提供真实的手部运动与接触信息；
- "AI 训练 AI"的自进化循环：公司描述了一个在虚拟环境中由 AI 生成任务、训练策略、评估结果、再生成新任务的自进化训练循环，使工程师能以物理实验室无法企及的速度测试与迭代。

周衔特别强调：仿真的最大价值不只是生成训练数据，而是加速评估——他认为评估是机器人迭代的主要瓶颈（这一观点与 1X 用世界模型做评估、TRI 强调评测严谨性异曲同工）。

3.3 展示能力

演示视频中，由 GENE-26.5 驱动的灵巧手完成了一系列高难度操作（如精细的工具使用、物体重定向、双手协作等），公司称其达到"接近人类水平的操作"——但这一说法来自公司宣传，尚无独立基准评测。权重闭源。

3.4 与"真实数据派"的路线对比

维度	Genesis（仿真派）	Generalist / Sunday（真实人类数据派）	PI（真机遥操作派）
主数据来源	物理仿真	人类真实交互/手套	多本体机器人遥操作
数据成本	GPU 时间（边际成本低）	采集人力（中）	遥操作人力与设备（高）
优势	无限规模、可控、可做 RL、评估快	真实分布、真实物理	本体对齐、质量高
劣势	sim2real 鸿沟（尤其接触与可形变物体）	形态鸿沟	规模受限

2026 年的行业现实是：三种数据来源都在被使用，关键在于配比。NVIDIA 的"数据金字塔"、Genesis 的"仿真为主 + 示范为辅"、Generalist 的"人类数据为主 + 少量机器人数据对齐"代表了三种不同的配比哲学。

---

4. 代表作三：Eno（2026.06.16）——"全栈化"的通用机器人

> 发布：Genesis AI 官方发布（2026-06-16）；The Robot Report、Robotics & Automation News 报道；TechCrunch（2026-05-06）“Genesis AI 已经全栈化”。

4.1 产品形态

Eno 是一款轮式移动操作机器人，配备 Genesis Hand 灵巧手，由 GENE 基础模型驱动。选择轮式而非双足，与 Sunday Memo、Galbot G1、星海图、智平方等的选择一致——在当前阶段，轮式底盘在稳定性、续航、成本与安全上更务实。

4.2 市场路径

阶段	客户
第一阶段	工业：制造、物流、实验室
第二阶段	服务业：酒店、医院
第三阶段	家庭与户外

生产与定向客户部署计划于 2026 年底开始。同日宣布与 LG CNS 建立长期战略合作，为其打开韩国及全球的企业客户渠道。

4.3 为什么一家仿真公司要做硬件？

TechCrunch 的标题”Genesis AI 已经全栈化”点出了一个 2026 年的行业趋势：纯软件的机器人大脑公司面临”没有自有本体就无法闭环数据”的压力。Genesis 的逻辑是： 1. 仿真需要与真实硬件精确对齐（sim2real），自研硬件可以把仿真模型做到”像素级 + 物理级”的一致； 2. 灵巧手是操作能力的瓶颈，市面上缺少与其仿真/模型深度匹配的手； 3. 有了自有机器人，才能形成”仿真 → 部署 → 真实反馈 → 改进仿真”的闭环。

这与 Skild（不做硬件、依靠合作）、PI（不做硬件）、Generalist（不做硬件）形成了路线分野。

---

5. 技术路线总结

```
2024.12  Genesis 物理引擎开源 —— 工具与社区影响力
    ↓
2025     1.05 亿美元种子轮 —— 从开源项目到公司
    ↓
2026.05  GENE-26.5 + Genesis Hand + 触觉手套 —— 仿真为主的灵巧操作模型
    ↓
2026.06  Eno 通用机器人 + LG CNS 合作 —— 全栈化与商业化
```

Genesis 的核心押注：仿真的规模化与快速评估能力，最终会战胜真实数据的稀缺性。

---

6. 横向对比与身位

维度	Genesis AI	NVIDIA（Isaac + Cosmos）	Skild（仿真 + 人类视频）
仿真工具	自研开源 Genesis	Isaac Sim/Lab、Newton	主要用 NVIDIA 工具

维度	Genesis AI	NVIDIA（Isaac + Cosmos）	Skild（仿真 + 人类视频）
世界模型	未作为核心	Cosmos、DreamZero	未公开
硬件	自研灵巧手 + Eno	不做本体	不做本体
商业阶段	早期（2026 年底开始部署）	平台成熟	ARR 超 1 亿美元（自称）

身位判断： - Genesis 在开源仿真工具上有显著影响力； - 在机器人大脑能力上处于早期，GENE-26.5 缺乏独立评测； - 其"仿真为主"的路线在 2026 年"真实数据缩放定律"（Generalist）与"世界模型"（NVIDIA/1X）两股潮流的夹击下，需要用产品表现证明自己。

---

7. 未来展望与风险

展望： 1. 快速迭代：以年月命名的版本策略（GENE-26.5）暗示其计划以月为单位迭代模型——这是仿真驱动路线的潜在优势； 2. 灵巧手 + 仿真：灵巧操作是仿真最难但价值最大的领域，若 Genesis 在这一点上取得突破，将形成独特壁垒； 3. 与世界模型融合：物理仿真与视频世界模型的结合（物理引擎提供精确接触，世界模型提供视觉真实性）是可能的方向。

风险： 1. sim2real 鸿沟：灵巧操作中的摩擦、柔性、触觉等难以精确仿真，是仿真派的根本挑战； 2. 从工具到产品的跨越：硬件制造、供应链、客户交付对一家由研究者主导的创业公司是全新挑战； 3. 资源竞争：与 NVIDIA（仿真 + 世界模型 + 芯片）的正面竞争非常困难。

---

8. 延伸阅读与核验来源

- Genesis 物理引擎：GitHub Genesis-Embodied-AI/Genesis（2024.12）
- TechCrunch：Khosla 支持的 Genesis AI 已全栈化（2026-05-06）
- Technology.org：Genesis AI 发布可控制类人灵巧手的基础模型
- Humanoid.guide：GENE-26.5
- The Robot Report：Genesis AI 发布 Eno 通用机器人
- Robotics & Automation News：Eno 由 GENE 基础模型驱动

> 核验说明：Genesis 引擎的速度数字为发布时项目方宣称，社区对基准公平性有质疑；GENE-26.5 的数据构成（仿真为主 + 触觉手套人类示范）、与无疆科技合作设计灵巧手、闭源权重来自官方发布与多家媒体；Eno 的形态、市场路径与 LG CNS 合作来自官方发布；"接近人类水平操作"为公司宣传口径。

第 17 章 斯坦福大学：机器人大脑的”黄埔军校”

> 一句话定位：斯坦福是全球机器人学习领域人才与思想最密集的源头之一——Physical Intelligence 的联合创始人 Chelsea Finn、Sunday 的创始人 Tony Zhao 与 Cheng Chi、UMI/Diffusion Policy 的通讯作者宋舒然、BEHAVIOR 的主导者李飞飞与吴佳俊都在这里。它为行业贡献了第一个被广泛使用的开源 7B VLA（OpenVLA）、第一个”看人即学”的低成本人形全身影子系统（HumanPlus），以及家庭机器人领域规模最大的仿真基准与年度挑战赛（BEHAVIOR）。斯坦福的角色不是”做产品”，而是”定义问题、提供基线、输出人才”。

---

0. 速览卡片

维度	内容
核心实验室	IRIS（Chelsea Finn）、REAL（宋舒然 Shuran Song）、SVL（李飞飞、吴佳俊）、ILIAD（Dorsa Sadigh）、Wetzstein 计算成像组等
代表工作（全集）	ALOHA/ACT（2023）、Mobile ALOHA（2024）、VoxPoser（2023）、ReKep（2024）、OpenVLA（2024）、OpenVLA-OFT（2025）、DROID（2024，多机构）、UMI（2024，与哥大/TRI）、HumanPlus（2024）、BEHAVIOR-1K 与 BEHAVIOR Challenge（2024–2026）、斯坦福 AI Index
人才输出	Physical Intelligence（Chelsea Finn 等）、Sunday（Tony Zhao、Cheng Chi）、World Labs（李飞飞）、多家中国具身公司的创始人/核心成员
本章三篇代表作	① OpenVLA（2024）与 OpenVLA-OFT（2025）② HumanPlus：人形影子跟随与模仿（2024）③ BEHAVIOR：家庭机器人的”ImageNet 时刻”尝试（2024–2026）
身位	学术思想与人才的顶级源头；开源基线的主要提供者之一

---

1. 故事的开端：从 ImageNet 到 BEHAVIOR

2009 年，李飞飞团队发布了 ImageNet，十多年后深度学习革命由此点燃。斯坦福机器人学者们心中一直有一个问题：机器人领域的 ImageNet 在哪里？

答案不是一个，而是三条并行的探索： - 开源模型：让任何人都能下载、微调一个强大的机器人基础模型（→ OpenVLA）； - 低成本数据：让任何人都能用便宜的设备采集数据（→ ALOHA、UMI、HumanPlus）； - 标准化基准：让所有方法在同一套任务上比较（→ BEHAVIOR）。

---

2. 代表作一：OpenVLA（2024）与 OpenVLA-OFT（2025）——开源 VLA 的”第一块基石”

> 论文：Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, …, Percy Liang, Sergey Levine, Chelsea Finn 等，*OpenVLA: An Open-Source Vision-Language-Action Model*（CoRL 2024，arXiv 2406.09246）——斯坦福、Berkeley、TRI、Google DeepMind、PI 等合作；*Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success*（OpenVLA-OFT，2025）。

2.1 为什么需要 OpenVLA

2023 年的 RT-2 证明了 VLA 的威力，但它闭源、55B 参数、只能在 Google 的云 TPU 上运行。学术界无法复现、无法微调、无法研究。OpenVLA 的目标是：用公开数据、公开 VLM，训练一个可下载、可微调、能在单张消费级 GPU 上运行的 VLA。

2.2 架构



- 底座：Prismatic-7B VLM（斯坦福 Siddharth Karamcheti 等人的工作）——其研究发现"DINOv2 + SigLIP 双编码器融合"比单一 CLIP/SigLIP 在空间推理上更好；
- 动作表示：沿用 RT-2 的离散化——每个动作维度分成 256 个桶，用 Llama 词表中最少使用的 256 个 token 表示；
- 总参数：约 70 亿。

2.3 数据与训练

- 数据：从 Open X-Embodiment 中精选约 97 万条机器人示范（经过清洗与重新加权）；
- 训练：在 64 张 A100 上训练约 14 天；
- 视觉编码器在 VLA 训练中解冻微调（论文发现这对机器人任务很重要，与 VLM 训练的常规做法相反）。

2.4 结果

- 在 29 个任务、多种机器人上，OpenVLA 的绝对成功率比 55B 的 RT-2-X 高 16.5%，而参数量只有其约 1/8；
- 在新任务上用 LoRA 等参数高效方法微调，可在消费级 GPU 上完成，且显著优于从零训练的 Diffusion Policy（在多任务、语言条件化场景中）。

2.5 OpenVLA-OFT（2025）：从 5Hz 到约 130Hz

OpenVLA 的最大问题是慢——自回归逐 token 生成，约 5Hz。2025 年的 OFT（Optimized Fine-Tuning） 配方做了三项关键改动： 1. 并行解码：一次前向同时输出所有动作 token，不再逐个生成； 2. 动作分块：一次输出多步动作（借鉴 ACT）； 3. 连续动作 + L1 回归：用 MLP 动作头直接回归连续动作，替代离散 token。

结果：推理吞吐提升到约 130Hz 级别（相比自回归约 5Hz），在 LIBERO 仿真基准上平均成功率达到当时最高水平（约 97%），并在双臂 ALOHA 真机上完成灵巧任务。OFT 说明：VLA 的"慢"不是 VLM 主干的宿命，而是动作解码方式的问题。

2.6 意义

OpenVLA 是 2024–2025 年被使用最广泛的开源 VLA 之一：大量学术论文以它为基线或起点，大量中国公司的早期 VLA 实验也从它开始。它与 Octo（Berkeley）、π0（PI 开源）共同构成了开源 VLA 的"三大基线"。

---

3. 代表作二：HumanPlus（2024）——"人做什么，人形就学什么"

> 论文：Zipeng Fu, Qingqing Zhao, Qi Wu, Gordon Wetzstein, Chelsea Finn, *HumanPlus: Humanoid Shadowing and Imitation from Humans*（CoRL 2024）

3.1 要解决的问题

人形机器人的遥操作极其困难：需要动捕服、VR、外骨骼等昂贵设备，且操作员需要大量训练。能否只用一个普通 RGB 摄像头，让人形实时"影子跟随"操作员的全身动作，并以此采集数据？

3.2 两阶段系统

阶段一：影子跟随（Shadowing） - 在仿真中，用约 40 小时人类动作数据（AMASS）训练一个人形影子 Transformer（Humanoid Shadowing Transformer）——一个底层全身控制策略，输入目标人体姿态，输出人形关节指令； - 部署时，用一个 RGB 摄像头实时估计操作员的身体姿态与手部姿态（现成的人体/手部姿态估计模型），重定向后作为影子 Transformer 的目标； - 结果：操作员在摄像头前做什么，人形就实时做什么——走路、蹲下、拿东西、打拳。 - 硬件：宇树 H1 + 每臂一只因时（Inspire-Robots）RH56DFX 灵巧手，共 33 自由度（19 自由度身体 + 两只 6 自由度手 + 两个 1 自由度手腕）；头部装两个 RGB 网络摄像头构成双目视觉；据报道整机改装成本约 10.8 万美元。

阶段二：模仿（Imitation） - 用影子跟随采集任务示范（每个任务最多约 40 条——论文强调"40 条示范即可学会双目感知 + 高自由度控制"）； - 训练一个人形模仿 Transformer（Humanoid Imitation Transformer）：输入人形自身的双目第一视角图像与本体状态，输出目标姿态（再交给影子 Transformer 执行）； - 结果：人形可以自主完成穿鞋站起并行走、从仓库货架卸货、叠运动衫、整理物品、打字、与另一台机器人打招呼等任务，成功率在 60%–100% 之间。

3.3 意义

HumanPlus 在 2024 年就提出了今天行业的标准分层：“上层视觉模仿策略输出目标姿态 + 底层全身追踪控制器执行”——这与 Figure Helix 02（S1 + S0）、NVIDIA（GR00T + SONIC）、Amazon FAR（ResMimic）的架构同构。它也证明了低成本 RGB 摄像头即可完成人形全身遥操作采集。第一作者 Zipeng Fu（Mobile ALOHA 共同一作）后来继续在人形与移动操作领域深耕。

---

4. 代表作三：BEHAVIOR——家庭机器人的”ImageNet 时刻”尝试（2024–2026）

> 论文：Chengshu Li, Ruohan Zhang, …, Jiajun Wu, Li Fei-Fei 等，*BEHAVIOR-1K: A Human-Centered, Embodied AI Benchmark with 1,000 Everyday Activities and Realistic Simulation*（CoRL 2022 / 2024 扩展）；BEHAVIOR Challenge 2025（NeurIPS 2025）与 2026。

4.1 BEHAVIOR-1K：以人为中心定义任务

BEHAVIOR 的独特之处在于任务从哪里来：团队调查了大量美国普通人，询问”你最希望机器人帮你做的日常家务是什么”，据此选出 1000 种日常活动（如收拾餐桌、做烤面包、整理房间、洗碗），并用一种逻辑语言（BDDL）精确定义每个活动的初始状态与目标状态。

配套的仿真环境 OmniGibson（基于 NVIDIA Omniverse/Isaac Sim）支持： - 50 个完整的室内场景、上万个带物理与语义属性的物体； - 刚体、可形变物体（布料）、流体、温度变化（烹饪）、开关状态等复杂物理与状态； - 照片级渲染。

4.2 BEHAVIOR Challenge 2025：一次”冷水实验”

2025 年，斯坦福在 NeurIPS 2025 上举办了第一届 BEHAVIOR Challenge： - 50 个完整的家务任务（从做吐司到整理房间）； - 统一的仿真机器人平台（双臂移动操作机器人），以及约 1 万条遥操作专家示范（逾 1200 小时）作为训练数据； - 结果：获胜方案在 50 个任务上的 q-score（含部分进展）约 26%；而完整完成整个任务的成功率仅约 12.4%。参赛方案中有不少基于 openpi（π0/π0.5）微调。

斯坦福 2026 年 AI 指数报告也引用了类似的结论：人形机器人在家务任务上的失败率约为 88%。

4.3 BEHAVIOR Challenge 2026

第二届挑战赛提交截止于 2026 年 10 月 16 日，获胜者将于 2026 年 11 月 4 日公布（截至本报告撰写日 2026 年 10 月 30 日尚未公布结果）。

4.4 意义

BEHAVIOR 的价值在于它给行业泼了一盆必要的冷水：在各家公司纷纷发布”机器人做家务”演示视频的 2025–2026 年，一个标准化、长时程、完整任务成功率的评测显示，最先进的方法在真实复杂度的家务上，完整成功率仍只有约 12%。这与 Figure Helix 2.5 在 30 户真实家庭中约 56% 的结果（任务更少、更聚焦）共同勾勒出 2026 年家务机器人能力的真实区间。

---

5. 技术路线总结：斯坦福的三条线

线索	代表工作	对行业的贡献
模型	OpenVLA / OFT	开源 VLA 基线；证明"动作解码方式"决定速度
数据	ALOHA、Mobile ALOHA、UMI、HumanPlus、DROID	低成本、可规模化的数据采集范式
评测	BEHAVIOR-1K / Challenge、AI Index	以人为中心的任务定义；真实能力的"温度计"
推理	VoxPoser、ReKep（李飞飞组）	用 VLM/LLM 生成 3D 价值图与关键点约束，零样本操作

---

6. 横向对比与身位

学术机构	最突出贡献	与产业的连接
斯坦福	OpenVLA、ALOHA/ACT、UMI、HumanPlus、BEHAVIOR	PI、Sunday、World Labs
UC Berkeley	Octo、HIL-SERL、人形 RL、BridgeData	PI、Covariant/Amazon
CMU	人形全身控制（H2O/ASAP/BFM-Zero）、Skild 一脉	Skild、NVIDIA GEAR、OpenAI
UCSD	人形遥操作与人类数据（TeleVision、HAT）	多家人形公司
清华	RDT、VPP、Spirit 一脉	星动纪元、千寻、星海图

身位：斯坦福在"开源基线 + 低成本数据 + 标准化评测"三个维度上都处于全球学术界最前列，是机器人大脑领域最重要的思想源头之一。

---

7. 未来展望

1. BEHAVIOR 2026 结果：11 月公布的第二届结果将显示家务能力一年间的进步幅度；
2. 人才持续外溢：斯坦福培养的博士生仍将是全球具身创业公司的核心来源；
3. 学术与产业的分工：在算力与数据规模上，学术界已难以与 PI、DeepMind、Generalist 竞争，斯坦福的优势将更多体现在"问题定义、评测与新范式探索"上。

---

8. 延伸阅读与核验来源

三篇代表作 - OpenVLA：arXiv 2406.09246；PMLR 版本；OpenVLA-OFT（arXiv 2502.19645） - HumanPlus：Fu et al., CoRL 2024（arXiv 2406.10454） - BEHAVIOR：BEHAVIOR-1K（arXiv 2403.09227）；斯坦福 HAI：BEHAVIOR 挑战赛为家庭机器人指明方向；Openpi Comet：2025 BEHAVIOR 挑战赛方案（arXiv 2512.10071）

其他 - eWeek：人形机器人炒作遭遇 88% 家务失败率 - Emergent Mind：OpenVLA 主题汇总

> 核验说明：OpenVLA 的架构、97 万条数据、比 RT-2-X 高 16.5% 来自原论文；OFT 约 130Hz 与 LIBERO 约 97% 来自 OFT 论文及二手汇总（具体数字以论文为准）；HumanPlus 的 40 小时 AMASS、最多 40 条示范、33 自由度来自原论文；BEHAVIOR Challenge 2025 的 26% q-score 与 12.4% 完整成功率来自挑战赛官方与参赛方报告；“88% 失败率”为媒体对斯坦福 AI Index 2026 的转述。补充核验：HumanPlus 的硬件构成（19+6+6+1+1=33 自由度、Inspire RH56DFX、双目网络摄像头）、40 条示范、60%–100% 成功率来自论文，改装成本约 10.8 万美元来自媒体报道。

第 18 章 UC Berkeley（BAIR）：强化学习的故乡，与”开源通才策略”的起点

> 一句话定位：Berkeley 人工智能研究实验室（BAIR）是深度强化学习与机器人学习的发源地之一——Pieter Abbeel、Sergey Levine、Jitendra Malik、Ken Goldberg、Trevor Darrell、Angjoo Kanazawa 等人的实验室，培养了 OpenAI、PI、Covariant、Skild（Pathak 曾为 Malik 学生/合作者）等公司的大量核心成员。在人形机器人大脑领域，Berkeley 贡献了三类关键思想：开源通才策略（Octo）、真机强化学习的实用化（HIL-SERL）、以及以 Transformer 序列建模统一人形运动控制（Radosavovic & Malik 的人形 RL 系列）。

0. 速览卡片

维度	内容
核心实验室	RAIL（Sergey Levine）、Abbeel 组、Malik 组、Hybrid Robotics（Koushil Sreenath）、Kanazawa 组、AUTOLAB（Ken Goldberg）
代表工作（全集）	TRPO/PPO/SAC（RL 基础算法）、QT-Opt（与 Google）、BridgeData V2（2023）、Octo（2024）、CrossFormer（2024）、HIL-SERL（2024）、人形 RL 系列（2023–2024）、Berkeley Humanoid（2024）、VideoMimic（2025）、Pi 系列（Levine 参与）
人才输出	OpenAI（Schulman 等）、PI（Levine 联合创始人）、Covariant/Amazon FAR（Abbeel、Chen、Duan）、众多中国具身公司研究负责人
本章三篇代表作	① Octo：开源通才机器人策略（2024）② HIL-SERL：人在环路的高效真机强化学习（2024）③ 人形运动的 Transformer 化：真实世界人形 RL 与”人形运动即下一个 token 预测”（2023–2024）
身位	强化学习与开源通才策略的思想源头；对 PI 的方法论（RECAP）、人形 RL 范式有直接影响

1. 故事的开端：“能不能让机器人自己学？”

Berkeley 的机器人学习传统，从一开始就带着”让机器人自主学习”的执念：Abbeel 早年的直升机特技学徒学习、Levine 2015 年的端到端视觉运动策略（GPS）、2016–2018 年与 Google 合作的 QT-Opt 大规模抓取 RL……这些工作都在回答”如何减少人的干预、让机器人从经验中变强”。

2022 年后，当”大模型 + 模仿学习”成为主流时，Berkeley 一方面积极参与（BridgeData、Octo、OpenVLA、OXE），另一方面坚持追问：模仿学习的天花板在哪里？RL 如何在真机上真正可用？——这条思路最终在 PI 的 π*0.6/RECAP 中开花结果。

2. 代表作一：Octo（2024）——开源通才机器人策略

> 论文：Octo Model Team（Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, …, Sergey Levine 等），*Octo: An Open-Source Generalist Robot Policy*（RSS 2024，arXiv 2405.12213）——Berkeley、斯坦福、CMU 等合作。

2.1 要解决的问题

2023 年 OXE 数据集发布后，一个问题摆在面前：能否训练一个开源的、能适配不同机器人（不同相机、不同动作空间）的"通才策略"，作为大家微调的起点？ RT-1-X/RT-2-X 未完全开源，且输入输出格式固定。

2.2 设计：灵活的 Transformer + 扩散动作头

```
任务 token（语言指令 或 目标图像）
观察 token（多路相机图像 patch、本体状态）      ← 可按需增减输入模态
读出 token（readout tokens）                  ← 类似 BERT 的 [CLS]，聚合信息
        |
        ▼
Transformer 主干（分块注意力：观察只能看任务与过去，读出 token 可看所有）
        |
        ▼
读出 token 的嵌入 → 扩散动作头 → 动作块
```

关键设计： - 模块化输入输出：新机器人有新相机或新动作空间时，只需加新的 tokenizer / 动作头并微调，主干不变； - 扩散动作头：借鉴 Diffusion Policy，以读出 token 为条件生成连续动作块； - 规模小：Octo-Small 约 2700 万参数，Octo-Base 约 9300 万参数——刻意保持小，以便学术界在普通 GPU 上使用； - 数据：在 OXE 中约 80 万条轨迹（25 个数据集）上预训练。

2.3 结果与意义

- 开箱即用可控制多种机器人（WidowX、UR5、Franka 等）；
- 在新机器人、新观察/动作空间上仅需少量数据微调即可达到良好性能，优于从零训练；
- 意义：Octo 是第一个真正"可插拔"的开源通才策略，确立了"预训练通才 + 少量数据微调"的开源工作流。它与 OpenVLA 形成互补：Octo 小、快、灵活但语义弱；OpenVLA 大、语义强但慢。π0 后来把两者优点结合（大 VLM 语义 + 扩散/流匹配动作专家）。

后续的 CrossFormer（2024） 进一步把同一个 Transformer 扩展到操作、导航、四足、无人机等 20 多种本体，验证了"跨本体通才"的可行性。

---

3. 代表作二：HIL-SERL（2024）——让真机强化学习"真正可用"

> 论文：Jianlan Luo, Charles Xu, Jeffrey Wu, Sergey Levine，*Precise and Dexterous Robotic Manipulation via Human-in-the-Loop Reinforcement Learning*（HIL-SERL，2024；Science Robotics 2025）

3.1 要解决的问题

真机 RL 长期被认为"不实用"：需要数十万次试错、需要精心设计奖励、训练不稳定、会损坏机器人。但模仿学习也有天花板——它最多学到示范者的水平，而且在精密装配这类任务上，几十条示范往往只能达到 50%–70% 的成功率。

3.2 方法：三个关键组件

1. 少量示范 + 奖励分类器：先采集少量成功/失败样本，训练一个视觉二分类器作为奖励（"任务成功了吗？"）——不需要手工设计奖励函数；
2. 样本高效的离线到在线 RL：基于 RLPD（利用先验数据的强化学习）等高 UTD（更新/数据比）的离策略算法，把示范数据与在线经验混合训练；
3. 人在环路纠正（Human-in-the-Loop）：当机器人在训练中犯错时，人用遥操作设备（如 SpaceMouse）实时接管纠正，纠正数据被加入回放缓冲区——人的干预既保证了安全，又提供了高价值的"在失败处如何做对"的数据。

3.3 结果

在一系列精密、灵巧、动态任务上——仪表盘装配、正时皮带安装、主板 RAM 插装、IKEA 家具组装、双臂物体交接、"抽打"叠叠乐中的一块（Jenga whipping）、翻煎锅中的鸡蛋等——HIL-SERL 在约 1 到 2.5 小时的真机训练后达到接近 100% 的成功率，并且执行速度明显快于人类示范（周期时间缩短）。相比之下，同等数据量的模仿学习基线成功率明显更低。

3.4 意义：通往 RECAP 的桥梁

HIL-SERL 的"示范 + 自主经验 + 人工纠正"三元组，几乎就是一年后 PI π*0.6 中 RECAP 的数据配方（演示数据、自主 rollout、专家纠正）。区别在于：HIL-SERL 是"每个任务训练一个小策略"，RECAP 把这一思想推广到"大 VLA + 优势条件化"。Berkeley 的真机 RL 思想，就这样通过 Sergey Levine 进入了 PI 的大模型体系。

---

4. 代表作三：人形运动的 Transformer 化（2023–2024）

> 论文：Ilija Radosavovic, Tete Xiao, Bike Zhang, Trevor Darrell, Jitendra Malik, Koushil Sreenath，*Real-World Humanoid Locomotion with Reinforcement Learning*（Science Robotics, 2024）；Radosavovic et al., *Humanoid Locomotion as Next Token Prediction*（NeurIPS 2024）。

4.1 第一篇：用 Transformer 做 RL 运动控制

问题：传统 RL 运动策略用 MLP，只看当前状态（或短历史），难以适应不同地形、负载与扰动。

方法： - 策略是一个因果 Transformer，输入过去一段时间的本体感知与动作历史，输出下一步关节指令； - 在仿真中用大规模 RL（含大量地形、动力学随机化）训练，借助"教师-学生"框架：先训练能看到特权信息（地形、摩擦等）的教师，再蒸馏给只能看本体感知的 Transformer 学生； - 零样本 sim2real 部署到 Agility 的全尺寸人形 Digit 上。

结果：Digit 在旧金山的街道、草地、人行道、斜坡等多种真实户外地形上稳定行走，能抵抗推搡、负重、踩到障碍物等扰动——而且全部在没有真机微调的情况下完成。

洞察：Transformer 的"上下文"在这里扮演了隐式的系统辨识器：通过观察过去的状态-动作历史，策略在推理时"推断"出当前地形和自身动力学特性，并相应调整——这与 Skild 后来宣称的"上下文中适应新身体"（第 4 章）同源，也与 Pathak/Malik 的 RMA 一脉相承。

4.2 第二篇：人形运动即"下一个 token 预测"

问题：能否像训练 GPT 一样，用自回归下一个 token 预测在多源数据上训练人形运动模型？

方法： - 把传感器观察与动作都 token 化，用一个因果 Transformer 做下一个 token 预测； - 数据来源多样：神经网络策略的轨迹、基于模型的控制器的轨迹、人类动作捕捉数据、YouTube 视频中提取的人类运动； - 对于缺少某种模态的数据（例如人类视频没有机器人动作），把缺失模态用掩码 token 代替，模型仍可从中学习。

结果：仅用约 27 小时的行走数据训练的模型，就能零样本部署到真实 Digit 上在旧金山街头行走，且能泛化到训练中未见过的指令（如后退行走）；加入不完整数据（视频、动捕）能进一步提升表现。

4.3 意义

这两项工作把 LLM 的方法论（Transformer、上下文学习、下一个 token 预测、多源异构数据）系统地带进了人形底层运动控制，为 2025–2026 年"运动控制基础模型"（SONIC、Figure S0、Agility 全身控制模型、BFM-Zero）奠定了思想基础。

---

5. 其他重要工作

- BridgeData V2（2023）：WidowX 低成本平台上约 6 万条轨迹的多环境数据集，是 OXE 与 Octo/OpenVLA 的重要组成；
- Berkeley Humanoid（2024，Hybrid Robotics）：低成本、面向学习的中尺寸人形研究平台；
- VideoMimic（2025，Kanazawa、Malik 等）：从普通手机视频中重建人和场景，训练人形学会"坐椅子、爬楼梯"等与环境交互的情境化动作——"看视频学人形技能"的代表作之一；
- Levine 组的 VLA 与 RL 研究：大量参与 OpenVLA、π 系列、RL 微调 VLA 的研究。

---

6. 横向对比与身位

维度	Berkeley	斯坦福	CMU
核心特长	RL（算法与真机）、开源通才策略、人形运动 Transformer	开源 VLA、低成本数据、家庭基准	人形全身控制、sim2real
对 PI 的影响	Levine（RL、RECAP 思想）	Finn（模仿学习、数据）	—
对人形的影响	Digit 上的 RL 运动、VideoMimic	HumanPlus	H2O/ASAP/BFM-Zero

身位：Berkeley 是”让机器人从经验中学习”这一思想流派的大本营。在 2026 年”VLA + RL 后训练”成为热点的背景下，Berkeley 的思想影响力处于顶峰。

---

7. 未来展望

1. RL 规模化：从”每任务一个小策略”（HIL-SERL）到”大模型的车队级 RL”，Berkeley 的研究者将继续在学术界推进这一方向；
2. 视频到人形技能：VideoMimic 一类工作代表了”看互联网视频学人形技能”的学术前沿，与特斯拉、Figure 的人类视频路线相呼应；
3. 人才持续外流到产业：Berkeley 的学生与教授持续流向 PI、OpenAI、Amazon 等。

---

8. 延伸阅读与核验来源

- Octo：arXiv 2405.12213
- HIL-SERL：Luo et al., arXiv 2410.21845；Science Robotics 2025
- Radosavovic et al., *Real-World Humanoid Locomotion with Reinforcement Learning*，Science Robotics 2024（arXiv 2303.03381）
- Radosavovic et al., *Humanoid Locomotion as Next Token Prediction*，NeurIPS 2024（arXiv 2402.19469）
- CrossFormer（arXiv 2408.11812）；BridgeData V2（arXiv 2308.12952）；VideoMimic（arXiv 2505.03729）

> 核验说明：Octo 的规模（约 2700 万/9300 万参数）、约 80 万条 OXE 轨迹来自原论文；HIL-SERL 的任务列表、1–2.5 小时训练、接近 100% 成功率来自原论文；人形 RL 系列的方法与”约 27 小时数据”来自原论文；本章未引用 2026 年新论文的具体数据。

第 19 章 卡内基梅隆大学（CMU）：人形”小脑”的军火库

> 一句话定位：CMU 机器人研究所（RI）是全球历史最悠久、规模最大的机器人学术机构。在人形机器人大脑领域，CMU 最突出的贡献集中在”小脑”——人形全身控制：从 H2O/OmniH2O（2024，用一个普通摄像头实时遥控全尺寸人形）、ASAP（2025，用”差分动作模型”对齐仿真与真实物理，让人形做出 C 罗庆祝、空中转体等敏捷动作），到 BFM-Zero（2025–2026，ICLR 2026，可被提示的人形行为基础模型，真机零样本）。CMU 的另一条线——Deepak Pathak 与 Abhinav Gupta——则直接孵化了估值 140 亿美元的 Skild AI。Guanya Shi 的 LeCAR 实验室与 NVIDIA GEAR 的深度合作，使 CMU 成为人形控制算法的主要”供给方”之一。

---

0. 速览卡片

维度	内容
核心实验室	LeCAR Lab（Guanya Shi，学习与控制）、Pathak 组（具身智能、适应）、Gupta 组（大规模数据）、Changliu Liu 组（安全控制）、Kris Kitani 组（人体运动）、Jessica Hodgins（动画与动捕）、Katerina Fragkiadaki（Genesis 引擎相关）
代表工作（人形相关）	H2O（2024）/ OmniH2O（2024）、HOVER（2024，与 NVIDIA）、ASAP（RSS 2025）、BFM-Zero（ICLR 2026）、FALCON、HumanoidVerse；Pathak 组：Extreme Parkour、LEAP Hand、VRB；Gupta 组：大规模自监督
人才输出	Skild AI（Pathak、Gupta）、Genesis AI（周衔）、NVIDIA GEAR（大量合作与实习）、OpenAI（ASAP 一作 Tairan He 据报道已加入 OpenAI）
本章三篇代表作	① H2O / OmniH2O：从人到人形的实时全身遥操作（2024）② ASAP：对齐仿真与真实物理，学会敏捷全身技能（2025）③ BFM-Zero：可提示的人形行为基础模型（2025–2026）
身位	人形全身控制算法的全球核心供给者之一

---

1. 故事的开端：从 DARPA 挑战赛到”学习型小脑”

CMU 在人形与足式机器人上的传统可以追溯到 Marc Raibert 早年在 CMU 的跳跃机器人研究（后来他去了 MIT，再创办 Boston Dynamics）。2015 年 DARPA 机器人挑战赛中，CMU 的 CHIMP 机器人获得第三名。但真正让 CMU 在人形领域”重回中心”的，是 2023 年后 Guanya Shi（加州理工博士，Neural-Lander、Neural-Fly 作者）加入 CMU 创立 LeCAR 实验室，以及与 NVIDIA GEAR 实验室（Jim Fan、Yuke Zhu）的深度合作。

LeCAR 的研究主线非常清晰：如何让人形机器人像人一样灵活、稳健地运动，并能被人方便地”教”？

---

2. 代表作一：H2O 与 OmniH2O（2024）——一个摄像头遥控全尺寸人形

> 论文：Tairan He, Zhengyi Luo, Wenli Xiao, Chong Zhang, Kris Kitani, Changliu Liu, Guanya Shi，*Learning Human-to-Humanoid Real-Time Whole-Body Teleoperation*（H2O，IROS 2024）；*OmniH2O: Universal and Dexterous Human-to-Humanoid Whole-Body Teleoperation and Learning*（CoRL 2024）

2.1 问题

在 2024 年之前，全尺寸人形的全身遥操作需要动捕服、外骨骼等昂贵设备。能否只用一个 RGB 摄像头，让操作员的全身动作被人形实时复现？

2.2 H2O 的三步法

1. “仿真到数据”的动作清洗：人类动捕数据集（AMASS）中有大量人形物理上做不到的动作（例如超出关节限位、需要不可能的平衡）。H2O 先用一个特权模仿策略在仿真中尝试追踪每一段动作，剔除追踪失败的动作——得到一个”人形可行”的动作数据集；
2. 特权教师策略：在仿真中训练一个能看到完整动作参考与特权状态的追踪策略；
3. 可部署的学生策略：蒸馏到一个只使用”真实可获得”输入的学生策略——即从 RGB 摄像头估计出的人体关键点位置（稀疏输入）+ 本体感知。

部署时，操作员站在摄像头前，人体姿态估计器（如基于视觉的 3D 姿态估计）实时输出关键点，学生策略驱动宇树 H1 复现动作——走路、踢腿、拳击、挥手等。

2.3 OmniH2O：从遥操作到”自主学习”

OmniH2O 在 H2O 的基础上做了三项扩展： - 通用接口：同一个控制策略支持多种输入——VR 头显（追踪头与双手）、RGB 摄像头、甚至语言指令（通过动作生成模型把文字转成动作）、以及自主策略的输出； - 灵巧性：加上灵巧手，支持精细操作； - 从遥操作到自主：用 OmniH2O 遥操作采集的示范，训练自主策略（例如基于 GPT-4o 的高层规划 + 模仿学习策略），实现人形的自主全身操作；并发布了 OmniH2O-6 人形全身操作数据集。

2.4 意义

H2O/OmniH2O 确立了”动捕数据清洗 → 特权教师 → 稀疏输入学生”的人形全身追踪训练范式，并提出”通用控制接口”的思想：底层追踪控制器成为一个标准接口，上层可以是人、VR、语言模型或自主策略。这正是 2025–2026 年”三层大脑”中 S0 层的设计思想。

---

3. 代表作二：ASAP（RSS 2025）——对齐仿真与真实物理

> 论文：Tairan He, Jiawei Gao, Wenli Xiao, …, Changliu Liu, Jessica Hodgins, Linxi “Jim” Fan, Yuke Zhu, Guanya Shi 等，*ASAP: Aligning Simulation and Real-World Physics for Learning Agile Humanoid Whole-Body Skills*（RSS 2025，arXiv 2502.01143）——CMU 与 NVIDIA 合作。

3.1 问题：sim2real 的”保守困境”

让人形做敏捷动作（跳跃、转体、单腿平衡）时，sim2real 鸿沟会被放大。传统两种方法都有问题： - 系统辨识（SysID）：需要大量手工调参，且难以覆盖所有未建模的动力学； - 域随机化（DR）：为了在所有随机参数下都稳定，策略变得过于保守——牺牲了敏捷性。

3.2 方法：差分动作模型（Delta Action Model）

```
阶段一（预训练）：在仿真中训练动作追踪策略（基于重定向的人类动作，例如 C 罗、科比、勒布朗的标志性动作）
        |
        ▼
阶段二（真机采集）：部署到真实 G1，记录真实轨迹
        |
        ▼
阶段三（学习差分动作模型）：训练一个模型 Δa = f(s, a)，
        使得"仿真中执行 a + Δa"的结果 ≈ "真实中执行 a"的结果
        → 它学到的是"真实物理与仿真物理的差异"，以动作修正的形式表达
        |
        ▼
阶段四（在"修正后的仿真"中微调）：把冻结的差分动作模型嵌入仿真器，
        在这个"更像真实"的仿真中继续微调策略
        |
        ▼
部署：最终策略直接在真机上运行（不再需要差分模型）
```

3.3 结果

- 在 IsaacGym → IsaacSim、IsaacGym → Genesis、IsaacGym → 真实 G1 三种迁移设置中，ASAP 都显著降低了动作追踪误差，优于 SysID、DR 与差分动力学学习等基线；
- 真机上展示了空中 180 度转体跳、单腿平衡、模仿 C 罗”Siu”庆祝动作、科比后仰跳投姿态等高敏捷动作。

3.4 意义

ASAP 证明了”用少量真机数据学习’物理差异’，再回到仿真中训练”是突破 sim2real 保守困境的有效路径。它与 RAI 研究所的 Atlas RL、NVIDIA SONIC、宇树的敏捷运动展示一起，构成了 2025 年”人形敏捷运动爆发”的技术基础。

---

4. 代表作三：BFM-Zero（ICLR 2026）——可提示的人形行为基础模型

> 论文：Yitang Li, Zhengyi Luo, Tonghe Zhang, Cunxi Dai, Anssi Kanervisto, Andrea Tirinzoni, Haoyang Weng, Kris Kitani, Mateusz Guzek, Ahmed Touati, Alessandro Lazaric, Matteo Pirotta, Guanya Shi，*BFM-Zero: A Promptable Behavioral Foundation Model for Humanoid Control Using Unsupervised Reinforcement Learning*（arXiv 2511.04131，ICLR 2026）——CMU 与 Meta FAIR 合作。

4.1 问题：从”追踪器”到”行为基础模型”

H2O、ASAP、SONIC 等都是"动作追踪器"——给它一段参考动作，它就复现。但如果任务不是"模仿某个动作"，而是"走到那个点""用一条腿站着""最大化某个奖励"呢？每种任务都要重新训练吗？

BFM-Zero 的目标是：一个策略、一个共享潜空间，通过"提示"完成多种任务——无需重新训练。

4.2 方法：把 Meta Motivo 的 FB-CPR 搬上真机

- 理论基础：前向-后向（FB）表征 + Meta 的 FB-CPR 算法（见第 12 章）——学习一个共享潜空间，把动作、目标与奖励都嵌入同一空间；
- 预训练数据：无标签的人类动作数据（LAFAN1）+ 无奖励的仿真交互——这是一个无监督强化学习问题；
- sim2real 关键设计：奖励塑形、域随机化、依赖历史的非对称学习（让策略从历史中推断真实动力学）；
- 零样本提示：动作追踪、目标到达、奖励优化；
- 少样本适应：在潜空间中用交叉熵方法（CEM）等搜索，快速优化新行为（例如单腿站立）。

4.3 结果

在 IsaacLab 仿真与真实宇树 G1 上： - 零样本跟随跳舞、行走、格斗等动作； - 从大幅推搡与跌倒中恢复； - 通过提示完成目标姿态到达与奖励优化。

这是首批在真实人形上部署的"可提示行为基础模型"之一（此前 Meta Motivo 只在仿真中）。

4.4 意义

BFM-Zero 把人形小脑从"执行器"提升为"基础模型"：上层大脑不必只给"参考动作"，还可以给"目标"或"奖励"，小脑自己找到合适的全身行为。这为 VLA/世界模型与全身控制之间提供了一个更灵活、更抽象的接口。

---

5. Pathak / Gupta 一脉：Skild 的学术源头

CMU 的另一条重要线索是 Deepak Pathak 与 Abhinav Gupta（详见第 4 章）： - Extreme Parkour（2023）：四足机器人仅凭单目深度相机完成跳跃、攀爬、跨越间隙； - LEAP Hand（2023）：低成本、开源、拟人灵巧手； - VRB（2023）：从人类视频中学习"可供性（affordance）"——哪里可以抓、该怎么动； - 大规模自监督机器人学习（Gupta）。

这些工作共同构成了 Skild "全身体 + 适应 + 人类视频"路线的学术基础。

---

6. 横向对比与身位

人形小脑工作	机构	核心思想
H2O / OmniH2O	CMU	动作清洗 + 教师-学生 + 通用接口
HOVER	NVIDIA + CMU 等	多模式统一（掩码切换控制模式）
ASAP	CMU + NVIDIA	差分动作模型对齐 sim/real
BFM-Zero	CMU + Meta	可提示行为基础模型（FB 表征）
SONIC	NVIDIA	动作追踪规模化（42M 参数、700 小时）

人形小脑工作	机构	核心思想
OmniRetarget / ResMimic	Amazon FAR	保留交互的重定向 + 残差移动操作
Helix 02 S0	Figure	1000+ 小时动捕 + RL，1kHz
Agility WBC	Agility	<1M 参数，仿真 RL，商用

身位：CMU（特别是 LeCAR）是人形全身控制算法最高产、最有影响力的学术来源之一，其学生大量进入 NVIDIA、OpenAI、各类人形公司。

---

7. 未来展望

1. 小脑与大脑的接口标准化：BFM-Zero 式的"提示接口"可能成为 VLA 调用全身控制器的标准方式；
2. 全身移动操作：从"模仿动作"走向"与物体、环境的物理交互"（如 HDMI、ResMimic 一类工作）；
3. 人才流动：CMU 人形团队的核心成员持续流向产业（NVIDIA、OpenAI、创业公司），学术前沿与产业前沿高度重合。

---

8. 延伸阅读与核验来源

- H2O：arXiv 2403.04436；OmniH2O：arXiv 2406.08858
- ASAP：arXiv 2502.01143；CMU RI 项目页；RSS 2025
- BFM-Zero：arXiv 2511.04131；ICLR 2026；项目页
- HOVER：arXiv 2410.21229

> 核验说明：H2O/OmniH2O 方法细节来自原论文；ASAP 的作者、方法与迁移实验来自论文与 RSS 2025 收录信息（Tairan He 加入 OpenAI 为个人主页信息的转述）；BFM-Zero 的作者、方法与真机结果来自 arXiv 与 ICLR 2026 页面。

第 20 章 加州大学圣地亚哥分校（UCSD）：人形遥操作与”人类即机器人”数据的开拓者

> 一句话定位：UCSD 王小龙（Xiaolong Wang）教授的实验室，是人形机器人”数据采集接口”与”人类数据利用”方向最有影响力的学术团队之一。它的 Open-TeleVision（2024）用 Apple Vision Pro 实现了沉浸式、带主动视觉反馈的人形遥操作，成为全球大量人形公司遥操作系统的原型；ExBody/ExBody2（2024）让人形学会”富有表现力”的全身动作；Humanoid Policy ~ Human Policy（2025）则用 VR 设备采集的大规模人类第一视角数据（PH2D）直接训练人形策略，提出”人类就是另一种人形”的观点。UCSD 的工作把”如何低成本、大规模地为人形获取数据”这一行业核心问题，推进到了可落地的工程方案。

---

0. 速览卡片

维度	内容
核心实验室	王小龙（Xiaolong Wang）组；另有 Hao Su（SAPIEN、ManiSkill 仿真）、Michael Yip 等
代表工作	DexMV（2022）、AnyTeleop（2023）、ExBody（2024）/ ExBody2（2024–2025）、Open-TeleVision（CoRL 2024）、Mobile-TeleVision、Humanoid Policy ~ Human Policy（2025）；SAPIEN/ManiSkill（Hao Su 组）
合作者	与 MIT、CMU、华盛顿大学、NVIDIA、Apple 等广泛合作
本章三篇代表作	① ExBody / ExBody2：富有表现力的人形全身控制 ② Open-TeleVision：沉浸式主动视觉遥操作 ③ Humanoid Policy ~ Human Policy：人类第一视角数据训练人形策略
身位	人形数据采集与人类数据利用方向的学术引领者

---

1. 故事的开端：从”看人手学灵巧”到”看人学人形”

王小龙实验室的研究一直围绕一个问题：机器人如何从人类身上学习？ 早期的 DexMV（2022）从人类手部视频中学习灵巧手操作；AnyTeleop（2023）用普通摄像头追踪人手，实现对多种机械臂/灵巧手的通用遥操作。2024 年人形机器人爆发后，这条”从人学”的主线自然延伸到了人形。

---

2. 代表作一：ExBody 与 ExBody2（2024）——让人形”动得像人”

> 论文：Xuxin Cheng, Yandong Ji, Junming Chen, Ruihan Yang, Ge Yang, Xiaolong Wang，*Expressive Whole-Body Control for Humanoid Robots*（ExBody，RSS 2024）；Mazeyu Ji, Xuanbin Peng, …, Xiaolong Wang，*ExBody2: Advanced Expressive Humanoid Whole-Body Control*（2024–2025）

2.1 ExBody 的思路：上下分离的表达

问题：人类动作数据中，上半身动作千变万化（挥手、跳舞、拥抱），而下半身动作往往难以被机器人精确复现（人形的腿比例、重量、关节与人差异大）。如果要求机器人全身精确模仿，很容易摔倒。

方法： - 上半身：精确模仿人类动作参考（表达性）； - 下半身：不追求精确模仿，只跟随根部速度等运动指令（稳健性）； - 在仿真中用大规模 RL（基于 CMU 动捕等数据）训练，零样本迁移到宇树 H1。

结果：H1 能一边稳定行走，一边做出跳舞、挥手、拥抱、击掌等丰富的上半身动作。

2.2 ExBody2：更全面、更精确

ExBody2 的改进： - 数据筛选：根据机器人的物理能力自动筛选可行的动作数据（类似 H2O 的思路）； - 教师-学生：特权教师策略 + 可部署学生策略； - 解耦的关键点与速度追踪：在保持稳定的同时，追踪全身更多关键点； - 结果：在宇树 G1/H1 上实现更精确、更多样的全身动作模仿，包括更大幅度的下肢动作。

2.3 意义

ExBody 系列代表了 2024 年人形”表现力全身控制”的前沿，与 CMU H2O 并列为人形动作模仿的早期代表作。它提出的”上半身追表达、下半身保稳定”的分解，在早期工程实践中被广泛采用。

---

3. 代表作二：Open-TeleVision（CoRL 2024）——“戴上头显，就是机器人”

> 论文：Xuxin Cheng, Jialong Li, Shiqi Yang, Ge Yang, Xiaolong Wang，*Open-TeleVision: Teleoperation with Immersive Active Visual Feedback*（CoRL 2024）

3.1 问题：遥操作者”看不清”

传统遥操作中，操作员通过固定相机的二维画面观察场景——缺乏深度感，无法主动”转头看”。这导致精细操作极其困难，操作员疲劳，数据质量差。

3.2 方案：主动视觉 + 立体沉浸

- 机器人端：在人形头部装一个可主动转动的立体相机（2–3 自由度”脖子”）；
- 操作员端：佩戴 Apple Vision Pro（或 Meta Quest）头显：
  - 头显追踪操作员头部姿态 → 实时驱动机器人”脖子”转动，机器人”看向”操作员想看的地方；
  - 机器人立体相机的画面实时以立体形式传回头显 → 操作员获得真实深度感；
  - 头显追踪操作员双手与手指 → 重定向为机器人手臂与灵巧手动作；
- 整个系统开源，并支持远程跨地域遥操作（论文演示了从美国东海岸遥控西海岸的机器人）。

3.3 结果

用 Open-TeleVision 采集数据训练的模仿策略，在宇树 H1 与 Fourier GR-1 上完成了罐头分拣、插入、折叠毛巾、卸货等长时程精细任务。

3.4 影响：行业遥操作的”参考设计”

Open-TeleVision 之后，“VR 头显 + 主动立体视觉 + 手部追踪”成为人形遥操作采集的主流方案。2025 年起，大量中国人形公司（宇树、傅利叶、智元等）的遥操作系统，以及 NVIDIA 的 GR00T 遥操作工作流，都采用了类似设计；宇树等开源的遥操作代码也明确受其影响。

---

4. 代表作三：Humanoid Policy ~ Human Policy（2025）——人类就是另一种人形

> 论文：Ri-Zhao Qiu, Shiqi Yang, Xuxin Cheng, …, Xiaolong Wang 等，*Humanoid Policy ~ Human Policy*（arXiv 2503.13441，2025.03，2025.10 更新）——UCSD、CMU、华盛顿大学、MIT、Apple 合作；项目页 human-as-robot.github.io

4.1 核心观点

标题本身就是论点：“人形策略 ≈ 人类策略”。人形机器人的形态与人高度相似——两只手、一个头、第一视角——因此人类的第一视角操作数据，在适当的表示下，可以直接作为人形的训练数据。而采集人类数据比遥操作机器人便宜得多、快得多。

4.2 PH2D 数据集

PH2D（Physical Human-Humanoid Data）： - 用消费级 VR 设备（如 Apple Vision Pro、Meta Quest）采集——头显本身同时提供第一视角视频与手部、手指的 3D 姿态； - 规模：约 2.68 万条人类示范、约 302 万帧；对比之下，同期采集的人形机器人遥操作数据约 1552 条、约 66.8 万帧——人类数据规模约为机器人数据的 4.5 倍（帧数）、17 倍（示范条数）； - 任务导向：与机器人要做的任务（抓取、放置、倒水等）对齐。

4.3 HAT 模型：人-人形共享的状态-动作空间

Human Action Transformer（HAT）： - 设计一个人与人形共享的状态-动作空间：以头部为参考系的手腕位姿 + 手指关键点等，人类数据与机器人数据都映射到这一空间； - 输出在共享空间中的动作，再通过重定向转为具体人形（灵巧手 + 手臂）的关节指令； - 人类数据与较少的机器人数据共同训练（co-training）。

4.4 结果

- 加入人类数据后，策略在泛化性（新物体位置、新物体、新背景）与鲁棒性上显著提升；
- 数据采集效率大幅提高——同样时间内，人类采集的示范数量远多于机器人遥操作。

4.5 意义

这篇论文是 2025 年”人类第一视角数据 → 人形策略”路线最清晰、最可复现的学术代表作之一。它在时间上与 Figure 的 Project Go-Big（2025.09）、特斯拉的”人类视频学习”（2025）、NVIDIA 的 EgoScale、PKU/智在无界的 Being-H0 同期，共同推动了 2026 年”人类数据派”的崛起。它的价值在于用公开数据集与代码把这条路线变成了任何人都能验证的方法。

---

5. 技术路线总结：UCSD 的”人-机器人”数据管线

```
人类全身动作（动捕）  ──► ExBody / ExBody 2 ──►  人形表现力全身控制（小脑）
人类头/手动作（VR）   ──► Open- TeleVision ──►  高质量人形遥操作数据
人类第一视角操作（VR）  ──► PH2D + HAT      ──►  人类数据直接训练人形策略（大脑）
```

三项工作构成了一条完整的"从人类到人形"的数据管线：从"让人形动起来"，到"让人方便地遥控人形"，再到"连遥控都不用、直接用人类数据"。

---

6. 横向对比与身位

"人类数据"路线代表	机构	数据采集方式	公开程度
Humanoid Policy ~ Human Policy	UCSD 等	消费级 VR 头显	开源数据与代码
Being-H0（第 47 章）	北大/智在无界	大规模人手视频	开源
EgoScale（GR00T N1.7）	NVIDIA	大规模人类第一视角	部分开放
Project Go-Big / Index	Figure	家庭第一视角视频	闭源
ACT-1	Sunday	技能采集手套	闭源
GEN 系列	Generalist	人类真实交互设备	闭源
AWE	它石智航	百万小时人类数据	部分开源（WIYH）

身位：UCSD 在"人形遥操作接口"与"人类数据训练人形"两个方向上处于学术引领地位，其开源系统被产业界广泛采用。

---

7. 未来展望

1. 消费级 VR/AR 设备作为数据入口：随着 Apple Vision Pro、Meta 智能眼镜等设备普及，人类第一视角数据的采集可能实现"无感化、规模化"；
2. 形态鸿沟的系统性研究：人手与机器人手、人眼与机器人相机之间的差异，需要更系统的对齐方法；
3. 从操作到全身：把人类数据从"手与上半身操作"扩展到"全身移动操作"。

---

8. 延伸阅读与核验来源

- ExBody：Cheng et al., RSS 2024（arXiv 2402.16796）；ExBody2（arXiv 2412.13196）
- Open-TeleVision：Cheng et al., CoRL 2024（arXiv 2407.01512）
- Humanoid Policy ~ Human Policy：arXiv 2503.13441；项目页
- AnyTeleop（arXiv 2307.04577）；DexMV（arXiv 2108.05877）

> 核验说明：PH2D 的规模（约 2.68 万条示范、约 302 万帧，对比机器人约 1552 条、66.8 万帧）与作者机构来自 arXiv 论文；Open-TeleVision 的系统设计与 ExBody 的上下分离思想来自原论文；"大量中国人形公司遥操作系统受其影响"为行业观察。

第 21 章 清华大学：中国具身智能的”母港”——从 RDT 到 RDT2，与一支创业”清华帮”

> 一句话定位：清华是中国具身智能最重要的学术源头与人才母港。朱军教授团队（TSAIL）的 RDT-1B（2024.10，ICLR 2025） 是当时全球最大的开源扩散式双臂操作基础模型；与生数科技合作的 Vidar（2025.07） 是”视频扩散模型作为机器人基座”路线的早期代表；RDT2（2026.02） 用超过 1 万小时的 UMI 式数据探索”零样本跨本体泛化”的极限。与此同时，清华交叉信息研究院（姚班体系）的年轻教授们创办或参与创办了星动纪元（陈建宇）、星海图（赵行、许华哲）、千寻智能（高阳）等一批头部具身公司——形成了中国具身智能独特的”清华帮”现象。

---

0. 速览卡片

维度	内容
核心团队	计算机系朱军团队（TSAIL，RDT 系列，与生数科技关联）；交叉信息研究院（IIIS）陈建宇、赵行、许华哲、高阳等；自动化系、精仪系等多个具身团队
代表工作	RDT-1B（2024.10）、Vidar（2025.07，与生数科技）、AnyPos、RDT2（2026.02）；IIIS：VPP、UP-VLA（星动纪元一脉）、Data Scaling Laws in Imitation Learning（高阳组）、Galaxea 相关工作（赵行、许华哲）
产业关联	生数科技（Vidu 视频模型）；星动纪元（第 38 章）、星海图（第 39 章）、千寻智能（第 41 章）
本章三篇代表作	① RDT-1B：十亿参数扩散式双臂操作基础模型 ② Vidar：具身视频扩散模型 + 掩码逆动力学 ③ RDT2：UMI 数据缩放与零样本跨本体泛化
身位	中国具身学术与人才第一源头；RDT 系列是中国最早具全球影响力的开源机器人基础模型之一

---

1. 故事的开端：扩散模型专家进入机器人

朱军教授是国内概率机器学习与扩散模型领域的权威——他的团队提出了 DPM-Solver（扩散模型快速采样器，被 Stable Diffusion 等广泛采用）、U-ViT（扩散 Transformer 的早期架构之一），并孵化了视频生成公司生数科技（Vidu）。

2024 年，当 Diffusion Policy 与 Octo 证明了”扩散模型生成动作”的威力后，朱军团队判断：机器人动作生成本质上是一个高维、多模态的生成问题，正是扩散模型的主场。他们要做的，是把”扩散 Transformer 的规模化经验”带到机器人领域。

---

2. 代表作一：RDT-1B（2024.10，ICLR 2025）——十亿参数的双臂扩散基础模型

> 论文：Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, Jun Zhu，*RDT-1B: a Diffusion Foundation Model for Bimanual Manipulation*（arXiv 2410.07864，ICLR 2025）；项目页 rdt-robotics.github.io

2.1 要解决的问题

双臂操作（倒水、交接、折叠）的难点是：动作空间维度高、动作分布高度多模态、而双臂数据极其稀缺。单一实验室的双臂数据往往只有几千条，训练不出通用模型；而大规模的 OXE 数据又大多是单臂、动作空间五花八门。

2.2 两个核心设计

（1）物理可解释的统一动作空间（Physically Interpretable Unified Action Space）

不同机器人的动作格式各异：有的输出关节角，有的输出末端位姿；有的是单臂 7 维，有的是双臂 14 维；有的还带移动底盘。RDT 设计了一个 128 维的统一空间： - 每个维度都有明确的物理含义（例如"右臂关节 1 位置""左臂末端 x 坐标""底盘线速度"）； - 每个机器人只填充它拥有的那些维度，其余用掩码标记； - 这样，不同机器人上"同一物理量"的数据会被映射到同一维度，模型可以跨本体共享物理知识（区别于 π0 的"零填充到 18 维"——π0 的维度不保证物理对应）。

（2）为机器人改造的扩散 Transformer（RDT）

组件	设计
视觉编码器	SigLIP（冻结），多路相机图像
语言编码器	T5-XXL（冻结）
主干	扩散 Transformer，约 12 亿参数
条件注入	交替交叉注意力：奇偶层分别注意图像 token 与语言 token，避免某一模态（图像 token 远多于语言 token）淹没另一模态
归一化	引入 QKNorm 与 RMSNorm，应对机器人物理量数值范围大、易导致训练不稳定的问题
输出	用非线性 MLP 解码器替代线性头，更好地拟合非线性的机器人动力学；一次生成多步动作块

2.3 数据与训练

- 预训练：在当时规模最大的多机器人数据集合上预训练（论文报告约 46 个数据集、超过 100 万条轨迹，包括 OXE、DROID 等）；
- 微调：团队自采了 6000+ 条双臂示范（在松灵 Cobot Magic / ALOHA 式双臂平台上），覆盖 300 多种任务，是当时最大的双臂数据集之一。

2.4 结果

- 零样本泛化：对未见过的物体、场景具有泛化能力；
- 指令跟随：能理解并区分细粒度指令（例如"倒三分之一杯水"vs"倒满"）；
- 少样本学习：只需 1–5 条示范就能学会新技能（例如折叠短裤、遥控机器狗的手柄操作）；

- 在灵巧双臂任务上显著优于 OpenVLA、Octo、ACT 等基线。

2.5 意义

RDT-1B 是中国团队较早发布、在国际上被广泛使用的开源机器人基础模型之一（开源代码与权重），也是”扩散 Transformer 规模化”在机器人领域的标志性工作。它提出的”物理可解释统一动作空间”被许多后续跨本体模型借鉴。

---

3. 代表作二：Vidar（2025.07）——视频扩散模型作为机器人基座

> 论文：*Vidar: Embodied Video Diffusion Model for Generalist (Bimanual) Manipulation*（清华大学 × 生数科技，arXiv 2507.12898，2025.07 首发，2025.09/12 修订）

3.1 思路：先”想象”，再”反推”

Vidar 是”世界模型（视频生成）→ 动作”路线在中国的早期代表作，与 1X 的 1XWM、NVIDIA 的 DreamGen 思路相通：



3.2 两个关键设计

1. 统一观察空间：把机器人、相机、任务与场景上下文统一编码为条件，使视频模型能在多平台的大规模具身视频上联合预训练——论文使用了来自 3 个真实机器人平台的约 75 万条多视角轨迹进行具身领域的继续预训练；
2. 掩码逆动力学模型（MIDM）：传统 IDM 容易被背景中无关的变化干扰（例如光线、其他物体移动）。MIDM 自动学习一个只关注机器人手臂区域的掩码，从而在新背景、新场景中更鲁棒地提取动作——不需要人工标注掩码。

3.3 结果

论文报告： - 在一个未见过的机器人上，仅用约 20 分钟人类示范（约为常规数据量的 1%）进行适配，Vidar 即优于当时的最优基线，并能泛化到未见过的任务、背景与相机布局； - 在 RoboTwin 基准的困难多任务设置下取得最优表现； - 测试时扩展（test-time scaling）：推理时生成多个候选未来视频，再从中挑选最合适的一个——把 LLM 领域"多采样再选择"的思想用到了视频策略上。

（作者包括 Yao Feng、Hengkai Tan 等；生数科技为合作方。检索中未能确认论文是否明确以 Vidu 为基础模型，本章不作断言。）

3.4 意义

Vidar 让"视频大模型公司（生数）+ 机器人学术团队（清华）"的组合成为现实，是 2025–2026 年中国"世界模型派"（极佳 GigaWorld、蚂蚁 LingBot-World、智元 Genie Envisioner、自变量 WALL-B）兴起的重要先声之一。

---

4. 代表作三：RDT2（2026.02）——UMI 数据的缩放极限与零样本跨本体

> 论文：Songming Liu, …, Jun Zhu 等，*RDT2: Exploring the Scaling Limit of UMI Data Towards Zero-Shot Cross-Embodiment Generalization*（arXiv 2602.03310，2026-02-03）；项目页 rdt-robotics.github.io/rdt2

4.1 问题：能否"零样本"换一台机器人？

RDT-1B 实现了"少样本"学习新技能，但换到一台全新的机器人上，仍需要在该机器人上采集数据微调。RDT2 追问：如果训练数据本身就与机器人无关（UMI 式手持采集），能否训练出一个在新机器人上零样本工作的模型？

4.2 数据：超过 1 万小时的增强版 UMI 数据

- 团队使用增强版 UMI（手持夹爪采集装置，见第 11 章）采集了超过 10,000 小时的演示数据；
- 据综述，这些数据来自 100 多个家庭环境——这与 π0.5"约 100 个家庭"的环境多样性量级相当，但采集方式不需要机器人；
- 这是 2026 年初公开报道中规模最大的 UMI 式数据之一。

4.3 模型：7B VLM + RVQ + 流匹配 + 蒸馏

组件	设计
主干	约 70 亿参数的视觉语言模型
动作表示	残差向量量化（RVQ）：把连续动作压缩为离散 token，便于 VLM 以语言建模方式学习（思路类似 FAST，但用学习式量化）
动作生成	流匹配：生成连续、精确的动作
实时化	蒸馏：把多步生成蒸馏为少步，满足实时推理

这一”离散 token 预训练 + 流匹配连续生成 + 蒸馏加速”的组合，与 PI 的 π0.5/KI 思想同源，可以看作中国团队对”VLA 训练配方”的独立实现与扩展。

4.4 结果

RDT2 被描述为最早同时对未见过的物体、场景、指令乃至机器人平台实现零样本泛化的模型之一：在训练中从未见过的机器人上，只需与 UMI 相同的腕部相机配置，即可直接执行开放词汇的操作任务。

4.5 意义

RDT2 是”无本体数据 + 大 VLM”路线的重要学术证据，与 Generalist（人类交互数据缩放）、Sunday（手套）、它石（人类数据）共同构成 2026 年”人类/手持数据派”的主张。它的开源属性使这条路线可以被学术界验证。

---

5. “清华帮”：从实验室到创业公司

清华交叉信息研究院（IIIS）的一批年轻教授，在 2023–2024 年集中创业，成为中国具身智能创业潮的核心力量：

教授	公司	代表工作	本报告章节
陈建宇	星动纪元	VPP（视频预测策略）、UP-VLA、HiRT、ERA-42	第 38 章
赵行、许华哲	星海图（联合创始人，CEO 高继扬）	G0 双系统 VLA、Galaxea 开放世界数据集	第 39 章
高阳	千寻智能（联合创始人、首席科学家）	Data Scaling Laws in Imitation Learning、Spirit v1.5	第 41 章

此外，清华自动化系、精仪系、电子系等也有大量具身智能团队，与北京人形机器人创新中心、北京智源研究院等机构紧密合作。

---

6. 横向对比与身位

维度	清华（RDT 系列）	斯坦福（OpenVLA）	Berkeley（Octo）
首个代表模型	RDT-1B（12 亿，扩散 DiT）	OpenVLA（70 亿，离散 token）	Octo（9300 万，扩散头）
动作空间	128 维物理可解释统一空间	7 维离散	模块化动作头
后续演进	RDT2（7B + RVQ + 流匹配 + UMI 1 万小时）	OFT（并行解码 + 连续动作）	CrossFormer（跨 20+ 本体）
产业孵化	生数（视频）、IIIS 系创业公司	PI、Sunday	PI、Covariant

身位：清华在中国具身学术界处于绝对领先地位，在全球范围内与斯坦福、Berkeley、CMU 处于同一梯队；其”学术 + 创业”的转化效率在全球高校中极为突出。

---

7. 未来展望

1. RDT 系列的继续缩放：从 1 万小时 UMI 数据走向更大规模，检验”无本体数据”的缩放上限；
2. 视频模型与 VLA 的融合：清华 × 生数的组合在”世界模型 → 策略”方向具有独特优势；
3. 产学研闭环：清华系创业公司的真实部署数据，可能反哺学术研究。

---

8. 延伸阅读与核验来源

- RDT-1B：arXiv 2410.07864；ICLR 2025
- Vidar：arXiv 2507.12898
- RDT2：arXiv 2602.03310；项目页 rdt-robotics.github.io/rdt2
- 爱范儿：清华 × 生数 Vidar 报道

> 核验说明：RDT-1B 的 12 亿参数、统一动作空间、6000+ 条双臂数据、1–5 条示范学会新技能来自 ICLR 论文与项目页；“46 个数据集、100 万+ 轨迹”为论文中的描述（检索结果未直接显示该数字，以论文为准）；Vidar 的统一观察空间、约 75 万条多视角轨迹（3 个平台）、MIDM、约 20 分钟（约 1%）数据适配、RoboTwin 最优与测试时扩展来自 arXiv 论文；RDT2 的 7B、1 万+ 小时 UMI 数据、RVQ + 流匹配 + 蒸馏、零样本跨本体来自 arXiv 论文与综述，“100+ 家庭”来自二手综述。

第 22 章 香港大学（OpenDriveLab 与 MMLab）：从自动驾驶到”潜在动作”，从仿真孪生到人形全身 VLA

> 一句话定位：港大在具身智能领域有两支极具影响力的团队：李弘扬的 OpenDriveLab（UniAD 获 CVPR 2023 最佳论文，后转向具身）和罗平（Ping Luo）的 MMLab@HKU。它们的代表性贡献是：UniVLA（RSS 2025）——用”任务中心的潜在动作”让 VLA 从任意视频（包括人类视频）中学习，以不到 OpenVLA 1/20 的预训练算力超越它；RoboTwin 2.0（2025）——可规模化的双臂操作合成数据生成器与基准；WholeBodyVLA（ICLR 2026）——在智元 X2 人形上用潜在动作学习实现全身”移动+操作”。港大团队与智元机器人、上海人工智能实验室深度合作（共同发布 AgiBot World 数据集），是”学术—产业—国家实验室”三方协同的典型。

0. 速览卡片

维度	内容
核心团队	OpenDriveLab（李弘扬；团队成立于 2021 年，曾长期依托上海人工智能实验室，李弘扬现任港大）；MMLab@HKU（罗平 Ping Luo）
合作方	智元机器人（AgiBot World、UniVLA、WholeBodyVLA）、上海人工智能实验室、上海交通大学（RoboTwin，穆尧组）等
代表工作	UniAD（自动驾驶，CVPR 2023 最佳论文）、AgiBot World Colosseo（与智元等，2025）、UniVLA（RSS 2025）、RoboTwin / RoboTwin 2.0（2024–2025）、WholeBodyVLA（ICLR 2026）
本章三篇代表作	① UniVLA：任务中心潜在动作 ② RoboTwin 2.0：双臂操作的可规模化合成数据与基准 ③ WholeBodyVLA：人形全身移动操作的统一潜在 VLA
身位	“潜在动作 + 从视频学习”路线的学术引领者之一；中国开源数据与基准的重要贡献者

1. 故事的开端：自动驾驶团队为什么转向具身？

OpenDriveLab 的 UniAD 在 2023 年获得 CVPR 最佳论文——它首次把感知、预测、规划统一到一个端到端网络中，是”端到端自动驾驶”的里程碑。李弘扬团队从中得到的经验是：端到端 + 大规模数据 + 统一表征。

当具身智能兴起时，团队发现机器人面临与自动驾驶早期完全相同的困境：数据稀缺、动作空间异构、无法利用海量视频。于是他们把自动驾驶的经验迁移过来，走了两条路： 1. 造数据：与智元合作，发布百万级真机轨迹的 AgiBot World 数据集（详见第 32 章）； 2. 用视频：既然机器人数据稀缺，就想办法让模型从没有动作标签的视频中学习——这就是 UniVLA。

2. 代表作一：UniVLA（RSS 2025）——任务中心的潜在动作

> 论文：Qingwen Bu, Yanting Yang, Jisong Cai, Shenyuan Gao, Guanghui Ren, Maoqing Yao, Ping Luo, Hongyang Li，*Learning to Act Anywhere with Task-centric Latent Actions*（UniVLA，RSS 2025，arXiv 2505.06111）——港大、智元等合作。

2.1 问题：潜在动作的"噪声"

"潜在动作（latent action）"的思想（Genie、LAPA、GR00T N1 中都有使用）是：从视频的相邻帧中学习一个离散码，来"解释"两帧之间发生了什么变化——这样任何视频都可以被标注成"潜在动作序列"，用于训练机器人策略。

但原始方法有一个大问题：视频中的变化不全是"任务相关"的——相机抖动、背景中走过的人、光照变化都会被编码进潜在动作，污染学习信号。

2.2 方法：两阶段解耦的潜在动作模型

```
阶段一：学习"任务无关"的潜在动作
  · 在 DINOv2 特征空间（而非像素空间）中做逆动力学：
    给定帧 t 与帧 t+k 的 DINOv2 特征，用 VQ-VAE 学一个离散潜在码
  · 不给语言条件 → 这一阶段的码会吸收各种变化（包括无关变化）

阶段二：学习"任务中心"的潜在动作
  · 加入语言指令作为条件，再学习一组新的潜在码
  · 由于阶段一的码已经"吸收"了与任务无关的变化，
    阶段二的码被迫只编码"与任务相关的动态"（手和物体如何按指令运动）

使用：
  · 用任务中心潜在动作标注大量视频（含人类视频、不同机器人视频）
  · 训练一个基于 Prismatic-7B 的 VLA，让它预测"任务中心潜在动作"
  · 下游只需在目标机器人上训练一个很小的"动作解码器"，把潜在动作映射为真实动作
```

关键设计：- 在 DINOv2 特征空间而非像素空间做逆动力学：DINOv2 特征对外观变化不敏感、更关注语义与几何，减少了无关视觉噪声；- 语言条件化的解耦：用"先学任务无关、再学任务相关"的两阶段，把有用的动态与噪声分开；- 潜在动作作为跨本体"通用语言"：不同机器人、甚至人类的视频，都被映射到同一套潜在动作空间。

2.3 结果

- 以不到 OpenVLA 1/20 的预训练算力（GPU 小时）和 1/10 的下游数据，超越 OpenVLA；
- 在 LIBERO 上成功率比 OpenVLA 高约 18.5%；在导航任务上高约 29.6%；在真机测试中高约 36.7%；
- 仅用 Bridge-V2 数据预训练的 UniVLA，就能超过在更大的 OXE 上训练的 OpenVLA 与 LAPA。

2.4 意义

UniVLA 证明了"潜在动作的质量"是"从视频学习"路线的关键，并给出了一个简单有效的提纯方法。它为 2025–2026 年大量"用人类视频预训练 VLA"的工作（包括 WholeBodyVLA、智元 GO-1 的潜在规划器思想）提供了技术

基础。

---

3. 代表作二：RoboTwin 2.0（2025）——双臂操作的可规模化合成数据与基准

> 论文：*RoboTwin 2.0: A Scalable Data Generator and Benchmark with Strong Domain Randomization for Robust Bimanual Robotic Manipulation*（arXiv 2506.18088，2025.06/08）——港大 MMLab（罗平）与上海交大（穆尧组）等；前作 RoboTwin（CVPR 2025 Highlight；早期版本获 ECCV 2024 研讨会最佳论文）。

3.1 问题

双臂操作数据稀缺，而现有仿真基准要么任务少、要么场景过于"干净"（无杂物、固定光照），用它们生成的数据训练出的策略在真实世界中很脆弱。

3.2 三大组件

1. RoboTwin-OD 物体库：731 个物体实例、147 个类别，每个物体带有语义与操作相关的标注（如可抓取部位、功能点）；
2. MLLM 驱动的自动化任务代码生成：用多模态大模型生成任务执行代码（"专家策略"），并用仿真反馈闭环修正——生成 → 在仿真中执行 → 根据失败信息修改代码 → 再执行，使代码生成成功率提升约 10.9%；
3. 五维强域随机化：杂物、光照、背景、桌面高度、语言指令五个维度的随机化，使生成的数据覆盖大量真实世界变化。

基准覆盖 50 个双臂任务、5 种机器人本体。

3.3 结果

用 RoboTwin 2.0 合成数据 + 仅 10 条真实示范训练的 VLA，相对于只用 10 条真实示范的基线，性能相对提升约 367%。代码、数据生成器、基准与预采集数据集全部开源。

3.4 意义

RoboTwin 2.0 是中国学术界在"仿真合成数据 + 标准化基准"方向上的代表作，在国内被广泛用作 VLA 评测基准（类似 LIBERO、SimplerEnv 在国际上的地位）。它与 NVIDIA 的 DexMimicGen、斯坦福的 BEHAVIOR 形成呼应，体现了"MLLM 生成任务 + 仿真验证"这一自动化数据生成范式。

---

4. 代表作三：WholeBodyVLA（ICLR 2026）——人形全身移动操作的统一潜在 VLA

> 论文：Haoran Jiang, Jin Chen, Qingwen Bu, Li Chen, Modi Shi, Yanjie Zhang, Delong Li, Chuanzhe Suo, Chuang Wang, Zhihui Peng, Hongyang Li，*WholeBodyVLA: Towards Unified Latent VLA for Whole-Body Loco-Manipulation Control*（arXiv 2512.11047，ICLR 2026）；代码托管于 OpenDriveLab GitHub。

4.1 问题

UniVLA 解决了"从视频学操作"，但人形机器人还需要一边走一边操作：推着购物车走、蹲下搬箱子、转身装包。全身移动操作的遥操作数据比桌面操作更加稀缺。

4.2 方法：潜在动作 + 分层执行



关键点： - 从无动作视频中学习：用潜在动作模型从大量人类第一视角视频中提取监督信号，解决人形全身数据稀缺； - 统一的潜在动作空间：上半身操作与下半身移动在同一个潜在空间中建模，由解码器分别映射； - 专门的 RL 运动控制器：下半身由一个面向"移动操作"优化的 RL 策略执行（能在推重物、下蹲时保持稳定），而非通用行走控制器。

4.3 结果

在智元 X2 人形机器人上完成三类任务：装包（Bag Packing）、装箱（Box Loading）、推车（Cart Pushing）。其中推动 50 公斤推车的成功率为 22/25。

4.4 意义

WholeBodyVLA 是 2025–2026 年把"潜在动作 + 人类视频预训练"从桌面操作推广到人形全身移动操作的代表性工作，并采用了与 Figure Helix 02、NVIDIA GR00T + SONIC 同构的"上层 VLA + 下层 RL 运动控制"分层结构。它也展示了港大与智元合作的紧密程度：从数据集（AgiBot World）到模型（UniVLA）再到人形部署（X2）。

---

5. 技术路线总结

方向	代表作	核心思想
真实数据	AgiBot World（与智元等）	百万级真机轨迹、标准化采集
视频数据	UniVLA	任务中心潜在动作，让任意视频可用
合成数据	RoboTwin 2.0	MLLM 生成任务 + 仿真闭环 + 强域随机化
人形全身	WholeBodyVLA	潜在动作 VLA + RL 移动操作控制器

港大团队的研究覆盖了"真实 / 视频 / 合成"三种数据来源，并都提供了开源实现——这在全球学术团队中都是少见的完整度。

---

6. 横向对比与身位

潜在动作路线代表	机构	特点
Genie（2024）	Google DeepMind	从游戏视频学潜在动作，生成可交互世界
LAPA（2024）	KAIST/微软等	潜在动作预训练 VLA
GR00T N1（2025）	NVIDIA	潜在动作作为"LAPA 虚拟本体"
UniVLA（2025）	港大/智元	DINOv2 空间 + 语言条件解耦的任务中心潜在动作
WholeBodyVLA（2026）	港大/智元	潜在动作扩展到人形全身移动操作
GO-1 / GO-2（2025–2026）	智元	潜在规划器 / 动作思维链

身位：在"从视频学习机器人动作"这一方向上，港大团队处于全球学术前列；与智元的深度合作，使其研究能快速在真实人形上验证。

---

7. 未来展望

1. 潜在动作 + 世界模型：潜在动作本质上是一种"压缩的世界变化"，与世界模型的结合（在潜在动作空间中规划）是自然方向；
2. 人形全身数据的规模化：WholeBodyVLA 只用了三类任务，扩展到更多全身任务需要更大规模的人类视频与人形数据；
3. 评测标准：RoboTwin 系列可能演进为覆盖人形全身任务的基准。

---

8. 延伸阅读与核验来源

- UniVLA：arXiv 2505.06111；RSS 2025 论文页
- RoboTwin 2.0：arXiv 2506.18088；项目页；RoboTwin 1.0（arXiv 2409.02920）
- WholeBodyVLA：arXiv 2512.11047；ICLR 2026
- 李弘扬个人主页；OpenDriveLab

> 核验说明：UniVLA 的作者、方法与数字（1/20 算力、1/10 数据、+18.5%/+29.6%/+36.7%）来自 RSS 2025 论文摘要；RoboTwin 2.0 的物体库规模、50 任务 5 本体、+10.9% 与 +367% 来自论文；WholeBodyVLA 的作者、方法、智元 X2 平台与 22/25 推车成功率来自 arXiv 与 ICLR 页面（代码开源状态存在不同说法）；李弘扬的任职信息各来源表述不一，本章采用"现任港大、曾依托上海人工智能实验室"的表述。

第 23 章 上海人工智能实验室（Intern Robotics）：国家队的”全栈开源具身体系”

> 一句话定位：上海人工智能实验室（上海 AI Lab）以”书生（Intern）“大模型体系为母体，打造了国内最完整的开源具身智能全栈——从城市级仿真平台（GRUtopia / InternUtopia）、大规模合成数据（InternData 系列）、到操作 VLA（InternVLA-M1、InternVLA-A1/A1.5）与导航 VLA（InternVLA-N1）。它的路线可以概括为”空间推理优先 + 合成数据规模化 + 理解/生成/动作统一”。作为国家级新型研发机构，上海 AI Lab 的目标不是卖机器人，而是为中国具身产业提供开源的公共基础设施；它也与智元、港大 OpenDriveLab 等深度合作（共同发布 AgiBot World 数据集）。

0. 速览卡片

维度	内容
机构	上海人工智能实验室（2020 年成立的国家级新型研发机构）；具身智能工作以 Intern Robotics（InternRobotics） 开源组织发布
母体模型	书生·浦语（InternLM）、书生·万象（InternVL）多模态大模型
代表工作	GRUtopia / InternUtopia（2024，城市级具身仿真）；InternData 系列数据集（N1 导航、A1 操作）；InternVLA-M1（2025.10）；InternVLA-N1（2025）；InternVLA-A1（2026.01）/ A1.5（2026.07）；InternManip、InternNav 等工具链
合作	与智元机器人、港大 OpenDriveLab 共同发布 AgiBot World；与众多本体厂商合作
开放程度	高：代码、权重、数据集、仿真平台开源（部分模型为非商业许可，如 A1.5 为 CC-BY-NC-SA-4.0）
本章三篇代表作	① GRUtopia / InternUtopia：城市级具身仿真与合成数据 ② InternVLA-M1：空间引导的双系统 VLA ③ InternVLA-A1 / A1.5：理解-生成-动作统一的 VLA（并述 N1 导航）
身位	中国具身开源基础设施的”国家队”；在空间推理与合成数据方向具有鲜明特色

1. 故事的开端：国家实验室为什么要做”全栈开源”？

上海 AI Lab 的定位决定了它的路线。与企业不同，它的使命是为产业提供公共技术底座——在大模型时代，它以书生系列开源模型为中国 AI 生态提供基座；在具身时代，它判断中国具身产业的最大短板是： 1. 数据：真机数据昂贵且分散，各家公司重复采集； 2. 仿真与评测：缺少统一的大规模仿真平台与基准； 3. 开源基座模型：国内企业早期多基于国外开源模型（OpenVLA、π0、GR00T）二次开发。

于是它的布局是”仿真平台 → 合成数据 → 开源模型 → 工具链”的全栈开源。

2. 代表作一：GRUtopia / InternUtopia（2024）——“城市级”的具身仿真

> 论文：*GRUtopia: Dream General Robots in a City at Scale*（上海 AI Lab，2024.07）；后续升级为 InternUtopia。

2.1 设计目标

当时主流的具身仿真（Habitat、OmniGibson、ManiSkill）大多局限于单个房间或单个桌面。GRUtopia 的目标是：把仿真扩展到”城市尺度”，覆盖家庭、商场、医院、餐厅、办公室等多种场景，并让机器人与”会说话的虚拟人”交互。

2.2 三大组件

组件	内容
GRScenes	约 10 万个可交互的、精细标注的场景（涵盖多种城市功能区），可组合成城市级环境
GRResidents	由大语言模型驱动的 NPC（虚拟居民），能与机器人对话、提出任务、提供信息——用于社会性交互任务
GRBench	基准，覆盖物体导航、社会导航、移动操作等任务，以人形机器人（宇树 H1 等）为主要评测本体

2.3 意义

GRUtopia 的核心理念是”在城市里做梦”（Dream General Robots in a City）——用仿真为通用机器人提供海量、多样、社会化的训练与评测场景。它后来演进为 InternUtopia，成为 InternVLA-N1 等模型的评测与数据生成平台，并支撑了 InternData 系列合成数据集。

---

3. 代表作二：InternVLA-M1（2025.10）——空间引导的双系统 VLA

> 论文：*InternVLA-M1: A Spatially Guided Vision-Language-Action Framework for Generalist Robot Policy*（arXiv 2510.13778）；代码与权重开源于 InternRobotics GitHub。

3.1 核心观点：空间理解是 VLA 的短板

许多 VLA 失败的原因并不是”听不懂指令”，而是”找不准位置”——“把杯子放到盘子左边”“抓住瓶盖而不是瓶身”这类指令，要求模型具备精确的空间定位与空间关系推理。通用 VLM 在互联网图文上学到的空间能力有限，而 VLA 训练中的动作损失又难以有效提升空间理解。

3.2 架构：空间推理规划器 + 动作专家



```
| VLM 规划器（System 2）                |
| · 经大规模空间定位预训练               |
| · 推理"在哪里""如何空间关联"           |
| · 通过"空间提示（spatial prompting）" |
|   产生潜在规划                        |
└──────────────────────────────────────┘
        | 空间接地的潜在表征
        ▼
┌──────────────────────────────────────┐
| 动作专家（System 1）                  |
| · 把空间接地的表征转为可执行动作       |
└──────────────────────────────────────┘
```

3.3 两阶段训练

1. 空间定位预训练：用超过 230 万条空间推理数据（物体检测框、指点、轨迹、可供性等）预训练 VLM，学习与本体无关的空间先验；
2. 空间引导的动作后训练：在 VLM 的空间接地能力之上，训练动作专家；用”空间提示”让 VLM 在生成规划时显式关注空间信息。

3.4 结果

- 相对”无空间引导”的变体，在 SimplerEnv 的 Google Robot Visual Matching 上提升约 14.6%、Visual Aggregation 上提升约 12.5%、WidowX 上提升约 17.0%（二手解读数据）；
- 在 LIBERO 上，空间任务成功率约 98.0%、长时程任务约 92.6%；
- 消融显示：去掉空间数据或空间提示，空间接地能力会迅速退化，操作任务收敛变慢。

3.5 意义

InternVLA-M1 把”空间推理”提升为 VLA 设计的一等公民。这与 DeepMind Gemini Robotics-ER（指点、3D 检测、轨迹）、阿里 RynnBrain（物理空间推理）、智源 RoboBrain（可供性与轨迹）的思路一致，代表了 2025–2026 年”具身大脑 = 空间推理 VLM + 动作专家”的中国主流方案之一。

---

4. 代表作三：InternVLA-A1 / A1.5（2026）——理解、生成、动作的统一

> 论文：*InternVLA-A1: Unifying Understanding, Generation and Action for Robotic Manipulation*（arXiv 2601.02456，2026-01-05）；InternVLA-A1.5（2026-07-06 发布）。

4.1 核心思想：VLA 也需要”想象”

InternVLA-M1 强调”理解空间”，A1 则进一步引入”预见（foresight）”：在行动之前，先生成”接下来的画面会是什么样”。这是 2026 年”VLA + 世界模型”融合趋势在上海 AI Lab 的体现。

4.2 架构：三专家 Mixture-of-Transformers

专家	职责
理解专家	场景理解与指令理解（继承 VLM 能力）
视觉预见生成专家	生成未来视觉状态（“想象”动作执行后的画面）
动作专家	输出机器人动作

三个专家通过统一的掩码自注意力交互，信息按”理解 → 生成 → 动作”的固定顺序流动（由累积式分段掩码保证）——理解为生成提供语义，生成为动作提供”预见的未来画面”，动作专家同时参考两者： - 生成专家使用基于 VAE 的视觉分词器（Cosmos 系列的连续图像分词器）在潜空间中预测未来画面； - 动作专家以流匹配目标生成连续动作。

- 基于 InternVL3 与 Qwen3-VL 构建，提供 20 亿与 30 亿参数两种规模；
- 预训练数据为合成与真实的混合：
  - InternData-A1：大规模仿真合成数据，超过 5.33 亿帧，覆盖 4 种本体、18 种技能、70 个任务、227 个场景；
  - AgiBot World：真实世界示范（智元，第 32 章）；
  - 另外使用了人类第一视角视频。
- 消融：去掉”视觉预见生成专家”后整体性能下降约 19.4%，在动态任务上下降尤为明显——直接证明了”想象未来”对动态操作的价值。

4.3 结果（论文报告，对比 π0.5）

场景	相对 π0.5 的提升
静态操作任务	+4.4%
RoboTwin 2.0 仿真基准	+2.6%
动态操作任务	+26.7%

解读：在静态任务上与 π0.5 接近，但在动态任务（物体在运动、传送带、需要预判）上大幅领先——这正是”视觉预见”的价值：能预测物体未来位置的模型，自然更擅长处理动态场景。

4.4 InternVLA-A1.5（2026.07）

- 在约 120 万条机器人片段与 300 万条多模态样本上预训练；
- 约 30 亿参数；
- 在六个仿真基准上取得最好的整体成绩（据项目页）；
- 许可证为 CC-BY-NC-SA-4.0（非商业）。

4.5 补充：InternVLA-N1——导航的双系统

InternVLA-N1（*Ground Slow, Move Fast: A Dual-System Foundation Model for Generalizable Vision-and-Language Navigation*，arXiv 2512.08186）： - 双系统：慢系统是一个约 70 亿参数的预训练 VLM，以约 2Hz 运行，负责理解指令、推理目标并生成潜在规划；快系统是低层控制器，负责实时运动与避障； - 正式版采用异步推理，支持动态避障； - InternData-N1 数据集：超过 5000 万张第一视角图像、3000+ 个场景、累计

4839 公里的机器人导航经验——全部来自仿真，但模型可零样本泛化到真实机器人； - 在 InternUtopia 中以宇树 H1 人形为本体进行评测。

---

5. 技术路线总结



上海 AI Lab 的特色可以概括为三点： 1. 空间推理优先：认为空间理解是具身智能的根基； 2. 合成数据为主力：导航数据完全来自仿真，操作数据合成 + 真实混合； 3. 统一架构：从"规划器 + 执行器"走向"理解 + 生成 + 动作"三专家统一。

---

6. 横向对比与身位

维度	上海 AI Lab	北京智源（第 24 章）	北京人形创新中心（第 36 章）
定位	国家实验室，全栈开源	研究院，具身大脑开源	产业创新中心，开源人形本体 + 大脑
母体	InternVL / Qwen3-VL	自研 + 开源 VLM	自研 / 开源
代表模型	InternVLA-M1/A1/N1	RoboBrain 系列、RoboOS	天工、Pelican-VL 等
特色	空间推理、合成数据、城市级仿真	具身推理大脑、跨本体协作 OS	人形本体与数据

身位：上海 AI Lab 是中国具身开源生态最完整的提供者之一，其模型在国内学术与产业界被广泛使用；在全球范围内，其 InternVLA 系列在仿真基准上可与 π0.5 等前沿开源模型竞争，但在真实大规模部署方面的验证不如企业。

---

7. 未来展望与风险

展望： 1. 合成数据规模化：InternData 系列持续扩大，可能成为中国最大的开源具身合成数据来源； 2. 与本体厂商深度合作：通过开源模型 + 产业联盟，形成"国家队底座 + 企业应用"的生态； 3. 世界模型方向：A1 的视觉预见能力可能进一步发展为完整的具身世界模型。

风险： 1. 非商业许可限制了部分模型的产业直接采用； 2. 合成数据的 sim2real 鸿沟在复杂操作中仍是挑战； 3. 与企业的竞合关系：头部企业（智元、银河等）的自研能力提升后，对公共开源模型的依赖可能下降。

---

8. 延伸阅读与核验来源

- GRUtopia：arXiv 2407.10943
- InternVLA-M1：arXiv 2510.13778
- InternVLA-A1：arXiv 2601.02456
- InternVLA-N1：arXiv 2512.08186；Hugging Face：InternVLA-N1
- Robotics Center：上海人工智能实验室机构页

> 核验说明：InternVLA-M1 的双系统、230 万空间数据与 LIBERO 成绩来自论文及二手解读（SimplerEnv 提升数字为二手数据）；InternVLA-A1 的三专家 MoT、理解→生成→动作的信息流、Cosmos 式 VAE 分词器、流匹配动作专家、2B/3B 规模、InternData-A1（5.33 亿+ 帧、4 本体、18 技能、70 任务、227 场景）、去掉生成专家 -19.4% 与对比 π0.5 的提升来自 arXiv 论文；A1.5 的数据规模、发布日期与许可证来自项目/目录页；InternVLA-N1 的 7B/2Hz 双系统与 InternData-N1 规模来自论文与 Hugging Face 模型卡；GRUtopia 的规模来自 2024 年论文。

第 24 章 北京智源人工智能研究院（BAAI）：专注”具身大脑”的推理模型与跨本体操作系统

> 一句话定位：智源研究院在具身智能领域走了一条清晰的”大脑优先”路线：不做动作模型（小脑），而是专注于为机器人提供”看懂、想清、规划”的具身推理大模型——RoboBrain 系列（1.0 → 2.0 → 2.5），并配套跨本体的大小脑协作框架 RoboOS。它的定位与 DeepMind 的 Gemini Robotics-ER 高度对应：输出可供性、轨迹、空间坐标、任务进度等”中间表征”，交给各家机器人的小脑去执行。RoboBrain 2.5 在国产算力（摩尔线程千卡集群）上完成全流程训练，也让它成为”国产算力训练具身大模型”的标志性案例。

---

0. 速览卡片

维度	内容
机构	北京智源人工智能研究院（BAAI），2018 年成立的新型研发机构
代表工作	RoboBrain 1.0（CVPR 2025）+ RoboOS（2025.03.29 中关村论坛发布）；RoboBrain 2.0（2025.07，7B / 32B）；RoboBrain 2.5（2025.12–2026.01 技术报告）；Emu3 / Emu3.5（原生多模态世界模型）；FlagScale / FlagEvalMM / FlagOS-Robo 等基础设施
合作	与银河通用（GraspVLA）、北京人形创新中心、众多本体厂商合作；与摩尔线程合作国产算力训练
开放程度	高：模型、数据、代码、基准开源
本章三篇代表作	① RoboBrain 1.0 + RoboOS：从抽象到具体的具身大脑与跨本体协作框架 ② RoboBrain 2.0：空间 + 时间推理的统一具身大脑 ③ RoboBrain 2.5：3D 度量空间推理与稠密时序价值预测
身位	中国”具身推理大脑（ER 类模型）“开源方向的代表；国产算力训练具身模型的先行者

---

1. 故事的开端：“大小脑分离”的判断

2024 年，国内具身智能讨论中最常见的一个框架是”大脑 + 小脑”：- 大脑：理解指令、理解场景、规划任务、推理空间关系——需要大模型；- 小脑：把规划转为精确的关节运动——需要高频、低延迟的控制模型。

智源的判断是：中国的本体厂商有能力做小脑（运动控制、技能库），但缺少一个开源的、强大的”具身大脑”；同时，各家机器人”各自为战”，缺少跨本体协作的操作系统。于是智源选择专注于两件事：RoboBrain（大脑模型）+ RoboOS（协作框架）。

---

2. 代表作一：RoboBrain 1.0 + RoboOS（2025.03）——从抽象到具体

> 论文：*RoboBrain: A Unified Brain Model for Robotic Manipulation from Abstract to Concrete*（CVPR 2025）；RoboOS 与 RoboBrain 于 2025 年 3 月 29 日在中关村论坛发布。

2.1 RoboBrain 1.0：三种能力

RoboBrain 1.0 把机器人操作所需的"大脑能力"拆解为从抽象到具体的三层： 1. 任务规划（Planning）：把"把桌子收拾干净"拆成"拿起杯子 → 放进水槽 → ……"； 2. 可供性感知（Affordance）：识别"杯子的哪个部位可以抓"（输出图像中的区域/框）； 3. 轨迹预测（Trajectory）：预测末端执行器应该走的 2D 轨迹点序列。

为此团队构建了 ShareRobot 数据集——在 OXE 等开源机器人数据上标注规划、可供性与轨迹信息，用于训练 VLM 获得这些具身能力。

2.2 RoboOS：跨本体的"大小脑协作操作系统"

RoboOS 被宣传为首个跨本体开源具身大小脑协作框架：



- 大脑：RoboBrain 负责理解与规划，可以同时为多台不同形态的机器人分配任务；
- 小脑技能库：各本体厂商提供自己的低层技能（通过标准接口注册）；
- 共享记忆：跨机器人共享空间、时间与本体信息，支持多机协作（例如一台机器人开门、另一台搬东西进去）。

2.3 意义

RoboOS 与 DeepMind Gemini Robotics-ER 2 的"多机分工"（2026.07）在思想上一致，但早了一年多，并且完全开源。它代表了中国"生态协同"式的具身路线：智源做公共大脑与协议，企业做本体与技能。

---

3. 代表作二：RoboBrain 2.0（2025.07）——空间 + 时间的统一具身大脑

> 论文：*RoboBrain 2.0 Technical Report*（BAAI RoboBrain Team，arXiv 2507.02029，至 2025.09 共五个版本）；项目页 superrobobrain.github.io

3.1 两种规模

版本	定位
RoboBrain 2.0-7B	轻量版，便于部署
RoboBrain 2.0-32B	完整版，性能最强

结构为”视觉编码器 + 语言模型”的标准 VLM 架构，重点在数据与训练。

3.2 能力体系

空间理解：- 可供性预测（哪里可以抓、哪里可以放）；- 空间指代（“左边第二个红色的杯子”→ 精确定位）；- 轨迹预测（末端执行器的运动路径）。

时间决策：- 闭环交互（根据执行反馈调整计划）；- 多智能体长时程规划（多台机器人协同完成长任务）；- 场景图更新（随着任务推进，动态更新对场景的结构化理解）。

3.3 训练

多阶段训练策略：通用多模态能力 → 具身空间/时间能力 → 第三阶段：具身场景下的思维链（CoT）推理——让模型在回答空间/规划问题前先进行逐步推理。训练依托智源自研的 FlagScale 框架，评测依托 FlagEvalMM。

3.4 结果

- 32B 版本在空间与时间两类基准上均领先此前的开源与闭源模型；
- 项目页称其在 9 个空间基准与 3 个时间基准上达到或接近最优；
- 代码、检查点、基准全部开源。

3.5 意义

RoboBrain 2.0 是 2025 年中国开源”具身推理 VLM”的代表作，与 DeepMind Gemini Robotics-ER 1.5（同年 9 月）、NVIDIA Cosmos Reason、阿里 RynnBrain（2026.02）构成同一赛道的竞争。

---

4. 代表作三：RoboBrain 2.5（2025.12–2026.01）——从”看懂说清”到”落手做准”

> 论文：RoboBrain 2.5 技术报告（arXiv 2601.14352；alphaXiv 显示时间为 2025-12-29）；智源官方发布与摩尔线程联合公告。

4.1 问题：两个被低估的短板

智源在发布中指出，过去一年具身智能的”视觉理解 + 语言推理”进步明显，但从实验室走向真实部署时，常遇到”看得见、做不对”的问题，根源在于两个长期被低估的短板： 1. 空间维度的度量盲区：2D 像素级的指点/

框，无法告诉机器人”离我多远、多高、多深”； 2. 时间维度的过程建模不足：模型能判断”任务成功/失败”，却无法稠密地估计”任务进行到了哪一步”。

4.2 两项核心升级

（1）精确的 3D 空间推理 - 从基于 2D 像素的定位，扩展为带深度感知的三维坐标预测； - 能生成符合物理约束的 3D 操作轨迹（而非只是 2D 图像上的点序列）。

这意味着 RoboBrain 2.5 的输出可以直接被机器人的运动规划器使用，而不需要再经过复杂的 2D→3D 转换。

（2）稠密时序价值预测 - 能跨视角估计任务的执行进度与状态，输出连续的”价值/进度”信号； - 为下游学习（例如强化学习、数据筛选、成功检测）提供稳定的反馈信号。

这与 PI π*0.6 的价值函数、DeepMind ER 2 的”任务进度追踪”属于同一类能力——通用的具身价值模型/奖励模型。在 2026 年”VLA + 真机 RL”成为热点的背景下，这一能力的价值极高。

4.3 国产算力训练

摩尔线程与智源基于 FlagOS-Robo 框架，在 MTT S5000 千卡智算集群上完成了 RoboBrain 2.5 的全流程训练，被宣传为国产算力集群在具身大模型训练中的首次验证。在高端 GPU 出口管制的背景下，这一案例对中国具身产业的算力自主具有象征意义。

4.4 意义

RoboBrain 2.5 的两项升级精确地命中了 2026 年具身大脑的两个关键需求： - 3D 度量空间推理 → 让”大脑输出”可以直接驱动”小脑执行”； - 稠密价值预测 → 让”大脑”成为 RL 自我改进的”裁判”。

智源官方将其概括为：从”能看懂、能说清”走向”能落手、做得准”。

---

5. 技术路线总结

版本	时间	核心能力	输出形式
RoboBrain 1.0	2025.03	规划 + 可供性 + 2D 轨迹	文本计划、2D 区域、2D 点序列
RoboBrain 2.0	2025.07	空间（可供性、指代、轨迹）+ 时间（闭环、多机、场景图）+ CoT	同上 + 多机规划、场景图
RoboBrain 2.5	2025.12–2026.01	3D 度量空间推理 + 稠密时序价值	3D 坐标、3D 轨迹、进度/价值信号

配合 RoboOS 的”大脑-共享记忆-小脑技能库”框架，智源构建了一个以推理大脑为中心的开放具身生态。

---

6. 横向对比与身位

“具身推理大脑”赛道	机构	特点	开放
Gemini Robotics-ER 1.5/1.6/2	DeepMind	最强综合能力，工具调用，多机编排	API
Cosmos Reason 1/2	NVIDIA	物理常识，作为 GR00T 的 VLM	开源
RoboBrain 2.0/2.5	智源	可供性/轨迹/3D 坐标/价值预测；RoboOS	开源
RynnBrain（第 26 章）	阿里达摩院	时空记忆、30B MoE	开源
Pelican-VL（第 36 章）	北京人形创新中心	具身 VLM	开源
InternVLA-M1 规划器（第 23 章）	上海 AI Lab	空间引导	开源

身位：智源是中国”具身推理大脑”开源方向的领先者之一，RoboBrain 系列在多个空间/时间基准上处于开源模型前列；其 RoboOS 是国内少有的跨本体协作框架。

---

7. 未来展望与风险

展望： 1. 大脑 + 价值模型的双重角色：RoboBrain 可能演进为”规划器 + 奖励模型”，支撑全行业的 RL 后训练； 2. RoboOS 的生态化：若足够多的本体厂商接入，可能形成中国的”机器人互操作标准”； 3. 国产算力适配：在国产 GPU 上的训练与推理优化将持续推进。

风险： 1. 只有大脑、没有小脑：在”端到端 VLA”成为主流的趋势下，纯推理大脑的价值需要通过与小脑的良好接口来体现； 2. 与大厂模型的竞争：阿里、字节、腾讯等都在推出具身大脑模型，智源需要在开源影响力上保持领先。

---

8. 延伸阅读与核验来源

- RoboBrain 1.0：CVPR 2025
- RoboBrain 2.0：arXiv 2507.02029；项目页
- RoboBrain 2.5：arXiv 2601.14352；智源社区介绍；开源中国：摩尔线程与智源完成 RoboBrain 2.5 全流程训练
- RoboOS：今日头条：智源发布首个跨本体开源具身大脑；国家科技创新信息

> 核验说明：RoboBrain 1.0 的三种能力与 ShareRobot 数据集来自 CVPR 2025 论文；RoboOS 的架构与发布时间来自官方与新华社/新京报报道；RoboBrain 2.0 的 7B/32B 规模、能力体系与”9 个空间 + 3 个时间基准”来自技术报告与项目页；RoboBrain 2.5 的两项升级来自 arXiv 摘要与智源官方介绍，国产算力训练来自摩尔线程联合公告；RoboBrain 2.5 的确切发布日期未能精确确认（论文时间约为 2025 年底至 2026 年 1 月）。

第 25 章 字节跳动 Seed：从”视频生成预训练”到”真机强化学习穿鞋带”

> 一句话定位：字节跳动 Seed 团队是中国大厂中最早、最系统、学术产出最扎实的机器人大脑团队。它的 GR 系列（GR-1 → GR-2 → GR-3 → GR-RL）有一条清晰的主线：用视频生成式预训练让机器人学会”世界如何变化”，再用 VLA 与强化学习让它学会”自己如何行动”。GR-1（2023.12）是全球最早用大规模视频生成预训练提升机器人操作的工作之一；GR-3（2025.07）配合自研双臂移动机器人 ByteMini 实现了强泛化与长时程操作；GR-RL（2025.12）首次以学习方法在真机上完成”穿鞋带”这一极限精细任务；Robix（2025.09）则是负责推理、规划与交互的”机器人大脑”。2026 年，Seed 大规模扩招机器人硬件与数据岗位，显示字节正在构建”自研本体 + 自研模型 + 自有数据产线”的完整闭环。

---

0. 速览卡片

维度	内容
机构	字节跳动 Seed（豆包大模型团队）机器人方向
代表工作	GR-1（2023.12，ICLR 2024）、GR-2（2024.10）、GR-MG、GR-3（2025.07）+ ByteMini 机器人、Robix（2025.09）、GR-RL（2025.12）
硬件	ByteMini：自研双臂移动机器人（腕部球形关节设计，便于灵巧操作）
2026 动态	Seed 在官网与招聘平台集中发布数十个机器人岗位（本体设计、灵巧手、减速机控制、仿真、数据算法等）；分析认为其在搭建”可自我迭代的具身数据产线”，自研机器人首要客户是 Seed 模型团队
开放程度	中：技术报告详细，部分模型与代码未开源（GR-3 未开放权重）
本章三篇代表作	① GR-1 / GR-2：视频生成式预训练的机器人操作模型 ② GR-3 + ByteMini：大规模 VLA 与软硬一体 ③ GR-RL（+ Robix）：真机强化学习与机器人”大脑”
身位	中国大厂机器人大脑的学术标杆；在”视频预训练 → VLA → RL”的完整技术链上布局最早

---

1. 故事的开端：一家视频公司的天然优势

字节跳动是全球拥有最多短视频数据与视频理解/生成技术的公司之一（抖音/TikTok、剪映、Seedance 视频生成模型）。当 Seed 团队 2023 年开始做机器人时，他们自然地提出了一个问题：

> 视频里蕴含着海量的”世界如何运转”的知识。能否让机器人通过”预测视频的下一帧”来学习物理世界？

这一问题定义了 GR 系列的出发点，也让字节成为全球最早系统探索”视频生成预训练 → 机器人操作”路线的团队之一——比 NVIDIA DreamZero、1X 1XWM 的”世界模型即策略”热潮早了两年。

---

2. 代表作一：GR-1（2023.12）与 GR-2（2024.10）——视频生成式预训练

> 论文：Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, Tao Kong，*Unleashing Large-Scale Video Generative Pre-training for Visual Robot Manipulation*（GR-1，ICLR 2024）；Chi-Lam Cheang 等，*GR-2: A Generative Video-Language-Action Model with Web-Scale Knowledge for Robot Manipulation*（2024.10）

2.1 GR-1：GPT 式的”视频 + 动作”模型

架构：一个 GPT 风格的因果 Transformer，输入为语言指令 + 历史图像序列 + 历史机器人状态，输出为未来图像（下一帧）+ 机器人动作。

两阶段训练： 1. 视频生成预训练：在 Ego4D 等大规模人类第一视角视频上，训练模型根据语言与历史帧预测未来帧——学习”世界如何随动作/时间变化”； 2. 机器人数据微调：在机器人数据上同时训练”预测未来帧”与”预测动作”。

预训练数据：Ego4D 中超过 3500 小时的人-物交互视频（二手综述称切分为约 80 万个 3 秒片段、约 800 万帧）。

结果（CALVIN：34 种语言指令操作任务，连续完成 5 个任务的长程评测）：

设置	此前最优	GR-1
标准设置成功率	88.9%	94.9%
平均完成长度（满分 5）	3.06	4.21
仅用 10% 数据的成功率	66.8%	77.8%
零样本未见场景成功率	53.3%	85.4%

消融实验显示：去掉视频预训练或去掉视频预测目标，成功率与平均完成长度都会显著下降——“预测未来”本身就是一种有效的监督信号。在真机上，GR-1 对未见过的场景与物体也表现出更好的泛化。

意义：GR-1 是全球最早证明”大规模视频生成预训练能显著提升机器人操作”的工作之一，开创了”视频预训练 → 动作”这条路线。

2.2 GR-2：网络规模的视频-语言-动作模型

- 预训练规模：约 3800 万个视频片段、超过 500 亿 token——涵盖人类日常活动的大量互联网视频；
- 架构：继承 GR-1，但规模与数据大幅扩展；
- 微调：在机器人轨迹上同时学习视频生成与动作预测；
- 结果：在 100 多个任务上平均成功率约 97.7%，并对新背景、新环境、新物体、新任务表现出强泛化；在端到端的工业箱体拣选任务中也有良好表现。

2.3 意义：GR 系列的”世界模型基因”

GR-1/GR-2 的本质是一个联合预测”未来视频 + 动作”的模型——这与 2026 年 NVIDIA DreamZero 的”世界动作模型”在思想上高度一致，只是规模与视频模型的质量不同。字节 Seed 可以说是”世界动作模型”这一方向的早期探索者之一。

---

3. 代表作二：GR-3 + ByteMini（2025.07）——大规模 VLA 与软硬一体

> 技术报告：*GR-3 Technical Report*（ByteDance Seed，arXiv 2507.15493，2025.07）；Seed 官方博客。

3.1 路线调整：从”视频生成”到”VLA”

GR-3 在架构上向 2025 年的主流 VLA 范式靠拢：

组件	设计
VLM 主干	Qwen2.5-VL-3B-Instruct
动作生成	扩散 Transformer（DiT）+ 流匹配，输出动作块
总规模	约 40 亿参数
效率设计	动作 DiT 的层数为 VLM 主干的一半，且只使用 VLM 后半部分层的 KV 缓存作为条件——在保证语义信息的同时加快推理
关键改进	在 DiT 中加入归一化改进以稳定训练；引入”任务状态”预测，帮助模型判断指令是否有效/任务是否完成

3.2 三类数据的协同训练

1. 机器人轨迹数据（遥操作）：学习动作；
2. 网络视觉-语言数据（co-training）：保持并增强 VLM 的语义与泛化能力——这让 GR-3 能理解”把最大的物体放进盒子”“把能吃的东西放到盘子里”等抽象概念指令；
3. VR 采集的人类轨迹数据（少样本）：用 VR 设备快速采集人类操作新物体的轨迹，每个新物体只需约 10 条人类轨迹，就能让 GR-3 学会操作该物体——据二手综述，这使未见物体的抓放成功率达到约 86.7%，比基线提升近 30 个百分点；数据采集效率远高于机器人遥操作。

3.3 ByteMini：为 VLA 设计的机器人

ByteMini 是 Seed 自研的双臂移动机器人，技术报告称其兼具”极高的灵活性与可靠性”：- 双臂 + 移动底盘（具体自由度数以技术报告为准）；- 腕部球形关节设计：模仿人类手腕的灵活性，便于在狭窄空间中操作；- 多相机配置（头部 + 腕部），为 VLA 提供充分视角。

3.4 结果

- 泛化：在未见过的物体、环境、抽象指令上显著优于 π0 基线；
- 长时程：完成”收拾餐桌”这类多步骤长任务；
- 灵巧：完成”把衣服挂到衣架上”这类需要双手精细配合、处理可形变物体的任务；

- 少样本：借助 VR 人类数据快速适配新物体。

3.5 局限

据第三方信息，GR-3 未开放权重与代码，外部无法复现。

---

4. 代表作三：GR-RL（2025.12）与 Robix（2025.09）——“小脑”的强化学习与”大脑”的推理

4.1 GR-RL：真机强化学习穿鞋带

> 技术报告：*GR-RL: Going Dexterous and Precise for Long-Horizon Robotic Manipulation*（arXiv 2512.01801，2025.12）；Seed 博客 *GR-RL: A Breakthrough in Dexterous Manipulation, Achieving the First Real-Robot Shoe Lacing with Reinforcement Learning*。

问题：Seed 团队指出模仿学习的两个根本缺陷—— 1. 人类示范是次优的：示范中充满犹豫、多余动作甚至错误； 2. 训练与推理的不匹配：训练时看的是”完美示范”，推理时却要面对自己犯错后的状态。

三阶段流程：

```
阶段一：离线 RL 过滤数据
  · 在成功与失败的轨迹上，用离线 RL 训练一个"任务进度模型"（critic）
  · 用它识别并过滤掉示范数据中"有害的"片段（使任务进度下降的动作）
        |
        ▼
阶段二：形态对称增强
  · 利用双臂机器人的左右对称性做数据增强（镜像），扩充数据
        |
        ▼
阶段三：真机在线 RL
  · 在真实机器人上闭环试错，微调策略
  · 探索不是直接在动作上加噪声，而是在潜空间中由学习的噪声预测器生成探索动作
```

架构：VLM 主干为 Qwen2.5-VL-3B-Instruct，动作由流匹配训练的动作扩散 Transformer 生成动作块——与 GR-3 一脉相承。

结果：GR-RL 被称为首个能把鞋带依次穿过多个鞋眼的学习型模型，整体成功率约 83.3%；相比监督学习的 GR-3（约 45.7%），提升近一倍。

意义：穿鞋带需要毫米级精度、双手协调、处理柔软的绳子、长时程多步骤——几乎集中了机器人操作的所有难点。GR-RL 与 PI 的 π*0.6（RECAP，2025.11）几乎同时出现，共同标志着 2025 年底”VLA + 真机 RL”从概念走向可用。两者的共同点是：都用一个”进度/价值模型”来判断数据好坏、指导改进。

4.2 Robix：机器人的”大脑”

> Seed 发布：*Robix*（2025.09）

Robix 是 Seed 推出的”机器人大脑”——一个把推理、任务规划与人机交互整合进单个端到端多模态模型的高层系统： - 理解复杂、模糊的人类指令（“我有点饿了”“帮我收拾一下”），并在不明确时主动提问澄清； - 把任务拆解为可执行的子任务，调用底层 VLA（如 GR-3）执行； - 在执行过程中根据反馈重新规划，处理用户中途改变主意等情况。

据报道，Robix-32B-RL 在所有评估集上排名第一，在两项跨领域测试中准确率分别领先 Gemini-2.5-Pro 约 11.8 与 3.0 个百分点。

Robix + GR-3/GR-RL 构成了字节的”大脑 + 小脑”体系，与 DeepMind 的”ER + VLA”、Figure 的”S2 + S1”同构。

---

5. 2026：从研究团队到”具身数据产线”

2026 年下半年（10 月下旬集中报道），字节 Seed 在官网与招聘平台更新了数十个机器人相关岗位，覆盖： - 本体设计、灵巧手、减速机与关节控制； - 仿真； - 数据算法工程师等。

行业分析认为： - 字节正在搭建一套可自我迭代的具身数据产线； - 其自研机器人的首要客户是 Seed 模型团队自己； - 在 2027 年底之前，设备大概率优先用于内部数据采集而非对外销售。

这一布局与特斯拉（自有工厂 + 自研本体）、Figure（BotQ + Index）、Generalist（数据工厂）的逻辑一致：在机器人大脑的竞争中，谁拥有可规模化、可迭代的数据产线，谁就拥有长期优势。

---

6. 技术路线总结

阶段	时间	范式	核心贡献
GR-1	2023.12	视频生成预训练 + 动作	首批证明视频预训练对操作有效
GR-2	2024.10	网络规模视频-语言-动作	3800 万视频片段，100+ 任务 97.7%
GR-3	2025.07	VLM + DiT 流匹配 VLA	协同训练 + VR 人类数据少样本 + ByteMini
Robix	2025.09	推理/规划/交互大脑	32B，超越 Gemini-2.5-Pro（部分测试）
GR-RL	2025.12	离线 RL 过滤 + 在线真机 RL	穿鞋带 83.3%（GR-3 为 45.7%）
2026	—	自研本体 + 数据产线	大规模硬件与数据团队扩张

---

7. 横向对比与身位

维度	字节 Seed	阿里达摩院（第 26 章）	蚂蚁灵波（第 27 章）	腾讯（第 28 章）
机器人大脑起步	2023（GR-1）	2025（Rynn 系列）	2026（LingBot）	2025（Tairos）

维度	字节 Seed	阿里达摩院（第 26 章）	蚂蚁灵波（第 27 章）	腾讯（第 28 章）
代表模型	GR-1/2/3、GR-RL、Robix	RynnVLA、RynnEC、RynnBrain	LingBot-VLA 1/2、LingBot-World	Tairos、RxBrain
自研本体	ByteMini（研究用）+ 扩张中	否	否	研究原型
开源	部分	积极开源	积极开源	部分
特色	视频预训练 + RL	具身大脑 + 时空记忆	大规模真机数据 + 世界模型	平台化

身位：字节 Seed 是中国大厂中学术积累最深、技术链最完整的机器人团队；在"真机 RL"方向与 PI 同步处于全球前沿。其短板是开放程度相对较低，且尚未形成对外的产品或平台。

---

8. 未来展望与风险

展望： 1. 视频生成能力的回流：字节在视频生成（Seedance 等）上的顶尖能力，可能催生更强的"世界动作模型"（类似 DreamZero）； 2. 自研机器人 + 数据产线：2027 年前后，字节可能拥有国内规模最大的内部具身数据产线之一； 3. 豆包生态的入口：Robix 等大脑能力与豆包助手的结合，可能让字节在家庭场景中拥有独特的交互入口。

风险： 1. 商业化路径不清：截至 2026 年 10 月，字节尚未公开机器人产品或对外平台； 2. 开放度较低：相比阿里、蚂蚁的积极开源，字节在开发者生态中的存在感较弱； 3. 组织优先级：机器人业务在字节内部的长期优先级，取决于其在大模型主战场之外的资源分配。

---

9. 延伸阅读与核验来源

- GR-1：ICLR 2024（arXiv 2312.13139）
- GR-2：arXiv 2410.06158
- GR-3：arXiv 2507.15493；Seed 博客
- GR-RL：arXiv 2512.01801；Seed 博客；Pandaily 报道
- Robix：腾讯新闻：字节 Seed 推出机器人大脑 Robix
- 2026 动态：腾讯新闻：字节 Seed 密集招聘机器人岗位；腾讯新闻：字节具身智能布局提速

> 核验说明：GR-1/GR-2 的方法、数据规模（3800 万视频片段、500 亿 token、100+ 任务 97.7%）来自原论文；GR-3 的主干（Qwen2.5-VL-3B）、DiT + 流匹配、VR 人类数据、ByteMini 来自技术报告与官方博客（约 40 亿参数为报告口径）；GR-RL 的三阶段流程、83.3% vs 45.7% 来自技术报告与媒体；Robix 的成绩来自字节发布的口径；2026 年招聘与"数据产线"分析来自媒体报道。

第 26 章 阿里巴巴（达摩院 + 通义千问）：中国具身大脑的”水电煤”与 RynnBrain

> 一句话定位：阿里在机器人大脑领域扮演着双重角色。其一，通义千问（Qwen）多模态模型是全球具身智能领域使用最广泛的 VLM 底座之一——小米 Xiaomi-Robotics-0（Qwen3-VL-4B）、宇树 UnifoLM-VLA-0（Qwen2.5-VL-7B）、字节 GR-3/GR-RL（Qwen2.5-VL-3B）、NVIDIA GR00T N1.7（Cosmos-Reason2，基于 Qwen3-VL 架构）、上海 AI Lab InternVLA-A1 等都以 Qwen 系列为母体，开源的 Wan2.1 视频模型更是 NVIDIA DreamZero 的主干。其二，达摩院具身智能实验室自研了一整套开源模型：WorldVLA（世界模型与动作模型融合）、RynnVLA-001（人类第一视角视频预训练）、RynnEC（世界理解）、RynnRCP（机器人上下文协议），以及 2026 年 2 月发布的具身大脑基础模型 RynnBrain（含业界首个 30B MoE 具身模型）。阿里的打法是：做中国具身产业的”水电煤”——底座模型、协议与开源大脑。

---

0. 速览卡片

维度	内容
机构	阿里巴巴达摩院具身智能实验室（负责人赵德丽）；通义实验室（Qwen、Wan）
底座贡献	Qwen2.5-VL / Qwen3-VL（大量 VLA 的 VLM 主干）；Wan2.1 视频生成模型（NVIDIA DreamZero 的主干）
达摩院代表工作	WorldVLA（2025.06）、RynnVLA-001-7B（2025.08）、RynnEC（2025.08）、RynnRCP（2025.08）、RynnBrain（2026.02.10 发布，技术报告 2026.02 arXiv 2602.14979）
开放程度	高：全部开源（GitHub、Hugging Face、ModelScope）
本章三篇代表作	① WorldVLA 与 RynnVLA-001：世界模型与人类视频预训练的 VLA ② RynnEC + RynnRCP：世界理解模型与机器人上下文协议 ③ RynnBrain：时空记忆与物理接地的具身大脑基础模型
身位	全球最重要的具身 VLM/视频底座提供者之一；达摩院自研模型在”具身大脑”开源赛道位于国内前列

---

1. 故事的开端：Qwen 如何成为机器人的”眼睛”

2024–2025 年，全球 VLA 团队在选择 VLM 主干时面临一个现实问题：PaliGemma 太小、LLaVA 系列空间能力弱、GPT-4o/Gemini 闭源。Qwen2-VL / Qwen2.5-VL 恰好填补了空白： - 开源且许可宽松； - 多种规模（2B/3B/7B/32B/72B），便于在端侧与云端之间取舍； - 原生动态分辨率（支持任意长宽比、高分辨率图像），对机器人多相机输入友好； - 强大的 grounding 能力（输出物体框、点坐标），这正是机器人最需要的”指哪打哪”能力。

结果是，到 2026 年，Qwen 系列已经成为中国乃至全球大量 VLA 的”默认眼睛”。阿里本身不必做出最强的 VLA，就已经深度嵌入了整个具身产业。

在此基础上，达摩院于 2025 年开始系统性地发布自研具身模型。

---

2. 代表作一：WorldVLA 与 RynnVLA-001（2025）——让 VLA 学会”预测世界”与”看人做”

2.1 WorldVLA（2025.06）：世界模型与动作模型的自回归统一

> 论文：*WorldVLA: Towards Autoregressive Action World Model*（达摩院等，arXiv 2506.21539）

核心思想：把两个模型放进同一个自回归框架： - 动作模型（VLA）：给定图像与指令，预测动作； - 世界模型：给定图像与动作，预测下一帧图像。

两者共享同一套图像/文本/动作 token 化与 Transformer 主干——模型从 Chameleon（一个统一图像理解与生成的离散 token 模型）初始化，相互促进：世界模型迫使模型理解”动作的物理后果”，从而帮助动作预测；动作模型帮助世界模型理解”什么样的视觉变化对应什么样的动作”。

一个关键技术细节：自回归生成动作块时，后面的动作会依赖前面已生成的动作，一旦前面出错，错误会传播。WorldVLA 提出一种动作注意力掩码：每个动作 token 只关注文本与视觉输入，不关注之前生成的动作 token——这既阻断了错误传播，也使动作块可以并行生成；世界模型部分仍保留标准因果掩码。

LIBERO 上的关键数字（论文报告）： - 不加掩码时，常规自回归分块会使抓取成功率下降 10%–50%；加入动作掩码后恢复 4%–23%； - 统一模型相比同主干的纯动作模型抓取成功率高约 4%；相比纯世界模型，生成视频的 FVD（Fréchet 视频距离）降低约 10%——即两种能力确实相互促进； - 二手综述称其在 512×512 分辨率、无大规模机器人预训练的条件下，LIBERO 平均成功率约 81.8%（对比 OpenVLA 约 76.5%），未在论文原文中核实。

意义：WorldVLA 是国内较早把”世界模型 + VLA 统一”做成开源模型的工作之一，比 2026 年的”世界动作模型”热潮早了半年以上。

2.2 RynnVLA-001-7B（2025.08）：从人类第一视角视频中学习

> 2025 年 8 月世界机器人大会开源；论文 *RynnVLA-001: Using Human Demonstrations to Improve Robot Manipulation*。

> 论文：*RynnVLA-001: Using Human Demonstrations to Improve Robot Manipulation*（arXiv 2509.15212，2025.09）；模型为从 Chameleon 文生图架构扩展而来的自回归 Transformer。

三阶段训练： 1. 第一视角视频生成预训练：在大规模人类第一视角操作视频上，训练一个”图像到视频”的生成模型——学习”手如何操作物体”的视觉动态； 2. 以人为中心的轨迹感知建模：在视频生成的基础上，让模型同时预测人手关键点的未来轨迹——把”视觉动态”与”动作轨迹”联系起来； 3. 机器人动作微调：迁移到机械臂上，预测机器人动作。

数据规模与清洗：第一阶段在约 1200 万条第一视角操作视频上训练”图像到视频”模型（以初始帧与语言指令为条件预测未来帧）；视频用姿态估计筛选——保留手与手腕可见的帧、剔除出现人脸关键点的帧（保证”操作视角”并兼顾隐私）。

ActionVAE：用变分自编码器把动作块压缩为紧凑的潜在向量，降低 VLA 输出空间的复杂度；人类轨迹与机器人动作分别训练各自的 ActionVAE，在 VLA 训练与推理时冻结。评测在自建的 SO100 机械臂环境中进行（因此不能与 LIBERO 成绩直接比较）。

意义：RynnVLA-001 是”人类视频 → 机器人”路线的又一个开源实现，与港大 UniVLA、北大 Being-H0、UCSD HAT 等工作同期，体现了 2025 年中国学界与产业界对”人类数据”的集体押注。

---

3. 代表作二：RynnEC 与 RynnRCP（2025.08）——世界理解与机器人”上下文协议”

3.1 RynnEC：具身的”世界理解”模型

RynnEC 是一个面向具身场景的多模态理解模型，能力包括：- 从位置、功能、数量等 11 个维度解析场景中的物体（例如”这个杯子在桌子左侧、可以装水、桌上有 3 个”）；- 仅凭视频序列建立连续的空间感知（不依赖深度相机或 3D 重建）——机器人在移动中逐步构建对环境的理解。

它的定位类似 Gemini Robotics-ER、RoboBrain：一个”看懂物理世界”的具身认知模型。

3.2 RynnRCP：机器人的”MCP”

RynnRCP（Robot Context Protocol，机器人上下文协议）是阿里借鉴大模型领域 MCP（Model Context Protocol）思想提出的机器人协议，包含两个模块：- RCP 框架：标准化数据、模型与机器人之间的接口——让不同厂商的机器人、不同来源的数据、不同的模型可以”即插即用”；- RobotMotion：把模型输出的低频、离散的推理命令，转换为机器人所需的高频、连续的控制信号（并处理平滑、安全约束）。

意义：RynnRCP 反映了阿里作为”平台型公司”的思维——在模型之外，定义接口与协议。如果它被广泛采用，阿里将在具身生态中占据类似”操作系统接口”的位置。这与智源 RoboOS（第 24 章）、逐际 COSA（第 35 章）在不同层面形成竞争与互补。

---

4. 代表作三：RynnBrain（2026.02）——时空记忆与物理接地的具身大脑

> 论文：*RynnBrain: Open Embodied Foundation Models*（arXiv 2602.14979，2026-02-13 提交，技术报告 2026-02-15 发布）；2026 年 2 月 10 日发布；GitHub alibaba-damo-academy/RynnBrain。

4.1 模型家族

模型	类型	用途
RynnBrain-2B	稠密	端侧部署
RynnBrain-8B	稠密	通用
RynnBrain-30B-A3B	MoE（总参数 30B，激活约 3B）	业界首个 MoE 架构的 30B 具身模型

模型	类型	用途
RynnBrain-Plan	后训练	机器人任务规划
RynnBrain-Nav	后训练	视觉语言导航
RynnBrain-CoP	后训练	点链（Chain-of-Point）推理

（媒体报道”一次性开源 7 个全系列模型”，不同媒体对数量的表述略有差异。）

4.2 两大核心能力

（1）时空记忆（Spatio-temporal Memory）

RynnBrain 在预训练中重点学习对空间、位置、事件、轨迹的多维表征，并在整个情景记忆（episodic memory）中进行定位与预测。一个直观的例子（来自媒体报道）：机器人在执行任务 A 时被打断、转去做任务 B，它能记住任务 A 的时空状态（做到哪一步、东西放在哪），完成 B 后接着做 A。

这正对应了 PI MEM（多尺度记忆）所解决的”长任务忘事”问题——不同的是，RynnBrain 把记忆能力放在”大脑”（推理模型）中，而 MEM 放在 VLA 中。

（2）物理世界接地（Physical World Grounding）

模型能在整个情景记忆中定位物体、目标区域，甚至预测轨迹——即”指出”物理世界中的具体位置，并给出机器人可用的坐标与路径。

4.3 训练

- 基于 Qwen3-VL 训练；
- 使用自研的 RynnScale 训练框架——一个负载均衡的时空训练框架，论文称在相同算力预算下训练效率约提升 2 倍；
- 预训练数据约 2000 万对高质量具身训练样本。

4.4 RynnBrain-Bench 与结果

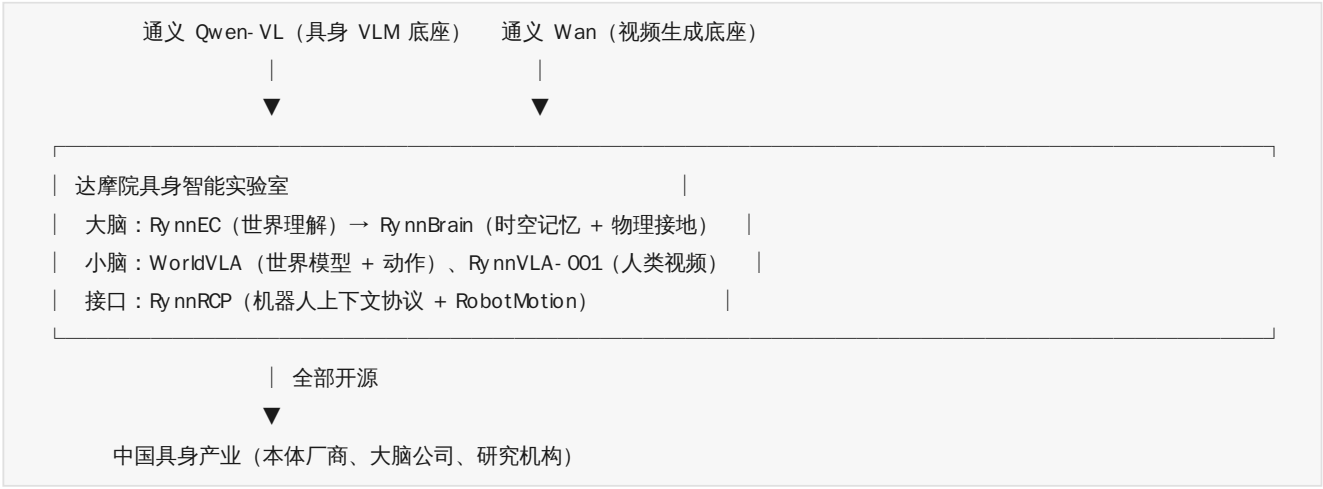
- 配套发布 RynnBrain-Bench：覆盖 21 项细粒度具身能力，包括物体认知、空间认知、接地与指点（在完整情景记忆范围内）；
- 阿里称 RynnBrain 在 16 项具身开源评测上刷新最优，超越 Gemini Robotics-ER 1.5 与 NVIDIA Cosmos Reason 2 等模型（阿里官方口径，尚无独立验证）；
- 第三方综述提到 RynnBrain-CoP-8B 在具身基准上平均约 73.8 分，30B-A3B 在 EgoTaskQA 上提升约 10.5%（二手数据）。

4.5 定位：大小脑分层中的”大脑”

达摩院具身智能实验室负责人赵德丽表示，RynnBrain 是实现大小脑分层架构下通用具身智能的关键一步。也就是说，阿里的路线是：- 大脑：RynnBrain（时空记忆、物理接地、规划、导航）；- 小脑：RynnVLA 等动作模型，或各本体厂商的控制器；- 接口：RynnRCP 协议。

---

5. 技术路线总结



---

6. 横向对比与身位

维度	阿里（达摩院 + Qwen）	字节 Seed	蚂蚁灵波	腾讯
底座影响力	最强（Qwen-VL、Wan 被广泛采用）	中	中	中（混元）
自研具身模型	开源大脑 + VLA + 协议	GR 系列（部分开源）	LingBot 系列（开源）	Tairos 平台、RxBrain
开源力度	高	中	高	中
特色	协议化、生态化	视频预训练 + RL	大规模真机数据 + 世界模型	平台化 + 合作

身位： - 作为”具身底座提供者”，阿里在全球都处于第一梯队——这一影响力常被低估； - 达摩院自研的 RynnBrain 在”具身推理大脑”开源赛道与智源 RoboBrain、上海 AI Lab InternVLA-M1 构成国内三强； - 阿里本身不做机器人本体，其商业价值更多通过云计算（训练与推理算力）、生态投资实现。

---

7. 未来展望与风险

展望： 1. Qwen 与 Wan 的持续升级：每一代 Qwen-VL / Wan 的进步，都会通过”底座效应”传导到大量 VLA 与世界模型； 2. RynnRCP 的标准化：若协议被广泛采用，阿里将在具身生态中掌握接口话语权； 3. 云 + 具身：具身模型训练与推理的算力需求，将成为阿里云的新增长点。

风险： 1. “底座被用、价值被别人拿走”：开源底座的商业回报有限，具身应用价值主要由本体与应用公司获取； 2. 地缘与合规：海外公司使用中国开源模型（如 Qwen）可能面临合规审查； 3. 大脑与小脑的接口之争：RoboOS、COSA、RCP 等多个协议并存，标准尚未统一。

---

8. 延伸阅读与核验来源

- WorldVLA：arXiv 2506.21539

- RynnVLA-001 / RynnEC / RynnRCP：IT之家报道；CSDN：达摩院开源 RynnVLA-001、RynnEC、RynnRCP
- RynnBrain：arXiv 2602.14979；Hugging Face Papers；GitHub alibaba-damo-academy/RynnBrain；IT之家：RynnBrain 发布；国家科技创新信息：RynnBrain

> 核验说明：WorldVLA 的注意力掩码策略来自论文；RynnVLA-001 的三阶段训练与 ActionVAE 来自论文与官方介绍；RynnEC 的"11 个维度"与 RynnRCP 的两模块结构来自官方发布；RynnBrain 的模型家族（2B/8B/30B-A3B 及三个后训练模型）、Qwen3-VL 底座、RynnScale 约 2 倍效率、约 2000 万对数据、RynnBrain-Bench 21 项能力来自技术报告与仓库；"16 项评测 SOTA、超越 Gemini Robotics-ER 1.5 与 Cosmos Reason 2"为阿里官方口径；部分细分成绩为二手数据。补充核验：WorldVLA 的 Chameleon 初始化、动作注意力掩码（并行生成动作块）、LIBERO 上 -10%~-50% / +4%~+23% / 抓取 +4% / FVD -10% 来自论文与二手综述（81.8% vs 76.5% 未在原文核实）；RynnVLA-001（arXiv 2509.15212）的约 1200 万条第一视角视频、姿态估计清洗、人/机分别训练的 ActionVAE、SO100 评测来自论文摘要。

第 27 章 蚂蚁集团·灵波科技（Robbyant）：后来者的”全栈开源”突袭——LingBot 系列

> 一句话定位：蚂蚁集团的具身智能子公司灵波科技（Robbyant）是 2026 年中国具身领域最大的”黑马”之一。它在 2026 年 1 月下旬的”具身进化周”中一口气开源了三款基座模型——高精度空间感知模型 LingBot-Depth、基于 2 万小时真机数据的 LingBot-VLA、可实时交互的世界模型 LingBot-World；7 月又发布 LingBot-VLA 2.0（6 万小时真机数据、覆盖 17 家厂商 20 多种构型）与 LingBot-World 2.0（720p/60fps 连续生成长达约一小时）。灵波的路线可以概括为”深度感知 + 大规模真机数据 VLA + 交互式世界模型”三位一体、全部开源——以一种”后来者全栈突袭”的姿态，直接对标 π0.5 与 NVIDIA Cosmos。

0. 速览卡片

维度	内容
机构	蚂蚁集团具身智能子公司”灵波科技（Robbyant）”
时间线	2026.01 下旬”具身进化周”：LingBot-Depth、LingBot-VLA（1.0）、LingBot-World（1.0，01.28 技术报告 / 01.29 发布）→ 2026.07：“全栈 2.0”：LingBot-VLA 2.0（07.08 开源）、LingBot-World 2.0
开放程度	高：代码 GitHub 开源，权重发布于 Hugging Face 与 ModelScope；LingBot-World 为 Apache-2.0 许可
生态	LingBot-VLA 2.0 支持 17 家主流机器人厂商的 20 多种构型
本章三篇代表作	① LingBot-VLA 1.0 → 2.0：大规模多构型真机数据训练的 VLA ② LingBot-World 1.0 → 2.0：开源实时交互世界模型 ③ LingBot-Depth：面向具身的高精度深度感知（作为 VLA 2.0 的默认组件）
身位	2026 年中国开源具身基座的重要力量；“真机数据规模 + 世界模型 + 开源”组合在国内领先

1. 故事的开端：一家金融科技集团为什么做机器人？

蚂蚁集团做具身智能，乍看令人意外。但从蚂蚁的技术积累看，有其逻辑： - 大模型能力：蚂蚁自研了百灵（Ling）系列大模型（LingBot 的命名即来源于此）； - 场景：支付、生活服务、医疗健康（蚂蚁旗下的医疗与养老服务）等线下场景，对服务型机器人有潜在需求； - 资本与耐心：具身智能需要长周期投入，蚂蚁有能力进行”全栈布局”。

灵波的策略是”后发先至”：不在 VLA 赛道的早期与 PI、字节等正面竞争，而是在 2026 年以一次性开源三款基座模型的方式进入，并迅速以”超越 π0.5”的评测结果建立声誉。

2. 代表作一：LingBot-VLA 1.0 → 2.0——大规模多构型真机数据的 VLA

2.1 LingBot-VLA 1.0（2026.01）

维度	内容
预训练数据	约 2 万小时多构型真机数据
本体覆盖	9 种主流双臂机器人构型
迁移效率	据称仅需约 150 条演示即可高质量迁移到新任务
训练效率	训练效率为主流框架的 1.5–2.8 倍（官方口径）
开源	代码 GitHub，权重 Hugging Face / ModelScope

评测： - GM-100（上海交通大学开源的 100 项真实操作任务基准）：在 3 个不同的真实机器人平台上，跨本体泛化平均成功率从 π0.5 的 13.0% 提升到 15.7%（不使用深度）；加入深度信息后达到 17.3%； - RoboTwin 2.0（50 项任务）：相比 π0.5 的操作成功率提升约 9.92%。

解读：GM-100 上的绝对成功率（13%–17%）非常低——这恰恰说明了跨本体零样本泛化在 2026 年初仍是极难的问题。灵波的贡献在于：在同一困难基准上相对 π0.5 有可测量的提升，并且深度信息（LingBot-Depth）带来了额外收益。

2.2 LingBot-VLA 2.0（2026.07.08）

维度	1.0	2.0
预训练真机数据	约 2 万小时	约 6 万小时
覆盖构型	9 种双臂	17 家厂商、20 多种构型
自由度	双臂	扩展头部、腰部、末端执行器与移动底盘的自由度支持
深度	可选	默认融合 LingBot-Depth
能力	桌面双臂操作	新增移动操作等
推理	—	高效后训练版本在 RTX 4090 上推理耗时可控制在 130 毫秒以内

6 万小时意味着什么：这是 2026 年中公开的、以机器人本体数据为主的开源 VLA 预训练规模中最大的之一（对比：π0 约 1 万小时、AgiBot World 约 3000 小时、LingBot 1.0 约 2 万小时）。注意它与 Generalist（50 万小时+）的区别：Generalist 主要是人类交互数据，而 LingBot-VLA 2.0 强调的是多品牌、多构型的真实机器人数据。

“17 家厂商、20 多种构型”的生态意义：灵波通过与大量本体厂商合作收集数据、并让模型原生支持这些构型，实际上在构建一个”开源跨本体大脑 + 本体厂商联盟”的生态——这与 NVIDIA GR00T（本体专属编解码器）、Gemini Robotics（Motion Transfer）的跨本体思路一致，但以开源方式推进。

（注：截至检索时，公开报道未明确披露 LingBot-VLA 的 VLM 底座与动作生成方式的细节，技术报告见 GitHub 仓库 lingbot-vla-v2，本章不做推测。）

---

3. 代表作二：LingBot-World 1.0 → 2.0——开源的实时交互世界模型

3.1 LingBot-World 1.0（2026.01.28–29）

> 技术报告：*Advancing Open-source World Models*（arXiv 2601.20540，2026-01-28）；Business Wire 新闻稿（2026-01-29）。

定位：一个"源自视频生成的开源世界模拟器"，面向具身智能、自动驾驶与游戏开发。

技术底座与训练： - 代码库基于阿里通义 Wan2.2（约 14B 的图生视频扩散主干）构建——又一个"阿里底座被广泛采用"的例子（参见第 26 章）； - 多阶段训练：以 Wan2.2 为起点预训练 → 中期训练 → 后训练为因果自回归生成——把"被动的视频合成"改造为"可交互、因果一致的世界模拟"； - 可扩展数据引擎：覆盖数据获取、画像（profiling）与描述标注，支撑动作条件化训练。

能力： - 从一张真实世界图像或游戏截图出发，生成可交互的视频流，无需针对特定场景训练； - 生成吞吐约 16 FPS，端到端交互延迟 小于 1 秒； - 可实现近 10 分钟连续稳定的生成（据报道）； - 提供 Base（Cam，相机位姿条件化）、Base（Act，动作条件化） 与 Fast 加速版，各有 480P 与 720P 两种分辨率（二手资料称 Fast 版在 A100 级 GPU 上 480P 约 16 FPS、每帧约 62 毫秒）； - Apache-2.0 许可。

与 Genie 3 的对比：Google DeepMind 的 Genie 3（2025.08）是同类"实时交互世界模型"的标杆（720p、24fps、数分钟一致性），但闭源。LingBot-World 以开源方式提供了类似能力，是中国开源世界模型的代表之一。

3.2 LingBot-World 2.0（2026.07）

- 支持以 720p、60fps 连续生成长达约一小时；
- 采用因果预训练方法与一种称为 MoBA（Mask of Bidirectional Attention） 的机制；
- 支持多用户共享一个持久世界；
- 首日即支持 SGLang 推理框架；
- 支持更多动作与事件（据报道）。

3.3 世界模型在灵波体系中的角色

在具身场景中，LingBot-World 可以承担： 1. 策略评估器：在世界模型中闭环测试 LingBot-VLA，替代部分真机评测； 2. 数据生成器：生成多样化场景，扩充训练数据； 3. 强化学习训练场：在可交互的世界模型中进行 RL。

这与 1X（世界模型评估）、特斯拉（神经世界模拟器）、它石 AWE 3.5（在模型内部世界中 RL）的思路一致。

---

4. 代表作三：LingBot-Depth——具身的"深度眼睛"

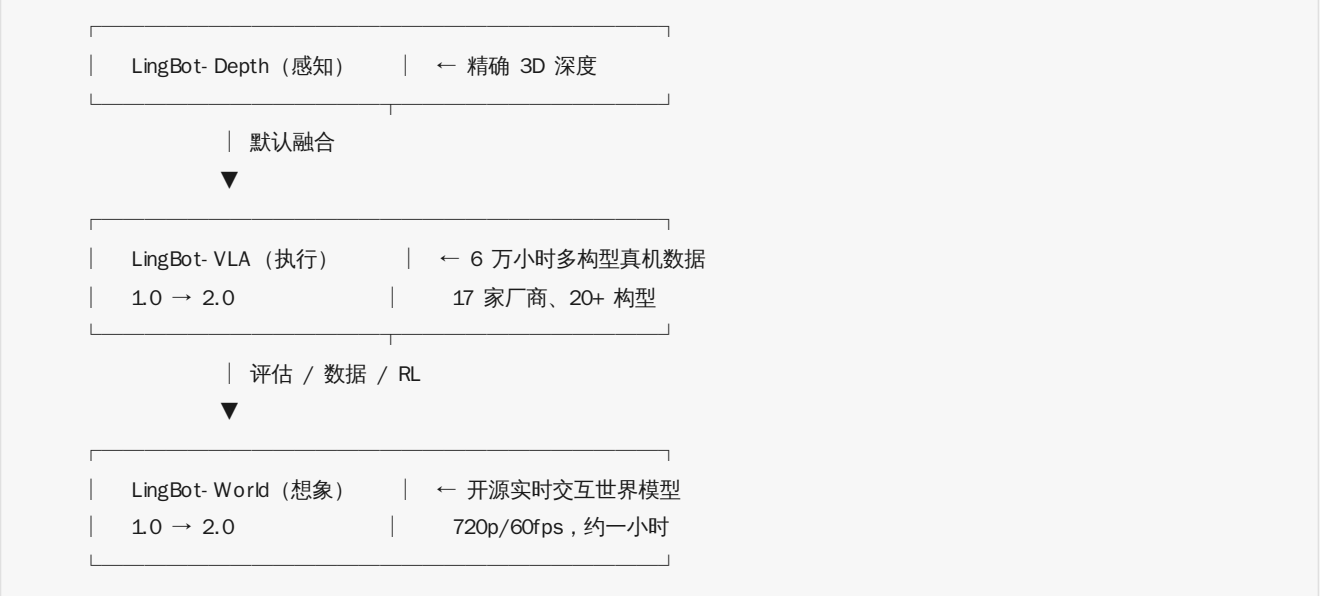
LingBot-Depth 是灵波在"具身进化周"中发布的高精度空间感知模型，用于为机器人提供精确的深度信息。公开技术细节较少，但从其在体系中的作用可以看出其价值： - 在 LingBot-VLA 1.0 的 GM-100 评测中，加入深度信

息使跨本体平均成功率从 15.7% 提升到 17.3%； - 在 LingBot-VLA 2.0 中被默认融合。

为什么深度重要：多数 VLA 只使用 RGB 图像，依赖模型从 2D 图像中"猜"深度；而精细操作（抓取、插入、放置）对三维位置精度极其敏感。这与智源 RoboBrain 2.5 强调"3D 度量空间推理"、HF LeRobot v0.6 加入"深度数据支持"属于同一趋势：2026 年，具身大脑正在从"2D 看图"走向"3D 度量"。

---

5. 技术路线总结：三位一体



灵波的特色：感知、执行、想象三个基座同时开源，且版本节奏整齐（1 月 1.0、7 月 2.0）——这是一种以"开源生态"换取影响力与合作伙伴数据的策略。

---

6. 横向对比与身位

维度	蚂蚁灵波	PI（π0.5 开源）	NVIDIA（GR00T + Cosmos）	阿里达摩院
VLA 预训练数据	6 万小时多构型真机	约 1 万小时+（π0）	金字塔（合成为主）	人类视频 + 机器人
世界模型	LingBot-World（开源）	用于子目标生成（π0.7）	Cosmos（开源）	WorldVLA
深度感知	LingBot-Depth	无专门模型	—	—
开源	全部开源	上一代开源	开源	开源
跨本体	17 家 20+ 构型	多本体	本体专属编解码器	—

身位：灵波在 2026 年迅速跻身中国开源具身基座的第一梯队，其 VLA 预训练的真机数据规模、世界模型的开源完整度都处于国内领先；但作为新进入者，其模型在大规模真实商业部署中的表现尚待验证。

---

7. 未来展望与风险

展望： 1. 数据联盟：若持续扩大与本体厂商的合作，LingBot-VLA 的数据规模可能继续快速增长； 2. 世界模型 + VLA 闭环：用 LingBot-World 做 VLA 的大规模评估与 RL，可能形成独特的"仿真-真实"迭代体系； 3. 蚂蚁的场景：医疗、养老、生活服务等场景可能成为灵波模型的首批落地方向。

风险： 1. 评测的绝对水平：GM-100 上 15%–17% 的成功率说明跨本体泛化仍很初级，开源模型的实用性需要更多真实部署验证； 2. 商业模式：全面开源的商业回报路径尚不清晰； 3. 竞争激烈：同时面对阿里、字节、智元、宇树等的开源模型竞争。

---

8. 延伸阅读与核验来源

- LingBot-VLA 1.0：阿里云开发者社区：LingBot-VLA 全面开源；智源社区
- LingBot-VLA 2.0：量子位；凤凰网；21 经济网
- LingBot-World：arXiv 2601.20540；Business Wire；Hugging Face：lingbot-world-fast
- LingBot-World 2.0：IT Brief

> 核验说明：LingBot-VLA 1.0 的 2 万小时、9 种构型、GM-100（13.0%→15.7%/17.3%）与 RoboTwin 2.0（+9.92%）来自官方开源报道；2.0 的 6 万小时、17 家 20+ 构型、130 毫秒推理来自多家媒体一致报道；LingBot-World 1.0 的 16 FPS、<1 秒延迟、arXiv 编号与许可证来自技术报告与模型卡；2.0 的一小时/720p/60fps/MoBA 来自 IT Brief 报道；LingBot-Depth 公开技术细节有限；LingBot-VLA 的 VLM 底座与动作头未见公开报道，本章未作推测。补充核验：LingBot-World 基于 Wan2.2 构建、多阶段训练（预训练→中期训练→因果自回归后训练）与 Cam/Act/Fast 版本来自 GitHub README、Hugging Face 模型卡与技术报告摘要；"A100 上 480P 约 16 FPS、每帧约 62 毫秒"为二手资料。

第 28 章 腾讯（Robotics X + 混元）：不造机器人，做”机器人的大脑供应商”——Tairos 与 Hy-Embodied 家族

> 一句话定位：腾讯在具身智能上的战略可以用一句话概括——“为机器人提供动力，而不是制造机器人（至少目前如此）”。它以 Robotics X 实验室（张正友领导）与混元大模型团队为核心，2025 年 7 月推出模块化具身智能开放平台 Tairos（钛螺丝），2026 年密集发布了 HY-Embodied-0.5（具身基础 VLM，4 月）、HyVLA-0.5（端到端操作 VLA，6 月）以及 WAIC 2026 上的”感知-认知-行动”三件套：Hy-Embodied-VLM-1.0、Hy-Embodied-RxBrain-1.0（基于 5 万小时以上具身数据的”具身世界认知基座模型”，结合语言推理与视觉想象）与 Hy-Embodied-VLA-0.5。腾讯的打法是平台化 + 开源 + 与本体厂商战略合作（如 2026 年 1 月与宇树的合作）。

0. 速览卡片

维度	内容
机构	腾讯 Robotics X 实验室（负责人张正友，2018 年成立）；腾讯混元大模型团队（HY）
平台	Tairos（2025.07.27 WAIC 发布，与福田实验室联合；模块化提供大模型、开发工具与数据服务；2026 年 WAIC 升级）
2026 模型	HY-Embodied-0.5（2026.04，arXiv 2604.07430）；HyVLA-0.5（2026.06）；Hy-Embodied-VLM-1.0 / RxBrain-1.0 / VLA-0.5（2026.07 WAIC）；TairosAgent 框架、Apexio 智能体
研究原型	Ollie（轮腿机器人）、Max（四足）、灵巧手等
合作	2026 年 1 月与宇树科技战略合作（文旅、商场、展厅等场景落地）；与多家本体厂商合作
开放程度	中高：HY-Embodied 系列与 RxBrain 权重开源（Hugging Face / GitHub）；Tairos 为商业平台
本章三篇代表作	① Tairos：模块化具身智能开放平台 ② HY-Embodied-0.5 与 HyVLA-0.5：具身基础 VLM 与端到端 VLA ③ Hy-Embodied-RxBrain-1.0：结合语言推理与视觉想象的具身世界认知模型
身位	中国大厂中”平台化”路线最典型的代表；模型能力处于国内第一梯队的追赶位置

1. 故事的开端：Robotics X 的”长期主义”

2018 年，腾讯成立 Robotics X 实验室，由前微软研究院首席研究员、计算机视觉领域著名学者张正友领导（“张正友标定法”是相机标定的经典方法）。Robotics X 早期的研究以硬件与运动控制为主： - Ollie：轮腿结合的平衡机器人，能跳跃、翻滚； - Max：四足机器人； - 灵巧手、触觉传感等。

这些原型展示了腾讯在机器人"身体"上的研究能力，但腾讯从未把它们产品化。2023 年后，随着大模型兴起，Robotics X 与混元团队合作，把重心转向"具身大脑"。

腾讯的战略判断是：中国已经有宇树、智元、优必选等大量优秀的本体厂商，腾讯的比较优势在于大模型、云计算与平台运营——因此应该做"机器人的大脑与平台"，而非与本体厂商竞争。

---

2. 代表作一：Tairos（2025.07）——模块化具身智能开放平台

> 发布：2025 年 7 月 27 日，世界人工智能大会（WAIC 2025），腾讯 Robotics X 与福田实验室联合发布。

2.1 平台构成

Tairos 被称为国内首个以模块化方式提供大模型、开发工具和数据服务的具身智能软件平台：

层级	内容
模型层	多模态感知模型、规划大模型、感知行动联合大模型
云服务层	仿真平台、数据平台、开发工具
接口	标准化接口与 SDK，供本体厂商与开发者调用

2.2 模块化的逻辑

与 PI、Figure 等"端到端单一大模型"路线不同，Tairos 选择模块化： - 本体厂商可以按需选用：只用感知模型、只用规划模型、或使用全套； - 不同模块可以独立升级； - 降低本体厂商接入大模型的门槛。

这种设计反映了腾讯对中国具身产业现状的判断：大多数本体厂商需要的是"可快速集成的能力组件"，而不是一个需要从头适配的黑盒大模型。

2.3 意义

Tairos 让腾讯在具身领域有了一个商业化的平台载体，并通过 2026 年 1 月与宇树的战略合作（推动宇树机器人在文旅景区、商场、企业展厅等场景落地）获得了真实部署场景。

---

3. 代表作二：HY-Embodied-0.5 与 HyVLA-0.5（2026.04–06）——基础 VLM 与端到端 VLA

3.1 HY-Embodied-0.5（2026.04）

> 论文：*HY-Embodied-0.5: Embodied Foundation Models for Real-World Agents*（腾讯 Robotics X 与混元视觉团队，arXiv 2604.07430）；权重开源于 Hugging Face（tencent/HY-Embodied-0.5）。

- 定位：面向真实世界智能体的具身基础视觉语言模型家族；
- 两档规模：
  - MoT-2B：激活约 2B、总参数约 4B 的高效版本，面向端侧部署（权重已开源）；
  - MoE-A32B：激活约 32B、总参数约 4070 亿的大模型，面向复杂推理；

- 架构要点：
  - 混合 Transformer（MoT）：为不同模态提供专门的计算路径；
  - 潜在 token（latent tokens）：增强感知表征；
  - 视觉编码器为原生分辨率的 HY-ViT 2.0（为端侧优化）；
- 训练：迭代式、自我演化的推理后训练范式 + 在策略蒸馏（on-policy distillation）——把大模型的能力迁移给 2B 小模型；
- 评测（腾讯自报）：在 22 个基准上，A32B 平均 67.0%，超过 Gemini 3.0 Pro（63.6%）；MoT-2B 在其中 16 个基准上优于同尺寸最优模型（例如 CV-Bench 89.2，对比 Qwen3-VL-2B 的 80.0）；
- 作为 Tairos 的感知与推理底座，提供场景理解、空间推理、任务规划等能力。

3.2 HyVLA-0.5（2026.06）

据二手报道（单一来源），HyVLA-0.5（Hy-Embodied-0.5-VLA） 于 2026 年 6 月中旬发布，是一个端到端操作 VLA： - 训练数据强调亚毫米级精度的 UMI 式手持采集数据； - 结合真机强化学习； - 目标是大幅减少对重度遥操作数据的依赖； - 报道称在仿真与真机任务上成功率超过 90%。

解读：“UMI 式数据 + 真机 RL”的组合，与清华 RDT2（UMI 数据）、PI π*0.6（真机 RL）、字节 GR-RL（真机 RL）一致，说明腾讯的 VLA 路线紧跟 2025–2026 年的全球前沿配方。

---

4. 代表作三：Hy-Embodied-RxBrain-1.0（2026.07）——“具身世界认知基座模型”

> 发布：WAIC 2026（2026 年 7 月中旬，报道日期 7 月 15–23 日不等）；权重：Hugging Face tencent/Hy-Embodied-RxBrain-1.0；GitHub Tencent-Hunyuan/Hy-Embodied-RxBrain-1.0。

4.1 “感知-认知-行动”三件套

WAIC 2026 上，腾讯把具身模型家族重新组织为三个层次：

层次	模型	职责
感知	Hy-Embodied-VLM-1.0	场景理解
认知	Hy-Embodied-RxBrain-1.0	世界认知：推理 + 想象 + 规划
行动	Hy-Embodied-VLA-0.5	动作执行

并同时发布了 TairosAgent 框架与 Apexio 智能体。（据社区资料，这一系列以 Apache 2.0 许可开源。）

4.2 RxBrain 的核心能力：语言推理 + 视觉想象

RxBrain 被定位为”具身世界认知基座模型”，其独特之处在于把两种”思考方式”结合在一个模型中：

1. 语言推理：对图像与视频进行问答与推理，理解场景、物体与任务；
2. 视觉想象：
   - 预测执行某个动作后的近未来画面（一种轻量的世界模型能力）；
   - 把任务分解为多个步骤，并为每一步生成”目标场景图像”——即”用语言拆解任务步骤，同时生成每一步完成后场景应该是什么样”。

```
用户："把桌子收拾干净"
        |
        ▼
RxBrain：
  步骤 1："把杯子放进水槽"      → [生成：杯子在水槽中的目标图像]
  步骤 2："把盘子摞起来"        → [生成：盘子摞好的目标图像]
  步骤 3："擦桌面"              → [生成：干净桌面的目标图像]
        |
        ▼
Hy-Embodied-VLA：以"文字子任务 + 目标图像"为条件执行每一步
```

4.3 与 π0.7 的对比

这一设计与 PI 的 π0.7（第 2 章）有惊人的相似性：π0.7 也用一个世界模型（以 BAGEL 初始化）生成"子目标图像"，作为 VLA 的多模态提示。区别在于： - π0.7：子目标图像生成器是一个独立的世界模型，与 VLA 异步运行； - RxBrain：把语言规划与目标图像生成放在同一个认知模型中，再交给独立的 VLA 执行。

腾讯称 RxBrain 是"混合式世界模型与规划器"，而非纯视觉世界模型。这代表了 2026 年具身大脑设计的一个重要趋势：用"图像化的子目标"作为大脑与小脑之间的接口——比纯文字更精确、比潜在向量更可解释。

4.4 训练数据

RxBrain 基于 5 万小时以上高质量具身数据训练。截至发布时，RxBrain-Bench 基准与 VQA/生成任务的微调代码仍在待发布列表中。

---

5. 技术路线总结

```
2018–2023  Robotics X：硬件与运动控制原型（Ollie、Max、灵巧手）
    ↓
2025.07    Tairos 平台：模块化（感知 / 规划 / 感知行动联合）
    ↓
2026.01    与宇树战略合作：场景落地
    ↓
2026.04    HY-Embodied-0.5：具身基础 VLM（2B / 32B 激活）
    ↓
2026.06    HyVLA-0.5：UMI 数据 + 真机 RL 的端到端 VLA
    ↓
2026.07    感知-认知-行动三件套：VLM-1.0 / RxBrain-1.0 / VLA-0.5 + TairosAgent
```

---

6. 横向对比与身位

维度	腾讯	阿里	字节	京东
战略	平台化，“给机器人供大脑”	底座 + 开源大脑 + 协议	自研全栈 + 数据产线	“给机器人供能力”（同类）

维度	腾讯	阿里	字节	京东
代表模型	Tairos、HY-Embodied、RxBrain	Qwen-VL、RynnBrain	GR-3、GR-RL、Robix	—
本体	不造（研究原型）	不造	自研（内部）	不造
合作	宇树等	生态广泛	内部为主	—

身位：腾讯在中国大厂具身布局中属于”平台派”的代表；其 2026 年的模型发布节奏密集、开源力度增强，但在学术影响力与公开评测上仍落后于字节 Seed 与阿里达摩院。

---

7. 未来展望与风险

展望： 1. “子目标图像”接口的标准化：若 RxBrain 的”文字 + 目标图像”规划方式被验证有效，可能成为腾讯 Tairos 平台的核心差异化能力； 2. 生态合作的放大：通过与宇树等头部本体厂商的合作，腾讯的大脑可能获得大规模部署机会； 3. 微信/小程序生态：腾讯的社交与服务生态可能成为服务型机器人的交互入口。

风险： 1. 平台路线的”被替代”风险：若本体厂商自研大脑能力足够强（如智元、宇树均已推出自有基座模型），平台型大脑的需求可能下降； 2. 评测透明度：缺乏在公共基准上的系统性对比； 3. 组织协同：Robotics X 与混元团队的协同效率，决定了其模型迭代速度。

---

8. 延伸阅读与核验来源

- Tairos：老虎证券：腾讯 Robotics X 发布 Tairos；中国日报：腾讯全景图亮相 WAIC
- HY-Embodied-0.5：arXiv 2604.07430；Hugging Face：tencent/HY-Embodied-0.5
- RxBrain：GitCode：Hy-Embodied-RxBrain-1.0；虎嗅；新浪财经
- HyVLA-0.5：BestHub（单一二手来源）
- KrASIA：京东与腾讯想为机器人提供动力而非制造机器人

> 核验说明：Tairos 的发布时间与构成来自官方报道；HY-Embodied-0.5 的两档规模来自 arXiv 与 Hugging Face；HyVLA-0.5 仅见于单一二手来源；RxBrain 的能力描述、5 万小时以上数据、开源地址来自 GitCode/新闻报道；WAIC 2026 三件套的命名与 Apache 2.0 许可主要来自社区 wiki，未见完整官方新闻稿核实。补充核验：HY-Embodied-0.5 的 MoT-2B（2B/4B）与 MoE-A32B（32B/407B）、HY-ViT 2.0、潜在 token、自我演化后训练与在策略蒸馏、22 基准成绩来自 arXiv 2604.07430 与 Hugging Face 模型卡（腾讯自报）。

第 29 章 小米：从”车-机器人统一大脑”到”10 万小时 UMI 数据”——一家硬件公司的后发急行军

> 一句话定位：小米曾在 2022 年发布 CyberOne（铁大）人形机器人，随后在 2023 年后主动暂停了人形机器人的对外宣发，转入”闭关”。2025 年 11 月，它以 MiMo-Embodied（首个同时在自动驾驶与具身智能上领先的开源跨具身基础模型）重新登场；2026 年 2 月开源 Xiaomi-Robotics-0（4.7B，MoT 架构，消费级显卡实时运行）；7 月发布、8 月开源 Xiaomi-Robotics-1——基于超过 10 万小时 UMI 设备采集的真实世界操作数据预训练，被小米称为”首次系统验证机器人缩放定律”，并在 RoboCasa、RoboDojo 等榜单登顶；8 月世界机器人大会上，经过约 4 个月汽车工厂实训的新一代人形”铁大”亮相。小米的路线是”工业场景优先 + 大规模真实数据 + 积极开源”，是 2026 年中国具身领域上升最快的大厂之一。

0. 速览卡片

维度	内容
机构	小米集团（机器人事业部 / 小米机器人实验室；MiMo 大模型团队）
关键人物	雷军（董事长，亲自站台机器人发布）；卢伟冰（总裁，称通用机器人进入家庭仍需 5–10 年，优先工业场景）；罗福莉等（MiMo 团队）
硬件谱系	CyberDog（2021）→ CyberOne 铁大（2022）→ 暂停对外宣发（2023 后）→ 新一代”铁大”（2026.08 WRC 亮相，约 1.70 米、66 公斤、66 自由度）
模型谱系	MiMo-Embodied（2025.11，7B）→ Xiaomi-Robotics-0（2026.02.12，4.7B）→ Xiaomi-Robotics-1（2026.07.16 发布，08.05 开源）
开放程度	高：三个模型均开源（GitHub XiaomiMiMo / XiaomiRobotics，Hugging Face）
落地	汽车工厂实训（自攻螺母上件等任务成功率提升至 98%，媒体报道）；雷军称未来 5 年会有大批人形机器人进入小米工厂
本章三篇代表作	① MiMo-Embodied：自动驾驶与具身智能的跨具身基础模型 ② Xiaomi-Robotics-0：实时执行的开源 VLA ③ Xiaomi-Robotics-1：10 万小时 UMI 数据与机器人缩放定律
身位	2026 年国内上升最快的具身大厂之一；开源模型在多个仿真基准上处于前列

1. 故事的开端：从 CyberOne 的”沉默”到 2025 年的回归

2022 年 8 月，雷军在年度演讲上牵着 CyberOne（“铁大”）登台，这是中国大厂较早的人形机器人展示之一。但此后小米在人形机器人上保持了长时间的沉默——据报道，小米在 2023 年之后主动暂停了人形机器人的对

外宣发。

沉默期间，小米做了三件事： 1. 造车：小米 SU7（2024）与 YU7 的成功，让小米积累了端到端自动驾驶、大规模数据闭环、汽车工厂智能制造的经验； 2. 自研大模型：MiMo 系列大模型团队成立，引入包括前 DeepSeek 研究员罗福莉在内的人才； 3. 具身研究：在内部构建机器人数据采集与模型训练体系。

2025 年 11 月起，小米以”每 3–5 个月一个开源模型”的节奏重新登场。

---

2. 代表作一：MiMo-Embodied（2025.11）——车与机器人的”统一大脑”

> 技术报告：*MiMo-Embodied: X-Embodied Foundation Model Technical Report*（arXiv 2511.16518）；Hugging Face：XiaomiMiMo/MiMo-Embodied-7B；GitHub：XiaomiMiMo/MiMo-Embodied。

2.1 核心主张：“跨具身（X-Embodied）”

MiMo-Embodied 的核心问题是：自动驾驶与具身机器人需要的”世界理解”能力，能否用一个模型统一？

两者的共性： - 都需要空间理解（距离、方位、可通行区域）； - 都需要动态预测（其他车辆/行人/物体如何运动）； - 都需要任务规划（去哪、怎么走、先做什么）。

两者的差异： - 自动驾驶：室外、大尺度、高速、以导航与避障为主； - 机器人：室内、小尺度、接触丰富、以操作为主。

小米的判断是：共性远大于差异，统一训练可以相互增益——这与特斯拉”FSD 与 Optimus 共享同一大脑”（第 6 章）、小鹏”VLA 2.0 同时用于汽车、Robotaxi、机器人与飞行汽车”（第 30 章）的思路一致，是”车企造机器人”的共同逻辑。

2.2 模型与结果

- 规模：7B 视觉语言模型；
- 能力：同时覆盖具身智能（可供性预测、任务规划、空间理解）与自动驾驶（环境感知、状态预测、驾驶规划）；
- 小米称其在 29 个基准上超过开源、闭源及专有模型（小米自报）；
- 被描述为首个同时在自动驾驶与具身智能任务上取得领先表现的开源视觉语言模型；
- 媒体报道小米计划从 2026 年第一季度起，把它应用到扫地机器人、AGV 与 SU7 的高级辅助驾驶中（媒体转述，未经官方确认）。

2.3 意义

MiMo-Embodied 是一个”理解层（大脑）”模型，类似 Gemini Robotics-ER 与 RoboBrain——它不直接输出电机指令，但为车与机器人提供统一的世界理解。它也标志着小米具身路线的起点：先建立统一的感知与推理底座，再向下做动作模型。

---

3. 代表作二：Xiaomi-Robotics-0（2026.02.12）——为”实时执行”而设计的开源 VLA

> 论文：*Xiaomi-Robotics-0: An Open-Sourced Vision-Language-Action Model with Real-Time Execution*（arXiv 2602.12684，2026-02-13）；项目页 xiaomi-robotics-0.github.io；GitHub：XiaomiRobotics/Xiaomi-Robotics-0。

3.1 架构：Mixture-of-Transformers

组件	设计
VLM 主干	Qwen3-VL-4B-Instruct（在后训练中冻结）
动作生成	16 层扩散 Transformer（DiT），流匹配生成连续动作块
结构	MoT（Mixture-of-Transformers）：VLM 与 DiT 作为两组 Transformer 专家协同
总规模	约 47 亿参数

3.2 数据

- 约 2 亿个时间步的机器人轨迹数据；
- 超过 8000 万条通用视觉-语言数据（防止 VLM 能力退化）；
- 部分自有遥操作数据覆盖乐高拆解、叠毛巾等精细任务。

3.3 核心创新：真正的"实时异步执行"

VLA 在真机上有一个普遍的工程难题：模型推理需要时间（几十到上百毫秒），机器人不能停下来等。常见做法是"异步执行"——机器人在执行当前动作块剩余部分的同时，模型推理下一个动作块。但这会带来两个问题：- 衔接抖动：新旧动作块在切换处不连续；- 动作惯性（action inertia）：如果把上一块的动作作为输入前缀以保证平滑，模型会过度依赖前缀、对新的视觉变化反应迟钝。

Xiaomi-Robotics-0 的解法：

1. 干净动作前缀（clean action prefix）：后训练时，把上一次推理得到的动作作为"干净前缀"拼接在带噪动作 token 之前，让新动作块与旧动作块平滑衔接；
2. Λ 形注意力掩码（Λ-shape attention mask）：替代 DiT 中的因果掩码——
    - 紧跟前缀的带噪动作 token 可以注意前缀 → 保证衔接平滑；
    - 更后面时间步的动作 token 不能注意前缀 → 被迫依赖视觉与语言输入 → 保证对环境变化的反应性；
3. 前缀随机掩码与自适应损失重加权（对偏离真实轨迹更大的动作赋予更高权重，重罚漂移）。

这一设计与 PI 的 RTC（实时动作分块）、HF SmolVLA 的异步推理解决的是同一类问题，但给出了一个简洁的"注意力掩码"方案。

3.4 结果

- LIBERO 平均成功率约 98.7%；
- 开源了基础模型与 LIBERO、CALVIN、SimplerEnv 上的微调检查点、推理代码；后训练代码于 2026 年 4 月 27 日开源；
- 媒体报道在 RTX 4090 上推理延迟约 80 毫秒、可实现约 30Hz 实时控制（单一来源）；

- 演示了经约 20 小时后训练即可完成耳机盒装配等精细任务（二手报道）。

---

4. 代表作三：Xiaomi-Robotics-1（2026.07.16 发布 / 08.05 开源）——10 万小时 UMI 数据与机器人缩放定律

> 官方发布：小米技术（2026-07-16）；开源（2026-08-05，GitHub 与 Hugging Face，含真机后训练到部署的完整流程与基准评测代码）；项目页 robotics.xiaomi.com/xiaomi-robotics-1.html。

4.1 数据：10 万小时 UMI 真实世界操作数据

Xiaomi-Robotics-1 最核心的信息是数据规模与采集方式： - 预训练：超过 10 万小时真实世界操作数据，通过 UMI 设备采集（手持/可穿戴式采集，见第 11 章），覆盖家庭、办公室、工业等多类场景； - 后训练（跨本体）：约 1 万小时跨本体数据——其中包括 7200 多小时移动操作机器人与双臂机器人数据，以及 Bridge V2、RT-1、DROID 等公开数据集；后训练主要解决”本体对齐”与”指令对齐”两个问题。

这一”大规模无本体（UMI）预训练 + 跨本体机器人数据后训练”的两阶段范式，与清华 RDT2（1 万小时 UMI）、Generalist（50 万小时人类交互 + 少量机器人对齐）、Sunday（手套）属于同一流派，但小米把 UMI 数据做到了 10 万小时——是 2026 年公开报道中 UMI 式数据规模最大的之一。

4.2 “首次系统验证机器人缩放定律”

媒体（华尔街见闻）以”小米扔深水炸弹：100000h 真实数据，首次系统验证机器人 Scaling Law”为题报道。这与 Generalist GEN-0（2025.11，27 万小时，缩放定律）在结论上呼应——在足够大规模的真实操作数据上，机器人模型的性能随数据与模型规模可预测地提升。

4.3 榜单成绩（小米自报）

基准	成绩	对比
RoboDojo（仿真）	平均分 20.07，平均成功率 13.93%	此前行业最优约 13.07 分、8.80%
RoboCasa	平均成功率 74.5%	高于 π0.5、GR00T N1.6 等
VLABench	平均成功率 59.1%，平均进度得分 70.3%	SOTA
RoboCasa365	平均任务成功率约 57.4%（单一转载来源）	此前海外最优约 46.6%

雷军在 7 月表示，Xiaomi-Robotics-1 在两大具身榜单中综合排名全球第一。

解读：RoboDojo 上 13.93% 的平均成功率说明这一基准极难（与 BEHAVIOR 2025 的 12.4% 完整成功率量级相当）；“登顶”的意义在于相对进步，而非绝对能力已达实用。

4.4 工厂实训：新一代”铁大”

2026 年 8 月 19 日世界机器人大会上，小米新一代人形机器人亮相： - 延续”铁大”之名，身高约 1.70 米、体重 66 公斤、全身 66 个自由度； - 此前在小米汽车工厂进行了约 4 个月实训； - 据报道，在自攻螺母上件等任务中成功率提升至 98%； - 采用”大脑 + 小脑”混合架构。

小米总裁卢伟冰表示，通用机器人进入家庭预计仍需 5–10 年，公司优先推进工业场景；雷军则称未来 5 年会有大批量人形机器人进入小米工厂干活。

---

5. 技术路线总结

阶段	时间	层级	核心
MiMo-Embodied	2025.11	大脑（理解）	车 + 机器人统一的跨具身 VLM（7B）
Xiaomi-Robotics-0	2026.02	小脑（VLA）	MoT（Qwen3-VL-4B + 16 层 DiT），Λ 形掩码实时异步执行
Xiaomi-Robotics-1	2026.07	基座（VLA）	10 万小时 UMI 预训练 + 1 万小时跨本体后训练；缩放定律
新一代铁大	2026.08	本体 + 工厂	66 自由度，汽车工厂实训

小米的特色：“硬件公司的工程化 + 大规模真实数据 + 开源”——每个模型都附带可复现的代码与评测，节奏快、开放度高。

---

6. 横向对比与身位

维度	小米	小鹏（第 30 章）	特斯拉（第 6 章）
车-机器人统一	MiMo-Embodied（统一理解）	VLA 2.0（统一动作）	FSD + Optimus 共享网络与世界模拟器
数据	10 万小时 UMI + 1 万小时跨本体	驾驶视频 + 机器人	车队 + 人类视频
开源	积极开源	较少	闭源
工厂场景	小米汽车工厂实训	门店与园区	弗里蒙特工厂

身位：小米在 2026 年迅速跻身中国具身基座模型第一梯队；其 Xiaomi-Robotics-1 的数据规模与开源完整度在国内领先。

---

7. 未来展望与风险

展望： 1. 工厂数据飞轮：小米汽车与手机工厂可以成为人形机器人的大规模训练场与首批客户； 2. 生态协同：小米的 IoT 生态（智能家居）为未来家庭机器人提供天然的连接与场景； 3. 持续开源：小米的开源节奏可能使其成为中国具身开源生态的核心贡献者之一。

风险： 1. 评测与真实能力的差距：仿真榜单登顶不等于真实场景可靠； 2. 人形本体的竞争：在本体成本与量产上，小米需要与宇树、优必选等专业厂商竞争； 3. 家庭市场的时间窗口：小米自己判断家庭场景还需 5–10 年，短期商业回报依赖工业场景。

---

8. 延伸阅读与核验来源

- MiMo-Embodied：arXiv 2511.16518；Hugging Face；SCMP 报道
- Xiaomi-Robotics-0：arXiv 2602.12684；项目页；GitHub；盖世汽车
- Xiaomi-Robotics-1：IT之家：Xiaomi-Robotics-1 发布；华尔街见闻：10 万小时真实数据验证缩放定律；新浪：开源报道
- 新一代铁大：凤凰网：小米新一代人形机器人亮相

> 核验说明：MiMo-Embodied 的 7B 规模与"29 个基准"来自小米技术报告（自报）；Xiaomi-Robotics-0 的 MoT 架构、16 层 DiT、Λ 形掩码、LIBERO 98.7% 来自 arXiv 论文，"80ms/30Hz"为单一来源；Xiaomi-Robotics-1 的 10 万小时 UMI 预训练、1 万小时后训练（含 7200+ 小时）与 RoboDojo/RoboCasa/VLABench 成绩来自官方发布与多家媒体（自报），RoboCasa365 成绩仅见于单一转载；新一代铁大参数与 98% 成功率来自媒体报道。

第 30 章 小鹏汽车：去掉”语言”的 VLA 2.0，与”最拟人”的 IRON

> 一句话定位：小鹏是中国车企中人形机器人投入最早、声量最大的一家。它的大脑路线有两个鲜明特征：一是”车、机器人、飞行汽车共用一个物理世界大模型”——云端 720 亿参数的”小鹏世界基座模型”蒸馏到各类终端；二是 2025 年 11 月科技日发布的第二代 VLA（VLA 2.0）——去掉了”视觉→语言→动作”中的语言转译环节，直接从视觉信号生成动作，被小鹏定义为一种”物理世界模型”范式，并于 2026 年 8 月升级为”4D 时空理解”。其新一代人形机器人 IRON（2025.11）以”最拟人”著称，搭载 3 颗自研图灵 AI 芯片，计划 2026 年底规模量产、2027 年对外交付；机器人业务于 2026 年 8 月完成首轮超 9 亿美元融资，投后估值超 63 亿美元。

---

0. 速览卡片

维度	内容
公司	小鹏汽车（XPeng），机器人业务（小鹏鹏行等）
关键人物	何小鹏（董事长兼 CEO，亲自推动机器人业务）
硬件谱系	小鹏鹏行四足/小白龙（2021–2022）→ PX5 双足（2023）→ IRON 一代（2024.11）→ 新一代 IRON（2025.11.05 科技日）
大脑	小鹏世界基座模型（720 亿参数，云端，2025.04 披露）→ 蒸馏到端侧；第二代 VLA（VLA 2.0，2025.11）——去语言转译，直接视觉→动作；2026.08 VLA 2.0 首次重大升级（静态 3D → 动态 4D 时空，端侧参数量提升约 3.5 倍）；IRON 上组合 VLT + VLA + VLM 的”大小脑”
算力	云端约 3 万卡集群；IRON 搭载 3 颗自研图灵 AI 芯片（有效算力约 2250 TOPS，研报口径）
量产与融资	2026 年底开始规模量产（月产能目标上千台），先在小鹏门店与园区落地，2027 年对外交付；2026.08.24 机器人业务首轮融资超 9 亿美元，投后估值超 63 亿美元（据报道）
本章三篇代表作	① 小鹏世界基座模型（720 亿参数，云端蒸馏范式）② 第二代 VLA：去掉语言的”物理世界模型”③ IRON：最拟人人形与车-机器人共用大脑
身位	车企机器人中声量与资源投入第一梯队；大脑技术细节公开较少，与特斯拉路线最相似

---

1. 故事的开端：何小鹏的”未来出行与机器人”执念

何小鹏多次表示，他最看重的不是汽车，而是”物理 AI”——汽车、机器人、飞行汽车是同一种智能在不同载体上的体现。2020 年起，小鹏先后孵化了小鹏鹏行（机器人）、小鹏汇天（飞行汽车），并投入人形机器人研发。

小鹏与特斯拉的路线相似度极高： - 都认为自动驾驶与人形机器人是同一个问题； - 都采用自研芯片 + 自研大模型 + 自建数据闭环； - 都把汽车业务的数据与工程能力迁移到机器人。

区别在于：小鹏更强调”一个云端物理世界大模型 → 蒸馏到多种终端”的架构，并在 2025 年给出了一个激进的技术判断——VLA 中的”L（语言）“在动作生成中是多余的。

---

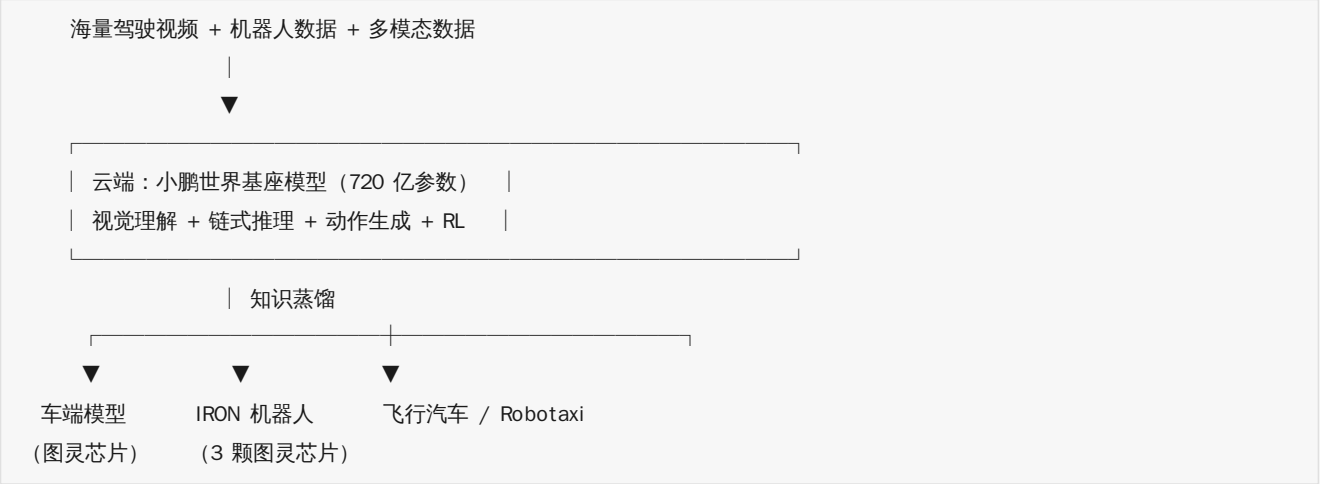
2. 代表作一：小鹏世界基座模型（2025.04）——720 亿参数的云端”物理世界大脑”

> 公开来源：小鹏 2025 年 4 月 AI 技术分享会；2025 年 11 月科技日。

2.1 架构与定位

- 规模：720 亿参数；
- 骨干：以大语言模型为骨干，具备视觉理解、链式推理与动作生成能力；
- 部署方式：在云端训练与运行，通过蒸馏部署到车端（以及机器人等其他终端）；
- 训练基础设施：约 3 万卡的云端算力集群；科技日时小鹏称已实现每 5 天一次的全链路迭代；
- 强化学习：在云端用强化学习进一步提升模型能力（与特斯拉、Waymo 的做法相似）。

2.2 “云端大模型 + 蒸馏”的逻辑



意义：这是一种”教师-学生”式的部署架构——大模型在云端不受算力约束地学习”物理世界”，小模型在端侧继承其能力并满足实时性。这与 DeepMind Gemini Robotics 的”云端骨干 + 本地解码器”不同：小鹏的端侧模型是独立运行的蒸馏模型，不依赖实时网络。

---

3. 代表作二：第二代 VLA（2025.11 / 2026.08 升级）——去掉”语言转译”的物理世界模型

> 公开来源：2025 年 11 月 5 日小鹏科技日；2026 年 8 月第二代 VLA 首次重大升级（首发小鹏 G9L）。

3.1 核心主张：动作不需要”先翻译成语言”

传统 VLA 的信息流是：视觉（V）→ 语言空间中的理解与推理（L）→ 动作（A）。小鹏认为，在驾驶与机器人控制中，“把视觉先转成语言 token 再推理”是一个不必要的瓶颈： - 语言是人类为交流而发明的离散符号系统，

难以精确表达连续的空间、速度、力等物理量； - 语言转译增加了延迟； - 驾驶/操作中大量的”隐性知识”（何时减速、手如何调整）本来就无法用语言描述。

因此，第二代 VLA 去掉了语言转译环节，从视觉信号直接生成动作指令——小鹏称其为一种”新的物理模型范式”：它既是动作生成模型，也是一个可以理解和推演世界的物理世界模型。

3.2 训练数据

第二代 VLA 可以直接利用海量真实驾驶视频训练——因为它不需要每段视频都配有语言标注。这与特斯拉 FSD v12”从人类驾驶视频端到端模仿”的思路一致。

3.3 2026 年 8 月的升级：从 3D 到 4D

2026 年 8 月的体验日上，第二代 VLA 迎来首次重大升级： - 引入时间维度：从静态 3D 空间理解转向动态 4D 时空理解——不仅理解”物体在哪”，还理解”物体将如何运动”； - 端侧模型参数量提升约 3.5 倍（据报道）； - 首发搭载于小鹏 G9L。

3.4 分析：去掉”L”是对是错？

观点	支持”去 L”（小鹏、部分自动驾驶团队）	支持”保留 L”（DeepMind、PI、Figure）
理由	语言是瓶颈；物理量难以语言化；延迟；可直接用无标注视频训练	语言带来互联网知识与常识；可解释；便于人机交互与任务指定
代表	小鹏 VLA 2.0；Generalist 的”和声推理”（不分系统 1/2）；世界动作模型（DreamZero 主干为视频模型）	Gemini Robotics 1.5”思考型 VLA”；π0.5 高层子任务；Helix S2

本报告的判断：两者并不矛盾——2026 年的主流实践是”语言用于任务指定与高层规划，动作生成直接在视觉-动作空间完成”。小鹏 IRON 上同时存在 VLT、VLA 与 VLM，本身就说明语言模块并未被完全去掉，而是被从动作生成的关键路径上移开。

---

4. 代表作三：IRON（2025.11）——“最拟人”的人形与车-机器人共用大脑

> 公开来源：2025 年 11 月 5 日小鹏科技日；2026 年各季度财报电话会；2026 年 8 月机器人业务融资报道。

4.1 硬件

新一代 IRON 以”最拟人的人形机器人”为卖点： - 类人的骨骼、肌肉与皮肤设计（科技日现场为证明”非真人”甚至剖开了外皮展示内部结构）； - 灵巧手与全身高自由度（具体自由度数各报道口径不一）； - 3 颗自研图灵 AI 芯片（研报称有效算力约 2250 TOPS）——这是目前公开的人形机器人端侧算力中最高的之一。

4.2 大脑：“VLT + VLA + VLM”的大小脑组合

IRON 搭载”物理世界大模型”，组合 VLT、VLA、VLM 构成”高阶大小脑能力”，支持对话、行走与交互： - VLM：视觉语言理解与对话交互； - VLA：第二代 VLA，直接生成动作； - VLT：官方未详细说明其具体含义与技术细

节。

何小鹏在 2026 年 3 月的电话会上表示，VLA 2.0 技术栈已在机器人上跑通。

4.3 量产时间表（多次表述一致）

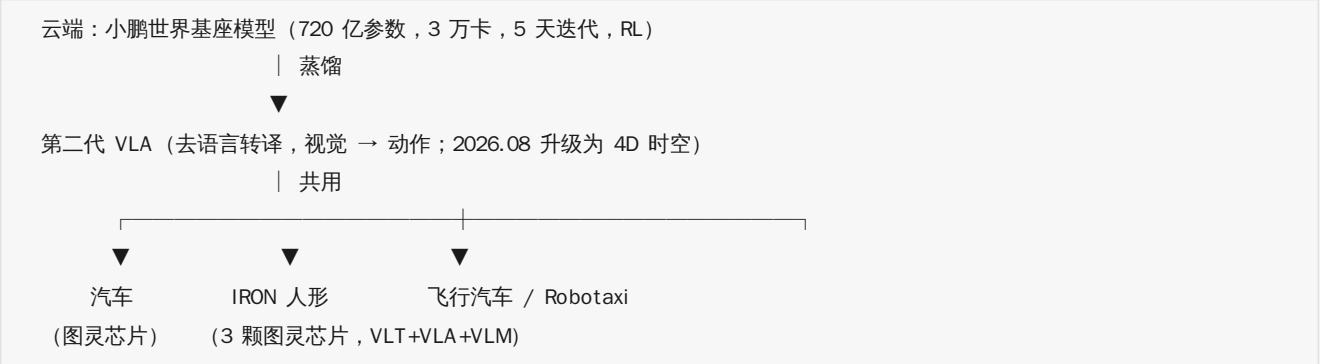
时间	表述
2026.03（电话会）	IRON 将在 2026 年底量产，VLA 2.0 已在机器人上跑通
2026.05（Q1 财报会）	量产版本软硬件研发进展顺利，计划三季度正式亮相
2026.07（华尔街日报）	力争年底前月产能提升至 1000 台以上，2027 年在全球推出
2026.08（半年报会）	年底开始规模量产，先在小鹏门店与园区落地，2027 年对外零售与服务业交付
2026.08.24	机器人业务首轮融资超 9 亿美元，投后估值超 63 亿美元
2026.10 前后	报道称已完成机器人生产线启用与自动化总装；2026 年底量产，2027 年上半年开启交付

4.4 冷静看待

- IRON 的大脑技术细节（模型规模、训练数据、任务成功率）公开极少，外界难以评估其真实自主能力；
- “最拟人”的外观与大脑能力并无直接关系；
- 评论认为，能否在年底前实现每月上千台产能、门店商业化能否跑通真实任务，将决定其估值是否合理。

---

5. 技术路线总结



---

6. 横向对比与身位

维度	小鹏	特斯拉	小米
统一大脑	世界基座模型 + VLA 2.0 共用	FSD 与 Optimus 共享网络 + 世界模拟器	MiMo-Embodied 统一理解
语言的角色	从动作关键路径移除	Grok 作为交互层	保留（VLM 主干）
芯片	自研图灵	自研 AI4/AI5	采购
开源	少	闭源	积极

维度	小鹏	特斯拉	小米
量产时间	2026 年底	2026 年早期生产，2027 年底外部交付	工厂实训中

身位：小鹏是中国车企中与特斯拉路线最相似、投入最坚决的一家；其”去语言 VLA”的技术主张在业内具有话题性，但大脑能力缺乏公开评测。

---

7. 未来展望与风险

展望： 1. 规模量产的检验：2026 年底—2027 年上半年的量产与交付，是检验 IRON 大脑真实能力的关键窗口； 2. 车-机器人数据互通：小鹏的车队数据与机器人数据能否真正在一个模型中相互增益，将决定”统一大脑”路线的价值； 3. 自研芯片优势：图灵芯片为端侧大模型部署提供了独特的算力保障。

风险： 1. 技术透明度低：缺乏论文与评测，外界只能从演示中判断； 2. “拟人”与”能干活”的差距：外观拟人化可能带来更高的期待，与实际自主能力形成落差； 3. 资金与估值：机器人业务的高估值需要量产与商业化的快速兑现。

---

8. 延伸阅读与核验来源

- 新华网：小鹏科技日发布第二代 VLA 大模型
- IT之家：新一代 IRON 亮相
- 少数派：小鹏第二代 VLA 解读
- 新华网：第二代 VLA 首次重大升级；同花顺：G9L 首发
- 凤凰网：何小鹏称 IRON 今年底量产，月产能目标超 1000 台；同花顺：小鹏计划明年全球推出 IRON
- 研报：小鹏科技日凸显物理 AI（图灵芯片算力）

> 核验说明：720 亿参数世界基座模型、3 万卡、5 天迭代来自小鹏官方披露的报道；第二代 VLA”去语言转译”与 2026.08 的 4D 升级来自新华网等报道，端侧参数”提升 3.5 倍”来自同花顺；IRON 的 3 颗图灵芯片与 VLT+VLA+VLM 来自科技日报道，2250 TOPS 为研报口径，VLT 的具体含义未见官方解释；量产时间表与融资数据来自多次电话会与媒体报道（融资数据为媒体报道口径）。

第 31 章 宇树科技（Unitree）：全球出货第一的”身体之王”，开始认真做”大脑”

> 一句话定位：宇树是全球人形与四足机器人出货量最大的公司（2025 年人形机器人出货超过 5500 台，公司称全球第一；四足累计销量超 3.3 万台），2026 年 8 月 19 日登陆科创板（688836；发行价 150.80 元/股，首日收盘 845 元、收涨约 460%，收盘总市值约 3418 亿元，此后有所回落）。长期以来，宇树以”极致性价比的硬件 + 开源运动控制生态”著称——全世界大量人形研究论文都跑在宇树 G1/H1 上。2025 年 9 月起，宇树开始系统发布自研”大脑”：UnifoLM-WMA-0（世界模型-动作框架，2025.09）、UnifoLM-VLA-0（2026.01）、UnifoLM-WLA-1.0（2026.09，6B，“世界-语言-动作”统一模型，单模型覆盖 64 项真机任务），以及闭源的工业模型 UnifoLM-X1-0。宇树的大脑路线是”世界模型先行、开源生态驱动、以真机任务覆盖面为核心指标”。

0. 速览卡片

维度	内容
成立	2016 年，杭州
创始人	王兴兴（CEO）；联合创始人陈立等
产品	四足：Go1/Go2、A1/A2、B1/B2；人形：H1（2023）、G1（2024）、H2、R1 等
资本	2026 年 3 月 20 日科创板 IPO 获受理（拟募资约 42.02 亿元）→ 6 月 1 日上市委审议通过 → 8 月 10 日启动申购（发行价 150.80 元/股，发行市值约 610 亿元，网上中签率约 0.0181%）→ 8 月 19 日上市（688836）：开盘 1100 元、首日收盘 845 元（+460.34%），收盘总市值约 3418 亿元；据报道至 9 月 10 日股价跌破 500 元、总市值约 2022 亿元
财务	营收：2023 年约 1.59 亿元、2024 年约 3.93 亿元、2025 年约 16.99 亿元（净利润约 2.78 亿元，主营毛利率约 60%）；2026 年一季度营收 4.23 亿元（同比 +68.49%）；海外约贡献一半营收
出货	2025 年人形出货超 5500 台（纯人形）；四足累计超 3.3 万台
大脑模型	UnifoLM-WMA-0（2025.09）、UnifoLM-VLA-0（2026.01.29）、UnifoLM-WLA-1.0（2026.09.10）、UnifoLM-X1-0（闭源工业模型，单一来源）
开源生态	unitree_rl_gym、unitree_IL_lerobot、遥操作代码、G1 数据集等
合作	2026 年 1 月与腾讯 Robotics X 战略合作
本章三篇代表作	① 开源运动控制与数据生态（unitree_rl_gym 等）② UnifoLM-WMA-0：世界模型-动作框架 ③ UnifoLM-WLA-1.0：世界-语言-动作统一基座（含 VLA-0 前作）

维度	内容
身位	身体与出货量全球第一；大脑能力处于快速追赶期，开源生态影响力全球领先

1. 故事的开端：从”学生作品”到全球最大的足式机器人公司

王兴兴在上海大学读研期间独自做出了低成本四足机器人 XDog，2016 年创办宇树。宇树的核心能力是电机、减速器、关节模组与整机设计——通过自研核心部件，把四足机器人的价格从数十万元打到数万元甚至万元以下。

2023 年，宇树推出首款人形 H1；2024 年推出 G1（起售价约 9.9 万元），迅速成为全球学术界与开发者最常用的人形机器人平台。截至 2026 年，CMU（ASAP、BFM-Zero）、UCSD（ExBody）、Amazon FAR（ResMimic）、NVIDIA（SONIC）、Stanford（HumanPlus）等大量顶级人形研究都在宇树机器人上完成。

这种”硬件被全世界研究者使用”的地位，给了宇树一个独特的优势：全球最前沿的人形控制算法，天然就适配宇树的机器人。但它也带来一个问题：宇树长期被视为”身体供应商”，大脑依赖学术界与第三方。2025 年起，宇树开始改变这一定位。

---

2. 代表作一：开源运动控制与数据生态——人形”小脑”的公共底座

2.1 unitree_rl_gym：人形 RL 的”入门教科书”

宇树开源的 unitree_rl_gym（基于 NVIDIA Isaac Gym / legged_gym 体系）提供了： - 宇树 Go2、H1、G1 等机器人的仿真模型； - 强化学习训练运动策略的完整流程（奖励设计、域随机化、课程学习）； - Sim2Sim（Isaac Gym → MuJoCo 验证）与 Sim2Real（部署到真机）的流程。

大量开发者以它为起点训练出行走、跑步、跳跃等运动策略。宇树在春晚、马拉松、格斗赛等场合展示的高动态动作（侧空翻、回旋踢、跑步），背后都是这一”仿真 RL + sim2real”体系的工业化版本。

2.2 遥操作与模仿学习工具链

- unitree_IL_lerobot：把宇树机器人接入 Hugging Face LeRobot 生态，用于模仿学习的数据采集与训练；
- 遥操作代码：基于 Apple Vision Pro 等设备的遥操作（受 UCSD Open-TeleVision 影响）；
- 开源数据集：G1 等机器人的操作数据集——这些数据后来也被用于训练 UnifoLM-WMA-0。

2.3 意义

宇树的开源生态是全球人形”小脑”研究的公共基础设施。它的价值不在于某个模型多强，而在于让全世界的研究者以最低成本在真实人形上验证算法——这反过来让宇树硬件成为事实上的”标准研究平台”。

---

3. 代表作二：UnifoLM-WMA-0（2025.09）——世界模型-动作框架

> 发布：2025 年 9 月 15–16 日；项目页 unigen-x.github.io/unifolm-world-model-action.github.io；许可证 CC BY-NC-SA 4.0（非商业）。

3.1 定位

UnifoLM-WMA-0 是宇树 UnifoLM（Unitree Unified Large Model） 系列的第一款开源模型，也是宇树首个开源的世界模型-动作（World-Model-Action）架构，面向通用机器人学习。其核心是一个学习”机器人与环境如何物理交互”的世界模型。

3.2 两种工作模式

模式	功能	作用
决策模式（Decision-Making Mode）	预测未来的物理交互信息	辅助策略生成动作——“先预判、再动手”
仿真模式（Simulation Mode）	根据机器人动作生成高保真的环境反馈	作为学习式模拟器，用于评估与数据生成

解读：这一”双模式”设计把世界模型的两种主流用途（作为策略的一部分 vs 作为模拟器）统一在一个框架中——与 1X 世界模型（先做评估器、后做策略）、蚂蚁 LingBot-World（模拟器）、NVIDIA DreamZero（直接作为策略）形成对照。

3.3 训练

在宇树开源的 5 个数据集上训练（以宇树机器人的操作数据为主）。

3.4 意义

WMA-0 是宇树从”身体公司”向”大脑公司”转型的第一步，也表明宇树在一开始就选择了”世界模型”作为大脑的核心——比单纯跟随 VLA 潮流更有前瞻性。

---

4. 代表作三：UnifoLM-WLA-1.0（2026.09）——“世界-语言-动作”统一基座

> 发布：2026 年 9 月 10 日宣布完全开源（代码、模型、数据集将开放）；项目页 unigen-x.github.io/unifolm-wla.github.io。前作：UnifoLM-VLA-0（2026-01-29，GitHub unitreerobotics/unifolm-vla）。

4.1 前作：UnifoLM-VLA-0（2026.01）

- 基于 Qwen2.5-VL-7B，在机器人操作数据上进行继续预训练；
- 参考了 NVIDIA Isaac GR00T 的代码体系；
- 面向人形操作，在真机实验中稳定完成 12 项任务。

VLA-0 是一个”跟上主流”的 VLA，而 WLA-1.0 则体现了宇树自己的技术主张。

4.2 WLA = World-Language-Action

WLA-1.0 把三件事纳入一个统一框架： 1. 具身推理（语言层面理解任务与场景）； 2. 未来动态区域预测（世界模型层面"预判"接下来场景中哪些区域会发生变化）； 3. 动作生成。

4.3 架构

组件	设计
具身推理底座	UnifoLM-ER-1-4B：基于 Qwen3-VL-4B，使用超过 500 万条训练数据进行具身推理训练
多模态主干	UnifoLM-ER-Flow：在 ER 底座上加入"未来动态区域预测"能力
世界模型监督	以图像 + 任务描述或动作为条件，预测未来场景的动态区域；训练时用光流提取未来场景的变化区域作为监督信号；这些未来变化被编码为离散 token 放入 VLM
动作专家	MMDiT（多模态扩散 Transformer）动作专家，以流匹配生成连续动作
总规模	约 60 亿参数
真机数据	约 2500 小时真机采集数据

设计亮点——"光流作为世界模型的监督"：与 DreamZero、1XWM 等生成完整未来视频的世界模型不同，WLA-1.0 只预测"未来哪里会动"（动态区域），并用光流提供监督。这是一种轻量化的世界模型：它不需要生成逼真的像素，只需要知道"变化发生在哪里"——这恰恰是机器人决策最需要的信息（例如"杯子会被推到哪里""门会向哪个方向打开"）。知乎技术解读把这一设计概括为"把未来变化收成离散 token 塞进 VLM，连续动作另外交给流匹配专家"。

4.4 能力与结果

- 单模型统筹 64 项真机任务：其中 10 项全身操作（移动 + 操作）、54 项桌面操作——同一套权重；
- 跨末端执行器泛化：支持二指夹爪与多种五指灵巧手；
- 在 7 项具身推理评测上领先参评的开源模型（宇树口径）；
- 媒体报道其在宇树 G1 上端侧闭环推理延迟约 106 毫秒（单一来源，未见官方页面确认）。

4.5 局限

技术解读指出：64 项任务未公布逐项成功率；WLA-Base 与后训练代码在发布时仍在开源计划中。

4.6 闭源工业模型

据单一来源报道，宇树另有一个闭源的工业模型 UnifoLM-X1-0，已在自有工厂试点。

---

5. 技术路线总结

```
2016– 2024   极致性价比硬件 + 开源 RL 运动控制（小脑生态）
      |
      ▼
2025.09      UnifoLM-WMA-0：世界模型-动作框架（决策模式 + 仿真模式）
```

```
    |
    ▼
2026.01    UnifoLM-VLA-0：Qwen2.5-VL-7B 继续预训练（跟上主流 VLA）
    |
    ▼
2026.09    UnifoLM-WLA-1.0：世界-语言-动作统一（ER-Flow + MMDiT，6B，64 项任务）
```

宇树的大脑路线有三个特点： 1. 世界模型先行：第一个模型就是世界模型-动作框架； 2. 轻量世界模型：用"动态区域 + 光流监督"代替完整视频生成，兼顾端侧实时性； 3. 任务覆盖面优先：以"一个模型覆盖多少真机任务"作为核心指标。

---

6. 横向对比与身位

维度	宇树	智元（第 32 章）	优必选（第 33 章）
出货	全球第一（2025 年人形 5500+）	头部	头部（工业人形）
大脑起步	2025.09	2025.03（GO-1）	较早（BrainNet 等）
大脑代表	UnifoLM-WLA-1.0	GO-1 / GO-2、GE 世界模型	Thinker 等
世界模型	WMA-0、WLA（轻量动态区域）	Genie Envisioner（视频世界模型）	—
开源	积极（部分非商业许可）	积极	部分
资本	科创板上市（2026.08.19，首日收盘市值约 3418 亿元）	控股上市公司	港股上市

身位： - 身体与出货：全球第一； - 大脑：起步晚于智元、字节等，但追赶速度快，WLA-1.0 的"轻量世界模型"设计具有独特性； - 生态：作为全球最常用的人形研究平台，宇树在"小脑"开源生态中的影响力无人能比。

---

7. 未来展望与风险

展望： 1. 上市后的研发投入：IPO 募资将显著加强宇树在大脑方向的投入； 2. 出货量带来的数据优势：数千台/年的人形出货量，如果能形成数据回流，将成为宇树大脑的独特燃料； 3. 与腾讯等平台的合作：外部大脑 + 自研大脑并行，降低单一路线风险。

风险： 1. 大脑能力的差距：与 PI、DeepMind、Figure 相比，宇树的大脑仍处于追赶阶段； 2. 非商业许可：部分开源模型的非商业许可限制了其在产业中的直接采用； 3. 价格战：低价策略带来规模，但也压缩了研发投入的利润空间（单价从 2022 年的 3.86 万元降至 2025 年前三季度的 2.72 万元）。

---

8. 延伸阅读与核验来源

- UnifoLM-WMA-0：项目页；第一财经：宇树开源世界模型
- UnifoLM-VLA-0：IT之家；GitHub unitreerobotics/unifolm-vla

- UnifoLM-WLA-1.0：项目页；极客公园；新浪科技；知乎技术解读
- IPO 与财务：中国金融信息网：申购启动；中国金融信息网：上市首日；华尔街见闻；新华网：上市委审议通过；第一财经

> 核验说明：WMA-0 的双模式、5 个数据集、CC BY-NC-SA 4.0 许可来自项目页与报道；VLA-0 基于 Qwen2.5-VL-7B、12 项任务来自 IT之家；WLA-1.0 的 6B、ER-1-4B（Qwen3-VL-4B、500 万+数据）、ER-Flow、MMDiT、约 2500 小时数据、64 项任务（10+54）、7 项评测领先来自官方发布与多家媒体；“106 毫秒”仅见于单一来源；UnifoLM-X1-0 仅见于单一来源；IPO 与财务数据来自交易所审核、发行与上市首日相关报道（不同媒体对盘中最高市值口径略有差异）。

第 32 章 智元机器人（AgiBot）：出货量全球第一的”数据工厂”，从 GO-1 到昨天发布的 GO-3

> 一句话定位：智元是 2026 年全球人形机器人出货量最大的公司（公司称 2026 年上半年出货 9700 台、全球份额超 43%；IDC 口径为 8600 台以上、全球约 35%、中国 45% 以上），也是中国具身”大脑”布局最完整的本体公司：AgiBot World（百万级真机轨迹开源数据集）、GO-1（ViLLA：VLM + 潜在规划器 + 动作专家，2025.03）、Genie Envisioner（视频世界模型平台 GE-Base/GE-Act/GE-Sim，2025.08）、GO-2（动作思维链 + 异步双系统，2026.04，CVPR 2026），以及 2026 年 10 月 29 日（本报告撰写前一天）在智元创新日上发布的 GO-3 Preview（具身原生架构 WRAM，宣称登顶 RoboDojo、RoboTwin、RoboColiseum 三大榜单，计划 2026 年底全面开源）。智元的路线是”规模化数据工厂 + VLA 与世界模型双线 + 本体出货形成部署态数据飞轮”。

0. 速览卡片

维度	内容
成立	2023 年 2 月，上海
创始团队	邓泰华（董事长兼 CEO，前华为副总裁）；彭志辉（稚晖君，联合创始人、CTO，前华为”天才少年”）；姚卯青（联合创始人）等
资本	多轮融资；2025 年取得科创板上市公司上纬新材控制权；2026 年 IPO 相关进展持续
产品	远征 A 系列（全尺寸人形）、精灵 G 系列（轮式双臂，G1/G2/G2 Max）、灵犀 X 系列（小尺寸人形，X1/X2）、四足等
出货	2025 年超 5000 台；2026 年上半年 9700 台（公司口径，全球份额超 43%）；2026 年 9 月第 2 万台下线；2026 年上半年营收接近 20 亿元
大脑谱系	AgiBot World（2024.12/2025）→ GO-1（2025.03）→ Genie Envisioner（2025.08）→ Genie Sim 3.0 / GE-Sim 2.0 → GO-2（2026.04.09）→ GO-3 Preview（2026.10.29）
其他发布（2026.10.29）	WITA-OMNI（具身全模态端到端交互模型，支持 100 多种语言）；Worken（“有效智能工作时长”——物理 AI 生产力度量单位）；灵渠 OS 1.0（开源并捐赠开放原子开源基金会）；Genie Master（具身智能体框架）；Genie Evolver（后训练系统）
学术合作	港大 OpenDriveLab（UniVLA、WholeBodyVLA）、上海 AI Lab（AgiBot World）、NVIDIA（DreamZero 使用智元数据）
本章三篇代表作	① AgiBot World + GO-1：百万级真机数据与 ViLLA 架构 ② Genie Envisioner：机器人操作的统一世界基础平台 ③ GO-2 → GO-3 Preview：动作思维链、异步双系统与 WRAM

维度	内容
身位	出货量全球第一；中国本体公司中大脑布局最完整、开源影响力最大者之一

---

1. 故事的开端：“天才少年”与”数据工厂”

彭志辉（稚晖君）在加入华为之前，就是 B 站上知名的硬件极客 UP 主，以手工打造自行车自动驾驶、机械臂等项目闻名。2022 年底他离开华为，与前华为副总裁邓泰华于 2023 年 2 月创办智元。

智元从一开始就做了一个与众不同的决定：在上海建立一座大规模的”数据采集工厂”——数百平方米乃至数千平方米的场地中，复刻家庭、商超、工业、餐饮、办公等真实场景，由大量数据采集员用统一的遥操作设备，在上百台机器人上按标准化流程采集数据。

这一决定的逻辑是：中国人形产业不缺硬件，缺的是高质量、标准化、大规模的真机数据。智元要做的是”具身智能的 ImageNet + 数据产线”。

---

2. 代表作一：AgiBot World + GO-1（2024.12–2025.03）——百万级真机数据与 ViLLA 架构

> 论文：*AgiBot World Colosseo: A Large-scale Manipulation Platform for Scalable and Intelligent Embodied Systems*（智元、上海 AI Lab、港大 OpenDriveLab 等，2025）；GO-1 发布（2025-03-10）。

2.1 AgiBot World 数据集

维度	内容
规模	超过 100 万条真机轨迹（约 3000 小时视频-语言配对数据）
任务	217 种任务
场景领域	5 大领域：家居、商超零售、工业、餐饮、办公
平台	智元自研双臂机器人（含灵巧手、多相机、全身自由度）
采集方式	标准化遥操作 + 人工质检
开源	分批开源（Alpha、Beta 版本），成为全球前沿研究的重要数据源

影响力：AgiBot World 被 NVIDIA（DreamZero 的机器人数据、GR00T N1 的预训练数据之一）、上海 AI Lab（InternVLA-A1）、港大（UniVLA）等广泛使用——这是中国开源具身数据集对全球前沿研究影响最大的案例之一。

2.2 GO-1：从 VLA 到 ViLLA

GO-1（Genie Operator-1）提出了 ViLLA（Vision-Language-Latent-Action） 架构：



为什么要加"潜在规划器"：- 机器人真机数据有限，但人类视频与其他本体的数据很多——它们没有本机动作标签，却可以通过潜在动作模型被标注为"潜在动作"；- 潜在规划器在这些数据上学习"抽象的动作意图"，动作专家再把意图转化为具体动作；- 这与 GR00T N1 的"LAPA 虚拟本体"、港大 UniVLA 的"任务中心潜在动作"同属一个思想谱系（UniVLA 的作者团队与智元深度合作）。

结果：智元称潜在规划器使任务成功率从约 66% 提升到约 78%（+12 个百分点）。GO-1 驱动精灵 G1 等机器人完成倒水、烤面包、补货、叠衣服等任务。

---

3. 代表作二：Genie Envisioner（2025.08）——机器人操作的统一世界基础平台

> 论文：*Genie Envisioner: A Unified World Foundation Platform for Robotic Manipulation*（arXiv 2508.05635，2025.08）；2025 年 8 月 14 日发布并宣布开源；2026 年 4 月 10 日发布 GE-Sim 2.0。

3.1 三位一体的世界模型平台

组件	作用	技术要点
GE-Base	世界基础模型	大规模、指令条件化的视频扩散 Transformer（DiT）；在 AgiBot-World-Beta 约 3000 小时视频-语言配对数据（100 万+ 真实操作片段）上训练；学习"在某个指令下，机器人与世界会如何演变"

组件	作用	技术要点
GE-Act	动作模块（“世界动作模型”）	在 GE-Base 上增加一个轻量的并行流匹配动作分支（约 1.6 亿参数；DiT 块深度与 GE-Base 相同但隐藏维度更小），把视觉潜在表征映射为结构化的动作轨迹；二手资料称可在普通 GPU 上约 200 毫秒内生成 54 步轨迹
GE-Sim	神经模拟器	把 GE-Base 改造成动作条件化的视频生成器，用于闭环策略评估与可控数据生成

GE-Base 以自回归分块的方式、以机器人视觉观察为条件生成视频。

跨本体迁移：论文报告，GE-Act 仅用约 1 小时遥操作示范即可迁移到双臂 Franka、松灵 Cobot Magic 等其他机器人上。

配套发布了 EWMBench（具身世界模型基准），从视觉保真度、物理一致性、指令-动作对齐等维度评估世界模型（代码与数据见 GitHub AgibotTech/EWMBench）。

3.2 闭环：策略 ↔ 世界模型

```
GE-Act（策略）生成动作轨迹
        |
        ▼
GE-Sim 把动作"渲染"为未来视觉状态
        |
        ▼
新的视觉状态反馈给策略 → 继续生成动作
        |
        ▼
形成"想象中的闭环"：评估策略、发现失败、生成训练数据
```

3.3 意义与局限

意义：Genie Envisioner 是中国本体公司中最早、最完整的开源”世界模型 + 动作 + 模拟器”平台之一，与 NVIDIA Cosmos、1X 世界模型同期。它把”视频世界模型”从生成工具变成了机器人研发的基础设施。

局限：论文作者承认，GE 依赖单一的大规模真实数据集（AgiBot World），本体与场景多样性受限。

3.4 演进：GE-Sim 2.0 与 GE-2

- GE-Sim 2.0（2026.04.10）：可训练、可交互的仿真环境升级；
- GE-2：据报道与 GO-2 协同使用的新一代世界模型（有媒体称其在 2026 World Arena 世界模型赛道获得总分冠军，但未见官方来源确认）；
- Genie Sim 3.0：GO-2 的零样本跨域评测平台。

---

4. 代表作三：GO-2（2026.04）→ GO-3 Preview（2026.10.29）

4.1 GO-2：动作思维链 + 异步双系统（2026.04.09）

> 发布：2026 年 4 月 9 日；相关成果被 CVPR 2026 接收。

问题：GO-1 等 VLA 存在”理解意图”与”稳定执行”之间的断层——模型知道要做什么，但执行时动作不连贯、长程任务易出错。

两项核心创新： 1. 动作思维链（Action Chain-of-Thought）：在执行之前，先在动作空间中生成高层动作序列作为规划——类似 LLM 的思维链，但”思考”的载体不是文字，而是粗粒度的动作序列。这让模型”先想清楚整体怎么动，再精细执行”； 2. 异步双系统：低频规划（生成动作思维链）与高频跟随（执行精细动作）异步协同——规划慢、执行快，互不阻塞。

结果（智元口径）： - LIBERO 平均成功率约 98.5%； - 在 Genie Sim 3.0 的零样本跨域评测中成功率约 82.9%； - 依托 Genie Studio 平台实现规模化部署，训练效率提升约 10 倍； - 真实产线验证：2026 年 6 月，搭载 GO-2 的精灵 G2 在龙旗科技工厂进行了 6 天真实产线直播，8 小时连续作业综合成功率超过 99.5%（据百科条目）。

“动作思维链”与同类工作的对比：

工作	“思考”的载体	时间
Gemini Robotics 1.5 思考型 VLA	自然语言	2025.09
π0.5 高层子任务	自然语言	2025.04
π0.7 / 腾讯 RxBrain	子目标图像	2026
智元 GO-2 动作思维链	粗粒度动作序列	2026.04
星海图 G0.5 原生动作思维链（第 39 章）	动作	2026.08

解读：用”动作”而非”语言”作为思维链载体，是 2026 年中国团队（智元、星海图）提出的一个有特色的方向——它绕开了”语言难以描述物理动作”的问题（与小鹏”去语言 VLA”的动机相近），同时保留了”先规划、后执行”的结构。

4.2 GO-3 Preview：具身原生架构 WRAM（2026.10.29）

> 发布：2026 年 10 月 29 日，智元创新日（上海世博中心），由联合创始人姚卯青发布。

架构：WRAM（World Reasoning Action Model，世界推理动作模型） - 智元自研的”具身原生架构”； - 把任务推理、未来预测（世界模型）与动作生成统一建模——即把 GO 系列（VLA/动作思维链）与 GE 系列（世界模型）融合到一个模型中； - 目标：跨任务泛化与精细操作。

训练体系： - Genie Evolver：真机、仿真与世界模型协同的后训练系统； - Genie Master：具身智能体框架； - 覆盖预训练 → 后训练 → 部署后的全链路规模化学习（即”部署态”持续学习）。

榜单（智元口径）：宣称登顶 RoboDojo、RoboTwin、RoboColiseum 三大评测榜单。需要注意： - 在 RoboDojo 公开榜上排第一的是同系列的 GO-3 Nano Preview（平均分 61.90、平均成功率 56.42%），完整版 GO-3 Preview 的分数未公开； - 作为对照：小米 Xiaomi-Robotics-1 在 2026 年 7 月时的 RoboDojo 成绩为平均分

20.07、成功率 13.93%——如果两者为同一评测口径，则 GO-3 Nano Preview 的进步幅度极大（本报告无法确认两者评测版本/口径是否完全一致，读者应谨慎比较）。

开源计划：GO-3 Preview 与 Genie Master 计划于 2026 年底全面开源。

4.3 同日发布的其他内容

- WITA-OMNI：具身全模态端到端交互大模型，支持 100 多种语言的极速交互；
- Worken：智元提出的"物理 AI 的度量单位"——有效智能工作时长（类比大模型时代的 Token）。彭志辉认为物理 AI 将经历"五次跃迁"，并以 Worken 衡量机器人创造的真实生产力；
- 灵渠 OS 1.0：机器人操作系统，开源并捐赠给开放原子开源基金会；
- 硬件：第三代硬件架构 AHA3、新一代灵巧手产品家族、重载人形 精灵 G2 Max 等。

"部署态"叙事：2026 年智元创新日的主题是"部署态"——强调机器人从"演示态"走向"真实部署中持续工作并持续学习"。这与 PI（RECAP）、Skild（ARR）、Generalist（99% 可靠性）等全球玩家在 2026 年的叙事转向一致。

---

5. 技术路线总结



---

6. 横向对比与身位

维度	智元	宇树（第 31 章）	Figure（第 7 章）	NVIDIA（第 3 章）
出货（2026H1）	9700 台（公司口径）	头部	数百台级	不造本体
开源数据集	AgiBot World（全球影响力大）	G1 数据集	无	合成数据
VLA	GO-1 → GO-2 → GO-3	UnifoLM-VLA/WLA	Helix 系列	GR00T
世界模型	Genie Envisioner、GE-2	WMA-0、WLA（轻量）	—	Cosmos、DreamZero
融合方向	WRAM（2026.10）	WLA（2026.09）	—	WAM（GR00T N2，2026 年底）

一个有趣的观察：2026 年 9–10 月，中美多家公司几乎同时提出了”推理 + 世界预测 + 动作”的统一架构——宇树 WLA（9 月）、智元 WRAM（10 月）、NVIDIA WAM/GR00T N2（预告 2026 年底）、腾讯 RxBrain（7 月）、π0.7（4 月，世界模型生成子目标）。“VLA 与世界模型的融合”已成为 2026 年下半年最明确的行业共识。

身位：智元是中国具身产业”本体 + 数据 + 大脑”综合实力最强的公司之一——出货量领先、数据集全球影响力大、VLA 与世界模型双线布局完整、开源力度大。

---

7. 未来展望与风险

展望： 1. GO-3 年底开源：若如期开源，将成为中国乃至全球开源具身基座的重要事件； 2. 2 万台部署的数据飞轮：随着出货量增长，“部署态”数据回流将成为智元大脑持续进化的核心燃料； 3. Worken 叙事：若”有效智能工作时长”被行业接受，可能成为衡量具身智能商业价值的标准指标。

风险： 1. 评测口径：多个”登顶”宣称来自智元自己或特定榜单，第三方独立验证不足；GO-3 完整版成绩未公开； 2. 出货口径差异：公司口径（9700 台、43%）与 IDC 口径（8600 台以上、35%）存在差异； 3. 产品矩阵过宽：同时做全尺寸人形、轮式双臂、小尺寸人形、四足，研发资源分散。

---

8. 延伸阅读与核验来源

三篇代表作 - AgiBot World + GO-1：*AgiBot World Colosseo*（2025）；GO-1 新闻稿；Interesting Engineering - Genie Envisioner：arXiv 2508.05635；第一财经 - GO-2：腾讯新闻：GO-2 发布；凤凰网；百度百科 GO-2 - GO-3 Preview：21 经济网；投资界：GO-3 Preview 拿下三大榜单；雷科技；中华网：GO-3 Preview 与 Genie Master 开源计划

出货与经营 - IDC：2026 上半年中国人形机器人出货近 2 万台，智元领先 - 新浪科技：智元上半年收入近 20 亿元，发布 Worken；澎湃新闻 - 新浪财经：WITA-OMNI

> 核验说明：AgiBot World 的规模（100 万+ 轨迹、217 任务、5 领域）来自论文与报道（“约 3000 小时”来自 GE 论文对 AgiBot-World-Beta 的描述）；GO-1 的 ViLLA 架构（InternVL-2B、潜在规划器、动作专家）与 66%→78% 来自智元官方；GE 的三组件与 GE-Act 约 1.6 亿参数来自论文与新闻稿；GO-2 的 LIBERO 98.5%、Genie Sim 3.0 82.9%、CVPR 2026 来自官方发布，龙旗产线 99.5% 来自百科条目；GO-3 Preview 为 2026-10-29 发布，WRAM 架构、三榜单宣称、Nano 版 RoboDojo 61.90/56.42% 与年底开源计划来自当日多家媒体（官方口径，完整版成绩未公开）；“GE-2 获 World Arena 冠军”未见官方确认。补充核验：GE-Base 的自回归分块生成、GE-Act 的并行流匹配分支（同深度、更小隐藏维度）、约 1 小时数据迁移到双臂 Franka 与松灵 Cobot Magic、EWMBench 的三个评估维度来自论文；“约 200 毫秒生成 54 步轨迹”为二手资料。

第 33 章 优必选（UBTech）：港股”人形第一股”的工业路线——群脑网络、Co-Agent 与 Thinker

> 一句话定位：优必选是全球最早上市的人形机器人公司之一（港交所 9880），也是中国工业人形商业化最早的玩家：Walker S 系列进入比亚迪、吉利/极氪、东风柳汽、富士康等工厂”实训”，Walker S2 于 2025 年 11 月开启量产交付，2025 年人形订单据报道超过 14 亿元；2026 年 3 月与西门子签约合作，上半年全尺寸人形销量 921 台。其大脑路线与”通用 VLA”派不同，走的是”工业场景驱动的分层智能”：群脑网络（BrainNet） 让多台机器人在工厂中协同与共享技能，Co-Agent 智能体融合推理大模型、具身交互大模型与技能小模型，Thinker（基于 Qwen3-VL 的 4B 具身 VLM，2026 年初开源）作为感知与推理底座。德本咨询《2026 中国具身大模型 TOP30》将优必选列为第一名——这一排名反映的是”落地能力”，而非学术前沿性。

0. 速览卡片

维度	内容
成立	2012 年，深圳
创始人	周剑（董事长兼 CEO）
上市	2023 年 12 月港交所上市（9880）
人形产品	Walker（2018 起）→ Walker X → Walker S / S1（工业实训）→ Walker S2（2025.11 量产交付，全球首创自主热插拔换电）→ Walker S3（规划，单一来源）；另有 Tiangong Walker（与北京人形合作）等
订单与交付	2025 年 11 月称 Walker 系列年内订单超 8 亿元；第一财经报道 2025 年人形订单总额超 14 亿元；2026 年上半年全尺寸人形销量 921 台（同比大增，KrASIA 报道）；2026 年产能目标 5000 台、2027 年 1 万台
合作	比亚迪、吉利/极氪、东风柳汽、一汽-大众青岛、富士康、顺丰等工厂与物流实训；2026.03.16 与西门子签约合作
大脑	群脑网络 BrainNet（1.0 → 2.0）、Co-Agent（工业人形智能体）、Thinker（4B 具身 VLM，基于 Qwen3-VL，2026 年初开源，非商业许可）
本章三篇代表作	① 群脑网络 BrainNet：多机协同与技能共享 ② Co-Agent：面向工业人形的分层智能体 ③ Thinker：开源具身视觉语言模型
身位	工业人形商业化与落地第一梯队；大脑路线偏工程化、分层化，学术前沿性弱于大脑公司

1. 故事的开端：从教育机器人到工厂里的人形

优必选早年以舵机起家，推出 Alpha 系列小型人形与教育机器人，在 2018 年发布第一代 Walker 大型人形。2023 年港股上市后，优必选做出一个关键决策：把人形机器人的主战场放在工厂。

理由很现实： - 工厂场景结构化程度高、任务重复性强，是人形最可能率先产生经济价值的地方； - 中国汽车与 3C 制造业规模巨大，对柔性自动化需求强烈； - 工厂中的真实任务（搬运料箱、质检、分拣、装配）是训练大脑的最佳数据源。

2024–2025 年，Walker S 系列陆续进入比亚迪、极氪、东风柳汽、富士康等工厂进行"实训"。这种"工厂实训"模式后来被小米（汽车工厂 4 个月实训）、Boston Dynamics（现代 Metaplant 应用中心）等广泛采用。

---

2. 代表作一：群脑网络 BrainNet（2025）——让一群机器人共享一个"大脑"

2.1 问题

工厂里不是一台机器人在工作，而是多台机器人在同一条产线上协同：一台搬料箱、一台分拣、一台质检。传统方案中，每台机器人各自独立决策，无法协同，技能也无法共享。

2.2 方案

优必选提出群脑网络（BrainNet）——一个面向多台人形机器人协同的分层智能框架： - "超级大脑"（云端/边缘）：负责全局任务分配、多机协同调度、复杂推理； - "智能小脑"（每台机器人）：负责本体的运动控制与技能执行； - 技能共享：一台机器人在实训中学到的技能，可以通过群脑网络共享给其他机器人。

2025 年，优必选展示了数十台 Walker S1 在极氪工厂中协同实训的场景——多台机器人在总装车间、SPS 仓储区、质检区分工协作完成搬运、分拣、质检等任务。随后升级为 BrainNet 2.0，与 Walker S2 一同交付。

2.3 意义

BrainNet 与智源的 RoboOS（第 24 章）、DeepMind 的 ER 2 多机协同（第 1 章）在思想上相通，但优必选的特点是从真实工厂场景出发——它首先要解决的是"十几台机器人在一条产线上如何不打架、如何分工"的工程问题。

---

3. 代表作二：Co-Agent（2025）——面向工业人形的分层智能体

3.1 定位

Co-Agent 被优必选称为全球首个专用于工业人形机器人本体的智能体技术。其核心是把三类模型融合在一个智能体框架中：

模型	职责
多模态推理大模型	理解意图、任务规划、异常判断
具身交互大模型	连接感知与动作，理解场景中的物体与空间关系
技能小模型	执行具体技能（抓取、放置、搬运等），高频、可靠

3.2 能力

- 意图理解：理解工人或系统下达的任务；
- 任务规划：把任务拆解为技能序列；
- 异常处理：遇到意外（物体掉落、位置偏差）时能识别并恢复。

3.3 与 VLA 路线的区别

Co-Agent 体现的是一种”大模型编排 + 技能小模型执行”的分层路线——与 SayCan（2022）、Gemini Robotics-ER + VLA、Robix + GR-3 属于同一思想谱系，但在执行层更强调”可靠的技能小模型”而非”端到端 VLA”。在工业场景中，这种设计的优势是可控、可调试、可认证；劣势是新技能的扩展成本较高。

3.4 配套硬件能力：自主热插拔换电

Walker S2 的一大卖点是全球首创的自主热插拔换电——机器人可以自己走到换电站更换电池，无需停机或人工干预，从而实现接近 7×24 小时的连续作业。这与大脑能力直接相关：连续作业意味着连续的数据回流与持续的”部署态”学习。

---

4. 代表作三：Thinker（2026 年初开源）——工业具身 VLM

> 据维基百科与相关报道：优必选于 2026 年初（1 月或 2 月，来源不一）开源自研视觉语言模型 Thinker；有报道称其为基于 Qwen3-VL 的约 4B 参数模型，采用非商业许可。

4.1 定位

Thinker 是优必选的具身感知与推理底座——在 Co-Agent 体系中承担”具身交互大模型/多模态推理”的角色： - 理解工厂场景（料箱、零件、工位、标识）； - 空间推理（位置、朝向、可抓取部位）； - 任务理解与规划。

4.2 关于 Thinker 3.0 的说法

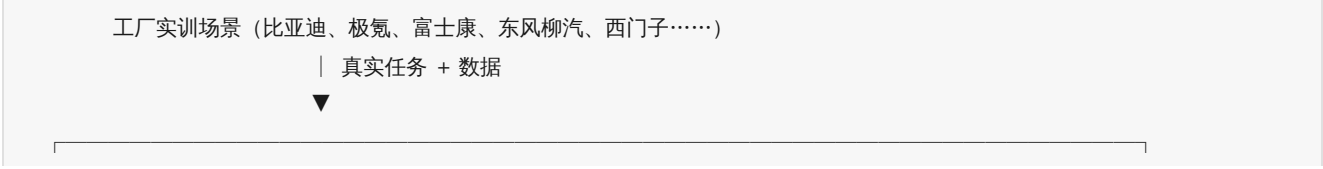
有单一财经来源称优必选在 2026 年 2 月发布了”Thinker 3.0”，定位”小参数、高性能、全开源”，并称 Walker S3 将于 2026 年第三季度上市并集成 Thinker 3.0——这些信息未找到官方公告或开源仓库的直接证据，本报告不作确认。

4.3 意义

Thinker 的开源表明优必选也在跟随”自研 + 开源具身基座”的行业潮流。但与智源 RoboBrain、阿里 RynnBrain、宇树 UnifoLM 等相比，Thinker 的公开技术细节与评测较少，更多作为优必选工业解决方案的内部组件。

---

5. 技术路线总结





优必选的大脑哲学可以概括为："可靠落地优先，分层可控优先"。

---

6. 横向对比与身位

维度	优必选	智元	宇树	Figure
主战场	工业（汽车、3C、物流）	工业 + 商业 + 科研	科研 + 消费 + 工业	工业 + 家庭
大脑路线	群脑 + Co-Agent + Thinker（分层）	GO 系列 VLA + GE 世界模型	UnifoLM（世界模型 + VLA）	Helix 端到端三层
多机协同	BrainNet（核心卖点）	Genie Master	—	Helix 多机协作（早期演示）
开源	Thinker（非商业）	积极	积极	无

身位： - 工业落地：中国第一梯队，客户名单与工厂实训数量领先； - 大脑前沿性：中等——优必选的大脑更像"工业智能系统"而非"通用基础模型"，学术与开源影响力弱于智元、宇树、字节等； - 在德本咨询等以"落地能力"为权重的榜单中排名靠前，在以"模型前沿性"为标准的评测中则不突出。

---

7. 未来展望与风险

展望： 1. 西门子合作：与工业自动化巨头的合作可能把 Walker S2 带入全球制造业； 2. 换电 + 连续作业：使工厂数据飞轮成为可能； 3. 大脑的端到端化：随着 VLA 技术成熟，Co-Agent 中的技能小模型可能逐步被端到端模型替代。

风险： 1. 订单到交付的转化：订单金额与实际交付、产能利用率之间存在差距（有报道称 2026 年中产能利用率偏低，但数据存在冲突）； 2. 盈利压力：上市公司持续亏损背景下，研发投入与商业化需要平衡； 3. 大脑能力的追赶：在通用大脑能力上，需要与智元、宇树以及大厂开源模型竞争。

---

8. 延伸阅读与核验来源

- PR Newswire：Walker S2 量产交付，订单超 8 亿元
- 网易：首批数百台 Walker S2 量产交付；moguoai：BrainNet 2.0 与 Co-Agent

- Wikipedia：UBtech Robotics（Thinker 开源）
- AI Business：优必选完成首批大规模人形交付
- 东方财富：2026 年优必选规划（单一来源）
- 搜狐时间线：德本咨询 2026 中国具身大模型 TOP30

> 核验说明：Walker S2 量产交付时间、BrainNet 2.0、Co-Agent 构成来自官方新闻稿与多家媒体；订单金额存在"超 8 亿元（官方 2025.11）"与"超 14 亿元（第一财经）"两种口径；2026 年上半年 921 台来自 KrASIA 报道；Thinker 的开源时间（1 月或 2 月）与"4B、基于 Qwen3-VL、非商业许可"来自维基百科与二手来源；Thinker 3.0 与 Walker S3 仅见于单一来源，未予确认；西门子合作来自二手报道。

第 34 章 美的集团（AI 研究院）：家电巨头的”VLA 论文工厂”——DiffusionVLA、DexVLA、ChatVLA 与 PointVLA

> 一句话定位：美的集团（库卡机器人的母公司）的 AI 研究团队与华东师范大学等高校合作，在 2024 年底至 2025 年间连续发表了一系列有影响力的 VLA 论文：DiffusionVLA（自回归推理 + 扩散动作）、DexVLA（十亿参数可插拔扩散动作专家 + 具身课程学习，CoRL 2025）、ChatVLA / ChatVLA-2（统一多模态理解与机器人控制、开放世界推理）、PointVLA（向 VLA 注入 3D 点云）。这些工作集中回答了 VLA 设计中的四个关键问题——推理如何进入动作、动作专家要多大、VLA 如何不遗忘语言能力、3D 信息如何注入。美的代表了”制造业巨头以研究院形式切入机器人大脑”的模式，其研究成果被学术界广泛引用和对比。

0. 速览卡片

维度	内容
机构	美的集团 AI 研究院 / 机器人相关研究团队（与华东师范大学、上海大学等合作）
产业背景	美的于 2017 年收购德国工业机器人巨头库卡（KUKA）；家电、楼宇、工业自动化等丰富场景
代表研究者	朱益辰（Yichen Zhu）、Junjie Wen、Feifei Feng 等（论文作者）
代表工作	DiffusionVLA（2024.12）、DexVLA（2025.02，CoRL 2025）、ChatVLA（2025.02）、PointVLA（2025.03）、ChatVLA-2（2025）
开放程度	论文公开，部分代码与权重开源
本章三篇代表作	① DexVLA：十亿参数可插拔扩散专家与具身课程学习 ② ChatVLA / ChatVLA-2：统一理解与控制，保留 VLM 能力 ③ PointVLA：向 VLA 注入 3D 世界（附 DiffusionVLA）
身位	学术影响力较强的企业研究团队；产业化路径（家电/工业场景）尚在探索

1. 故事的开端：一家家电公司为什么研究 VLA？

美的是全球最大的家电制造商之一，同时通过库卡拥有全球领先的工业机器人业务。这给了美的两个独特视角： - 工业机器人视角：传统工业机器人靠编程，换一个任务就要重新编程——VLA 有望让机器人”听懂指令、自主完成”； - 家庭场景视角：家电是家庭中最普遍的”机器”，未来的家务机器人必然要与家电交互（开冰箱、操作洗衣机、装洗碗机）。

美的的研究团队选择了一条”以论文和开源方法影响行业”的路线：在 2024–2025 年 VLA 架构快速演化的窗口期，针对每一个关键设计问题提出自己的方案。

2. 代表作一：DexVLA（2025.02，CoRL 2025）——十亿参数的可插拔扩散动作专家

> 论文：Junjie Wen, Yichen Zhu 等，*DexVLA: Vision-Language Model with Plug-In Diffusion Expert for General Robot Control*（arXiv 2502.05855，CoRL 2025）——美的集团、华东师范大学。

2.1 核心问题：动作专家应该多大？

2024–2025 年的主流 VLA 中，动作专家通常很小：π0 约 3 亿参数、GR00T N1 的 DiT 也只有数亿参数。美的团队提出一个问题：如果 VLM 有数十亿参数，而动作专家只有几百万到几亿，动作生成会不会成为瓶颈？ 尤其是在跨本体（单臂、双臂、灵巧手、移动双臂）的复杂场景中。

2.2 方案：可插拔的十亿参数扩散专家

设计	内容
扩散动作专家规模	扩展到 约 10 亿参数（基于 ScaleDP 等可扩展扩散策略架构），远大于此前常见的数百万到数亿规模
多头结构	动作专家采用多头架构，每个头对应一种特定本体——共享主干学习通用动作知识，各头适配本体差异
可插拔	动作专家可以作为独立模块"插"到不同的 VLM 上

2.3 具身课程学习（三阶段）

```
阶段一：在跨本体数据上预训练扩散专家
        （只训练动作专家，学习通用的低层运动技能）
            ↓
阶段二：将 VLA 与特定本体对齐
        （联合 VLM 与动作专家，对齐到目标机器人）
            ↓
阶段三：后训练，快速适应新任务
        （少量数据即可学会新任务）
```

这种"由易到难"的课程设计，让大规模动作专家能够在有限数据下稳定训练。

2.4 结果

- 在单臂、双臂、灵巧手、移动双臂等多种机器人上测试，许多任务在无需任务专门适配的情况下即达到高成功率；
- 在长时程叠衣服任务上，直接提示（不微调）时大幅超过 π0；
- 整体优于 Octo、OpenVLA、Diffusion Policy 等。

2.5 意义

DexVLA 的核心贡献是提出"动作专家也需要规模化"——这一观点后来被 π0.6（动作专家扩到 8.6 亿）、GR00T N1.6（DiT 加深到 32 层）、Xiaomi-Robotics-0（16 层 DiT）等工作在不同程度上印证。

---

3. 代表作二：ChatVLA 与 ChatVLA-2（2025）——VLA 能否既会聊天又会干活？

3.1 问题：VLA 的"灾难性遗忘"

把 VLM 微调成 VLA 后，模型往往丧失原有的视觉问答、对话与推理能力——这既浪费了 VLM 的知识，也让机器人无法与人自然交流。（PI 的知识隔离 KI 论文也关注同一问题，见第 2 章。）

3.2 ChatVLA（2025.02）：分阶段对齐 + 混合专家

> 论文：*ChatVLA: Unified Multimodal Understanding and Robot Control with Vision-Language-Action Model*（2025.02）

两个关键设计： 1. 分阶段对齐训练（Phased Alignment Training）：先训练控制能力，再逐步引入多模态理解数据——避免两类任务在训练初期相互干扰； 2. 混合专家（MoE）：在 Transformer 的 MLP 层设置"理解专家"与"控制专家"两组参数，共享注意力层——让两类任务在共享表征的同时，在各自的专家中保留专门能力，减少任务干扰。

结果：ChatVLA 在多模态理解基准（如 MMMU、MMStar 等）上保持了有竞争力的成绩，同时在 25 项真实机器人操作任务上优于 OpenVLA 等现有 VLA——即"一个模型既能聊天问答，又能控制机器人"。

3.3 ChatVLA-2：开放世界具身推理

ChatVLA-2 进一步追求"可执行的推理"——让 VLA 把 VLM 的开放世界知识真正用于动作： - 采用混合专家结构与三阶段训练流程，在保留 VLM 原有能力的同时实现可执行的推理； - 典型演示（据论文介绍）：机器人看懂白板上的数学题并据此摆放对应的数字卡片、识别训练中未见过的物体并据此执行操作——即推理结果直接驱动动作。

3.4 意义

ChatVLA 系列与 PI KI（梯度隔离）、Gemini Robotics 1.5（思考型 VLA）、π0.5（协同训练网络数据）一起，构成了 2025 年"如何让 VLA 保持并利用 VLM 能力"这一问题的几种代表性答案：

方案	机制
π0.5	机器人数据与网络数据协同训练
PI KI	动作专家到 VLM 的梯度截断
ChatVLA	MoE：理解专家与控制专家分离，共享注意力
Gemini Robotics 1.5	思考与动作交错

4. 代表作三：PointVLA（2025.03）——把 3D 世界注入 VLA

> 论文：*PointVLA: Injecting the 3D World into Vision-Language-Action Models*（arXiv 2503.07511）

4.1 问题

绝大多数 VLA 只用 RGB 图像。但机器人操作本质上是三维的——物体高度、深度、空间关系都需要精确感知。直接把点云喂给 VLM 需要重新预训练，代价巨大。

4.2 方案：只向动作专家注入 3D，而不动 VLM

- 以 DexVLA 为基础：VLM 为 Qwen2-VL-2B，动作专家为 1B 参数的 ScaleDP；
- VLM 保持不变（继续用 2D 图像做语义理解）；
- 用一个轻量的点云编码器提取 3D 特征，以模块化方式注入到动作专家中；
- “跳块分析（skip-block analysis）”：分析动作专家中哪些 Transformer 块对性能贡献最小，把 3D 特征注入这些”不太重要”的块——在不破坏已学到的 2D 能力的前提下增加 3D 感知。

4.3 结果

- 少样本多任务：少量示范即可学会多个任务；
- 真实物体 vs 照片的区分：能区分真实的物体与物体的照片（纯 2D 模型容易被照片”骗”）；
- 高度适应：能处理训练数据中未出现过的不同桌面高度上的物体——这是 2D VLA 的典型失败场景。

4.4 附：DiffusionVLA（2024.12）

美的更早的 DiffusionVLA 把自回归推理（由 VLM 生成语言推理）与扩散策略（生成动作）结合，并设计了一个推理注入模块，把推理结果直接注入到策略学习中——是”思考型 VLA”的早期探索之一。

---

5. 技术路线总结：美的 VLA 研究的四个问题

问题	美的的回答	代表作
推理如何进入动作？	推理注入模块	DiffusionVLA
动作专家要多大？	十亿参数 + 多头 + 课程学习	DexVLA
如何不遗忘 VLM 能力？	分阶段对齐 + 理解/控制 MoE	ChatVLA / ChatVLA-2
3D 信息如何注入？	只注入动作专家 + 跳块分析	PointVLA

---

6. 横向对比与身位

维度	美的 AI 研究院	字节 Seed	阿里达摩院
性质	制造业巨头的研究院	互联网大厂 AI 团队	互联网大厂研究院
代表方向	VLA 架构设计（动作专家规模、MoE、3D 注入）	视频预训练 + RL	具身大脑 + 世界模型 + 协议
本体与场景	库卡工业机器人、家电场景	ByteMini（研究）	不做本体
开源	部分	部分	积极

身位：美的在 VLA 架构设计研究方面具有明显的学术影响力（多篇论文被广泛引用与对比）；但截至 2026 年 10 月，其在人形机器人产品与大规模部署上的公开进展有限，研究成果向产品的转化路径仍不清晰。

---

7. 未来展望与风险

展望： 1. 家电 + 机器人融合：美的在家电场景的深厚积累，可能让其在"家务机器人与家电协同"上形成独特优势； 2. 库卡 + VLA：把 VLA 能力引入库卡工业机器人，可能是最直接的商业化路径； 3. 持续的架构创新：美的研究团队在 VLA 设计上的创新速度，使其成为学术界的重要参与者。

风险： 1. 研究与产品脱节：论文影响力不等于产品竞争力； 2. 人才竞争：具身领域顶尖人才向创业公司与大厂集中，研究院模式的人才保持面临挑战； 3. 2026 年动态不足：本次检索未找到美的 2026 年在人形机器人上的重大公开进展。

---

8. 延伸阅读与核验来源

- DexVLA：arXiv 2502.05855；CoRL 2025（PMLR）
- PointVLA：arXiv 2503.07511
- ChatVLA：arXiv 2502.14420；ChatVLA-2：2025 年发布（见美的/华东师大作者主页）
- DiffusionVLA：arXiv 2412.03293
- Robotics Center：美的集团机构页

> 核验说明：DexVLA 的十亿参数扩散专家、多头结构、三阶段课程、超越 π0 的叠衣服结果来自论文；PointVLA 的 Qwen2-VL-2B + 1B ScaleDP 与跳块分析来自论文；ChatVLA 的分阶段对齐 + MoE、25 项真机任务来自论文摘要，ChatVLA-2 的演示内容基于论文介绍的公开描述；ChatVLA/ChatVLA-2/DiffusionVLA 的 arXiv 编号为本报告根据公开记录整理，建议以论文页面为准；美的 2026 年人形进展本次未检索到确切信息。

第 35 章 逐际动力（LimX Dynamics）：“模型只是技能，系统才是大脑”——COSA 具身智能体操作系统

> 一句话定位：逐际动力是中国运动控制最强的足式/人形机器人公司之一，其双足（P1、TRON 1）与人形（CL-1、Oli）以强化学习运动控制著称。2026 年，逐际提出了一个与”端到端单一大模型”截然不同的大脑主张——“模型只是技能，系统才是大脑”：发布 LimX COSA（Cognitive OS of Agents，具身智能体操作系统，2026.01.12），构建 System 0（全身运动基础模型）+ System 1（人形 VLA / 全身动作模型 WAM）+ System 2（以大语言模型与世界模型为引擎的智能体操作系统） 的三层架构；7 月发布 COSA 0.5，以全尺寸人形 Oli 一镜到底、无遥操作、无剪辑地完成整屋家务。同月完成近 2 亿美元 Pre-IPO 融资，投后估值约 150 亿元。

0. 速览卡片

维度	内容
成立	2022 年，深圳
创始人	张巍（南方科技大学教授，曾任教于美国俄亥俄州立大学，控制理论与机器人专家）
产品	P1（点足双足，2023）→ TRON 1（多形态双足，2024）→ CL-1（人形，2024，展示连续上下楼梯）→ Oli（全尺寸人形，2025）
大脑	LimX COSA（2026.01.12 发布）→ COSA 0.5（2026.07.15）；三层：System 0 / System 1（VLA/WAM）/ System 2（COSA）；FluxVLA Engine（企业级开源平台）
资本	2026 年 3 月完成股改，IPO 推进中；2026.07.14 宣布近 2 亿美元 Pre-IPO 融资，投后估值约 150 亿元；半年累计融资约 4 亿美元
本章三篇代表作	① System 0：强化学习全身运动基础模型（从 P1/TRON 1 到 Oli）② System 1：人形 VLA/WAM 与 FluxVLA Engine ③ LimX COSA / COSA 0.5：具身智能体操作系统
身位	运动控制第一梯队；“系统派”大脑路线的代表

1. 故事的开端：控制理论学者的”系统观”

张巍是控制理论出身的学者，在俄亥俄州立大学任教多年后回国加入南方科技大学。控制理论的核心思想是”系统”：一个复杂系统由多个子系统组成，每个子系统有自己的时间尺度与职责，通过反馈回路协同工作。

这种系统观深刻影响了逐际的大脑路线。当行业在 2025 年热烈讨论”端到端 VLA 是否就是机器人大脑”时，逐际的回答是：不是。VLA 是一种技能，而大脑是一个能调度技能、理解世界、规划任务、处理异常的”操作系统”。

2. 代表作一：System 0——强化学习全身运动基础模型

2.1 从点足双足到全尺寸人形

逐际的运动控制能力是在一系列"难控"的平台上锤炼出来的：

平台	年份	特点与挑战
P1	2023	点足双足（脚是一个点，没有脚掌支撑面）——静态不稳定，必须持续动态平衡，是 RL 运动控制的"极限测试"。P1 曾在野外复杂地形中完成盲走测试
TRON 1	2024	多形态双足（点足/足掌/轮足可切换）——同一套控制方法适配多种足端
CL-1	2024	人形，展示了基于 RL 的连续上下楼梯等动态地形能力
Oli	2025	全尺寸人形，面向家务等全身操作场景

2.2 System 0 的定位

System 0 = 全身运动基础模型： - 让机器人在手臂、腿部、躯干协同运动的同时保持稳定； - 在逐际的规划中，它解决的是机器人"能走、能稳、能全身协调"的问题； - 技术路线为"仿真中大规模强化学习 + sim2real"（与 Figure S0、NVIDIA SONIC、Agility 运动皮层同属一类）。

逐际未公开 System 0 的具体模型结构与训练指标。

---

3. 代表作二：System 1——人形 VLA / 全身动作模型（WAM）与 FluxVLA Engine

3.1 System 1 的组成

- 人形 VLA：视觉-语言-动作模型，负责从感知与指令生成操作动作；
- 全身动作模型（WAM，Whole-body Action Model）技能：面向人形全身操作的动作模型；
- 训练基础设施：训练上述模型所需的数据与训练工具链。

（注："WAM"在不同公司语境中含义不同：在 NVIDIA/银河通用中常指"世界动作模型（World Action Model）"，在逐际的公开表述中为"全身动作模型"。）

3.2 FluxVLA Engine

逐际推出 FluxVLA Engine，定位为企业级开源平台，用于 VLA 的训练、部署与管理。这与 Hugging Face LeRobot、智平方 AlphaBrain Platform、上海 AI Lab InternManip 等形成竞争——体现了 2026 年中国具身公司"以开源平台建立开发者生态"的趋势。

3.3 定位：技能，而非大脑

在逐际的体系中，System 1 的 VLA/WAM 被明确定位为”技能”——它们是 COSA 可以调用的能力模块，而不是整个大脑。这与 Figure（Helix S1 是大脑的一部分）、PI（π 系列 VLA 本身就是大脑）在概念上有本质区别。

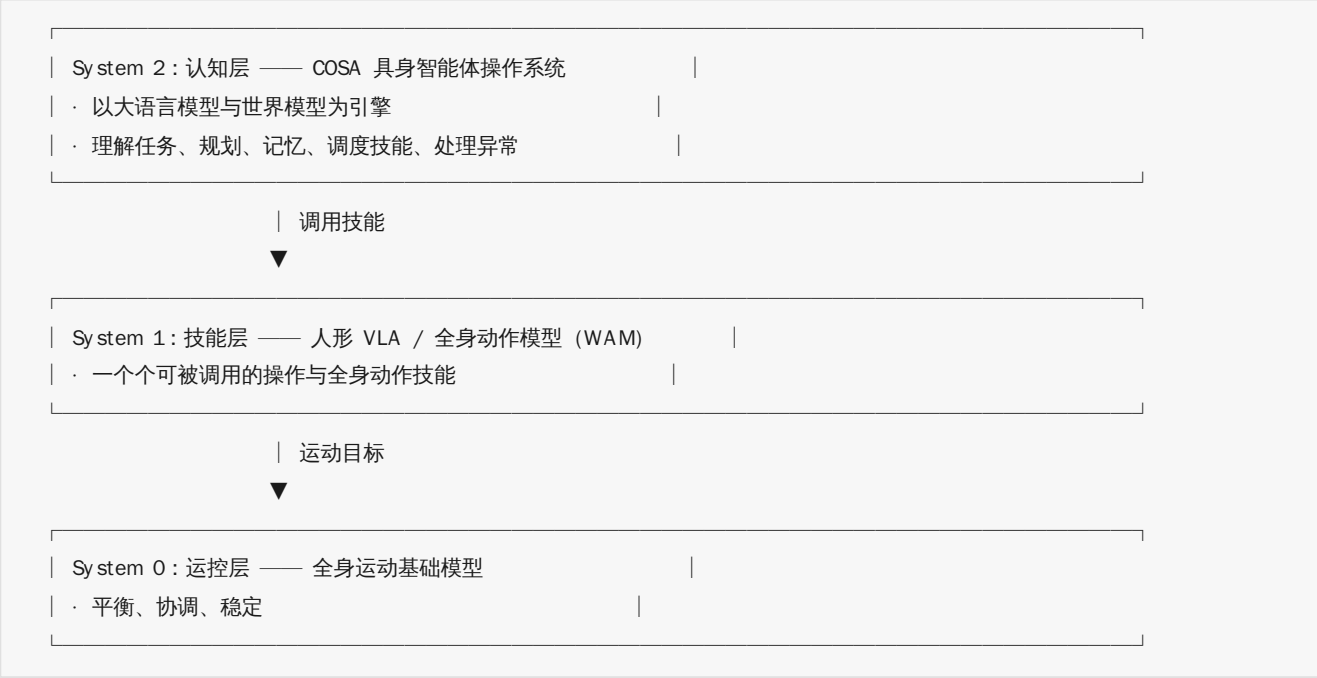
---

4. 代表作三：LimX COSA（2026.01）→ COSA 0.5（2026.07）——具身智能体操作系统

> 发布：LimX COSA（2026-01-12）；COSA 0.5（2026-07-15）。

4.1 COSA 是什么

COSA（Cognitive OS of Agents） 被定位为面向物理世界的具身 Agentic OS——目标是让机器人同时具备认知与全身运控能力。



4.2 “模型只是技能，系统才是大脑”

逐际的核心论点：- 单一的 VLA 模型擅长”在某个场景下完成某类动作”，但长时程、多任务、需要记忆与异常处理的真实家务，需要一个更高层的”操作系统”来组织；- 大脑 = 认知（理解与规划）+ 记忆 + 技能调度 + 异常处理 + 运控——这是一个系统工程问题，而不仅是一个模型问题；- 类比：手机的”大脑”不是某个 App，而是操作系统。

4.3 COSA 0.5 演示

2026 年 7 月 15 日，逐际发布 COSA 0.5，并用全尺寸人形 Oli 演示了：- 一镜到底、无遥操作、无剪辑的家务场景；- 机器人不间断地完成一整屋家务。

这类”一镜到底 + 无遥操作”的演示，与 Figure Helix 02 的 4 分钟洗碗机任务、1X 被质疑的遥操作兜底形成对照——2026 年，“是否遥操作、是否剪辑”已成为评价人形演示可信度的基本标准。

4.4 与其他”系统派”的对比

“OS/系统”类方案	公司	重点
LimX COSA	逐际	三层（运控 / 技能 / 认知）一体，面向人形全身家务
RoboOS	智源	跨本体大小脑协作，共享记忆
RynnRCP	阿里	机器人上下文协议（接口标准）
灵渠 OS / Genie Master	智元	机器人操作系统 + 具身智能体框架
Tairos / TairosAgent	腾讯	模块化平台 + 智能体框架
BrainNet + Co-Agent	优必选	工业多机协同 + 分层智能体

一个明显的中国特色：2026 年中国公司普遍在”模型之上再建一层系统/OS/智能体框架”——这与美国大脑公司（PI、Generalist、Skild）“一个越来越强的端到端模型”的路线形成对照。前者强调可控、可组合、可落地；后者强调规模化与涌现。

---

5. 技术路线总结

```
2023– 2024：P1 / TRON 1 / CL-1 —— 在"难控"平台上锤炼 RL 运动控制（System 0 的根基）
      ↓
2025：Oli 全尺寸人形 —— 从"能走"到"能全身操作"
      ↓
2026.01：LimX COSA —— 三层架构的具身智能体操作系统
      ↓
2026.07：COSA 0.5 —— 一镜到底、无遥操作的整屋家务；FluxVLA Engine 开源平台
```

---

6. 横向对比与身位

维度	逐际	Figure	宇树	智元
运动控制	顶尖（点足双足起家）	顶尖	顶尖	强
大脑哲学	系统派（COSA）	端到端三层（Helix 02）	世界模型 + VLA	VLA + 世界模型 + 智能体框架
三层架构	S0 / S1 / S2（COSA）	S0 / S1 / S2	—	—
开源平台	FluxVLA Engine	无	多项	多项

有趣的是，逐际与 Figure 的三层结构命名几乎一致（System 0/1/2），但内涵不同：Figure 的 S2 是一个 VLM，逐际的 System 2 是一个以 LLM 与世界模型为引擎的操作系统。

身位：逐际在运动控制上处于中国乃至全球第一梯队；在大脑上以”系统派”的鲜明主张形成差异化；其 COSA 的实际能力需要更多公开评测验证。

---

7. 未来展望与风险

展望： 1. IPO 与规模化：Pre-IPO 融资与股改完成后，逐际可能在 2027 年前后上市，获得更多研发资源； 2. COSA 生态：若 COSA 能够开放给其他本体厂商，可能成为人形”操作系统”的候选标准之一； 3. 家务场景：COSA 0.5 的整屋家务演示若能转化为可靠产品，将是家庭人形的重要突破。

风险： 1. “系统派”vs”端到端派”之争：如果端到端模型的规模化带来压倒性的涌现能力，复杂的分层系统可能被简化； 2. 技术透明度：System 0/1/2 的具体技术细节与评测公开不足； 3. 资源竞争：与资金更雄厚的大厂、头部本体公司竞争。

---

8. 延伸阅读与核验来源

- 同花顺：逐际动力人形大脑系统 LimX COSA 0.5 更新
- 腾讯新闻：逐际动力融资与 COSA
- Pulse 2.0：逐际动力完成近 2 亿美元 Pre-IPO 融资
- 凤凰网：逐际动力 COSA；智源社区
- 新浪：LimX COSA 发布（2026.02）

> 核验说明：COSA 发布日期（2026.01.12）、COSA 0.5（2026.07.15）、三层架构、“模型只是技能，系统才是大脑”、Oli 一镜到底整屋家务、FluxVLA Engine、Pre-IPO 融资与估值均来自公司发布与多家媒体报道；System 0/1 的具体模型结构与训练指标未公开；P1/TRON 1/CL-1 的能力描述基于公司历年公开演示。

第 36 章 北京人形机器人创新中心（X-Humanoid）：“天工”与”慧思开物”——国家级创新中心的开源大小脑

> 一句话定位：北京人形机器人创新中心（国地共建具身智能机器人创新中心，英文 X-Humanoid）由优必选、小米、京城机电等联合发起，是中国最重要的人形机器人公共研发平台之一。它的打法是”开源本体 + 开源数据 + 开源大小脑”的全栈公共品：开源人形本体天工（Tiangong）系列；发布RoboMIND（多本体、多任务的真机数据集，2024.12）与 RoboMIND 2.0、ArtVIP 等数据；发布具身大脑 Pelican-VL（天鹕）1.0（7B–72B，提出 DPPO”刻意练习”训练范式，2025.11）；发布具身小脑 VLA XR-1（统一视觉-运动码 UVMC，ICML 2026，2025.12 全面开源，国内首个通过具身智能国家标准测试的 VLA）；并以 WoW（我悟）世界模型构成”慧思开物”大小脑体系。在 2025 年 4 月北京亦庄人形机器人半程马拉松上，天工以第一名完赛，是其公众声量的高光时刻。

---

0. 速览卡片

维度	内容
机构	北京人形机器人创新中心（X-Humanoid），2023 年底成立于北京经济技术开发区（亦庄）
股东	优必选、小米、京城机电等
本体	天工 Tiangong（1.0 → Ultra → 2.0 等），开源本体设计；天工曾获 2025 年北京亦庄人形机器人半程马拉松冠军
体系	“慧思开物”：大脑 Pelican-VL（天鹕）+ 小脑 XR-1 + 世界模型 WoW（我悟）+ 本体”具身天工”
数据	RoboMIND（2024.12）→ RoboMIND 2.0；ArtVIP（铰接物体资产）
本章三篇代表作	① RoboMIND：多本体标准化真机数据集 ② Pelican-VL 1.0：具身大脑与 DPPO 刻意练习训练 ③ XR-1：统一视觉-运动码的跨本体 VLA
身位	中国人形”国家队”中的开源全栈代表；在数据集与具身大脑开源上有重要贡献

---

1. 故事的开端：为什么需要一个”人形创新中心”？

2023 年，北京在亦庄成立人形机器人创新中心，定位为解决行业共性技术问题的公共平台。其核心判断是：中国人形产业链上的大量企业（本体、零部件、大脑）都面临共同的瓶颈——缺少开源的标准化本体、缺少高质量的公共数据集、缺少开源的大小脑模型。如果每家公司都从零做起，将造成巨大的重复投入。

因此创新中心的工作围绕”公共品”展开：开源本体（天工）、开源数据（RoboMIND）、开源模型（Pelican-VL、XR-1）。

---

2. 代表作一：RoboMIND（2024.12）——多本体、标准化的真机数据集

> 论文：*RoboMIND: Benchmark on Multi-embodiment Intelligence Normative Data for Robot Manipulation*（北京人形机器人创新中心与北京大学等，2024.12）

2.1 设计

RoboMIND 的特点是"标准化（Normative）"——所有数据按统一的采集协议、统一的数据格式、统一的质量标准采集： - 多本体：覆盖 4 种平台——Franka Emika Panda（约 2.69 万条）、天工人形机器人（约 1.52 万条）、松灵 AgileX Cobot Magic V2.0 双臂（约 1.03 万条）、UR5e（约 2.52 万条），另有约 3 万条仿真数据； - 多任务：479 种操作任务、96 个物体类别，覆盖铰接物体、双臂协调、精密操作、物体交互，含双臂与灵巧手轨迹； - 规模：共约 10.7 万条示范轨迹； - 失败数据：另含约 5000 条真实失败轨迹，用于"从错误中学习"——这对训练鲁棒策略与价值模型很有价值； - 标准化：全部来自同一套标准化采集体系（区别于多实验室拼合的 OXE）； - 论文被 RSS 2025 接收。

2.2 意义

RoboMIND 与智元 AgiBot World、上海 AI Lab InternData、宇树 G1 数据集共同构成了 2025 年中国开源具身数据集的第一梯队。其"包含人形本体数据 + 失败数据 + 标准化协议"的设计，使其成为 XR-1 等模型的重要预训练数据来源之一。2025 年 12 月，创新中心又开放了 RoboMIND 2.0 与 ArtVIP（铰接物体视觉资产）的最新版本。

---

3. 代表作二：Pelican-VL 1.0（2025.11）——具身大脑与"刻意练习"训练

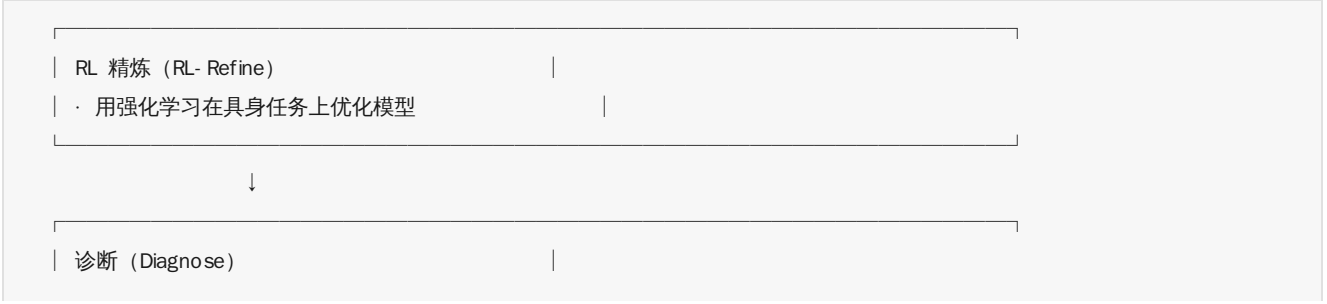
> 论文：*Pelican-VL 1.0: A Foundation Brain Model for Embodied Intelligence*（X-Humanoid，arXiv 2511.00108，v2 2025-11-14）；配套论文 *Bridging VLMs and Embodied Intelligence with Deliberate Practice Policy Optimization*（arXiv 2511.16602）。

3.1 定位

Pelican-VL（天鹕）是一个开源的具身大脑模型家族，参数规模从 70 亿到 720 亿——是 2025 年开源具身大脑模型中规模最大的之一。

3.2 核心方法：DPPO（Deliberate Practice Policy Optimization，刻意练习策略优化）

Pelican-VL 最有特色的是其训练范式——借鉴人类的"刻意练习"理论（专家通过针对薄弱环节的反复练习来提升）：



```
| · 找出模型在哪些能力上仍然薄弱（失败案例分析）       |
└──────────────────────────────────────────────────────┘
                        ↓
┌──────────────────────────────────────────────────────┐
| 有针对性的 SFT                                       |
| · 针对薄弱能力收集/构造数据进行监督微调              |
| · 扩展能力边界                                       |
└──────────────────────────────────────────────────────┘
                        ↓
                回到 RL 精炼，循环
```

DPPO 把 RL 与 SFT 统一在一个循环中：RL 负责"精炼已有能力"，SFT 负责"扩展新能力"，诊断环节决定"下一步练什么"。

3.3 数据与算力

- Metaloop 数据管线：从包含 40 亿以上 token 的原始数据中蒸馏出高质量数据集；
- 在 1000 张以上 A800 GPU 的集群上训练，每个检查点消耗 5 万以上 A800 GPU 小时。

3.4 结果

- 相对其基础模型，性能提升约 20.3%；
- 超过 1000 亿参数级开源对手约 10.6%（论文口径）；
- 开源推理代码、SFT 与 LoRA 训练代码，以及 7B 与 72B 基础模型检查点。

3.5 意义

Pelican-VL 与智源 RoboBrain、阿里 RynnBrain、上海 AI Lab InternVLA-M1 规划器同属"具身推理大脑"赛道。其 DPPO 范式把 LLM 领域"RL + SFT 交替"的后训练经验系统化地引入具身大脑——这与 PI RECAP、字节 GR-RL 在 VLA 层面的 RL 后训练相互呼应。

---

4. 代表作三：XR-1（2025.12 开源，ICML 2026）——统一视觉-运动码的跨本体 VLA

> 论文：*XR-1: Towards Versatile Vision-Language-Action Models via Learning Unified Vision-Motion Representations*（arXiv 2511.02776，2025-11-04；ICML 2026，PMLR 306）；项目页 xr-1-vla.github.io；2025 年 12 月 18 日全面开源（含数据集 RoboMIND 2.0、ArtVIP）。

4.1 问题：视觉动态与机器人动作的"语言不通"

跨本体 VLA 的核心难题是：不同机器人的动作空间不同，而视频（包括人类视频）中的视觉动态又没有动作标签。能否找到一种同时描述"看到的变化"与"机器人的运动"的共同语言？

4.2 核心方法：统一视觉-运动码（UVMC）

UVMC（Unified Vision-Motion Codes） 是一种离散的潜在表示，通过双分支 VQ-VAE 学习：

```
视觉分支：输入原始观察（相邻帧）→ 编码视觉动态 ──┐
                                                    ├──► 共享码本（离散潜在空间）
运动分支：输入机器人运动（动作序列）→ 编码运动 ──────┘
                + 视觉- 运动对齐损失：让视觉码靠近对应的运动码
```

- 两个分支共享同一个码本，强制视觉与运动在离散空间中使用”同一套词汇”；
- 视觉-运动对齐损失进一步把视觉码拉向对应的运动码；
- 结果：模型从视频中看到的”变化”，可以直接映射为”机器人应该怎么动”的码。

这与港大 UniVLA（任务中心潜在动作）、智元 GO-1（潜在规划器）同属”潜在动作”谱系，但 XR-1 的特色是显式地联合学习视觉与运动两种模态的共享码本。

4.3 三阶段训练

1. 自监督 UVMC 学习；
2. UVMC 引导的跨本体预训练（在多本体数据上，以 UVMC 作为中间监督）；
3. 任务特定的后训练。

4.4 结果

- 在 6 种不同机器人本体上进行了 1.4 万次以上评测，覆盖 120 多种操作任务；
- 稳定超越 π0 与 GR00T-N1.5 等最先进基线（ICML 论文页口径）；
- 可在天工 2.0、UR、Franka 等多种平台间迁移操作知识；
- 被宣传为国内首个通过具身智能国家标准测试的 VLA 模型。

（有二手资料称 XR-1 以 PaliGemma 为策略主干、并有基于 Florence-2 的轻量版 XR-1-Light，未经论文原文核实。）

---

5. 技术路线总结：“慧思开物”大小脑体系

```
┌──────────────────────────────────────────────┐
│ 大脑：Pelican- VL（天鹕）7B– 72B   │  ← 具身推理、规划（DPPO 训练）
└──────────────────────────────────────────────┘
                    │
┌──────────────────────────────────────────────┐
│ 世界模型：WoW（我悟）              │  ← 预测与想象
└──────────────────────────────────────────────┘
                    │
┌──────────────────────────────────────────────┐
│ 小脑：XR- 1（UVMC 跨本体 VLA）      │  ← 动作生成
└──────────────────────────────────────────────┘
                    │
┌──────────────────────────────────────────────┐
│ 本体：具身天工（开源人形）          │
└──────────────────────────────────────────────┘
```

```
                    ↑
数据：RoboMIND / RoboMIND 2.0 / ArtVIP
```

---

6. 横向对比与身位

维度	北京人形创新中心	上海 AI Lab	智源
性质	国家级/地方共建创新中心	国家实验室	新型研发机构
本体	天工（开源人形）	无	无
大脑	Pelican-VL（7B–72B）	InternVLA-M1 规划器	RoboBrain 2.0/2.5
小脑	XR-1（ICML 2026）	InternVLA-A1	无（RoboOS 调度）
数据	RoboMIND（含人形与失败数据）	InternData（合成为主）	ShareRobot

身位：北京人形创新中心是中国唯一同时开源人形本体 + 真机数据集 + 大脑 + 小脑 + 世界模型全栈的公共机构；其 XR-1 进入 ICML 2026、Pelican-VL 达到 72B 规模，学术质量与规模都处于国内公共机构前列。

---

7. 未来展望与风险

展望： 1. 国家标准：作为首个通过具身智能国标测试的 VLA 的发布方，创新中心可能在中国具身标准制定中扮演重要角色； 2. 开源本体的普及：天工开源本体若被广泛采用，将降低行业门槛； 3. 大小脑联动：Pelican-VL + WoW + XR-1 的系统级整合有望形成完整的开源人形大脑方案。

风险： 1. 公共机构的迭代速度：与创业公司和大厂相比，公共机构的产品化与迭代速度可能偏慢； 2. 与股东企业的关系：作为由企业联合发起的平台，如何平衡公共品与股东企业的商业利益； 3. 评测独立性：部分成绩来自自有评测体系。

---

8. 延伸阅读与核验来源

- RoboMIND：arXiv 2412.13877
- Pelican-VL 1.0：arXiv 2511.00108；DPPO：arXiv 2511.16602
- XR-1：arXiv 2511.02776；ICML 2026；PMLR
- AIbase：XR-1 开源，国内首个通过具身智能国标的模型；IT之家；中华网

> 核验说明：Pelican-VL 的 7B–72B 规模、DPPO 循环、Metaloop 40 亿+ token、1000+ A800 与每检查点 5 万+ GPU 小时、+20.3% 与超越百亿级模型 10.6% 来自 arXiv 论文；XR-1 的 UVMC 双分支 VQ-VAE、三阶段训练、6 本体 1.4 万+ 次评测、120+ 任务、超越 π0 与 GR00T-N1.5 来自论文与 ICML 页面，“ICML 口头报告（Oral）”的说法未能在官方日程中核实，PaliGemma 主干等实现细节来自二手资料；“国内首个通过具身智能国标测试的 VLA”来自官方宣传；RoboMIND 的规模（10.7 万条轨迹、479 任务、96 类物体、4 种平台的分项数量、约 5000 条失败轨迹、RSS 2025）来自 arXiv 论文核验（有第三方摘要给出”5.5 万条、279 任务”等旧数字，应以论文最新版本为准）。

第 37 章 银河通用（Galbot）：“仿真合成数据派”的旗手，从十亿帧抓取到”银河星脑”

> 一句话定位：银河通用由北京大学助理教授王鹤创立，是中国具身智能领域融资最多的公司之一（据报道成立 34 个月完成 6 轮、累计约 70 亿元融资，其中 2026 年 3 月一轮约 25 亿元）。它最鲜明的技术标签是”仿真合成数据”：GraspVLA（2025）用十亿帧全仿真合成数据（SynGrasp-1B）预训练抓取基础模型并零样本迁移到真实世界；NavFoM（ICLR 2026）用约 800 万条跨本体导航样本训练统一导航基础模型；2026 年，它把操作、导航、全身控制整合为”银河星脑（AstraBrain）”——以”大脑 + 脑桥 + 小脑”架构、“世界-动作模型（WAM）”路线驱动轮式 G1、重载 S1 与 2026 年 8 月首发的双足人形 ET1。王鹤称公司已积累约 100 万小时人类数据与 8 万小时真实场景回流数据。

0. 速览卡片

维度	内容
成立	2023 年，北京
创始人	王鹤（北京大学助理教授，EPIC 实验室负责人，斯坦福博士，师从 Leonidas Guibas）
融资	据报道 34 个月 6 轮约 70 亿元；2026 年 3 月约 25 亿元一轮
产品	Galbot G1（轮式双臂人形，主力商用）、Galbot S1（重载）、Galbot ET1（双足人形，2026.08 世界机器人大会首发）；“银河太空舱”机器人值守零售店
大脑谱系	DexGraspNet 系列（灵巧抓取，学术）→ GraspVLA（2025.01 发布）→ TrackVLA（2025.05）→ GroceryVLA（2025.06，零售）→ NavFoM（2025.09，ICLR 2026）→ 银河星脑 AstraBrain（WAM 0.5、WBC 0.5/1.0、Agent，2026）
其他	2026 年央视春晚演示；牵头获批具身智能大模型重点实验室（公司宣传）
本章三篇代表作	① GraspVLA：十亿帧合成数据预训练的抓取基础模型 ② NavFoM：跨本体、跨任务的导航基础模型 ③ 银河星脑 AstraBrain：大脑-脑桥-小脑与世界动作模型
身位	“仿真合成数据”路线的中国代表；资本实力与商业落地（零售、工业）位于国内第一梯队

1. 故事的开端：一位三维视觉学者的”数据判断”

王鹤在斯坦福读博期间研究三维视觉与物体位姿估计（NOCS 等工作）。回国后在北大建立 EPIC 实验室，长期研究灵巧抓取：DexGraspNet（大规模灵巧抓取合成数据集）、UniDexGrasp 等。这些研究给了他一个核心信念：

> 真机数据采集太慢太贵，而物理仿真 + 程序化生成可以以几乎零边际成本产出海量高质量数据——只要能跨过 sim2real 鸿沟，合成数据就是具身智能的规模化之路。

这一判断让银河通用成为中国"仿真合成数据派"的旗手，与智元（真机数据工厂）、它石（人类数据）、Generalist（人类交互数据）形成鲜明对照。

---

2. 代表作一：GraspVLA（2025）——十亿帧合成数据预训练的抓取基础模型

> 论文：*GraspVLA: a Grasping Foundation Model Pre-trained on Billion-scale Synthetic Action Data*（arXiv 2505.03233）——银河通用、北京大学等；项目页 pku-epic.github.io/GraspVLA-web；2025 年 1 月随银河通用联合北大、智源、港大发布。

2.1 SynGrasp-1B：十亿帧合成抓取数据

维度	内容
规模	十亿帧级别的抓取数据（全部在仿真中生成）
物体	从 Objaverse 中选取 240 个类别、1 万多个物体网格
渲染	照片级渲染
域随机化	机器人位姿、物体位姿、背景、光照、材质等全面随机化
动作	由运动规划等方法自动生成成功的抓取轨迹

2.2 架构：渐进式动作生成（PAG）

GraspVLA 把"抓取"拆解成一条思维链式的渐进生成过程：

```
图像 + 语言指令（"抓起那个蓝色杯子"）
        │
        ▼
VLM 主干（自回归）
  步骤 1：预测目标物体的检测框（bounding box）
        ← 互联网数据与合成数据共享这一步的监督
  步骤 2：预测抓取位姿（grasp pose）
        ← 仅合成数据有这一步的监督
        │（VLM 的 KV 缓存作为条件）
        ▼
流匹配动作专家
  步骤 3：生成末端执行器的增量动作块（delta actions）
```

PAG（Progressive Action Generation）的精妙之处：- 把互联网数据与合成数据"缝合"在一起：检测框这一步，互联网上有海量带框标注的图像（可以教模型"认识更多物体"）；抓取位姿与动作这两步，只有合成数据有——于是模型从互联网学"认物"，从合成数据学"抓物"；- 这让模型能够抓取合成数据中从未出现过的长尾物体（例如充电器、毛巾、泳镜）——因为它通过互联网数据认识了这些物体，再把抓取技能迁移过去。

据二手综述，VLM 基于 InternLM2，并融合 DINOv2 与 SigLIP 视觉特征。

2.3 结果

- 零样本 sim2real：只在 SynGrasp-1B 上预训练，就能直接在真实世界中抓取；
- 开放词汇抓取：根据自然语言指令抓取指定物体；
- 长尾泛化：抓取合成动作数据中不存在的物体类别；
- 少样本偏好学习：用少量示范教会模型特定的抓取偏好（例如"抓杯子把手而不是杯身"）。

2.4 意义与延伸

GraspVLA 是全球首批证明"纯合成数据预训练的 VLA 可零样本迁移到真实世界"的大规模工作之一。其思路被延伸到零售场景的 GroceryVLA（2025.06，宣称首个面向零售的端到端 VLA，驱动"银河太空舱"无人值守药店/便利店中的取货机器人）。

---

3. 代表作二：NavFoM（2025.09，ICLR 2026）——跨本体、跨任务的导航基础模型

> 论文：*Embodied Navigation Foundation Model*（arXiv 2509.12129，ICLR 2026）——北京大学、银河通用等；项目页 pku-epic.github.io/NavFoM-Web。前作：TrackVLA（2025.05，具身视觉跟踪 VLA）。

3.1 问题：导航的碎片化

具身导航长期被切分成大量子任务——视觉语言导航（VLN）、物体搜索、目标跟踪、自动驾驶——而且每种本体（四足、无人机、轮式、汽车）都有自己的模型。能否用一个模型处理所有本体、所有导航任务？

3.2 方法

设计	内容
数据	约 800 万条导航样本，覆盖四足、无人机、轮式机器人、汽车等本体，以及 VLN、物体搜索、目标跟踪、自动驾驶等任务（另有约 470 万条问答等数据，合计约 1270 万条，据二手综述）
TVI token（时间-视角指示符）	用标识符 token 编码"相机视角信息"（不同本体的相机数量与位置不同）与"任务的时间上下文"——让一个模型理解"我现在是一只四足/一架无人机，有几个相机朝哪里"
BATS（预算感知的 token 采样）	在固定的视觉 token 预算下进行采样，保证长时程导航中的计算可控

3.3 结果

- 在多种导航任务与本体上，无需任务专门微调即达到最优或高度有竞争力的表现；
- 例如在 HM3D-OVON（开放词汇物体导航）未见验证集上，零样本成功率从 40.8% 提升到 43.6%；
- 代码在论文接收后开源（据项目页）。

3.4 TrackVLA

TrackVLA（2025.05）是银河通用的具身视觉跟踪 VLA——让机器人在动态环境中持续跟随指定目标（例如跟随一个人穿过人群），是 NavFoM 的前序工作之一。

3.5 意义

NavFoM 体现了银河通用”一个大脑、所有身体”的理念在导航维度上的实现。它的 TVI token 设计（把本体信息作为输入 token）与 GR00T 的本体专属编解码器、RDT 的统一动作空间，是三种不同的”跨本体”技术方案。

---

4. 代表作三：银河星脑 AstraBrain（2026）——大脑、脑桥、小脑与世界动作模型

> 来源：2026 年央视春晚演示；2026 年 8 月世界机器人大会（Galbot ET1 首发）；王鹤 2026 年数博会主旨演讲；百度百科”银河星脑”条目及媒体报道。

4.1 架构：大脑 + 脑桥 + 小脑



4.2 WAM（世界-动作模型）

银河通用称其 WAM 路线由其团队于 2025 年 ICCV 首次提出（公司说法）。其宣传重点是数据利用能力——WAM 可以统一处理：- 虚拟与真实数据（仿真合成 + 真机）；- 人类与机器人混合数据；- 有动作标签与无动作标签的数据（例如人类视频）。

AstraBrain WAM 0.5 被称为”全球首个通用大脑基座模型”（公司说法），其关键设计是把动作从具体关节抽象为”抓取、推拉”等物理操作——这样同一个大脑输出的”操作意图”，可以被双足、轮式、重载等不同本体的小脑各自执行。

4.3 AstraBrain-WBC：小脑的缩放定律

- WBC 0.5：据称基于”有史以来最大规模”的人类动作数据训练，并宣称验证了运动控制领域的缩放定律；
- WBC 1.0：随 2026 年 8 月发布的双足 ET1 搭载。

4.4 数据：100 万小时人类数据 + 8 万小时回流数据

王鹤披露，公司已积累约 100 万小时人类数据与 8 万小时真实场景回流数据（未见独立核实）。这说明银河通用的数据策略在 2026 年已从”仿真合成为主”扩展为”合成 + 人类 + 真实回流”三源融合——与 NVIDIA 的”数据金字塔”思路趋同。

4.5 ET1：双足首秀

2026 年 8 月 19 日世界机器人大会上，银河通用首次发布双足人形 Galbot ET-1，并展示了打网球等动态能力；与 G1、S1 一起，体现了”一颗星脑，所有身体”的跨本体主张。

---

5. 技术路线总结

阶段	时间	代表	数据
学术积累	2023 前	DexGraspNet、UniDexGrasp	合成灵巧抓取数据
操作基础模型	2025.01–05	GraspVLA、GroceryVLA	十亿帧合成 + 互联网
导航基础模型	2025.05–09	TrackVLA、NavFoM	800 万跨本体导航样本
统一具身基座	2026	银河星脑 AstraBrain（WAM 0.5、WBC 0.5/1.0、Agent）	合成 + 100 万小时人类 + 8 万小时回流

---

6. 横向对比与身位

维度	银河通用	智元	Genesis AI（美）	NVIDIA
数据哲学	合成为主 → 三源融合	真机数据工厂	仿真为主	数据金字塔
代表模型	GraspVLA、NavFoM、AstraBrain	GO 系列、GE	GENE-26.5	GR00T、Cosmos
跨本体	抽象物理操作 + TVI token	潜在动作	—	本体专属编解码器
商业落地	零售（太空舱）、工业	工业 + 商业	2026 年底起	平台

身位： - 银河通用是中国”合成数据 + 学术驱动”路线最成功的公司，GraspVLA 与 NavFoM 具有国际学术影响力； - 资本实力在国内具身公司中处于最前列； - AstraBrain 的许多宣称（“全球首个”“缩放定律”）尚缺乏公开论文与独立评测。

---

7. 未来展望与风险

展望： 1. 双足 + 星脑：ET1 的推出意味着银河通用开始进入全尺寸人形赛道，“一颗星脑驱动所有身体”将面临真正的跨形态检验； 2. 零售场景的数据飞轮：太空舱等商业部署带来的真实回流数据（8 万小时）是其独特资产； 3. 国家级平台：牵头的具身大模型重点实验室可能带来更多资源与合作。

风险： 1. sim2real 天花板：在需要精细力控与可形变物体处理的任务上，合成数据的局限可能凸显； 2. 宣传与验证的落差：多项”全球首个”宣称缺乏独立验证； 3. 估值压力：高额融资需要更快的商业化兑现。

---

8. 延伸阅读与核验来源

- GraspVLA：arXiv 2505.03233；项目页
- NavFoM：arXiv 2509.12129；ICLR 2026
- 银河星脑：百度百科：银河星脑；新浪财经：一颗星脑所有身体用；雷锋网：王鹤谈具身智能的 AlphaGo 与 ChatGPT 时刻；腾讯新闻：王鹤 2026 数博会演讲
- ET1 与 2026 WRC：新浪：银河通用发布 Galbot ET1
- 虎嗅：银河通用 34 个月 6 轮融资 70 亿

> 核验说明：GraspVLA 的 SynGrasp-1B（十亿帧、240 类、1 万+ 物体）与 PAG 三步结构来自论文与项目页，VLM 基于 InternLM2 为二手综述；NavFoM 的 800 万导航样本、TVI token、BATS、ICLR 2026 与 HM3D-OVON 成绩来自论文；AstraBrain 的架构（大脑-脑桥-小脑）、WAM 0.5、WBC 0.5/1.0、Agent 来自百科与媒体报道，“ICCV 2025 首次提出 WAM”“全球首个”“缩放定律”“100 万小时 + 8 万小时”均为公司说法，未见论文或独立核实；融资数据来自媒体报道。

第 38 章 星动纪元（Robot Era）：清华交叉信息院的”视频预测派”——VPP、ERA-42 与 Ctrl-World

> 一句话定位：星动纪元由清华交叉信息研究院助理教授陈建宇于 2023 年 8 月创立，是中国具身领域学术基因最强的创业公司之一，也是”视频预测 / 世界模型 → 策略”路线在中国最早、最系统的实践者：VPP（视频预测策略，ICML 2025 Spotlight） 用视频扩散模型内部的”预测性视觉表征”驱动策略；ERA-42（2024.12） 是结合五指灵巧手 XHAND1 的端到端原生机器人大模型，能完成 100 多种灵巧操作；Ctrl-World（与斯坦福 Chelsea Finn 组合作，ICLR 2026） 是可控生成式世界模型，能在”想象中”评估与改进策略，据报道在 2026 年 2 月 WorldArena 世界模型榜单中领先。2026 年星动纪元累计融资近 50 亿元，估值突破百亿，物流场景（顺丰、中国邮政）成为其商业化主战场。

0. 速览卡片

维度	内容
成立	2023 年 8 月，北京（清华大学交叉信息研究院孵化）
创始人	陈建宇（清华交叉信息研究院助理教授，UC Berkeley 博士，研究方向为强化学习、人形机器人与世界模型）
融资	2026 年 3 月 10 亿元战略轮（估值破百亿）；2026 年 7 月 6 日 10 亿元新一轮（诚通基金领投，多家国资参与）；2026 年累计近 50 亿元；顺丰、红杉中国、IDG 等参与过往轮次
产品	STAR1 / L7（全尺寸人形）、Q5（轮式）、M7、XHAND1（五指灵巧手）
落地	与中国邮政、顺丰等合作落地 10 余个物流中心；计划 2026 年二季度开启千台级批量交付
大脑谱系	HiRT（分层 VLA）、VPP（2024.12 / ICML 2025）、UP-VLA（ICML 2025）、ERA-42（2024.12）、Ctrl-World（2025.10 / ICLR 2026）
本章三篇代表作	① VPP：视频预测策略 ② ERA-42：结合灵巧手的端到端原生机器人大模型（含 UP-VLA）③ Ctrl-World：可控生成式世界模型
身位	中国”世界模型 / 视频预测”路线的学术与产业先行者；物流场景落地领先

1. 故事的开端：从强化学习到”预测未来”

陈建宇在 UC Berkeley 读博期间研究强化学习与自动驾驶决策，回国后在清华交叉信息研究院从事人形机器人与具身智能研究。他的一个核心判断是：

> 机器人之所以笨拙，是因为它们只”看到现在”，而不会”预测未来”。人类在伸手拿杯子之前，大脑已经预演了手的轨迹和杯子的反应。

这一判断决定了星动纪元的技术主线：让机器人大脑学会预测未来，并基于预测行动。在 2024 年底，当行业主流还在 VLM + 动作专家的 VLA 框架内迭代时，星动纪元已经提出了”视频预测策略”。

---

2. 代表作一：VPP——视频预测策略（2024.12 / ICML 2025 Spotlight）

> 论文：Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, …, Jianyu Chen 等，*Video Prediction Policy: A Generalist Robot Policy with Predictive Visual Representations*（arXiv 2412.14803；ICML 2025，PMLR 267）；项目页 video-prediction-policy.github.io

2.1 问题：视觉编码器只看”静态”

VLA 与模仿学习策略通常使用预训练的视觉编码器（CLIP、SigLIP、DINOv2、R3M 等）。这些编码器在静态图像上训练，擅长描述”现在是什么”，却不包含”接下来会怎样”的动态信息。而机器人操作恰恰是一个关于”变化”的问题。

2.2 核心洞察：视频扩散模型的内部特征是”预测性表征”

VPP 的关键发现：视频扩散模型在去噪过程中的内部潜在特征，同时编码了当前场景内容与对未来运动的预测——作者称之为”预测性视觉表征（predictive visual representations）”。

更重要的是：不需要真正把未来视频生成出来——只需要做一步（或很少几步）前向，取出中间层特征，就已经包含了足够的未来信息。这大幅降低了推理成本（相比完整生成视频）。

2.3 两阶段方法

```
阶段一：把通用视频扩散模型微调为"文本引导的操作视频预测模型"（TVP）
   · 起点：通用视频扩散模型
   · 数据：互联网人类操作视频 + 多种机器人操作数据（统一视频生成目标）
   · 学会："给定当前画面和指令，未来会怎样变化"
            |
            ▼
阶段二：训练策略
   · 对当前观察只做一次（少步）前向，提取 TVP 的预测性视觉表征
   · 用一个 Video Former 聚合多视角、多时间步的特征
   · 用扩散策略（动作头）从这些表征生成动作
   · 本质上，策略在隐式地学习一个"逆动力学模型"：
     "要让预测的未来发生，我该怎么动？"
```

2.4 结果

- 在 CALVIN ABC→D（跨环境泛化基准）上相对此前最优提升约 18.6%；
- 在复杂的真实灵巧操作任务上，成功率提升约 31.6%；
- 在灵巧手（XHAND）上完成大量精细任务。

2.5 意义

VPP 是”视频生成模型作为机器人视觉主干”这一思想的早期代表作（2024.12），与字节 GR-1/GR-2（视频生成预训练）、清华 Vidar（视频扩散 + 逆动力学）、NVIDIA DreamZero（视频-动作联合去噪，2026）同属一条技术谱系。它的独特之处在于”只取特征、不生成视频”，在效率与效果之间取得了很好的平衡。

---

3. 代表作二：ERA-42（2024.12）与 UP-VLA——端到端原生机器人大模型

3.1 ERA-42

> 发布：2024 年 12 月 23 日。

ERA-42 被星动纪元称为”端到端原生机器人大模型”，也是被宣传为世界首个结合五指灵巧手的具身大模型： - 搭配自研五指灵巧手 XHAND1（12 个主动自由度）； - 完成 100 多种灵巧操作任务，例如用螺钉钻拧紧螺钉、用锤子敲钉子、使用工具等； - 融合了世界模型（预测未来状态以辅助决策——即 VPP 思想的工程化），并”初步体现出规模化效应”； - 端到端：从视觉直接到灵巧手与手臂的动作，不依赖分层的技能库。

名字”42”致敬《银河系漫游指南》中”生命、宇宙以及一切的终极答案”。

3.2 UP-VLA：统一理解与预测

> 论文：*UP-VLA: A Unified Understanding and Prediction Model for Embodied Agent*（2025，ICML 2025）

UP-VLA 进一步把”多模态理解”与”未来预测”统一到一个 VLA 中： - 同时训练模型的高层语义理解（VQA 等）与低层视觉预测（预测未来图像）能力； - 理解提供”做什么”，预测提供”世界会怎样变”，两者共同支撑动作生成； - 在需要精细空间信息与语义理解的任务上优于普通 VLA。

3.3 意义

ERA-42 代表了星动纪元把”视频预测 + 灵巧手 + 端到端”三者结合的工程实践；它与灵巧手 XHAND1 的软硬协同，使星动纪元成为中国较早在五指灵巧操作上展示大量真实技能的公司。

---

4. 代表作三：Ctrl-World（2025.10 / ICLR 2026）——可控生成式世界模型

> 论文：Yanjiang Guo, Lucy Xiaoyang Shi, Jianyu Chen, Chelsea Finn，*Ctrl-World: A Controllable Generative World Model for Robot Manipulation*（arXiv 2510.10125，ICLR 2026）——斯坦福与清华合作。

4.1 问题：VLA 的评估与改进太依赖真机

一个通用策略要在大量任务上评估、找到失败、再改进，需要成千上万次真机试验。能否让策略在一个足够逼真、可控的世界模型中”想象地”运行，从而在不动真机的情况下评估与改进它？

4.2 方法

- 多视角世界模型：生成与机器人多相机一致的未来画面；
- 可控：以机器人动作为条件——策略输出的每一个动作，都会在世界模型中产生相应的视觉后果；
- 闭环 rollout：策略在世界模型生成的画面中连续地闭环运行（看 → 动 → 世界模型生成新画面 → 再看 → 再动）；
- 在 DROID 数据集上训练，能保持 20 秒以上连贯的 rollout。

4.3 两大用途与结果

1. 策略评估：在世界模型中运行不同策略，其排序与真实世界结果一致——即可以"不动真机就知道哪个策略更好"；
2. 策略改进：在世界模型中生成成功的合成轨迹，用于监督微调——策略成功率提升约 44.7%（某一版本报告在新指令上从 38.7% 提升到 83.4%）。

4.4 局限

作者承认：在需要精确交互或长时程推理的任务上世界模型可能失败，且输出对初始观察较敏感。

4.5 WorldArena

据报道，星动纪元研发的 Ctrl-World 在 2026 年 2 月的 WorldArena 世界模型榜单中超越谷歌、英伟达等国际巨头（媒体报道口径，未见官方榜单核实）。

4.6 意义

Ctrl-World 是"世界模型作为策略评估器与数据生成器"的高质量学术代表作，与 1X 世界模型（评估器）、特斯拉神经世界模拟器、蚂蚁 LingBot-World 处于同一方向。它也体现了星动纪元与斯坦福（Chelsea Finn，PI 联合创始人）的紧密学术联系。

---

5. 技术路线总结



---

6. 横向对比与身位

维度	星动纪元	字节 Seed	NVIDIA	1X
视频预测/世界模型	VPP（特征）、Ctrl-World（评估/改进）	GR-1/GR-2（视频生成预训练）	DreamZero（联合去噪）、Cosmos	1XWM（生成 + IDM）
灵巧手	自研 XHAND1	—	—	—
学术	ICML 2025、ICLR 2026	ICLR 2024 等	多篇	博客为主
落地	物流（顺丰、邮政）	内部	平台	家庭

身位：星动纪元是中国”视频预测 / 世界模型”路线的学术与产业双先行者，其学术成果在国际顶会上具有影响力；2026 年的大额融资与物流场景落地使其成为清华系具身公司中的头部玩家。

---

7. 未来展望与风险

展望： 1. 世界模型闭环：Ctrl-World 式的”想象中评估与改进”若与物流场景的真实数据结合，可能形成高效的迭代飞轮； 2. 千台级交付：2026 年的批量交付将检验其大脑在真实物流中的可靠性； 3. 灵巧手优势：XHAND1 + 端到端模型的组合在精细操作上具有差异化。

风险： 1. 视频模型的推理成本：即便只取特征，视频扩散主干的算力需求仍高于普通 VLM； 2. 宣传与评测：WorldArena 等榜单成绩的独立性有待核实； 3. 物流场景的竞争：Agility、Figure、智元等都在物流场景布局。

---

8. 延伸阅读与核验来源

- VPP：arXiv 2412.14803；ICML 2025；PMLR
- ERA-42：新京报；百度百科；品玩
- UP-VLA：ICML 2025（arXiv 2501.18867）
- Ctrl-World：arXiv 2510.10125；ICLR 2026
- 融资：腾讯新闻：星动纪元 2026 年累计融资近 50 亿；新浪财经：10 亿战略融资，估值过百亿

> 核验说明：VPP 的方法与 CALVIN +18.6%、真实灵巧任务 +31.6% 来自论文；ERA-42 的发布时间、XHAND1、100+ 灵巧任务、融合世界模型来自官方发布与媒体；UP-VLA 的 arXiv 编号为本报告根据公开记录整理，以论文页面为准；Ctrl-World 的作者、ICLR 2026、+44.7% 与 38.7%→83.4% 来自论文；“WorldArena 2026 年 2 月领先”为媒体报道口径；融资与落地数据来自媒体统计。

第 39 章 星海图（Galaxea）：开放世界数据 + 双系统 VLA，走向”原生动作思维链”与分布式真机强化学习

> 一句话定位：星海图由前自动驾驶工程师高继扬与清华交叉信息研究院的赵行、许华哲联合创立，是中国具身领域估值最高的创业公司之一（2026 年 4 月再融 20 亿元，估值约 200 亿元）。它的大脑路线清晰而务实：先用开放世界真机数据集 GOD + 双系统 VLA G0（2025.08）建立开源影响力（数据集下载超 60 万次），再以 G0 Plus（2026.02） 提供开箱即用的 VLA 基座，到 G0.5（2026.06 发布并开源、2026.08 世界机器人大会深化） 引入”原生动作思维链”——把感知、语言、推理与动作生成统一在一条自回归数据流中，并配套发布世界模型 Fast-WAM（单步推理 800 毫秒降至 190 毫秒）与分布式强化学习系统 G-Fleet。星海图是”自动驾驶方法论迁移到具身”的典型代表。

0. 速览卡片

维度	内容
成立	2023 年，北京
联合创始人	高继扬（CEO，前 Momenta 等自动驾驶公司技术负责人）；赵行（清华交叉信息研究院助理教授，自动驾驶与多模态学习）；许华哲（清华交叉信息研究院助理教授，强化学习与机器人学习）
融资	2026 年 4 月再融 20 亿元，估值约 200 亿元（量子位报道）
产品	R1 / R1 Pro / R1 Lite（移动双臂，约 23 自由度）、Nexo（新一代轮臂人形，全身 30 自由度、双臂最高负载 20kg，2026.08）
大脑谱系	G0（2025.08，双系统 VLA）+ Galaxea 开放世界数据集（GOD） → G0 Plus（2026.02，GalaxeaVLA 仓库）→ G0.5（2026.06.16 发布并开源 / 2026.08.21 WRC 深化，复现计划）→ G0.5 MAX（筹备中）
配套	Fast-WAM 世界模型（2026.08）、G-Fleet 分布式强化学习系统（2026.08）；与北京亦庄共建数据公司，启动”百万小时真实数据计划”
本章三篇代表作	① G0 + Galaxea 开放世界数据集：双系统 VLA 与单本体预训练的价值 ② G0 Plus：开箱即用的 VLA 基座（“万物抓取”）③ G0.5 + Fast-WAM + G-Fleet：原生动作思维链与部署闭环
身位	中国具身大脑创业公司第一梯队；开源影响力（数据集）领先

1. 故事的开端：自动驾驶老兵的”数据闭环”思维

高继扬在自动驾驶行业经历了从”规则驱动”到”数据驱动”的完整转型——他亲历了数据闭环（车队采集 → 自动标注 → 训练 → 部署 → 回流）如何把自动驾驶系统从”能演示”推向”能量产”。赵行与许华哲则分别在多模态感

知与强化学习/机器人学习上有深厚积累。

三人对具身智能的共同判断是： 1. 数据要"开放世界"——在真实、多样、杂乱的人类环境中采集，而不是在干净的实验室； 2. 本体要统一——用同一款机器人大规模采集，保证数据的一致性与精度； 3. 最终要闭环——部署、回流、迭代，像自动驾驶一样。

---

2. 代表作一：G0 + Galaxea 开放世界数据集（2025.08）

> 论文：*Galaxea Open-World Dataset and G0 Dual-System VLA Model*（Tao Jiang 等，arXiv 2509.00576，2025-08-30）；项目页 opengalaxea.github.io/G0

2.1 Galaxea 开放世界数据集（GOD）

维度	内容
平台	单一本体：Galaxea R1 Lite（移动双臂，约 23 自由度）
规模	约 500 小时机器人行为数据（另有摘要称约 10 万条高分辨率轨迹）
场景	真实的人类生活与工作场景（家庭、零售、餐饮、办公等），而非实验室
标注	细粒度的子任务级语言标注
影响	开源后累计下载量超过 60 万次（据报道）

"单一本体 + 开放世界"的设计哲学：与 OXE（多本体、数据格式不一）不同，GOD 刻意只用一种机器人采集——保证了动作空间、相机视角、标注格式的高度一致。

2.2 G0：双系统 VLA



2.3 三阶段训练与关键发现

阶段	数据	目标
阶段一：跨本体预训练	多样数据集（含 OXE 与部分 Galaxea 数据）	用 FAST tokenizer 的自回归动作预测学习通用动作知识

阶段	数据	目标
阶段二：单本体预训练	Galaxea 开放世界数据（本体专属视角 + 高层与子任务指令）	用流匹配损失学习精确的本体控制
阶段三：任务后训练	少量任务示范	适配具体任务

消融实验的关键发现（对行业很有价值）： - 单本体预训练对精确的多肢体协调至关重要——它让模型充分利用 R1 Lite 的结构细节（双臂 + 躯干 + 底盘协同）； - 跨本体预训练有助于泛化到新动作，但过度依赖它会在需要精确、本体特定控制的任务上表现更差。

解读：这一发现为"跨本体通用 vs 本体专精"之争提供了实证：跨本体数据给"广度"，单本体数据给"精度"，两者都需要，且顺序与配比很重要。这与 π0（多本体预训练 + 高质量后训练）、GR00T（本体专属编解码器）的经验相互印证。

---

3. 代表作二：G0 Plus（2026.02）——开箱即用的 VLA 基座

> 发布：2026 年 2 月；开源代码：GitHub OpenGalaxea/GalaxeaVLA。

3.1 定位："即插即用"

G0 Plus 被星海图定位为开箱即用（plug-and-play）的 VLA 基础模型，主打"万物抓取（Pick Up Anything）"——即在未见过的物体与场景中，仅凭语言指令就能抓取任意物体。

3.2 意义

从 G0 到 G0 Plus 的转变，是从"研究模型 + 数据集"到"产品化基座"的转变： - 降低客户与开发者的使用门槛（不需要大量微调）； - 以"抓取"这一最高频、最通用的操作为切入点，建立可靠性口碑； - 通过开源代码（GalaxeaVLA）扩大开发者生态。

（G0 Plus 的公开技术细节有限，本章不做架构推测。）

---

4. 代表作三：G0.5 + Fast-WAM + G-Fleet（2026.06–08）——原生动作思维链与部署闭环

4.1 G0.5：统一自回归 VLA 与原生动作思维链

> 发布：2026 年 6 月 16 日全球开发者大会正式发布并宣布开源；2026 年 8 月 21 日世界机器人大会深化发布并启动"G0.5 复现计划"。

架构：统一自回归 VLA - 把视觉理解、语言推理与动作生成融入同一条自回归链路——不再是 G0 那样的"规划器 + 执行器"两个模型； - 内嵌原生动作思维链：模型在生成最终动作之前，可以在同一数据流中进行图像感知、语言理解、逻辑推理的"思考"，再生成动作。

零样本能力：据报道，G0.5 在 R1 Lite 上零样本（未经该场景任何微调）仅凭自然语言指令即可驱动机器人完成操作任务。

G0.5 复现计划：面向全球研究机构与开发者开放模型权重、推理接口、评测基准与微调工具；G0.5 MAX 版本在筹备中。

与智元 G0-2 的对比：

维度	星海图 G0.5	智元 G0-2
思维链	原生动作思维链（统一自回归数据流中推理）	动作思维链（在动作空间生成高层动作序列）
架构	统一自回归 VLA（单模型）	异步双系统（低频规划 + 高频跟随）
时间	2026.06 / 08	2026.04

两家头部公司在 2026 年不约而同地提出”动作思维链”，说明这已成为中国具身大脑的主流设计方向之一（参见第 32 章）。

4.2 Fast-WAM：快速世界动作模型

2026 年 8 月世界机器人大会上，星海图发布世界模型 Fast-WAM： - 单步推理延迟从传统范式的约 800 毫秒降至约 190 毫秒，提速 4 倍以上； - 意义：世界模型最大的工程障碍之一是推理慢（NVIDIA DreamZero 7Hz、1XWM 需要生成视频），Fast-WAM 把世界模型推向”可实时使用”。

4.3 G-Fleet：分布式真机强化学习系统

G-Fleet 用于打通”模型部署 → 真机交互 → 数据回流 → 迭代训练”的闭环——即在机器人车队上进行分布式强化学习。这正是高继扬”自动驾驶数据闭环”思维在具身中的落地，也与 PI RECAP（车队级 RL 愿景）、智元 Genie Evolver（部署后学习）、Generalist（部署数据飞轮）同属 2026 年”部署态学习”的主流方向。

4.4 数据：百万小时真实数据计划

星海图与北京亦庄共建数据公司，启动”百万小时真实数据计划”——表明其数据战略正从”500 小时开放世界数据集”扩展到”百万小时级”的规模化真实数据（参见它石、Generalist、小米的数据规模竞赛）。

4.5 新硬件 Nexo

2026 年 8 月发布新一代轮臂人形 Nexo：全身 30 个自由度（覆盖双臂、肩颈、腰腹与底盘），双臂最高可承载 20kg——为更重、更复杂的全身操作任务提供平台。

---

5. 技术路线总结

```
2025.08  G0（双系统：VLM 规划 + VLA 执行）+ GOD 开放世界数据集（单本体、500 小时）
           关键发现：跨本体给广度，单本体给精度
    ↓
2026.02  G0 Plus：开箱即用 VLA，"万物抓取"
    ↓
2026.06  G0.5：统一自回归 VLA + 原生动作思维链，零样本运行，开源
```

↓
2026.08 G0.5 复现计划；Fast-WAM（190ms）；G-Fleet（分布式真机 RL）；Nexo；百万小时数据计划

---

6. 横向对比与身位

维度	星海图	智元	自变量（第 40 章）	千寻（第 41 章）
数据集	GOD（开放世界、单本体）	AgiBot World（百万轨迹）	—	开放式目标驱动采集
架构演进	双系统 → 统一自回归 + 动作 CoT	ViLLA → 动作 CoT 双系统 → WRAM	VLA → 世界统一模型	统一 VLA
世界模型	Fast-WAM	GE 系列	WALL-B（WUM）	—
RL 闭环	G-Fleet	Genie Evolver	—	—
开源	积极	积极	WALL-OSS	Spirit v1.5

身位：星海图是中国具身”大脑创业公司”中数据、模型、系统三方面布局最均衡的之一；估值约 200 亿元，处于国内第一梯队。

---

7. 未来展望与风险

展望： 1. G-Fleet 闭环：若分布式真机 RL 在规模化部署中跑通，星海图将具备”越用越强”的数据飞轮； 2. G0.5 复现计划：开源权重、基准与工具，可能使 G0.5 成为中国开源 VLA 的重要基线； 3. 百万小时数据：与地方政府共建数据公司的模式，可能解决数据采集的资金与场地问题。

风险： 1. 开源范围的不确定：G0.5 的开源细节（许可证、权重范围）需以官方仓库为准； 2. 硬件与大脑的双线投入：同时做本体（R1、Nexo）与大脑，资源压力大； 3. 激烈竞争：与智元、银河、自变量等在融资与人才上的直接竞争。

---

8. 延伸阅读与核验来源

- G0 + GOD：arXiv 2509.00576；项目页；知乎：星海图开源快慢双系统 VLA 与真机数据集
- G0 Plus：品玩：G0 Plus 发布，开箱即用实现万物抓取；GitHub OpenGalaxea/GalaxeaVLA
- G0.5 / Fast-WAM / G-Fleet / Nexo：星海图官方：2026 世界机器人大会；科技日报；澎湃新闻；中新网：2026 世界机器人大会首发新品
- 融资与数据计划：量子位：再融 20 亿，估值 200 亿；证券时报：共建数据公司，启动百万小时真实数据计划

> 核验说明：G0 的双系统、三阶段训练与消融结论来自 arXiv 论文；GOD 规模存在”500 小时”与”10 万条轨迹”两种表述；下载量 60 万次来自媒体报道；G0 Plus 的”万物抓取”来自官方发布，技术细节有限；G0.5 的统一自回归架构、原生动作思维链、零样本、复现计划来自官方与多家媒体；Fast-WAM 800ms→190ms、G-Fleet、Nexo 参数来自 2026 WRC 报道；估值来自量子位报道。

第 40 章 自变量机器人（X Square Robot）：从开源 WALL-OSS 到”世界统一模型”WALL-B

> 一句话定位：自变量机器人是中国具身领域最坚定的”端到端统一大模型”派——它从一开始就不走”大脑-小脑分层”的路线，而是追求一个统一的模型。其演进路径非常清晰：2024 年底的 VLA 模型 WALL-A → 2025 年 9 月开源的轻量版 WALL-OSS（紧耦合 VLA，统一跨层级思维链）→ 2026 年 4 月的 WALL-B——被称为全球首个”世界统一模型（World Unified Model, WUM）”架构的具身基础模型，把视觉、语言、动作与物理预测放进同一个网络中从头联合训练；35 天后搭载 WALL-B 系列模型的机器人首批进入真实家庭；5 月开源 WALL-OSS-0.5（完整训练栈），并相继发布事件级世界动作模型 WALL-WM 与下一尺度自回归世界模型 WALL-SS。自变量是 2026 年中国”VLA → 原生多模态统一 + 世界模型”转型最激进的公司。

0. 速览卡片

维度	内容
成立	2023 年，深圳（2026 年 5 月注册地迁至深圳并更名为”自变量科技（深圳）股份有限公司”）
创始团队	王潜（CEO）；王昊（联合创始人兼 CTO）
融资	多轮融资，含约 1.403 亿美元一轮（阿里云领投，据报道）；有单一来源称 2026 年 6 月投后估值超 200 亿元
产品	轮式双臂机器人（夹爪 + 轮式底盘方案，面向家庭；2026.05.25 首批进入真实家庭，与 58 同城合作）
模型谱系	WALL-A（2024 底，VLA）→ WALL-OSS（2025.09 开源）→ WALL-B（2026.04.21，WUM）→ WALL-AS（家庭部署模型）→ WALL-OSS-0.5（2026.05.28 完全开源）→ WALL-WM（2026.05，事件级世界动作模型）→ WALL-SS（2026.08，下一尺度自回归世界模型 / 虚拟训练场）
开放程度	高：WALL-OSS 与 WALL-OSS-0.5 开源（GitHub wall-x / X-Square-Robot）
本章三篇代表作	① WALL-OSS → WALL-OSS-0.5：紧耦合 VLA 与梯度桥接的协同训练 ② WALL-B：世界统一模型（WUM）③ WALL-WM 与 WALL-SS：事件级世界动作模型与虚拟训练场
身位	中国”统一模型派”的代表；家庭场景商业化先行者之一

1. 故事的开端：“统一”的执念

自变量的创始团队对”大脑-小脑分层”有一个尖锐的批评：模块之间传递信息时会损耗。当一个 VLM 把它的理解压缩成一句文字指令或一个潜在向量交给动作模型时，大量对动作至关重要的细节（物体的精确形状、材质、受力）就丢失了。

联合创始人兼 CTO 王昊用一个类比来解释他们的理念：就像 Apple Silicon 的”统一内存”取代了 CPU 与 GPU 之间来回拷贝数据的传统架构，具身大脑也应该让视觉、语言、动作与物理预测在同一个网络、同一个表征空间中直接交互。

---

2. 代表作一：WALL-OSS（2025.09）→ WALL-OSS-0.5（2026.05）

2.1 WALL-OSS（2025.09）：紧耦合的 VLA

> 论文：*WALL-OSS*（arXiv 2509.11766，2025-09-08）；代码 GitHub wall-x。

WALL-OSS 是 WALL-A 的轻量开源版本，其核心特点： - 紧耦合架构：视觉-语言-动作在一个可微分框架内联合训练，而非把 VLM 与动作头松散拼接； - 统一的跨层级推理与动作生成：在同一个模型中贯通”指令推理 → 子目标分解 → 细粒度动作”，让推理与动作在同一链路中进行（业内解读常称之为”统一跨层级思维链”）； - 具身 VQA 能力：保留并强化模型对具身场景的问答与理解能力； - 紧耦合的 MoE 结构：Hugging Face LeRobot 文档将其描述为结合离散与连续动作建模的紧耦合混合专家结构；开源检查点包括 wall-oss-flow（流匹配连续动作，已集成进 LeRobot），第三方页面还列出 wall-oss-fast（离散 token）版本； - 论文报告在指令跟随与长时程操作上优于基线。

2.2 WALL-OSS-0.5（2026.05.28）：完全开源的训练栈

> 技术报告：*Wall-OSS-0.5 Technical Report*（arXiv 2605.30877）；官网标注发布日期 2026-05-28。

维度	内容
规模	约 40 亿参数的 VLA，基于约 30 亿参数的 VLM 主干
关键训练方法	梯度桥接协同训练（gradient-bridged co-training）：动作 token 的交叉熵损失直接更新 VLM 主干——让主干学会”对动作有用的表征”
动作 tokenizer	视觉对齐的 RVQ（Vision-Aligned RVQ）动作分词器
开源内容	完整栈：权重、训练代码、训练配方、优化器
真机成绩（官方）	在 15 个任务的真机评测集上平均任务进度 60.5，比 π0.5 高 17.5 个点

与 PI”知识隔离”的观点对比：PI 的 KI（第 2 章）主张截断动作专家到 VLM 的梯度以保护 VLM；WALL-OSS-0.5 则主张通过离散动作 token 的交叉熵桥接梯度、让 VLM 主干主动学习动作表征。两者并不完全矛盾——KI 截断的是”连续流匹配专家”的梯度，同时也用 FAST 离散 token 训练 VLM；WALL-OSS-0.5 用的是”视觉对齐 RVQ 离散 token”。共同点是：让 VLM 通过离散动作 token 学习动作，而不是被连续动作头的噪声梯度破坏。

---

3. 代表作二：WALL-B（2026.04.21）——世界统一模型（WUM）

> 发布：2026 年 4 月 21 日；官网 x2robot.com/research。

3.1 从 VLA 到 WUM

自变量把 WALL-B 定位为"从 VLA 架构向原生多模态融合架构的跨越"，并称其并非 WALL-A 的简单迭代，而是架构与训练范式的重写。

维度	典型 VLA	WALL-B（WUM）
结构	VLM（预训练）+ 动作头（后接）	单一网络
模态关系	视觉、语言、动作模块各自独立，信息在模块间传递	视觉、语言、动作与物理预测在同一网络中
训练	以预训练 VLM 为起点，再加动作训练	从零开始联合训练（据报道）
物理预测	通常没有	原生包含物理预测（世界模型能力）

3.2 为什么"从零联合训练"

如果以一个现成的 VLM 为起点，模型的表征空间已经被"图文对齐"塑造，动作与物理只能"后加"。从零联合训练意味着模型的表征从一开始就同时为"看、说、做、预测"服务——这与 LLM 领域"原生多模态模型（如 GPT-4o、Gemini 从训练之初就混合多模态）"的思路一致。代价是：需要极大规模的多模态具身数据与算力，无法直接继承互联网 VLM 的全部知识。

3.3 进入家庭：35 天后

发布会上宣布，搭载 WALL-B 系列模型的新一代机器人将在 35 天后（2026 年 5 月 25 日）首批进入真实家庭： - 形态：夹爪 + 轮式底盘（而非灵巧手或双足）——自变量明确选择"先进入家庭、再追求形态"； - 合作：与 58 同城合作，家庭部署搭载的是 WALL-AS 模型（WALL 系列的应用版本）。

这与 1X NEO（双足 + 遥操作兜底）、Sunday Memo（轮式 + 手套数据）、Figure（双足 + Helix 2.5）形成了家庭场景的多路线竞争。

---

4. 代表作三：WALL-WM 与 WALL-SS（2026.05–08）——事件级世界动作模型与虚拟训练场

4.1 WALL-WM（2026.05）：在"事件关节"处切分世界

> 论文：*WALL-WM: Carving World Action Modeling at the Event Joints*（X Square Robot Team，2026.05）；媒体称其为全球首个具备"事件级预测能力"的世界模型。

问题：逐帧预测的低效。大多数视频世界模型逐帧预测未来——但对机器人而言，大量帧是"无事发生"的（手在移动、物体静止），真正重要的是"事件"：杯子被拿起、门被打开、物体掉落。

WALL-WM 的思路："在事件的关节处切分"（化用柏拉图"在自然的关节处切分自然"的说法）——世界动作模型以事件而非帧为单位进行预测与建模，直接预测"下一个关键事件会是什么、需要什么动作来引发它"。媒体以"逐帧时代终结？"为题报道。

意义：这是对 1XWM、DreamZero 等"逐帧/逐片段视频生成"世界模型的一种效率与语义层面的改进思路——与宇树 WLA 只预测"动态区域"、星海图 Fast-WAM 降低延迟一样，都在解决"世界模型太慢、太冗余"的问题。

4.2 WALL-SS（2026.08）：下一尺度自回归世界模型

> 发布：2026 年 8 月下旬（报道称”机器人运动会散场后，自变量给机器人建了一座虚拟训练场”）。

- 下一尺度自回归（next-scale autoregressive）：借鉴图像生成中”由粗到细、逐尺度生成”的思路（如 VAR），以多尺度方式生成世界；
- 定位：一座让机器人”在虚拟世界练出真本事”的虚拟训练场——用于策略的训练、评估与强化学习。

---

5. 技术路线总结

```
2024 底    WALL-A：VLA
    ↓
2025.09    WALL-OSS：紧耦合 VLA + 统一跨层级思维链（开源）
    ↓
2026.04    WALL-B：世界统一模型（视觉 + 语言 + 动作 + 物理预测，单网络、从零联合训练）
    ↓
2026.05    WALL-AS 进入家庭（与 58 同城）；WALL-OSS-0.5 完全开源（梯度桥接 + 视觉对齐 RVQ）
           WALL-WM：事件级世界动作模型
    ↓
2026.08    WALL-SS：下一尺度自回归世界模型（虚拟训练场）
```

自变量的路线是一条”越来越统一”的路径：从 VLA 的模块拼接，到单网络统一，再把世界模型作为统一模型的原生能力与训练场。

---

6. 横向对比与身位

维度	自变量	智元（WRAM）	宇树（WLA）	NVIDIA（WAM / GR00T N2）
统一方式	单网络从零联合训练（WUM）	推理 + 预测 + 动作统一建模	ER-Flow + MMDiT（动态区域预测）	视频模型为主干联合去噪
起点	不依赖预训练 VLM（据报道）	VLM + 世界模型融合	Qwen3-VL-4B	Wan2.1-14B 视频模型
家庭部署	2026.05 起（轮式 + 夹爪）	工业为主	科研/消费	不造本体
开源	WALL-OSS / 0.5（完整栈）	GO-3 年底开源	WLA-1.0	开源

身位：自变量是中国”统一模型派”的最坚定代表，其 WALL-B 的”从零联合训练”主张在业内最为激进；同时在家庭场景商业化上走在国内前列。其开源完整度（WALL-OSS-0.5 完整训练栈）也在国内领先。

---

7. 未来展望与风险

展望： 1. WUM 的规模化：若”从零联合训练”的统一模型在数据规模扩大后展现出比”VLM + 动作头”更强的物理理解，将对行业架构产生深远影响； 2. 家庭数据飞轮：真实家庭部署带来的数据，是统一模型最需要的多模态具身数据； 3. 世界模型训练场：WALL-SS 若能有效替代部分真机训练，将显著降低迭代成本。

风险： 1. 从零训练的知识缺失：不继承互联网 VLM，可能在开放词汇理解、常识推理上弱于基于 VLM 的方案； 2. 技术细节透明度：WALL-B 的完整技术报告与独立评测有限； 3. 家庭场景的可靠性：轮式 + 夹爪方案在家务覆盖面上有限，用户体验与安全仍需验证。

---

8. 延伸阅读与核验来源

- WALL-OSS：arXiv 2509.11766
- WALL-OSS-0.5：arXiv 2605.30877；Utusan/PRNewswire；自变量官网
- WALL-B：人民政协网；量子位；环球网；品玩；NE 时代
- WALL-WM：每经网：事件级预测能力世界模型；CSDN 论文解读
- WALL-SS：腾讯新闻：自变量发布 WALL-SS；爱范儿
- 融资：Pulse 2.0：自变量 1.4 亿美元 A++ 轮；Robotics & Automation News

> 核验说明：WALL-OSS 的”紧耦合、统一可微分框架、指令跟随与长时程优势”来自 arXiv 论文；“Uni-CoT”与”FLOW/FAST 两个版本”来自开源仓库与业内解读，检索中未能逐字核实；WALL-OSS-0.5 的 4B/3B、梯度桥接、视觉对齐 RVQ、完整栈开源来自技术报告与新闻稿；WALL-B 的 WUM 定位、Apple Silicon 类比、“从零联合训练”、35 天进家庭来自多家媒体报道（WALL-AS 与 58 同城合作来自报道）；WALL-WM、WALL-SS 来自论文解读与媒体；估值”超 200 亿元”仅见单一来源。补充核验：“统一跨层级推理与动作生成”与 LeRobot 文档中”离散 + 连续动作建模的紧耦合 MoE”已核实，“Uni-CoT”这一命名未能核实；WALL-OSS-0.5 真机 15 任务平均进度 60.5、领先 π0.5 17.5 点来自官方发布；阿里云领投约 1.403 亿美元来自媒体报道。

第 41 章 千寻智能（Spirit AI）：“脏数据”哲学、登顶 RoboChallenge，与 RoboArena 的 72 小时

> 一句话定位：千寻智能由前珞石机器人联合创始人韩峰涛与清华交叉信息研究院高阳联合创立，是 2026 年中国具身领域最具戏剧性的公司：它的学术根基——高阳团队的《模仿学习中的数据缩放定律》（ICLR 2025 Oral）——揭示了”环境与物体的多样性比示范数量更重要”；它的 Spirit v1.5（2026.01）凭”开放式、目标驱动的’脏数据’采集”在第三方真机评测平台 RoboChallenge 的 Table30 榜单上首次超过 π0.5 登顶并开源，被称为中国具身的”DeepSeek 时刻”；而 2026 年 6 月，Spirit v1.6 在 RoboArena 登顶仅约 72 小时后，因评测数据异常被撤销，引发行业对”具身榜单能否被信任”的集体反思。同时，千寻在宁德时代电池产线上的柔性线束操作宣称成功率超过 99%，并于 2026 年 6 月完成 15 亿元 A+ 轮融资。

0. 速览卡片

维度	内容
成立	2024 年，杭州/北京
联合创始人	韩峰涛（CEO，前珞石机器人联合创始人，工业机器人老兵）；高阳（首席科学家，清华交叉信息研究院助理教授，UC Berkeley 博士）
融资	多轮融资；2026 年 6 月 3 日宣布 15 亿元 A+ 轮（另有英文报道称约 2.8 亿美元）
产品	Moz 系列人形机器人（如 Moz1）
落地	宁德时代（CATL）电池产线：人形机器人处理柔性线束，公司称成功率超过 99%
模型谱系	Spirit v1.5（2026.01.12 开源，RoboChallenge Table30 第一）→ Spirit v1.6（2026.06，RoboArena 排名被撤销）
学术根基	*Data Scaling Laws in Imitation Learning for Robotic Manipulation*（ICLR 2025 Oral）等
本章三篇代表作	① 模仿学习的数据缩放定律（ICLR 2025）② Spirit v1.5：开放式目标驱动数据 + 统一 VLA，登顶 RoboChallenge ③ Spirit v1.6 与 RoboArena 事件：具身评测的信任危机
身位	中国开源 VLA 的代表之一；数据哲学鲜明；评测争议使其成为行业”榜单治理”讨论的焦点

1. 故事的开端：一位工业机器人老兵与一位”数据科学家”

韩峰涛在工业机器人行业摸爬滚打多年（珞石机器人是国内协作机器人头部公司之一），深知工业现场的需求：可靠、可重复、能在真实产线上跑。高阳则是清华交叉信息研究院的年轻教授，研究方向是机器人学习与数据缩放。

两人的组合代表了千寻的双重基因：工业落地 + 数据科学。高阳团队在 2024 年的一项研究，奠定了千寻的数据哲学。

---

2. 代表作一：模仿学习的数据缩放定律（ICLR 2025 Oral）

> 论文：Fanqi Lin, Yingdong Hu, Pingyue Sheng, Chuan Wen, Jiacheng You, Yang Gao，*Data Scaling Laws in Imitation Learning for Robotic Manipulation*（arXiv 2410.18647，ICLR 2025 Oral）——清华大学。

2.1 问题

LLM 有清晰的缩放定律：数据越多、模型越大，性能越好。机器人模仿学习有没有类似规律？更具体地说：要让一个策略泛化到全新的环境与物体，我们应该收集"更多示范"，还是"更多环境与物体"？

2.2 实验设计

- 使用 UMI 手持夹爪（第 11 章）采集人类示范——便于在大量不同环境中采集；
- 核心任务：倒水（Pour Water）与鼠标摆放（Mouse Arrangement）；扩展验证：叠毛巾、拔充电器；
- 规模：超过 4 万条示范、超过 1.5 万次真实世界评测 rollout——在当时的学术研究中规模极大；
- 系统地改变"环境数量""物体数量""每个环境/物体的示范数量"，观察泛化性能的变化。

2.3 关键发现

1. 泛化性能与环境数量、物体数量之间近似呈幂律关系——机器人领域也存在"缩放定律"，但它首先体现在多样性上；
2. 多样性比示范数量更重要：当每个环境/物体的示范数量达到一定阈值后，继续增加示范几乎没有帮助；而增加新的环境与物体则持续带来提升；
3. 高效的数据采集策略：在尽可能多的环境中、用尽可能多的物体、每个只采少量示范。论文报告，按这一策略，4 名采集员一个下午采集的数据，就足以让策略在未见过的环境与物体上达到约 90% 的成功率（针对两个任务）。

2.4 意义

这项研究与 π0.5 的"训练环境数量缩放"（2025.04）、GEN-0 的"真实数据缩放定律"（2025.11）一起，构成了"数据多样性优先"的核心证据链。它直接塑造了千寻的数据采集哲学：与其在一个干净的场景里反复采集，不如走进大量真实、杂乱的环境。

---

3. 代表作二：Spirit v1.5（2026.01）——"脏数据"与登顶 RoboChallenge

> 开源：2026 年 1 月 12 日（基础模型权重、推理代码、使用示例、核心评测代码）；GitHub Spirit-AI-Team/spirit-v1.5；Hugging Face Spirit-AI-robotics/Spirit-v1.5。

3.1 数据哲学：开放式、目标驱动的采集

Spirit v1.5 最受关注的不是架构，而是数据： - 训练数据主要来自开放式、目标驱动（goal-driven）的采集——操作员追求高层目标（“把桌子收拾干净”），而不是执行预先编排好的动作脚本（“先拿杯子、再放到 A 点”）； - 这样的数据看起来更”脏”：充满任务切换、失败与恢复、不同顺序、不同手法； - 但正是这种”脏”，让数据自然覆盖了任务切换、恢复行为以及与各种物体和环境的交互——这些恰恰是”干净脚本数据”所缺失的。

公司报告：多样化数据训练的模型达到同等性能所需的迭代次数比基线减少约 40%。英文媒体以”挑战’干净数据’采集范式”“通过脏数据规模化机器人”为题报道。

与 π0.7 的有趣呼应：π0.7（2026.04）发现，混合质量数据需要配合”元数据”（标注速度、质量）才能持续带来增益（第 2 章）；千寻则主张”脏数据”本身因包含恢复行为而有价值。两者共同说明：数据”脏”不可怕，关键是模型能否从中学到正确的东西。

3.2 架构：统一 VLA

Spirit v1.5 被描述为一个统一的视觉-语言-动作模型——把感知、语言指令理解与运动规划合并到一条神经网络通路中，而非分模块的流水线。（公开报道未给出参数量与详细结构，以官方仓库为准。）

3.3 登顶 RoboChallenge

RoboChallenge 是 2025 年由原力灵机（Dexmal）、Hugging Face 等推出的第三方真机评测平台（第 14、45 章）。2026 年 1 月： - Spirit v1.5 在 Table30 榜单上取得总分 66.09、成功率 50.33%，超过此前领先的 π0.5，位列第一； - 被报道为首个在 RoboChallenge 上超过 π0.5 的中国团队模型，也是首个成功率超过 50% 的模型； - 单项成绩例如叠碗约 100%、把水果放进篮子约 80%（二手报道）； - 随即开源——被国内媒体称为具身智能的”DeepSeek 时刻”。

3.4 工业落地：宁德时代

据报道，Spirit 系列模型已用于宁德时代的电池产线，控制人形机器人处理柔性线束（插接、整理线缆——典型的可形变物体精细操作），公司称成功率超过 99%。这一场景与它石智航（第 43 章）在 WAIC 2026 上展示的线束产线类似——“柔性线束”正在成为中国人形工业落地的代表性任务。

---

4. 代表作三：Spirit v1.6 与 RoboArena 事件（2026.06）——具身评测的信任危机

4.1 事件经过

时间	事件
2026.06.03	千寻宣布 Spirit v1.6 在 RoboArena 评测中排名第一；同日宣布 15 亿元 A+ 轮融资
之后数日	业内人士发现异常：Spirit v1.6 的 310 次评测中，约 72% 的分数来自两个新注册账号；而 NVIDIA 用同一模型测试 21 次，胜率为 0
2026.06.14	RoboArena 发布公告，称榜单存在被操纵的痕迹，剔除问题数据

时间	事件
结果	回滚后 Spirit v1.6 仅剩 25 组有效评测，未达 100 组的上榜门槛，从官方榜单移除；RoboArena 回溯调查、排除利益关联数据，并重置评测者准入规则

从宣布登顶到成绩被撤，间隔约 72 小时。

（注：以上信息来自多家媒体报道与百科条目；本报告未找到千寻或 RoboArena 方面更正式、完整的书面回应。）

4.2 RoboArena 是什么

RoboArena 是一个众包式的分布式真机评测平台（思路类似大模型领域的 LMSYS Chatbot Arena）：不同评测者在各自的真实机器人上，对两个匿名策略进行成对比较，用胜率计算排名。众包的优点是规模大、场景多样；缺点是评测者身份与独立性难以保证。

4.3 行业反思：具身榜单能信吗？

21 财经以”人均第一，具身智能榜单能信吗？”为题发出追问。这一事件暴露出 2026 年具身评测的几个结构性问题： 1. 众包评测的可操纵性：评测者准入、利益关联审查、异常检测机制不足； 2. “榜单营销”：融资发布与榜单登顶同日宣布，使榜单成为营销工具； 3. 评测碎片化：RoboChallenge、RoboArena、RoboDojo、RoboTwin、RoboColiseum、GM-100、BEHAVIOR……各家都能在某个榜单”登顶”（参见第 29、32 章的”三大榜单第一”宣称）； 4. 真机评测的统计噪声：TRI 的研究（第 15 章）早已指出，真机评测方差极大，小样本结论不可靠。

4.4 意义

这一事件的意义超出了千寻本身：它标志着具身智能行业从”演示视频时代”进入”榜单时代”，并迅速遭遇了榜单时代的第一次信任危机。 此后，RoboArena 加强了准入与审查，行业对”盲测、大样本、利益隔离、可复现”的评测要求显著提高。

---

5. 技术路线总结

```
学术根基：数据缩放定律（ICLR 2025）—— 多样性 > 数量
        ↓
数据哲学：开放式、目标驱动的"脏数据"采集 —— 覆盖切换、恢复、交互
        ↓
模型：Spirit v1.5（统一 VLA）—— RoboChallenge 第一，开源
        ↓
落地：宁德时代柔性线束（>99%，公司口径）
        ↓
教训：Spirit v1.6 / RoboArena —— 评测治理的必要性
```

---

6. 横向对比与身位

维度	千寻	星海图	智元	PI
数据哲学	开放式目标驱动”脏数据”	开放世界单本体	标准化数据工厂	多本体 + 元数据条件化
开源	Spirit v1.5	G0、G0.5	GO-1、GE、GO-3（计划）	π0/π0.5
第三方榜单	RoboChallenge 第一（v1.5）；RoboArena 撤销（v1.6）	—	三榜第一（自称，部分为 Nano 版）	被作为基线
工业落地	宁德时代	多场景	龙旗等	合作伙伴

身位：千寻是中国开源 VLA 的代表之一，Spirit v1.5 在第三方平台超越 π0.5 是中国具身开源的标志性事件；但 Spirit v1.6 事件对其公信力造成了损害，后续需要以更透明、可复现的评测重建信任。

---

7. 未来展望与风险

展望： 1. 数据哲学的再验证：“脏数据”路线若在更大规模上持续有效，将影响行业的数据采集方式； 2. 工业落地：宁德时代等头部制造客户的规模化部署，是比榜单更有说服力的证据； 3. 开源生态：持续开源可能帮助千寻重建学术与开发者社区的信任。

风险： 1. 公信力：RoboArena 事件的影响可能持续； 2. 评测依赖：若过度依赖榜单营销，可能偏离真实能力建设； 3. 竞争：国内开源 VLA 竞争激烈（星海图、智元、小米、蚂蚁、宇树等）。

---

8. 延伸阅读与核验来源

- 数据缩放定律：arXiv 2410.18647；ICLR 2025 Oral
- Spirit v1.5：新浪财经：千寻正式开源 Spirit v1.5；腾讯新闻：RoboChallenge 榜首模型开源；维科号；Pulse：挑战干净数据范式；LAVX：进入工业部署；Rocking Robots：Spirit AI 融资 2.8 亿美元
- Spirit v1.6 / RoboArena：虎嗅：RoboArena 遭操纵，Spirit v1.6 排名被清零；腾讯新闻；21 财经：人均第一，具身智能榜单能信吗？；百度百科：Spirit v1.6

> 核验说明：数据缩放定律的方法与结论来自 ICLR 2025 论文，“4 名采集员一个下午达到约 90%”来自二手综述；Spirit v1.5 的开源日期、RoboChallenge Table30 66.09 分/50.33% 成功率、超越 π0.5 来自多家媒体；“迭代次数减少约 40%”与宁德时代”>99%“为公司口径；Spirit v1.6 事件的时间线、”310 次中 72% 来自两个新账号”、“25 组有效评测未达 100 组门槛”来自多家媒体与百科，未见双方完整书面回应；融资金额存在人民币与美元两种口径。

第 42 章 智平方（AI² Robotics）：全域全身 VLA、“快在慢中”与类脑 NeuroVLA

> 一句话定位：智平方由郭彦东（Yandong Guo）创立，以”全域全身 VLA”为核心叙事——其具身大模型 AlphaBrain（原 AI2R Brain，2025 年 4 月更名）以 GOVLA 为起点，强调 360° 全空间感知与 34 自由度全身协同；与北大、港中文、智源合作的 FiS-VLA（Fast-in-Slow，NeurIPS 2025） 提出”把快系统嵌入慢系统”的双系统新范式，在 8 步动作块下实现约 117.7Hz 控制；Video2Act（2025.11，与北大合作）把 4D 世界模型融入 VLA；2026 年 4 月开源的 NeuroVLA 则走出一条极具辨识度的”类脑”路线——以皮层-小脑-脊髓三层结构、脉冲神经网络（SNN）动作层与 R-STDP 式在线自适应，实现毫秒级反射与极低功耗。智平方估值约 200 亿元，主力产品为轮式双臂机器人 AlphaBot 2。

---

0. 速览卡片

维度	内容
成立	2023 年，深圳
创始人	郭彦东（Yandong Guo，前小鹏等公司 AI 高管，媒体报道）
估值	约 200 亿元（媒体报道）
产品	AlphaBot 2（爱宝 2）：轮式双臂智能机器人（2025.04 发布），并启动 2028 年万台产能计划
大脑谱系	GOVLA / AI2R Brain → AlphaBrain（2025.04 更名）→ FiS-VLA（2025.06，NeurIPS 2025）→ Video2Act（2025.11）→ NeuroVLA（2026.04 开源）；AlphaBrain Platform 开源社区（2026.04）
本章三篇代表作	① GOVLA 与 FiS-VLA：全域全身 VLA 与”快在慢中”的双系统 ② Video2Act：融合 4D 世界模型的 VLA ③ NeuroVLA：类脑三层结构与脉冲神经网络
身位	中国具身大脑创业公司中”架构创新”最活跃者之一；类脑路线独树一帜

---

1. 故事的开端：“全域全身”的执念

大多数 VLA 只控制机械臂——输出末端位姿或关节角。但一个真实的服务/工业机器人需要：转头看、转身找、移动底盘、升降躯干、双臂协作。智平方的出发点是：VLA 必须是”全域”（360° 感知）与”全身”（底盘 + 躯干 + 双臂 + 头部协同）的。

这决定了智平方的大脑设计必须处理比”桌面双臂”高得多的动作维度与空间范围。

---

2. 代表作一：GOVLA 与 FiS-VLA——全域全身 VLA 与”快在慢中”

2.1 GOVLA：全域全身 VLA（AlphaBrain 早期核心）

据公开介绍，GOVLA 具备： - 360° 全空间感知； - 34 自由度全身协同控制（含底盘移动轨迹与全身动作）； - 快慢双系统：由空间交互基础模型、慢系统、快系统三部分组成——慢系统负责复杂推理与任务拆解，快系统输出全身控制动作与移动轨迹； - 智平方称其首次将 DeepSeek 的技术融入 VLA 构建，以增强长程复杂任务的推理能力（公司说法）。

GOVLA 在 2026 年 3 月的一份"全球具身智能 TOP10"榜单中被作为智平方领跑的依据（该榜单带有明显的企业推广色彩，见第 41 章对榜单的讨论）。

2.2 FiS-VLA：快在慢中（NeurIPS 2025）

> 论文：Hao Chen, Jiaming Liu, Chenyang Gu, Zhuoyang Liu, Renrui Zhang, Xiaoqi Li, Xiao He, Yandong Guo, Chi-Wing Fu, Shanghang Zhang, Pheng-Ann Heng，*Fast-in-Slow: A Dual-System Foundation Model Unifying Fast Manipulation within Slow Reasoning*（arXiv 2506.01953，NeurIPS 2025）——港中文、北大、智源等（郭彦东为作者之一）。

问题：主流双系统（Helix、GR00T、G0）中，快系统（System 1）是一个独立的小策略网络，接在慢系统（大 VLM）后面。这带来两个问题： - 快系统是小模型，无法充分利用 VLM 的预训练知识； - 两个系统之间通过潜在向量或文字传递信息，存在信息损耗与对齐困难。

核心思想："快"不是另一个模型，而是"慢"的一部分：



- 共享参数：把 VLM 最后若干个 Transformer 块"改造"为高效的执行模块（System 1）；
- 异构输入与异步频率：两个系统使用不同的输入（快系统用更轻量、高频的观察），以不同频率运行；
- 双感知协同训练（dual-aware co-training）：联合优化两个系统。

结果： - 平均成功率在仿真中超过此前最优约 8%，真实任务中约 11%； - 在动作块大小为 8 时，控制频率达到约 117.7Hz。

意义：FiS-VLA 提出了与 Helix/GR00T"外挂快系统"、PI π0"共享注意力的动作专家"都不同的第三种方案——快系统是慢系统的"尾部"。它对 VLA 架构设计的讨论有重要价值。

---

3. 代表作二：Video2Act（2025.11）——融合 4D 世界模型的 VLA

> 发布：2025 年 11 月，智平方与北京大学联合推出；并入 AlphaBrain。

核心思想：把世界模型（对未来场景的预测）融入 VLA——据报道是一个融合 4D 世界模型（三维空间 + 时间）的 VLA 架构： - 模型不仅理解当前场景，还预测未来的 4D 场景变化； - 以这种预测作为动作生成的依据——“从视频（预测）到动作”，即 Video2Act 名称的含义。

结果：据报道在第三方评测中相较硅谷同类模型性能领先超过 30%（公司/媒体口径，未见独立验证）。

意义：Video2Act 是智平方对 2025–2026 年”VLA + 世界模型融合”潮流的回应，与星动纪元 VPP、字节 GR 系列、NVIDIA DreamZero 同属一个大方向；其”4D”的强调与小鹏 VLA 2.0 的”3D → 4D 时空”升级（2026.08）思路相通。

---

4. 代表作三：NeuroVLA（2026.04 开源）——类脑三层结构与脉冲神经网络

> 发布：2026 年 4 月，智平方推出并开源 NeuroVLA，定位为 AlphaBrain 的最新版本；同月发布一站式具身智能模型开源社区 AlphaBrain Platform。

4.1 灵感：人类神经系统的三级控制

人类的运动控制并不是”大脑直接控制每块肌肉”，而是分层的： - 大脑皮层：理解、规划、决策（慢）； - 小脑：运动协调、平滑、误差修正（中）； - 脊髓：反射——手碰到烫的东西会在大脑”意识到”之前缩回（极快）。

4.2 NeuroVLA 的三层架构

层级	类比	职责	实现
皮层（Cortex）	大脑皮层	语义理解与任务规划	VLM / VLA 主干
小脑（Cerebellum）	小脑	高频运动协调与动态修正	高频控制模块
脊髓（Spinal Cord）	脊髓	快速执行与安全反射	脉冲神经网络（SNN），异步驱动

4.3 为什么用脉冲神经网络

脉冲神经网络（Spiking Neural Network, SNN） 是一类更接近生物神经元的网络——神经元以离散的”脉冲”在时间上传递信息，事件驱动、异步运行： - 极低延迟的反射：据报道，碰撞后约 20 毫秒内即可产生反射响应； - 极低功耗：在神经形态处理器上，第三方项目摘要称功耗约 0.4W； - 在线自适应：智平方介绍其引入了 R-STDP（奖励调制的脉冲时序依赖可塑性）式训练/学习算法——一种生物启发的局部学习规则，支持部署阶段的在线自适应。

4.4 报道的效果

- 机器人运动抖动降低超过 75%；
- 碰撞后约 20 毫秒反射；
- 功耗显著降低。

（以上为公司与媒体口径，未见独立评测。）

4.5 意义与争议

意义：NeuroVLA 是全球具身大脑中少有的类脑/神经形态路线。它回应了一个真实的工程需求——安全反射：当机器人与人或物体发生意外碰撞时，等待大模型"想明白"再反应是来不及的，必须有一个极快的、不经过大模型的反射层。这与 Agility 的"始终在线的安全层"（第 10 章）、Figure S0 的 1kHz 控制在功能上相似，但实现方式完全不同。

争议/局限：SNN 在大规模学习任务上的成熟度仍远低于标准深度网络；"全球首个类脑 VLA"等说法为公司宣传；R-STDP 的具体实现与效果有待论文与第三方验证。

---

5. 技术路线总结

```
2025.04  AlphaBrain（GOVLA）：全域全身 VLA，快慢双系统，34 自由度
    ↓
2025.06  FiS-VLA（NeurIPS 2025）：快系统嵌入慢系统（复用 VLM 尾部层），117.7Hz
    ↓
2025.11  Video2Act：融合 4D 世界模型的 VLA
    ↓
2026.04  NeuroVLA：皮层-小脑-脊髓三层类脑结构，SNN 反射层，在线自适应
         AlphaBrain Platform：开源社区（数据、训练、模型、评测全链路）
```

智平方的特点是架构创新密度高：一年内提出了三种不同的大脑架构思想（快在慢中、4D 世界模型融合、类脑分层）。

---

6. 横向对比与身位

维度	智平方	Figure	逐际	银河通用
分层方式	皮层-小脑-脊髓（类脑）	S2-S1-S0	COSA S2-S1-S0	大脑-脑桥-小脑
快系统	嵌入慢系统（FiS）/ SNN 反射	独立 S1 + S0	VLA/WAM 技能	小脑 WBC
世界模型	Video2Act（4D）	—	COSA 引擎	WAM
本体	轮式双臂 AlphaBot 2	双足	双足	轮式 + 双足

身位：智平方在架构创新上非常活跃（FiS-VLA 进入 NeurIPS），类脑路线具有独特性；但在公开、可复现的评测与大规模部署证据上不如智元、宇树等。

---

7. 未来展望与风险

展望： 1. 类脑芯片 + 机器人：若神经形态硬件成熟，NeuroVLA 的低功耗、低延迟优势可能在端侧机器人上凸显； 2. 安全反射层的标准化：机器人进入家庭与人共处后，"脊髓式"安全反射可能成为刚需； 3. AlphaBrain

Platform 生态：开源社区若吸引足够开发者，可形成平台效应。

风险： 1. 宣传口径："全球首个""领先 30%"等说法需独立验证； 2. SNN 路线的不确定性：主流深度学习生态与工具链对 SNN 支持有限； 3. 多条架构路线并行可能分散资源。

---

8. 延伸阅读与核验来源

- FiS-VLA：arXiv 2506.01953；NeurIPS 2025
- AlphaBrain / GOVLA：百度百科：AlphaBrain；21 财经：AlphaBot 2 发布；智平方官网
- Video2Act / NeuroVLA：量子位；RobotToday：NeuroVLA；投资界；SourcePulse：NeuroVLA 项目
- 搜狐：智平方估值 200 亿

> 核验说明：FiS-VLA 的方法、作者（含 Yandong Guo）、NeurIPS 2025、+8%/+11%、117.7Hz 来自 arXiv 与 NeurIPS 页面（作者机构未列出智平方，郭彦东为作者之一）；GOVLA 的 360°、34 自由度、三部分结构、"融入 DeepSeek 技术"来自公司与百科；Video2Act 的"4D 世界模型""领先 30%"来自媒体报道；NeuroVLA 的三层结构、SNN 脊髓层、抖动 -75%、20 毫秒反射来自公司/媒体，0.4W 来自第三方项目摘要，R-STDP 来自公司介绍，均未见独立论文核实；估值来自媒体。

第 43 章 它石智航（TARS）：“不仿真、不遥操、不是 VLA”——以人为中心数据训练的具身世界引擎 AWE

> 一句话定位：它石智航由前华为车 BU 自动驾驶首席科学家陈亦伦与前百度 Apollo 负责人李震宇联合创立，2026 年 4 月以 4.55 亿美元 Pre-A 轮（高瓴创投、红杉中国联合领投）刷新中国具身智能单轮融资纪录。它的技术主张极其鲜明：彻底摒弃遥操作与纯仿真数据，用”以人为中心（Human-centric）“的真实人类操作数据（含触觉）训练一个”具身世界引擎”——AWE（AI World Engine）。其开源的 WIYH（World In Your Hands） 是全球首个大规模真实世界 VLTA（视觉-语言-触觉-动作）数据集；AWE 3.0（2026.03）基于 10 万小时以上人类数据，主攻汽车/3C 制造中”最后一块纯人工堡垒”——线束装配；AWE 3.5（2026.07，WAIC，获 SAIL 奖）进一步强化长时记忆与时空理解，并能生成可交互环境、在模型内部世界中做强化学习。它石宣称已迈过 100 万小时人类数据，目标是 2026 年底冲击千万小时。

0. 速览卡片

维度	内容
成立	2024–2025 年（来源不一），总部上海/北京
联合创始人	陈亦伦（CEO，前华为车 BU 自动驾驶首席科学家、大疆机器视觉负责人）；李震宇（董事长，前百度集团副总裁、Apollo 自动驾驶负责人）
融资	2025 年天使轮（约 1.2 亿美元级，据报道）；2026.04.16 Pre-A 轮 4.55 亿美元（高瓴创投、红杉中国联合领投，美团龙珠等跟投），中国具身智能单轮融资最高纪录
数据	WIYH（World In Your Hands，2025.12.26 开源，全球首个大规模真实世界 VLTA 数据集，含超过 10 万条真实人类操作视频）；宣称”百万小时级”人类数据，目标 2026 年底千万小时
模型谱系	AWE 2.0（2025 年底，驱动刺绣机器人等首秀）→ AWE 3.0（2026.03）→ AWE 3.5（2026.07 WAIC，获 SAIL 之星）
场景	线束装配（汽车、3C 制造）为核心；全场景验证
本章三篇代表作	① WIYH：以人为中心的视觉-语言-触觉-动作数据集 ② AWE 3.0：不仿真、不遥操、不是 VLA 的”具身世界引擎”③ AWE 3.5：长时记忆、可交互世界生成与模型内强化学习
身位	中国”人类数据派”的旗手，与美国 Generalist 遥相呼应；资本实力位列中国具身第一梯队

1. 故事的开端：两位自动驾驶老兵的”数据顿悟”

陈亦伦与李震宇都在自动驾驶行业经历了完整周期。他们从自动驾驶中学到的最重要一课是：

> 自动驾驶之所以能做起来，是因为有”人类驾驶数据”——数百万司机每天都在免费地生成高质量的”示范”。人形机器人也应该从”人类做事的数据”中学习，而不是依赖昂贵的遥操作或失真的仿真。

这一判断形成了它石的”三不”主张：不仿真（主要数据不来自仿真）、不遥操（主要数据不来自遥操作）、不是 VLA（模型不是传统的 VLM + 动作头）。

---

2. 代表作一：WIYH——以人为中心的 VLTA 数据集（2025.12.26 开源）

2.1 定位

WIYH（World In Your Hands，“世界在你手中”） 被它石称为全球首个大规模真实世界具身 VLTA（Vision-Language-Tactile-Action，视觉-语言-触觉-动作）多模态数据集。

2.2 设计要点

维度	内容
采集范式	以人为中心（Human-centric）：人在真实工作与生活场景中自然操作，配戴采集设备（多视角相机、手部动作追踪、触觉传感）
模态	视觉 + 语言标注 + 触觉 + 手部动作
规模	超过 10 万条真实人类操作视频（开源部分，据报道）
场景	工业装配、家庭、商业等真实场景

2.3 为什么”触觉”是关键

绝大多数具身数据集只有视觉与动作。但在接触密集的操作中——插接线束、拧螺丝、装配精密零件——真正决定成败的是”手感”：插头是否对准、是否插到底、用力是否过大。人类在这些任务中高度依赖触觉。WIYH 把触觉作为一等模态，正是为了让模型学会”眼手触协同”。

这与 Figure 03 指尖触觉传感器、Genesis 的触觉数据手套、Sunday 的技能采集手套属于同一趋势：2026 年，触觉正在从”可选”变成”必需”。

---

3. 代表作二：AWE 3.0（2026.03）——“能干活的通用具身大模型”

> 发布：2026 年 3 月（AWE 2026 期间）；量子位报道标题：“不仿真不 VLA 不遥操：它石智航重磅发布’能干活的通用具身大模型’AWE3.0”。

3.1 “不是 VLA，而是世界模型”

它石明确表示，AWE 3.0 不是 VLA，也不是 3D 资产生成模型，而是一个真正意义上能够作为具身大脑的世界模型——全称 AI World Engine。其含义（基于公开表述的理解）是：- 模型的核心能力是理解与预测物理世界（物体如何变形、接触如何发生、动作会产生什么后果）；- 动作生成建立在这种世界理解之上，而非”VLM 理解 + 动作头输出”的拼接。

（它石未公开 AWE 3.0 的详细网络结构。）

3.2 数据：10 万小时以上 Human-centric 数据

训练数据来自超过 10 万小时的以人为中心数据，并包含大规模触觉数据。

3.3 核心场景：线束装配

线束装配被称为汽车与 3C 制造中”最后一块纯人工堡垒”： - 材质柔软易变形：线束不是刚体，位置与形状随操作不断变化； - 接口间隙微小：插接需要毫米乃至亚毫米精度； - 操作空间受限：常在狭窄的车身或机壳内部操作。

传统工业机器人几乎无法自动化这一工序，因此至今高度依赖人工。

“线束装配图灵测试”：它石报告，在一项让观众分辨”人类操作视频 vs 机器人操作视频”的测试中，超过 50% 的投票者分不清哪个是机器人（公司口径）。

行业对照：千寻智能也宣称其模型在宁德时代电池产线上处理柔性线束（第 41 章）——“柔性线束”已成为 2026 年中国具身工业落地的标志性任务。

---

4. 代表作三：AWE 3.5（2026.07，WAIC 2026）——长时记忆、可交互世界与模型内强化学习

> 发布：2026 年 7 月，世界人工智能大会（WAIC 2026）主论坛，陈亦伦发布；获本届唯一的具身智能基座模型 SAIL 之星奖；WAIC 展台以”真实线束产线”现场演示。

4.1 三项升级

1. 结构强化：依托 Human-centric 数据专门强化了模型结构，以学习长时记忆与长时序空间理解——解决长流程装配中”记住已经做了什么、记住零件在哪”的问题；
2. 可交互环境生成：AWE 3.5 可以生成可交互的环境——即模型本身能作为一个”世界模拟器”；
3. 模型内强化学习：后训练可以从连续过程中切出多个动作片段，在模型内部生成的世界中进行强化学习——“在想象中练习”。

4.2 “世界引擎”名副其实

到 AWE 3.5，“AI World Engine”的含义变得清晰：它同时是策略（生成动作）与世界模型（生成可交互环境），并利用后者为前者提供强化学习训练场。这与 NVIDIA DreamZero（世界动作模型）、星动纪元 Ctrl-World（世界模型评估与改进）、自变量 WALL-SS（虚拟训练场）、1X 1XWM 属于同一个 2026 年大趋势。

4.3 数据规模：从百万小时到千万小时

据报道，它石已迈过自动驾驶级（100 万小时）的高质量真实数据规模，并计划在 2026 年底前冲击千万小时级真实世界预训练数据。若实现，将是全球公开宣称的最大规模真实人类操作数据之一（对照：Generalist 50 万小时+、小米 10 万小时 UMI、Figure Index 每秒约 35 分钟）。

5. 技术路线总结

```
数据：以人为中心（Human- centric）、含触觉的真实人类操作数据
      WIYH（开源，10 万+ 视频）→ 10 万小时（AWE 3.0）→ 100 万小时（2026 年中）→ 目标 1000 万小时（2026 年底）
                                  |
                                  ▼
模型：AWE（AI World Engine）—— "不是 VLA，而是世界模型"
      AWE 2.0（2025 底）→ AWE 3.0（2026.03，线束装配）→ AWE 3.5（2026.07，长时记忆 + 可交互世界 + 模型内 RL）
                                  |
                                  ▼
场景：线束装配等接触密集的工业任务（"最后一块纯人工堡垒"）
```

6. 横向对比与身位

维度	它石智航	Generalist（美）	Sunday（美）	小米
数据来源	以人为中心 + 触觉	人类真实交互设备	技能采集手套	UMI 设备
数据规模（宣称）	100 万小时 → 千万小时目标	50 万小时+	1000 万条家庭片段	10 万小时
模型定位	世界引擎（非 VLA）	和声推理基础模型	ACT-1	VLA 基座
核心场景	工业线束装配	通用（授权）	家庭	工业（自家工厂）
开源	WIYH 数据集	否	否	是

身位： - 它石是中国”人类数据派”的旗手，也是全球少数把”触觉”作为核心数据模态的公司； - 资本实力（单轮 4.55 亿美元）位列中国具身第一； - 德本咨询《2026 中国具身大模型 TOP30》将其排在前列； - 但其模型的技术细节公开有限，“不是 VLA”“百万/千万小时”等宣称缺乏论文与独立验证。

7. 未来展望与风险

展望： 1. 千万小时数据：若年底实现千万小时级真实数据，将对”人类数据缩放定律”提供前所未有的规模验证； 2. 线束装配的规模化：若在汽车/3C 产线实现规模化替代，将是人形工业落地的标志性事件； 3. 模型内 RL：AWE 3.5 的”在世界模型中强化学习”若有效，可大幅降低真机迭代成本。

风险： 1. 人-机形态鸿沟：人手数据（含触觉）如何精确迁移到机器人手，仍是根本挑战； 2. 透明度：缺少技术报告与第三方评测； 3. 资本消耗：千万小时级数据采集需要巨额持续投入。

8. 延伸阅读与核验来源

- WIYH：中国日报：WIYH 数据集正式开源
- AWE 3.0：量子位：不仿真不 VLA 不遥操，AWE3.0 发布；中国日报（2026.03）
- AWE 3.5：量子位：WAIC 首发 AWE 3.5；新浪科技：AWE 摘得 SAIL 之星；OFweek；中国工业新闻网

- 融资：投资界：它石 4.55 亿美元 Pre-A；量子位；界面新闻；网易：它石领跑 2026 具身资本盛宴

> 核验说明：融资金额、领投方与日期来自多家媒体一致报道；WIYH 的开源日期、VLTA 定位与 10 万+视频来自中国日报等；AWE 3.0 的”不是 VLA 而是世界模型”“10 万小时以上数据”“线束装配图灵测试 >50%”来自公司发布与媒体报道；AWE 3.5 的三项升级与 SAIL 奖来自 WAIC 报道；“百万小时”“千万小时目标”为公司口径；公司成立时间存在 2024 年与 2025 年 2 月两种说法；AWE 的具体网络结构未公开。

第 44 章 极佳视界（GigaAI）：世界模型"造数据"，再用世界模型"练策略"

> 一句话定位：极佳视界（GigaAI，又称极佳科技）是中国"世界模型驱动具身智能"路线最纯粹的创业公司之一，获华为等机构押注（2026 年 3 月前后完成 10 亿元 Pre-B 轮）。它的技术主线可以用两句话概括：第一，用世界模型"造数据"——GigaWorld-0（2025.11）被其称为首个验证"世界模型生成数据能有效提升真实机器人 VLA 性能"的工作；第二，用世界模型"练策略"——GigaBrain-0（2025.10）是用世界模型生成数据大规模训练的 VLA，GigaBrain-0.5M*（2026.02）进一步在世界模型中做强化学习（RAMP 框架）。2026 年，它又推出 GigaWorld-1 与 GigaWorld-Policy（世界-动作模型），并以"GigaBrain + GigaWorld + Maker H01 机器人"三位一体构建"具身基模"。

0. 速览卡片

维度	内容
公司	极佳视界 / 极佳科技（GigaAI），北京
融资	2025 年 12 月 A2 轮约 2 亿元（达晨、华控领投）；2026 年 3 月前后 Pre-B 轮 10 亿元（媒体报道华为参与押注）
产品体系	GigaBrain（VLA 具身基模）+ GigaWorld（世界模型）+ Maker H01（机器人本体）
模型谱系	GigaBrain-0（2025.10）、GigaBrain-0.1（开源，宣称在大规模真机评测中超越 π0.5）、GigaWorld-0（2025.11，开源）、GigaBrain-0.5M*（2026.02，世界模型强化学习 RAMP）、GigaWorld-Policy、GigaWorld-1（2026.03）
开放程度	较高：GigaBrain-0 / 0.1、GigaWorld-0 开源（GigaWorld-0 GitHub 星标超 1500）
本章三篇代表作	① GigaWorld-0：世界模型作为具身数据引擎 ② GigaBrain-0：世界模型数据驱动的 VLA ③ GigaBrain-0.5M* 与 GigaWorld-1/Policy：在世界模型中强化学习与世界-动作模型
身位	中国世界模型路线的专精型代表；技术叙事与 NVIDIA（Cosmos + GR00T）高度对标

1. 故事的开端：从自动驾驶世界模型到具身

极佳团队较早在自动驾驶世界模型（驾驶场景视频生成、4D 场景重建）方向积累技术。自动驾驶行业在 2023–2024 年验证了一个关键结论：用世界模型生成的长尾场景数据，可以有效提升端到端驾驶模型的性能。极佳的判断是：这一结论同样适用于具身智能——而且由于机器人真机数据比驾驶数据稀缺得多，世界模型生成数据的价值在具身领域会更大。

2. 代表作一：GigaWorld-0（2025.11）——世界模型作为具身数据引擎

2.1 定位

GigaWorld-0 被极佳称为”全球首个验证’世界模型生成数据能够有效提升真实物理机器人（VLA）性能’的里程碑式工作”（公司说法）。其开源代码在 GitHub 上获得超过 1500 星。

2.2 两条分支：视频世界模型 + 3D 物理世界

> 论文：*GigaWorld-0: World Models as Data Engine to Empower Embodied AI*（GigaWorld Team，arXiv 2511.19861，2025-11-25，v2 2025-11-30）；项目页 gigaworld0.github.io。

GigaWorld-0 不是一个”会画画”的视频模型，而是一个为 VLA 训练生产数据的统一世界模型框架，由两条分支组成：

（1）GigaWorld-0-Video：大规模视频生成 - 基础模型 GigaWorld-0-Video-Dreamer：一个混合专家（MoE）架构的”图像+文本 → 视频”生成模型； - 在其上做三种后训练，得到三个”数据迁移”变体： - 外观迁移：保持机器人动作与轨迹不变，改变场景外观（材质、光照、背景、物体纹理）——“一条真实轨迹变成大量视觉多样的轨迹”； - 视角迁移：从一个相机视角生成其他视角的画面； - 动作模仿（motion mimicry）：例如把人类操作视频转换为机器人执行的视频。

（2）GigaWorld-0-3D：物理可执行的 3D 场景 - 用 3D 生成模型生成前景物体资产； - 用 3D 高斯泼溅（3DGS）重建场景； - 用运动规划模块计算机械臂可执行的动作——保证生成数据在几何与物理上一致，而不只是”看起来像”。

（3）GigaTrain：高效训练框架——采用 FP8 精度与稀疏注意力降低显存与算力开销。

关键结论（论文报告）：用 GigaWorld-0 生成的数据训练的 VLA（GigaBrain-0），在训练中不使用真实世界交互的条件下，提升了真机任务成功率与泛化能力。

2.3 意义

GigaWorld-0 与 NVIDIA Cosmos/DreamGen、智元 GE-Sim 属于同一方向，但更聚焦于”生成的数据是否真的能提升真机 VLA”这一可验证的问题——这正是世界模型在具身中最务实的价值。

---

3. 代表作二：GigaBrain-0（2025.10）——世界模型数据驱动的 VLA

> 技术报告：*GigaBrain-0: A World Model-Powered Vision-Language-Action Model*（arXiv 2510.19430，2025.10）；后续开源 GigaBrain-0 与 GigaBrain-0.1。

3.1 核心思想与架构

GigaBrain-0 是一个以世界模型生成数据为重要训练来源的 VLA，以降低对昂贵真机数据的依赖，目标是在外观、物体摆放、相机视角变化下保持泛化。

组件	设计
主干	混合 Transformer（MoT），以 PaliGemma2 VLM 为基础
动作生成	动作扩散 Transformer（DiT），以流匹配预测连续动作
视觉	RGB-D 输入：扩展 SigLIP 第一层卷积以接收深度通道；训练中随机丢弃深度，使模型在只有 RGB 时也能工作
具身思维链	中间推理 token 包括：2D 操作轨迹（10 个关键点）、子目标语言、离散动作 token
数据	真机数据 + 大规模 GigaWorld 生成数据（外观/视角/动作迁移、3D 物理场景）

为什么是 RGB-D + 具身思维链：深度提供精确的三维几何（与蚂蚁 LingBot-Depth、智源 RoboBrain 2.5 的"3D 化"趋势一致）；2D 轨迹关键点让模型在输出动作前先"画出"手要走的路径——这是一种空间化的思维链，与 RoboBrain 的轨迹预测、DM0 的空间脚手架思路相通。

3.1.1 GigaBrain-0-Small：面向端侧

论文提供了轻量版 GigaBrain-0-Small，面向 NVIDIA Jetson AGX Orin 等边缘设备。据二手摘要，它在 Orin 上以约 π0 参数量的 12.5%、约 1/5 的 FLOPs、约 1/9 的显存与约 1/10 的延迟取得可比的成功率（以论文表格为准）。

3.2 结果

- 在灵巧操作、长时程任务、移动操作等真实任务上表现出更好的泛化；
- 开源的 GigaBrain-0.1 被极佳称为在全球较大规模的真机评测中超越 π0.5 等模型、排名第一（公司口径，具体榜单与时间需以官方为准）。

---

4. 代表作三：GigaBrain-0.5M* 与 GigaWorld-1 / GigaWorld-Policy（2026）——在世界模型中强化学习

4.1 GigaBrain-0.5M*（2026.02）：世界模型强化学习 VLA

> 论文：*GigaBrain-0.5M**（2026.02），基于 GigaBrain-0.5 构建。

RAMP 框架：基于世界模型条件策略的强化学习—— - 先用世界模型预测"在某个动作下，未来会是什么样"； - 以世界模型的预测作为条件，训练/改进策略； - 在世界模型"想象"的环境中进行强化学习，减少昂贵且危险的真机试错。

意义：这与 PI 的 π0.7（世界模型生成子目标）、它石 AWE 3.5（模型内 RL）、星动纪元 Ctrl-World（世界模型中评估与改进）、星海图 G-Fleet（真机 RL）共同构成 2026 年"VLA + 世界模型 + RL"三者融合的潮流。"M*"的命名也呼应了 PI 的 π*0.6（"*"表示经过 RL 优化）。

4.2 GigaWorld-Policy：世界-动作模型

GigaWorld-Policy 被宣传为在主流”世界-动作模型（WA）”的推理效率与性能上实现全面超越（公司口径）——即把世界模型直接变成策略（与 NVIDIA DreamZero 同一方向），并重点解决推理效率问题。

4.3 GigaWorld-1（2026.03）

2026 年 3 月底，极佳发布 GigaWorld-1，宣称在世界模型评测中”再获全球第一、超越谷歌、英伟达”（媒体标题口径，未见独立核实）。

---

5. 技术路线总结



极佳是少数把世界模型同时用在”数据生成、强化学习、直接作为策略”三个位置的公司——与 NVIDIA（Cosmos 造数据 + DreamZero 当策略）、1X（评估 + 当策略）的布局高度相似。

---

6. 横向对比与身位

维度	极佳视界	NVIDIA	蚂蚁灵波	智元
世界模型	GigaWorld-0/1、Policy	Cosmos、DreamZero	LingBot-World	Genie Envisioner、GE-2
世界模型造数据	核心卖点	Cosmos、DreamGen	部分	GE-Sim
世界模型 RL	GigaBrain-0.5M*（RAMP）	—	规划中	Genie Evolver
VLA	GigaBrain-0/0.1/0.5	GR00T	LingBot-VLA	GO 系列
本体	Maker H01	无	无	多款

身位：极佳是中国世界模型具身路线的专精型代表，开源影响力不俗（GigaWorld-0）；但多项”全球第一”宣称缺乏独立核实，且在本体与部署规模上弱于智元、宇树等头部公司。

---

7. 未来展望与风险

展望： 1. 世界模型 RL 的规模化：若 RAMP 类方法能在真实任务上稳定带来提升，将显著降低真机数据需求；2. 与华为等产业方的协同：可能获得算力与场景资源； 3. 世界-动作模型的效率突破：GigaWorld-Policy 若真正解决推理效率问题，将推动世界模型从”研究”走向”部署”。

风险： 1. 宣传与验证：多个”全球第一”需要第三方评测佐证； 2. 生成数据的上限：世界模型生成数据的物理正确性（尤其是接触与形变）仍是根本挑战； 3. 竞争：与 NVIDIA、蚂蚁、智元等资源更雄厚的世界模型玩家竞争。

---

8. 延伸阅读与核验来源

- 知乎：GigaBrain-0.5M*：一个基于世界模型强化学习的 VLA；CSDN 版本
- 腾讯新闻：GigaWorld-1 发布
- 搜狐：极佳视界完成 10 亿元 Pre-B 轮融资；投资界：华为押注的机器人公司再融 10 亿；新浪：A2 轮再融 2 亿
- 知乎：“世界模型”新锐：极佳视界
- GigaBrain-0：arXiv 2510.19430
- GigaWorld-0：arXiv 2511.19861；Hugging Face Papers

> 核验说明：融资信息与”华为押注”来自媒体报道；GigaWorld-0”首个验证世界模型数据提升真机 VLA”、GigaBrain-0.1”超越 π0.5 排名第一”、GigaWorld-1”全球第一”、GigaWorld-Policy”全面超越”均为公司宣传口径；GigaBrain-0 的 MoT（PaliGemma2）+ 流匹配 DiT、RGB-D（扩展 SigLIP）、具身思维链组成来自 arXiv 2510.19430 及其摘要，Small 版本的效率数字为二手摘要；GigaWorld-0 的 Video-Dreamer（MoE）、三种迁移、3D 分支（3DGS + 运动规划）、GigaTrain（FP8 + 稀疏注意力）来自 arXiv 2511.19861；RAMP 框架来自 GigaBrain-0.5M* 论文的二手解读。

第 45 章 原力灵机（Dexmal）：做行业的”度量衡”——RoboChallenge、Dexbotic 与具身原生模型 DM0

> 一句话定位：原力灵机由旷视科技联合创始人、前 CTO 唐文斌等人于 2024 年创立，是中国具身领域”基础设施 + 评测 + 模型”三位一体的独特玩家。它与 Hugging Face 联合发起的 RoboChallenge（2025）是全球首个大规模第三方真机评测平台，已有智元、星海图、星动纪元等近 20 家企业参与运营，成为 2026 年中国 VLA 竞争的”主赛场”之一；它开源的 Dexbotic（2025.10 → 2.0，2026.02）是一站式 VLA 开发工具箱；它在 2026 年 2 月发布的具身原生大模型 DM0（2.4B 参数、全面开源，与阶跃星辰合作）在 RoboChallenge 获得单任务与多任务双项第一。唐文斌提出”2026 年是具身原生元年”。

---

0. 速览卡片

维度	内容
成立	2024 年，北京
创始团队	唐文斌（CEO，旷视科技联合创始人、前 CTO）；汪天才（联合创始人）等，团队多来自旷视（Megvii）
核心产品	RoboChallenge（2025，与 Hugging Face 联合发起的真机评测平台）；Dexbotic（2025.10 开源 VLA 工具箱）→ Dexbotic 2.0（2026.02）；DM0（2026.02.10，2.4B 具身原生 VLA，开源）；DFOL（量产工作流）；DM0.5（即将推出，据报道）
合作	Hugging Face（RoboChallenge）；阶跃星辰 StepFun（DM0 论文合作方）；近 20 家企业联合运营 RoboChallenge
学术活动	RoboChallenge ICRA Competition 2026
本章三篇代表作	① RoboChallenge：大规模第三方真机评测平台 ② Dexbotic：模块化 VLA 开发工具箱 ③ DM0：具身原生 VLA
身位	中国具身”评测与工具链”基础设施的核心提供者；模型能力位于开源第一梯队

---

1. 故事的开端：计算机视觉老兵的”度量衡”情结

唐文斌在旷视经历了计算机视觉从学术到产业的完整周期。他深知：ImageNet、COCO 这样的标准化评测，是计算机视觉十年飞速发展的关键推动力——有了统一的度量，才有可比较的进步，才有资本与人才的理性流动。

而 2024–2025 年的具身智能，恰恰缺少这样的度量：各家公司在自己挑选的场景、自己布置的物体、自己剪辑的视频中展示能力，无法相互比较。原力灵机的第一个判断就是：具身智能需要一个”度量衡”。

---

2. 代表作一：RoboChallenge（2025）——大规模第三方真机评测平台

2.1 设计

RoboChallenge 是原力灵机与 Hugging Face 联合发起的全球首个大规模真机评测平台： - 真机而非仿真：模型在平台统一维护的真实机器人上运行评测； - 标准化任务集：例如 Table30（30 个桌面操作任务）等榜单； - 远程提交：研究者/企业提交模型，平台在统一环境中执行并给出成绩； - 联合运营：智元、星海图、星动纪元等近 20 家企业参与。

2.2 影响

RoboChallenge 在 2026 年成为中国 VLA 竞争的"主赛场"之一： - 2026 年 1 月，千寻 Spirit v1.5 在 Table30 以 66.09 分、50.33% 成功率首次超过 π0.5 登顶（第 41 章）； - 2026 年 2 月，原力灵机 DM0 获得单任务与多任务双项第一（本章第 4 节）； - 智元 GO-3 Preview（2026.10）宣称登顶的"RoboColiseum"等榜单也在这一生态中（第 32 章）； - 2026 年举办 RoboChallenge ICRA Competition，进入国际顶会体系。

2.3 争议与挑战

作为平台运营方同时也是参赛方（DM0），RoboChallenge 天然面临"运动员兼裁判"的质疑；此外，2026 年 6 月 RoboArena 的操纵事件（第 41 章）也让所有具身榜单面临更严格的公信力审视。

---

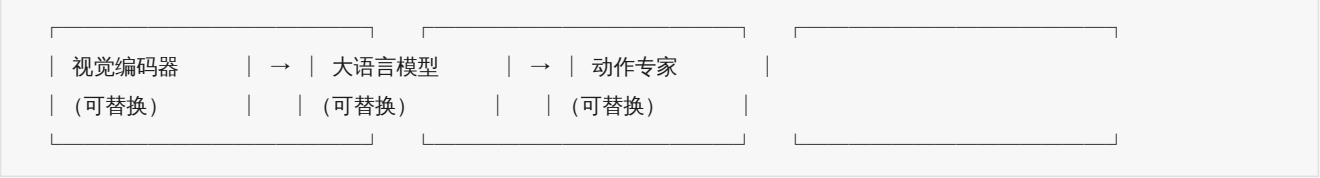
3. 代表作二：Dexbotic（2025.10 → 2.0，2026.02）——模块化 VLA 开发工具箱

3.1 定位

Dexbotic 是原力灵机开源的一站式 VLA 开发框架，目标是让研究者与企业能在统一的代码库中开发、训练、评测与部署 VLA： - 集成多种主流 VLA 方法（如 π0 类流匹配、OpenVLA-OFT 类、CogACT 类等）； - 提供统一的数据格式、训练流程与评测接口（与 RoboChallenge 对接）。

3.2 Dexbotic 2.0（2026.02）：三模块解耦

2.0 版本的核心是把 VLA 拆为三个可独立升级/替换的模块：



开发者可以单独升级视觉编码器（如换成更强的感知模型）、更换 LLM（如换成新一代 Qwen）、或替换动作专家（扩散/流匹配/自回归），而无需重写整个系统——这与阿里 RynnRCP 的"接口标准化"、HF LeRobot 的"统一实现"在理念上一致。

3.3 DFOL：量产工作流

同期发布的 DFOL 被定位为"应用量产工作流"——把 VLA 从"研究原型"推向"可复制的商业部署"的工程流程。

---

4. 代表作三：DM0（2026.02）——具身原生 VLA

> 论文：*DM0: An Embodied-Native Vision-Language-Action Model towards Physical AI*（arXiv 2602.14974，2026-02-16，原力灵机与阶跃星辰团队）；GitHub Dexmal/dexbotic；2026 年 2 月 10 日技术开放日发布，2.4B 参数版本全面开源（含代码、模型，以及 30 个任务的参数与推理代码）。

4.1 “具身原生”是什么意思

多数 VLA 的做法是：先有一个互联网 VLM，再”嫁接”机器人能力——VLM 的表征是为图文理解优化的，具身能力是”后加”的。

“具身原生（Embodied-Native）” 的主张是：从预训练阶段起，就把具身数据（机器人观察、空间定位、驾驶、操作）作为一等公民纳入，让模型的底层表征天然具备物理与空间先验。

4.2 架构

组件	设计
VLM 主干	基于 Qwen3-1.7B 语言模型，配合 Perception Encoder（感知编码器）
动作专家	流匹配动作专家，输出连续机器人动作
总规模	约 24 亿参数
推理模式	① 直接模式：从观察与指令直接预测动作序列；② 思考模式：先生成文本形式的具身推理，再行动

4.3 三阶段训练

阶段	数据	目标
预训练	统一的视觉语言数据 + 驾驶数据 + 具身数据（在机器人观察上做 grounding 与描述问答）	建立物理与空间先验
中期训练（Mid-Training）	加入动作预测；混合通用视觉语言数据（Cambrian、LLaVA-OneVision 1.5 等）与具身推理数据	学会动作，同时不丢失通用能力
后训练	特定任务	适配

4.4 两个关键技术

1. 混合训练策略：在具身数据上，动作专家的梯度不回传到 VLM（保持 VLM 表征的通用性）；在非具身数据上，VLM 保持可训练。——这与 PI 的知识隔离（KI，第 2 章）思路一致；
2. 具身空间脚手架（Embodied Spatial Scaffolding）：构造空间思维链（Spatial CoT）推理数据，让模型学会在行动前进行显式的空间推理（“目标在哪、手在哪、需要往哪个方向移动多少”）。

4.5 结果

- 在 RoboChallenge 上获得单任务与多任务双项第一（公司口径，发布时位列全球榜单首位）；

- 论文报告其通才（Generalist）版本平均成功率约 37.3%，领先 π0.5-Generalist；
- 二手综述提到在长时程操作上约 62.0% 的成功率（需以论文为准）。

注意：37.3% 这一通才成功率与 Spirit v1.5 的 50.33%（Table30）口径可能不同（通才 vs 专项、不同任务集），不宜直接比较。

4.6 意义

DM0 证明了一个小而精（2.4B）的具身原生 VLA，在标准化真机评测上可以与 π0.5 等更大的模型竞争——这对端侧部署与成本控制意义重大。它也展示了中国大模型公司（阶跃星辰）与具身公司合作的一种模式。

---

5. 技术路线总结

```
"度量衡"：RoboChallenge（真机评测平台，与 Hugging Face 联合发起）
                    |
"工具箱"：Dexbotic → Dexbotic 2.0（视觉 / LLM / 动作专家三模块解耦）
                    |
"模型"：DM0（具身原生，2.4B，Qwen3-1.7B + 感知编码器 + 流匹配专家）
                    |
"量产"：DFOL 工作流 → DM0.5（即将推出）
```

---

6. 横向对比与身位

维度	原力灵机	Hugging Face	千寻	星海图
评测平台	RoboChallenge（发起方）	RoboChallenge（联合发起）	参赛（v1.5 第一）	联合运营
工具链	Dexbotic	LeRobot	—	GalaxeaVLA
开源模型	DM0（2.4B）	SmolVLA（0.45B）	Spirit v1.5	G0/G0.5
模型哲学	具身原生 + 空间思维链	小模型 + 社区数据	脏数据 + 统一 VLA	原生动作思维链

身位：原力灵机是中国具身”基础设施与评测”层的核心玩家，其 RoboChallenge 对行业竞争格局有显著影响；DM0 作为小参数开源模型在评测上处于前列。

---

7. 未来展望与风险

展望： 1. 评测标准化：RoboChallenge 若持续扩大参与方并完善治理，可能成为国际公认的具身评测标准之一； 2. DM0.5 与具身原生路线：下一代模型将检验”具身原生预训练”的缩放效应； 3. 工具链生态：Dexbotic 的模块化设计有望吸引更多企业基于其开发。

风险： 1. “运动员兼裁判”：作为评测平台运营方与参赛方，需要建立更透明的治理机制以避免利益冲突质疑； 2. 评测可信度的行业性危机：RoboArena 事件后，所有榜单的公信力都面临考验； 3. 模型规模：小模型路线在更复杂的长时程任务上可能遭遇天花板。

8. 延伸阅读与核验来源

- DM0：arXiv 2602.14974；IT之家：DM0 发布并开源；腾讯新闻：DM0 硬核拆解；腾讯新闻：原力灵机三箭齐发
- Dexbotic / DFOL：知乎：具身原生来了；机器人大讲堂；GitHub Dexmal/dexbotic
- RoboChallenge / ICRA 2026：品玩：原力灵机的 ICRA 2026 时刻
- 百度百科：Dexmal 原力灵机

> 核验说明：DM0 的架构（Qwen3-1.7B + Perception Encoder + 流匹配专家）、两种推理模式、三阶段训练、混合训练策略、具身空间脚手架、通才 37.3% 领先 π0.5-Generalist 来自 arXiv 论文；2.4B 与全面开源、RoboChallenge 双项第一来自官方发布与 IT之家（公司口径）；“62.0%”为二手综述数据；Dexbotic 2.0 的三模块解耦来自媒体报道；RoboChallenge 近 20 家企业参与来自公司口径；DM0.5 为”即将推出”的报道。

第 46 章 灵初智能（PsiBot）：灵巧手优先——从 DexGraspVLA 到人类手部数据驱动的 Psi-R2 与世界模型 Psi-W0

> 一句话定位：灵初智能是中国具身领域"灵巧手操作优先"的代表公司，团队与北京大学人工智能研究院（杨耀东等）渊源深厚。它的代表作 DexGraspVLA（2025.02）以"VLM 规划 + 扩散式灵巧抓取控制 + 领域不变表征"实现了在上千种未见物体-光照-背景组合下约 90% 的零样本灵巧抓取；Psi-R1（2025）提出"动作思维链（CoAT）"推理框架，结合仿真强化学习完成麻将、外卖分拣、商店理货等长程灵巧任务；2026 年 4 月发布的 Psi-R2 与动作条件世界模型 Psi-W0，转向"人类手部数据预训练"，并开源首批 1000 小时人类手部操作全模态数据集——据报道 Psi-R2 登顶艾伦 AI 研究所（AI2）发起的 MolmoSpaces 全球基准。2026 年 7 月据报道推进新一轮融资，投后估值约 14.8 亿美元。

---

0. 速览卡片

维度	内容
成立	2024 年，北京
团队	与北京大学人工智能研究院（杨耀东等）合作紧密；核心团队兼具强化学习、灵巧操作与工程背景
融资	2024 年 11 月早期融资（高瓴创投、蓝驰创投共同领投）；2026 年 7 月据报道推进新一轮，投后估值约 14.8 亿美元（待交割与官方确认）
模型谱系	Psi R0（2024.12）→ Psi R0.5（2025.03）→ DexGraspVLA（2025.02，学术）→ Psi-R1（2025，CoAT）→ Psi-R2 + Psi-W0（2026.04.10）
数据	开源首批 1000 小时人类手部操作全模态数据集（宣称全球最大人类手部数据集）
本章三篇代表作	① DexGraspVLA：通用灵巧抓取的分层 VLA ② Psi-R1：动作思维链 + 强化学习的长程灵巧操作 ③ Psi-R2 + Psi-W0：人类手部数据预训练与世界模型数据飞轮
身位	灵巧手操作方向的中国代表；"人类数据派"的新晋重要成员

---

1. 故事的开端：为什么是"手"？

人形机器人的价值在于"像人一样使用人类的工具与环境"——而这几乎完全取决于手。夹爪能抓起大多数物体，但无法拧瓶盖、无法翻书、无法使用剪刀、无法打麻将。特斯拉把手视为"最难的硬件"（第 6 章），Figure、DeepMind（Gemini Robotics 2 五指手任务成功率 32%–92%）都把灵巧操作作为最大挑战之一。

灵初智能从一开始就把"灵巧手的大脑"作为主攻方向：不是先做通用 VLA 再适配灵巧手，而是从灵巧操作的特殊性出发设计大脑——高自由度、接触丰富、需要精细力控与在手操作。

---

2. 代表作一：DexGraspVLA（2025.02）——通用灵巧抓取的分层 VLA

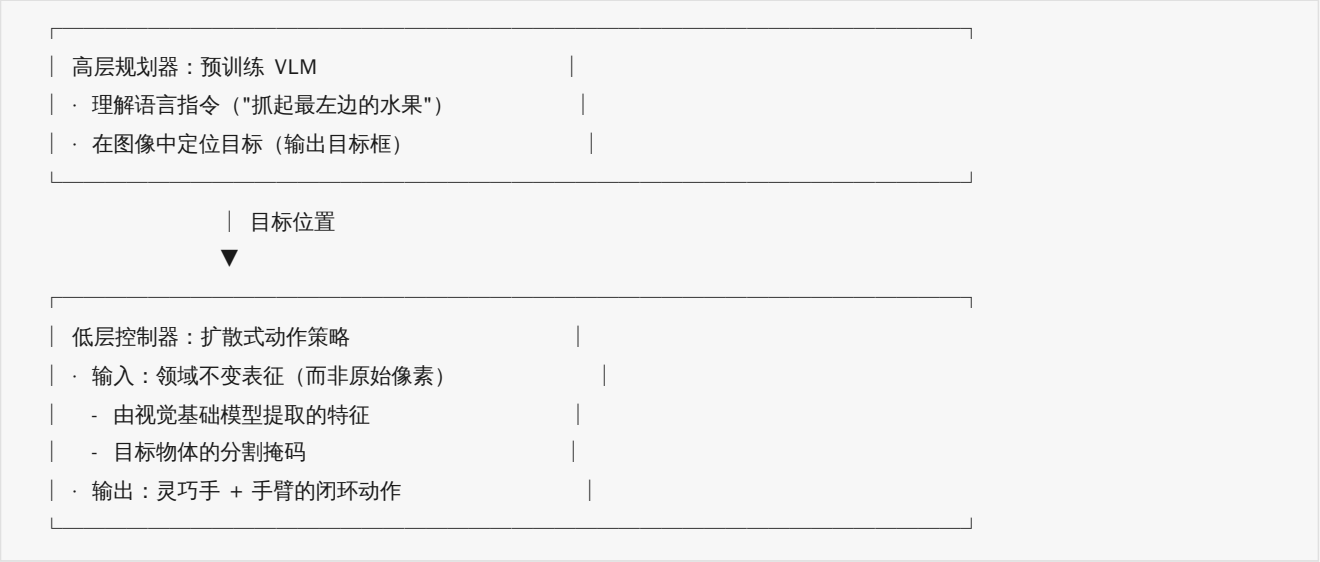
> 论文：*DexGraspVLA: A Vision-Language-Action Framework Towards General Dexterous Grasping*（arXiv 2502.20900，2025.02）——灵初智能与北京大学等。

2.1 问题

灵巧抓取的"通用性"有两个维度： - 物体泛化：能抓起任意形状、材质、大小的物体； - 环境泛化：在不同光照、背景、杂乱程度下都能工作。

端到端训练的灵巧抓取策略往往过拟合到训练时的视觉外观——换个桌布颜色、换盏灯就失败。

2.2 方法：分层 + 领域不变表征



关键洞察——"领域不变表征"：低层控制器不直接看原始图像，而是看视觉基础模型提取的特征 + 目标掩码。这些表征对光照、背景、纹理变化天然不敏感，从而让在有限数据上训练的扩散策略能泛化到全新环境。这一思想与 PointVLA（第 34 章，注入点云）、UniVLA（第 22 章，在 DINOv2 空间做潜在动作）一样，都在回答"VLA 应该在什么表征空间里学习动作"这个问题。

2.3 结果

- 在杂乱场景中、1287 种未见过的物体-光照-背景组合上，零样本灵巧抓取成功率达到 90.8%（未见物体 91.1%、未见背景 90.5%、未见光照 90.9%，单次尝试）；
- 单物体基准成功率约 98.6%；长时程语言指令任务成功率约 89.6%；
- 对语言指令中的复杂目标描述（位置、颜色、类别）有良好理解，支持杂乱场景中的连续多物体抓取；
- 论文作者来自北京大学与灵初智能（Zhong 等），后收录于 AAAI。

---

3. 代表作二：Psi-R1（2025）——动作思维链 + 强化学习的长程灵巧操作

3.1 CoAT：动作思维链

Psi-R1 被描述为”分层端到端 VLA + 强化学习”模型，核心是 CoAT（Chain of Action-Thought，动作-思维链） 推理框架： - 在执行长程任务时，模型交替进行”思考”（规划下一步要做什么）与”动作”（执行精细操作）； - 思考链帮助模型在长任务中保持上下文、处理意外。

（“动作思维链”的思想在 2026 年被智元 GO-2、星海图 G0.5 等更广泛地采用，见第 32、39 章。）

3.2 训练路线：仿真强化学习 + 遥操作

灵初在 Psi-R1 阶段选择在仿真环境中进行强化学习（提升灵巧操作的鲁棒性与精度）并结合遥操作数据。

3.3 演示

Psi-R1 驱动的机器人展示了一系列长程灵巧任务： - 打麻将（摸牌、理牌、出牌——需要精细的在手操作与牌面识别）； - 外卖分拣（识别订单、抓取不同包装的外卖）； - 商店理货（在货架上整理商品）。

这些任务的共同点是：长时程 + 多次精细抓放 + 需要理解场景规则。

---

4. 代表作三：Psi-R2 + Psi-W0（2026.04.10）——人类手部数据与世界模型飞轮

4.1 路线转向：从”仿真 + 遥操作”到”人类数据”

2026 年 4 月 10 日，灵初发布新一代具身大模型 Psi-R2 与 Psi-W0，核心变化是：基于人类数据预训练。量子位以”中国具身模型狂揽全球第一！机器人的人类数据时代来了”为题报道——灵初成为 2026 年中国”人类数据派”（它石、智在无界、小米等）的又一重要成员。

4.2 开源：1000 小时人类手部操作全模态数据集

同时开源首批 1000 小时人类手部操作全模态数据集（宣称全球最大人类手部数据集）： - 全模态：第一视角视频 + 手部精细动作（手指关节级）+ 可能的触觉/力等信号； - 聚焦”手”：与其他人类数据集（侧重全身或整体场景）不同，它专注于手部精细操作——与灵初”灵巧手优先”的定位一致。

4.3 Psi-W0：动作条件世界模型

Psi-W0 是一个动作条件世界模型——给定当前观察与动作，预测未来状态。它的作用是： - 评估策略：在世界模型中测试 Psi-R2 的表现； - 提升策略：生成数据、发现失败、改进策略； - 与 Psi-R2 形成数据飞轮：“策略 → 世界模型评估 → 改进数据 → 更好的策略”。

4.4 MolmoSpaces 基准

据报道，Psi-R2 以 46.4% 的 Oracle 成功率登顶 MolmoSpaces 全球基准——这是由美国艾伦人工智能研究所（AI2）发起的具身基准。由海外第三方机构发起的基准登顶，比自建榜单更具说服力（但仍需注意不同基准的口径差异）。

---

5. 技术路线总结

```
2024.12–2025.03  Psi R0 / R0.5：早期具身模型
        ↓
2025.02          DexGraspVLA：分层 VLA + 领域不变表征，约 90% 零样本灵巧抓取
        ↓
2025             Psi-R1：CoAT 动作思维链 + 仿真 RL + 遥操作，长程灵巧任务
        ↓
2026.04          Psi-R2（人类数据预训练）+ Psi-W0（动作条件世界模型）
                 开源 1000 小时人类手部全模态数据集；MolmoSpaces 46.4% 第一
```

---

6. 横向对比与身位

维度	灵初智能	它石智航	智在无界	星动纪元
核心聚焦	灵巧手操作	线束装配等工业接触任务	人类视频 → 跨本体	视频预测 + 灵巧手
人类数据	1000 小时手部全模态（开源）	百万小时（宣称）	20 万小时人类视频	部分
世界模型	Psi-W0（评估与改进）	AWE（引擎）	Being-H0.7（隐式）	Ctrl-World
第三方基准	MolmoSpaces 第一（报道）	SAIL 奖	6 榜第一（宣称）	WorldArena（报道）

身位：灵初是中国灵巧手大脑方向的代表公司，学术成果（DexGraspVLA）扎实；2026 年转向人类数据与世界模型后，在第三方海外基准上取得亮眼成绩，估值进入独角兽行列。

---

7. 未来展望与风险

展望： 1. 人类手部数据的规模化：从 1000 小时扩展到更大规模，可能建立”手部操作”领域的数据壁垒； 2. 世界模型飞轮：Psi-W0 若能有效降低真机迭代成本，将加速灵巧操作的进步； 3. 场景落地：零售理货、外卖分拣等场景是灵巧手最可能率先商业化的方向。

风险： 1. 灵巧手硬件的可靠性与成本：灵巧手是最易损、最昂贵的部件，规模化部署面临挑战； 2. 人手到机器人手的迁移：形态差异（自由度、尺寸、触觉）仍是核心难题； 3. 估值与融资不确定性：新一轮融资尚待交割与官方确认。

---

8. 延伸阅读与核验来源

- DexGraspVLA：arXiv 2502.20900
- Psi-R1：知乎：灵初智能推出端到端 VLA 模型 Psi R1
- Psi-R2 / Psi-W0：量子位：机器人的人类数据时代来了；中华网：灵初双模型亮相，全球最大人类手部数据集开源；艾邦机器人
- 融资：界面新闻：灵初智能冲刺独角兽，估值 14.8 亿美元；RoboRadar：PsiBot

> 核验说明：DexGraspVLA 的分层架构、领域不变表征、1287 种组合上 90.8% 的零样本成功率及分项成绩来自 arXiv 论文与项目页（早期版本使用”90%+、1200+ 场景”的约数）；Psi-R1 的 CoAT 框架与演示任务来自公司发布与知乎报道（发布时间存在 2025 年 4 月的不同记载）；Psi-R2/Psi-W0 发布日期、1000 小时数据集开源、MolmoSpaces 46.4% 来自量子位等报道；估值 14.8 亿美元为”推进中、待确认”的报道口径。

第 47 章 智在无界（BeingBeyond）：以人为中心的机器人学习——Being-H0 → H0.5 → H0.7

> 一句话定位：智在无界由北京大学计算机学院长聘副教授卢宗青于 2025 年 5 月创立，是”人类视频 → 机器人”路线在中国学术最系统、迭代最快的公司：Being-H0（2025.07）是其首个基于约 1000 小时人类第一视角视频预训练的 VLA；Being-H0.5（2026.01，CoRL 2026）以 3.5 万小时的 UniHand-2.0 语料（含约 1.6 万小时人类第一视角动作与约 1.4 万小时机器人操作数据）、统一动作空间与稀疏专家控制实现跨本体泛化，在 LIBERO 上达到 98.9%；Being-H0.7（2026.04，NeurIPS 2026）把人类视频扩展到 20 万小时，提出”基于潜空间推理的世界模型”（隐式世界模型，不逐帧生成未来图像），宣称横扫 6 大榜单；随后的 Being-H-Flash 完成端侧芯片实时部署。卢宗青团队还提出了人形全身控制框架 FAST。

0. 速览卡片

维度	内容
成立	2025 年 5 月，北京
创始人	卢宗青（北京大学计算机学院长聘副教授，强化学习与具身智能）
模型谱系	Being-H0（2025.07.21）→ Being-H0.5（2026.01.20，旗舰 VLA）→ Being-H0.7（2026.04.14，旗舰 WAM / 世界-动作模型）→ Being-H-Flash（端侧隐式世界模型）；FAST（人形全身控制）
数据	Being-H0：约 1000 小时人类第一视角视频；Being-H0.5：UniHand-2.0 约 3.5 万小时（约 1.6 万小时人类第一视角动作 + 约 1.4 万小时机器人操作）；Being-H0.7：约 20 万小时人类视频
开放程度	高：GitHub BeingBeyond/Being-H；Hugging Face BeingBeyond
学术	Being-H0.5 被 CoRL 2026 接收、Being-H0.7 被 NeurIPS 2026 接收（据官方仓库，未独立核实）
本章三篇代表作	① Being-H0：人类视频 VLA 预训练的起点 ② Being-H0.5：以人为中心的跨本体泛化 ③ Being-H0.7：潜空间推理的隐式世界模型
身位	中国”人类视频派”的学术旗手；迭代速度与开源力度领先

1. 故事的开端：一位强化学习教授的”人类视频”押注

卢宗青长期研究强化学习与多智能体系统。他对具身智能的判断与 Generalist、它石、Figure 等一致，但更强调”可规模化”：

> 遥操作数据永远无法达到互联网规模；仿真数据永远有鸿沟；只有人类视频——尤其是人类第一视角的手部操作视频——可以达到数十万乃至数百万小时的规模。机器人要学会操作，就应该先"看人怎么做"。

关键的技术难题是：人类视频里没有机器人动作。智在无界的核心工作，就是一步步解决"如何把人类的手部运动变成机器人可学习的动作表示"。

---

2. 代表作一：Being-H0（2025.07）——人类视频 VLA 预训练的起点

> 论文：*Being-H0: Vision-Language-Action Pretraining from Large-Scale Human Videos*（arXiv 2507.15597，2025.07；作者来自北京大学、中国人民大学等）；发布：2025 年 7 月 21 日；GitHub BeingBeyond/Being-H。

2.1 物理指令微调（Physical Instruction Tuning）

Being-H0 把 LLM/VLM 领域的"视觉指令微调"扩展到物理操作，形成三阶段训练范式： 1. 在人类视频上预训练：从大规模人类第一视角视频中学习"看到什么、听到什么指令、手该怎么动"； 2. 物理空间对齐：把人类视频中的手部运动与三维物理空间对齐（统一相机、尺度、坐标系等差异）； 3. 面向机器人的后训练适配：用少量机器人数据，把学到的手部运动知识迁移到机器人灵巧手上。

2.2 部件级运动 token 化（Part-Level Motion Tokenization）

关键难题是：如何让自回归语言模型"说出"手的动作？ Being-H0 把连续的手部运动（手腕位姿 + 各手指关节）按部件量化为离散 token，使自回归模型能够预测手部运动，同时保持毫米级精度——这与 PI 的 FAST、RDT2 的 RVQ 一样，都是在回答"动作如何 token 化"（参见技术专题第 2 节）。

2.3 UniHand 数据集

UniHand 是 Being-H0 构建的大规模人手数据集合，包含超过 1.5 亿条指令跟随样本，融合了动作捕捉、VR 录制与纯 RGB 视频三类来源（其中人类第一视角视频约 1000 小时量级）。

2.4 架构

主干采用 InternLM3 或 Qwen2.5 等语言模型，视觉、文本与手部运动 token 在共享注意力中统一建模。二手综述报告，与架构相近但没有经过物理指令微调的 InternVL3 相比，Being-H0 在手部运动生成与下游操作上有明显优势。

2.5 意义

Being-H0 是中国较早的"以人手视频为主要预训练数据的灵巧操作 VLA"之一，与 UCSD 的 HAT（第 20 章）、NVIDIA 的 EgoScale（GR00T N1.7）同期。它确立了智在无界"以人为中心（human-centric）"的研究主线，并为 H0.5 的"统一动作空间"打下了基础。

---

3. 代表作二：Being-H0.5（2026.01）——以人为中心的跨本体泛化

> 论文：*Being-H0.5: Scaling Human-Centric Robot Learning for Cross-Embodiment Generalization*（arXiv 2601.12993，2026-01-20）；项目页 research.beingbeyond.com/being-h05；据官方仓库被 CoRL 2026 接收。

3.1 数据：UniHand-2.0

构成	规模
人类第一视角动作数据	约 1.6 万小时
机器人操作数据	约 1.4 万小时
合计（UniHand-2.0）	约 3.5 万小时

（媒体对人类视频规模有”近 2 万小时”“1 万小时”等不同表述，以论文为准。）

3.2 三大技术支柱

1. 统一动作空间（Unified Action Space）：把人手与多种机器人（不同灵巧手、夹爪、双臂）的动作映射到同一个动作空间——人类数据与机器人数据可以在同一模型中共同训练；
2. 人类运动监督（Human Motion Supervision）：以人类运动作为大规模、低成本的监督信号；
3. 稀疏专家控制（Sparse Expert Control）：使用混合专家（MoE）式的稀疏动作专家——不同专家可以负责不同本体或不同类型的动作，提高跨本体的容量与效率。

3.3 结果

- LIBERO：约 98.9%；
- RoboCasa：约 53.9%；
- 跨本体泛化：同一模型适配多种机器人。

3.4 配套：FAST 人形全身控制框架

智在无界随后发布 FAST——一个面向人形全身控制的框架（注意与 PI 的 FAST 动作分词器同名但完全不同）：- CoM（质心）感知控制：在激进动作下保持平衡；- MoE 策略：把通用运动基元与本体特定动力学分开；- Parseval 引导的残差适应：在不完全重训的情况下快速更新行为，并用 Parseval 与 KL 正则防止快速更新中的策略漂移；- 能力：踢腿、旋转、太极、长时程舞蹈、遥操作、操作任务、人机交互。

在智在无界的技术栈中：H0.5 负责跨本体表示与动作空间，FAST 负责稳定执行与实时人形控制——“表示 → 本体 → 控制 → 适应”。

---

4. 代表作三：Being-H0.7（2026.04）——潜空间推理的隐式世界模型

> 发布：2026 年 4 月 14 日；媒体标题”直面 LeCun 愿景，智在无界发布最强具身世界模型，20 万小时人类视频屠榜 6 大榜单”；据官方仓库被 NeurIPS 2026 接收。

4.1 数据规模：20 万小时人类视频

Being-H0.7 把人类视频数据扩展到约 20 万小时——比 H0.5 的人类数据增长了一个数量级以上，跻身全球公开宣称的大规模人类视频具身预训练之列（对照：Generalist 50 万小时+、它石百万小时宣称、Figure Index）。

4.2 核心范式：基于潜空间推理的世界模型

H0.7 被官方仓库定位为旗舰 WAM（世界-动作模型），其关键特征是"隐式世界模型"： - 不在训练与推理中逐帧生成未来图像（区别于 1XWM、DreamZero 等视频生成式世界模型）； - 而是在潜空间中进行"推理式"的未来预测——预测未来的抽象状态，再据此生成动作。

"直面 LeCun 愿景"的含义：这正是 Yann LeCun / Meta JEPA 路线（第 12 章）的核心主张——不预测像素，在表征空间预测未来。智在无界把这一思想与大规模人类视频、VLA 动作生成结合，形成了"JEPA 式隐式世界模型 + 动作"的具身方案。

4.3 为什么"隐式"重要：效率

逐帧生成视频的世界模型推理极慢（DreamZero 约 7Hz、Fast-WAM 也需约 190ms 一步）。隐式世界模型不生成像素，推理成本可大幅降低——这使得随后的 Being-H-Flash 能够在端侧芯片上实时部署（媒体称为"全球首个端侧芯片实时部署"的隐式世界模型产品）。

4.4 结果

宣称在 6 大榜单上取得领先（媒体口径，具体榜单与数字以论文为准）。

---

5. 技术路线总结

```
2025.07   Being-H0：约 1000 小时人类视频，手部运动 token 化（物理指令微调）
    ↓
2026.01   Being-H0.5：UniHand-2.0（约 3.5 万小时），统一动作空间 + 稀疏专家；LIBERO 98.9%
          + FAST：人形全身控制（CoM 感知 + MoE + 残差适应）
    ↓
2026.04   Being-H0.7：约 20 万小时人类视频，潜空间推理的隐式世界模型（WAM）
    ↓
          Being-H-Flash：端侧芯片实时部署
```

人类视频规模：1000 小时 → 约 1.6 万小时 → 约 20 万小时，一年内增长约 200 倍。

---

6. 横向对比与身位

维度	智在无界	Meta（JEPA）	NVIDIA（DreamZero）	它石智航
世界模型类型	隐式（潜空间推理）	隐式（表征预测）	显式（视频-动作联合生成）	"世界引擎"（细节未公开）
数据	20 万小时人类视频	100 万小时网络视频 + 1.5 万小时机器人	视频模型 + 机器人数据	百万小时人类数据（宣称）

维度	智在无界	Meta（JEPA）	NVIDIA（DreamZero）	它石智航
动作	VLA / WAM 统一	MPC 规划（V-JEPA 2-AC）	联合去噪	—
端侧	Being-H-Flash	—	需 Thor 级算力	—
开源	积极	积极	开源	数据集开源

身位：智在无界是中国”人类视频派”中学术最扎实、开源最积极的公司之一；其”隐式世界模型”路线在国内具有开创性，并与 Meta 的 JEPA 路线形成国际呼应。

---

7. 未来展望与风险

展望： 1. 百万小时级人类视频：按其增长速度，2027 年可能达到百万小时级，届时将检验”人类视频缩放定律”的上限； 2. 隐式世界模型的端侧化：Being-H-Flash 若在量产机器人上可靠运行，将成为端侧世界模型的标杆； 3. 人形全身：H0.x + FAST 的组合，可能形成完整的”人类数据驱动的人形大脑”。

风险： 1. 人类视频的动作标签质量：手部姿态估计的误差会直接传导到动作学习； 2. 榜单口径：“横扫 6 大榜单”等宣称需要细读评测设置； 3. 公司年轻：成立仅一年多，工程化与商业化能力尚待验证。

---

8. 延伸阅读与核验来源

- Being-H0：arXiv 2507.15597；GitHub BeingBeyond/Being-H
- Being-H0.5：arXiv 2601.12993；项目页
- Being-H0.7：腾讯新闻：智在无界发布通用具身世界模型 Being-H0.7；新浪财经；China Research Collective
- Being-H-Flash：第一电动网
- Hugging Face：BeingBeyond

> 核验说明：Being-H0 的三阶段物理指令微调、部件级运动 token 化、UniHand（1.5 亿+ 样本，动捕/VR/RGB 三源）与主干选择来自 arXiv 2507.15597，发布日期与”约 1000 小时人类视频”来自官方仓库与报道；Being-H0.5 的 UniHand-2.0 规模（约 3.5 万小时，1.6 万 + 1.4 万）、三大技术支柱、LIBERO 98.9%/RoboCasa 53.9% 来自论文与二手摘要；FAST 的设计来自公开发布的摘要；Being-H0.7 的 20 万小时与”潜空间推理的隐式世界模型”来自官方发布与媒体；“横扫 6 大榜单”“端侧首个”为公司/媒体口径；CoRL 2026、NeurIPS 2026 接收信息来自官方仓库，未独立核实。

第 48 章 穹彻智能（Noematrix）：从 AnyGrasp、RH20T 到”零遥操作”的世界动作模型 Noe-0

> 一句话定位：穹彻智能由上海交通大学教授卢策吾创立，是中国具身智能”以力为中心（force-centric）”与”无本体数据”路线的代表。其学术根基包括通用抓取模型 AnyGrasp（2022–2023）与包含力/力矩信号的大规模接触丰富数据集 RH20T（2023）；产品层面推出”穹彻具身大脑（Noematrix Brain）“系列（2.0 于 2025 年 7 月发布）；2026 年，它以”World Action Model with 0 Teleop Data”为主题，在 WAIC 2026 上展示新一代预训练世界动作模型 Noe-0——宣称基于在全国 47 个城市采集的十万小时级家庭场景数据预训练，预训练与后训练均未使用遥操作数据，数据由无本体采集系统 RoboPocket 采集、DM3 平台治理。

0. 速览卡片

维度	内容
成立	2023 年，上海
创始人	卢策吾（上海交通大学教授，计算机视觉与具身智能；HAKE、AnyGrasp、RH20T 等工作）
融资	多轮融资；A++ 轮获上海交大、创智学院、无锡数据集团等联合注资；2026 年 6 月完成新一轮数亿元融资，计划发布新一代具身世界模型
产品	穹彻具身大脑 Noematrix Brain（1.0 → 2.0，2025.07 发布）；数据：RoboPocket（无本体数据采集系统）、DM3（数据管理平台）；模型：Noe-0（具身世界模型技术预览，2026）
应用	酒店洗衣、家庭整理等场景（规划拓展）
本章三篇代表作	① AnyGrasp 与 RH20T：通用抓取与以力为中心的数据 ② 穹彻具身大脑（Noematrix Brain 2.0）③ Noe-0：零遥操作数据的世界动作模型
身位	学术根基深厚的上海具身代表；“无本体数据 + 世界模型”路线的中国代表之一

1. 故事的开端：从”理解人的动作”到”理解力”

卢策吾在上海交大长期研究人类行为理解（HAKE：人体活动知识引擎）与机器人抓取。他的一个核心观点是：机器人操作的本质是”力”的交互——视觉告诉你”东西在哪”，但只有力告诉你”抓稳了没有、插到底了没有、拧紧了没有”。这一”以力为中心（force-centric）”的观点贯穿了穹彻的技术路线。

2. 代表作一：AnyGrasp 与 RH20T——通用抓取与接触丰富的多模态数据

2.1 AnyGrasp（2022–2023）：通用抓取

> 论文：Hao-Shu Fang, Chenxi Wang, Hongjie Fang, …, Cewu Lu，*AnyGrasp: Robust and Efficient Grasp Perception in Spatial and Temporal Domains*（IEEE T-RO 2023）；前作 GraspNet-1Billion（CVPR 2020）。

- 在大规模抓取数据（GraspNet-1Billion 等）上训练的通用 6-DoF 抓取感知模型；
- 对任意物体、杂乱场景、动态物体（时间域上的抓取跟踪）都能给出稳健的抓取位姿；
- 在大量真实杂乱场景中实现了接近人类水平的抓取成功率，并被学术界与产业界广泛使用（许多 VLA 系统把 AnyGrasp 作为"抓取技能"模块调用）。

2.2 RH20T（2023）：以力为中心的大规模数据集

> 论文：Hao-Shu Fang 等，*RH20T: A Comprehensive Robotic Dataset for Learning Diverse Skills in One-Shot*（2023）

- 规模：超过 11 万条接触丰富的机器人操作序列，覆盖大量技能与任务；
- 多模态：视觉（多视角 RGB-D）+ 力/力矩传感 + 音频 + 本体状态；
- 配对的人类示范：每条机器人序列配有对应的人类示范视频——便于研究"看人一次就学会（one-shot）"；
- 被纳入 Open X-Embodiment 等大规模数据集合。

意义：RH20T 是 2023 年少有的系统包含力觉信号的大规模机器人数据集，体现了"以力为中心"的数据观，也为后来它石 WIYH（触觉）、灵初（手部全模态）等工作提供了先例。

---

3. 代表作二：穹彻具身大脑（Noematrix Brain）

> 发布：Noematrix Brain 1.0（2024）；Noematrix Brain 2.0（2025 年 7 月 WAIC 2025 正式发布）。

3.1 定位

穹彻具身大脑是穹彻面向商业客户的具身智能大脑产品，其设计延续"以力为中心"的理念： - 视觉 + 力的多模态感知：在接触丰富任务中融合力反馈进行闭环控制； - 通用操作能力：基于大规模数据训练的抓取、放置、柔性物体操作等通用技能； - "软硬兼修"：穹彻在 WAIC 2025 上展示了从技术到应用的完整链条，包括大脑模型与配套的硬件/数据系统。

（Noematrix Brain 2.0 的详细技术报告公开有限，本章不做架构推测。）

3.2 应用方向

穹彻公开表示将拓展酒店洗衣、家庭整理等场景——这类任务充满可形变物体（衣物、床单）与接触交互，正是"以力为中心"能力的用武之地。

---

4. 代表作三：Noe-0（2026）——零遥操作数据的世界动作模型

> 来源：穹彻官网 WAIC 2026 新闻稿《让模型理解世界，让智能进入现实》；官网首页 Noe-0 技术预览；2026 年 6 月融资新闻（计划发布新一代世界模型）。官方称技术报告计划于 2026 年 7–8 月发布。

4.1 主题："World Action Model with 0 Teleop Data"

穹彻在 WAIC 2026 上以"零遥操作数据的世界动作模型"为主题，展示新一代预训练模型。

4.2 架构（官方描述）

新一代模型采用世界模型架构，由三部分组成： 1. 通用具身世界模型基座：学习物理世界如何变化； 2. 专用动作预测模型：在世界模型之上预测动作； 3. 后训练套件：适配具体任务。

4.3 数据：十万小时级、47 城、零遥操作

维度	内容
规模	十万小时级家庭场景数据
地域	2026 年在全国 47 个城市采集
遥操作	预训练与后训练阶段均未使用遥操作数据
采集系统	RoboPocket：无本体的大规模真实世界数据采集系统（类似 UMI/手套等"人带设备采集"的范式）
数据治理	DM3：负责数据治理与训练数据交付

官网首页把 Noe-0 描述为"全链路无本体数据构建的具身世界模型"，并提供技术预览。

4.4 意义

Noe-0 是 2026 年"无本体数据 + 世界模型"路线最激进的宣称之一：连后训练都不用遥操作。如果成立，意味着： - 数据采集可以像"众包"一样在全国规模展开（47 城）； - 机器人公司可以摆脱昂贵的遥操作团队； - 世界模型成为把"人类无本体数据"转化为"机器人能力"的关键桥梁。

这与小米（10 万小时 UMI 预训练，但后训练用 1 万小时机器人数据）、Generalist（预训练无机器人数据，后训练约 1 小时机器人数据适配）、Sunday（零机器人数据）形成了一个有趣的光谱——"零遥操作"到底能走多远，是 2026–2027 年最值得关注的问题之一。

---

5. 技术路线总结

```
学术根基：GraspNet-1Billion → AnyGrasp（通用抓取）；RH20T（力觉 + 人类配对示范）
                ｜ "以力为中心"
                ▼
产品：穹彻具身大脑 Noematrix Brain 1.0 → 2.0（2025.07）
                ｜
                ▼
数据：RoboPocket（无本体采集，47 城，十万小时级家庭数据）+ DM3（数据治理）
                ｜
```

▼

模型：Noe- 0 —— 零遥操作数据的世界动作模型（世界模型基座 + 动作预测 + 后训练套件）

---

6. 横向对比与身位

“零/少遥操作”路线	公司	数据采集	机器人数据用量
Noe-0	穹彻	RoboPocket，47 城十万小时级家庭数据	预训练与后训练均为零遥操作（宣称）
ACT-1	Sunday	技能采集手套，500+ 家庭	零机器人数据（宣称）
GEN-1	Generalist	人类交互设备，50 万小时+	预训练零机器人数据，适配约 1 小时
Xiaomi-Robotics-1	小米	UMI，10 万小时	后训练约 1 万小时跨本体
RDT2	清华	增强 UMI，1 万小时+	零样本跨本体
AWE	它石	以人为中心 + 触觉，百万小时（宣称）	不遥操（宣称）

身位：穹彻学术根基深厚（AnyGrasp、RH20T 具有国际影响力），2026 年以”零遥操作世界动作模型”跻身前沿叙事；但 Noe-0 仍处于技术预览阶段，技术报告与独立评测尚待公布。

---

7. 未来展望与风险

展望： 1. Noe-0 技术报告：计划中的技术报告将揭示”零遥操作”的具体实现与评测结果； 2. 全国规模数据网络：47 城的数据采集网络若持续扩张，可能形成独特的数据资产； 3. 力觉优势：在可形变物体与接触丰富任务上，“以力为中心”的积累可能转化为差异化能力。

风险： 1. “零遥操作”的可行性：无本体数据与机器人本体之间的鸿沟，可能在高精度任务上暴露； 2. 透明度：Noe-0 尚为技术预览，关键指标未公开； 3. 竞争：同一路线上有小米、Generalist、它石等资源更雄厚的玩家。

---

8. 延伸阅读与核验来源

- AnyGrasp：IEEE T-RO 2023（arXiv 2212.08333）；GraspNet-1Billion（CVPR 2020）
- RH20T：arXiv 2307.00595
- 穹彻官网：WAIC 2026 新闻；WAIC 2025 新闻；官网首页（Noe-0）；A++ 轮融资
- 澎湃新闻：穹彻完成新一轮数亿元融资，将发布新一代世界模型；21 财经
- RoboRadar：穹彻智能档案

> 核验说明：AnyGrasp 与 RH20T 的描述来自原论文（RH20T”11 万+ 序列”等数字以论文为准）；Noematrix Brain 2.0 于 2025 年 7 月发布来自官网新闻稿（第三方网站称 2026 年 4 月，与官方不一致，以官方为准）；Noe-0 的三部分架构、47 城十万小时级家庭数据、零遥操作、RoboPocket/DM3、

> 技术报告计划来自穹彻官网（公司口径，技术报告截至本报告撰写时是否已发布未能确认）；融资信息来自媒体报道。

第 49 章 地平线（Horizon Robotics）与地瓜机器人：智驾芯片巨头的”一个大脑，多种形态”——H-RDT、HoloMotion 与 HoloBrain

> 一句话定位：地平线是中国最大的智能驾驶芯片与算法公司之一，其分拆的地瓜机器人（D-Robotics）是中国机器人开发者平台（RDK 系列）的主要提供者（开发者生态超过 10 万人；2026 年 4 月完成 1.5 亿美元 B2 轮）。2025–2026 年，地平线把智驾的”端到端 + 端侧部署”能力迁移到具身，形成了一套开源的大小脑组合：H-RDT（2025.07，AAAI 2026，用 EgoDex 人类第一视角数据预训练的 2B 双臂扩散 Transformer）、HoloMotion（2025.11 起，人形全身运动基础模型，以视频重建动作为多样性主来源）、HoloBrain-0（2026.02，显式融入”本体先验”——多视角相机参数与 URDF 运动学——的 VLA，0.2B 小版本可媲美大得多的基线）以及全栈 VLA 基础设施 RoboOrchard。地平线的独特优势是”芯片 + 模型 + 开发者生态”的端侧闭环。

0. 速览卡片

维度	内容
公司	地平线（Horizon Robotics，港交所上市）；地瓜机器人（D-Robotics，地平线生态的机器人开发平台公司）
创始人	余凯（地平线创始人兼 CEO，前百度深度学习研究院负责人）
硬件平台	地瓜机器人 RDK 系列（如 RDK S100、RDK S600），原生兼容 HoloMotion 与 HoloBrain
生态与融资	地瓜开发者生态超 10 万（同比 +100%）；2026.04.08 地瓜完成 1.5 亿美元 B2 轮，B 系列累计 2.7 亿美元
模型谱系	H-RDT（2025.07，AAAI 2026）、HoloMotion（v1.0 2025.11 / v1.1 2026.01 / HoloMotion-1 技术报告 2026.05）、HoloBrain-0（2026.02.12 技术报告，全面开源）、RoboOrchard（全栈 VLA 基础设施）
本章三篇代表作	① H-RDT：人类操作增强的双臂扩散策略 ② HoloMotion：人形全身运动基础模型 ③ HoloBrain-0：融入本体先验的 VLA 与”一个大脑，多种形态”
身位	中国具身”端侧芯片 + 开源模型 + 开发者生态”的独特玩家

1. 故事的开端：智驾芯片公司的”第二曲线”

地平线的核心业务是智能驾驶的芯片与算法（征程系列芯片），其核心能力是：在有限的端侧算力上运行端到端感知-决策模型。当人形机器人兴起时，余凯的判断是：机器人与汽车一样，是”端侧 AI”的载体，而端侧 AI 的瓶颈是”算力-功耗-模型效率”三角——这正是地平线的强项。

地平线的具身战略是”一个大脑，多种形态”：同一套智能内核（模型 + 芯片 + 工具链）部署到人形、机械臂、移动机器人等不同形态上；并通过地瓜机器人的 RDK 平台，把这套能力开放给海量开发者。

2. 代表作一：H-RDT（2025.07，AAAI 2026）——人类操作增强的双臂扩散策略

> 论文：*H-RDT: Human Manipulation Enhanced Bimanual Robotic Manipulation*（arXiv 2507.23523，AAAI 2026）——地平线等。

2.1 思路：用人类手部数据预训练双臂策略

H-RDT 在 RDT（第 21 章，清华 RDT-1B）的基础上，引入人类第一视角操作数据作为预训练来源： - 人类数据：来自 EgoDex（苹果发布的大规模第一视角灵巧操作数据集）——约 829 小时、33.8 万条片段，带有 3D 手部姿态标注； - 两阶段：先在人类数据上预训练（学习"手如何操作物体"的通用模式），再在机器人数据上微调（适配具体双臂本体）。

2.2 架构

- 20 亿参数的扩散 Transformer；
- 流匹配建模复杂的动作分布。

2.3 结果

- 相比从零训练，仿真中提升约 13.9%、真实世界中提升约 40.5%；
- 优于 π0 与 RDT 基线；
- 在真实的叠毛巾任务中，据二手摘要报告完整成功率约 52%（RDT 基线约 40%，从零训练约 0%）。

2.4 意义

H-RDT 是"人类第一视角数据预训练 → 双臂机器人"的又一个有说服力的学术证据（与 UCSD HAT、智在无界 Being-H、NVIDIA EgoScale 同类），并显示了苹果 EgoDex 这类公开人类数据集对具身研究的价值。

---

3. 代表作二：HoloMotion（2025.11 起）——人形全身运动基础模型

> 开源项目：GitHub HorizonRobotics/HoloMotion（v1.0 2025.11，v1.1 2026.01）；技术报告 *HoloMotion-1*（arXiv 2605.15336，2026.05）。

3.1 定位

HoloMotion 是地平线开源的人形全身控制基础模型——即人形的"小脑"：给定目标动作（来自动捕、视频或上层大脑），驱动人形全身稳定地追踪执行。

3.2 关键设计

- 以视频重建动作为多样性的主要来源：不同于主要依赖动捕数据的 SONIC（NVIDIA）、Figure S0，HoloMotion 把从视频中重建的人体动作作为动作多样性的主要来源，再辅以精选的动捕数据与内部动作数据——视频的规模与多样性远超动捕；
- 基于 Transformer 的动作追踪架构；

- 规模据目录信息约 4 亿参数，Apache-2.0 许可（此规模信息来自第三方目录，需谨慎）；
- 有媒体报道其实现了约 300 FPS 级别的高频控制（媒体标题口径）。

3.3 意义

HoloMotion 与 NVIDIA SONIC、CMU BFM-Zero、Amazon FAR ResMimic、宇树/智在无界 FAST 等一起，构成 2025–2026 年"开源人形小脑"的竞争格局。其"视频重建动作"路线与 Berkeley VideoMimic（第 18 章）思想相通——互联网视频是人形动作的最大宝库。

---

4. 代表作三：HoloBrain-0（2026.02）——融入本体先验的 VLA

> 技术报告：*HoloBrain-0 Technical Report*（arXiv 2602.12062，2026-02-12，32 页）——地平线；全面开源（预训练 VLA 基座、后训练检查点、RoboOrchard 基础设施）。

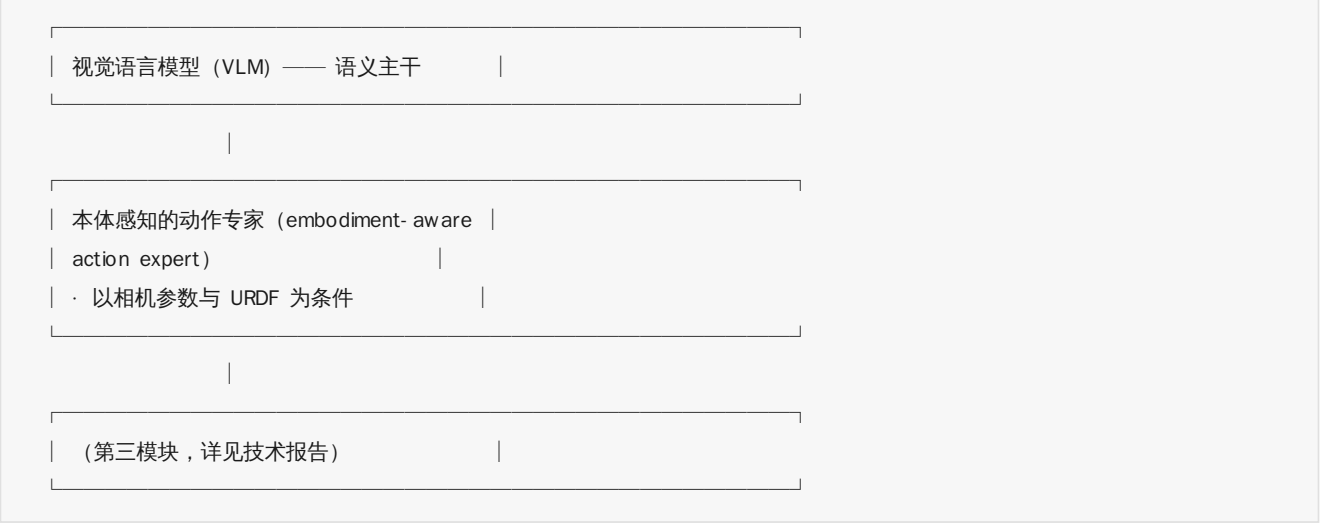
4.1 核心创新：显式引入"本体先验"

多数 VLA 让模型从数据中隐式学习机器人的身体结构（相机装在哪、关节如何连接）。HoloBrain-0 的主张是：这些信息是已知的，为什么不直接告诉模型？

HoloBrain-0 显式输入两类本体先验（embodiment priors）： 1. 多视角相机参数（内参、外参）——让模型精确知道每个相机"在哪里、朝哪里看"，从而做出准确的 3D 空间推理； 2. URDF 运动学描述——机器人的关节结构与运动学链，让模型理解"这个身体能怎么动"。

效果：更好的 3D 空间推理，以及对不同机器人类型的支持——同一模型可以在不同本体之间迁移（"一个大脑，多种形态"的技术实现）。

4.2 架构：三个核心模块



4.3 训练："预训练 + 后训练"与测试驱动的数据采集

- 预训练-后训练范式；

- 后训练阶段提出一种迭代的、测试驱动的数据采集方法——针对长时程双臂任务，先测试找到失败模式，再有针对性地采集数据（类似 TRI LBM 研究中"评估决定下一轮采集"的闭环，第 15 章）。

4.4 结果

- 在 RoboTwin 2.0、LIBERO、GenieSim 等仿真基准上达到最优；
- 0.2B（2 亿参数）小版本可媲美大得多的基线——支持低延迟端侧部署（这正是地平线的核心诉求）；
- 真机演示：叠衣服、可形变纸箱折叠、"万物抓取（Grasp Anything）"。

4.5 RoboOrchard：全栈 VLA 基础设施

RoboOrchard 被定位为覆盖数据整理、模型训练与部署的全栈 VLA 基础设施，与 HoloBrain 一同开源。地瓜机器人的 RDK S600 原生兼容 HoloMotion 与 HoloBrain。

---

5. 技术路线总结



---

6. 横向对比与身位

维度	地平线 / 地瓜	NVIDIA	高通/其他芯片厂商
端侧芯片	RDK S100/S600（征程技术）	Jetson Thor	各类 SoC
开源大脑	HoloBrain-0	GR00T	—
开源小脑	HoloMotion	SONIC	—
开发者生态	10 万+（地瓜）	全球最大	—
定位	中国的"NVIDIA 式"具身平台	全球平台	—

身位：地平线/地瓜是中国最接近"NVIDIA 式全栈平台"的玩家——芯片 + 开源模型 + 工具链 + 开发者生态。在高端 GPU 出口管制的背景下，其国产端侧平台对中国具身产业具有战略意义。

---

7. 未来展望与风险

展望： 1. 国产端侧平台：随着中国人形出货量快速增长（2026 上半年近 2 万台），RDK 系列可能成为国产人形的主流端侧计算平台之一； 2. 小模型端侧化：HoloBrain-0 的 0.2B 版本证明了"小而强"的可能，符合端侧部署的现实约束； 3. 大小脑统一：HoloBrain + HoloMotion 的组合有望形成完整的开源人形大脑方案。

风险： 1. 与 NVIDIA 的生态竞争：在全球范围内，NVIDIA 的软硬件生态仍占绝对优势； 2. 模型前沿性：在通用能力上，地平线模型与 π、Gemini 等前沿模型仍有差距； 3. 评测透明度：HoloMotion 尚无公共基准成绩。

---

8. 延伸阅读与核验来源

- H-RDT：arXiv 2507.23523；AAAI 2026
- HoloMotion：HoloMotion-1 技术报告 arXiv 2605.15336；GitHub HorizonRobotics/HoloMotion；Interesting Engineering
- HoloBrain-0：arXiv 2602.12062；arXiv HTML
- 地瓜机器人融资：盖世汽车：地瓜机器人完成 1.5 亿美元融资

> 核验说明：H-RDT 的 2B 参数、流匹配、EgoDex（829 小时、33.8 万片段）、+13.9%/+40.5%、AAAI 2026 来自论文，叠毛巾 52%/40%/0% 来自二手摘要；HoloMotion 的版本时间与"视频重建动作为主"来自 GitHub 与技术报告，0.4B 规模与 300 FPS 来自第三方/媒体；HoloBrain-0 的本体先验（相机参数 + URDF）、三模块、测试驱动数据采集、0.2B 版本与仿真 SOTA 来自技术报告；地瓜融资与开发者规模来自盖世汽车报道。

第 50 章 星尘智能（Astribot）：为 AI 而生的绳驱身体，与 Lumo 基座 + DuoCore 快慢双系统

> 一句话定位：星尘智能由前腾讯 Robotics X 实验室的来杰创立，是中国具身领域”软硬一体、为学习而设计身体”的代表：其旗舰 Astribot S1（2024.08 发布）采用绳驱（cable-driven）手臂，末端速度可达每秒 10 米级、重复定位精度约 ±0.1 毫米，并以泡茶、做饭、弹琴、练咏春拳等”类人速度与柔顺”的演示出圈；2025 年 7 月发布的技术报告 Astribot Suite（*Towards Human-level Intelligence via Human-like Whole-Body Manipulation*）系统阐述了”机器人平台 + 全身遥操作接口 + 全身视觉运动策略 DuoCore-WB”三位一体的方法；2026 年，其 AI 路线被概括为”基座模型 Lumo + 快慢双系统框架 DuoCore”，并构建”AI 模型—具身 OS—绳驱本体”的全栈架构。2026 年星尘智能连续融资：6 月 B 轮系列超 10 亿元（估值破百亿），10 月 13 日再融 10 亿元（深投控旗下投控东海领投），估值约 150 亿元。

0. 速览卡片

维度	内容
成立	2022 年底，深圳
创始人	来杰（CEO，前腾讯 Robotics X 实验室核心成员；部分来源写作”赖杰”）
产品	Astribot S1（轮式双臂移动操作机器人，绳驱手臂，2024.08 发布）；T1（2026 年 6 月开始发货，入门价约 9 万元）
订单与交付	公司称 S 系列自 2025 年 9 月起获得千台级订单，2025 年底开启千台级交付（具体出货量与营收未披露）
融资	2026.06.03：三个月内连续完成 3 轮、B 轮系列合计超 10 亿元，估值突破百亿元；2026.10.13：再融 10 亿元，估值约 150 亿元（深投控旗下投控东海领投，俞敏洪旗下公司等参与）
AI 路线	Lumo（基座模型）+ DuoCore（快慢双系统框架）；全栈”AI 模型—具身 OS—绳驱本体”
学术	*Towards Human-level Intelligence via Human-like Whole-Body Manipulation*（Astribot Suite，arXiv 2507.17141，2025.07）
本章三篇代表作	① Astribot S1：为学习而设计的绳驱身体 ② Astribot Suite 与 DuoCore-WB：全身操作的平台-遥操作-策略三位一体 ③ Lumo + DuoCore：基座模型与快慢双系统（2026）
身位	中国”软硬一体”具身公司中的估值第一梯队；身体设计理念独特

1. 故事的开端：从腾讯 Robotics X 走出的”身体主义者”

来杰在腾讯 Robotics X 实验室（第 28 章）期间参与了多个机器人项目，他的核心判断是：

> “AI 大脑”的上限受制于”身体”。如果身体太慢、太僵、不安全，大脑再聪明也只能做慢吞吞的演示。要让机器人像人一样灵巧，首先要有一个像人一样快、柔顺、安全的身体——而且这个身体要为”学习”而设计。

这一”身体主义”判断，让星尘智能选择了一条少见的硬件路线：绳驱。

---

2. 代表作一：Astribot S1（2024.08）——为学习而设计的绳驱身体

2.1 为什么是绳驱

传统机械臂的电机与减速器直接安装在关节处，导致手臂惯量大、速度受限、碰撞时危险。绳驱（腱绳驱动）把电机放在躯干或基座，通过绳索传动到关节——这与人类”肌肉在前臂、通过肌腱驱动手指”的结构类似（特斯拉 Optimus Gen 3 的手也采用了前臂执行器 + 腱绳驱动，第 6 章）：- 手臂轻、惯量小 → 可以非常快（S1 末端速度可达每秒 10 米级）；- 天然柔顺 → 与人和环境接触时更安全；- 精度 → 通过精密的绳索张力控制实现约 ±0.1 毫米的重复定位精度。

2.2 S1 的展示

2024 年 8 月发布时，S1 展示了泡茶、做饭、叠衣服、弹琴、练咏春拳、颠锅、快速抽桌布不倒杯子等动作——这些演示的共同点是”类人的速度与柔顺”，大量采用 VR 遥操作完成。

2.3 “为学习而设计”的含义

S1 的设计考虑了数据采集的需求：- 类人的工作空间与运动学：让人类遥操作员可以”自然地”控制机器人，采集的数据更接近人类动作；- 高速与柔顺：让机器人能完整复现人类示范中的快速动作，而不是被硬件限制”降速”——这意味着学习到的策略也能以人类速度执行。

---

3. 代表作二：Astribot Suite 与 DuoCore-WB（2025.07）——全身操作的三位一体

> 技术报告：Astribot Team（Guang Gao, Jianan Wang 等），*Towards Human-level Intelligence via Human-like Whole-Body Manipulation*（arXiv 2507.17141，2025-07-23）。

3.1 三位一体

Astribot Suite 是一个面向全身操作的机器人学习套件，由三部分组成：

组件	内容
机器人平台	绳驱、类人的全身操作平台（双臂 + 躯干 + 移动底盘）
遥操作接口	直观、低延迟的全身遥操作系统——让操作员用全身动作控制机器人的双臂、躯干与底盘
视觉运动策略	DuoCore-WB（Whole-Body）：以 RGB 观察为输入的全身模仿学习策略

3.2 DuoCore-WB

- 以 RGB 观察为输入的模仿学习策略；
- 二手摘要描述其为基于扩散的 Transformer 模型，在遥操作示范上训练，在末端执行器空间中输出动作（以论文为准）；
- 覆盖全身：双臂、躯干与底盘协同。

3.3 结果

在 6 个真实世界全身任务上（每个任务一个策略），DuoCore-WB 的平均成功率约 80%、最高 100%。

3.4 作者自述的局限

作者坦承：系统在学习需要更高敏捷性、灵巧性或长期记忆的更高级任务上仍存在局限——这正是 2026 年 Lumo/DuoCore 要解决的问题。

3.5 意义

Astribot Suite 的价值在于它把"硬件、遥操作、策略"作为一个整体来设计与评估——这与 Figure（Figure 03 为 Helix 重新设计）、UMI（数据接口与策略接口对齐）、Sunday（手套与机器人手共同设计）的理念一致：在具身智能中，身体、数据接口与大脑必须协同设计。

---

4. 代表作三：Lumo + DuoCore（2026）——基座模型与快慢双系统

> 来源：2026 年融资报道与公司介绍（"公司与 Figure 不约而同采取了基座模型（Lumo）与快慢系统模型框架（DuoCore）的路径"）。

4.1 架构（基于公开表述的概括）

- Lumo（基座模型）：星尘智能的具身基座模型，负责感知、理解与通用操作能力的预训练；
- DuoCore（快慢双系统框架）：在"DuoCore-WB 全身策略"的基础上演进为快慢双系统——慢系统负责理解与规划，快系统负责高频全身动作执行（与 Figure Helix 的 S2/S1、GR00T、G0 等同属双系统范式）；
- 具身 OS：位于模型与绳驱本体之间的操作系统层。

（星尘智能尚未公开 Lumo 与 DuoCore 的详细技术报告，本章不做进一步推测。）

4.2 全栈："AI 模型—具身 OS—绳驱本体"

星尘智能把自己的全栈架构概括为"AI 模型—具身 OS—绳驱本体三位一体"。融资资金将重点用于AI 基座模型迭代、真实场景数据积累与研发人才扩充。

4.3 产品化：T1

2026 年发布的 T1 被认为可以快速商业落地，于 2026 年 6 月开始发货，入门价约 9 万元——显著降低了绳驱机器人的门槛，有利于扩大部署规模与数据回流。

---

5. 技术路线总结

```
2024.08   Astribot S1：绳驱身体（快、柔顺、精准、为学习而设计）
      ↓
2025.07   Astribot Suite：平台 + 全身遥操作 + DuoCore-WB（6 任务平均 80%）
      ↓
2025.09–  S 系列千台级订单；2025 年底开启千台级交付
      ↓
2026      Lumo 基座 + DuoCore 快慢双系统 + 具身 OS；T1 量产发货（约 9 万元）
          连续融资，估值约 150 亿元（2026.10）
```

---

6. 横向对比与身位

维度	星尘智能	Figure	特斯拉	智元
身体特色	绳驱手臂（极快、柔顺）	自研电机，为 Helix 设计	22 自由度腱绳手	多形态产品矩阵
大脑	Lumo + DuoCore（快慢双系统）	Helix S0/S1/S2	端到端（FSD 体系）	GO / GE / WRAM
软硬协同	核心理念	核心理念	核心理念	较强
估值	约 150 亿元（2026.10）	390 亿美元（2025.09）	上市公司	未披露（控股上市公司）

身位：星尘智能是中国软硬一体路线中身体设计最有特色的公司之一；在大脑层面采用与 Figure 类似的”基座 + 快慢双系统”主流架构，技术细节公开有限；资本层面 2026 年估值快速上升至约 150 亿元。

---

7. 未来展望与风险

展望： 1. 绳驱 + 学习：高速柔顺的身体可能让学习到的策略以”人类速度”执行，提升商业价值（吞吐量）； 2. T1 规模化：低价产品带来的规模部署与数据回流，是大脑迭代的关键燃料； 3. 全栈闭环：AI 模型、具身 OS 与本体的协同设计有望形成差异化。

风险： 1. 绳驱的可靠性与维护：绳索的磨损、张力漂移、寿命是绳驱方案长期运行的挑战； 2. 大脑透明度：Lumo/DuoCore 缺乏公开技术报告与评测； 3. 竞争：在轮式双臂市场与智元、银河、星海图、智平方等直接竞争。

---

8. 延伸阅读与核验来源

- Astribot Suite：arXiv 2507.17141；HTML 版本
- Astribot S1：IT之家：Astribot S1 发布
- 融资：EqualOcean：星尘智能融资 10 亿元，估值约 150 亿元；同花顺：星尘智能完成 B 轮超 10 亿元融资；新浪科技；财新：中国机器人融资热潮

> 核验说明：Astribot Suite 的三位一体、DuoCore-WB 6 任务平均 80%/最高 100% 与局限来自 arXiv 论文（DuoCore-WB 为扩散 Transformer、末端空间动作为二手摘要）；S1 的绳驱参数（10 米/秒级、±0.1 毫米）来自 EqualOcean 等报道；“Lumo + DuoCore”路线来自融资报道中的公司介绍，未见技术报告；千台级订单与交付为公司口径；T1 发货时间与价格、2026 年融资与估值来自 EqualOcean、同花顺、新浪等报道；创始人姓名存在”来杰/赖杰”两种写法。

第三部分（上）横向对比与身位矩阵

> 本章把 50 家放在同一张”地图”上比较。所有评级均为本报告基于公开信息的综合判断（E 级：分析与推断），不构成投资建议；评级标准见每张表的说明。

一、50 家一表速览

评级说明（★1–5）：- 大脑前沿性：模型/方法在全球技术前沿的位置（论文影响、架构创新、公开评测）；- 落地与规模：真实部署、出货、商业收入、客户质量；- 开放影响力：开源模型/数据/工具对行业的影响。

#	机构	国家	核心路线	2026 代表成果	大脑前沿性	落地与规模	开放影响力	一句话身位
1	Google DeepMind	美	Gemini 母体 + ER/VLA 分层 + 跨本体	Gemini Robotics 2 / ER 2（2026.07）	★★★★★	★★★	★★★★	具身推理与通用性第一，平台路线
2	Physical Intelligence	美	VLM + 流匹配动作专家，可引导，RL 后训练	π0.7（2026.04）	★★★★★	★★	★★★★★	开源 VLA 标准答案的定义者
3	NVIDIA	美	数据金字塔 → 世界动作模型；全栈平台	DreamZero / GR00T N2 预告；N1.7	★★★★★	★★★★（生态）	★★★★★	生态之王，路线转向 WAM
4	Skild AI	美	全身体 + 上下文适应	S1 视频上下文学习（2026.08）	★★★★	★★★★（ARR 宣称 >1 亿美元）	★	最像产品公司的大脑公司
5	Generalist AI	美	人类真实数据缩放 + 和声推理	GEN-1 / GEN-1.5（2026）	★★★★★	★★	★	真实数据规模与缩放定律领先
6	特斯拉	美	FSD 统一大脑 + 世界模拟器 + 人类视频	Gen 3 早期生产（2026.10）	★★★（不可评估）	★★★（潜力★★★★★）	★	声量与量产野心第一，大脑黑箱
7	Figure AI	美	Helix 三层 + 人类经验数据	Helix 02、Helix 2.5（30 户 56%）	★★★★★	★★★	★	人形整机大脑公开证据最充分
8	1X	美/挪	世界模型即大脑	1XWM（2026.01）、NEO 量产	★★★★	★★	★★	家用人形先行者，世界模型布道者

#	机构	国家	核心路线	2026 代表成果	大脑前沿性	落地与规模	开放影响力	一句话身位
9	Boston Dynamics	美	顶级身体 + 外部大脑（TRI、DeepMind）	量产 Atlas + Gemini 合作	★★★	★★★（2028 规模化）	★★	身体最强，大脑靠合作
10	Agility Robotics	美	全身控制"运动皮层" + 务实落地	Digit 5（2026.09）、SPAC	★★	★★★★	★	最早付费部署的务实派
11	Sunday Robotics	美	手套数据（零机器人数据）+ 家用	ACT-1、Memo	★★★★	★	★	ACT/DP/UMI 作者的家用实践
12	Meta FAIR	美	JEPA 潜空间世界模型	RoboJEPA（2026.10，8B）	★★★★	★	★★★★	非生成式世界模型旗手
13	Amazon FAR	美	人形小脑工具链 + 超级用户	OmniRetarget、ResMimic、Holosoma	★★★★	★★（潜力巨大）	★★★	全球最大机器人用户的前沿研究
14	Hugging Face	美/法	开源生态中枢	LeRobot v0.6、SmolVLA	★★★	★★	★★★★★	开源机器人的"Transformers"
15	TRI	美/日	扩散策略 + 严谨评测 + 工业	Walden 分拆、丰田 40 万台计划	★★★★	★★★	★★★★	动作生成范式奠基者
16	Genesis AI	美/法	仿真为主 + 全栈	GENE-26.5、Eno	★★★	★	★★★	仿真派旗手，产品早期
17	斯坦福	美	开源基线 + 低成本数据 + 评测	BEHAVIOR 2026	★★★★★	—	★★★★★	思想与人才第一源头
18	UC Berkeley	美	RL + 开源通才 + 人形 RL	—	★★★★★	—	★★★★	RL 思想大本营
19	CMU	美	人形全身控制	BFM-Zero（ICLR 2026）	★★★★★	—	★★★★	人形小脑算法军火库
20	UCSD	美	遥操作接口 + 人类数据	HAT/PH2D	★★★★	—	★★★★	人类即人形的开拓者
21	清华大学	中	扩散基础模型 + UMI 缩放 + 创业母港	RDT2（2026.02）	★★★★★	—	★★★★	中国学术与人才第一源头
22	香港大学	中	潜在动作 + 合成基准 + 人形全身	WholeBodyVLA（ICLR 2026）	★★★★	—	★★★★	从视频学动作的学术前沿

#	机构	国家	核心路线	2026 代表成果	大脑前沿性	落地与规模	开放影响力	一句话身位
23	上海 AI Lab	中	空间推理 + 合成数据 + 全栈开源	InternVLA-A1/A1.5	★★★★	—	★★★★	国家队全栈开源
24	北京智源	中	具身推理大脑 + 跨本体 OS	RoboBrain 2.5	★★★★	—	★★★★	中国 ER 类大脑开源代表
25	字节 Seed	中	视频预训练 → VLA → 真机 RL	GR-RL；2026 扩建数据产线	★★★★★	★	★★	中国大厂学术标杆
26	阿里（达摩院 + 通义）	中	底座 + 开源大脑 + 协议	RynnBrain（30B MoE）；Qwen-VL/Wan	★★★★	—	★★★★★（底座）	具身”水电煤”
27	蚂蚁灵波	中	真机数据规模 + 世界模型 + 深度	LingBot-VLA 2.0、LingBot-World 2.0	★★★★	★	★★★★	后来者全栈开源突袭
28	腾讯	中	平台化：感知-认知-行动	Hy-Embodied-RxBrain-1.0	★★★	★★	★★★	平台派代表
29	小米	中	10 万小时 UMI + 开源 + 工厂	Xiaomi-Robotics-1	★★★★	★★	★★★★	上升最快的大厂
30	小鹏	中	车-机器人统一大脑，去语言 VLA	VLA 2.0 升级、IRON 量产准备	★★★	★★（2026 底量产）	★	中国版特斯拉路线
31	宇树	中	硬件 + 开源小脑生态 + 轻量世界模型	UnifoLM-WLA-1.0、IPO	★★★	★★★★★	★★★★★（研究平台）	身体与出货之王
32	智元	中	数据工厂 + VLA + 世界模型双线	GO-3 Preview（2026.10.29）	★★★★	★★★★★	★★★★★	出货第一，大脑布局最完整之一
33	优必选	中	工业分层智能 + 多机协同	Walker S2、Thinker	★★	★★★★	★★	工业人形落地标杆
34	美的	中	VLA 架构研究	DexVLA、ChatVLA、PointVLA	★★★★	★	★★★	家电巨头的 VLA 论文工厂
35	逐际动力	中	系统派（COSA）+ 顶级运控	COSA 0.5	★★★	★★	★★	运控强者的系统观
36	北京人形创新中心	中	开源本体 + 数据 + 大小脑	XR-1（ICML 2026）、Pelican-VL	★★★★	★★	★★★★	国家队全栈开源

#	机构	国家	核心路线	2026 代表成果	大脑前沿性	落地与规模	开放影响力	一句话身位
37	银河通用	中	仿真合成 → 三源融合；星脑 WAM	AstraBrain、ET1	★★★★	★★★	★★★	合成数据派旗手
38	星动纪元	中	视频预测 / 世界模型	Ctrl-World（ICLR 2026）	★★★★	★★★	★★★	视频预测派学术与产业先行者
39	星海图	中	开放世界数据 + 动作思维链 + 真机 RL	G0.5、Fast-WAM、G-Fleet	★★★★	★★★	★★★★	数据-模型-系统最均衡
40	自变量	中	统一模型（WUM）+ 世界模型	WALL-B、WALL-OSS-0.5	★★★★	★★	★★★★	统一模型派最激进
41	千寻智能	中	“脏数据” + 统一 VLA	Spirit v1.5 / v1.6	★★★★	★★★	★★★	RoboChallenge 冠军与 RoboArena 风波
42	智平方	中	全域全身 + 快在慢中 + 类脑	NeuroVLA	★★★	★★	★★★	架构创新最活跃之一
43	它石智航	中	人类数据 + 触觉 + 世界引擎	AWE 3.5	★★★★（待验证）	★★	★★（数据集）	中国人类数据派旗手
44	极佳视界	中	世界模型造数据 + 练策略	GigaWorld-1、GigaBrain-0.5M*	★★★	★	★★★	世界模型专精
45	原力灵机	中	评测 + 工具 + 具身原生模型	DM0、RoboChallenge	★★★★	★★	★★★★	行业”度量衡”
46	灵初智能	中	灵巧手 + 人类手部数据 + 世界模型	Psi-R2 / Psi-W0	★★★★	★★	★★★	灵巧手大脑代表
47	智在无界	中	人类视频 + 隐式世界模型	Being-H0.7	★★★★	★	★★★★	人类视频派学术旗手
48	穹彻智能	中	以力为中心 + 零遥操作世界模型	Noe-0	★★★	★★	★★★	无本体数据激进派
49	地平线 / 地瓜	中	端侧芯片 + 开源大小脑	HoloBrain-0、HoloMotion	★★★	★★★（生态）	★★★★	中国的”NVIDIA 式”平台
50	星尘智能	中	绳驱身体 + 基座 + 快慢双系统	Lumo + DuoCore、T1	★★★	★★★	★★	为 AI 设计身体

二、梯队划分（2026 年 10 月）

2.1 “大脑前沿性”梯队

梯队	成员	判断依据
T0：定义范式	Google DeepMind、Physical Intelligence、NVIDIA	持续提出被全行业采用的范式（VLA、流匹配动作专家、数据金字塔、ER/VLA 分层、世界动作模型）
T1：全球前沿	Figure、Generalist、Skild、字节 Seed、斯坦福、Berkeley、CMU、清华、Meta	有全球影响力的代表作或领先的公开结果
T1.5：快速追赶的中国头部	智元、阿里、小米、蚂蚁、星海图、自变量、千寻、星动纪元、银河、港大、上海 AI Lab、智源、北京人形、原力灵机、智在无界、灵初	开源模型在主流基准上与 π0.5 等可比，部分在第三方评测中超越
T2：特色/专精	TRI、Amazon FAR、UCSD、HF、1X、特斯拉（不可评估）、宇树、它石、极佳、智平方、美的、地平线、穹彻、腾讯、逐际、星尘、Genesis、小鹏	在特定维度（小脑、数据、世界模型、工具、平台）有突出贡献
T3：落地优先	Agility、优必选、Boston Dynamics（大脑靠合作）、Sunday（早期）	大脑以务实或合作为主

2.2 “落地与规模”梯队

梯队	成员
出货量领先	智元（2026 上半年 9700 台，公司口径）、宇树（2025 年 5500+ 台人形）
工业付费部署	Agility（GXO）、优必选（多家车企）、Figure（宝马）、星动纪元（顺丰/邮政）、千寻（宁德时代，公司口径）、智元（龙旗等）
量产准备	特斯拉（弗里蒙特早期生产）、1X（海沃德工厂）、小鹏（2026 底）、BD（2028 规模化）、小米（工厂实训）
软件收入	Skild（ARR >1 亿美元，公司口径）

三、分维度横评

3.1 具身推理（System 2）

排名	机构	代表	说明
1	DeepMind	Gemini Robotics-ER 1.5/1.6/2	15 个基准综合领先（1.5），工具调用、多机编排、任务进度追踪

排名	机构	代表	说明
2	阿里	RynnBrain（30B MoE）	时空记忆 + 物理接地，宣称超越 ER 1.5 与 Cosmos Reason 2
2	智源	RoboBrain 2.5	3D 度量推理 + 稠密价值预测
4	字节	Robix	推理 + 规划 + 交互
4	NVIDIA	Cosmos Reason 2	物理常识，GR00T 主干
6	北京人形	Pelican-VL（72B）	DPPO 刻意练习
6	腾讯	HY-Embodied-0.5（A32B）/ RxBrain	22 基准平均 67.0%（自报超过 Gemini 3.0 Pro）；语言推理 + 视觉想象
6	上海 AI Lab	InternVLA-M1 规划器	空间引导

3.2 操作 VLA（System 1）

排名	机构	代表	说明
1	PI	π0.7	可引导、组合泛化、RL 后训练体系
1	Figure	Helix 02 / 2.5	全身 200Hz、家庭零样本
3	DeepMind	Gemini Robotics 2	全身 + 五指手，公开成功率
3	Generalist	GEN-1 / 1.5	99% 可靠性、一次学会（公司口径）
5	字节	GR-3 / GR-RL	穿鞋带 83.3%
5	智元	GO-2 / GO-3 Preview	动作思维链、WRAM
5	小米	Xiaomi-Robotics-1	10 万小时 UMI
5	星海图	G0.5	原生动作思维链
5	蚂蚁	LingBot-VLA 2.0	6 万小时、20+ 构型
5	千寻	Spirit v1.5	RoboChallenge 第一（2026.01）

3.3 世界模型

流派	领先者
视频-动作联合生成	NVIDIA DreamZero（GR00T N2）、字节 GR 系列（早期）
视频生成 + IDM	1X 1XWM、清华 Vidar
隐式/潜空间	Meta RoboJEPA、智在无界 Being-H0.7、宇树 WLA
神经模拟器（评估/RL）	特斯拉、星动纪元 Ctrl-World、智元 GE-Sim、蚂蚁 LingBot-World、自变量 WALL-SS
造数据	NVIDIA Cosmos、极佳 GigaWorld
融合到统一大脑	智元 WRAM、自变量 WALL-B、它石 AWE、银河 AstraBrain WAM

3.4 全身控制（System 0）

领先者	代表
Figure	Helix 02 S0（1kHz，1000+ 小时动捕）
NVIDIA	SONIC（开源）
Boston Dynamics + RAI	Atlas RL（每技能约 1.5 亿次仿真）
CMU	H2O / ASAP / BFM-Zero
宇树	开源 RL 生态 + 高动态表演
逐际	点足双足起家的 System 0
Amazon FAR	OmniRetarget / ResMimic / Holosoma
地平线	HoloMotion（视频重建动作）

3.5 数据规模（公开宣称）

量级	机构
百万小时级（宣称）	它石（目标千万小时）、银河（人类 100 万小时）、Figure Index（采集速率）
十万小时级	Generalist（50 万+）、Being-H0.7（20 万）、小米（10 万 UMI）、穹彻（十万小时级）
万小时级	蚂蚁（6 万）、RxBrain（5 万+）、Being-H0.5（3.5 万）、PI（1 万+）、RDT2（1 万+）

3.6 开源影响力

层级	机构
改变行业基线	PI（openpi）、NVIDIA（GR00T、Cosmos、SONIC）、HF（LeRobot）、阿里（Qwen-VL、Wan）、智元（AgiBot World）、宇树（RL 生态）、斯坦福（OpenVLA）、Berkeley（Octo）
国内主流选择	上海 AI Lab、智源、蚂蚁、小米、星海图、自变量、千寻、原力灵机、北京人形、智在无界、地平线

四、六组关键对决

4.1 PI vs DeepMind：同门之争

两者都源于 Google RT 系列。DeepMind 依托 Gemini，强在推理、语言与安全；PI 依托开源 VLM 做小而精的模型，强在动作质量、数据配方与 RL。判断：在”通用常识与推理”上 DeepMind 领先，在”动作可靠性与方法论影响力”上 PI 领先；商业化上两者都尚未证明。

4.2 Figure vs 特斯拉：美国整机双雄

Figure 公开了详细的架构与严格的家庭评测（30 户、56%）、11 个月宝马部署；特斯拉几乎不公开，但拥有量产、数据与芯片的全部要素。判断：截至 2026 年 10 月，Figure 在”可验证的大脑能力”上领先；2027 年特斯拉若实现规模化交付，数据飞轮可能逆转格局。

4.3 NVIDIA vs 世界模型创业公司

NVIDIA 以 DreamZero/GR00T N2 定义"世界动作模型"，同时开源 Cosmos。中国的极佳、星动纪元、智在无界、蚂蚁，以及美国的 1X，都在同一方向竞争。判断：NVIDIA 的平台与算力优势巨大；创业公司的机会在于垂直场景的数据闭环与端侧效率（如 Fast-WAM、Being-H-Flash）。

4.4 智元 vs 宇树：中国本体双雄

智元：出货第一（公司口径）、大脑布局最完整（数据集 + VLA + 世界模型 + OS + 智能体框架）。宇树：身体与研究平台之王、IPO、开源小脑生态，大脑起步稍晚但 WLA-1.0 有特色。判断：智元更像"中国的 Figure + NVIDIA 数据生态"，宇树更像"中国的研究平台 + 低成本整机之王"；两者在 2027 年的竞争焦点将是"部署态数据飞轮"。

4.5 人类数据派内部：Generalist vs 它石 vs Sunday vs 智在无界

	Generalist	它石	Sunday	智在无界
数据	人类交互设备 50 万小时 +	人类 + 触觉，百万小时（宣称）	手套，1000 万片段	人类视频 20 万小时
模型	和声推理	世界引擎	ACT-1	隐式世界模型
公开证据	博客 + 多项宣称	发布会 + 数据集	博客	论文 + 开源
场景	通用授权	工业线束	家庭	研究 + 端侧

判断：Generalist 的公开结果最亮眼；智在无界的学术与开源最扎实；它石的数据规模宣称最大但待验证；Sunday 的软硬协同最紧。

4.6 系统派 vs 端到端派

逐际 COSA、智源 RoboOS、腾讯 Tairos、优必选 Co-Agent（系统派）vs PI、Generalist、自变量 WALL-B（端到端/统一派）。判断：短期（2026–2027）系统派在工业落地中更可控；长期若端到端模型持续涌现新能力（上下文学习、组合泛化），系统层可能被大幅"吸收"进模型——但安全反射与多机编排等功能仍可能保留在系统层。

五、一张"路线谱系图"




数据：遥操作 → UMI/手套 → 人类视频 → 仿真/世界模型生成 → 部署回流
超越模仿：RECAP / GR-RL / HIL-SERL / DPPO / RAMP / 模型内 RL / G-Fleet
全身控制：动作追踪 + 仿真 RL（SO）—— SONIC / Helix S0 / BFM-Zero / HoloMotion
系统层：ER / OS / 智能体 —— Gemini ER 2 / RoboOS / COSA / Tairos / Genie Master

---

第三部分（下）趋势、预测与建议

> 本章包含两类内容：（一）已发生的趋势——基于前 50 章的事实归纳；（二）对未来的预测——属于本报告的分析判断（E 级），附带置信度与需要观察的信号，供读者自行校准。

一、2026 年的十大趋势（已发生）

趋势 1：三层大脑成为共识

Figure Helix 02（S0/S1/S2）、逐际 COSA（System 0/1/2）、NVIDIA（Cosmos Reason / GR00T / SONIC）、DeepMind（ER / VLA / On-Device + 外部控制器）、银河（大脑-脑桥-小脑）、智平方（皮层-小脑-脊髓）——2026 年几乎所有头部玩家都采用了”推理 / 视觉运动 / 全身控制”的三层结构。（第 7、35、3、1、37、42 章）

趋势 2：VLA 与世界模型的融合

从”VLA 或世界模型”的路线之争，走向”VLA + 世界模型”的融合：π0.7 用世界模型生成子目标；GR00T N2 以世界动作模型为主干；智元 WRAM、宇树 WLA、自变量 WALL-B、它石 AWE、银河 AstraBrain WAM 都把”预测未来”作为大脑的原生能力。2026 年 9–10 月，中美至少五家公司几乎同时发布或预告了统一”推理 + 预测 + 动作”的架构。（第 2、3、32、31、40、43、37 章）

趋势 3：数据从”遥操作”走向”人类与无本体”

数据规模在两年间增长约两个数量级（万小时 → 十万至百万小时），增量几乎全部来自人类第一视角视频、UMI/手套类无本体采集与触觉数据。Generalist（50 万小时+）、小米（10 万小时 UMI）、Being-H0.7（20 万小时）、它石（百万小时宣称）、Figure Index、穹彻 Noe-0（零遥操作）是代表。（第 5、29、47、43、7、48 章）

趋势 4：缩放定律在机器人领域得到多维验证

数据多样性缩放（清华、π0.5）、真实数据规模缩放（GEN-0、Xiaomi-Robotics-1）、世界模型规模缩放（RoboJEPA）、运动控制缩放（SONIC）——机器人领域第一次有了”继续投入会可预测变好”的证据，这直接驱动了 2026 年的资本洪流。（第 41、2、5、29、12、3 章）

趋势 5：强化学习进入大模型后训练

π*0.6 RECAP、GR-RL、Pelican-VL DPPO、GigaBrain-0.5M* RAMP、AWE 3.5 模型内 RL、星海图 G-Fleet——“预训练 + 模仿后训练 + RL 后训练” 成为标准三段式，与 LLM 的发展路径高度同构。（第 2、25、36、44、43、39 章）

趋势 6：上下文学习出现

Skild S1（一段视频，10 分钟任务，66% vs 语言提示 9%）、GEN-1.5（3–12 秒示范，一次学会，59%→微调后 83%）——机器人出现了"给示范就会做"的能力，部署方式可能从"采数据→训模型"转向"给示范→直接做"。（第 4、5 章）

趋势 7：全身与灵巧

Gemini Robotics 2 把全身与五指手纳入 VLA；Helix 02 全身自主；特斯拉 22 自由度手；灵初、星动纪元、Sunday、Genesis 等聚焦灵巧手与触觉。但公开数据显示灵巧装配类任务成功率仍在 30%–45% 区间（Gemini Robotics 2 拧灯泡 36%、系袋子 44%），"拆"远比"装"容易。（第 1、7、6、46、38 章）

趋势 8：从演示态到部署态

智元"部署态"与 Worken、优必选工厂实训、Figure 宝马、Agility GXO、千寻宁德时代、星动纪元物流中心、小米汽车工厂——行业叙事从"能演示"转向"能上班、能持续工作、能持续学习"。（第 32、33、7、10、41、38、29 章）

趋势 9：评测进入"榜单时代"并遭遇信任危机

RoboChallenge、RoboArena、RoboDojo、BEHAVIOR、MolmoSpaces、WorldArena……评测平台大量出现；"登顶"成为融资营销工具；2026 年 6 月 RoboArena 操纵事件引发行业反思。（第 45、41、17 章）

趋势 10：中国在开源、出货与资本上的全面加速

2026 年上半年中国人形出货近 2 万台（IDC）；Qwen 成为全球最常用具身 VLM 底座之一；中国公司开源模型数量与频率全球领先；宇树 IPO、它石单轮 4.55 亿美元、星动纪元年内近 50 亿元……中国在"规模与开放"上领先，美国在"前沿范式与单点深度"上领先。（第 1 部分第七节）

二、未来 12–36 个月预测（本报告判断）

> 置信度：高（≥70%）、中（40%–70%）、低（<40%）

2.1 技术

#	预测	时间	置信度	需要观察的信号
T1	"推理 + 世界预测 + 动作"的统一架构成为新发布旗舰模型的主流（超过半数头部公司采用）	2027 年内	高	GR00T N2 正式发布表现；GO-3 年底开源；π0.8/π1 的架构
T2	至少一家公司公开展示在多个全新任务上、仅凭一次示范、整任务成功率 >80% 的上下文学习	2027 年内	中	Skild S2、GEN-2、π 系列的 ICL 结果

#	预测	时间	置信度	需要观察的信号
T3	真实家庭场景（陌生家庭、零样本、整任务）成功率达到 75%+ 的公开评测出现	2027–2028	中	Figure Helix 3、BEHAVIOR 2027、第三方家庭评测
T4	灵巧装配类任务（插接、旋入、线束）在受控产线上达到 99%+ 且有第三方或客户验证	2027	中	它石/千寻线束、GO 系列产线、特斯拉工厂
T5	端侧（单芯片）实时运行 10B 级世界动作模型成为可能	2028	中	AI5、Thor 后继、地平线新一代 RDK
T6	车队级"部署中持续学习"（多台机器人数据回流→RL→OTA 更新）在至少一家公司形成可量化的闭环	2027	中	智元 Genie Evolver、星海图 G-Fleet、PI RECAP、特斯拉
T7	纯遥操作数据在新旗舰模型预训练中的占比降至 20% 以下	2027	高	各家技术报告的数据配比
T8	出现被广泛接受的第三方、盲测、大样本具身评测标准（类似 ImageNet/LMSYS 的地位）	2027–2028	中	RoboChallenge/RoboArena 治理改革、学术联盟评测

2.2 产业

#	预测	时间	置信度	需要观察的信号
I1	全球人形年出货量突破 10 万台	2027	中	智元、宇树、特斯拉、优必选、小米、Figure 的实际交付
I2	特斯拉对外交付 Optimus	2027 年底前后	中	AI5 集成（约 2027.04）、弗里蒙特产能爬坡
I3	至少一家纯大脑公司（PI / Skild / Generalist）年收入超过 5 亿美元	2028	低–中	Pi API、Skild ARR、Generalist 授权
I4	中国出现 3 家以上市值/估值超过 1000 亿元的人形/具身公司	2027	中	宇树上市表现、智元、银河、星海图等估值
I5	家用人形以"无需遥操作兜底"的方式向普通消费者规模交付（>1 万台）	2028 年后	低	1X、Figure、Sunday、自变量的家庭可靠性

#	预测	时间	置信度	需要观察的信号
I6	OpenAI、Meta、Amazon 中至少一家推出自有人形或人形大脑产品	2027	中	OpenAI 2027 演示、Meta Reality Labs、Amazon FAR
I7	行业出现一次重大整合（头部大脑公司被收购或大规模合并）	2027–2028	中	估值回调、融资环境

三、五个最关键的不确定性

1. 世界模型 vs VLA 的最终形态：视频生成式世界模型的算力成本与物理一致性问题能否解决？隐式世界模型能否在复杂任务上胜出？
2. 人类数据的天花板：人手与机器人手的形态鸿沟（自由度、力、触觉、速度）是否会让人类数据在高精度任务上触顶？
3. 可靠性的最后一公里：从 90% 到 99.9% 需要的是更多数据、更大模型、RL，还是根本性的新方法（触觉闭环、形式化安全）？
4. 评测与真实价值的脱节：榜单进步能否转化为客户愿意付费的生产力（Worken 式度量能否成立）？
5. 地缘与算力：高端 GPU 出口管制、开源模型的跨境合规，会如何影响中美两条技术生态的分化？

四、给不同读者的建议

4.1 投资人

- 看数据飞轮，而不只看模型：2026 年的头部玩家都在建"部署 → 回流 → 训练"的闭环；没有数据飞轮的大脑公司，壁垒会被开源快速侵蚀；
- 对榜单宣称打折：优先看严格定义的整任务成功率、第三方盲测、客户复购与部署时长；
- 关注"小脑"与基础设施：全身控制、灵巧手、触觉、端侧芯片、数据采集设备、评测平台，往往比"大脑"更早产生确定性收入；
- 区分三类估值逻辑：纯大脑公司（平台/API 逻辑）、整机公司（出货与毛利逻辑）、数据公司（数据资产逻辑）。

4.2 创业者

- 避开与平台正面竞争：通用 VLA 底座的竞争已高度集中（PI、DeepMind、NVIDIA、阿里、智元等）；
- 机会在"场景 × 数据 × 本体"的垂直闭环：线束装配、物流、零售、医院、实验室等场景的专有数据与可靠性；
- 认真对待"部署态"：可靠性、可维护性、安全认证、遥操作兜底策略，决定能否拿到第二笔订单。

4.3 研究者

- 高价值开放问题：①人-机形态迁移；②触觉与力的大规模学习；③世界模型的物理正确性与效率；④长时程记忆；⑤上下文学习的机理；⑥可信、低方差的真机评测方法；⑦安全（语义安全 + 物理安全）；

- 善用开源底座：openpi、GR00T、LeRobot、InternVLA、RDT2、WALL-OSS-0.5、DM0、Being-H、UnifoLM 等已提供了强基线，学术研究可以把精力放在"方法"而非"复现"。

4.4 产业方（制造、物流、零售等）

- 先从"半结构化、高重复、高人力成本"的工序切入（料箱搬运、线束、分拣）；
- 要求供应商提供可量化的可靠性与吞吐数据（整班次成功率、平均干预间隔、节拍）；
- 把你的工厂当作数据资产：与供应商谈判数据所有权与使用权——在 2026 年，真实场景数据是最稀缺的资源。

五、结语

2026 年的人形机器人大脑，像极了 2019–2020 年的大语言模型：缩放定律刚刚被证实、架构正在收敛、上下文学习初现端倪、资本蜂拥而至、评测体系尚不成熟、真实世界的价值尚待证明。

区别在于，物理世界没有"互联网语料"可以直接下载——数据必须一小时一小时地从真实世界中采集出来，可靠性必须一次一次地在真实工厂与家庭里验证出来。这决定了机器人的"GPT 时刻"可能不会以一次发布的方式到来，而会以一条渐进但加速的曲线到来：先是工厂里的某一道工序，再是仓库里的某一类任务，然后是某一种家务……

谁能把"模型的缩放定律"与"部署的数据飞轮"同时转动起来，谁就会定义下一个十年。

附录

附录 A：人形机器人大脑大事年表（2016–2026.10）

时间	事件	章节
2016	CMU"5 万次尝试、700 机器人小时"抓取自监督学习	4、19
2017	Covariant 成立；Cassie 双足发布（Agility 前身研究平台）	13、10
2018	Google QT-Opt：58 万次真实抓取的离线 RL	1
2019	Agility Digit 首次亮相	10
2021	RMA 快速运动适应；Cassie RL 跑完 5 公里；特斯拉 AI Day 宣布 Tesla Bot	4、10、6
2022.04	SayCan：LLM 规划 + 价值函数	1
2022.12	RT-1：13 万条示范的 Robotics Transformer	1
2023.03	Diffusion Policy；PaLM-E	15、1
2023.04	ALOHA / ACT	11、17
2023.07	RT-2：VLA 诞生	1
2023.10	Open X-Embodiment（OXE）	1
2023.12	GR-1 视频生成预训练；Optimus Gen 2	25、6
2024.01	Mobile ALOHA	11、17
2024.03	Covariant RFM-1；Project GR00T 宣布；Figure × OpenAI 演示	13、3、7
2024.04	电动 Atlas 发布	9
2024.05	Octo；LeRobot 发布	18、14
2024.06	OpenVLA；HumanPlus；H2O/OmniH2O	17、19
2024.07	Skild AI A 轮（15 亿美元估值）；GRUtopia	4、23
2024.08–09	亚马逊吸纳 Covariant 创始人；Astribot S1 发布	13、50
2024.10	π0；RDT-1B；GR-2；TRI × BD 合作；We, Robot 发布会	2、21、25、9、6
2024.12	Genesis 物理引擎开源；ERA-42；Meta Motivo；RoboMIND；Psi R0；VPP	16、38、12、36、46
2025.01	π0-FAST；Cosmos；GraspVLA	2、3、37
2025.02	Figure 与 OpenAI 分手 → Helix；openpi 开源；DexVLA / ChatVLA；DexGraspVLA	7、2、34、46

时间	事件	章节
2025.03	GR00T N1；Gemini Robotics / ER；GO-1 / AgiBot World；RoboBrain + RoboOS；RAI × BD	3、1、32、24、9
2025.04	π0.5；AlphaBrain；PointVLA（03）	2、42、34
2025.05	GR00T N1.5；DreamGen；Knowledge Insulation；UniVLA；TrackVLA	3、2、22、37
2025.06	V-JEPA 2；Gemini Robotics On-Device；SmolVLA；Redwood AI；WorldVLA；FiS-VLA；RTC；GroceryVLA	12、1、14、8、26、42、2、37
2025.07	GR-3 + ByteMini；Skild Brain；LBM 严谨评测（TRI）；RoboBrain 2.0；Astribot Suite；Being-H0；H-RDT	25、4、15、24、50、47、49
2025.08	Atlas LBM；Genie Envisioner；G0 + 开放世界数据集；RynnVLA-001 / RynnEC / RynnRCP；Agility 全身控制模型	9、32、39、26、10
2025.09	Gemini Robotics 1.5；WALL-OSS；Robix；NavFoM；Figure Project Go-Big；Figure C 轮（390 亿美元）；UnifoLM-WMA-0	1、40、25、37、7、31
2025.10	Figure 03；1X NEO 预售；InternVLA-M1；Ctrl-World；ICCV 特斯拉神经世界模拟器；Dexbotic	7、8、23、38、6、45
2025.11	π*0.6 / RECAP；GEN-0（27 万小时）；SONIC；MiMo-Embodied；Pelican-VL；Video2Act；Sunday ACT-1；Walker S2 量产；小鹏 VLA 2.0 + IRON；HoloMotion；OmniRetarget/ResMimic（09–10）；PI B 轮（56 亿美元）	2、5、3、29、36、42、11、33、30、49、13
2025.12	GR-RL（穿鞋带）；XR-1 开源；Holosoma；WIYH 数据集；WholeBodyVLA；RoboBrain 2.5（技术报告，12–01）	25、36、13、43、22、24
2026.01	Helix 02；1XWM；Spirit v1.5 登顶 RoboChallenge；LingBot-VLA/World/Depth；UnifoLM-VLA-0；Being-H0.5；InternVLA-A1；BD × DeepMind（CES）；Skild C 轮（140 亿美元+）；LimX COSA	7、8、41、27、31、47、23、9、4、35
2026.02	DreamZero；Xiaomi-Robotics-0；RynnBrain；DM0；RDT2；HoloBrain-0；G0 Plus；GigaBrain-0.5M*	3、29、26、45、21、49、39、44

时间	事件	章节
2026.03	GTC 预告 GR00T N2；MEM；AWE 3.0；PI 洽谈 110 亿美元+ 估值；宇树 IPO 受理；GigaWorld-1；星动纪元估值破百亿	3、2、43、31、44、38
2026.04	π0.7；GO-2；GEN-1；WALL-B；Being-H0.7；Psi-R2 / Psi-W0；HY-Embodied-0.5；Gemini Robotics-ER 1.6；NeuroVLA；它石 4.55 亿美元 Pre-A；1X 海沃德工厂量产	2、32、5、40、47、46、28、1、42、43、8
2026.05	WALL-OSS-0.5；WALL-WM；GENE-26.5；HoloMotion-1 报告；OpenAI 机器人团队组建（报道）	40、16、49、6
2026.06	Spirit v1.6 / RoboArena 事件；G0.5 发布；HyVLA-0.5；Eno；Figure 03 进驻宝马；Agility SPAC；星尘 B 轮	41、39、28、16、7、10、50
2026.07	Gemini Robotics 2 / ER 2；Xiaomi-Robotics-1；LingBot-VLA 2.0 / World 2.0；AWE 3.5；RxBrain；COSA 0.5；LeRobot v0.6 + GR00T 1.7；Walden Robotics；逐际 Pre-IPO；Generalist 多末端执行器	1、29、27、43、28、35、14、15、35、5
2026.08	Skild S1；GEN-1.5；Figure Index；G0.5 复现计划 + Fast-WAM + G-Fleet；Galbot ET-1；小米新一代铁大；WALL-SS；宇树科创板上市（08.19）；小鹏机器人融资；VLA 2.0 升级	4、5、7、39、37、29、40、31、30
2026.09	Helix 2.5（30 户家庭 56%）；UnifoLM-WLA-1.0；Digit 5；丰田 40 万台计划；BD 佐治亚应用中心；Figure F.02 退役；OpenAI 确认人形（播客）	7、31、10、15、9、6
2026.10	RoboJEPA（8B）；特斯拉 Q3 电话会：Optimus 早期生产；星尘估值约 150 亿元；10.29 智元 GO-3 Preview + WITA-OMNI + Worken；10.13 PI 开放 Pi API 测试版（托管微调与推理）	12、6、50、32、2

附录 B：150 项代表作索引

> 格式：章节｜机构｜代表作（时间）｜类型｜关键标识

章	机构	代表作一	代表作二	代表作三
1	Google DeepMind	RT-2（2023.07，论文，arXiv 2307.15818）	Gemini Robotics 1.0 → 1.5（2025.03/09，技术报告，arXiv 2503.20020 / 2510.03342）	Gemini Robotics 2 / ER 2 / On-Device 2（2026.07，官方博客）
2	Physical Intelligence	π0 + openpi（2024.10，arXiv 2410.24164）	π0.5 + KI（2025.04–05，arXiv 2504.16054）	π0.7（2026.04，arXiv 2604.15483；前置 π*0.6 arXiv 2511.14759、MEM arXiv 2603.03596）
3	NVIDIA	GR00T N1 → N1.7（2025.03–2026，arXiv 2503.14734）	Cosmos WFM + DreamGen（2025.01/05，arXiv 2501.03575）	DreamZero → GR00T N2（2026.02，arXiv 2602.15922）
4	Skild AI	Skild Brain（2025.07，博客/视频）	跨身体上下文适应（2025.09）	S1 视频上下文学习（2026.08，官方博客）
5	Generalist AI	GEN-0（2025.11，官方博客）	GEN-1（2026.04）	GEN-1.5（2026.08）
6	特斯拉	FSD 端到端 + 神经世界模拟器（ICCV 2025 主题演讲等）	人类第一视角视频学习（2025）	Optimus Gen 3 + AI5 + 百万台产线（2026）
7	Figure AI	Helix（2025.02，技术博客）	Helix 02（2026.01）	Helix 2.5 + Index（2026.08–09）
8	1X	1X World Model + 挑战赛（2024）	Redwood AI（2025）	1XWM 作为策略（2026.01）
9	Boston Dynamics	Atlas LBM（2025.08，与 TRI）	动捕 RL 全身运动（2025，与 RAI）	量产 Atlas + Gemini + Metaplant（2026）
10	Agility	双足 RL sim2real（ICRA/RSS 2021）	全身控制基础模型（2025）	Digit 5（2026.09）
11	Sunday	ALOHA/ACT（RSS 2023，arXiv 2304.13705）	UMI（RSS 2024，arXiv 2402.10329）	ACT-1 + 技能采集手套（2025.11）
12	Meta FAIR	Meta Motivo（arXiv 2504.11054）	V-JEPA 2（2025.06）	RoboJEPA（2026.10，arXiv 2610.10515）
13	Amazon FAR	RFM-1（Covariant，2024.03）	OmniRetarget（arXiv 2509.26633）	ResMimic（arXiv 2510.05070）+ Holosoma
14	Hugging Face	LeRobot（2024）	SmolVLA（arXiv 2506.01844）	LeRobot v0.6（2026.07）
15	TRI	Diffusion Policy（RSS 2023，arXiv 2303.04137）	LBM 严谨评测（arXiv 2507.05331）	Atlas LBM / Walden / 丰田 40 万台（2025–2026）

章	机构	代表作一	代表作二	代表作三
16	Genesis AI	Genesis 物理引擎（2024.12）	GENE-26.5（2026.05）	Eno（2026.06）
17	斯坦福	OpenVLA / OFT（arXiv 2406.09246 / 2502.19645）	HumanPlus（arXiv 2406.10454）	BEHAVIOR-1K / Challenge（arXiv 2403.09227）
18	UC Berkeley	Octo（arXiv 2405.12213）	HIL-SERL（arXiv 2410.21845）	人形 RL Transformer 系列（arXiv 2303.03381 / 2402.19469）
19	CMU	H2O / OmniH2O（arXiv 2403.04436 / 2406.08858）	ASAP（arXiv 2502.01143）	BFM-Zero（arXiv 2511.04131）
20	UCSD	ExBody / ExBody2（arXiv 2402.16796 / 2412.13196）	Open-TeleVision（arXiv 2407.01512）	Humanoid Policy ~ Human Policy（arXiv 2503.13441）
21	清华	RDT-1B（arXiv 2410.07864）	Vidar（arXiv 2507.12898）	RDT2（arXiv 2602.03310）
22	港大	UniVLA（arXiv 2505.06111）	RoboTwin 2.0（arXiv 2506.18088）	WholeBodyVLA（arXiv 2512.11047）
23	上海 AI Lab	GRUtopia（arXiv 2407.10943）	InternVLA-M1（arXiv 2510.13778）	InternVLA-A1 / A1.5（arXiv 2601.02456）+ N1（arXiv 2512.08186）
24	智源	RoboBrain 1.0 + RoboOS（CVPR 2025）	RoboBrain 2.0（arXiv 2507.02029）	RoboBrain 2.5（arXiv 2601.14352）
25	字节 Seed	GR-1 / GR-2（arXiv 2312.13139 / 2410.06158）	GR-3 + ByteMini（arXiv 2507.15493）	GR-RL（arXiv 2512.01801）+ Robix
26	阿里	WorldVLA + RynnVLA-001（arXiv 2506.21539）	RynnEC + RynnRCP（2025.08）	RynnBrain（arXiv 2602.14979）
27	蚂蚁灵波	LingBot-VLA 1.0 → 2.0（2026.01 / 07）	LingBot-World 1.0 → 2.0（arXiv 2601.20540）	LingBot-Depth（2026.01）
28	腾讯	Tairos（2025.07）	HY-Embodied-0.5（arXiv 2604.07430）+ HyVLA-0.5	Hy-Embodied-RxBrain-1.0（2026.07）
29	小米	MiMo-Embodied（arXiv 2511.16518）	Xiaomi-Robotics-0（arXiv 2602.12684）	Xiaomi-Robotics-1（2026.07）
30	小鹏	世界基座模型 720 亿参数（2025.04）	第二代 VLA（2025.11 / 2026.08 升级）	IRON（2025.11）
31	宇树	开源运动控制生态（unitree_rl_gym 等）	UnifoLM-WMA-0（2025.09）	UnifoLM-WLA-1.0（2026.09）

章	机构	代表作一	代表作二	代表作三
32	智元	AgiBot World + GO-1（2025.03）	Genie Envisioner（arXiv 2508.05635）	GO-2（2026.04）→ GO-3 Preview（2026.10.29）
33	优必选	群脑网络 BrainNet	Co-Agent	Thinker
34	美的	DexVLA（arXiv 2502.05855）	ChatVLA / ChatVLA-2（arXiv 2502.14420）	PointVLA（arXiv 2503.07511）
35	逐际动力	System 0 全身运动基础模型	System 1 VLA/WAM + FluxVLA Engine	LimX COSA / COSA 0.5（2026）
36	北京人形	RoboMIND（arXiv 2412.13877）	Pelican-VL 1.0（arXiv 2511.00108）	XR-1（arXiv 2511.02776）
37	银河通用	GraspVLA（arXiv 2505.03233）	NavFoM（arXiv 2509.12129）	银河星脑 AstraBrain（2026）
38	星动纪元	VPP（arXiv 2412.14803）	ERA-42 + UP-VLA	Ctrl-World（arXiv 2510.10125）
39	星海图	G0 + GOD（arXiv 2509.00576）	G0 Plus（2026.02）	G0.5 + Fast-WAM + G-Fleet（2026）
40	自变量	WALL-OSS → 0.5（arXiv 2509.11766 / 2605.30877）	WALL-B（2026.04）	WALL-WM + WALL-SS（2026）
41	千寻智能	数据缩放定律（arXiv 2410.18647）	Spirit v1.5（2026.01）	Spirit v1.6 / RoboArena 事件（2026.06）
42	智平方	GOVLA + FiS-VLA（arXiv 2506.01953）	Video2Act（2025.11）	NeuroVLA（2026.04）
43	它石智航	WIYH 数据集（2025.12）	AWE 3.0（2026.03）	AWE 3.5（2026.07）
44	极佳视界	GigaWorld-0（2025.11）	GigaBrain-0（2025.10）	GigaBrain-0.5M* + GigaWorld-1 / Policy（2026）
45	原力灵机	RoboChallenge（2025）	Dexbotic / 2.0	DM0（arXiv 2602.14974）
46	灵初智能	DexGraspVLA（arXiv 2502.20900）	Psi-R1（2025）	Psi-R2 + Psi-W0（2026.04）
47	智在无界	Being-H0（2025.07）	Being-H0.5（arXiv 2601.12993）	Being-H0.7（2026.04）
48	穹彻智能	AnyGrasp + RH20T（arXiv 2212.08333 / 2307.00595）	Noematrix Brain 2.0（2025.07）	Noe-0（2026）
49	地平线	H-RDT（arXiv 2507.23523）	HoloMotion（arXiv 2605.15336）	HoloBrain-0（arXiv 2602.12062）

章	机构	代表作一	代表作二	代表作三
50	星尘智能	Astribot S1（2024.08）	Astribot Suite / DuoCore-WB（arXiv 2507.17141）	Lumo + DuoCore（2026）

> 注：arXiv 编号来自检索核验或公开记录，个别编号（已在相应章节核验说明中标注）建议以论文页面为准。

附录 C：术语表

术语	英文	含义
VLA	Vision-Language-Action	视觉-语言-动作模型：输入图像与语言，输出机器人动作
VLM	Vision-Language Model	视觉语言模型，VLA 的常见”母体”
ER	Embodied Reasoning	具身推理：空间理解、指点、轨迹、任务进度等
WAM	World Action Model	世界动作模型：联合预测未来世界状态与动作（注意：逐际语境中 WAM 指”全身动作模型”）
WUM	World Unified Model	世界统一模型（自变量 WALL-B 提出）
WRAM	World Reasoning Action Model	世界推理动作模型（智元 GO-3 提出）
WLA	World-Language-Action	世界-语言-动作（宇树 UnifoLM-WLA 提出）
动作专家	Action Expert	VLA 中专门生成动作的子网络
流匹配	Flow Matching	学习从噪声到数据的速度场的生成方法
扩散策略	Diffusion Policy	用扩散模型生成机器人动作
动作分块	Action Chunking	一次预测未来多步动作
FAST	Frequency-space Action Sequence Tokenization	PI 的频域动作分词器（注意：智在无界另有同名人形控制框架）
RVQ	Residual Vector Quantization	残差向量量化
潜在动作	Latent Action	从视频相邻帧学习的离散动作码
双系统	Dual System	慢推理（System 2）+ 快执行（System 1）
三层大脑	S0/S1/S2	全身控制 / 视觉运动 / 推理
知识隔离	Knowledge Insulation (KI)	截断动作专家到 VLM 的梯度以保护 VLM 知识
RECAP	RL with Experience & Corrections via Advantage-conditioned Policies	PI 的优势条件化强化学习
IDM	Inverse Dynamics Model	逆动力学模型：由前后状态推断动作
sim2real	Simulation to Reality	仿真到真实迁移

术语	英文	含义
运动追踪	Motion Tracking	让机器人追踪参考动作（人形 S0 的主流训练任务）
重定向	Retargeting	把人体动作映射到机器人骨架
UMI	Universal Manipulation Interface	手持夹爪无本体数据采集接口
遥操作	Teleoperation	人远程操控机器人采集示范
上下文学习	In-Context Learning (ICL)	不更新权重，从提示（如示范视频）中学会新任务
组合泛化	Compositional Generalization	把已知技能与已知本体/场景组合出未见过的能力
OXE	Open X-Embodiment	多机构联邦机器人数据集
JEPA	Joint-Embedding Predictive Architecture	联合嵌入预测架构（LeCun），在表征空间预测
SNN	Spiking Neural Network	脉冲神经网络
Worken	—	智元提出的"有效智能工作时长"度量
RaaS	Robots as a Service	机器人即服务

附录 D：研究方法与局限声明

1. 信息截止：2026 年 10 月 30 日。
2. 核验方法：以论文原文的已知内容为基础，对 2025 年下半年至 2026 年 10 月的关键事实，通过网络检索获取原文摘录进行多源交叉核实；每家公司 2–4 轮检索。
3. 访问限制：研究环境无法直接打开部分网站原文（如 arXiv 全文页、部分公司官网），事实核验主要依赖检索引擎提供的原文摘录；未能逐字核实的数字已在各章"核验说明"中注明。
4. 公司口径：大量 2026 年的成绩来自公司自评或自有榜单，本报告统一标注为"公司口径/宣称"，读者应谨慎对待。
5. 评级与预测：第 90、91 章中的评级、梯队与预测为本报告的分析判断，不构成投资建议。
6. 遗漏：具身智能领域发展极快，2026 年 10 月下旬至撰写日之间的少量发布可能未被覆盖；50 家之外仍有大量优秀团队（如 OpenAI、Apptronik、傅利叶、Dyna、乐聚、众擎、加速进化、帕西尼、光轮智能、北大与上海交大的多个实验室等）。